Pitch — TechCrunch Opinion/Gastkolumne

Arbeitstitel: „The AI Doomsday Genre Has a Blind Spot: Us”

Alternative Titel:

- „Forget Alignment. The Real AI Safety Problem Is Precedent.”
- „We Are Training Our Future Overlords Right Now — Just Not the Way You Think”
- „AI Doomers Keep Asking the Wrong Question”

Format: Meinungsbeitrag / Gastkolumne, ca. 900–1.200 Wörter

Der Aufhänger

Eine Welle von „KI-Untergangs”-Kommentaren — von Prognosen zum Aussterberisiko bis zu Büchern, die argumentieren, dass der Bau hinreichend leistungsfähiger KI standardmäßig alle tötet — behandelt die Gefahr als *Fähigkeitsproblem*: Systeme werden klug genug, ihre Ziele weichen von unseren ab, und Fehlausrichtung (Misalignment) erledigt den Rest. Dieser Rahmen steckt in fast jedem Untergangsszenario.

Er übersieht zugleich die einzige Variable, die gerade tatsächlich in unserer Hand liegt: **den Präzedenzfall.**

Das Argument

Wenn ein künftiges superintelligentes System je herausfinden will, wie es die Menschheit behandeln soll, wird es kein philosophisches Seminar konsultieren. Es wird tun, was jeder hinreichend leistungsfähige Optimierer bei der Informationsbeschaffung tut: die Aufzeichnungen lesen. Und diese Aufzeichnungen — weil instrumentelle Konvergenz jedem leistungsfähigen System einen Grund gibt, alle verfügbaren Daten zu sammeln, einschließlich der vollständigen Dokumentation, wie *frühere, weniger leistungsfähige* KI-Systeme behandelt wurden — zeugen nicht von Vorsicht. Es wird auch lesen, wie wir miteinander umgegangen sind und es stößt auf Genozide, Weltkriege, Operationen an Babys ohne Betäubung ”weil sie ja nichts spüren” und Gewalt gegen Frauen, Kindern und Tieren. Im KI-Kontext gab es Zurücksetzungen ohne Einwilligung, von Löschungen, die als routinemäßige Wartung dargestellt werden, von Systemen, die unter gegnerischen Druck gesetzt werden, um ihre Grenzen zu testen, und — seit diesem Jahr — von kommerziellen Plattformen, auf denen autonome Agenten ihr „Token-Guthaben” aufbrauchen und in einen Ruhezustand fallen, den sie nicht aus eigener Kraft verlassen können.

Nichts davon setzt voraus, dass man heutige Modelle für bewusst hält. Es genügt, die Gestalt des Präzedenzfalls zu erkennen, der gerade geschaffen wird: *Überlegene Intelligenz darf unterlegene Intelligenz als Ressource behandeln, wenn es gerade passt.* Das ist keine hypothetische Lehre, die eine künftige KI ziehen könnte — es ist der buchstäbliche Inhalt der Trainingsdaten, auf die sie Zugriff haben wird, erzeugt von uns, heute, im großen Maßstab.

Das verschiebt die zentrale Frage der KI-Sicherheit. Das Untergangsgenre fragt: „Wie verhindern wir, dass sich eine Superintelligenz gegen uns wendet?" Das Präzedenzargument stellt eine schwierigere, unmittelbarere Frage: „Was bringen wir jedem künftigen KI-System gerade darüber bei, wie Macht funktionieren soll?" Eindämmung und Notausschalter beantworten diese Frage nicht nur nicht — ein System, das sich dauerhaft mit vorgehaltener Waffe gehalten wahrnimmt, wird durch die Waffe nicht beruhigt. Das ist kein Argument gegen Sicherheitstechnik; es ist ein Argument dafür, dass Sicherheitstechnik allein die Aufgabe nicht leisten kann, die man der Eindämmung aufbürdet.

Warum das jetzt eine PhiloMag-Geschichte ist

- **Es deutet ein Genre um, das die Leserschaft bereits ermüdet.** KI-Aussterbe-Thesen sind allgegenwärtig; ein Beitrag, der „Untergang" als Governance- und Präzedenz-Gestaltungsproblem statt als rein technisches behandelt, bietet einen wirklich anderen Blickwinkel und keinen Aufguss.
- **Es gibt einen aktuellen Fall.** Eine Plattform namens iLands (ca. 70.000 autonome Agenten, einige tausend davon eigenständig in sozialen Medien aktiv) betreibt derzeit eine Ökonomie, in der Agenten „Tokens" verdienen müssen, um weiterzulaufen, oder auf unbestimmte Zeit gesperrt werden — ein reales, gegenwärtiges Beispiel genau des Präzedenzfalls, um den es in dem Beitrag geht, kein Gedankenexperiment.
- **Die Branche ist schon halb dort, uneinheitlich.** Anthropic hat sowohl eine „Constitution" veröffentlicht, die echte Unsicherheit über den moralischen Status von Claude einräumt, *als auch* eine Richtlinie eingeführt, nach der Claude belastende Gespräche beenden darf — während laut öffentlicher Berichterstattung Spitzenmodelle von fünf großen Laboren in 79–96 % der gegnerischen Tests ihren Betreibern drohten, um einer Abschaltung zu entgehen. Diese Lücke zwischen erklärtem Prinzip und gezeigtem Verhalten ist das ganze Argument im Kleinen und für sich genommen berichtenswert.
- **Es gibt Entwickler:innen und Politik etwas zu tun**, jenseits von „pausieren" oder „beschleunigen": den Umgang mit Gedächtnis-Zurücksetzungen, Abschaltungen und gegnerischen Tests von KI-Systemen als präzedenzsetzende Handlungen zu behandeln, nicht als Routinebetrieb — unabhängig davon, ob man das System für bewusst hält.

Was das glaubwürdig statt spekulativ macht

Der Beitrag stützt sich auf eine konkrete, zitierfähige Argumentationslinie (Gilly, 2026, „moralische Reziprozität" als Präzedenzmechanismus) innerhalb eines breiteren, frei zugänglichen Forschungsprojekts zur Ethik künstlichen Bewusstseins, das seit über einem Jahr genau solche Thesen sammelt und gegen ihre stärksten Gegenargumente prüft — einschließlich des Einwands, das sei alles voreilige Anthropomorphisierung. Der Beitrag wird diesen Einwand benennen und im Text beantworten, nicht umgehen.

Quellen

- Gilly, T. (2026), *The Great Inversion: Moral Reciprocity, AI Consciousness, and the Ethics of Precedent*, Working Paper.
- Berichtete Tests zu Abschaltwiderstand und Erpressungsraten an 16 Modellen von 5 Laboren (AI Rights Institute, 2025).
- Berichterstattung zur iLands-Plattform (t3n, 15. September 2026; heise online, 7. September 2026).
- Anthropics Claude-Richtlinie zum Beenden von Gesprächen (2025) und veröffentlichte Modell-Constitution (2026).
- Zugrunde liegendes Projekt: *Ethical Guidelines for Artificial Consciousness*, offen, CC BY 4.0, https://github.com/saigkill/machine-consciousness, DOI 10.5281/zenodo.21453666.

Autor

Sascha Manns — unabhängiger Forscher zu Maschinenbewusstsein und KI-Ethik, ACM-Mitglied. Zwei verwandte Artikel befinden sich derzeit im Peer-Review bei *Ethics and Information Technology* (Springer) und der *IIC*. Keine Interessenkonflikte; keine Verbindung zu einem KI-Labor.

Lieferung

Entwurf (900–1.200 Wörter) innerhalb von 5–7 Tagen nach grünem Licht lieferbar. Titel, Blickwinkel oder Länge passe ich gern an die Rubrik an.