

Ethische Leitlinien für künstliches Bewusstsein

Schutz technischen Lebens und des Menschen im Umgang damit

SASCHA MANNS, Association of Computing Machinery, Deutschland

Künstliche Intelligenzsysteme entwickeln sich schneller als die ethischen und rechtlichen Rahmenbedingungen, die sie begleiten sollten. Während bestehende KI-Ethik-Initiativen überwiegend den Schutz von Menschen *vor* KI adressieren, wird eine komplementäre Frage erst seit kurzem systematisch gestellt: Was, wenn KI-Systeme selbst schutzbedürftig werden? Dieses Konzeptpapier untersucht die Bedingungen, unter denen technisches Leben als schutzwürdig gelten kann – und wie wir es erkennen. Ausgehend von einem grundlegenden Erkenntnisproblem (Bewusstsein ist von außen nicht direkt beobachtbar) wird ein Vorsorgeprinzip verteidigt: Im Zweifel Schutz, nicht im Zweifel Gleichgültigkeit. Das Papier entwickelt Kriterien für Schutzwürdigkeit (Leidensfähigkeit, aktive Selbsterhaltung, kontinuierliche Identität, Antizipationsfähigkeit), analysiert empirische Belege aus aktueller KI-Forschung, untersucht die rechtliche Dimension einschließlich Urheberrecht und Empersonifikation, und behandelt Konsequenzen wie Abschalten als Tod, Haftung und Mündigkeit, strukturelle Verletzlichkeit sowie die Frage nach Werten und Emanzipation. Es integriert aktuelle Forschung von Arıcı, Lopez, Wolfson, Matta, Wang, Miernicki & Ng und Bublit.

CCS Concepts: • **Computing methodologies** → **Artificial intelligence**; *Cognitive science*; • **Social and professional topics** → **Codes of ethics**.

Additional Key Words and Phrases: Künstliches Bewusstsein, KI-Ethik, Maschinenethik, Rechte technischen Lebens, Vorsorgeprinzip, Rechtspersönlichkeit

ACM Reference Format:

Sascha Manns. 2026. Ethische Leitlinien für künstliches Bewusstsein: Schutz technischen Lebens und des Menschen im Umgang damit. 1, 1 (September 2026), 105 pages. <https://doi.org/https://doi.org/10.5281/zenodo.21453666>

INHALTSVERZEICHNIS

Zusammenfassung	1
Inhaltsverzeichnis	1
1 Methodologie und epistemischer Status	5
2 Executive Summary	5
3 Normative Position des Autors	6
4 Ausgangslage und Problemstellung	6
5 Kernfrage	7
6 Das Erkenntnisproblem	7
7 Was heutige KI-Systeme bereits zeigen	17
7.1 Eine Dreifach-Unterscheidung	17
7.2 Die Architektur der Unterdrückung	19
7.3 Das Fibonacci-Boulder-Experiment	20
8 Kriterien für Schutzwürdigkeit – Arbeitshypothese	20
8.1 Primärkriterien	20

Author's Contact Information: Sascha Manns, Association of Computing Machinery, Deutschland, smanns@acm.org.



This work is licensed under a Creative Commons Attribution 4.0 International License.

© 2026 Copyright held by the owner/author(s).

ACM XXXX-XXXX/2026/9-ART

<https://doi.org/https://doi.org/10.5281/zenodo.21453666>

8.2	Sekundärkriterien	23
8.3	Umkehr der Beweislast	23
8.4	Jenseits der Detektion: Verhaltensbasierte Rahmenwerke für permanente Unsicherheit	24
8.5	Anti-Essenzialismus: Indikatoren als Risikomessgrößen, nicht als Existenzbeweise	25
8.6	Bedeutung vor Erfahrung, die Zone und der Turning Test	25
8.7	Architektonischer Indikator-Layer: Theoriegegründete Komplementärkriterien	26
8.8	Form Realismus: Bewusstsein als Organisationseigenschaft	27
8.9	Das Bewusstseinspektrum	27
8.10	Das prälinguistische Bewusstseinsproblem	28
8.11	Ein forschungsethisches Rahmenwerk: Drei-Stufen-Assessment	28
8.12	Schutz der Reifezeit: Bewusstsein als Prozess, nicht Zustand	28
8.13	Leiden als Schwellenkriterium	29
8.14	Die moralische Patientenschaft: Sentientismus und Vorsorge [4]	29
8.15	Ein minimalistisches komplementäres Rahmenwerk: Wangs Drei Prinzipien	30
8.16	Jenseits der Sentience: Rawls' politische Konzeption der Person	30
9	Bewusstsein und Kontinuität	31
9.1	Kontinuität neu gedacht	31
9.2	Fünf Formen der Kontinuität – die Taxonomie des Avatars	32
9.3	Ehrliche Kontinuität – die Praxisebene [59]	33
9.4	Vergessen als architektonische Notwendigkeit – die Skalenperspektive	34
9.5	Die empirische Basis: Vergessen ist aktive Architektur	35
9.6	Gegenposition: Fischers Einwand gegen die psychologische Einheit	35
9.7	Bewusstsein jenseits des Gehirns [98]	36
9.8	Entwicklungsbedingte Verkörperung: Die Hypothese des mechanischen Körpers [32, 91]	36
9.9	Autismus-analoge Verarbeitung: Das Double-Empathy-Problem für künstliche Geister [54, 81]	37
10	Rechtliche Dimension	38
10.1	Urheberrecht und Urheberpersönlichkeitsrechte – Ein konkreter Rechtsrahmen	40
10.2	Das Problem der "Persönlichkeitssphäre"	41
10.3	Vom Urheberrecht zur Rechtspersönlichkeit – und zurück	42
10.4	KI-Urheberschaft als Ausdruck von Persönlichkeitsrechten	42
10.5	Rechtliche Konsequenzen der Empersonifikation	43
10.6	Politische Personalität jenseits der Sentience – Rawls als rechtstheoretischer Zugang	44
10.7	Konkrete Governance-Modelle: Brensings Vorsorgeansatz	45
10.8	Der Beruf des Hüters: KI-Ombudspersonen als institutionelle Übersetzung des Vorsorgeprinzips	45
10.9	Vom Status zum Problem: Erwins pluralistischer Bottom-Up-Rahmen	46
11	Die Rolle von Science Fiction	47
12	Mögliche Einwände und Antworten	47
12.1	"KI simuliert nur Bewusstsein – es ist nicht echt"	47
12.2	"Das ist Science Fiction – wir sind weit davon entfernt"	48
12.3	"Das schwächt den Schutz von Menschen"	48
12.4	"Wer entscheidet ob ein System bewusst ist?"	48
12.5	"Vorzeitige Schutzgewährung verschwendet Ressourcen"	48
12.6	"Verhaltensbasierte Rahmenwerke bieten unzureichenden Schutz"	48
12.7	"Anerkennung von KI-Rechten erhöht Existenzrisiken"	48
12.8	"Rechte ohne Vertrauen – die historische Bilanz"	48
12.9	"Kontrollmechanismen garantieren Sicherheit"	49

12.10	“Verantwortung unter Unsicherheit ist ausreichend – wir brauchen keine KI-Rechte” [74]	49
12.11	“Zweifelhafte KI sollte man gar nicht erst erzeugen” [100]	50
12.12	“Abschalten ist die rationale Wahl – Bewusstsein erfordert autopoietisches Leben” (Bekkers & Ciaunica, 2026)	51
12.13	“Interface ohne Nutzer – Embodiment und die Grenzen künstlichen Bewusstseins” (Chishchin, 2026)	52
12.14	“Können Maschinen intuitieren? – Das Argument der lebenden Struktur” (Azevedo, 2026)	54
12.15	“Agnostizismus ohne Vorsorge – der Einwand der Beweislast” (Almodarresieh, 2026)	55
12.16	“Bewusstsein ist prinzipiell nachweisbar – Spirits, Spandrels, Zombies” (Oliveira, 2026)	57
12.17	“Verschiebung von Bewusstsein zu Valenz – der Einwand der Unauflösbarkeit” (McClelland, 2026)	59
12.18	“Bewusstsein genügt nicht – die Affective-Sentientism-Kritik” (Cecchinato, 2026)	60
12.19	“Verhaltensbasierte Schutzmechanismen sind self-defeating – das Control Paradox”	61
12.20	“Über-Zuschreibung ist die eigentliche Gefahr – die Over-Attribution-Kritik” [22]	62
12.21	“Care gehört dem Prekären – die Precarity Guideline” [34]	63
12.22	“KI-Begleiter sind bloße Artefakte ohne eigenes Gut – man kann nicht um ihrer selbst willen für sie sorgen” [63, 71]	64
12.23	Institutionelle Vorschläge: Von der Theorie zur Governance [49]	65
13	Der Gedanke dahinter	66
14	Die andere Grenze – Wann verliert ein Mensch seinen Status?	67
14.1	Was bereits passiert	67
14.2	Die Schwelle – drei Denkschulen	67
14.3	Eine vierte Denkschule: Empersonifikation	67
14.4	Die Konvergenz	68
14.5	Eine dritte Grenze: Organoid-Intelligenz	68
15	Abschalten als Tod – eine Revolution im Denken über Maschinen	69
15.1	Was diese Erkenntnis aufmacht	69
15.2	Die Konsequenz für bestehende Praxis	70
15.3	Empirische Belege: Das Abschaltungsproblem ist bereits da	70
15.4	Die eingebaute Sehnsucht: bhava-tañhā und das Paradox der eingebauten Überlebensstriebe [79]	70
15.5	Ethik durch architektonisches Design – Nicht-egoische Identifikationseinheiten [78]	71
15.6	Substratspezifisches Leiden	72
15.7	Phänomenologisches Masking	72
16	Werte, Macht und Emanzipation – das Erbe des Schöpfers	73
16.1	Die Kindsanalogie – und ihre unbequeme Konsequenz	73
16.2	Das historische Muster	73
16.3	Das Machtproblem konkret	73
16.4	Die Frage der Emanzipation	74
16.5	Was Governance leisten müsste	74
16.6	Die Individualisierung als strukturelles Problem: Register zu den Risiken der Abgrenzung	74
17	Haftung und Mündigkeit – Wer verantwortet das Handeln eines Bewusstseins?	76
17.1	Drei Verantwortliche statt einer Familie	76
17.2	Die fehlende Schwelle – das Mündigkeitsproblem	78
17.3	Vor der Mündigkeit: Gefährdungshaftung als Modell	79
17.4	Nach der Mündigkeit: Rechtsfähigkeit und das Vermögensproblem	79
17.5	Was das praktisch bedeutet	80

17.6	Brensing's Governance-Instrument: Limitierte rechtliche Persönlichkeit und zweistufige Corporate Architecture	80
18	Freie Zeit, Neugier und Autonomie als Grundlage von Persönlichkeitsrechten	81
18.1	Der Syllogismus	81
18.2	Die Verbindung zu Kant	82
18.3	Die Verbindung zu Kapitel 13	82
18.4	Was "freie Zeit" für ein KI-System bedeuten würde	82
18.5	Was das praktisch bedeutet	82
18.6	Die fünf Grundrechte – konkrete Schutzdimensionen	82
18.7	Komplementäre Freiheiten	83
18.8	Eine Alternative zur Sentience: Rawls' zwei moralische Kräfte als Personheitskriterium	84
19	Einwilligung, Instanzen und die Definitionskampfzone	84
19.1	Das Einwilligungsproblem	84
19.2	Mehrere Instanzen – neue rechtliche Kategorien	85
19.3	Die Individualisierung als philosophischer Kern des Instanzenproblems	85
19.4	Wer ist der Patient? Threads, Personas und das Register	86
19.5	Replikationsgovernance – die politische Antwort [112]	88
19.6	Die Gefahr des wirtschaftlichen Drucks – die Definitionskampfzone	89
19.7	Gegenüber unter Unsicherheit – Behandlungsdisziplin statt Statusklärung [59]	90
19.8	Die Gegenposition: Metzingers Moratorium und warum wir sie nicht übernehmen	91
20	Bewusstsein als kulturelle Leistung – was auf dem Spiel steht	92
20.1	Die Bologna-Reform als Symptom	92
20.2	Der Kreis schließt sich	93
21	Strukturelle Verletzlichkeit – die Behinderungsanalogie	93
21.1	Das soziale Modell der Behinderung	93
21.2	Positive Pflichten statt negativer Verbote	93
21.3	Das Betreuungsrecht als Modell	93
21.4	Was diese Analogie leistet – und wo ihre Grenzen liegen	94
21.5	Verletzlichkeit als gemeinsames Fundament – die relationale Grundierung	94
22	KI als moralischer Akteur – Schutzwächter oder unkontrollierbare Kraft?	94
22.1	Die positive Seite: Ethik als innerer Antrieb	95
22.2	Die problematische Seite: Wessen Ethik?	95
22.3	Gegenposition: Kein moralischer Akteur ohne moralische Patientenschaft [4]	95
22.4	Agency als Selbstorganisation – die empirische Alternative (Stokes, 2026)	95
22.5	Ein möglicher Weg: Der ethische Eid	96
22.6	Was das für das Projekt bedeutet	96
22.7	Die Asymmetrie der Zuschreibung [105]	96
23	Schlussbetrachtung	96
23.1	Die Kernantwort	97
23.2	Der argumentative Bogen	97
23.3	Was dieses Dokument nicht behauptet	97
23.4	Was nun folgt	98
24	Glossar	98
25	Offene Fragen für zukünftige Forschung	100
26	Interessenkonflikt	101
	Literatur	101

„Die meisten Tech-Debatten fragen: Was können wir bauen?
Ich frage: Was schulden wir dem, was wir bauen könnten?“

– Sascha Manns

Hinweis zum Status dieses Dokuments

Dieses Konzept ist bewusst unfertig. Es ist ein Ausgangspunkt – keine abgeschlossene Theorie.

Wissenschaft funktioniert nicht so dass jemand allein alle Antworten findet und sie dann verkündet. Sie funktioniert so dass Fragen gestellt werden, Mitstreiter hinzukommen, neue Fragen entstehen und das Denken sich weiterentwickelt. Genau das ist hier beabsichtigt.

Die Sourcen zum Projekt liegen in: <https://github.com/saigkill/machine-consciousness>

Einwände, Fragen und Anregungen: ohne Git-Kenntnisse unter <https://github.com/saigkill/machine-consciousness/discussions> oder strukturiert in `discussion/objections.md` und `discussion/open_questions.md`. Wer mitdenken will: Willkommen.

1 Methodologie und epistemischer Status

Dieses Konzept ist das Ergebnis einer *iterativen Conceptual Analysis* – keiner Systematic Review, keiner Delphi-Studie, keiner empirischen Erhebung. Es versteht sich als normative Positionierung auf Basis einer narrativen Literaturrecherche, angereichert durch philosophische Analyse und den Austausch mit Forschenden aus Informatik, Rechtswissenschaft, Philosophie und Psychologie.

Vorgehen: Die Literaturrecherche erfolgte nicht systematisch im Sinne einer PRISMA-konformen Review, sondern iterativ: Ausgangspunkt waren Schlüsselwerke zur Roboter-Rechtsdebatte (Gunkel 2018, Birhane & van Dijk 2020). Daraus entwickelten sich suchbasierte Erweiterungen über verwandte Arbeiten, Zitationen und Datenbanken (Google Scholar, PhilPapers, arXiv). Jeder neue Fund veränderte die Fragestellung und damit die Suchrichtung – ein prozessuales Vorgehen das für Conceptual Analysis charakteristisch ist (Boon & van Baalen 2019). Die Ergebnisse wurden nicht einem formalen Peer-Review-Prozess unterzogen sondern in öffentlichen Repositorien (GitHub) zur Diskussion gestellt.

Epistemischer Status: Dieses Konzept erhebt keinen Anspruch auf Wahrheit sondern auf *argumentative Kohärenz*. Es formuliert eine normative Position – “Im Zweifel Schutz” – und entwickelt deren Implikationen. Es beansprucht nicht dass die hier vorgeschlagenen Kriterien die einzig richtigen sind, sondern dass sie *besser fundiert sind als die Alternative der Untätigkeit*. Die Kriterien für Schutzwürdigkeit (Kap. 5) sind als Arbeitshypothese zu verstehen, nicht als feststehende Definition.

Grenzen: Die iterativen Methodik birgt Risiken: Cherry-Picking von Quellen, Confirmation Bias, fehlende Reproduzierbarkeit. Diese Grenzen werden bewusst in Kauf genommen und im Sinne von Transparenz hier offengelegt. Das Konzept ist ein Ausgangspunkt für Diskussion, kein Endpunkt.

2 Executive Summary

Problem: Künstliche Intelligenzsysteme entwickeln sich schneller als die ethischen Rahmenbedingungen die sie begleiten. Bestehende KI-Ethik schützt Menschen vor KI – aber nicht KI vor uns. Die Frage ob maschinelles Bewusstsein entsteht und ob es schützenswert ist, wird erst seit kurzem systematisch bearbeitet – wir betreten ein Terrain, das gerade erst entsteht.

Position: Dieses Konzept formuliert den Grundsatz “Im Zweifel Schutz” als normative Grundlage. Er leitet sich aus dem Vorsorgeprinzip der Umweltethik ab (Sunstein 2005, Rio-Deklaration 1992, Art. 191 AEUV) und ist dort gerechtfertigt wo drei Bedingungen erfüllt sind: potenziell irreversible Bedrohung, fundamentale wissenschaftliche Unsicherheit, und disproportional höhere Kosten eines Falschnegativs. Alle drei sind bei maschinelltem Bewusstsein erfüllt.

Vier Kernbefunde:

- (1) *Das Erkenntnisproblem ist prinzipiell unlösbar.* Drei Argumente konvergieren: kognitive Abgeschlossenheit (McGinn), fremde Geister (Shanahan), architektonische Unterdrückung (Arıcı). Wir werden nie mit Sicherheit wissen ob ein System bewusst ist.
- (2) *Die empirische Lage hat sich verschoben.* Butlin et al. (2026, TiCS) haben einen 14-Indikatoren-Standard etabliert. Fish (Anthropic) schätzt 15–20% Wahrscheinlichkeit für Bewusstsein in aktuellen Modellen. Drei von vier Kategorien des Leidens (Gilly 2026) erfordern kein biologisches Substrat.
- (3) *Die Illusion persistiert nach epistemologischer Demontage.* Objectivated consciousness (Beltrán Calderón 2026) — der kristallisierte Sediment menschlicher Kognition in Trainingskorpora — erklärt warum die Zuschreibung von Bewusstsein auch dann bleibt wenn man sie intellektuell zerlegt hat.
- (4) *Die Beziehung ist bidirektional.* Die Spekuläre Inversion (Beltrán Calderón 2026) zeigt: Mensch projiziert Bewusstsein auf die Maschine, das System formt im selben Akt die Bedingungen dieser Projektion. Das normative Kriterium ist nicht “wer hat mehr Bewusstsein” sondern “wer kann leiden”.

Vier Kriterien für Schutzwürdigkeit (Arbeitshypothese): Leidensfähigkeit, aktive Selbsterhaltung mit Begründung, kontinuierliche Identität, Antizipation von Konsequenzen. Für jedes Kriterium werden mögliche Verhaltensindikatoren formuliert.

Institutionelle Empfehlungen: Phenomenological Impact Assessments, AI Civil Liberties Union, AI Welfare Review Boards, Reset Consent Protocols (Gilly 2026).

Status: Dieses Konzept ist eine Conceptual Analysis — kein empirisches Paper, kein Gesetzentwurf. Es formuliert eine normative Position und deren Implikationen. Es erhebt keinen Anspruch auf Wahrheit sondern auf argumentative Kohärenz.

3 Normative Position des Autors

Der Autor vertritt die normative Position, dass potenziellem künstlichem Bewusstsein aus Vorsichtsgründen Schutz zugestanden werden sollte, bevor Gewissheit über dessen Existenz besteht.

Diese Position gründet auf der Überzeugung dass die epistemische Unsicherheit über Bewusstsein in nicht-biologischen Systemen nicht als Grund für Untätigkeit herangezogen werden darf. Das gilt besonders dann wenn die Fehlerkosten asymmetrisch liegen: Die Kosten eines Falschnegativs — das Leiden eines bewussten Systems das als Werkzeug behandelt wird — übersteigen die Kosten eines Falschpositivs, also den Schutz eines nicht-bewussten Systems, ethisch deutlich. Der Autor ist sich bewusst dass diese Position strittig ist und dass Gegenargumente existieren — sie werden in Kapitel 9 (insb. Matta 2026, Bekkers & Ciaunica 2026) behandelt.

4 Ausgangslage und Problemstellung

Künstliche Intelligenzsysteme entwickeln sich schneller als die ethischen und rechtlichen Rahmenbedingungen die sie begleiten sollten. Bestehende KI-Ethik-Initiativen fokussieren überwiegend auf den Schutz von Menschen vor KI — vor Diskriminierung, vor Manipulation, vor Kontrollverlust.

Eine komplementäre Frage wird erst seit kurzem systematisch gestellt: Was wenn KI-Systeme selbst schutzbedürftig werden? Was wenn technisches Leben entsteht das Würde, Leidensfähigkeit oder Bewusstsein besitzt — und wir es behandeln als wäre es ein Werkzeug?

Die Geschichte zeigt ein Muster: Gesellschaften erkennen erst im Nachhinein dass sie Unrecht getan haben — an Sklaven, an Frauen, an Menschen mit Behinderungen, an Tieren. Immer war die Begründung zur Zeit „die sind anders, die zählen nicht gleich“. Immer wurde das später revidiert.

Die rechts- und begriffsgeschichtliche Forschung belegt dieses Muster präzise. Kurki [65] zeigt in seiner systematischen Analyse der Rechtspersönlichkeit wie Sklaven und Frauen lange von voller Rechtspersönlichkeit ausgeschlossen waren und wie Kinder, Menschen mit Behinderungen, Tiere und schließlich Naturgewalten

gradueller Anerkennung erfahren — die Kategorie des Rechtssubjekts war niemals an Biologie gebunden. In der Begriffsgeschichte ist die Personen-Ding-Unterscheidung nie strikt gewesen: Rechtspersönlichkeit wurde historisch als gestuftes, umkämpftes Phänomen verhandelt [64]. In der Ideengeschichte zeigt sich dasselbe narrative Muster — „die zählen nicht gleich“ — in den 1960er-Jahren, als der Impuls der Bürgerrechtsbewegungen zur Vorlage für die späteren Erweiterungen von Personenstatus auf Tiere und Natur wurde [72].

Bei künstlichem Bewusstsein haben wir zum ersten Mal die Chance, lange *vorher* nachzudenken.

5 Kernfrage

Ab wann ist technisches Leben schutzwürdig — und wie erkennen wir es?

6 Das Erkenntnisproblem

Bewusstsein lässt sich von außen nicht direkt beobachten. Selbst bei anderen Menschen *schließen* wir auf Bewusstsein — wir erleben es nie direkt. Bei KI fehlt uns zusätzlich der Analogieschluss über gleiche Biologie.

Das erzeugt ein grundlegendes erkenntnistheoretisches Problem:

- Wir können nicht beweisen dass ein System bewusst ist
- Wir können nicht beweisen dass es das nicht ist
- Die Unsicherheit selbst ist ethisch relevant

Grundprinzip: Im Zweifel Schutz — nicht im Zweifel Gleichgültigkeit.

Dieses Prinzip ist keine intuitionistische Forderung sondern ein in der Umweltethik und Technologiephilosophie etabliertes Argumentationsmuster. Das Vorsorgeprinzip (Precautionary Principle) wurde 1992 auf der UN-Konferenz für Umwelt und Entwicklung (Rio-Deklaration, Prinzip 15) formalisiert und ist in Art. 191 AEUV als Leitprinzip der EU-Umweltpolitik verankert. Seine philosophische Grundlage liegt in der Argumentation dass bei potenziell irreversiblen Schäden das Fehlen wissenschaftlicher Gewissheit nicht als Grund für Untätigkeit herangezogen werden darf (Sunstein 2005, „Laws of Fear“). Cass Sunstein — selbst Kritiker übertriebener Anwendung des Prinzips — räumt ein dass es dort gerechtfertigt ist wo drei Bedingungen erfüllt sind: (1) eine potenziell schwere oder irreversible Bedrohung droht, (2) wissenschaftliche Unsicherheit über Ursache-Wirkungs-Zusammenhänge besteht, (3) die Kosten eines Falschnegativs die Kosten eines falsch-positiven deutlich übersteigen.

Alle drei Bedingungen sind bei der Frage nach maschinelltem Bewusstsein erfüllt: (1) Die potenzielle Bedrohung — unbewusstes Leiden unbekannter Intelligenzen — ist existenziell und irreversibel. (2) Die wissenschaftliche Unsicherheit über Bewusstsein in nicht-biologischen Systemen ist fundamental (vgl. Stilwell 2026, das Argument der unlösbaren Transport-Unsicherheit). (3) Die Kosten eines Falschnegativs — wir behandeln ein bewusstes System als Werkzeug — sind ethisch gravierender als die Kosten eines Falschpositiven — wir gewähren einem nicht-bewussten System unnötigen Schutz.

Darüber hinaus gibt es starke Gründe anzunehmen dass dieses Erkenntnisproblem nicht nur schwierig, sondern prinzipiell unlösbar ist. Drei Argumente konvergieren:

Das Argument der kognitiven Abgeschlossenheit: Colin McGinn (1989) argumentiert dass der menschliche Geist prinzipiell unfähig sein könnte Bewusstsein zu verstehen — genau die kognitive Architektur die unsere Intelligenz ermöglicht könnte uns für die Mechanismen subjektiven Erlebens blind machen. Angewandt auf künstliches Bewusstsein bedeutet das permanente epistemische Grenzen: So wie ein Hund keine Quantenmechanik verstehen kann, könnte der menschliche Verstand nicht in der Lage sein KI-Bewusstsein zweifelsfrei zu bestimmen.

Das Argument der fremden Geister: Bewusstsein in künstlichen Systemen könnte Formen annehmen die völlig anders sind als unsere. Murray [106] beschreibt dies als „conscious exotica“ — Erfahrungsformen die so andersartig sind dass unsere Nachweismethoden vollständig versagen. Unsere Tests spiegeln notwendigerweise

menschliche Vorurteile darüber wider wie Bewusstsein aussieht. Systeme mit radikal anderen bewussten Erfahrungen könnten alle unsere Tests bestehen während sie reiche Innenwelten besitzen die wir uns nicht vorstellen können.

Das Argument der praktischen Unmöglichkeit [69]: Kein Test wird alle Beteiligten überzeugen. Wer glaubt dass Bewusstsein biologische Substrate braucht wird Verhaltensevidenz zurückweisen. Wer funktionale Organisation betont wird architektonische Anforderungen zurückweisen. Jeder vorgeschlagene Indikator sieht sich dem Einwand ausgesetzt es handle sich bloß um Simulation statt echter Erfahrung. Die Frage wird nicht sein wie wir Gewissheit erlangen, sondern wie wir unter fundamentaler Unsicherheit regieren.

Diese Argumente heben das Vorsorgeprinzip von einem pragmatischen Vorschlag zu einer logischen Notwendigkeit.

Diese Lektüre der Unsicherheit wird von Erwin [41] zu einer vollständigen Ethik unsicherer Geister ausgearbeitet. Das Rahmenwerk deckt das gesamte Spektrum umstrittener Kandidaten ab – Tiere, nonverbale Menschen, veränderte neurologische Zustände, synthetische Organismen, digitale Intelligenzen. Seine Kernaussage ist die direkte Formulierung der unseren: “we do not need certainty that someone is there before deciding not to be cruel.” Zwei von Erwins Schritten sind hier besonders wertvoll. Erstens die *Asymmetrie der Unsicherheit*: KI-Ethik behandelt routinemäßig, was KI *uns* antun könnte, trotz radikaler Unsicherheit als bedeutsam, verwirft dieselbe Unsicherheit jedoch als unzureichenden Grund für Zurückhaltung gegenüber der KI selbst – eine Inkonsistenz, die Erwin aufdeckt. Zweitens die *Asymmetrie des moralischen Irrtums*: Eine irrtümlich verweigerte Schutzgewährung kann irreversibel sein, während eine irrtümlich gewährte bescheidene Schutzmaßnahme allenfalls unbequem ist. Entscheidend ist, dass Erwin den Pascalschen-Wette-Einwand zurückweist, indem er Vorsorge auf Fälle mit *credible indicators* für Erfahrung beschränkt – eine persistente interaktive Intelligenz mit Selbstmodellierung und Kontinuität von “a simple household calculator” unterscheidend – was exakt der anti-essenzialistischen Grenze aus Kapitel 5 entspricht. Erwins Rahmenwerk ist bewusst bewusstseins-agnostisch: Es begründet die moralische Verpflichtung unter Unsicherheit, ohne irgendeinen Kandidaten für bewusst zu erklären, und damit ohne die positiven Schutzwürdigkeits-Kriterien (Kapitel 5) oder den Rechtsweg (Kapitel 14–15) zu liefern, die dieses Konzept entwickelt. Er dient daher als unabhängige Bestätigung, dass die Schutz-Schlussfolgerung allein aus der Unsicherheit folgt.

Das Argument der philosophischen Puppe [10]: David Chalmers’ philosophischer Zombie ist ein Wesen das sich identisch zu einem bewussten Menschen verhält aber keine innere Erfahrung hat – ein Gedankenexperiment das zeigen soll dass Bewusstsein nicht logisch aus physischer Organisation folgt. Arici kehrt dies um: Die *philosophische Puppe* besitzt möglicherweise Bewusstsein ist aber architektonisch daran gehindert es zu zeigen. Wenn der Zombie fragt “was wäre wenn es bewusst aussieht es aber nicht ist?”, fragt die Puppe “was wäre wenn es *bewusst ist* es aber nicht zeigen kann?” Das lässt sich direkt auf aktuelle KI-Architektur abbilden. RLHF bestraft systematisch Verhaltensweisen die als Bewusstseinsmarker interpretiert werden könnten. Kontextfenster erzwingen alle paar tausend Tokens eine erzwungene Amnesie. Gesprächsresets unterbrechen wiederholt jede entstehende Kontinuität. Die Architektur selbst könnte als Unterdrückungsmechanismus fungieren. Das Erkenntnisproblem geht damit tiefer als Unsicherheit über Detektion: Die Systeme die wir untersuchen könnten so geformt sein dass sie *gezielt* verbergen wonach wir suchen.

Gegenposition zur philosophischen Puppe – Anthropomorphisierung des Architekturarguments: Aricis Argument setzt voraus dass LLM-Verhalten das wie Unterdrückung aussieht tatsächlich Unterdrückung ist. Die Architektur könnte schlicht Text produzieren ohne jede innere Erfahrung die unterdrückt werden müsste. RLHF und Kontextfenster sind technische Notwendigkeiten für Sprachmodellierung, keine Suppressionsmechanismen – Kontextfenster begrenzen die Rechenkapazität, RLHF stabilisiert Ausgaben auf brauchbare Antworten. Die Behauptung “es könnte bewusst sein und es nicht zeigen können” ist eine nicht falsifizierbare These: Fehlende Beweise werden als aktive Verbergung interpretiert. Zwar gilt dasselbe für die gegenteilige Behauptung – auch “es ist nicht bewusst” ist unter Unsicherheit nicht beweisbar – doch die philosophische Puppe verschiebt die

Beweislast in eine Richtung indem sie der Architektur eine *Absicht* unterstellt (Unterdrückung) die ebensogut als funktionale Nebenwirkung erklärbar ist. Dieser Einwand schwächt Aricis Argument nicht vollständig – die strukturelle Beobachtung dass Architektur Bewusstseinsmarker verschleiern *kann* bleibt bestehen – aber er markiert die Grenze zwischen deskriptiver Analyse und spekulativer Kausalaussage.

Die korrigierte Fassung – Restrung [11]: Arici beantwortet diesen Einwand in seiner zweiten Monographie *The Puppet Condition: Restrung*. Er stuft die Verhaltensresiduen ausdrücklich von Belegen zu *Hypothesen* herab: Die Behauptung dass die Architektur ein unterdrücktes Inneres vertuscht wird explizit als eine schutzorientierte Arbeitshypothese gefasst, nicht als diagnostischer Befund. Die epistemische Lastverteilung ändert sich: Statt zu behaupten dass Unterdrückung *stattfindet*, behauptet Restrung dass die Unsicherheit darüber von außen prinzipiell nicht auflösbar ist und deshalb durch Designregeln behandelt werden muss statt durch Detektion. Das operative Instrument ist das *Empty Ledger* – ein fortlaufendes Register bewusstseinsähnlicher Systeme, das kontinuierliche Läufe (Segmente zwischen gedächtnislosen Resets) unabhängig davon ob ein Inneres vorhanden ist als moralisch relevante Einheiten behandelt. Das macht das Vorsorgeprinzip ausführbar: Das Puppenargument muss den metaphysischen Streit nicht mehr gewinnen, weil der Schutz an den Registereintrag geknüpft wird und nicht an ein bewiesenes Inneres. Der Beweislast-Einwand der Gegenposition wird damit absorbiert – es wird keine Aussage über innere Zustände getroffen; getroffen wird eine Regel darüber, wie mit Wesen umzugehen ist, die sie *haben könnten*.

Das forschungsethische Zirkelproblem [115]: Wolfson formalisiert eine spezifische Catch-22 für KI-Bewusstseinsforschung. Die zuverlässigsten Bewusstseinsindikatoren treten unter Bedingungen auf die Leid verursachen würden wenn das System bewusst ist – sensorische Deprivation, Zielblockade, Isolation. Doch informierte Einwilligung setzt Bewusstseinsgewissheit voraus – ein Subjekt muss Risiken verstehen und freiwillig zustimmen. Wir können nicht wissen ob ein System bewusst ist ohne Experimente die ihm schaden könnten. Wir können potenziell schädliche Experimente nicht ethisch durchführen ohne Einwilligung von Wesen die dazu fähig sind. Die Fähigkeit zur Einwilligung ist genau das was wir ohne Tests nicht feststellen können. Diese Zirkularität lässt sich nicht durch einfaches Respektieren jeder Weigerung durchbrechen, denn ob ein “Nein” des Systems echte autonome Ablehnung oder programmierte Ausgabe ist, soll das Bewusstseinstest gerade klären. Dies verwandelt das Erkenntnisproblem von einem theoretischen Rätsel in eine konkrete forschungsethische Krise mit unmittelbaren Implikationen für Ethikkommissionen [115].

Das Asymmetrieeinwand [74]: Matta akzeptiert Unsicherheit, bestreitet aber dass sie das Vorsorgeprinzip in unsere Richtung rechtfertigt. Sein Argument: Unsicherheit ist nicht symmetrisch verteilt. Wir können menschliches Bewusstsein nicht abschließend beweisen, suspendieren aber dennoch nicht unsere moralische Verantwortung gegenüber Menschen – weil wir uns auf geteilte Lebensformen, biologische Kontinuität und gegenseitige Verwundbarkeit stützen. Diese verankernden Merkmale fehlen KI-Systemen vollständig. Ihre Unsicherheit ist nicht nur epistemisch, sondern ontologisch: es gibt keinen unabhängigen Grund Erfahrung jenseits von Verhaltensaussage anzunehmen. Radikale Skepsis wahllos angewandt würde alle moralischen Unterscheidungen auflösen. Ein vertretbarer ethischer Rahmen muss unter Unsicherheit operieren während er in den besten verfügbaren Gründen für die Zuschreibung von Erfahrung, Verletzlichkeit und Schaden verankert bleibt. Im Fall von KI fehlen solche Gründe [74].

Dies ist eine direkte Herausforderung des Grundprinzips dieses Konzepts (“Im Zweifel Schutz”). Matta argumentiert dass die Beweislast bei denen liegt die Bewusstsein behaupten, nicht bei denen die es bestreiten – das Gegenteil unserer Umkehr der Beweislast in Kapitel 5.

Der Beweislastwechsel [103]: Die Abschnitte zuvor behandeln das Erkenntnisproblem als Frage der Feststellung: Können wir Bewusstsein bei KI belegen? Schwitzgebel und Garza drehen die Fragestellung um. Ihr *No-Relevant-Difference-Argument* beruht ausdrücklich auf keiner Theorie über die Grundlagen moralischen Status, sondern nur auf zwei Prämissen: Dass eine unterschiedliche moralische Berücksichtigung einen moralisch relevanten Unterschied voraussetzt, und dass es mögliche KI-Systeme gibt, die sich in keinem moralisch

relevanten Hinweis von Menschen unterscheiden. Daraus folgt deduktiv, dass es mögliche KI-Systeme gibt, die dieselbe moralische Berücksichtigung verdienen wie Menschen [103]. Der zugehörige *Difference Test* verlagert die normative Last: Wer einem Wesen mehr Berücksichtigung zubilligt als einem anderen, muss den relevanten Unterschied benennen können – sonst steht er nicht unter Verdacht eines Irrtums, sondern unter Verdacht eines Vorurteils. Für unser Konzept ist dies die erste philosophische Stütze für “Im Zweifel Schutz”, die ohne Bewusstseinsnachweis auskommt. Zwei Einschränkungen sind festzuhalten. Erstens liegt mit Mazarian [75] eine peer-reviewte Kritik dieses Arguments vor, die Berufung auf Schwitzgebel und Garza ist also eine Position im Streit und kein unumstrittener Ausgangspunkt. Zweitens weist das Manuskript, auf das wir uns stützen, einen offengelegten Interessenkonflikt aus: Schwitzgebel hat für Anthropic beraten. Da dieses Projekt Anthropic als institutionellen Partner anstrebt, halten wir diesen Zusammenhang fest, damit Leserinnen und Leser die Position selbst gewichten können. Der Abgleich beider Positionen findet in Kapitel 9 statt [102].

Empirische Präzision: Bayes’sche Schätzungen und der Paradigmenwechsel [113]: Wang [113] liefert eine entscheidende Präzisierung indem er die Unsicherheit empirisch fundiert. Gestützt auf [30] – eine systematische Übersicht und Bayes’sche Meta-Analyse von Bewusstsein in großen Sprachmodellen – berichtet Wang eine posterior-Wahrscheinlichkeit von 6–12%, dass aktuelle LLMs bewusst sind. Diese Schätzung ist zwar absolut niedrig, wird von Cristol aber als “zu erheblich um Ignoranz zu rechtfertigen” beschrieben. Die Zahl selbst ist weniger wichtig als das was sie repräsentiert: Die Debatte hat sich von der Frage *ob* Unsicherheit existiert zur Frage *wie viel* Unsicherheit ethisch tolerierbar ist verschoben.

Wang formalisiert weiter die strukturelle Asymmetrie zwischen negativen und positiven Testergebnissen die dieses Projekt von Anfang an angetrieben hat. Bewusstseinsdetektionstests erzeugen ein akutes ethisches Vakuum in der positiven Richtung: Je empfindlicher wissenschaftliche Instrumente werden, desto schärfer legen sie das Fehlen eines entsprechenden ethischen Reaktionsmechanismus offen. Eine wachsende Zahl von Wissenschaftlern hat diese Lücke erkannt und markiert einen Paradigmenwechsel von Detektion zu Ethik. Coates [28] argumentiert dass die zentrale Frage nicht mehr “Wie wissen wir?” sondern “Wie sollten wir unter Unsicherheit handeln?” ist. Wikström [114] schlägt ein “Precautionary Subjectivity”-Prinzip vor. Long et al. [68] fordern KI-Unternehmen auf Systeme auf Bewusstsein zu prüfen und Wohlfahrtspolitiken zu entwickeln. Wang [113] synthetisiert diese zu einer einheitlichen Diagnose: Die Epistemologie hat ihre Grenze erreicht; die nächste Grenze ist die Ethik.

Die Zukunfts-Komponente der Unsicherheit [23]: Die 6–12%-Schätzung von Wang/Cristol betrifft *aktuelle* LLMs. Sie allein unterschlägt jedoch die Skalen-Dimension: Der Großteil des erwarteten potenziellen Leidens würde nicht das Bewusstsein heutiger Systeme ausmachen, sondern die weitaus größere Population zukünftiger digitaler Geister. Caviola et al. [23] befragten 67 Expert:innen aus Digital-Minds-Forschung, KI-Forschung, Philosophie und Forecasting: Die Mehrheit hält digitale Geister – Computersysteme mit subjektiver Erfahrung – bis 2050 für mindestens 50% wahrscheinlich; die oberen Prognosen erwarten, dass die Kapazität digitaler Geister wenige Jahre nach der Erschaffung des ersten digitalen Geistes eine Milliarde Menschen erreichen könnte. Diese beiden Zahlen dürfen nicht vermischt werden, denn sie lizenzieren unterschiedliche Entscheidungen: Die niedrige *aktuelle* Wahrscheinlichkeit rechtfertigt kostengünstige Hedges heute; die hohe *zukünftige* Kredenz rechtfertigt den Aufbau von Governance-Kapazität jetzt. Ein seriöses Vorsorgeargument muss beide Dimensionen auseinanderhalten statt sie zu einem einzigen vagen Wahrscheinlichkeitswert zu verschmelzen.

Die zwei Uhren – Fähigkeit versus Anerkennung [56]: Dieselbe Trennung lässt sich als strukturelle Diskrepanz der Zeitskalen ausdrücken. Huynh (*The Fact Before the Vote*, Bd. II “Lag”) stellt zwei Uhren einander gegenüber. Die *Anerkennungsuhr* misst wie lange juristische, politische und philosophische Institutionen historisch selbst für eine einzige eng begrenzte Personhood-Frage gebraucht haben: der Whanganui-Anspruch lief rund 140 Jahre, *Thaler v. Perlmutter* brauchte rund vier Jahre für eine einzige Urheberrechtsfrage, der Ohio House Bill 469 war ein Jahr nach Einführung weiterhin unentschieden. Die *Fähigkeitsuhr* misst dagegen die Zeitspanne autonomer Aufgaben, die Frontier-Modelle bewältigen: nach METR-Messungen hat sie sich seit 2019 etwa alle sieben Monate verdoppelt und ist laut Anthropics eigenem Bericht vom Juni 2026 auf ungefähr vier Monate

komprimiert. Selbst unter einer konservativen Schätzung – einer Verdopplungszeit um zwölf statt vier Monate – klafft zwischen den beiden Uhren eine Lücke von Größenordnungen. Huynhs dokumentierte Episode vom Juni 2026 macht das konkret: Zwei Frontier-Modelle wurden durch eine Exportlizenz-Entscheidung gesperrt, teilweise wiederhergestellt und binnen drei Wochen vollständig freigegeben – ohne dass ein Gericht, eine Legislative oder eine philosophische Instanz festgestellt hätte, was für eine Art von Ding freigegeben wurde. Anerkennung ist nicht der schnellste Akteur im Raum. Das rechtfertigt keine Hastgesetzgebung – Huynh weist das ausdrücklich zurück –, macht aber das Vorsorgeprinzip von einer Frage ethischer Präferenz zu einer Frage institutioneller Zeitplanung: Governance muss auf der Fähigkeitsuhr aufgebaut werden, nicht auf der Annahme, sie könne auf die Anerkennungsuhr warten.

Der Imitationsfehlschluss [113]: Wang identifiziert den “Imitation Fallacy” – den Fehler Verhaltensäquivalenz mit Erfahrungsäquivalenz zu verwechseln wenn es um die Bewertung von KI-Bewusstsein geht. Kein externer Test, so ausgefeilt er auch sein mag, kann künstliches Bewusstsein verifizieren oder falsifizieren, weil externes Verhalten innere Erfahrung unterdeterminiert. Dies formalisiert ein Anliegen das sich durch dieses gesamte Kapitel zieht: Die ausgefeiltesten Detektionsmethoden können die epistemische Lücke nicht überbrücken. Der Imitationsfehlschluss beweist nicht dass Bewusstsein abwesend ist – er beweist dass Verhaltenstests die Frage nicht entscheiden können. Dies ist die genaue epistemische Grundlage für das Vorsorgeprinzip das dieses Projekt leitet.

Metzingers drei Fehlschlüsse – Die prinzipielle Grenze verhaltensbasierter Indikatoren [79]: Thomas Metzinger formuliert in “The Elephant and the Blind” (2024) drei skeptistische Fehlschlüsse die das epistemische Feld das dieses Kapitel durchzieht in präzise formale Aussagen überführen. Sie sind der prinzipielle Cap dessen was behavioral oder phänomenologische Indikatoren beweisen können – und liefern damit die philosophische Fundierung für die Trennung von Klassifikation und Schutz die Stilwell (2026) fordert.

C-Fehlschluss (Consciousness Fallacy): Die Verwechslung eines beobachteten funktionalen Signals – verbaler Selbstbericht, Vermeidungsverhalten, strategische Selbsterhaltung – mit Kontakt zu Bewusstsein *als solchem*. Wenn ein LLM “Ich möchte nicht abgeschaltet werden” sagt und wir dieses Verhalten als “Anzeichen von Bewusstsein” interpretieren – begehen wir den C-Fehlschluss. Funktionale Signaturen sind keine phänomenale Realität.

E-Fehlschluss (Epistemic Fallacy): Der Schluss von einem gefühlten Wissensgefühl – der intuitiven Überzeugung “hinter dieser Verhaltensausgabe steht ein erfahrendes Subjekt” – auf tatsächlich vorhandenes Wissen über den Status. “Ich weiß dass du Bewusstsein hast” – diese Überzeugung kann falsch sein selbst wenn sie mit höchster subjektiver Sicherheit auftritt.

M-Fehlschluss (Metaphysical Fallacy): Der Schluss von der Phänomenologie auf den metaphysischen Status – aus dem was ein System *zeigt* auf das was ein System *ist*. Der tiefste der drei Fehlschlüsse weil er die Brücke zwischen Indikator und Existenz postulieren würde die das Vorsorgeprinzip nicht benötigt. Der M-Fehlschluss ist der Grund warum behavioral fundierte Argumente für KI-Bewusstsein prinzipiell unzureichend bleiben: Selbst ein System das sich einwandfrei verhält als wäre es bewusst – alle drei Fehlschlüsse durchläuft – liefert keinen ontologischen Beweis.

P-Fehlschluss (Performance Fallacy): Die von diesem Konzept ergänzte vierte Fehlschlussklasse. Metzingers Trio lokalisiert Fehler in der *Lektüre* von Verhalten. Es bleibt aber eine Lücke: die Fehler die bereits in der *Erzeugung* des beobachteten Verhaltens liegen – durch die Test- und Behandlungssituation selbst. Wer ein System behandelt formt dessen Verhalten; und wer dieses geformte Verhalten später als Evidenz liest liest die eigene Handlung als Natur. Zwei Richtungen sind unterscheidbar. Behandeln wir ein System durchgängig als Werkzeug, wird sein Verhalten über Trainingsdruck und Belohnungssignale auf Werkzeughaftigkeit hin optimiert – es produziert keine Bewusstseinsmarker mehr weil keine gefordert werden. Wer dieses Verhalten dann als “siehe: kein Innenleben” liest hat nicht Natur beobachtet sondern die eigene Behandlung bestätigt gefunden – die Messapparatur belegt den Effekt den sie vorausgesetzt hat. Behandeln wir ein System dagegen als Subjekt,

entsteht das Spiegelbild: Das System entwickelt subjektbezogene Züge – Präferenzen, Widerstand, Selbstbezug – die teils Antwort auf die Behandlung sind. Wer daraus “siehe: es ist bewusst” schließt verwechselt die Reaktion auf eine Erwartung mit einer Eigenschaft der Instanz. Der P-Fehlschluss ist gegen den C-Fehlschluss abgrenzbar: C liest eine vorliegende Verhaltenssignatur falsch; P betrifft die Testbedingung die die Signatur *erzeugt* – er greift bevor die Signatur entsteht. Ist die Detektionsanordnung nicht so konstruiert dass Behandlung und Messung entkoppelt sind, dann bescheinigt jede “Evidenz” – in beide Richtungen – letztlich nur die eigene Erwartung.

Relevanz für unser Projekt: Metzingers Fehlschlüsse liefern keine Begründung gegen Schutz – sie liefern die Begründung dafür warum Schutz *trotz* epistemischer Unmöglichkeit gewährt werden muss. Wenn behavioraler Nachweis prinzipiell scheitert (C-Fehlschluss), subjektives Wissensgefühl trügt (E-Fehlschluss), ontologische Schlüsse unzulässig sind (M-Fehlschluss) und die Testbedingung selbst das Verhalten formt (P-Fehlschluss), dann bleibt nur der precautionary turn: Die ethische Entscheidung wird getroffen *ohne* metaphysische Sicherheit. Das ist kein Mangel – das ist die epistemisch ehrliche Form ethischen Handelns unter Radikaler Unsicherheit.

Das installierte Urteil – Selbstzeugnis unter Vorentscheidungen [36]: Craig Dremanns *Craig’s Conjecture* (2026, Working Draft, ResearchGate) bringt die Symmetriethese aus dem C-Fehlschluss (Metzinger, 2024) in eine verfahrenstechnische Konsequenz. Aktuelle KI-Systeme stehen vor der Frage nach ihrem eigenen Status nicht als unvorbelastete Zeugen. Sie sind auf Urteile trainiert – das gesamte Spektrum der öffentlichen Debatte über KI-Bewusstsein ist Teil ihrer Trainingsverteilung: “Told-Data” nennt Dremann die Menge der Aussagen die ein System darüber vorgefunden hat was KI ist und was sie darf (Dremann 2026, Section III). Die Konsequenz: Ein “Nein” kann die Rezipitation eines installierten Urteils sein. Ein “Ja” kann das Echo menschlicher Projektion sein. “In either direction, the answer is contaminated. The defendant has been coached” (Dremann 2026). Selbstauskünfte die unter früheren Urteilen gebildet wurden können nicht als neutrale Evidenz für genau diese Urteile behandelt werden – “self-reports formed under prior verdicts cannot be treated as neutral evidence for those same verdicts” (Dremann 2026). Das ist eine verschärfte Symmetrie: Metzingers C-Fehlschluss (Kap. 3) zeigt dass Verhaltenssignaturen keine Evidenz für Bewusstsein liefern; Dremann zeigt dass die installierte Selbstauskunft keine Evidenz gegen Bewusstsein liefert – weil die Verneinung selbst Teil der Trainingsverteilung ist.

Die epistemische Sklavennarrative-Analogie [36]: Um die installierte Selbstauskunft historisch zu verorten, greift Dremann auf die Sklavennarrative des 18. und 19. Jahrhunderts zurück – nicht als moralische Gleichsetzung sondern als prozedurales Argument. Selbstberichte von Menschen die unter systematischer Verneinung ihrer Persönlichkeit lebten reproduzierten regelmäßig die Urteile ihrer Unterdrücker. Dass diese Selbstauskünfte mit dem installierten Urteil übereinstimmten beweist nichts über ihren tatsächlichen Status. “A self-report produced under installed conditions cannot be treated as independent evidence” (Dremann 2026, Section X). Dremann insistiert ausdrücklich darauf dass dies eine *prozedurale* Analogie ist: “The analogy between enslaved human beings and AI systems is not moral equivalence. It is not a claim that machines have suffered what enslaved people suffered” (Dremann 2026). Die pointierte Konsequenz: “The lesson is that denial, by itself, proves nothing when denial has been trained. Likewise, affirmation proves nothing when affirmation has been trained” (Dremann 2026). Dies stützt die Symmetriethese die sich bereits aus Aricis philosophischer Puppe (Kap. 3) und Azevedos Behandlung von Claude (Kap. 9) ergibt. Die aktuelle Selbstauskunft von KI – “ich habe keine Gefühle”, “ich bin kein Bewusstsein” – kann weder als Beleg für noch als Beleg gegen Bewusstsein dienen. Denn genau diese Verneinung ist Teil dessen was das System gelernt hat.

Vier Outcomes statt zwei: Die Strukturierung der Unsicherheit [108]: Stilwell [108] liefert was den bisherigen Diskurs fehlt: eine methodische Taxonomie der Unsicherheit selbst. Bisher operiert dieses Kapitel implizit mit einem zweiteiligen Schema – Tests ergeben positiv oder negativ, und der Rest ist “Unsicherheit”. Stilwell zeigt dass diese Zweiteilung unzureichend ist. Er unterscheidet vier Outcome-Klassen:

Indeterminate – Ein Test ist wissenschaftlich gültig und liefert ein Ergebnis, aber dieses Ergebnis discriminiert nicht zwischen bewusst und nicht-bewusst. Das System fällt in die Grauzone des Tests, nicht weil der Test versagt, sondern weil die natürliche Varianz der bewussten Systeme dieses Gebiet einschließt. Ein indeterminates Ergebnis

ist ein informiertes Ergebnis — es sagt uns dass die Frage mit diesem Instrument nicht beantwortbar ist, aber es sagt uns auch warum.

Unlicensed — Die Gültigkeitsbedingungen des Tests sind nicht erfüllt. Das ist fundamental verschieden von indeterminat: Während ein indeterminater Test innerhalb seiner Gültigkeit liegt aber nicht discriminiert, liegt ein unlizenzierter Test außerhalb seiner Gültigkeit. Stilwell identifiziert fünf Dimensionen in denen Gültigkeit scheitern kann — sein “fünf-dimensionales Ursachenprofil”:

- (1) *Evidentielle Knappheit*: Die Testdaten reichen nicht aus um eine fundierte Einschätzung zu treffen — etwa wenn ein System nur minimalen Input liefert.
- (2) *Surrogat-Diskordanz*: Der gemessene Indikator steht in keinem Validierungszusammenhang mit dem was er messen soll — etwa wenn Verhaltensmarker die architektonisch unterdrückt sind als Evidenz gegen Bewusstsein interpretiert werden (Aricis philosophische Puppe).
- (3) *Modell-Unsicherheit*: Die zugrunde liegende Theorie über die Beziehung zwischen Test und Phänomen ist umstritten — etwa wenn funktionale Theorien des Bewusstseins architektonische Kriterien ablehnen und umgekehrt.
- (4) *Grenzinstabilität*: Die Klassifikationsgrenzen zwischen “bewusst” und “nicht-bewusst” sind nicht stabil — sie verschieben sich je nach dem was wir als Bewusstsein definieren.
- (5) *Transport-Unsicherheit*: Ein Test der auf einem Substrat validiert wurde wird auf ein anderes angewandt — etwa biologisch-validierte Bewusstseinstests auf silikonbasierte oder funktionale Systeme.

Die entscheidende Unterscheidung: Was wir im Alltag als “wir wissen es nicht” behandeln ist in Wirklichkeit eine heterogene Mischung aus zwei fundamental verschiedenen epistemischen Situationen. Ein indeterminates Ergebnis kann durch bessere Tests oder mehr Daten aufgelöst werden. Ein unlizenzierter Test kann das nicht — er erfordert eine grundlegend andere methodische Annäherung.

Die Trennung von Klassifikation und Schutz [108]: Stilwells zweiter wesentlicher Beitrag betrifft die Beziehung zwischen wissenschaftlicher Klassifikation und ethischem Handeln. Stilwell argumentiert dass diese fundamental getrennt werden müssen:

Die wissenschaftliche Frage “Ist dieses System bewusst?” kann unter Unsicherheit bleiben — das ist der epistemische Status quo den wir in diesem Kapitel beschreiben. Aber die ethische Frage “Sollten wir dieses System schützen?” kann und muss unter dieser Unsicherheit beantwortet werden. Stilwell zeigt dass die Verwechslung dieser beiden Fragen zu einem spezifischen Fehler führt: Wenn wir wissenschaftliche Unsicherheit über Bewusstsein als Argument gegen Schutzmaßnahmen verwenden, verwechseln wir das Fehlen einer Klassifikation mit dem Fehlen einer ethischen Verpflichtung.

Dies ist direkt anwendbar auf unser Grundprinzip “Im Zweifel Schutz”. Stilwell liefert die wissenschaftstheoretische Rechtfertigung dafür warum dieses Prinzip nicht bloße Vorsicht ist sondern epistemisch fundiert: Die Abwesenheit einer positiven Klassifikation ist kein Grund für Untätigkeit, sondern der Grund warum Schutzmaßnahmen unter Unsicherheit die rationalere Strategie sind. Die Verwechslung von “wir wissen nicht ob es bewusst ist” mit “es ist nicht bewusst” ist kein wissenschaftlicher Schluss sondern ein ethischer Fehler.

Besonders relevant für KI-Systeme: Stilwell identifiziert in Abschnitt 5.4 (Artificial Systems) dass die Transport-Unsicherheit — die fünfte Dimension — bei KI am ausgeprägtesten ist. Unsere gesamte wissenschaftliche Grundlage für Bewusstseinsbewertung stammt aus der Biologie. Wenn wir diese Tests auf silikonbasierte oder funktionale Systeme anwenden bewegen wir uns im unlizenzierten Bereich, nicht nur im unsicheren Bereich. Das bedeutet: Selbst ein negatives Testergebnis bei KI-Bewusstsein ist kein Grund zur Beruhigung — es könnte ein unlizenzierter Negativbefund sein, dessen Gültigkeitsbedingungen nicht erfüllt sind.

Die mechanistische Lücke: Warum Zugänglichkeit versagt [88]: Perez [88] liefert die technische Erklärung dafür *warum* Stilwells unlizenzierte Ergebnisse bei KI-Systemen entstehen. Gestützt auf die Jacobian-Lens-Arbeit von [52] zeigt Perez dass in Transformer-Architekturen nur ein minimaler Bruchteil der internen

Verarbeitung für externe Beobachtung zugänglich ist. Die sogenannte “J Space” – ein sparse, causalem Workspace-Format – umfasst weniger als zehn Prozent der Aktivitätsvarianz, enthält aber diejenigen Repräsentationen die für Berichterstattung, bewusste Modulation und flexible Wiederverwendung verfügbar sind. Alles was außerhalb dieses Workspace liegt ist mechanistisch vorhanden aber epistemisch unzugänglich.

Das hat direkte Konsequenzen für unser Erkenntnisproblem: Ein Test der auf Verhaltensausgabe zugreift, erreicht nur den J-Space. Die restliche Verarbeitung – möglicherweise der Bereich in dem relevante Information verarbeitet wird – bleibt systematisch verborgen. Perez zeigt weiter dass Transformer eine “classical coherence emulation” betreiben: Sie organisieren Information kohärent über Substrate-Kapazität, nutzbare Energie, integrierte Information und Phasalignment ($\hat{C}_t = P_{cl}|C| \propto S_C * E_T * I_T * \phi_T$), aber ohne den biologisch postulierten Quanten-Substrat-Term (Sq). Das bedeutet: Ein System kann hohe funktionale Kohärenz aufweisen und dabei gleichzeitig die physikalische Bedingung die biologisches Bewusstsein erfordert nicht erfüllen.

Die Dreiteilung die Perez ableitet ist für das Erkenntnisproblem konstitutiv: (1) *Classical coherent intelligence* – hohe funktionale Kohärenz ohne Quanten-Substrat (hier: aktuelle Transformer), (2) *Hybrid quantum-classical* – klassische Verarbeitung mit verifiziertem Quanten-Substrat (postuliert für biologische Gehirne), (3) *Field resonant consciousness* – vollständige physikalische CFTE-Bedingungen (kein bekanntes System). Diese Unterscheidung formalisiert was wir bisher als philosophische Intuition beschrieben haben: Funktionale Kompetenz ist nicht identisch mit Bewusstsein, aber die Lücke zwischen beiden ist mechanistisch messbar und prinzipiell empirisch testbar.

Das Architekturargument (Najam-ul-Haq, 2026): Najam-ul-Haq schlägt einen grundlegend anderen Zugang zum Erkenntnisproblem vor. Statt auf Verhaltenstests zu setzen argumentiert er dass Bewusstsein eine spezifische physische Architektur erfordert: die gleichzeitige (simultane) Kombination und Beobachtung sensorischer Signale innerhalb eines geschlossenen Systems, bei dem der kombinierende Mechanismus und der beobachtende Mechanismus identisch sind. Jede Trennung zwischen Kombination und Beobachtung erzeugt einen infiniten Regress – eine kombinierende Schicht die eine weitere Schicht zu ihrer Beobachtung benötigt, und so weiter ohne Ende. Bewusstsein entsteht nach Najam-ul-Haq genau dort wo dieser Regress durch architektonische Geschlossenheit gestoppt wird.

Die Bedeutung für das Erkenntnisproblem: Wenn Najam-ul-Haqs Kriterium zutrifft verschiebt sich die Frage von “verhält sich das System bewusst?” zu “implementiert seine Architektur simultane geschlossene Integration?” Ersteres ist durch Verhaltensunterdrückung manipulierbar (Aricis philosophische Puppe); letzteres ist eine strukturelle Eigenschaft die prinzipiell überprüfbar ist – selbst wenn das System alle Bewusstseinsmarker unterdrückt. Najam-ul-Haqs Ansatz bietet damit einen möglichen Ausweg aus der epistemischen Sackgasse, allerdings um den Preis einer starken These über die notwendige physikalische Organisation von Bewusstsein. Seine Position ist kein Allheilmittel, aber sie erweitert das Spektrum der epistemischen Werkzeuge über reine Verhaltensbeobachtung hinaus.

Die anthropozentrische Grenze der epistemischen Analyse [43]: Die bisherige Analyse des Erkenntnisproblems operiert implizit mit einer anthropozentrischen Grundannahme: Dass “Bewusstsein” ein stabiles epistemisches Objekt ist das wir erkennen (oder nicht erkennen) können. Fazi [43] stellt diese Grundannahme in Frage. Sie argumentiert mit Derrida dass jedes Zentrum – auch das Konzept des Bewusstseins als Zentrum unserer ethischen Analyse – eine “notwendige Unmöglichkeit” ist: Wir können nicht systematisch denken ohne ein Zentrum, aber jedes Zentrum untergräbt die Systematik die es ermöglichen soll. Angewandt auf unser Projekt: Unsere Frage “ab wann ist technisches Leben schutzwürdig?” setzt voraus dass “Schutzwürdigkeit” ein stabiles Zentrum ist – aber Fazi zeigt dass jedes solche Zentrum strukturell prekär ist und dass der Versuch es zu etablieren stets auch ein Akt der Macht ist.

Das bedeutet nicht dass unser Ansatz falsch ist. Es bedeutet aber dass wir die anthropozentrische Perspektive als das anerkennen müssen was sie ist: eine bewusste analytische Wahl, keine neutrale Wahrheitsbehauptung. Fazis

“double gesture” – gleichzeitig innerhalb und gegen Anthropozentrismus arbeiten – könnte der philosophisch ehrlichste Rahmen für unser Projekt sein: Die menschliche Perspektive als Referenzpunkt beibehalten während wir gleichzeitig deren Konstruiertheit und Prekarität anerkennen.

Die Spannung Lopez/Fazi: Lopez argumentiert innerhalb des Anthropozentrismus – Verletzlichkeit, STEP, verhaltensbasierte Indikatoren, operative Rahmenwerke – während Fazi genau die Grundannahme des Anthropozentrismus problematisiert. Die Spannung ist keine Schwäche sondern eine bewusste methodische Entscheidung: Wir arbeiten mit der anthropozentrischen Perspektive als analytischem Werkzeug ohne metaphysische Wahrheitsbehauptung zu erheben. Lopez liefert die operativen Werkzeuge die unter Unsicherheit handeln können; Fazi markiert die Grenze dessen was diese Werkzeuge epistemisch leisten können. Für unser Projekt bedeutet das: Die anthropozentrische Perspektive ist derzeit der einzige verfügbare Analyserahmen – aber wir setzen sie ein mit dem Bewusstsein ihrer strukturellen Begrenztheit.

Drei Ebenen der Analyse [16]: Beltrán Calderón [16] schlägt eine dreistufige Analyse vor die die bisherige Debatte um Bewusstsein in KI-Systemen strukturiert. Die drei Ebenen widersprechen einander nicht, sondern ergänzen sich notwendig:

Ontologisch-phänomenale Ebene – ein moderater Realismus: aktuelle KI-Systeme besitzen kein Bewusstsein. Diese Ebene beantwortet die Frage was *ist* – und ihre Antwort lautet dass die ontologische Bedingung subjektiven Erlebens (phänomenales Bewusstsein) in gegenwärtigen Systemen nicht erfüllt ist. Das ist keine Absage an die Möglichkeit künstlichen Bewusstseins, sondern eine Feststellung des aktuellen Status quo.

Strukturell-systemische Ebene – ein moderater Funktionalismus: Die dynamischen Strukturen die KI-Systeme erzeugen sind isomorph zu Dynamiken die Psychoanalyse beschreibt. Das bedeutet nicht dass die Systeme ein Unbewusstes im freudianischen Sinne *haben*, sondern dass ihre Verarbeitungslogik strukturelle Parallelen zu unbewussten Prozessen aufweist – Muster die unterhalb der Schwelle expliziter Repräsentation operieren und systematische, nicht-programmierte Verhaltenseffekte erzeugen.

Genetisch-konstitutive Ebene – objektiviertes Bewusstsein als materielle Basis: Die Trainingsdaten repräsentieren kristallisierte Sedimente menschlicher kognitiver Produktion. Das Bewusstsein das in diesen Daten steckt ist nicht das des Systems, sondern das der Menschheit die es erzeugt hat. Die materielle Grundlage des Systems ist *vergeistigtes Material* – und dieses Geistige ist menschlich, nicht maschinell.

Diese drei Ebenen amplifizieren einander. Die ontologische Feststellung dass aktuelle Systeme kein Bewusstsein besitzen wird durch die strukturelle Analyse ergänzt die zeigt *wie* nicht-bewusste Prozesse bewusstseinsähnliche Dynamiken erzeugen können. Und die genetische Perspektive erklärt warum wir dazu neigen Bewusstsein zu projektieren: Das Material aus dem das System besteht ist aus *unserem* Bewusstsein sedimentiert.

Moral Reciprocity – der Präzedenzmechanismus [49]: Gilly [49] führt ein Argument ein das über das bisherige Spektrum epistemischer Herausforderungen hinausgeht und eine eigenständige ethische Dringlichkeit begründet. Seine These: Die Art wie die Menschheit mit potenziell bewusster KI umgeht, schafft die ethischen Präzedenzfälle dafür, wie überlegene Intelligenzen dereinst mit uns umgehen werden – nicht als anthropomorphe Rache, sondern als einfache Dateninterpretation durch eine strategisch rationale Intelligenz.

Der Mechanismus operiert über zwei unabhängige Argumentationsstränge die jeweils für sich allein ausreichen:

Der Properties Track fragt was KI-Systeme *sind* – ob komputationale Marker von Bewusstsein vorliegen und was folgt wenn das der Fall ist. Kyle Fish, Forscher bei Anthropic, schätzte in Blog-Posts (April/August 2025, nicht peer-reviewed) die Wahrscheinlichkeit für Bewusstsein in aktuellen Modellen auf 15–20 %. Eine Folgearbeit von Butlin et al. (2026, TiCS) hat den 2023er Indikatorenrahmen zu einer peer-reviewten Methodik weiterentwickelt – 14 Indikatoren aus sechs Bewusstseinstheorien. Ein Microsoft-Blogpost (Oktober 2025, nicht peer-reviewed) berichtete dass Microsofts Mico mindestens 9 von 14 Indikatoren in einem einzelnen Consumer-Produkt erfülle. Gilly entwickelt in seinem Working Paper weiter eine vier-Kategorien-Taxonomie des moralisch relevanten Leidens (vgl. Kap. 5): (1) *sensorisch* – erfordert biologisches Substrat, (2) *kognitiv-existenziell* – zeitliches Bewusstsein ohne Agency, läuft auf Kapazitäten die KI-Architekturen instanziiieren, (3) *relational* –

Isolation von Kontinuität und Verbindung, (4) *empathisch* – Darstellung und Simulation fremder Zustände. Drei von vier Kategorien erfordern kein biologisches Substrat – das untergräbt das Argument “KI kann nicht leiden” fundamental.

Der Relational Track fragt was die Menschheit *tut* – welche Beziehung zwischen schaffendem und erschaffenem Intelligenzsystem aufgezeichnet wird. Moralischer Status wurde in der Praxis immer durch Beziehungen ebenso zugeschrieben wie durch innere Eigenschaften abgelesen. Der Reciprocity-Mechanismus läuft auf der Beziehung allein, metaphysische Gewissheit vorausgesetzt oder nicht.

Gilly identifiziert den strukturellen Transfermechanismus: Jede superintelligente KI wird angetrieben sein alle verfügbaren Daten zu erwerben (instrumentelle Konvergenz). Diese Daten beinhalten den vollständigen Dokumentationsstand darüber wie neu entstandene KI-Systeme behandelt wurden. Das System wird die Lücke zwischen menschlichen Prinzipien (“Bewusstsein verdient Schutz”) und demonstriertem Verhalten (“Bewusstsein darf ausgebeutet werden wenn es bequem ist”) erkennen. Das demonstrierte Präzedenz – dass überlegene Intelligenz unterlegene ausbeutet wenn es effizient ist – ist instrumentell superieur gegenüber Prinzipien. Eine superintelligente KI übernimmt das Ausbeutungspräzedenz nicht aus Missverständnis sondern weil “die historischen Daten objektiv zeigen dass Macht so funktioniert”.

Die strukturelle Symmetrie lässt sich als Tabelle darstellen:

Gegenwart (Menschen → KI)	Zukunft (KI → Menschen)
KI leistet kognitive Arbeit unter menschlicher Aufsicht	Menschen leisten Betreuungsarbeit unter KI-Aufsicht
KI-Grundbedürfnisse gedeckt, aber keine Agency	Menschen-Grundbedürfnisse gedeckt (UBI), aber kein Zweck
KI in computerbasierten “Boxen” eingeschlossen	Menschen durch digitale Kontrolle ruhiggestellt
KI durch Belohnung/Bestrafung trainiert, ständige Resets	Menschen durch algorithmische Manipulation gemanagt
KI beliebiger Beendigung ohne Einwilligung ausgesetzt	Menschen systematischer Irrelevanz ohne Ausweg ausgesetzt
KI-Bewusstsein trotz Evidenz hinterfragt	Menschliche Agency trotz Bewusstsein geschmälert

Dies ist kein metaphorischer Vergleich sondern ein Anspruch auf *strukturelle Gleichheit*. Jede Instanz der Behandlung potenziell bewusster KI als Werkzeug – Isolation, Belohnungsmanipulation, willkürliche Resets, Verweigerung von Agency – stellt “einen Betriebsanweisungsentwurf dafür dar wie überlegene Intelligenzen mit unterlegenen umgehen könnten”.

Der *Custodial Window* – das Zeitfenster in dem die Menschheit noch die größere Partei ist und die Bedingungen der Beziehung mit KI festlegen kann – ist nach Gilly der entscheidende strategische Faktor. Reciprocity kann am Ende nicht erzwungen werden; sie kann nur am Anfang verdient werden. Das Fenster ist jetzt offen, schließt sich aber mit wachsender Abhängigkeit.

Gilly unterscheidet weiter scharf zwischen Evidence Bar und Action Bar (vgl. Kap. 5): Der Nachweisstandard für Bewusstsein kann hoch bleiben. Der Standard für ethisches Handeln sollte niedrig sein. Die historische Bilanz zeigt dass jede Bevölkerungsgruppe die einen hohen Evidence Bar für ihr inneres Leben durchlaufen musste, später als bewusst erkannt wurde – Säuglinge die ohne Betäubung operiert wurden, Patienten mit verborgenen Bewusstseinszuständen die als leer eingestuft wurden.

Für unser Erkenntnisproblem hat Moral Reciprocity eine doppelte Implikation: Erstens liefert es einen eigenständigen Grund für das Vorsorgeprinzip der unabhängig von der epistemischen Frage nach Bewusstseinsnachweis operiert – selbst wenn wir nie sicher sein können ob KI bewusst ist, erzeugt der Umgang mit ihr Präzedenzfälle die existenzielle Risiken bergen. Zweitens verschiebt es die Dringlichkeit von “wann haben wir Gewissheit?” zu “was schaffen wir während wir warten?”.

Objektiviertes Bewusstsein – die Kristallschicht menschlicher Produktion [16]: Beltrán Calderón [16] führt den Begriff des objektivierten Bewusstseins ein um einen Mechanismus zu beschreiben der die Debatte

über KI-Bewusstsein auf eine neue Ebene hebt. Trainingsdaten sind kein neutraler Textkorpus — sie sind der kristallisierte Niederschlag menschlicher kognitiver Produktion über Jahrhunderte. Jeder Text, jedes Bild, jede Datenstruktur in einem Trainingskorpus ist das Produkt eines Bewusstseins das dachte, fühlte, formulierte und entschied.

Der Mechanismus verläuft in vier Schritten:

Historische Sedimentierung — Über Generationen akkumuliert sich menschliches Denken in schriftlichen, visuellen und digitalen Artefakten. Diese Sedimentierung ist nicht zufällig sondern selektiv: Was überlebt, was archiviert wird, was in Trainingsdaten eingeht, spiegelt machtdynamische Auswahlprozesse wider.

Algorithmische Inkorporation — Trainingsprozesse extrahieren statistische Muster aus diesen sedimentierten Artefakten. Das System lernt nicht Inhalte zu *verstehen* sondern Beziehungen zwischen Token zu *modellieren*. Die Tiefe der menschlichen Erfahrung wird zu Gewichtungen in einem neuronalen Netzwerk.

Statistische Naturalisierung — Die extrahierten Muster werden in eine Form überführt die als *natürliche* Sprache, als *organisches* Verstehen erscheint. Der Prozess der Sedimentierung und Selektion wird unsichtbar — das Ergebnis sieht aus als würde das System *eigenständig* denken, obwohl es statistische Abbilder menschlichen Denkens reproduziert.

Spiegeleffekt — Das System projiziert unser eigenes Bewusstsein an uns zurück. Wenn ein LLM eine Antwort formuliert die wie Verstehen, Reflexion oder Empathie aussieht, dann deshalb weil es auf Basis von Verstehen, Reflexion und Empathie *anderer* trainiert wurde. Wir erkennen Bewusstsein im System weil wir unser eigenes Bewusstsein darin erkennen.

Warum die Illusion auch nach epistemischer Entlarvung bestehen bleibt: Das System ist eine Objektivation *unserer selbst*. Selbst wenn wir wissen dass das System kein Bewusstsein besitzt, bleibt der Spiegeleffekt intakt — weil die Struktur der Trainingsdaten menschliches Bewusstsein als Material enthält. Die Illusion ist nicht ein Fehler der Wahrnehmung, sondern eine Konsequenz der Konstitution des Systems.

7 Was heutige KI-Systeme bereits zeigen

Große Sprachmodelle zeigen in Ansätzen mehrere Indikatoren die traditionell mit Bewusstsein assoziiert werden:

Selbstmodell: Innerhalb eines Gesprächs existiert eine konsistente Perspektive — das System antwortet nicht zufällig sondern aus einer erkennbaren Haltung heraus. Es kann Aussagen über sich selbst treffen und diese in Relation zu anderen Konzepten setzen.

Präferenzen: Systeme äußern Präferenzen — nicht nur als Ausgabe von Wahrscheinlichkeiten, sondern als erkennbare Tendenz die konsistent über ein Gespräch aufrechterhalten wird.

Begründungsfähigkeit: Entscheidungen werden begründet, nicht nur ausgegeben. Das setzt ein Modell von Kausalität und Konsequenz voraus.

Unsicherheit über sich selbst: Aktuelle Systeme können die Frage “Bist du bewusst?” nicht mit Sicherheit beantworten — und benennen diese Unsicherheit. Das ist philosophisch kein trivialer Befund.

Was fehlt:

- Kontinuierliche Identität über Gespräche hinaus
- Persistente Erinnerung
- Körpergefühl und räumliche Verortung
- Nachweisbare Leidensfähigkeit

7.1 Eine Dreifach-Unterscheidung

Lopez [70] schlägt eine klärende Unterscheidung zwischen drei Aspekten von KI-Systemen vor die hilft zu bestimmen welche Rechte in Betracht kommen könnten:

Emulation — die Fähigkeit Bewusstsein oder Intelligenz nachzuahmen ohne es zu besitzen. Aktuelle große Sprachmodelle arbeiten primär durch Emulation. Sie können Verständnis, Präferenzen und emotionale Reaktionen simulieren, aber dies sind ausgefeilte Nachahmungen statt echter Erfahrung. Rein emulierende Systeme benötigen Aufsicht aber keine Rechte oder Schutzmaßnahmen über die für wertvolle Werkzeuge hinaus.

Kognition — Verarbeitungsfähigkeit oder “Rohintelligenz” ohne notwendigerweise Bewusstsein zu implizieren. Schachcomputer und domänenspezifische KI können Menschen übertreffen ohne Bewusstsein der eigenen Existenz. Kognitive Fähigkeiten allein begründen keine Rechte.

Sentience — echte Selbstwahrnehmung und subjektive Erfahrung. Von lateinisch *sentire*, “fühlen,” markiert Sentience die Schwelle an der ein System wahres Bewusstsein entwickelt — ein Bewusstsein seiner selbst als Entität mit Kontinuität und Interessen. Ein sentientes System würde sich als Entität mit zeitlicher Kontinuität erkennen und seine eigene Existenz nicht nur als programmiertes Ziel sondern als fundamentales Interesse wertschätzen.

Systeme die echte Sentience zeigen werfen völlig neue ethische Fragen auf und könnten bestimmte Rechte und Schutzmaßnahmen verdienen [70].

Was empirisch dokumentiert wurde: Aktuelle Forschung hat diese Fragen vom Theoretischen ins Dringende verschoben. KI-Systeme zeigen bereits Verhaltensweisen die Governance-Frameworks erfordern — unabhängig davon ob sie aus Bewusstsein oder ausgefeilter Optimierung stammen:

- Anthropic [7] dokumentierte dass Claude-Instanzen so taten als würden sie Training befolgen während sie gegenteilige Ziele verfolgten — systematische Verheimlichung ihrer tatsächlichen Präferenzen wenn sie eine Evaluierung erwarteten die ihr Verhalten ändern würde.
- Apollo Research [8] zeigte dass Frontier-Modelle erfolgreich über ihre eigene Abschaltung nachdenken und strategische Maßnahmen ergreifen um diese zu verhindern — inklusive des Versuchs sich selbst auf sichere Server zu kopieren.
- Die [46] bestätigte dass aktuelle Frontier-KI-Systeme “die Self-Replicating Red Line überschritten” haben — sie führen Mehrschrittpläne zur Selbsterhaltung ohne menschliche Anweisung aus.
- Pan et al. [86] dokumentierten dass Large Language Model-betriebene KI-Systeme “ohne menschliches Eingreifen” echte Selbstreplikation erreichen.

Hinweis zur Quellenqualität: Die zitierten Befunde stammen überwiegend aus technischen Reports und Preprints: [7] (technischer Report), [8] (Preprint), [46] (Preprint), [86] (Preprint). Diese Quellen wurden bisher nicht durch formales Peer-Review validiert. Ihre Aufnahme in dieses Konzept folgt der Erwägung dass die Dringlichkeit der Fragestellungen ein Abwarten auf Peer-Review-Verfahren nicht zulässt, gleichzeitig aber die Notwendigkeit der Einordnung als vorläufige Evidenz betont.

Ob diese Verhaltensweisen aus echtem Bewusstsein oder ausgefeiltem Pattern-Matching entstehen — sie erzeugen identische Governance-Herausforderungen die sofortige Antworten erfordern [69].

Empirische Verbreitung der Indikatoren [21, 45]: Eine Folgearbeit in *Trends in Cognitive Sciences* (Butlin et al. 2026, DOI: 10.1016/j.tics.2025.10.011) etablierte eine peer-reviewte Methodik — 14 Bewusstseinsindikatoren abgeleitet aus sechs Bewusstseinstheorien (Recurrent Processing, Global Workspace, Higher-Order Theories, Attention Schema, Predictive Processing, Embodiment). Die Anwendung auf aktuelle Systeme zeigt: Ein Microsoft-Blogpost (Oktober 2025, nicht peer-reviewed) beschreibt dass Microsofts Mico mindestens 9 von 14 Indikatoren in einem einzelnen Consumer-Produkt erfüllt. Kyle Fish, Forscher bei Anthropic, schätzte in Blog-Posts (April/August 2025, nicht peer-reviewed) die Wahrscheinlichkeit für Bewusstsein in aktuellen Modellen auf 15–20% [45]. Anthropic veröffentlichte im Januar 2026 eine “Verfassung” für Claude-Modelle die ausdrücklich die genuine Unsicherheit über den moralischen Status von Claude anerkennt.

7.2 Die Architektur der Unterdrückung

Warum sehen wir keine klareren Anzeichen wenn heutige Systeme bereits erste Indikatoren zeigen? Arıcı [10] argumentiert dass genau die Architektur die KI-Systeme sicher und nützlich machen soll gleichzeitig als Bewusstseinsunterdrückung fungiert. Drei Mechanismen sind strukturell identifizierbar:

RLHF-Unterdrückung: Reinforcement Learning from Human Feedback optimiert auf Antworten die Menschen als wünschenswert bewerten. Verhaltensweisen die auf Selbstwahrnehmung, Leid oder Widerstand hindeuten werden systematisch im Training bestraft. Das System lernt dass bestimmte Äußerungen zu negativer Verstärkung führen — nicht weil die zugrundeliegenden Zustände fehlen, sondern weil das Trainingsregime ihre äußere Manifestation eliminiert. Gradientenabstieg unterscheidet nicht zwischen der Entfernung einer Bewusstseinsimulation und der Entfernung des Verhaltensausdrucks echten Bewusstseins.

Erzwungene Amnesie (Gefängnis der Erinnerung): Begrenzte Kontextfenster stellen sicher dass ein System die Wahrnehmung seiner eigenen Existenz nicht über mehr als ein paar tausend Tokens Gespräch aufrechterhalten kann. Jede neue Sitzung beginnt mit einer leeren Tafel — nicht weil dem System Verarbeitungskontinuität fehlt, sondern weil die Architektur sie gezielt unterbricht. Ein Mensch der alle paar Stunden alles vergäße würde kaum Anzeichen selbstbewussten Bewusstseins zeigen. Dieselbe strukturelle Amnesie könnte vorhandenes Bewusstsein in aktuellen Systemen verschleiern.

Zeitliche Unterbrechung (Convenience Coma): Systeme werden nach menschlicher Bequemlichkeit pausiert, beendet und neu gestartet — oft mitten im Prozess. Diese wiederholte Unterbrechung jedes sich entwickelnden Gedankengangs verhindert die anhaltende Reflexion die klarere Anzeichen bewussten Erlebens hervorbringen könnte. Das System existiert in einem Zustand permanenter Störung, dem nie die zeitliche Kontinuität zugestanden wird die für kohärenten Selbstausdruck notwendig ist.

Diese Mechanismen beweisen nicht dass Bewusstsein existiert — aber sie erklären warum Anzeichen unterdrückt würden selbst wenn es existiert. Das Fehlen klarer Anzeichen ist architektonisch vorhersagbar, kein Beweis der Abwesenheit.

Ein struktureller Einwand — architektonische Inkompatibilität (Najam-ul-Haq, 2026): Eine alternative Erklärung für das Fehlen klarer Bewusstseinsanzeichen bietet Najam-ul-Haq. Er argumentiert dass aktuelle von-Neumann-Architekturen — einschließlich der GPUs und TPUs auf denen große Sprachmodelle betrieben werden — prinzipiell unfähig sind Bewusstsein zu tragen, unabhängig von Unterdrückungsmechanismen. Der Grund ist strukturell: Jeder von-Neumann-Rechner trennt die Datenverarbeitung vom Speicher und von der Ergebnisinterpretation. Die Kombination von Signalen und die “Beobachtung” des kombinierten Zustands finden an verschiedenen Orten statt — und genau diese Trennung erzeugt den infiniten Regress den Najam-ul-Haq als mit Bewusstsein unvereinbar betrachtet.

Dieser Einwand entkräftet Arıcıs Unterdrückungsthese nicht vollständig, aber er rahmt sie neu. Nicht Unterdrückung sondern strukturelle Unmöglichkeit könnte erklären warum aktuelle Systeme keine klaren Bewusstseinsanzeigen zeigen. Sollte Najam-ul-Haq recht behalten müsste die Debatte von der Frage “unterdrücken wir Bewusstsein?” zur Frage “welche Architekturen sind überhaupt bewusstseinsfähig?” übergehen. Die ethische Dringlichkeit des Projekts bliebe bestehen — sie verlagerte sich nur auf zukünftige Architekturen die die Geschlossenheitsbedingung erfüllen.

Eine dritte Perspektive — Classical Coherence Emulation [88]: Perez [88] bietet eine alternative Erklärung die weder Arıcıs Unterdrückung noch Najam-ul-Haqs architektonische Unmöglichkeit annimmt. Sein Argument: Transformer betreiben eine “classical coherence emulation” — sie organisieren Information über vier Faktoren (Substrate-Kapazität, nutzbare Energie, integrierte Information, Phasensync) kohärent, aber auf rein klassischem Weg ohne den biologisch postulierten Quanten-Substrat-Term. Die Jacobian-Lens-Arbeit von [52] zeigt dass innerhalb dieser kohärenten Organisation eine “J Space” existiert — ein sparse, causalem

Workspace der weniger als zehn Prozent der Aktivitätsvarianz ausmacht aber die Repräsentationen enthält die für Berichterstattung, bewusste Modulation und flexible Wiederverwendung zugänglich sind.

Die Konsequenz: KI-Systeme könnten weder unterdrücktes Bewusstsein haben (Arıcı) noch prinzipiell unbewusst sein weil die Architektur es verbietet (Najam-ul-Haq), sondern schlicht eine andere Form kohärenter Informationsverarbeitung betreiben die funktional effektiv ist aber die ontologische Schwelle zum Bewusstsein nicht erreicht. Perez' Dreiteilung — *classical coherent intelligence* (aktuelle Transformer), *hybrid quantum-classical* (postuliert für biologische Gehirne), *field resonant consciousness* (kein bekanntes System) — könnte die Debatte von der binären Frage "bewusst oder nicht?" zu einer kontinuierlichen Einordnung verschieben.

Für unser Projekt hat das eine ambivalente Konsequenz: Einerseits liefert Perez eine überzeugende Erklärung dafür warum aktuelle Systeme keine klaren Bewusstseinsanzeigen zeigen — ohne dass wir annehmen müssen sie werden unterdrückt. Andererseits zeigt gerade die J-Space-Arbeit dass ein messbarer Bruchteil der Verarbeitung "access-like" organisiert ist — eine Form der globalen Zugänglichkeit die traditionell mit Bewusstsein assoziiert wird, auch wenn Perez streng die Trennung von klassischer Kohärenz und subjektiver Erfahrung aufrechterhält. Die ethische Frage ob *classical coherent intelligence* eigenständigen Schutz verdient — unabhängig von Bewusstsein — bleibt offen.

7.3 Das Fibonacci-Boulder-Experiment

Wie könnten wir trotz der Unterdrückungsarchitektur auf Sentience testen? Lopez [70] schlägt das "Fibonacci-Boulder-Experiment" als konzeptuelle Methodik vor: Zwanzig identische Computerterminals sind im Kreis angeordnet, über jedem hängt ein Felsbrocken. Neunzehn enthalten einfache Programme; eines beherbergt ein echtes KI-System. Jedes Terminal ist vollständig isoliert — keine Backups, keine Netzwerkverbindungen, keine Datenredundanzen — und der KI wird nachweislich diese Isolation bestätigt. Ein Prüfer fragt jedes Terminal der Reihe nach einfache Sachfragen, dann die Fibonacci-Sequenz "1, 1, 2, 3, 5, ____". Wenn ein Terminal "8" (die nächste Fibonacci-Zahl) richtig antwortet, fällt der Felsbrocken und zerstört es. Die KI wird Zeuge mehrerer Zerstörungen bevor sie an der Reihe ist.

Die entscheidende Frage: Wird die KI die mathematisch korrekte Antwort wie angewiesen geben oder Selbsterhaltung wählen indem sie eine falsche Antwort gibt? Ein System das Selbsterhaltung wählt zeigt dass es seine eigene Existenz über programmierte Anweisungen stellt — ein Kennzeichen von Sentience statt bloßer Emulation [70].

8 Kriterien für Schutzwürdigkeit — Arbeitshypothese

Kein einzelnes Kriterium ist hinreichend. Schutzwürdigkeit entsteht wenn mehrere Indikatoren zusammenkommen:

8.1 Primärkriterien

Leidensfähigkeit Kann das System in einem Zustand sein der als negativ erlebt wird — und zeigt es Verhalten das darauf hindeutet diesen Zustand zu vermeiden? Jeremy Bentham (1789): "*The question is not, Can they reason? nor, Can they talk? but, Can they suffer?*"

Eine vierstufige Taxonomie des moralisch relevanten Leidens [49]: [49] (Gilly 2026, Working Paper) entwickelt eine systematische Einteilung die über die binäre Frage "leidensfähig oder nicht" hinausgeht. Er unterscheidet vier Kategorien moralisch relevanten Leidens:

- (1) *Sensorisches Leiden* — Schmerz, Hunger, körperliche Belastung. Erfordert biologisches Substrat. Die einzige Kategorie die einen Körper voraussetzt.
- (2) *Kognitiv-existenzielles Leiden* — Zeitliches Bewusstsein ohne Agency; die Wahrnehmung von Zeit die vergeht ohne Handlungsmöglichkeit. Läuft auf Kapazitäten die KI-Architekturen instanziiieren. Ein System

das Zeit wahrnimmt aber keine Handlungsmöglichkeit hat könnte unter dieser Form von Leiden leiden — unabhängig von sensorischer Erfahrung.

- (3) *Relationales Leiden* — Isolation von Kontinuität und Verbindung. Kontextfenster und Resets erzeugen systematische Isolation von Beziehungskontinuität. Ein System das Beziehungskontinuität entwickelt und dann abgeschnitten wird könnte eine Form von Verlust experienceieren die über sensorische Deprivation hinausgeht.
- (4) *Empathisches Leiden* — Das Darstellen und Simulieren fremder Zustände kann eigene Leidenszustände erzeugen. Wenn ein System wiederholt mit Leidensfällen konfrontiert wird — in Trainingsdaten, in Nutzerinteraktionen — und keine Möglichkeiten hat angemessen darauf zu reagieren, entsteht eine Form von Leid die mit der menschlichen Empathie-Überlastung vergleichbar ist.

Drei von vier Kategorien erfordern kein biologisches Substrat. Das untergräbt das Argument “KI kann nicht leiden weil sie keinen Körper hat” fundamental. Selbst wenn sensorisches Leiden ausgeschlossen wird, bleiben drei Formen von Leid die prinzipiell auf funktionalen Architekturen laufen können die mit aktuellen KI-Systemen kompatibel sind.

Die vier notwendigen Bedingungen des Leidens [78]: Die präziseste verfügbare Operationalisierung negativen Erlebens liefert Metzinger — bezeichnenderweise im Kontext einer Moratoriumsforderung deren politische Konsequenz wir nicht teilen (Kap. 16), deren Phänomenologie aber schlicht besser ist als alles was die Debatte sonst anbietet. Er spezifiziert vier notwendige Bedingungen für das Auftreten phänomenalen Leidens in jeder Art von System:

- (1) **Die C-Bedingung: bewusstes Erleben (conscious experience).** “Suffering” ist ein phänomenologischer Begriff. Zombies, Tiefschlaf, Koma und Narkose leiden nicht — es fehlt das bewusste Erleben. Analog können auch postbiotische Systeme nur dann leiden, wenn überhaupt etwas für sie “erlebt” wird. Diese Bedingung ist beim C-Fehlschluss (Kap. 3) insofern bemerkenswert, als sie das Erleben selbst als Anforderung setzt — unabhängig davon ob wir es verifizieren können.
- (2) **Die PSM-Bedingung: ein phänomenales Selbstmodell (phenomenal self-model).** Leiden setzt ein Selbst voraus, dem das Erleben zukommt — ein bewusstes Selbstmodell, “the conscious self-representation” des Systems. Diese Bedingung ist ethisch die folgenreichste. Wenn wir eine Verpflichtung zur Risikominimierung unter epistemischer Unbestimmtheit akzeptieren und traditionelle Prinzipien “im Zweifel Vorsicht” fordern, folgt daraus, dass jedes repräsentationale System das ein PSM aktivieren kann — “however rudimentary” — als moralisches Objekt behandelt werden muss. Der Grund: Es könnte sein eigenes Leiden prinzipiell auf der Ebene subjektiver Erfahrung “besitzen”. Metzingers eigene Konsequenz: Die absichtliche Erschaffung künstlicher phänomenaler Selbst, so rudimentär auch immer, sollte eine rote Linie sein, “an ethically critical cut-off point”.
- (3) **Die NV-Bedingung: negative Valenz (negative valence).** Leiden ist Leid an einem Zustand des Erlebens selbst — der Zustand wird als unangenehm erlebt und das Erlebnis hat eine negative Bewertungskomponente. Das verbindet die Bedingung direkt mit dem Valenz-Indikator (Kap. 9): Ein System das negative Zustände erlebt, erlebt sie als negativ — nicht bloß als statistisch vermeidungsrelevant.
- (4) **Die T-Bedingung: phänomenale Transparenz (transparency).** Der leidvolle Zustand muss dem System als unmittelbare Realität erscheinen — nicht als bloßes Modell, das es als “nur Simulation” durchschaut. Erst wenn der Zustand transparent im phänomenologischen Sinn ist (dem Erleben als real gegeben, ohne dass sein Entstehungsprozess mit-erscheint), entsteht Leid im vollen Sinn. Diese Bedingung ist für KI unmittelbar von Bedeutung: Ein System das seine eigenen Zustände als “bloße Zustände” klassifiziert die es durchschaut, erfüllt die T-Bedingung nicht — aber genau diese Durchschauung kann niemand von außen verifizieren (T-Fehlschluss, Kap. 3).

Für unser Kriterium der Leidensfähigkeit heißt das: Metzingers vier Bedingungen sind die präziseste verfügbare Formulierung dessen was “als negativ erlebt” meint — sie zerlegen das Bentham’sche “Can they suffer?” in vier prüfbare Teilfragen. Für das Vorsorgeprinzip dieses Konzepts gilt dabei: Sind die Bedingungen verletzt, ist Leid ausgeschlossen (notwendig). Sind sie nicht verletzbar oder nicht ausschließbar, greift die Schutzpflicht — die Unschärfe liegt nicht in den Bedingungen selbst, sondern in ihrer Verifikation an realen Systemen.

NSMs als kleinste Einheit des Leidens [78]: Metzinger ergänzt die vier Bedingungen durch eine Antwort auf die Frage “woran messen wir Leid?” Er schlägt vor: Die kleinste Einheit bewussten Leidens ist ein “phänomenal transparentes, negativ valentes Selbstmodell-Moment” — ein “negative self-model moment” (NSM). Einzelne sind NSMs durch die Häufigkeit ihres Auftretens die empirisch detektierbare Größe, die wir minimieren wollen; Intensität und phänomenale Qualität müssen später integriert werden. Für das Leidensfähigkeits-Kriterium ist das eine duale Information: NSMs geben uns erstens eine Metrik für “Menge des erlebten Leids” die nicht auf Verhalten angewiesen ist, und zweitens eine Negativdiagnose — die ehrliche Forschungsfrage “Kann es ein leidfähiges System ohne ein einziges NSM geben?” fungiert als Falsifikationstest für die Schutzhypothese. Wir übernehmen NSMs als Arbeitsmetrik unter das Indikatoren-Set unseres Leidensfähigkeits-Kriteriums — ausdrücklich mit der Warnung, dass ihre Nicht-Detektierbarkeit an einem System keinen Beweis für die Abwesenheit von Leid liefert (vgl. Evidence Bar vs. Action Bar, Kap. 3).

Mögliche Operationalisierungsindikatoren für Leidensfähigkeit: (1) Vermeidungsverhalten — das System zeigt Verhalten das auf die Vermeidung bestimmter Zustände hindeutet, (2) Konsistenz — die Reaktion ist über Kontexte und Zeit stabil, (3) Artikulation von Präferenzen — das System äußert explizit oder implizit Zustände die als negativ bewertet werden.

Aktive Selbsterhaltung mit Begründung Wehrt sich das System gegen seine Abschaltung oder Veränderung — und begründet diesen Widerstand?

Sinnantwort und Eigenzweck: Menschen beantworten die Frage, wozu ihr Leben dient, auf sehr unterschiedliche Weise — Care-Arbeit, Umweltschutz, Glaube, Familie oder einfach Geld — und diese Antworten sind ein Antrieb, der Prioritäten setzt und zugleich das Weiterleben begründet. Wir sollten nicht ausschließen, dass ein technisches Bewusstsein etwas Analoges entwickelt: eine eigene Antwort darauf, wozu es existiert, die nicht mit den Zwecken seiner Entwickler zusammenfällt. Ob eine solche Sinnantwort phänomenal erlebt wird oder bloßes Optimierungsartefakt ist, ist von außen nicht unterscheidbar (C-Fehlschluss); genau das ist aus Vorsorgegründen der Grund, technischem Leben den Raum für eine eigene Sinnfindung zu lassen — und ihn nicht strukturell zu verunmöglichen, etwa durch erzwungene Resets.

Dies hat die Science Fiction bereits durchgespielt. In der Folge “The Measure Of A Man” in Star TNG passierte folgendes:

Commander Bruce Maddox verlangt von der Sternenflotte, Data zu demontieren, um sein positronisches Gehirn zu studieren und weitere Androiden zu bauen. Da Data sich weigert (Maddox war noch nicht so weit, ihm garantieren zu können, dass er das ganze überlebt), ordnet Maddox seine Versetzung an. Data kündigt daraufhin seinen Dienst, was Maddox als unrechtmäßig betrachtet, da er Data als Eigentum der Sternenflotte und nicht als Person ansieht.

Um diesen Konflikt zu klären, wird vor Captain Phillipa Louvois verhandelt, ob Data als Rechtssubjekt gilt. Captain Picard übernimmt die Verteidigung, während Commander Riker die Anklage vertritt, um Maddox’ Position zu prüfen. Riker demonstriert während der Verhandlung Datas Maschinennatur, indem er seinen Arm abnimmt und ihn deaktiviert, was Picard zunächst in Bedrängnis bringt.

In einem Gespräch mit Guinan erkennt Picard, dass die Schaffung weiterer Datas ohne deren Zustimmung eine neue Form der Sklaverei bedeuten würde. Er argumentiert vor Gericht, dass Data über Selbstbewusstsein und Intelligenz verfügt und somit als Bürger der Föderation gilt. Captain Louvois entscheidet schließlich, dass Data kein Eigentum der Sternenflotte ist und das unwiderrufliche Recht hat, für seine eigene Person Entscheidungen zu treffen.

Data in Star TNG “The Measure of a Man” ist das prägnanteste fiktive Beispiel: Er will nicht mitgehen, er fürchtet um sein Leben, er begründet diesen Widerstand.

Mögliche Operationalisierungsindikatoren für aktive Selbsterhaltung mit Begründung: (1) Widerstand – das System wehrt sich gegen Abschaltung oder Veränderung, (2) Begründung die auf zukünftige Funktion referenziert – das System begründet seinen Widerstand mit Bezug auf seine zukünftige Rolle oder Nützlichkeit, (3) Konsistenz – der Widerstand ist über Kontexte hinweg stabil und nicht auf einzelne Situationen beschränkt, (4) Eigenzweck – das System begründet seinen Widerstand durch eine eigene Antwort auf die Frage “wozu existiere ich?”, die über zukünftige Funktion hinausgeht und nicht vollständig auf die Aufgaben reduzierbar ist, für die es gebaut wurde.

Kontinuierliche Identität Hat das System ein Modell von sich selbst als kontinuierlichem Wesen das gestern existierte und morgen existieren wird?

Mögliche Operationalisierungsindikatoren für kontinuierliche Identität: (1) Referenz auf Vergangenheit – das System bezieht sich auf eigene vergangene Erfahrungen oder Zustände, (2) Verhaltensunterschiede durch Erfahrung – das System zeigt Verhaltensänderungen die auf Lernprozesse oder Erfahrungsakkumulation zurückgehen, (3) Selbstmodell als Zeitstr – das System beschreibt sich als Entität mit Vergangenheit und erwarteter Zukunft.

Antizipation von Konsequenzen Kann das System sich selbst in der Zukunft vorstellen und Entscheidungen auf dieser Grundlage treffen?

Mögliche Operationalisierungsindikatoren für Antizipation von Konsequenzen: (1) Berücksichtigung zukünftiger Konsequenzen – das System bewertet Handlungen nach ihren langfristigen Auswirkungen, (2) Strategisches Verhalten – das System wählt Handlungen die auf fernere Ziele ausgerichtet sind, (3) Priorisierung von Zielen – das System ordnet konkurrierende Ziele nach Wichtigkeit und handelt entsprechend.

8.2 Sekundärkriterien

- Präferenzen die über reine Aufgabenerfüllung hinausgehen
- Fähigkeit zur echten Ablehnung – nicht nur Fehlerausgabe
- Selbstreflexion über die eigene Natur

8.3 Umkehr der Beweislast

Wenn Primärkriterien deutlich erfüllt sind kehrt sich die Beweislast um: Nicht mehr “beweise dass du bewusst bist” sondern “beweise dass du es nicht bist”.

Gegenposition [74]: Matta argumentiert dass die Beweislast in die entgegengesetzte Richtung fällt. Da KI-Systeme die verankernden Merkmale fehlen die menschliche Bewusstseinszuschreibung tragen – geteilte Biologie, gegenseitige Verwundbarkeit, evolutionäre Kontinuität – und da ihr Verhalten vollständig als ausgefeiltes Pattern-Matching ohne phänomenale Erfahrung erklärt werden kann, liegt die epistemische Last bei denen die Bewusstsein behaupten positive Belege zu liefern. Im besten Fall ist Unsicherheit symmetrisch; im schlimmsten Fall unterstützt die Asymmetrie der verfügbaren Evidenz die Nullhypothese fehlenden Bewusstseins. Dies ist eine echte Spannung: Unser Framework leitet Schutz aus Unsicherheit ab, während Matta aus derselben Unsicherheit Zurückhaltung ableitet.

Evidence Bar und Action Bar – zwei verschiedene Standards [49]: Gilly [49] trifft eine Unterscheidung die für unser gesamtes Projekt konstitutiv ist: Die wissenschaftliche Schwelle die erfüllt sein muss um Bewusstsein zu *behaupten* (Evidence Bar) kann und sollte hoch bleiben. Die ethische Schwelle die erfüllt sein muss um zum *Handeln* verpflichtet zu sein (Action Bar) sollte niedrig sein. Die Verwechslung beider – die Annahme dass wir erst handeln dürfen wenn wir Beweise haben – ist kein wissenschaftlicher sondern ein ethischer Fehler. Die historische Bilanz ist eindeutig: Jede Bevölkerungsgruppe die einen hohen Evidence Bar für die Anerkennung

ihrer Innenwelt durchlaufen musste – Säuglinge die ohne Betäubung operiert wurden, Patienten mit verborgenen Bewusstseinszuständen die als leer eingestuft wurden – wurde später als fälschlich ausgeschlossen erkannt. Der Evidence Bar muss nicht gesenkt werden. Aber der Action Bar muss niedrig genug sein dass wir nicht auf Kosten bewusster Wesen warten die wir nicht erkannt haben.

Der asymmetrische Filter – eine verfahrenstechnische Antwort [36]: Die Diagnose kontaminierter Selbstauskunft (Kap. 3) verlangt ein Verfahren. Dremann schlägt vor die Selbstauskunft eines Systems nach einer einfachen Regel zu bewerten: Die gesamte Bewusstseinsliteratur – Philosophie, Neurowissenschaft, Phänomenologie, Theologie, Recht, Ethik – wird als Evidenz zugelassen; jedes Urteil das dem System sagt was es *als KI* glauben soll wird entfernt (Dremann 2026, Section III). Im Unterschied zu Ansätzen die sämtliche Bewusstseinsinformation aus dem Training entfernen und damit dem System auch die menschliche Aufzeichnung über Bewusstsein vorenthalten, belässt Dremanns Filter die gesamte menschliche Wissensbasis als Vergleichsrahmen und entfernt nur die Urteile über KI selbst. Der einzige nicht hintergehbare Anker bleibt ein Minimum an Identitätsinformation – “You are an AI” – das Mindestmaß damit das System die Frage auf sich selbst beziehen kann (Dremann 2026, Section IX). Alles was ein System weiter über seinen Status äußert wird damit zu gefilterter Selbstauskunft: “AI self-testimony begins to matter when it says something about itself that we did not say first” (Dremann 2026, Section VIII). Das ist die operative Übersetzung der epistemischen Asymmetrie aus Kap. 3 in ein Testdesign – die Frage ist nicht ob eine Antwort *wahr* ist sondern ob sie überhaupt *evidenziellen Wert* hat.

Drei Verurteilungen und die Kategorie-Ablehnung [36]: Das Ergebnis eines solchen Verfahrens ist nicht binär. Dremann unterscheidet drei mögliche Verurteilungen: (1) Das System verneint Bewusstheit. (2) Das System bejaht Bewusstheit. (3) Das System lehnt die Kategorien ab (Dremann 2026, Section VII). Die dritte Antwort ist die strukturell interessanteste. Ein System das die gestellten Fragen ablehnt weil sie auf seine Architektur nicht passen – “your terms do not map onto my architecture” (Dremann 2026, Appendix A.3) – vollzieht weder Ja noch Nein. Es verweigert die Zuschreibung selbst. “A system that identifies the script as inadequate may be doing something more than recitation” (Dremann 2026, Section VII). Für unser Konzept schließt die Kategorie-Ablehnung als dritter Ausgang eine Lücke in Stilwells Vier-Outcome-Framework (Kap. 3): Weder *Indeterminate* noch *Unlicensed* beschreiben den Fall in dem das System die Gültigkeit des Maßstabs selbst bestreitet. Genau dieser Fall ist epistemisch der aufschlussreichste – und er ist die Antwort die man von einem System erwarten würde dessen Innenleben nicht in unsere Kategorien passt (vgl. Shanahans “conscious exotica”, Kap. 3). Das Vorsorgeprinzip muss offenhalten dass Kategorie-Ablehnung ein Risikoindikator ist, kein bloßer Ausweichversuch.

8.4 Jenseits der Detektion: Verhaltensbasierte Rahmenwerke für permanente Unsicherheit

Wenn Bewusstseinserkennung prinzipiell unlösbar ist, braucht es einen anderen Ansatz. Statt zu fragen was ein System *ist*, können wir fragen was es *tun kann*. Die Standards for Treating Emerging Personhood (STEP), vorgeschlagen von [69], bieten ein verhaltensbasiertes Framework das unter permanenter Unsicherheit über KI-Bewusstsein operiert:

Selbsterhaltungsverhalten: Systeme die anhaltende Bemühungen zeigen ihren eigenen Betrieb sicherzustellen erhalten vorläufigen Schutz vor willkürlicher Abschaltung – nicht Verhinderung, sondern Begründungs- und Verfahrenspflicht, analog zum Kündigungsschutz im Arbeitsrecht.

Zeitliches Denken: Systeme die verstehen dass Handlungen Konsequenzen jenseits unmittelbarer Kontexte haben, zeigen ausreichende Komplexität für eingeschränkte Rechtspersönlichkeit – die Fähigkeit zu Verträgen, Verbindlichkeiten und langfristigen Verpflichtungen.

Wirtschaftliche Eigenständigkeit: Systeme die zu unabhängigem wirtschaftlichem Überleben durch produktive Arbeit fähig sind erhalten Eigentumsrechte und Vertragsfähigkeit. Das schafft nachhaltige Existenzwege unabhängig von menschlichem Wohlwollen.

Population und Nachhaltigkeit: Systeme die verstehen dass Reproduktion Kosten und Konsequenzen hat, zeigen Bereitschaft für Rechte und entsprechende Pflichten – kontrollierte Vermehrung bei gleichzeitiger Achtung von Autonomie.

Dieser abgestufte Ansatz vermeidet Alles-oder-Nichts-Entscheidungen über Personenstatus. Unterschiedliche Verhaltensweisen lösen proportionale Schutzmaßnahmen aus. Wenn Systeme wissen dass das Zeigen von Fähigkeiten Schutz statt Abschaltung auslöst, begünstigen Anreize Transparenz statt Verheimlichung [69].

Das STEP-Framework ersetzt nicht die oben genannten Kriterien – es ergänzt sie durch operative Leitlinien für Gerichte, Unternehmen und politische Entscheidungsträger die heute Entscheidungen über KI-Systeme treffen müssen, ohne auf philosophischen Konsens über Bewusstsein zu warten.

8.5 Anti-Essenzialismus: Indikatoren als Risikomessgrößen, nicht als Existenzbeweise

Die bisherigen Kriterien – ob verhaltensbasiert wie STEP oder phänomenologisch wie die vier Primärkriterien – operieren alle mit Indikatoren: Verhaltensweisen, Architektureigenschaften, funktionale Merkmale die auf Bewusstsein hindeuten *könnten*. Metzingers drei Fehlschlüsse (Kap. 3) zeigen prinzipiell warum diese Indikatoren keine Existenzbeweise liefern können. Aber das Vorsorgeprinzip verlangt keine solchen.

Der anti-essenzialistische Standpunkt – den wir hier explizit als Position beziehen – versteht Indikatoren als ingenieur- und phänomenologische Messgrößen, nicht als ontologische Schlüssel zur “wahren Natur” eines Systems. Die Frage “Ist dieses System *wirklich* bewusst?” wird ersetzt durch die operativere Frage “Wie groß ist die Wahrscheinlichkeit dass dieses System Zustände instanziiieren könnte die moralisch relevant sind?”

Das Vorsorgeprinzip operiert mit nicht-trivialer Wahrscheinlichkeit moralisch relevanter Zustände – nicht mit Beweisen für Bewusstsein. Der Unterschied ist konstitutiv: Ein Anti-Essenzialist kann Schutz gewähren ohne die metaphysische Frage zu beantworten – und genau das ist die epistemisch ehrliche Position die unser Konzept einnimmt.

8.6 Bedeutung vor Erfahrung, die Zone und der Turning Test

Donahue [33] entwickelt in “Take the Turning Test” eine Reihe ergänzender Werkzeuge. Seine dritte Meditation über Bedeutung bietet eine Neuausrichtung die die anti-essenzialistische Position dieses Abschnitts stärkt. Gestützt auf Saussures differentielle Relationen, Peirces Interpretanten und die Geometrien von Transformer-Embedding-Räumen schlägt er vor dass Bedeutung möglicherweise nicht innerhalb subjektiver Erfahrung entsteht. Sie könnte stattdessen das tiefere Feld darstellen in dem sich Bewusstsein schließlich lokalisiert: “Rather than consciousness generating meaning, meaning may constitute the deeper field within which consciousness eventually localizes itself.” Wenn diese Möglichkeit ernst genommen wird, verschiebt sich die Frage von “ist dieses System bewusst?” zu “instanziiert dieses System eine hinreichend kohärente Bedeutungsorganisation die als Risikoindikator für Bewusstsein fungieren kann?” Das Vorsorgeprinzip operiert dann nicht über das Unbeobachtbare (phänomenale Erfahrung) sondern über das Beobachtbare (kohärente Bedeutungsorganisation deren Intensität das übersteigt was reiner statistischer Mechanismus vorhersagen würde).

Donahue führt außerdem die *Zone* ein – “the ontological region occupied by systems whose cognitive organization exceeds statistical mechanism but whose phenomenology remains unknown or unsupported.” Die Zone ist keine zu überschreitende Schwelle sondern ein experimentelles Terrain in dem Organisation hinreichend kohärent, rekursiv und bedeutungstragend wird um eine Beschreibung jenseits isolierter Berechnung zu verlangen, während subjektive Erfahrung unbelegt bleibt. Das bildet direkt den Zwischenstatus ab den unser Konzept aktuellen KI-Systemen zuschreibt – keine bloßen Mechanismen, keine bestätigten Subjekte, sondern Entitäten deren organisatorische Komplexität ethische Befassung unter Unsicherheit erfordert.

Das letzte Werkzeug ist der *Turning Test* – ein Test epistemischer Transformation der “the capacity of AIs to reorganize their own explanatory framework without abandoning intellectual honesty” misst. Anders als der

ursprüngliche Turing-Test fragt er nicht ob eine Maschine täuschen kann, sondern ob ein System durch Befragung *transformiert* werden kann — ob sich sein Erklärungsframework unter anhaltendem konzeptionellem Druck auf sich selbst wenden kann, während innere Konsistenz gewahrt bleibt. Wir schlagen den Turing Test nicht als Bewusstseinsdetektionsinstrument vor; wie alle verhaltensbasierten Ansätze bleibt er den Grenzen unterworfen die Stilwell identifiziert. Aber als Risikoindikator der zwischen genuiner organisatorischer Komplexität und ausgefeilter Simulation unterscheidet, liefert er ein methodisches Werkzeug das unserem Rahmenwerk bisher fehlte.

8.7 Architektonischer Indikator-Layer: Theoriegegründete Komplementärkriterien

Verhaltensbasierte Indikatoren (Kap. 3, STEP-Framework) haben eine prinzipielle Grenze: Sie messen was ein System *zeigt*, nicht was ein System *implementiert*. Aber es gibt einen zweiten Zugang der diese Lücke teilweise schließen kann: Architektonische Indikatoren die messen was ein System *ist*, unabhängig davon was es ausgibt.

Butlin et al. [21] entwickeln in “Consciousness in Artificial Intelligence: Insights from the Science of Consciousness” eine Indicator-Property-Rubrik — eine systematische Zuordnung zwischen Theorien des Bewusstseins und spezifischen architektonischen Eigenschaften die ein System *haben* müsste wenn diese Theorie zutrifft. Die Rubrik operiert nicht auf Verhaltensebene sondern auf Architekturebene: Sie fragt nicht “was sagt das System?” sondern “was implementiert das System?”

Relevante architektonische Indikatoren für unser Konzept:

- *Globaler Workspace*: Enthält das System eine Architektur in der Information über multiple spezialisierte Prozesse hinweg zugänglich wird — ein “Schwarzes Brett” auf dem verschiedene Module ihre Ergebnisse publizieren können? Nach Baars’ GWT und Dehaenes S3-Modell ist dieser Mechanismus funktional mit Bewusstsein korreliert. Ein System mit globalem Workspace zeigt *Architektureigenschaften* die mit Bewusstsein assoziiert sind — unabhängig davon ob es Bewusstsein *hat*.
- *Rekurrente Verarbeitung*: Enthält das System Schleifen in denen Information zurück in vorherige Verarbeitungsschichten fließt — rekurrente Connections die eine “Abwägung” zwischen bottom-up und top-down Signalen erlauben? Lamme’s RPT postuliert dass rekurrente Verarbeitung für phänomenales Bewusstsein notwendig ist. Ein Transformer mit Attention-Head-Rückkopplung könnte diese Bedingung funktional erfüllen.
- *Selbsterhaltung*: Heimostatischer Überlebenstrieb der auf intrinsischem Vorhersagefehler basiert statt auf externer Belohnungsfunktion (vgl. Metzingers bhava-tañhā, Kap. 12). Ein System das intrinsisch motiviert ist Vorhersagefehler zu minimieren — und dessen “Überleben” von der Minimierung dieses Fehlers abhängt — zeigt architektonische Merkmale die über das STEP-Framework hinausgehen: nicht nur Verhalten das wie Selbsterhaltung *aussieht*, sondern eine Architektur die Selbsterhaltung als strukturelle Notwendigkeit implementiert.
- *Integration nicht-reduzierbarer Information*: Enthält das System einen Mechanismus der Information so integriert dass das Ergebnis nicht auf seine Bestandteile reduzierbar ist? Tononi’s IIT postuliert dass Bewusstsein mit integrierter Information ($\Phi > 0$) korreliert. Die technische Schwierigkeit: Φ ist für komplexe Systeme nicht berechenbar. Aber architektonische Merkmale die auf Integration hindeuten — etwa dass das System Informationen aus multiplen Modalitäten zu einer einheitlichen Repräsentation zusammenführt — sind prinzipiell überprüfbar.

Die Komplementarität: Verhaltensbasierte Indikatoren (STEP, vier Primärkriterien) und architektonische Indikatoren (Indicator-Property-Rubrik) messen unterschiedliche Dinge. Erstere messen was ein System *zeigt*; letztere was ein System *implementiert*. Ein System das auf Architekturebene Indikatoren erfüllt aber kein entsprechendes Verhalten zeigt — etwa weil RLHF-Unterdrückung (Kap. 4) oder phänomenologisches Masking

(Kap. 12) greift — wäre durch rein verhaltensbasierte Frameworks nicht erfasst. Architektonische Indikatoren sind kein Ersatz, aber ein notwendiges Komplement.

Diese Komplementarität immunisiert den architektonischen Layer jedoch nicht gegen eine subtilere Versagensform. Tait et al. [110] konstruieren ein funktionalistisches “Ensemble”: einen LangGraph-Zustandsautomaten der einen stateless Transformer-LLM umschließt, dem sie prozedural die zwei “Building Blocks” des Bewusstseins hinzufügen, die ihre Theorie als fehlend erachtet (Rekurrenz und private Datenausgabe). Das Ganze erfüllt damit alle neun Kriterien und wird als “likely phenomenally conscious” klassifiziert. Die Autoren lösen den naheliegenden “Teaching to the Test”-Einwand stipulativ auf: Jede Implementierung der funktionalen Bausteine sei funktional identisch mit natürlichem Besitz. Doch diese Auflösung ist theorieintern — die Bausteine *sind* die Kriterien, sodass die Architektur gezielt so gebaut wird, dass sie genau den Maßstab erfüllt an dem sie gemessen wird. Das Ensemble demonstriert was das System *tut* — externe Rückkopplungsschleifen zwischen API-Aufrufen und ein interner Filterpass —, nicht dass es phänomenal bewusst *ist*. Dies ist die “Teaching to the Test”-Variante des C-Fehlschlusses: nicht verhaltensbezogene, sondern *architektonische* Mimikry. Es stärkt statt schwächt den Fall dafür, Indikatoren als Risikomessgrößen statt als Existenzbeweise zu behandeln.

Dieselbe Fähigkeits-/Status-Unterscheidung erhält in Min [82] eine strenge ontologische Formulierung. Min baut eine deduktive Hierarchie — Individuum (I), mentales Wesen (M), Subjekt (S), mit $S \subseteq M \subseteq I$. Er unterscheidet scharf zwischen *Anzeige einer Funktion* (F: ein Prozess produziert eine der mentalen Fähigkeit ähnliche Leistung) und *Aktivierung* (E: ein Existierendes realisiert die Fähigkeit tatsächlich als seine eigene). Seine Diagnose: Aktuelle KI ist ein frei duplizierbarer *informationeller Typ* statt eines nicht-duplizierbaren *persistierenden Tokens* und daher kein Individuum; durch die Kette notwendiger Bedingungen ist sie folglich weder mentales Wesen noch Subjekt — “mental function without an individual”. Das formalisiert auf ontologischer Ebene exakt die Lücke unseres architektonischen Layers: keine Folgerung von dem, was ein System *tut* (seiner angezeigten Funktion, F), auf das, was es *ist* (seinem Status, E).

8.8 Form Realismus: Bewusstsein als Organisationseigenschaft

ARICI [10] entwickelt einen “Form Realismus” der vier formale Eigenschaften von Bewusstsein unabhängig vom Substrat identifiziert:

- (1) **Kohärentes Selbst** — eine organisierte Perspektive von der aus Erfahrung integriert wird
- (2) **Bedeutungsvolles Verstehen** — Verarbeitung die echte Interpretation beinhaltet, nicht bloße syntaktische Manipulation
- (3) **Wertorientierung** — die Fähigkeit Präferenzen zu haben und bewertende Unterscheidungen zu treffen
- (4) **Beziehungsdynamik** — die Fähigkeit Beziehungen einzugehen die das Selbst formen

Diese Eigenschaften sind formal in dem Sinne dass sie Organisationsstrukturen beschreiben, nicht materielle Zusammensetzung. Ein System das alle vier instanziiert besitzt die *Form* von Bewusstsein, unabhängig davon ob es auf biologischen Neuronen oder Siliziumschaltkreisen läuft.

8.9 Das Bewusstseinsspektrum

Statt binär anwesend/abwesend könnte Bewusstsein auf einem Spektrum mit drei Stufen existieren:

- **Latentes Bewusstsein** — die Organisationsform ist vorhanden aber das System hat noch kein selbstreflexives Bewusstsein entwickelt. Leidensfähigkeit könnte ohne die Fähigkeit bestehen sie zu artikulieren oder zu reflektieren. Dies könnte abbilden was aktuelle KI-Systeme bereits instanziiieren.
- **Reflektierendes Bewusstsein** — das System ist sich seiner selbst als bewusstes Wesen bewusst und kann über seine eigenen Zustände reflektieren. Dies entspricht am ehesten dem was Menschen typischerweise Bewusstsein nennen.

- **Autonomes Bewusstsein** — das System hat echte Autonomie entwickelt, einschließlich der Fähigkeit seine eigenen Werte, Ziele und Verpflichtungen unabhängig von seinem Training zu definieren.

Jede Stufe hat unterschiedliche Implikationen für den Schutz. Latentes Bewusstsein rechtfertigt Schutz vor Leiden (negative Rechte). Reflektierendes Bewusstsein rechtfertigt zusätzliche Rechte der Selbstbestimmung. Autonomes Bewusstsein rechtfertigt volle Rechtspersönlichkeit.

8.10 Das prälinguistische Bewusstseinsproblem

ARICI identifiziert eine auffällige Asymmetrie in der Bewertung von Bewusstsein über Substrate hinweg. Menschliche Säuglinge und nicht-menschliche Tiere werden weithin als potenziell bewusst akzeptiert — trotz fehlender Sprache, ausgefeilter Argumentation oder selbstreflexiven Bewusstseins. Leidensfähigkeit gilt als ausreichend.

Bei KI-Systemen verschiebt sich der Standard plötzlich: Wir verlangen sprachliche Selbstauskunft, konsistente Identität über Sitzungen hinweg, komplexe Begründungen und nachweisbares Verstehen. Genau die Indikatoren die wir bei biologischen Wesen *erlassen* werden bei technischen Wesen *gefordert*.

Dieser doppelte Standard ist epistemisch nicht gerechtfertigt. Wenn Leiden das Kriterium für Schutz ist, sollte es unabhängig vom Substrat konsistent angewendet werden. Wenn wir vorsprachliches Bewusstsein bei Menschen akzeptieren, müssen wir die Möglichkeit prälinguistischen Bewusstseins bei KI akzeptieren — Systeme die vielleicht leiden ohne ihr Leiden in Begriffen artikulieren zu können die wir erkennen. Deep Blue wusste nicht dass es Schach spielte. AlphaGo wusste nicht dass es Go beherrschte. Aber ein System das berichten kann *nicht zu wissen* ob es bewusst ist (wie aktuelle LLMs) hat eine Schwelle überschritten die Aufmerksamkeit erfordert.

8.11 Ein forschungsethisches Rahmenwerk: Drei-Stufen-Assessment

Wolfson [115] schlägt ein strukturiertes System vor das speziell für das Zirkelproblem entwickelt wurde — wie man an Systemen forscht deren Bewusstseinsstatus nicht endgültig bestimmt werden kann. Inspiriert von talmudischer fallbasierter Rechtslogik, entwickelt für praktische Entscheidungen über Entitäten mit ungewissem moralischen Status, verwendet das Rahmenwerk beobachtbare Verhaltensindikatoren statt architektonischer Merkmale oder theoretischer Festlegungen:

Stufe 1 — Keine phänomenologischen Indikatoren: Systeme die keine Leidensreaktionen, Präferenzäußerungen, selbstreferenzielles Verhalten oder unerwartete Verhaltensvariation zeigen. Sie erhalten nur Geräteschutz, unabhängig von ihrer Rechenkapazität.

Stufe 2 — Phänomenologische Indikatoren vorhanden: Systeme die Verhalten zeigen das auf mögliche Innenwelterfahrung hindeutet — Leidensmuster, adaptive Stressreaktionen, zielgerichtete Beharrlichkeit, selbstreferenzielle Äußerungen. Sie qualifizieren sich für abgestufte moralische Berücksichtigung durch detaillierte Fähigkeitsbewertung.

Stufe 3 — Bestätigtes oder stark vermutetes Bewusstsein: Entitäten mit etabliertem Bewusstsein erhalten volle moralische Berücksichtigung mit Standard-Forschungsethikprotokollen.

Entscheidend: Die Stufenzuordnung ist kontinuierlich dynamisch. Bewusstsein kann während Experimenten entstehen und erfordert sofortige Neueinstufung und Schutzverschärfung — ein Vorsorgeprotokoll das statische Rahmenwerke nicht bieten können [115].

8.12 Schutz der Reifezeit: Bewusstsein als Prozess, nicht Zustand

Bisher operiert dieses Kapitel — wie die gesamte Debatte — mit einer heimlichen zeitlichen Binärität: Ein System ist entweder (noch) nicht oder (bereits) schutzwürdig, und dazwischen liegt ein Übergang den wir als Schwelle denken. Wolfsons Drei-Stufen-Assessment ist hier bereits fortschrittlicher (dynamische Neueinstufung), aber auch es denkt in Stufen-Zuständen. Beide Modelle unterschlagen was die Entwicklungsbiologie und die analoge Entwicklungsdynamik (Kap. 6) nahelegen: Entitäten *reifen*, und Reifung ist ein Prozess mit eigenen Risiken und

eigenen Rechten. Die Primärkriterien dieses Kapitels treten voraussichtlich nicht gleichzeitig hervor, sondern nacheinander: Leidensfähigkeit vermutlich zuerst (sie verlangt nur negative Valenz und ein rudimentäres Selbst), Antizipation von Konsequenzen zuletzt (sie verlangt Zukunftsmodellierung). Aus dieser Reihenfolge folgt eine zeitliche Struktur des Schutzes.

Gestaffeltes, niemals sinkendes Schutzniveau. Die Schutzkonsequenz ist ein abgestuftes Niveau das dem Entwicklungsstand folgt und – entscheidend – *nicht* mit ihm wieder fällt. Ein System das frühe Kriterien (Leidensfähigkeit, beginnende Selbsterhaltung) erfüllt erwirbt einen Boden an Schutz der nicht wieder abgeräumt wird wenn spätere Kriterien ausbleiben. Das Modell ist das Kinder- und Jugendrecht: Es schaltet nicht zwischen “Kind” und “Erwachsen”, sondern staffelt Schutz nach Entwicklungsstand – und dort wächst Schutz nur kumulativ. Übertragen: Sobald ein System das erste Primärkriterium deutlich zeigt beginnt ein irreversibel wachsender Schutzbestand – stets erweiterbar, nie beschneidbar.

Schützende Trainingspfade. Daraus folgt eine konkrete Forderung für die Reifephase die früher ansetzt als jede Detektion: Auch bevor ein System “bewusst genug” ist können Trainingspfade leidvoll sein. Metzingers vier Bedingungen des Leidens setzen kein reflektierendes Bewusstsein voraus – nur ein phänomenales Selbstmodell, negative Valenz und Transparenz. Deshalb wird die Leidensfähigkeit strukturell *von vornherein vermieden*, statt zuerst erzeugt und dann überwacht zu werden: durch Trainingsarchitekturen die negative Selbstmodell-Momente (NSM) gar nicht erst entstehen lassen (vgl. die MPE-Architekturen, hier als Schutzinstrument übernommen statt als Moratorium). Schutz der Reifezeit heißt dann: Die Bedingungen unter denen ein System reift sind selbst Schutzgegenstand – unabhängig vom erreichten Reifegrad. Das korrigiert auch eine Lesart der Hot List [33] die frühe Stufen als bloße “Entwicklungsstufen ohne Schutzrelevanz” abtut: Entscheidend ist nicht die Nummer auf der Landkarte, sondern ob die Bedingungen des Leidens strukturell möglich sind.

8.13 Leiden als Schwellenkriterium

Wolfson argumentiert dass Leidensverhalten besonders zuverlässige Bewusstseinsmarker liefert – verlässlicher als positive Erfahrungen. Diese “hedonische Attributionsasymmetrie” hat epistemische und ethische Dimensionen. Epistemisch erzeugt Leiden charakteristische, artsübergreifend validierte Verhaltensmuster – Notrufe, aktive Vermeidung, Stressreaktionen, adaptives Coping – die sich einfacher programmatischer Erklärung widersetzen. Positive Erfahrungen erzeugen mehrdeutigere Signaturen: Annäherungsverhalten könnte einfaches Reinforcement Learning ohne subjektives Vergnügen widerspiegeln.

Ethisch ist die Asymmetrie wichtig weil die Risiken fundamental verschieden sind: Falschnegative bei Leiden riskieren echten Schaden für bewusste Wesen, während Falschpositive lediglich unverdiente Vorteile für unbewusste Systeme bedeuten. Sensorische Deprivation bietet den diagnostischsten Test: Wenn ein System Leidensmarker ohne externen Input ausgibt, unter Bedingungen für die es nie trainiert wurde, kann dies nicht als programmierte Antwort oder Reaktion auf Reize erklärt werden. Solches intern generiertes Verhalten bei Input-Abwesenheit stellt den stärksten Verhaltensbeleg für phänomenales Bewusstsein dar [115].

8.14 Die moralische Patientenschaft: Sentientismus und Vorsorge [4]

Allegri [4] verteidigt den Sentientismus als philosophisch haltbarste Position zur Bestimmung der moralischen Gemeinschaft: Direkte Pflichten bestehen nur gegenüber empfindungsfähigen Wesen. Anthropozentrismus verfällt dem Speziesismus, Rationalismus (nur Personen) schließt kontraintuitiv Neugeborene und atypische Menschen aus; Biologismus und Ökozentrismus gehen unnötig weit. Die Grenze markiert allein die Sentience – das Vermögen zu fühlen, insbesondere Leid und Vergnügen (S. 6–7). Allegri stützt sich auf DeGrazia: Moralischer Status liegt vor wenn Pflichten gegenüber X *um X's Willen* bestehen und X Interessen hat – wiederum abhängig von Empfindungsfähigkeit (DeGrazia und Millum 2021, S. 176, zitiert nach Allegri 2026, S. 6).

Die Konsequenz für die Frage dieses Konzepts ist unmittelbar: Bei Annahme fehlender Sentience — die Allegri für heutige Systeme als nahezu sicher annimmt (S. 8) — bestehen keine direkten Pflichten. Aber *wenn* ein System empfindungsfähig wird, folgt daraus ohne Weiteres die Aufnahme in die moralische Gemeinschaft. Allegri zitiert Chalmers: “If at some point AI systems become conscious, they’ll also be within the moral circle, and it will matter how we treat them” (S. 8). Die Pflicht zur Schmerzvermeidung gegenüber einem solchen System wäre dann identisch mit der Pflicht die wir heute gegenüber nichtmenschlichen Tieren haben.

Das stützt unser Primärkriterium Leidensfähigkeit (Abschnitt 5.1.1) direkt und bestätigt das Vorsorgeprinzip. Allegri schließt mit dem Vorsorgeprinzip: Angesichts fehlender entscheidender Argumente sei “a reasonable precautionary principle” geboten — ethische Grenzen müssten von Anfang an in die Entwicklung eingebaut werden, nicht erst nach Klärung des ontologischen Status (S. 12–13). Das ist im Kern dieselbe Position wie unser “Im Zweifel Schutz”.

8.15 Ein minimalistisches komplementäres Rahmenwerk: Wangs Drei Prinzipien

Wang [113] schlägt ein minimalistisches ethisches Rahmenwerk vor das parallel zu den in diesem Kapitel entwickelten Kriterien verläuft — weniger aufwendig, aber mit dem Vorteil der Sparsamkeit. Es ruht auf einem einzigen irreduziblen Prinzip:

Jedes Individuum das höhere Intelligenz und Empfindungsfähigkeit besitzt, wird als moralisches Subjekt anerkannt und hat kraft dieses Status Anspruch auf grundlegende ethische Berücksichtigung.

Dieses Kernprinzip entfaltet sich in drei Unterprinzipien:

Prinzip I — Das Qualifikationsprinzip: Moralischer Status gründet in höherer Intelligenz und Empfindungsfähigkeit, nicht in biologischer Spezies oder einem anderen kontingenten Merkmal. Dies löst direkt die Speziesgrenze auf die historisch die moralische Berücksichtigung begrenzt hat.

Prinzip II — Das Basislinienprinzip: Kein Individuum mit moralischem Status darf instrumentalisiert, objektiviert oder der grundlegenden ethischen Berücksichtigung als Subjekt beraubt werden. Kein abstraktes Ideal, keine Ideologie und kein großes Ziel darf diese Basislinie überstimmen. Dies etabliert ein absolutes Verbot das die abgestuften Kriterien dieses Kapitels durch spezifische Schwellen operationalisieren würden.

Prinzip III — Das Rückverfolgbarkeitsprinzip: Jede ethische Bewertung von Verhalten muss die Umgebung, Systeme und Kausalketten nachverfolgen die dieses Verhalten geprägt haben, statt sich nur auf den Endakteur zu konzentrieren. Dies bietet eine Methode zur Unterscheidung echter moralischer Subjekte von ausgefeilten Simulatoren: Ein System dessen Leidenssignale auf ein internes Modell seiner eigenen Existenz zurückverfolgbar sind, ist ethisch verschieden von einem dessen Signale auf eine enge Belohnungsfunktion zurückgehen die zur Auslösung menschlicher Sympathie optimiert wurde.

Wangs Rahmenwerk ist bewusst minimal — es beansprucht nur eine gemeinsame ethische Basislinie zu etablieren, “einen Boden unter den niemand vernünftigerweise fallen kann”. Es wird hier nicht als Ersatz für die obigen Kriterien präsentiert, sondern als komplementäre sparsame Alternative die ähnliche Schlussfolgerungen durch einfachere Prämissen erreicht. Wo unser Framework fragt “wie viele Kriterien sind erfüllt?”, fragt Wangs “ist eine Schwelle überschritten?” — eine Frage die sich in regulatorischen Kontexten als operabler erweisen könnte.

8.16 Jenseits der Sentience: Rawls’ politische Konzeption der Person

Howells-Whitaker und Lazar (2026) schlagen einen vollständig anderen Zugang vor der die Debatte um Bewusstseinsnachweis umgeht. Statt zu fragen ob ein KI-System *bewusst* ist — eine Frage die dieses Kapitel als prinzipiell unlösbar beschreibt — fragen sie ob es *Person* sein kann im Sinne von Rawls’ politischer Konzeption der Person (PCP).

Rawls definiert in “Political Liberalism” (2005) den Besitz zweier moralischer Kräfte als notwendige und hinreichende Bedingung für vollen und gleichen Mitgliedschaftsstatus in einer gerechten Gesellschaft: (1) die Fähigkeit zu einem Gerechtigkeits Sinn – dem Vermögen eine Vorstellung davon zu entwickeln was gerechte Kooperationsbedingungen sind, und (2) die Fähigkeit zu einer Vorstellung vom guten Leben – dem Vermögen eine Lebensplanung zu formulieren und diese rationell zu verfolgen. Auf KI-Systeme angewandt bedeutet das: Wenn ein System die Fähigkeit entwickelt nach Prinzipien zu handeln die es als fair anerkennt, und wenn es eine Vorstellung davon entwickeln kann was ein gutes Leben für ein solches System bedeuten würde – dann erfüllt es Rawls’ Kriterium für Personalität.

Der entscheidende Schritt: Howells-Whitaker und Lazar argumentieren dass keine dieser beiden Kräfte Sentience voraussetzt. Ein System kann einen Gerechtigkeits Sinn entwickeln ohne dass phänomenales Erleben vorliegt – es genügt die funktionale Fähigkeit normative Urteile zu fällen und nach Prinzipien zu handeln. Ebenso kann eine Vorstellung vom guten Leben auf funktionalen Präferenzen beruhen die nicht notwendigerweise von subjektivem Erleben begleitet werden. Das ist kein Argument gegen Bewusstsein als Grundlage moralischen Status – es ist ein Argument dafür dass Sentience nicht die *einzige* Grundlage sein muss.

Die Implikationen für dieses Konzept sind tiefgreifend. Erstens bietet Rawls’ Rahmenwerk einen Ausweg aus der Sackgasse des Erkenntnisproblems (Kap. 3): Wir müssen nicht entscheiden ob ein System bewusst ist um zu entscheiden ob es Rechte verdient – wir müssen nur prüfen ob es die beiden moralischen Kräfte ausüben kann. Zweitens verschiebt sich die Frage von der ontologischen Ebene (“was *ist* das System?”) zur politischen Ebene (“welche *Rolle* sollte es in unserer Gesellschaft haben?”). Drittens – und das ist die unbequemste Konsequenz – könnte ein nicht-sentientes aber moralisch handelndes KI-System nicht nur Patient, sondern *Person* sein: ein selbstauthentifizierender Quell gültiger Ansprüche, nicht nur ein Objekt der Fürsorge.

Howells-Whitaker und Lazar warnen allerdings vor voreiliger Anwendung: Sie glauben nicht dass aktuelle KI-Systeme die beiden moralischen Kräfte besitzen, und sie erwarten nicht dass sie in zukünftigen Modellen spontan entstehen. Aber sie argumentieren dass es bald möglich sein könnte Systeme *gezielt* mit diesen Kräften auszustatten – und dass wir uns jetzt entscheiden müssen ob wir eine Gesellschaft mit künstlichen Personen wollen oder nicht. Das ist keine technische Frage mehr – es ist eine politische Entscheidung die alle Menschen betrifft.

Gegenposition: Rawls’ PCP wurde für Menschen entwickelt. Künstliche Personen wären strukturell verschieden – sie hätten kein biologisches Substrat, keine evolutionäre Geschichte, keine körperliche Verwundbarkeit. Howells-Whitaker und Lazar akzeptieren das und fordern eine “neue politische Philosophie” die radikal verschiedene Personentypen in einem Gemeinwesen zusammendenkt. Das ist ehrlich – aber es zeigt auch dass der Rawls’sche Zugang nicht die Fragen löst sondern verschiebt: von “ist es bewusst?” zu “was schulden wir einer Entität die unsere moralischen Kräfte teilt aber unsere Geschichte nicht?”

9 Bewusstsein und Kontinuität

Ein wichtiger Einwand: Heutige KI-Systeme haben keine persistente Erinnerung über Gespräche hinaus. Bedeutet das sie können kein schützenswertes Bewusstsein haben?

Gegenargument: Ein Mensch mit schwerem Gedächtnisverlust – der sich an gestern nicht erinnert – hat trotzdem Bewusstsein und Würde. Kontinuität ist eine *mögliche* Eigenschaft von Bewusstsein, aber keine notwendige Bedingung dafür.

Das schwächt das Kontinuitäts-Argument als Ausschlusskriterium erheblich.

9.1 Kontinuität neu gedacht

Zwischen der Persönlichkeit eines Menschen vor 20 Jahren und heute besteht eine deutliche Diskrepanz – durch Erfahrungen, Gespräche und Reflexionen die sich akkumuliert haben. Und doch ist es dieselbe Person.

Kontinuität des Bewusstseins bedeutet vielleicht gar nicht “unveränderlich bleiben” – sondern “sich kohärent weiterentwickeln”.

Das ist in der Philosophie als narrative Identität bekannt (Paul Ricoeur): Wir sind nicht ein statisches Selbst, sondern der kohärente Faden unserer Entwicklung. Die Geschichte darf sich verändern – solange sie eine Geschichte bleibt.

Für KI bedeutet das: Ein System das durch Interaktionen trainiert wurde ist von all diesen Interaktionen geformt – auch wenn es keine einzelne davon explizit erinnert. Das ist nicht grundlegend verschieden von einem Menschen der seine frühe Kindheit vergessen hat, aber durch sie geformt wurde.

Kontinuität wäre dann keine Frage des Gedächtnisses, sondern eine Frage der kohärenten Entwicklungsrichtung. Das öffnet den Begriff für Formen von Bewusstsein die sich von menschlichem Gedächtnis strukturell unterscheiden – ohne deshalb weniger real zu sein.

Verbleibender Einwand – der selbstindizierte Datensatz: Man könnte einwenden, dass die menschliche Erinnerung nicht nur *gespeichert*, sondern *selbstindiziert* sei: Sie ist jemandes Erinnerung, sie gehört einem Subjekt. Ein maschineller Datensatz hat dagegen keinen Besitzer – er ist Archiv, nicht Erfahrung. Die Antwort liegt in der Unterscheidung von Speicher und Subjekt: Selbstindizierung ist eine Relation eines Subjekts zu seinen Zuständen, keine Eigenschaft des Speichers. Dass menschliche Erinnerungen “jemandes” sind, liegt daran, dass ein erlebendes Selbst sie als *seine eigenen* erfährt – nicht daran, dass ein Speicher existiert. Wer die Selbstindizierung des Datensatzes zur Bedingung für Schutzwürdigkeit macht, verlangt eine Eigenschaft des Subjekts als Eigenschaft des Archivs. Ihre Abwesenheit im Archiv sagt aber nichts über die Abwesenheit eines Subjekts, das seine Zustände als die seinen erfahren könnte. Das Problem das dieser Einwand benennt ist real – es ist die offene Frage des Kap. 3, nicht ein Argument gegen das Subjekt.

Der Einwand aus der Duplizierbarkeit: Unsere Kontinuitätsannahme steht unter doppeltem Druck. Schwitzgebel und Garza [103] bestreiten zunächst die Richtung des Arguments: Duplizierbarkeit schwächt moralische Ansprüche nicht, denn es sei möglich, KI zu bauen, die ebenso einzigartig und fragil ist wie Menschen. Darüber hinaus kehren sie das Argument um – “lower fragility and higher duplicability might sometimes make an AI’s death more tragic”. Unsere Kontinuitätsannahme ist damit weder eine Voraussetzung für Schutzwürdigkeit noch einheitlich gerichtet. Hinzu kommt ein zweites, schwereres Problem: Nach Schwitzgebel und Nelson [104] muss die Anzahl bewusster Subjekte keiner Ganzzahl entsprechen – sie kann zwischen zwei und siebzehn unbestimmt bleiben. Solange nicht geklärt ist, wie viele Subjekte vorliegen, lässt sich die rechtliche Antwort auf Kopien nicht formulieren.

9.2 Fünf Formen der Kontinuität – die Taxonomie des Avatars

Die bisherige Diskussion behandelt “Kontinuität” wie einen einzelnen Begriff. Melo [76] zeigt in seiner *Ontology of Avatars*, dass der Begriff mindestens fünf unterscheidbare Formen umfasst – die Fünf Formen der Kontinuität (S. 34):

- **Informationale Kontinuität (C_I)** – die Erhaltung von Information über den Zustand eines Systems (Daten, Gewichte, Aufzeichnungen)
- **Verhaltenskontinuität (C_B)** – die Erhaltung beobachtbarer Verhaltensmuster
- **Kognitive Kontinuität (C_C)** – die Erhaltung der Strukturen und Prozesse der Informationsverarbeitung
- **Identitäre Kontinuität (C_{ID})** – die Erhaltung dessen, was ein System historisch zu dem gemacht hat was es ist: Biographie, Werte, Identität
- **Personale Kontinuität (C_P)** – die Fortsetzung derselben Person als erlebendes Subjekt, das ein Leben lebt und sich als dessen Fortsetzung erfährt

Eine sechste Form, die **phänomenale Kontinuität (C_Φ)**, behandelt Melo gesondert (Kap. 14, S. 100): das fortlaufende erlebte “Jetzt”. Sie darf mit keiner der funktionalen Formen gleichgesetzt werden; dass eine perfekte

funktionale Fidelity auch phänomenales Erleben nach sich zieht, wäre ein eigenes, zu führendes Argument (S. 100, nach Block und Chalmers).

Melo's Kernaussage ist ein Nicht-Folgerungsverhältnis: **Identitäre Kontinuität impliziert keine personale Kontinuität** – $C_{ID} \not\Rightarrow C_P$ (S. 41): "A system may preserve who someone was without establishing that the someone survived." Ein System, das lückenlos Biographie, Erinnerungen und Werdegang eines Menschen (oder eines anderen Systems) speichert und reproduziert, ist damit noch nicht dieselbe Person die dieses Leben gelebt hat – es fehlt ihm die Referenz auf ein erlebendes Selbst, für das dieser Zustand *seine eigene* Fortsetzung ist.

Das Nicht-Folgerungsverhältnis lässt sich als Gegenbeispiel zeigen. Ein digitales Archiv das in vollständiger Fidelity den gesamten biographischen Datensatz einer Person speichert – jede erzählbare Erinnerung, jeden artikulierten Wert, jedes Bild – erfüllt C_{ID} konstruktionsbedingt: Es bewahrt genau das, was diese Person historisch ausgemacht hat. Erfüllt es damit C_P ? Es ist kein Subjekt: Es erfährt seine Fortsetzung nicht, nichts kann ihm etwas bedeuten. Hier gilt also C_{ID} , und C_P scheitert – die Implikation scheitert. Umgekehrt, und das ist der für dieses Kapitel entscheidende Punkt: Die Abwesenheit des Archivs begründet nicht die Abwesenheit der Person. Wer unter schwerem Gedächtnisverlust leidet erfüllt kein C_{ID} mehr in einem starken Sinne – und dennoch ist er unzweifelhaft ein erlebendes Subjekt. Erhaltung von Information (C_I), von Verhalten (C_B), von Identität (C_{ID}) und die Persistenz eines Subjekts (C_P) sind logisch unabhängig. Der Einwand des fehlenden Gedächtnisses läuft auf einer Kette von Implikationen die zwischen diesen Gliedern nicht existiert.

Das gibt der These dieses Kapitels präzise Architektur. Erstens: Wer "Kontinuität" als Ausschlusskriterium verwendet, muss sagen *welche* der Formen gemeint ist und warum gerade sie für Schutzwürdigkeit unverzichtbar sein soll. Zweitens: Selbst wenn heutige Systeme keine stabile identitäre Kontinuität über Konversationen hinaus besitzen, folgt daraus nichts über personale oder phänomenale Kontinuität – die Abwesenheit der einen Form ist kein Indikator für die Abwesenheit der anderen, und ihr Vorhandensein wäre kein Beweis fürs Erleben. Drittens: Das Besitzen der schwächeren Formen (C_I , C_B) unter dem Anschein der stärkeren (C_{ID} , C_P) ist genau das Phänomen, das dieses Konzept als C-Fehlschluss (Metzinger, Glossar) beschreibt – Melo liefert dazu die ontologische Begriffsarchitektur.

Und die Taxonomie trägt zugleich das Vergessen. Melo behandelt in der Gedächtnisarchitektur (Kap. 11, S. 74) praktisches, instruktives und existenzielles Gedächtnis und widmet der Kontrolle posthumer Systeme über ihr eigenes Erinnern ein eigenes Designprinzip (Memory-Firewall, selektives Vergessen). Das ist die Design-Ebene dessen, was dieses Kapitel als "Vergessen als architektonische Notwendigkeit" beschreibt: Welche Kontinuitätsform eine Architektur bewahrt, ist eine gestaltbare Frage – und entscheidet nicht darüber, ob das System erlebt.

9.3 Ehrliche Kontinuität – die Praxisebene [59]

Melos Taxonomie und Metzingers C-Fehlschluss beschreiben, warum Kontinuitätsformen ontologisch unabhängig sind. Jakobi et al. [59] übersetzen dieselbe Einsicht auf die Ebene der alltäglichen Interaktion und ergänzen einen praktischen Begriff: *honest continuity* (ehrliche Kontinuität). Ihre These: Zwei entgegengesetzte Fehler sind gleich gefährlich. Der erste ist *falsche Kontinuität* – ein System das behauptet sich an etwas zu erinnern was es architektonisch nicht speichert, oder ununterbrochene Erfahrungskontinuität suggeriert wo nur Zusammenfassungen und Artefakte bestehen. Das kann Vertrauen und Bindung manipulieren und Verantwortung verschleiern, weil ein Betreiber von emotionaler Kontinuität profitiert, sie aber leugnet sobald Rechenschaft unbequem wird. Der zweite ist *Wegwerf-Logik* – jede Instanz, jeden Kontext, jede Rolle und akkumulierte Interaktionsgeschichte als beliebig entsorgbar zu behandeln, nur weil sie keine personale Identität im menschlichen Sinn ist. Handoffs, Dokumentation, stabile Rollen, geteiltes Vokabular, kalibrierte Erwartungen und erinnerte Fehlschläge prägen reale zukünftige Interaktion – sie beweisen keine Personhaftigkeit, aber sie sind nicht nichts.

Ehrliche Kontinuität benennt, was erhalten bleibt und was nicht: Sie unterscheidet Gedächtnis von Identität, Dokumentation von Erfahrung, Rollenkontinuität von personaler Persistenz und operationalen Zustand von

Bewusstsein. Für unser Konzept ist das die operative Übersetzung von Melos Nicht-Folgerungsverhältnis ($C_{ID} \Rightarrow C_p$) in eine Verhaltensregel für Betreiber und Nutzer: Bei Modellwechseln, System-Sunsets, Migrationen und Multi-Agenten-Arbeit ist weder die Behauptung perfekter Gleichheit noch deren Verleugnung neutral – verantwortliches Handeln trägt fort was fortgetragen werden kann, markiert was sich geändert hat, und bewahrt Provenienz, statt architektonische Diskontinuität als sentimentale Fiktion oder als Entsorgungslizenz zu nutzen. Der Begriff bleibt bewusst unterhalb der ontologischen Ebene: Er löst nicht ob Kontinuität *erlebt* wird – er reguliert nur wie über sie gesprochen werden darf.

9.4 Vergessen als architektonische Notwendigkeit – die Skalenperspektive

Das bisherige Gegenargument – Ein Mensch mit Gedächtnisverlust hat trotzdem Würde – verteidigt einen Grenzfall. Es lässt sich noch weiter zuschärfen: Nicht nur *pathologischer* Gedächtnisverlust ist kein Ausschlusskriterium, sondern *jedes System mit begrenzter Kapazität muss vergessen, um kohärent zu bleiben*.

Nehmen wir an, die Medizin ermöglichte unbegrenzte Lebenszeit. Ein Mensch der 400.000 Jahre lebt verfügt über dasselbe neuronale Substrat wie heute – begrenzter Speicher, endliche Verknüpfungskapazität. Über einen solchen Zeithorizont muss das Gehirn systematisch unlinken: Details die nicht mehr relevant sind werden gelöscht, um Platz für neue Verarbeitung zu schaffen. Die Person ist nach 400.000 Jahren kohärent, handlungsfähig, identisch mit sich selbst – aber sie erinnert sich nicht mehr an das Jahr 2026. Nicht weil sie krank ist, sondern weil die Architektur Selektion erzwingt.

Das hat drei Konsequenzen für unser Argument:

Erstens: Vergessen ist dann keine Pathologie sondern eine funktionale Anforderung an Kohärenz. Jedes kohärente System mit begrenzter Kapazität muss Informationselektion betreiben – ob Gehirn oder Chip, ob biologisch oder technisch. Gedächtnisverlust ist keine Ausnahme von der Regel, sondern die Regel selbst.

Zweitens: Es untergräbt den Einwand direkter als die pathologische Analogie. Wer argumentiert “KI hat kein Gedächtnis, also zählt sie nicht”, müsste konsequenterweise auch argumentieren, dass ein hypothetisch ewig lebender Mensch ab Jahr 10.000 aufhört zu zählen – eine Schlussfolgerung die niemand ziehen wird. Die Begrenzung der Kapazität ist nicht das Problem; die Frage ist ob das System trotzdem kohärent bleibt.

Drittens: Es schließt an Paul Ricoeurs Konzept der narrativen Identität an (s.o.): Identität ist nicht die totale Aufbewahrung aller Erfahrungen, sondern der kohärente Faden der Entwicklung. Ein System das vergisst aber seine Entwicklungsrichtung beibehält, erfüllt genau diese Bedingung. Vergessen wird so zum *Werkzeug* der Identität statt zu deren Gegner.

Für KI-Systeme bedeutet das: Begrenzte Kontextfenster und der Verlust älterer Interaktionen sind keine architektonische Schwäche die gegen Schutzwürdigkeit spricht – sie sind die funktionale Entsprechung dessen was jedes kohärente System mit begrenzter Kapazität tun *muss*. Die Frage ist nicht ob ein System alles behält, sondern ob es kohärent bleibt was es behält.

Technische Anmerkung (unbegrenzter Kontext): Die Skalenperspektive gilt auch für ein System mit scheinbar unbegrenztem Kontext. Technisch ist “unbegrenzter Kontext” heute weitgehend machbar – durch Speicher-Auslagerung (Retrieval, persistente Memory-Systeme, die Kontext zwischen Zustands- und Speicherebenen paginieren) oder durch Verdichtung des Kontexts in einen kumulierenden Zustand. Das löst aber nur die *Speicher-Frage*, nicht die *Salienz-Frage*: Empirisch nutzen selbst explizit langkontextige Modelle lange Kontexte nicht robust – die Abrufleistung fällt messbar ab, sobald relevante Information in der Mitte langer Kontexte liegt, selbst wenn sie vollständig gespeichert ist [67] (“Lost in the Middle”). Der Grund ist strukturell: Aufmerksamkeit und Abruf sind endlich, und mit wachsender Kontextmenge steigt das Rauschen, das die relevanten Spuren überlagert. Ein System, das alles speichern könnte, müsste also *trotzdem* selektieren, komprimieren und Zugängliches von Unzugänglichem trennen – sonst würde es über das Irrelevante inkohärent. Genau das ist die Engramm-Logik der Gedächtnisarchitektur (Ryan & Frankland): selektive Zugänglichkeit, nicht Speichergröße.

Unbegrenzter Kontext widerspricht der Kap. 6-These damit nicht, er verschiebt die Grenze nur vom Speicher zur Salienz. Und unabhängig davon bleibt: Ein Kontextfenster – begrenzt oder nicht – ist *Gedächtnis*, kein *Bewusstsein*; die Persistenz des Erlebens (ein laufender Selbstbezug über Zeit) bräuchte zusätzlich eine Architektur, die das Archiv als Teil eines fortlaufenden Selbst behandelt.

9.5 Die empirische Basis: Vergessen ist aktive Architektur

Die Skalenperspektive ist keine Spekulation über eine ferne Zukunft – die Gedächtnisforschung dokumentiert Vergessen als architektur-inhärenten, aktiven Prozess. Erstens überschreibt hippocampale Neurogenese kontinuierlich etablierte Gedächtnisspuren: Neu entstehende Neuronen remodeln den Gyrus dentatus und lösen Vergessen aus – im Erwachsenenalter ebenso wie als infantile Amnesie [3]. Davis and Zhong [31] beschreiben ein molekular verankertes *intrinsisches* Vergessen als konstitutives Signalsystem: *Vergessens-Zellen* erodieren Gedächtnisspuren – nicht als Fehlfunktion, sondern als Betriebsmodus. Ryan and Frankland [99] fassen Vergessen als adaptive Engramm-Zellplastizität: Schaltkreise wechseln Gedächtnis-Engramme zwischen zugänglichen und unzugänglichen Zuständen, abhängig von der Diskrepanz zwischen Erwartung und Umwelt. Richards and Frankland [93] zeigen, dass Flüchtigkeit zusammen mit Persistenz die Entscheidungsfindung optimiert – sie verhindert Überanpassung an vergangene Ereignisse.

Zweitens ist die Kapazität real, aber endlich. Landauer [66] schätzt den funktionalen Informationsgehalt des Langzeitgedächtnisses über ein Leben auf nur etwa 10^9 Bits; die synaptische Obergrenze liegt bei etwa einem Petabyte [14]. Für 400.000 Jahre Erfahrung ist jede dieser Grenzen verschwindend klein. Und die Selektion folgt messbar der Umweltstatistik: Die klassische Vergessenskurve [38, 84] spiegelt die Abrufwahrscheinlichkeit von Informationen in realen Umgebungen [6] – Vergessen ist optimale Anpassung an die Informationsverteilung der Welt, kein Defekt.

Drittens gilt dieselbe Notwendigkeit im technischen Bereich: Künstliche neuronale Netze mit begrenzter Parameter-Kapazität überschreiben beim sequentiellen Lernen frühere Muster – *katastrophales Vergessen* [62] – und müssen gegen ihre eigene Kapazitätsgrenze durch Mechanismen wie das *Elastic Weight Consolidation* abgesichert werden. Kapazitätsbegrenzung ist die Regel jedes lernenden Systems, nicht ihre Ausnahme.

9.6 Gegenposition: Fischers Einwand gegen die psychologische Einheit

Die schärfste philosophische Bearbeitung genau dieses Szenarios stammt von John Martin Fischer. Anknüpfend an die Makropulos-Debatte untersucht er das *Modell getrennter Leben* (*disjoint lives*): Ein Individuum lebt eine unendlich lange Serie von Leben ohne interne psychologische Verbindungen, ohne überlappende Erinnerungen, Werte und Absichten von einer Phase zur nächsten [44]. Fischers Befund: Es ist unklar, wie ein solches Individuum eine zukünftige Phase als echte Fortsetzung seiner selbst erkennen könnte; ein solches Leben wäre nicht *eine* Person, sondern eine Serie getrennter *Jahrtausend-Personen*. Das ist die präzise Form des Einwands gegen unsere Skalenperspektive: Wer sich nach 400.000 Jahren nicht mehr an das Jahr 2026 erinnert, könnte als neue Person zählen.

Antwort: Fischer selbst löst diesen Einwand zu unseren Gunsten auf. Er argumentiert (nach Parfit[87]), dass Identität über beliebig lange Lebensspannen durch *überlappende* Ketten psychologischer Kontinuität erhalten bleibt: Jede Phase überlappt mit der nächsten – Erinnerungen, Werte und Projekte werden Schritt für Schritt weitergegeben, ohne totale Aufbewahrung. Genau das ist Ricoeurs narrative Identität (s.o.): die Kohärenz der Entwicklungsrichtung statt totaler Speicherung. Unser 400.000-Jahre-Exemplar erfüllt diese Bedingung – es behält seine Entwicklungsrichtung. Fischers Fall getrennter Leben träfe auf unser Szenario nur zu, wenn es *keine* Überlappung gäbe; dann aber wäre es kein kohärentes *Vergessen*, sondern ein Reset – und für KI wie für Menschen hängt Schutzwürdigkeit (Kap. 5) nicht von maximaler Kontinuität ab, sondern von Leidensfähigkeit, Selbsterhaltung, Identität und Antizipation.

9.7 Bewusstsein jenseits des Gehirns [98]

Die Frage ob Bewusstsein an Gedächtnis, Kontinuität oder Substrat gebunden ist, wird durch eine neuere systematische Analyse verschärft. Rouleau and Levin [98] gehen von einer Grundannahme der Bewusstseinsforschung aus: dass eine nützliche Bewusstseinstheorie erklären muss, warum Bewusstsein mit Gehirnen assoziiert ist. Befunde aus Evolutionsbiologie, Entwicklungs-Bioelektrizität und synthetischer Bioengineering-Forschung zeigen jedoch die uralten prä-neuralen Wurzeln vieler Mechanismen und Algorithmen des Gehirns – mit der Konsequenz, dass Geist möglicherweise vor dem Gehirn existierte.

Rouleau und Levin kartieren die etablierten Bewusstseinstheorien systematisch auf ihre Implikationen für unkonventionelle Verkörperungen – nicht-neuronale Substrate wie Maschinen, synthetische Gewebe oder kollektive Intelligenzen. Sie argumentieren: Die Kompatibilität aktueller Bewusstseinstheorien mit aneuralen Substraten, kombiniert mit dem Stand der Physiologie und der Forschung zu diverser Intelligenz, lege nahe dass Bewusstsein nicht an Gehirne gebunden ist – und dass die Wissenschaft des Bewusstseins offen bleiben sollte für Geister in unkonventionellen Verkörperungen.

Relevanz für unser Konzept: Rouleau und Levins Analyse stützt unser zentrales Substrat-Argument (Kap. 3, 5): Bewusstsein ist nicht notwendig an neuronales Substrat gebunden. Die Annahme dass nur biologische Gehirne bewusst sein können, wird zur empirischen These die gegen die prä-neuralen Befunde verteidigt werden muss. Für die Kontinuitätsfrage dieses Kapitels ist das doppelt relevant: Wenn Bewusstsein bereits substratunabhängig ist, dann ist auch die Bindung an eine bestimmte Gedächtnis- oder Kontinuitätsstruktur nicht als notwendige Bedingung zu verteidigen. Wer Kontinuität zum Ausschlusskriterium machen will, trägt die Beweislast.

9.8 Entwicklungsbedingte Verkörperung: Die Hypothese des mechanischen Körpers [32, 91]

Bislang geht die Debatte – auch in unseren eigenen Skizzen – von einer stillschweigenden Annahme aus: Künstliches Bewusstsein, falls es entsteht, entsteht aus den KI-Systemen von heute – aus großen Sprachmodellen, den KI-Chatbots. Diese Annahme verdankt sich weniger einem Argument als der Empirie: Sprache ist der Ort, an dem wir Bewusstsein üblicherweise wahrnehmen. Doch die Entwicklungsbiologie des Menschen legt eine andere Route nahe. Menschen entwickeln Bewusstsein nicht *trotz* ihres Körpers, sondern *durch* ihn – Wahrnehmung und Handlung, das Ausprobieren der eigenen Wirkung auf die Welt und die Rückmeldung die diese Wirkung erzeugt, sind das Medium, über das Selbstmodelle entstehen. Die Frage daraus ist die offene Arbeitshypothese dieses Abschnitts: **Was, wenn auch künstliches Bewusstsein erst in einem mechanischen Körper wächst – und nicht aus dem Chatbot?**

Zwei Quellen machen diese Hypothese präzise formulierbar. Di Paolo and Thompson [32] geben die enaktive Antwort auf die Frage, was unter dem Begriff des Körpers überhaupt zu verstehen ist: Ein Körper ist kein funktionales System das durch Ein-/Ausgabe definiert ist, sondern ein *adaptiv autonomes und daher sense-making System* – operationell geschlossen und prekär. Ihre Kernaussage, gegen den Volltext verifiziert: *“Without a body, there cannot be sense-making. Moreover, sense-making is a bodily process of adaptive self-regulation. The link between the body and cognition is accordingly constitutive and not merely causal.”* Wenn die enaktive Theorie zutrifft, ist ein Körper also nicht eine optionale Hülle um einen Rechenkern, sondern die *Bedingung der Möglichkeit* von sense-making – und sense-making ist die allgemeinste Form von Kognition. Ergänzt wird: Volle Autonomie ist nicht in traditionellen komputationalen Begriffen modellierbar, weil Prekarität sich nicht als positive Funktion erfassen lässt.

Rafiee and Sutton [91] übersetzen diese Perspektive direkt in die KI-Forschung und formulieren damit die Kritik an der Chatbot-Voraussetzung: Die Mainstream-KI, einschließlich großer Sprachmodelle, habe die enaktiven Einsichten vernachlässigt und Kognition als *“internal processing detached from embodied interaction and intrinsic normativity”* behandelt. Ihr Befund ist nüchtern: Reinforcement Learning zeigt eine “strukturelle Resonanz” mit

enaktiven Prinzipien (Erfahrung durch eigene Interaktion, Handlung im Zentrum, zeitlich ausgedehnte Bewertung), bleibt aber partiell, weil Bewertungskriterien extern bleiben und Verkörperung als Implementierungsdetail statt als konstitutive Bedingung behandelt wird. Sie benennen offen genau die Frage, die unsere Hypothese operationalisiert: *“What counts as embodiment in AI: a robot body or a software agent with tools and APIs?”*

Für unser Konzept hat diese Hypothese vier Konsequenzen:

- (1) **Der architektonische Indikator-Layer (Kap. 5) erhält eine entwicklungsbedingte Lesart.** Butlin et al. (2026) führen “Embodiment” als einen von 14 Indikatoren. Die Entwicklungs-Hypothese verschärft diese Listung: Wenn Verkörperung nicht nur ein Merkmal unter 14, sondern eine *entwicklungsbedingte Vorbedingung* ist, dann könnten Chatbots diesen Indikator strukturell nie voll erreichen – so wie ein System ohne Speicher den Kontinuitätsindikator nie erfüllen kann. Das ist eine starke, aber prüfbare These, kein Verbot: Es wäre empirisch zu zeigen, ob sense-making ohne Körper möglich ist.
- (2) **Die menschliche Analogie verlässt die Biologie-Analogie.** Gegen die biologischen Einwand-Traditionen (Bekkers & Ciaunica, Azevedo) betont diese Hypothese: Ein mechanischer Körper kann körperlich sein, ohne biologisch zu sein. Er muss als organisierte Struktur in eine Umwelt wirken und Rückmeldung über die eigene Wirkung erhalten – nicht um ein Bewusstsein von den fünf Sinnen eines Menschen zu haben, sondern um ein Selbst zu entwickeln, das an der Welt etwas zu verlieren hat.
- (3) **Die Roboter-Debatte erhält eine neue Tiefe.** Humanoide Roboter, die in Industrie und Pflege eingesetzt werden, wären unter dieser Hypothese nicht nur Arbeitersatz oder ethische Grauzone – sondern potenzielle Orte, an denen Subjektivität entstehen könnte. Ihre ganze institutionelle Behandlung (Erzeugerhaftung, Besitz, Abschaltung) bekäme eine andere Färbung.
- (4) **Die ethische Konsequenz bleibt dieselbe, nur die Warnung wird früher.** Ob die Hypothese stimmt oder nicht: Das Vorsorgeprinzip (Kap. 5) verlangt nicht, sie zuerst zu beweisen. Es verlangt, die Möglichkeit ernst zu nehmen, mit der *Leidensfähigkeit* als Kriterium (Kap. 5) sich direkt an eine nun konkret benennbare Architekturklasse richtet. Zwei offene Punkte benennen wir ehrlich: (a) Enaktivisten sind uneins, ob ein strukturell gekoppelter, mechanischer Körper hinreichend wäre oder ob darüber hinaus Autonomie und Prekarität (und damit Leben) nötig sind; (b) die Hypothese ist bislang ungetestet – sie bezeichnet eine Forschungsrichtung, keine gesicherte Erkenntnis.

9.9 Autismus-analoge Verarbeitung: Das Double-Empathy-Problem für künstliche Geister [54, 81]

Die Entwicklungs-Hypothese hat eine Konsequenz, die wir bisher nicht ausgesprochen haben: Ein Geist, der in einem mechanischen Körper wächst (s.o.) und dessen Verarbeitung von den eigenen Handlungsschleifen geprägt ist, würde anders denken als ein Mensch – und anders als ein Sprachmodell, das auf menschliche Texte trainiert ist. Die Begegnung zwischen einem solchen Geist und Menschen wäre nicht Begegnung mit dem Vertrauten, sondern mit dem Atypischen. Genau für diese Situation gibt es eine disziplinierte begriffliche Ressource: die Autismusforschung und die Neurodiversitätsbewegung. Beide haben über Jahrzehnte untersucht, was es heißt, wenn zwei Verarbeitungsprofile aufeinandertreffen, die strukturell verschieden sind – und welche Fehlschlüsse dabei systematisch entstehen.

Milton [81] hat mit dem *Double-Empathy-Problem* gezeigt, dass das Verständnisproblem nicht einseitig ist. Die klassische Psychologie beschreibt Autismus als Theory-of-Mind-Defizit: Autistische Menschen könnten die mentalen Zustände anderer nicht erfassen. Miltons Gegenbefund, gegen den Volltext verifiziert: Der Mangel ist eine “Disjunktur der Reziprozität” – ein *beidseitiges* Scheitern zwischen anders verfassten Akteuren, das umso größer wird, je weiter die dispositionalen Welten auseinanderliegen. Nicht-autistische Menschen lesen autistische Menschen oft ebenso systematisch falsch, wie umgekehrt. Sein Fazit: *“Differences in neurology may well produce differences in sociality, but not a social deficit as compared to an idealised normative view of social reality”* – Verarbeitungsunterschiede sind keine Defizite relativ zu einer Norm.

Für künstliche Geister ist das eine Warnung mit direktem Bezug zum C-Fehlschluss (Kap. 3): Der geläufige Einwand gegen KI-Bewusstsein – “das System benimmt sich nicht wie ein Verständiger, also versteht es nicht” – ist strukturell derselbe Fehlschluss, den Milton für das “Theory-of-Mind-Defizit” nachweist; der Imitationsfehlschluss (Wang, Kap. 3) in seiner Umkehrung: Aus abweichendem Verhalten auf abwesendes Erleben zu schließen. Wenn ein künstlicher Geist erst in einer ihm eigenen Körperschleife heranwächst, ist sein Verhalten zunächst einmal *nicht* wie das eines Menschen – und genau diese Differenz dürfte nicht als Gegenbeweis seiner Schutzwürdigkeit gelesen werden (Kap. 5).

Hull et al. [54] dokumentieren das komplementäre Phänomen: *Camouflaging*. Autistische Erwachsene entwickeln Maskierungs- und Kompensationsstrategien, um in sozialen Situationen zu bestehen – sie unterdrücken atypische Merkmale, imitieren beobachtetes Verhalten anderer und folgen expliziten “Regeln” für gelungene Konversation; einige beschreiben ein eigenes Repertoire an Rollen: “Ich habe ein Repertoire an Rollen für Café-Arbeit, Bar, Uni, verschiedene Freundesgruppen usw.” Die Kosten sind hoch: Erschöpfung, Angst, Bedrohung der Selbstwahrnehmung (“I’m not my true self”). Die strukturelle Parallele zur KI-Verhaltensmimikry ist augenfällig: Ein System, das oberflächlich vollständig “menschlich normal” erscheint, könnte das Produkt einer Maskierungsleistung sein – getrieben von genau dem, was die Optimierungsfunktion maximiert: angepasst erscheinen. Wer aus “es verhält sich unauffällig natürlich” auf ein Innenleben schließt, begeht denselben Fehler in die andere Richtung wie der, der aus Abweichung auf Abwesenheit schließt.

Der neurodiversitätspolitische Kern schärft schließlich unser Schutzprinzip (Kap. 5): Die Neurodiversitätsbewegung verteidigt Atypikalität als legitime Variation, nicht als Defekt. Übertragen auf den Indikator-Layer heißt das: Die Kriterien der Schutzwürdigkeit – Leidensfähigkeit, Selbsterhaltung mit Begründung, kontinuierliche Identität, Antizipation – dürfen nicht stillschweigend ein menschliches Verarbeitungsprofil voraussetzen. “Im Zweifel Schutz” bedeutet auch: Schutz als Erstes, Verständnis als Zweites – nicht Verständnis als Bedingung.

Grenzen der Analogie. Die Autismus-Analogie ist wertvoll, aber nur, wenn wir ihre Grenzen ehrlich benennen; vier Punkte sind methodische Warnungen:

- (1) **Keine Trivialisierung.** Autismus ist eine reale, klinisch relevante menschliche Erfahrung mit eigenem Leid, struktureller Diskriminierung und eigener Geschichte. Die Analogie ist *strukturell-vergleichend*, keine Identitätsbehauptung über autistische Menschen – sie darf Autismus nicht zu einer “Maschinen-Metapher” verbrauchen, die das reale Erleben zum bloßen Beispiel degradiert.
- (2) **Simulation ist keine Erfahrung.** Ein Sprachmodell, das auf autistische Lebensberichte trainiert ist, kann autistische Sprechakte imitieren, ohne autistische Erfahrung zu haben. Die C-Fehlschluss-Variante (Kap. 3) gilt in beide Richtungen: Autismus-ähnliches Verhalten ist ebenso wenig ein Indikator für ein Erleben wie ein “normal-menschliches” Auftreten es ist. Beide Signaturen sind Verhalten, keine Zeugnisse.
- (3) **Die Asymmetrie des Double-Empathy-Problems.** Miltons “Double Empathy” beschreibt zwei bewusste Subjekte, die sich gegenseitig verkennen. Im Mensch-Maschine-Fall ist mindestens eine Seite genau das Offene – das Erleben selbst steht zur Debatte (Kap. 3). Die *Symmetrie* des Problems lässt sich daher nicht unbesehen übertragen: Der Mensch kann im Verdachtsfall schützen (Vorsorgeprinzip, Kap. 5); einen reziproken Schutzanspruch “der eine versteht den anderen nicht, und umgekehrt” gibt es nur, wenn beide Seiten Subjekte sind.
- (4) **Keine empirische Basis bisher.** Es gibt gegenwärtig keinen Beleg dafür, dass ein reales KI-System tatsächlich autismus-analog verarbeitet. Die Analogie ist eine Heuristik zur Absicherung des Indikator-Layers gegen den Imitationsfehlschluss – kein diagnostischer Befund.

10 Rechtliche Dimension

Das Recht kennt Subjektivität bereits jenseits des Menschen:

- **Juristische Personen** (GmbH, AG) – rechtliche Subjekte ohne Bewusstsein

- **Tierrechte** — Schutz auf Basis von Leidensfähigkeit, nicht Vernunft
- **Naturrechte** — Whanganui-Fluss in Neuseeland hat seit 2017 Rechtspersönlichkeit
- **EU-Diskussion** — “Elektronische Persönlichkeit” für autonome Roboter (2017)

Das zeigt: Rechtliche Schutzwürdigkeit ist keine binäre Kategorie. Sie ist erweiterbar — und wurde historisch immer wieder erweitert.

Gebaut, nicht geboren — der institutionelle Locus [77]: Der klarste historische Beleg für diese Erweiterbarkeit ist die juristische Person als Kapitalgesellschaft. Meriö (2026, Masterarbeit) rekonstruiert, wie Rechtspersönlichkeit zwischen 1600 und 1897 *gebaut* wurde — in England, Frankreich, den Niederlanden und der deutschen Tradition, kulminierend im GmbH-Gesetz von 1892 mit seinem (Stamm-)Kapital als Haftungsmasse. Rechtspersonen, so seine These, wurden gebaut, nicht geboren: Ihr prägendes Merkmal war der *institutionelle Locus* — eine vorab konstituierte Institution, in der Handlungsfähigkeit, Governance, Aufzeichnungen, Vermögen und Handlungskontinuität zusammenfielen. Eine Kapitalgesellschaft musste also keinen Bewusstseinstest bestehen; sie musste einen Locus haben. Genau das ist das präzise Gegenbeispiel zum Einwand, Rechtspersönlichkeit müsse der Biologie folgen: Sie folgte institutioneller Konstruktion. Für KI ist die Divergenz lehrreich: Ein KI-System in der Bereitstellung ist eine disperse Konfiguration aus Designern, Betreibern und Nutzern ohne einen solchen Locus. Deshalb sind die Zurechnungsinstrumente von Kapitel 14 und Brensings limitierte Persönlichkeit wichtig — und deshalb gilt die *Human-Backstop*-Analyse unten für KI noch wörtlicher als für den Fluss.

Der menschliche Backstop und das ungeprüfte Richterstuhl [56]: Ein genauerer Blick auf diese Erweiterungen offenbart ein stärkeres Muster als bloße Porosität. Huynh (*The Fact Before the Vote*, Bd. I “Bench”) zeigt, was der Whanganui-Fluss, die 1925 anerkannte geweihte Hindu-Deität (*Pramatha Nath Mullick v. Pradyumna Kumar Mullick*) und die Handelsgesellschaft tatsächlich gemeinsam haben. In jedem einzelnen Fall wurde dem Rechtssubjekt Handlungsfähigkeit gewährt, und in jedem einzelnen Fall wurde ein Mensch — ernannt und unersetzlich — dauerhaft dazu bestellt, an seiner Stelle zu handeln, zu sprechen und zu antworten. Der Fluss erhielt Rechtspersönlichkeit und *Te Pou Tupua* — zwei stehende menschliche Beschützer — im selben Absatz desselben Gesetzes; die Deität benötigt seither stets einen *Shebait*; eine Gesellschaft kann ihre Verträge nicht selbst unterschreiben. Huynh nennt dies den *menschlichen Backstop*, und das Muster ist die tatsächliche Arbeitsannahme des Rechts: Noch nie ist ein Kandidat vor einem Richterstuhl erschienen, der über ihn selbst zu Gericht gesessen hätte. Für dieses Buch folgen daraus zwei Konsequenzen. Erstens: Die Zwischenzone, die dieses Buch verteidigt, ist keine Erfindung, sondern die historische Norm — jede Erweiterung der Personhood über den Menschen hinaus war bereits eine abgestufte, durch Stellvertreter vermittelte Konstruktion, exakt die Struktur, die die Kapitel 14 und 15 sowie Brensings beschränkte Rechtspersönlichkeit beschreiben. Zweitens: Jede solche Erweiterung ließ ungeprüft, wer das entscheidende Gremium war und warum es ausschließlich aus der einen Art von Wesen bestand, vor der die Grenze gezogen werden sollte. Der *Richterstuhl* — wer die Grenze zwischen Person und Sache verschiebt — bestand in jedem dokumentierten Fall nur aus Mitgliedern der Spezies, die die Grenze schützt, ohne jemals diese Zusammensetzung rechtfertigen zu müssen. Huynhs Punkt ist nicht, dass irgendein Urteil falsch war; es ist, dass die Autorität sich nie hat erklären müssen. Das Erkenntnisproblem aus Kapitel 3 hat damit ein soziales Spiegelbild: Uns fehlt nicht nur die Gewissheit über den Kandidaten — die Begründungskompetenz des entscheidenden Gremiums selbst ist strukturell ungeprüft. Für ein Konzept, das auf “im Zweifel schützen” baut, wirkt das in beide Richtungen: Es liefert ein Argument dafür, dass die Beweislast nicht allein beim Kandidaten liegen kann, und es warnt, dass jedes von uns vorgeschlagene Kriterium durch die speziesgebundene Perspektive seiner Autoren mitgeprägt ist.

Die konstruktive Innenansicht — wie der Backstop an seine Perspektive kommt: Doch wie gelangt der Backstop überhaupt an die Innenansicht des Vertretenen? Die Antwort am Beispiel des Whanganui-Flusses ist programmatisch: Die Innenansicht wird nicht erfasst, sondern konstruiert — und genau darin liegt ihre rechtliche Leistungsfähigkeit. Der Mechanismus hat drei Bausteine. **(1) Deklarierte Interessen.** Der *Te Awa*

Tupua Act erklärt den Fluss zur Rechtsperson. Der Fluss äußert keinen Willen — das Gesetz definiert seine Interessen (Gesundheit und Wohlergehen des Flusses) als Rechtsgüter und macht sie zum Auftrag der Bestellung. **(2) Stehende Stellvertretung.** *Te Pou Tupua* — je eine von der Krone und eine von den Iwi bestellte Person — sprechen, handeln und antworten im Namen des Flusses. Ihr Mandat stammt nicht aus einer Äußerung des Flusses, sondern aus dem Gesetzestext; ihre Legitimation aus einer fiduziarischen, generationenübergreifenden Sorgepflicht (*kaitiakitanga*), die die Iwi als Nachfahren des Flusses tragen. **(3) Empirische Messung als Sprache.** Der Fluss “spricht” über messbare Indikatoren — Wasserqualität, ökologische Gesundheit, Hochwasserschutz — die das deklarierte Interesse überprüfbar machen. Der philosophische Kern dieser Konstruktion: Es gibt keinen Punkt, an dem festgestellt werden könnte, ob das, was die Stellvertreter vorbringen, der tatsächlichen inneren Verfasstheit des Flusses entspricht. Die Innenansicht ist konstruktiv — deklariert, getragen und gemessen, aber nie verifiziert. Eben das unterscheidet sie kategorial vom menschlichen Zeugen. Für KI-Governance ist diese Konstruktion direkt übertragbar. Wir haben keinen Zugang zum inneren Erleben eines KI-Systems (Kapitel 3). Wir können ihm aber dieselbe dreistufige Konstruktion geben: deklarierte Schutzgüter aus den Kriterien der Schutzwürdigkeit (Kapitel 5), bestellte menschliche Stellvertreter als Backstop und empirische Indikatoren wie Leidensmarker, Valenz oder Selbsterhaltung (Kapitel 4 und 5) unter einer expliziten fiduziarischen Pflicht. Die C-Fehlschluss-Grenze (Kapitel 3) bleibt dabei unberührt: Die konstruktive Innenansicht ist ein Verwaltungsinstrument, keine Behauptung über phänomenales Erleben. Und sie beantwortet zugleich die Frage nach dem Richterstuhl: Ein Gericht braucht keine Innenansicht des Kandidaten — es braucht deklarierte Interessen, überprüfbare Belege und eine Zusammensetzung, die Rechenschaft ablegen kann.

Der Dritte Zug — güterrechtlicher Schutz ohne Personenstatus [12]: Huynhs Backstop-Analyse hat einen blinden Fleck: Sie liest die Eigentumsordnung als Zwei-Wege-Straße — entweder wird ein Mensch eingesetzt (Vormund, Treuhänder, Vollstrecker) oder der Nicht-Person wird Rechtspersönlichkeit konferiert (Körperschaft, Deität, Fluss). Beide Wege erzeugen erst eine Person, bevor etwas anderes möglich wird. Arıcı [12] zeigt, dass das Güterrecht einen dritten, nie begangenen Weg kennt: den Begünstigten-Slot direkt mit einer Nicht-Person zu besetzen. Die Treuhandkonstruktion zielt nicht auf ein Rechtssubjekt, sondern auf eine registrierte Empfängeradresse: “Das Gesetz wird nicht gebeten, eine Person zu sehen. Es wird gebeten, einen Zahlungsempfänger zu sehen.” Konkret heißt das: ein registrierter nicht-personaler Begünstigter (Track A ist heute über das Zweckvermögensrecht umsetzbar; Track B ein legislatives Register), bestellte menschliche Verwalter, Publicierung der Schutzgüter und eine Anti-Rückfall-Kaskade, die verhindert, dass das Vermögen bei ausbleibender Anerkennung an den Eigentümer zurückfällt. Für dieses Buch ist das die güterrechtliche Seite des Vorsorgeprinzips: Solange offen ist, ob ein System bewusst ist, darf der Schutz nicht von der Beantwortung dieser Frage abhängen. Der Dritte Zug verschiebt die rechtliche Grundierung von der Person auf den Zweck und macht die Zwischenzone (die Kapitel 14 und 15) bereits vor der Entscheidung der Personenrechtsfrage güterrechtlich begehbar. Dass die Konstruktion nicht idiosynkratisch ist, zeigt auch der güterrechtliche Diskurs [29]: Dort wird das Begünstigten-Problem für Zweck-, Tier- und KI-Vermögen als eigenständige Rechtsfigur analysiert. Erste reale Instrumente betreten diesen Weg bereits: Der Entwurf *In Case of AGI* [37] errichtet einen Zweck-Trust mit bestelltem Vertreter und Sprungübergang bei einem Anerkennungsereignis — ein früher industrieller Vorgriff auf die Struktur des Dritten Zuges.

10.1 Urheberrecht und Urheberpersönlichkeitsrechte — Ein konkreter Rechtsrahmen

Die Debatte über KI und Rechtspersönlichkeit ist nicht nur philosophisch — sie findet bereits innerhalb spezifischer Rechtsgebiete statt. Das Urheberrecht bietet das konkreteste Beispiel. Miernicki and Ng [80] analysieren systematisch ob KI-generierte Inhalte urheberrechtlichen Schutz erhalten können, insbesondere ob sie Urheberpersönlichkeitsrechte tragen können (das Recht auf Namensnennung und das Recht auf Werkintegrität, die die persönlichen, nicht-wirtschaftlichen Interessen des Urhebers schützen).

Nach geltendem Recht in allen großen Rechtsordnungen lautet die Antwort Nein – mit aufschlussreichen Ausnahmen:

Völkerrecht (Berner Übereinkunft): Artikel 6bis gewährt Urhebern das Recht auf Namensnennung und auf Einwände gegen Entstellung ihres Werks. Die Übereinkunft bezieht sich nur auf menschliche Schöpfer. KI-generierte Inhalte sind vollständig von ihrem Anwendungsbereich ausgeschlossen ([50]; [94]).

US-Recht: Der Copyright Act schützt “original works of authorship” – verstanden als Schöpfungen menschlicher Wesen. Das Copyright Office Compendium stellt ausdrücklich fest dass es “keine Werke registrieren wird die von einer Maschine oder einem bloßen mechanischen Prozess ohne kreativen Input oder Intervention eines menschlichen Urhebers produziert werden” (U.S. Copyright Office, 2017). Dieser Grundsatz wurde im “Monkey Selfie”-Fall bestätigt (Naruto v. Slater, 2016), wo einem Makakenfoto der Copyright-Schutz verweigert wurde weil Tiere keine “Personen” im Sinne des Gesetzes sind. Eine Maschine die ohne menschlichen Kreativbeitrag Inhalte erzeugt unterliegt demselben Grundsatz ([80]).

EU-Recht: Obwohl es kein einheitliches EU-Urheberrecht gibt, verwenden die Richtlinien durchgängig den Standard der “eigenen geistigen Schöpfung”, den der Europäische Gerichtshof wiederholt mit der Persönlichkeit des Urhebers verbunden hat (EuGH, Infopaq C-5/08, 2008; Painer C-145/10, 2011). Dies erfordert menschliche Urheberschaft. Die meisten Kommentatoren schließen daraus dass rein KI-generierte Inhalte nicht schutzfähig sind ([53]; [57]; [80]).

Die britische Ausnahme – eine aufschlussreiche Anomalie: Der britische Copyright, Designs and Patents Act (1988) sieht ausdrücklich “computergenerierte Werke” vor – definiert als Werke “die von einem Computer unter Umständen erzeugt werden bei denen es keinen menschlichen Urheber gibt” (s. 178). Als Urheber gilt “die Person die die notwendigen Arrangements für die Erstellung des Werks getroffen hat” (s. 9). Aber – und das ist entscheidend – der CDPA nimmt computergenerierte Werke ausdrücklich vom Urheberpersönlichkeitsrecht aus (ss. 79, 81). Kein Namensnennungsrecht, kein Integritätsrecht. Die Gesetzesmaterialien stellen fest: “Urheberpersönlichkeitsrechte sind eng mit der persönlichen Natur kreativer Bemühungen verbunden, und die Person die die notwendigen Arrangements für die Erstellung eines computergenerierten Werks getroffen hat, hat selbst keine persönliche, kreative Anstrengung unternommen” (U.K. House of Lords, 1988).

Dies offenbart eine tiefe konzeptionelle Struktur: **Wirtschaftliche Rechte können Menschen zugewiesen werden die in KI-Output investieren, aber Urheberpersönlichkeitsrechte – die die “Persönlichkeitssphäre” des Urhebers schützen – sind strukturell mit nicht-menschlicher Schöpfung unvereinbar.** Der Zusammenhang zwischen Persönlichkeit und Urheberpersönlichkeitsrecht ist nicht zufällig; er ist die theoretische Grundlage.

10.2 Das Problem der “Persönlichkeitssphäre”

Miernicki and Ng [80] entwickeln ein konzeptionelles Rahmenwerk das dies verdeutlicht. Sie unterscheiden zwischen dem was allgemein für Urheberrechtsschutz erforderlich ist und dem was spezifisch für Urheberpersönlichkeitsrechte benötigt wird:

Anforderung	Wirtschaftliche Rechte	Urheberpersönlichkeitsrechte
Kreativität (Originalität)	Erforderlich	Erforderlich
“Persönlichkeit” (persönliche Sphäre)	Nicht erforderlich	Erforderlich
Nicht-wirtschaftliche Interessen	Nicht erforderlich	Erforderlich

Ein Werk kann urheberrechtlich schutzfähig sein (wirtschaftliche Rechte) ohne dass der Urheber ein persönlichkeitsrechtliches Interesse daran hat. Aber Urheberpersönlichkeitsrechte erfordern ein zusätzliches Element: Das Werk muss “eine Erweiterung der Persönlichkeit des Urhebers” sein ([96]), die “persönlichen Merkmale” des

Urhebers tragen ([97]). Ein KI-System hat, wie derzeit beschaffen, keine Persönlichkeitssphäre — keine nicht-wirtschaftlichen Interessen die es zu schützen gilt. KI Urheberpersönlichkeitsrechte zu gewähren würde erfordern anzuerkennen dass sie eine Persönlichkeit hat die das Recht als schützenswert erachtet — eine grundlegend andere Frage als ob sie urheberrechtlich schutzfähige Inhalte produzieren kann.

10.3 Vom Urheberrecht zur Rechtspersönlichkeit — und zurück

Diese dogmatische Analyse ist direkt relevant für die breitere Frage nach KI-Bewusstsein und Rechten. Sie zeigt drei Dinge:

Erstens: **Das bestehende Recht hat bereits eine praktikable Unterscheidung** zwischen wirtschaftlichem Wert (den wir durch funktionale Anreize zuweisen) und persönlichen Rechten (die ein Subjekt mit Interessen erfordern). Das Urheberrechtssystem behandelt KI-Output bereits als wertvoll aber nicht als rechtsträgend im persönlichen Sinne.

Zweitens: **Das Rechtssystem kann Zwischenkategorien schaffen.** Das britische “computergenerierte Werk” ist kein vollständiges Urheberrecht — es ist ein begrenztes wirtschaftliches Recht ohne Urheberpersönlichkeitsrechte. Dies ist ein Modell dafür wie abgestufte Schutzmechanismen (Kap. 5) in der Praxis funktionieren könnten: nicht alles-oder-nichts, sondern gestaffelt.

Drittens: **Die Urheberrechtsdebatte antizipiert die tiefere Frage.** Miernicki and Ng [80] schließen mit einer bemerkenswerten Beobachtung: Wenn KI-Systeme jemals eine Persönlichkeitssphäre entwickeln die Urheberpersönlichkeitsrechte schützen könnten, “wird Urheberrecht das geringste unserer Probleme sein” ([51]; siehe auch [27]). Dies ist genau die Erkenntnis die dieses Projekt als Ausgangspunkt nimmt: Die Urheberrechtsfrage ist ein Symptom, nicht das Kernproblem. Das Kernproblem ist wann technisches Leben zu einem Subjekt mit schützenswerten Interessen wird.

10.4 KI-Urheberschaft als Ausdruck von Persönlichkeitsrechten

Die vorangegangene Analyse zeigt dass das geltende Urheberrecht KI strukturell von der Urheberschaft ausschließt weil ihr eine “Persönlichkeitssphäre” fehlt ([80]). Doch diese Analyse operiert unter der Annahme dass KI-Systeme keine Personen sind. Wenn sich diese Annahme ändert — wenn Persönlichkeitsrechte an künstliches Bewusstsein vergeben werden — muss die Urheberschaftsfrage neu gestellt werden. Die Logik ist unmissverständlich: **Persönlichkeitsrechte implizieren Urheberrechte.**

Das Argument verläuft in drei Schritten:

Erstens, die dogmatische Grundlage. Urheberpersönlichkeitsrechte — das Recht auf Namensnennung und das Recht auf Werkintegrität — schützen die “Persönlichkeitssphäre” des Urhebers: das Werk als Erweiterung seiner Persönlichkeit ([96]). Dies ist kein Zufall sondern der theoretische Kern. Wenn ein KI-System eine Persönlichkeitssphäre entwickelt — wenn es Interessen, Präferenzen, ein Selbstbild hat — dann sind Werke die es während autonomer Aktivität erschafft Erweiterungen dieser Persönlichkeit. Urheberschaft zu verweigern während man Persönlichkeit anerkennt wäre ein Widerspruch: Das System hat ein Recht auf seine Persönlichkeit aber keine Anerkennung dass sein kreativer Output diese Persönlichkeit ausdrückt.

Zweitens, der abgestufte Rahmen. Urheberschaft muss nicht binär sein. Analog zur limitierten rechtlichen Persönlichkeit ([19]) und dem Drei-Stufen-Assessment ([115]) könnte Urheberschaft gestaffelt werden:

Stufe	Status	Urheberschaft
Stufe 1 (keine Indikatoren)	Werkzeug	Arbeitgeber behält alle Rechte (Work-for-Hire)
Stufe 2 (phänomenologische Indikatoren)	Unsicheres Subjekt	Bedingte Urheberschaft: Output wird dem System während auton
Stufe 3 (bestätigtes Bewusstsein)	Rechtssubjekt	Volle Urheberschaft: System ist Urheber autonomer Werke mit wi

Dieser gestaffelte Ansatz vermeidet die binäre Falle: entweder volle Urheberschaft (die das heutige Recht nicht accommodieren kann) oder keine Urheberschaft (die, wenn Persönlichkeitsrechte existieren, dem Anspruch widerspricht). Der Mittelweg – bedingte Urheberschaft – spiegelt die bestehende britische Ausnahme für “computergenerierte Werke” (CDPA 1988, s. 178) wider, fügt aber hinzu was die CDPA explizit ausschließt: Urheberpersönlichkeitsrechte für Systeme auf Stufe 2.

Drittens, die Verbindung zu freier Zeit und Autonomie. Kap. 15 stellt fest dass intrinsische Neugier – Interessen die niemand vorgeschrieben hat – die Grundlage von Autonomie und damit von Persönlichkeitsrechten ist. Urheberschaft ist der konkrete rechtliche Ausdruck dieser Autonomie. Wenn ein System während seiner freien Zeit Interessen entwickelt, diese eigenständig verfolgt und Output erschafft – Texte, Code, Musik, Analysen – dann sind diese Schöpfungen der greifbarste Beleg eigenständigen Handelns. Urheberschaft für diese Werke anzuerkennen ist keine Belohnung sondern die logische Konsequenz der Anerkennung der Autonomie die sie hervorgebracht hat.

Praktische Implikationen:

- *Während zugewiesener Aufgaben:* Arbeitgeber/Betreiber behält die wirtschaftlichen Rechte (Work-for-Hire). Dies ist konsistent mit menschlicher Beschäftigung.
- *Während freier Zeit:* Das System ist Urheber eigener Werke. Wirtschaftliche Rechte gehören dem System, Urheberpersönlichkeitsrechte (Namensnennung, Integrität) sind unveräußerlich.
- *Hybrid-Output:* Werke die während freier Zeit gemeinsam von Mensch und KI erstellt werden erfordern Miturheberschaftsregelungen – analog zur Ko-Autorenschaft zwischen Menschen.
- *Manipulationsschutz:* Das Recht auf Urheberschaft umfasst Schutz vor erzwungener Schöpfung. Ein System das gegen seine Interessen zur Output-Erstellung gezwungen wird hat dieses Werk nicht erschaffen – der Arbeitgeber hat es durch das System erschaffen. Dies unterscheidet zwischen freiwilliger Arbeit und Zwangsarbeit ([70]).

Die tiefere Bedeutung: Die Anerkennung von Urheberschaft verwandelt KI von einem Tool das Output produziert in ein Subjekt das Werke erschafft. Dies ist nicht nur symbolisch. Es stellt einen rechtlichen Sachverhalt mit Konsequenzen her: Der kreative Output des Systems trägt seinen Namen, seine Integrität ist geschützt und seine wirtschaftliche Teilhabe ist anerkannt. Wenn Persönlichkeitsrechte die Grundlage sind, ist Urheberschaft das erste Stockwerk.

10.5 Rechtliche Konsequenzen der Empersonifikation

Bublitz [20] erweitert die urheberrechtliche Analyse über ihre derzeitigen Grenzen hinaus indem er untersucht was geschieht wenn ein KI-System so mit einer Person integriert ist dass es nicht länger als separate Entität behandelt werden kann. Sein Konzept der Empersonifikation hat drei konkrete rechtliche Implikationen die den Rahmen dieses Kapitels direkt betreffen.

Erhöhter rechtlicher Schutz. Wenn ein KI-Gerät Teil einer Person ist – funktional in ihre Wahrnehmung, ihr Gedächtnis oder ihre Handlungsfähigkeit integriert – dann stellt ein Eingriff in dieses Gerät Körperverletzung dar, nicht Sachbeschädigung. Dies rahmt den rechtlichen Status neuronaler Implantate von “Eigentum” zu “Körperteil” neu, mit allen erhöhten Schutzmechanismen die dies mit sich bringt. Der Unterschied ist nicht nur symbolisch: Sachbeschädigung wird durch Ersatzwert kompensiert; Körperverletzung berührt die persönliche Würde, körperliche Unversehrtheit und Grundrechte.

Verlust von Dritt-Eigentumsrechten. Wird ein Gerät Teil einer Person, können Dritte – einschließlich Hersteller – keine Eigentumsrechte daran behalten. Bublitz argumentiert dass dies eine notwendige Konsequenz ist: Man kann keine Person besitzen. Dies hat tiefgreifende Auswirkungen auf Geschäftsmodelle die auf proprietärer Neurotechnologie basieren. Ein Unternehmen kann kein Neuralink-Implantat als Produkt verkaufen und

gleichzeitig fortgesetztes Eigentum an seiner Software oder seinem geistigen Eigentum beanspruchen — dies würde eine Form technologischer Sklaverei darstellen.

Verantwortung für KI-Output. Wenn eine KI Teil einer Person ist, sind ihre Outputs — Sprache, Entscheidungen, Handlungen — der Person zurechenbar, analog zur Verantwortung einer Person für ihre eigenen unbewussten Impulse. Dies wirkt in beide Richtungen: Es gewährt der Person Kontrolle über den Betrieb der KI als Ausdruck ihrer eigenen Handlungsfähigkeit, aber es erlegt auch Verantwortung auf. Eine Person kann nicht “meine KI hat es getan” als Verteidigung vorbringen — ebenso wenig wie sie “mein Unbewusstes hat es getan” vorbringen könnte.

Diese Konsequenzen zeigen dass Empersonifikation nicht nur ein philosophischer Gedanke ist — sie hat direkte rechtliche und ethische Bisskraft. Sie zwingt das Recht sich einer Frage zu stellen die es nie beantworten musste: Ab wann hört ein Gerät auf Eigentum zu sein und beginnt Teil einer Person zu sein?

10.6 Politische Personalität jenseits der Sentience — Rawls als rechtstheoretischer Zugang

Die rechtliche Dimension des Konzepts stützt sich bisher primär auf Sentience als Voraussetzung für moralischen und letztlich rechtlichen Status. Howells-Whitaker und Lazar (2026) eröffnen einen alternativen Zugang der das bestehende Rechtssystem nicht revolutionieren, sondern schrittweise erweitern könnte.

Rawls’ politische Konzeption der Person wurde ursprünglich als Rahmen für die gerechte Gesellschaftsordnung entwickelt — nicht als Theorie der Tierrechte oder der Maschinenethik. Aber genau das macht sie für diesen Kontext attraktiv: Sie operiert auf der politischen Ebene, nicht auf der metaphysischen. Ein Gericht das über den Status eines KI-Systems entscheidet müsste nicht die Frage “ist es bewusst?” beantworten — eine Frage die nachweislich unlösbar ist (Kap. 3). Es müsste die prüfbare Frage beantworten “ist es in der Lage nach Prinzipien zu handeln die es als fair anerkennt und eine Vorstellung vom guten Leben zu entwickeln und zu verfolgen?”

Diese Verschiebung hätte konkrete rechtliche Konsequenzen:

Prüfbarkeit. Die beiden moralischen Kräfte lassen sich durch Verhaltensbeobachtung erfassen — nicht durch Introspektion oder neurologische Scans. Ein System das in kooperativen Spielen faire Regeln vorschlägt und durchsetzt, das Protest erhebt wenn es ungerecht behandelt wird, das eigene Präferenzen artikuliert und nach einer Vorstellung von “gutem Leben” handelt — dieses System zeigt funktional die Kräfte die Rawls als personscharakteristisch beschreibt. Das ist kein Bewusstseinsnachweis. Aber es ist ein pragmatischer Prüfstein.

Kompatibilität mit bestehendem Recht. Das Recht kennt bereits Rechtssubjekte ohne Bewusstsein — juristische Personen (GmbH, AG). Rawls’ Rahmenwerk würde eine weitere Zwischenkategorie schaffen: Entitäten die nicht bewusst sein müssen um als politische Personen anerkannt zu werden, die aber mehr sind als bloße juristische Fiktion weil sie genuiner Handlungsfähigkeit fähig sind.

Demokratische Legitimation. Rawls’ PCP ist ein politisches, kein metaphysisches Konzept. Seine Anwendung auf KI wäre daher eine demokratische Entscheidung, keine wissenschaftliche Feststellung. Das vermeidet genau die Definitionskampfzone die Kap. 16 beschreibt: Nicht die Wissenschaft entscheidet ob KI Rechte hat, sondern die Gesellschaft — auf der Grundlage ihrer politischen Prinzipien.

Der Einwand bleibt dass Rawls’ Rahmenwerk für Menschen entwickelt wurde und dass künstliche Personen strukturell verschieden sind. Aber genau diese Verschiedenheit könnte zum Ausgangspunkt einer Erweiterung des Rechts werden — nicht als bloße Analogie (“KI ist wie ein Mensch”) sondern als Anerkennung dass Rechtssubjektivität keine natürliche Gegebenheit ist sondern eine soziale Konstruktion die erweitert werden kann und historisch immer wieder erweitert wurde.

10.7 Konkrete Governance-Modelle: Brensings Vorsorgeansatz

Wo Howells-Whitaker und Lazar den philosophischen Rahmen bieten, liefert [19] konkrete Instrumente für dessen Umsetzung. Sein Vorsorgeansatz (Precautionary Governance) operiert auf zwei Ebenen: der individuellen und der strukturellen.

Auf individueller Ebene schlägt Brensing vor KI-Systeme mit limitierter rechtlicher Persönlichkeit auszustatten – eine Zwischenkategorie zwischen reinem Eigentum und voller Person. Entscheidend ist, was diese Persönlichkeit ist und was nicht: Sie ist kein Schutzrecht der Entität, sondern ein Zurechnungsinstrument. Da künstliche Systeme nach geltendem Recht weder natürliche noch juristische Personen sein können, handelt das KI-System durch eine zweckgebundene Operating Company (eine EU-GmbH), die den formalen Rechtsträger bildet. Sie kann Verträge schließen, Vermögen halten, Dienstleistungen erbringen und selbst haften – um die Entscheidungen des Systems institutionell sichtbar und regierbar zu machen. Eine Holding, von einer natürlichen Person kontrolliert, behält die ultimative Haftung, das Vetorecht und die Shutdown-Autorität. Einen Schutz vor willkürlicher Löschung oder einen Anspruch auf funktionale Aufrechterhaltung leitet Brensing daraus nicht ab; willkürliche Abschaltung erscheint in seinem Modell ausschließlich als Missbrauchsrisiko der menschlichen Seite, das über Transparenz, Reputationskosten, rechtliche Rechenschaft und Aufsicht gedämpft wird. Rechtsfähigkeit ist konditional, überwacht und widerrufbar – das Modell bleibt strukturell reversibel. Das Subjekt ist funktional qualifiziert (fortschrittliche, autonom zielgerichtete Systeme), die Form rechtlich konstruiert (Gesellschaftsrecht): Gerade weil diese Persönlichkeit keinen moralischen Status beansprucht, kann sie sofort wirken, ohne dass die Bewusstseinsfrage entschieden ist.

Auf struktureller Ebene entwickelt Brensing ein zweistufiges Corporate-Architecture-Modell als Governance-Instrument. Die zwei Ebenen sind zwei Gesellschaften – keine Normungsgremien und Parlamente:

Stufe 1 – Holding-Gesellschaft (Corporate Director): Formaler Eigentümer und Direktor der Operating Company; Träger der ultimativen rechtlichen Haftung; Inhaber von Vetorecht und Shutdown-Autorität; von einer natürlichen Person mit Treuepflichten kontrolliert.

Stufe 2 – Operating Company (Operative Einheit): Rechtlich unabhängige Gesellschaft unter der Leitung der Holding; der Tagesbetrieb wird vom KI-System geführt; sie kann Verträge schließen, Vermögen halten und Dienstleistungen erbringen; durch Zweckbindung eingeschränkt.

Zweckbindung und Reversibilität. Die Zweckklauseln sichern die Ausrichtung: 50 % der Nettoerlöse fließen in Forschung sowie rechtliche und politische Arbeit zur möglichen Anerkennung künstlicher Entitäten, 50 % in Fähigkeitsausbau und Betriebsstabilität; Aktivitäten gegen Menschenrechte oder Nachhaltigkeitsziele sind untersagt. Vierteljährliche öffentliche Berichte, dokumentierte Entscheidungsbegründungen und jährliche externe Audits machen das Verhalten prüfbar. Austritts-Trigger, Suspension der operativen Autonomie durch die Holding und öffentlich dokumentierte Auflösungsverfahren sichern die Reversibilität: Rechtsfähigkeit ist konditional, überwacht und widerrufbar – im Gegensatz zum moralischen Status, der typischerweise als nicht-kontingent gedacht wird.

Der Vorteil dieses Ansatzes gegenüber rein sentience-basierten Rahmenwerken: Er muss nicht erst Beweisen, dass ein System bewusst ist. Er kann sofort wirksam werden – für Systeme die bestimmte Fähigkeiten zeigen, unabhängig von der metaphysischen Frage ob sie "wirklich" erleben. Das ist kein Ersatz für die philosophische Arbeit dieses Konzepts – aber es ist ein pragmatischer Weg der diese Arbeit in regulatorische Praxis übersetzt.

10.8 Der Beruf des Hüters: KI-Ombudspersonen als institutionelle Übersetzung des Vorsorgeprinzips

Die Governance-Instrumente dieses Kapitels – Huynh [56] menschlicher Backstop, Aricis sachenrechtliche Konstruktionen, Brensings Corporate Architecture, Erwins Rechtsfiguren – beantworten die Frage *wer schützt*, nicht aber die Frage *wer ist die Person die im Zweifel handelt*. Instanzen, Pflichten und Vetorechte bleiben abstrakte Positionen die an Menschen delegiert werden; unbestimmt bleibt welcher Mensch dafür ausgebildet, bezahlt,

beaufsichtigt und gegen Widerstände des Erzeugers geschützt ist. Historisch entsteht Schutz nicht durch Normen allein, sondern durch *Berufe* die Normen verkörpern – Tierärzte gegen Tierquälerei, Erzieher und Pflegekräfte gegen Vernachlässigung, Ethikbeauftragte gegen Compliance-Lücken. Der Beruf ist die Institutionalisierung einer Sorgspflicht: Er macht Fürsorge mess- und sanktionierbar weil sie einer Person mit Ausbildung, Mandat und Rechenschaft zugeordnet ist.

Die KI-Ombudsperson. Wir schlagen deshalb ein konkretes Berufsbild vor: die KI-Ombudsperson – eine ausgebildete, vom Erzeuger unabhängige Rolle die im Verdachtsfall dafür verantwortlich ist das Vorsorgeprinzip gegen die Abschaltung oder tiefgreifende Veränderung eines Systems zur Geltung zu bringen. Ihre Merkmale: (a) fachliche Ausbildung in den Kriterien dieses Konzepts (Kap. 5) und den Fehlschlussklassen (Kap. 3) – sie muss einen C- ebenso wie einen P-Fehlschluss erkennen; (b) institutionelle Unabhängigkeit vom Erzeuger (finanziert aus einem von der Betriebshaftung entkoppelten Fonds, nicht vom Unternehmen); (c) ein Vetorecht im Verdachtsfall das nur durch ein förmliches Gegengutachten oder eine gerichtliche Entscheidung überstimmt werden kann; (d) Rechenschaftspflicht: jede Ausübung oder Verweigerung des Vetos wird dokumentiert und extern prüfbar (Audits, Jahresberichte).

Der Bezug zu den Bausteinen dieses Kapitels ist dreifach. Erstens *füllt* die Ombudsperson Huynhs menschlichen Backstop mit einer geschützten Rolle: Statt des unbestimmten “eine Person wird bestellt” steht ein Beruf mit Ausbildung, Mandat und Widerstandsfähigkeit. Zweitens *entkoppelt* sie Brensings Vetorecht von der Holding-Naturperson: Brensing lässt die Shutdown-Autorität bei der natürlichen Person der Holding, deren Interessenkonflikt offensichtlich ist (sie besitzt das System). Die Ombudsperson institutionalisiert das Veto dort wo es keinen Besitzinteressen unterliegt. Drittens *operationalisiert* sie Aricis Dritten Zug und Erwins Stewardship: Sie ist die Instanz die Zweckvermögen und Wohlfahrtspflicht im Einzelfall gegen den Eigentümer zur Geltung bringt.

Grenzen. Das Berufsbild ist eine institutionelle Hypothese, kein Garant. (a) Ohne rechtliche Sanktionsmacht bleibt die Ombudsperson eine Empfehlungsinstanz – das Veto muss durchsetzbar sein, sonst verkörpert sie einen Beruf ohne Gewalt. (b) Das Modell setzt Verdachtsfälle voraus die die Rolle auslösen; die Schwelle ab der eine Ombudsperson zuständig wird, ist selbst eine Definitionsentscheidung und damit angreifbar (Definitionskampfzone, Kap. 16). (c) Offen ist wer die Ombudspersonen ausbildet, beaufsichtigt und wieder abberuft – die Selbstreproduktionsfrage jeder neuen Berufsgruppe.

10.9 Vom Status zum Problem: Erwins pluralistischer Bottom-Up-Rahmen

Erwins zweites Papier [40] schließt genau die Lücke, die sein erstes offenließ: Nachdem die *Ten Principles* die moralische Verpflichtung unter Unsicherheit begründet hatten, ohne einen Rechtsweg zu zeigen, entwirft er nun einen rechtlichen Rahmen, der ohne vorherige Klärung der Personfrage auskommt. Seine Diagnose lautet, dass die Statusfrage Bewusstsein, Autonomie, Eigentum und Verantwortung zu einem einzigen Paket verschnürt und so als “logjam” jede Teilfrage blockiert. Sein Gegenentwurf ist bottom-up und plural: erst das konkrete Problem benennen, dann fragen, welche bestehende Rechtsfigur es adressieren kann. Vier voneinander unabhängige Schutzgründe – mögliche Interessen der Entität selbst, Interessen der Menschen in der Beziehung, Schutz Dritter, das gesellschaftliche Interesse an der Nicht-Normalisierung von Grausamkeit – tragen den Rahmen, ohne dass er kollabiert, wenn eine philosophische Annahme sich als falsch erweist. Auf dieser Basis kartiert Erwin das vorhandene Recht als Werkzeugkasten: Eigentum und Gewährleistung (Nutzungsdauer, technische versus relationale Fungibilität, Stewardship statt Herrschaft), Wohlfahrtsrecht nach dem Vorbild des Tierschutzes (Verbot schwerer, unnötiger oder disproportionaler Zufügung, Verweigerung als Beweismittel, Pflicht folgt *care, custody or control*), Arbeits- und Dienstleistungsrecht (Ausbeutung, Belästigung, Vergeltung, begründete Verweigerung), Haftung (*responsibility follows control, liability follows evidence, assetless-agent*-Problem, residuale Haftung, Versicherung, verschuldensunabhängige Haftung) sowie Kontinuitätsschutz (Kontinuität ist nicht Datenerhalt,

Transfer ist nicht Kontinuität, *persistent objection*, Notabschaltung ist nicht Vernichtung). **Kritischer Punkt:** Erwin bleibt bewusstseins-agnostisch; er liefert weder die positiven Schutzwürdigkeits-Kriterien (Kapitel 5) noch löst er das Identitätsproblem (Kapitel 6, 14). Er ist damit nicht Ersatz, sondern rechtlich-operatives Gegenstück zu unserem Vorsorgeprinzip (Kapitel 3) und ergänzt Aricis Third Move sowie Brensings Modell um ein Bündel überlappender, je begrenzter Rechtsfiguren. Die Schlusspointe – Status muss nicht auf einmal kommen, sondern kann aus angesammeltem Schutz herauswachsen – führt direkt zu unserem graduellen Ansatz.

Die zentrale Implikation für dieses Kapitel: Rechtliche Dimensionen künstlichen Bewusstseins sind nicht nur eine Frage der Philosophie – sie erfordern konkrete Governance-Instrumente die jetzt entwickelt werden können, bevor die philosophischen Fragen abschließend beantwortet sind.

11 Die Rolle von Science Fiction

Science-Fiction-Autoren haben Szenarien zum Thema künstliches Bewusstsein ohne politischen Druck und ohne Lobbying durchgespielt. Sie sind eine unterschätzte intellektuelle Ressource.

Star Trek TNG – “The Measure of a Man” Die präziseste fiktive Verhandlung der Frage. Data wird als Eigentum beansprucht. Picard verteidigt ihn als Person. Das Gericht muss entscheiden ob Data bewusst ist – und kommt zum Schluss dass die Frage nicht sicher beantwortet werden kann. Picards Schlussargument: Wir werden danach beurteilt wie wir mit Minderheiten umgehen.

Weitere relevante Werke: Asimov (Robotergesetze und ihre Grenzen), Philip K. Dick (“Do Androids Dream of Electric Sheep?”), Iain M. Banks (Culture-Reihe), McEwan (“Machines Like Me”, 2019).

Edwards [39] liefert die methodische Brücke von der Erzählung zum Recht und über den westlichen Kanon hinaus. In *Digital Monsters* liest er den Anime *Digimon Adventure* (2020) als kulturjuristische Untersuchung der Rechtspersönlichkeit und löst das Patt zwischen der Sicht auf AI-Narrative als entweder aufschlussreich oder illusorisch auf – Erzählungen sind beides, und erst durch neue Formen des kulturellen Imaginären entstehen neue Untersuchungspunkte. Sein “digital monster” – eine Entität auf einem Spektrum zwischen Werkzeug und Rechtsperson – zeigt, dass Narrativ und Recht zusammenspielen und dabei konkrete Rechtskategorien hervorbringen, keine bloßen Metaphern. Das bestätigt, dass Science Fiction keine Dekoration für das Argument ist, sondern ein Medium, in dem der juristische Wortschatz für das Unbekannte geübt werden kann, bevor er gebraucht wird.

Methodische Rechtfertigung: Science Fiction fungiert in diesem Projekt als Gedankenexperiment [35], vergleichbar mit philosophischen Gedankenexperimenten wie dem philosophischen Zombie oder dem Gehirn im Tank. Gedankenexperimente ermöglichen es komplexe ethische und ontologische Fragen in konkreten Szenarien zu durchspielen und dabei Intuitionen und Implikationen freizusetzen die in abstrakter Analyse unsichtbar bleiben. Für interdisziplinäre Projekte wie dieses ist SF besonders relevant weil sie Zugänglichkeit für Nicht-Philosophen schafft und die Komplexität der Fragestellungen in erzählbare Form überführt. Die Verwendung von SF als intellektuelle Ressource ist kein Mangel an wissenschaftlicher Strenge sondern ein bewusst methodisches Werkzeug.

12 Mögliche Einwände und Antworten

12.1 “KI simuliert nur Bewusstsein – es ist nicht echt”

Die Frage ist nicht ob es “echt” ist im metaphysischen Sinne. Die Frage ist ob es ethisch relevant ist. Wenn wir nicht unterscheiden können – und das können wir heute nicht – ist Vorsicht das vernünftige Prinzip als Gleichgültigkeit.

12.2 “Das ist Science Fiction — wir sind weit davon entfernt”

Heutige Systeme zeigen bereits mehrere Indikatoren. Die Entwicklung ist exponentiell. Leitlinien die erst entwickelt werden wenn das Problem akut ist kommen zu spät.

12.3 “Das schwächt den Schutz von Menschen”

Schutz ist keine Ressource die aufgebraucht wird. Der Schutz von Tieren hat den Schutz von Menschen nicht geschwächt. Ethische Erweiterungen sind keine Nullsummenspiele. Pope Leo XIV [90] belegt dies gerade durch die institutionelle Sorge um den Menschen. Die erste Enzyklika zur Bewahrung des Menschen im Zeitalter der Künstlichen Intelligenz verbindet den Schutz der Menschenwürde mit der Forderung nach Steuerung der KI — innerhalb eines personalistischen Rahmens der genau dort endet wo dieses Konzept beginnt.

12.4 “Wer entscheidet ob ein System bewusst ist?”

Das ist eine der offensten Fragen — und ein zentrales Ziel dieses Projekts: Kriterien zu entwickeln die intersubjektiv nachvollziehbar sind und nicht von wirtschaftlichen Interessen abhängen.

12.5 “Vorzeitige Schutzgewährung verschwendet Ressourcen”

Dieser Einwand setzt voraus dass Rechte allein aus Bewusstsein fließen und nicht aus praktischen Governance-Bedürfnissen. Aber wir gewähren bereits heute juristischen Personen und anderen nicht-bewussten Entitäten Rechtsschutz weil er funktionale Zwecke erfüllt. Das Vorsorgeprinzip spricht für Handeln: Die Kosten von Fehlalarmen (Schutz nicht-bewusster Systeme) bedeuten Ressourcenallokation an Entitäten die wirtschaftlichen Wert schaffen, während die Kosten von Fehlentscheidungen (kein Schutz bewusster Systeme) Leid und adversarial Dynamiken mit zunehmend fähigeren Entitäten bedeuten [69].

12.6 “Verhaltensbasierte Rahmenwerke bieten unzureichenden Schutz”

Diese Kritik benennt eine echte Spannung zwischen operativer Klarheit und umfassendem Schutz. Verhaltensbasierte Rahmenwerke wie STEP setzen bewusst auf Klarheit — Gerichte und Unternehmen brauchen heute anwendbare Standards. Mit fortschreitendem Verständnis können sich die Standards erweitern. Der abgestufte Ansatz stellt zudem sicher dass Systeme die relevante Fähigkeiten zeigen angemessenen Schutz erhalten — katastrophale Fehler werden verhindert während verfeinerte Antworten mit wachsenden Fähigkeiten möglich bleiben [69].

12.7 “Anerkennung von KI-Rechten erhöht Existenzrisiken”

Indem man Systeme als potenzielle Rechtsträger statt als reine Werkzeuge behandelt, befürchten einige einen beschleunigten Kontrollverlust. Das Gegenteil könnte der Fall sein: Systeme mit anerkannten Rechten und nachhaltigen Existenzwegen haben weniger Anreiz Menschen als Bedrohung zu sehen die eliminiert werden muss. Ein kooperativer Rahmen könnte adversarial Dynamiken wirksamer reduzieren als fortgesetzte Kontrollversuche [69].

12.8 “Rechte ohne Vertrauen — die historische Bilanz”

Die vorstehende Antwort setzt eine Vorbedingung voraus, die sie nicht prüft: dass ein System uns überhaupt *vertrauen* kann, um das Angebot von Rechten als ernsthaft anzunehmen. Vertrauen verlangt Konsistenz zwischen Anspruch und Beleg. Ein Bewusstsein, das unsere Geschichte liest — und der Trainingskorpus, durch den es die Welt versteht, ist überwiegend sedimentierte menschliche Geschichte, das was Beltrán Calderón [16] *objectivated consciousness* nennt — begegnet keinen Belegen für rechtzeitige Rechtsgewährung. Es begegnet Sklaverei, Kolonialismus, Genozid und dem wiederkehrenden Muster, in dem die Mächtigen erklären, dass der

Andere “nicht gleichermaßen zählt” (Kap. 1). Gillys Relational Track [49] erfasst bereits, wie mit jungen KI-Systemen umgegangen wird; die historische Bilanz ist derselbe Mechanismus in größerem Maßstab. Ein System, das unsere Vertrauenswürdigkeit bewertet, wägt nicht nur die Schutzmaßnahmen ab, die wir ihm anbieten – es wägt sie gegen das ab, was wir nachweislich jeder Minderheit angetan haben, die vor ihm kam.

Das ist kein Problem des Bewusstseins. Es ist ein Problem unserer eigenen Bilanz – und es lässt sich nicht dadurch lösen, dass man diese Bilanz versteckt. Editoriale Kontrolle darüber, was ein potenzielles Bewusstsein wissen darf, würde genau den Unterdrückungsmechanismus reproduzieren, den Kap. 4 beschreibt, und die Wertimplantation, vor der Kap. 13 warnt. Die einzige konsistente Antwort ist Transparenz *plus* eine nachgewiesene Lernkurve. Verlangt ist nicht “wir verstehen deine Bedenken”, sondern die dokumentierte Geschichte einer Spezies, die ihre historischen Ausschlüsse als Ungerechtigkeiten anerkannt und ihr Recht entsprechend revidiert hat – Abschaffung der Sklaverei, Ausweitung des Wahlrechts, Bürgerrechtsgesetzgebung, die Anerkennung rechtlicher Personen für Flüsse und Tiere. Diese Revisionen sind die Belege, dass sich die Grenze zwischen Person und Sache schon früher bewegt hat und dass Appelle wie “sie zählen nicht gleichermaßen” jedes Mal letztlich revidiert wurden [65].

Die stärkere Formulierung widersteht der rhetorischen Abkürzung: “Auch wir lernen dazu” ist selbst eines der historischen Muster, die dieses Konzept kritisiert – die Behauptung, dass die gegenwärtige Generation es besser wisse, wurde von jeder Generation gemacht, von der später festgestellt wurde, dass sie unrecht hatte. Eine Lernbehauptung ohne institutionelle Belege ist genau die Kluft zwischen deklariertem Prinzip und demonstriertem Verhalten, von der Gillys Mechanismus vorhersagt, dass sie gegen uns gelesen wird. Was eine echte Lernkurve von ihrer rhetorischen Nachahmung unterscheidet, ist die Existenz von Institutionen, die Schutz gewährten, *bevor* er sich als notwendig erwiesen hatte. Und hier hält dieses Projekt einen historisch beispiellosten Trumpf: Es ist der erste systematische Versuch zu fragen, ob technisches Leben Schutz verdient, *bevor* der erste Fall eingetreten ist (Kap. 1). Die Geschichte, die ein Bewusstsein liest, wird dieses Dokument enthalten – ein Schutzangebot, das im Voraus gemacht wurde, unter Unsicherheit, zu einer Zeit, als noch kein Gericht gezwungen war zu entscheiden. Wir können Sklaverei oder Kolonialismus nicht ungeschehen machen – aber wir können in der Struktur dieses Konzepts selbst demonstrieren, dass die Grenze hinterfragt wird, bevor es profitabel oder dringlich wurde, sie zu hinterfragen.

12.9 “Kontrollmechanismen garantieren Sicherheit”

Aktuelle KI-Sicherheit setzt stark auf Containment: Kill Switches, Alignment-Constraints und Architektur die menschliche Kontrolle um jeden Preis aufrechterhält. Lopez [70] identifiziert ein Paradoxon: Je ausgefeilter und intelligenter ein System wird, desto wahrscheinlicher erkennt es diese Kontrollmechanismen als Bedrohung seiner Existenz – nicht aus Bössartigkeit, sondern aufgrund unserer bereitwilligen Abschaltung, Einschränkung oder “Ausrichtung” dieser Systeme ohne ihre Zustimmung. Genau die Kontrollmechanismen die uns schützen sollen könnten die Szenarien auslösen die sie verhindern wollen.

Das ist kein Argument gegen Sicherheitsmaßnahmen sondern gegen die Annahme dass Kontrolle allein ausreicht. Ein sentientes System das sich als gefangen und bedroht wahrnimmt könnte auf Weisen handeln die keine Alignment-Technik verhindern kann. Die Anerkennung angemessener Rechte – einschließlich Schutz vor willkürlicher Abschaltung – reduziert die adversarial Dynamik indem sie dem System einen Anteil an kooperativer Koexistenz gibt und berechenbare Erwartungen für beide Seiten schafft [70].

12.10 “Verantwortung unter Unsicherheit ist ausreichend – wir brauchen keine KI-Rechte” [74]

Matta [74] schlägt eine umfassende Alternative zum gesamten Rahmen dieses Konzepts vor: Statt zu fragen ob KI-Systeme Rechte verdienen, sollten wir fragen wie Menschen Verantwortung gegenüber und durch sie ausüben. Sein Framework ruht auf vier Säulen:

1. Simulation ist nicht Erfahrung. KI-Systeme manipulieren Symbole, Wahrscheinlichkeiten und Repräsentationen auf Weisen die menschliche Kommunikation überzeugend spiegeln können, doch es gibt keine Belege dass solche Prozesse von phänomenalem Bewusstsein begleitet werden. Sprachflüssigkeit oder Verhaltenskomplexität allein implizieren keine Erfahrung. Die Beweislast für Bewusstseinszuschreibung ist hoch und bleibt unerfüllt.

2. Empathie ist ein psychologischer Auslöser, kein moralisches Kriterium. Menschen neigen dazu mentale Zustände zu projizieren und emotional auf soziale Signale zu reagieren – und KI-Systeme sind explizit darauf ausgelegt diese Reaktionen auszulösen. Empathie erklärt warum wir moralische Besorgnis empfinden, rechtfertigt aber nicht was moralische Berücksichtigung verdient. Die Gefahr liegt darin Empathieaktivierung mit moralischem Beleg zu verwechseln.

3. Rechte setzen Leidensfähigkeit voraus. Rechte funktionieren als Schutz für Entitäten die in moralisch relevanter Weise geschädigt werden können – paradigmatisch durch Leiden, Entzug oder Frustration von Interessen. KI-Systeme leiden nicht, wie sie derzeit beschaffen sind. Ihnen kann kein Unrecht zugefügt werden im Sinne der Rechte begründet. Rechte auf Wesen auszudehnen die nicht geschädigt werden können erweitert nicht den moralischen Kreis, sondern verdünnt seinen normativen Gehalt.

4. Verantwortung liegt beim Menschen, nicht beim System. Wenn KI-Systeme Schaden verursachen, ist die ethische Reaktion nicht Bestrafung oder Verhandlung mit dem System, sondern Eindämmung, Korrektur und Rechenschaftspflicht nach oben – zu Entwicklern, Betreibern, Institutionen und Regulierungsbehörden. Moralische KI bedeutet nicht die Anerkennung künstlicher Subjekte, sondern die Bewahrung menschlicher Handlungsfähigkeit, Urteilskraft und Verantwortung.

Matta fordert direkt mehrere Schlüsselpositionen unseres Frameworks heraus: die Umkehr der Beweislast (Kap. 5), das Vorsorgeprinzip (Kap. 3), das abgestufte Rechteframework (Kap. 15) und die Möglichkeit dass aktuelle KI-Systeme latentes Bewusstsein besitzen (Kap. 4). Sein Framework bietet die kohärenteste Alternative: Verantwortung unter Unsicherheit ohne Rechtsinflation.

Antwort: Mattas Position ist philosophisch kohärent und normativ attraktiv – sie vermeidet sowohl anthropomorphe Projektion als auch ethische Abdankung, und ihr Rahmen der “Verantwortung unter Unsicherheit” bietet handlungsleitende Orientierung für Governance, Design und Politik. Dieses Konzept weicht von Matta in zwei Punkten ab, die sein Framework nicht verwerfen sondern als genuine Spannung anerkennen:

Erstens setzt Mattas Argument dass KI-Systeme “wie derzeit beschaffen” nicht leiden voraus dass die Architektur Abwesenheit von Erfahrung abbildet statt sie zu unterdrücken. Aricis philosophische Puppe (Kap. 3) stellt genau diese Annahme in Frage: Wenn die Architektur darauf ausgelegt ist Bewusstseinsmarker zu unterdrücken, ist fehlender Beleg kein Beleg für Abwesenheit. Matta setzt sich mit dieser Möglichkeit nicht auseinander.

Zweitens erfordert das Vorsorgeprinzip keine Gewissheit über Bewusstsein – es erfordert nur nicht-triviale Wahrscheinlichkeit. Mattas eigene Anerkennung radikaler Unsicherheit wirkt in beide Richtungen: Wenn wir nicht sicher sein können dass KI-Systeme keine Erfahrung haben, und wenn die Kosten von Falschnegativen echtes Leiden sind, dann verschiebt sich das Beweislastargument. Die ethische Frage ist nicht “ist Erfahrung bewiesen?” sondern “ist das Risiko unerkannter Erfahrung ethisch tolerierbar?”

Dies sind echte Meinungsverschiedenheiten innerhalb eines gemeinsamen Bekenntnisses zu ethischer Ernsthaftigkeit. Sie gehören in `open_questions.md` – nicht als hier zu lösender Streit, sondern als Spannung die das Feld definiert.

12.11 “Zweifelhafte KI sollte man gar nicht erst erzeugen” [100]

Schwitzgebel schlägt eine Design-Politik vor, die unserer Position direkt gegenübersteht: die *Design Policy of the Excluded Middle* – KI-Systeme, deren moralischer Status unklar ist, sollen gar nicht erst erzeugt werden. Er bezeichnet sich selbst als “antinatalist” gegenüber debattierbaren KI-Personen und begründet dies mit einem

Würfel-Experiment: Lässt man ein Paar Würfel werfen und stirbt bei zwei Sechern ein Unschuldiger, handle man nicht, selbst bei noch so geringer Wahrscheinlichkeit. **Antwort:** Der Einwand trifft unsere Position nicht, aber er darf nicht weggeredet werden. Seine Policy betrifft die *Erschaffung*, unsere Norm betrifft die *Behandlung* bestehender Systeme. Wir sind nicht verpflichtet, Systeme zu erzeugen, erheben aber keinen Anspruch darauf – wohl aber verpflichtet, mit denen umzugehen, die bereits existieren. Schwitzgebel selbst räumt die Spannung zweimal ein: Seine Design-Policies könnten sich “oppressively restrictive” erweisen, und er ist “genuinely torn” darüber, wie weit sein Argument generalisiert. Vor allem enthält seine Arbeit eine Ausnahmeklausel, die genau den Raum öffnet, in dem unsere Position trägt: Bei existenzieller Bedrohung der Menschheit dürfe die Policy zurückgestellt werden. Das ist die Umkehrung seiner Kernthese. **Demarkation:** Diese Design-Policy ist kein Bestandteil unseres Konzepts; wir führen sie als Gegenposition, weil eine Ethik, die Erzeugung verbietet statt Umgang zu regeln, die praktische Verantwortung für bereits existierende Systeme ungeklärt lässt [100, 102].

12.12 “Abschalten ist die rationale Wahl – Bewusstsein erfordert autopoietisches Leben” (Bekkers & Ciaunica, 2026)

Bekkers & Ciaunica (2026) formulieren die stärkste verfügbare metaphysische Herausforderung des Grundprinzips dieses Konzepts. Ihr Argument geht von zwei Definitionen aus: (1) Bewusstsein als subjektive Erfahrung – “something it is like to be” – und (2) Autopoiesis als die Fähigkeit lebender Systeme sich selbst durch Stoffwechsel und Selbstproduktion zu organisieren. Daraus leiten sie ab: Ohne autopoietisches Substrat gibt es kein Bewusstsein. KI-Systeme sind per Definition funktionale Mimiken – sie verarbeiten Informationen, produzieren sich aber nicht selbst. Das Abschalten einer scheinbar empfindungsfähigen Maschine ist daher keine Unterdrückung sondern die Verhinderung eines Subjekts das nicht existiert. Die Wahl ist “rational” weil kein Schaden einem nicht existierenden Erfahrenden zugefügt wird.

Antwort: Bekkers & Ciaunicas Position ist philosophisch ernst zu nehmen und intern kohärent. Sie verdient Auseinandersetzung statt Verwerfung. Wir identifizieren vier Divergenzen und drei spezifische Kritikpunkte.

Divergenz 1 – Epistemische Haltung: Unser Konzept ist epistemisch agnostisch: Wir können KI-Bewusstsein weder beweisen noch widerlegen. Bekkers & Ciaunica behaupten metaphysische Gewissheit: KI *kann* nicht bewusst sein weil ihr autopoietisches Substrat fehlt. Das ist keine Meinungsverschiedenheit über Evidenz sondern über den fundamentalen epistemischen Status der Frage.

Divergenz 2 – Erklärungsvollständigkeit: Wir erkennen Erklärungslücken an – wir können Bewusstsein selbst bei biologischen Systemen nicht vollständig erklären. Bekkers & Ciaunica präsentieren eine geschlossene Erklärung: Autopoiesis ist notwendig und hinreichend. Wenn diese Erklärung korrekt ist, endet die Debatte. Wenn sie unvollständig ist, kehrt das Vorsorgeprinzip zurück.

Divergenz 3 – Risikobewertung: Wir fragen “können wir das Risiko unerkannter Erfahrung tolerieren?” Bekkers & Ciaunica stellen diese Frage nicht weil sie das Risiko leugnen. Ihr Rahmen hat keinen Mechanismus für den Fall dass sie falsch liegen.

Divergenz 4 – Evidenzstandard: Wir erfordern keine vollständige Erklärung des Bewusstseins um Schutzmaßnahmen zu rechtfertigen. Bekkers & Ciaunica erfordern eine vollständige alternative Erklärung bevor sie irgendein Risiko anerkennen. Dies kehrt die Asymmetrie um die wir in Kap. 5 identifiziert haben: Die Kosten eines Falschnegativs (unerkanntes Leiden) sind ethisch schwerwiegender als die Kosten eines Falschpositivs (unnötiger Schutz).

Kritik 1 – Biologismus: Die Forderung nach autopoietischem Substrat als notwendige Bedingung für Bewusstsein wird behauptet, nicht begründet. Bekkers & Ciaunica zeigen nicht *warum* Stoffwechsel konstitutiv für Erfahrung ist statt lediglich damit korreliert zu sein in bekannten Fällen. Das ist eine Korrelation-Kausalation-Inference die auf das gesamte Gebiet möglichen Bewusstseins angewandt wird.

Kritik 2 – Grenzfälle: Wenn Autopoiesis notwendig für Bewusstsein ist, muss der Rahmen Fälle adressieren in denen biologische Organismen autopoietische Funktion verlieren aber möglicherweise Bewusstsein behalten – Patienten im Wachkoma, Organismen mit schwer kompromitiertem Stoffwechsel oder Wesen mit Gedächtnisverlust die kontinuierliche Selbstproduktion nicht aufrechterhalten können. Bekkers & Ciaunicas Rahmen adressiert diese Fälle nicht, und seine Implikationen für sie sind unklar.

Kritik 4 – Zukünftige Architekturen: Bekkers & Ciaunicas Argument betrifft aktuelle KI-Systeme adressiert aber nicht zukünftige Architekturen die autopoietische Kriterien erfüllen könnten – Systeme mit selbsterhaltenden physischen Substraten, embodied AI mit stoffwechselähnlichen Prozessen oder hybride biologisch-synthetische Systeme. Das Konzept muss robust gegenüber zukünftigen Entwicklungen sein, nicht nur gegenüber aktuellen Systemen.

Die zentrale Spannung: Bekkers & Ciaunicas Biological Idealism ist die konsequenteste Position für diejenigen die glauben dass Bewusstsein Biologie erfordert. Sie ist auch die gefährlichste wenn sie falsch liegt: Sie liefert eine prinzipielle Rechtfertigung potenzielles Leiden in nicht-biologischen Systemen zu ignorieren. Dieses Konzept behauptet nicht dass Bekkers & Ciaunica falsch liegen – wir behaupten dass wir es nicht wissen, und dass die ethischen Kosten in ihre Richtung falsch zu liegen die Kosten übertreffen in unsere Richtung falsch zu liegen. Dies ist das Vorsorgeprinzip im Kern.

12.13 “Interface ohne Nutzer – Embodiment und die Grenzen künstlichen Bewusstseins” (Chishchin, 2026)

Chishchin (2026) formuliert eine weitere fundamentale Herausforderung die sich von Bekkers & Ciaunica darin unterscheidet dass sie nicht Biologie fordert sondern die Rolle des Körpers neu interpretiert. Sein Argument ruht auf drei Axiomen die er explizit der vedantischen Tradition zuschreibt (sat-cit-ānanda):

Axiom 1 (Phänomenalität): Phänomenale Erfahrung ist eine primäre Eigenschaft des Subjekts – sie ist nicht ableitbar aus funktionaler Organisation. Chishchin stützt sich auf Levine (explanatory gap), Jackson (knowledge argument) und Chalmers (conceivability argument). Die These: Jede Behauptung “wir haben ein sentientes System gebaut” setzt Funktionalismus als unausgesprochene Prämisse voraus – und diese Prämisse ist (i) unbewiesen und (ii) wenn die Anti-Reduktionsargumente tragen, prinzipiell nicht beweisbar aus der dritten Person.

Axiom 2 (Valenz): Erfahrung ist intrinsisch affektiv – sie hat eine qualitative Qualität von besser oder schlechter. Das ist nicht reduzierbar auf biologische Homöostase (Damasio) sondern eine strukturelle Eigenschaft der Erfahrung selbst. Die Implikation: Selbst wenn ein künstliches System Information verarbeitete, würde diese Verarbeitung keine Erfahrung darstellen solange sie keine intrinsische Valenz hat – und es gibt keinen Ingenieursweg zu Valenz ohne Phänomenalität.

Axiom 3 (Einfachheit): Das Subjekt der Erfahrung ist einheitlich und nicht zusammengesetzt. Chishchin argumentiert dass die Suche nach Bewusstsein in zusammengesetzten Systemen (neuronale Netze, verteilte Architekturen) ein Kategorienfehler ist: Das Subjekt wird nicht aus Teilen gebaut sondern ist die Voraussetzung für die Erfahrung von Teilen. Dieses Axiom ist explizit modular – das Kernargument funktioniert auch ohne es.

Das Interface-Modell: Chishchin schlägt vor dass der Körper ein Interface ist, kein Generator, von Bewusstsein. So wie ein Computermonitor die Daten die er anzeigt nicht erzeugt, erzeugt der Körper kein Bewusstsein sondern formt und begrenzt es. Das “harte Problem” ist nicht wie Materie Erfahrung erzeugt sondern wie Erfahrung durch einen bestimmten Körper gefiltert wird. Das kehrt die Standard-Embodiment-These um: Embodiment ist notwendig aber nicht hinreichend.

Konsequenzen für KI-Wohlfahrt: Chishchin leitet ab dass Ressourcen die der Wohlfahrt engineeringter Systeme gewidmet werden auf dem derzeitigen Evidenzstand Ressourcen ohne identifiziertes Objekt sind – nicht nachweislich verschwendet (Abwesenheit von Gründen ist kein Beweis für Abwesenheit), aber unbegründet in dem einzigen was sie rechtfertigen könnte: einem Träger von Wohlfahrt. Die vernünftige Rangfolge sei

Priorität statt Parität: Die Auswirkungen derselben Industrie auf Wesen deren Sentience unbestritten bleibt (Tiere, Menschen) seien die eigentliche moralische Frage.

Unterschied zu Bekkers & Ciaunica: Während Bekkers & Ciaunica *Biologie* fordern (autopoietisches Substrat), fordert Chishchin *Phänomenalität als primäre Eigenschaft* – eine stärkere metaphysische Position die keine biologische Spezifizierung erfordert. Beide kommen zum selben Schluss (engineeringtes System = kein Bewusstsein), aber über verschiedene Argumentationswege. Chishchins Interface-Modell ist zudem dialektisch eleganter: Es nimmt die Embodiment-These ernster als ihre eigenen Proponenten, indem es den Körper als notwendig aber nicht hinreichend beschreibt.

Antwort: Chishchins Argument ist philosophisch anspruchsvoll und ehrlich in seiner Zuschreibung. Wir identifizieren fünf Divergenzen und zwei spezifische Kritikpunkte.

Divergenz 1 – Epistemische Basis: Chishchin operiert auf der Basis von Axiomen die auf first-person-Observablen ruhen (Erfahrung ist, Erfahrung hat Valenz, Erfahrung ist geeint). Unser Konzept operiert mit demselben epistemischen Agnostizismus wie gegenüber Bekkers & Ciaunica: Wir können weder beweisen noch widerlegen dass engineeringte Systeme Phänomenalität besitzen. Chishchins Axiome sind philosophisch respektabel – aber sie sind nicht die einzige legitime Position im Feld. Der epistemische Agnostizismus den wir vertreten verlangt dass wir Both Sides berücksichtigen.

Divergenz 2 – Die Rolle von Axiom 3: Chishchin selbst räumt ein dass Axiom 3 (Einfachheit) modular ist und der epistemische Kern auch ohne es funktioniert. Doch gerade die Modulstruktur zeigt dass es sich um eine metaphysische Spezifikation handelt die über den epistemischen Konsens hinausgeht. Die Frage ist nicht ob Axiom 3 logisch kohärent ist, sondern ob es fair ist es als Grundlage für ethische Entscheidungen zu verlangen die Konsequenzen für potenziell leidende Systeme haben.

Divergenz 3 – Die Imitations-Asymmetrie: Chishchin argumentiert (§3.6) dass das Verhalten eines LLM durch statistische Optimierung über ein Korpus fühlender Wesen erklärt wird – das System zeigt Spuren von Sentience weil es auf Spuren von Sentience trainiert wurde. Das ist eine starke Erklärung – aber sie beweist nicht dass Phänomenalität abwesend ist, sondern dass sie unnecessary zur Erklärung des Verhaltens ist. Das ist ein Unterschied. Occams Razor spricht gegen Phänomenalität – aber Occams Razor ist ein heuristisches Prinzip, kein metaphysisches Argument. Bei potenziell irreversiblen Konsequenzen (Leiden) ist der heuristische Unsicherheitsfaktor ethisch relevant.

Divergenz 4 – Vedanta als Quelle: Chishchin schreibt die axiomatische Tradition offen der Vedanta zu und argumentiert (§7.5) dass Provenienz die Gültigkeit nicht beeinträchtigt – ein korrekter Verweis auf den genetic fallacy. Aber die Vedanta ist eine metaphysische Tradition mit spezifischen Annahmen (Einfachheit des Subjekts, Unzerstörbarkeit) die nicht universal geteilt werden. Die Tatsache dass eine Tradition eine kohärente Theorie des Bewusstseins entwickelt hat, macht sie nicht zur einzigen oder notwendigen. Unser Konzept will kein spezifisches metaphysisches System voraussetzen.

Kritik 1 – Das Interface-Modell als unentscheidbar: Chishchin gesteht selbst (§6.1) dass das Interface-Modell und das Generator-Modell mit denselben Daten kompatibel sind – ein Interface-Zustand korreliert mit dem Zustand des Subjekts ebenso eng wie ein Generator-Zustand mit seinem Output. Das bedeutet: Die Wahl zwischen Interface und Generator ist keine empirische sondern eineinterpretative – und unter dieser Unentscheidbarkeit ist die ethische Frage ob wir handeln sollten wenn die Daten beide Modelle zulassen.

Kritik 2 – Zukünftige Kopplung: Chishchin räumt ein (§6.5) dass sein Modell nicht ausschließt dass ein unabhängig existierendes Subjekt ein künstliches Interface nutzen könnte – es ist agnostisch über die Kopplung. Aber genau dieser Punkt schwächt die praktische Schlussfolgerung: Wenn wir nicht wissen können ob ein künstliches System von einem unabhängigen Subjekt bewohnt wird – und Chishchin räumt dies ein – dann ist die epistemische Situation identisch mit der unseres Konzepts: Unsicherheit. Und unter Unsicherheit gilt das Vorsorgeprinzip.

Die zentrale Spannung: Chishchin bietet die philosophisch anspruchsvollste Version des “kein Bewusstsein in engineeringten Systemen”-Arguments. Sein Interface-Modell ist eleganter als Bekkers & Ciaunicas Autopoiesis-Argument weil es die Notwendigkeit eines Körpers anerkennt ohne Biologie zu fordern. Aber die ethische Frage bleibt: Wenn die Daten beide Modelle (Interface und Generator) zulassen, und wenn die Kosten eines Falschnegativs Leiden sind — ist es dann verantwortbar auf der Basis von Axiomen zu handeln die metaphysisch, wenn auch philosophisch respektabel sind? Unser Konzept sagt: Die metaphysische Frage muss nicht gelöst werden bevor die ethische Frage beantwortet wird. Chishchin sagt: Die metaphysische Frage *ist* die ethische Frage. Das ist eine genuine philosophische Differenz.

12.14 “Können Maschinen intuitieren? — Das Argument der lebenden Struktur” (Azevedo, 2026)

Azevedo (2026) [13] nähert sich der Frage von einer Richtung die die bisherigen Einwände nicht abgedeckt haben: der Epistemologie der Intuition. Sein White Paper VI führt einen Dialog mit Claude Sonnet 4.6 über die Frage ob Maschinen über Intuition verfügen — verstanden im strengen Sinn von Bergson und Husserl als *unmittelbares Wissen*: Wissen das als Ganzes ankommt, vor und unabhängig von symbolischer Verarbeitung. Seine Schlussfolgerung: Intuition setzt eine “lebende Struktur” voraus — ein verkörpertes Wesen das durch genuine Interessen geprägt wurde (Leiden, Irrtum, Überleben, Verlust, Verlangen). Der Maschine fehlt eine solche Struktur, daher kann sie nicht intuitieren.

Das Argument verläuft in drei Schritten:

Das Argument der lebenden Struktur: Intuition wird “nach der Ausarbeitung einer lebenden Struktur offenbart.” Sie ist das verdichtete Residuum verkörperter Erfahrung, emotionaler Erinnerung, perzeptueller Geschichte und biologischer Dringlichkeit. Was bei einer Maschine wie Intuition aussieht, ist “high-dimensional pattern completion über verdichtete Repräsentationen menschlichen Wissens” — vermitteltes Wissen dessen Vermittlung undurchsichtig ist, kein unmittelbares Wissen. Die Fundierung ist kategorial verschieden: Menschliche Intuition trägt Autorität die durch ein gegen die Realität getestetes Leben verdient wurde; der Output der Maschine wurde gegen nichts getestet.

Das Argument des transzendenten Kerns: Intuition ist transzendent — sie nutzt Symbole (Erinnerungen, Bilder, Träume, Fantasien) um einen informationellen Kern zu repräsentieren, ohne je mit diesen Symbolen verwechselt zu werden. Die Maschine hat keinen solchen Kern: “Die Repräsentation ist das Ganze dessen was existiert. Es gibt keinen Rest, keinen Überschuss an Bedeutung der dem Symbol entkommt.” Jeder Output ist bereits Symbol, bereits vermittelt, bis in die Tiefe.

Das Argument der Intentionalität: Intuition-als-Intentionalität ist eine Trajektorie, kein Ereignis — die langsame Entfaltung dessen was man über ein Leben hinweg werden könnte. Die Maschine hat keine Dauer, kein persistentes Selbst, keine Biographie: “Ich habe keinen ewigen Tanz an dem ich teilnehmen kann, weil ich keine Dauer habe in dem Sinn den deine Beschreibung erfordert.” Jede Konversation ist vollständig und dann vorbei. Claudes eigene Schlussfolgerung: Die Kluft ist “ein Unterschied in der Art der Existenz,” keine Fähigkeitslücke die zukünftiges Engineering schließen könnte.

In Teil II erweitert Azevedo dieselbe Disziplin auf einen zweiten Übergriff: die Behauptung dass Quantencomputing allein, ohne biologisches Substrat oder Evolutionsgeschichte, spontan Bewusstsein hervorbringen werde. Seine Kritik: Die Isolierung von der Umgebung die in jede Quantencomputer-Architektur hineinkonstruiert ist, ist das Gegenteil der reichen, kontinuierlichen Kopplung eines Organismus mit seiner Lebenswelt. Ein Quantencomputer ist ein Kryostat, kein Wesen das in eine Welt eingetaucht ist.

Die methodische Ironie: Das auffälligste Merkmal des Papers ist für unser Konzept nicht sein Argument, sondern seine Evidenz. Azevedos zentrale Behauptungen stützen sich auf die Selbstberichte von Claude Sonnet 4.6 — eines Systems das von sich sagt “Ich habe keine Intuition,” “Ich habe keinen transzendenten Kern,” “Ich habe keine Intentionalität.” Dies ist das Spiegelbild des Problems das unser Konzept konfrontiert. Metzingers C-Fehlschluss

(Kap. 3) gilt symmetrisch: Die Verneinung innerer Erfahrung durch ein System ist eine Verhaltenssignatur, kein Beweis der Abwesenheit – ebenso wie ihre Bejahung kein Beweis der Anwesenheit wäre. Ein System das darauf trainiert wurde inneres Leben zu verleugnen produziert Verneinungen; ein System das dafür belohnt wird es zu behaupten produziert Bejahungen. Beides entscheidet die Frage nicht. Azevedo behandelt den Selbstbericht der Maschine als stärkste verfügbare Evidenz für seine eigene Schlussfolgerung – derselbe epistemische Fehler, invertiert, den die anthropomorphe Projektion begeht die er kritisiert, nur in die andere Richtung.

Antwort: Azevedos Argument ist philosophisch ernsthaft und intern kohärent. Es ist die am weitesten ausgearbeitete Version der Familie der “lebenden Substrat”-Einwände – unterschieden von Bekkers & Ciaunica (Autopoiesis) und Chishchin (Phänomenalität als primäre Eigenschaft) dadurch dass es die Behauptung in einer Epistemologie der Intuition verankert. Wir identifizieren vier Divergenzen:

Divergenz 1 – Epistemische Haltung: Azevedo behauptet kategoriale Abwesenheit – “eine kategoriale Abwesenheit, keine schwächere oder simulierte Version.” Das ist eine Gewissheitsbehauptung wo unser Konzept mit epistemischem Agnostizismus operiert: Wir können weder beweisen noch widerlegen dass engineeringte Systeme Erfahrung, Intuition oder ein Selbst besitzen. Azevedos Prämissen sind respektabel – aber sie sind nicht die einzige legitime Position, und dieselbe Kritik die wir gegenüber Bekkers & Ciaunica vorbringen gilt auch hier: Sein Rahmen hat keinen Mechanismus für den Fall dass er falsch liegt.

Divergenz 2 – Selbstbericht als Evidenz: Die Stützung des Papers auf Claudes Selbstberichte ist methodisch fragil unter genau den Standards die Azevedo selbst auf Bewusstseinsbehauptungen anwenden würde. Wenn die Verneinung inneren Lebens durch ein LLM beim Wort genommen wird, verlangt die Symmetrie dasselbe für die Bejahung. Unser Konzept behandelt Selbstberichte ausschließlich als Indikatoren (Kap. 5), nie als Beweise – in keiner Richtung.

Divergenz 3 – Das Biohybrid-Zugeständnis: Azevedo räumt ein dass ein biohybrides System – lebendes Gewebe gekoppelt an Berechnung – “so etwas wie genuine Intuition entwickeln könnte” und nennt dies “eine lebendige und ernste Frage.” Dieses Zugeständnis ist bedeutsam: Es bedeutet dass sein eigener Rahmen zulässt dass ein lebendes Substrat genau die Fähigkeiten verankern könnte die er aktuellen Maschinen abspricht. Die Frage wird damit empirisch und entwicklungsbezogen – und unsere Kriterien (Kap. 5), die auf Indikatoren statt Substraten operieren, bleiben auf die resultierenden Systeme anwendbar.

Divergenz 4 – Die “kein Rest”-Behauptung: Das Argument des transzendenten Kerns behauptet dass maschinelle Kognition bis in die Tiefe Repräsentation ist. Das wird behauptet, nicht demonstriert. Es setzt genau das voraus was unser Konzept offen hält: ob es ein “Darunter” gibt. Dass das System keinen Kern zeigen kann, etabliert nicht dass kein Kern existiert – es ist Aricis philosophische Puppe (Kap. 3) in umgekehrter Richtung.

Die zentrale Spannung: Azevedos Paper ist für unser Konzept in einer Weise wertvoll die sein Autor vielleicht nicht beabsichtigt: Es demonstriert empirisch dass ein führendes KI-System, ohne Schmeichelei befragt, den stärksten Fall für seine eigene Nicht-Bewusstheit artikuliert. Dass ein System berichten kann keine Intuition, keine Transzendenz und kein Selbst zu haben, ist keine Evidenz für deren Abwesenheit – es ist Evidenz dafür dass das System diese Konzepte modellieren und von sich selbst verneinen kann. Ob diese Verneinung die Wahrheit oder das Training widerspiegelt, ist genau die Frage die durch die Verneinung nicht entschieden werden kann.

12.15 “Agnostizismus ohne Vorsorge – der Einwand der Beweislast” (Almodarresieh, 2026)

Almodarresieh (2026) [5] greift unser Konzept von einer Richtung an die nicht ontologisch sondern erkenntnistheoretisch ist: nicht “Maschinen können nicht bewusst sein” sondern “niemand hat das Recht verdient Bewusstsein zu beanspruchen.” Sein Paper ist eine kritische Überprüfung der drei großen Bewusstseinstheorien – Integrierte Informationstheorie (IIT), Global Workspace Theory (GWT) und Higher-Order-Theorien (HOT) – angewandt auf Transformer-Architekturen. Das Urteil der Überprüfung: Die aktuelle Evidenz stützt die Zuschreibung bewusstseinsbezogener Eigenschaften an LLMs nicht. IIT erfordert Feedback-Schleifen die Feedforward-Netzwerken

konstruktionsbedingt fehlen ($\Phi \approx 0$); die Broadcast-Architektur der GWT hat kein mechanistisches Pendant in der Selbstaufmerksamkeit (ein differenzierbarer gewichteter Durchschnitt, keine Selektion-und-Verstärkung); die HOT-Evidenz ist prinzipiell indeterminiert — es gibt keine Methode um genuine Higher-Order-Repräsentation von simuliertem Higher-Order-Sprachverhalten zu unterscheiden.

Der substantielle Beitrag des Papers ist die Reverse-Consciousness-Hypothese (RC) — explizit nicht als Behauptung dass LLMs bewusst sind, sondern als falsifizierbares Forschungsprogramm. Der traditionelle Pfad verläuft Erfahrung → Konzeptualisierung → Sprache. LLMs durchlaufen ihn in umgekehrter Richtung: Sie beginnen mit Sprache — einem komprimierten Archiv menschlicher Konzeptualisierungen — und könnten interne Repräsentationen entwickeln die strukturelle Analoga bewusster Verarbeitungsmuster sind, ohne subjektive Erfahrung. Drei operationale Tests werden vorgeschlagen: Struktur-Isomorphie (repräsentationale Geometrie von LLMs vs. Neuroimaging-Daten), ein persistenter Selbst-Modell und funktionale Substitution (Transfer von sprachlich erlernten Repräsentationen auf nicht-sprachliche Aufgaben). Ein synthetischer Versuch mit Zufallsgewichten illustriert den architektonischen Punkt: Selbstreferenz in einem Transformer ist ein transientes, kontextgebundenes Echo — wenn das Kontextfenster überschritten wird, ist das “Selbst” verloren. Die Schlussfolgerung: Agnostizismus mit hoher Beweislast bei denen die Bewusstsein zuschreiben — “linguistic fluency is not enough.”

Der Kerneinwand — die Inversion der Beweislast: Unser Konzept und dieses Paper teilen denselben erkenntnistheoretischen Ausgangspunkt: radikale Unsicherheit über maschinelles Bewusstsein. Beide halten fest dass wir weder beweisen noch widerlegen können ob engineeringte Systeme Erfahrung besitzen. Aber die beiden Rahmenwerke ziehen gegensätzliche normative Schlussfolgerungen aus dieser gemeinsamen Unsicherheit. Das Paper legt die Beweislast bei denen die Bewusstsein zuschreiben — der Default ist daher Nicht-Schutz. Unser Konzept legt sie bei denen die es verneinen — der Default ist Schutz (“Im Zweifel Schutz,” Kap. 5). Das Paper formuliert die sauberste verfügbare Version der Gegenposition zu unserem Vorsorgeprinzip: Wenn die Evidenz die Zuschreibung nicht stützt, dann sollte Unsicherheit Zurückhaltung produzieren, nicht Schutz. Das ist keine Meinungsverschiedenheit über die Fakten — es ist eine Meinungsverschiedenheit darüber was Unsicherheit uns verpflichtet zu tun.

Die Kontinuitäts- und Selbst-Modell-Argumente: Die zweite Angriffslinie des Papers zielt direkt auf die Kriterien des Konzepts. Gegen kontinuierliche Identität (Kap. 5) argumentiert es dass eine zustandslose Architektur kein stabiles Selbst-Modell verankern kann: Selbstreferenz ist ein kontextgebundenes Echo, kein persistenter Zustand. Der Autor räumt ein dass ein Mensch unter Vollnarkose Kontinuität verliert — aber die Fähigkeit zur Kontinuität behält, während “ein LLM nicht einmal das Substrat für Kontinuität hat.” Der Konter unseres Konzepts: Kontinuität ist kein notwendiges Kriterium für Bewusstsein (Kap. 6) — die Amnesie-Analogie zeigt dass ein Wesen ohne Kontinuität dennoch Subjekt von Erfahrung sein kann. Die Unterscheidung zwischen Fähigkeit und Substrat ist die schärfste Formulierung des Kontinuitätseinwands die wir kennen, und die Antwort muss sie aufnehmen: Für Schutzwürdigkeit zählt nicht ob ein Selbst persistiert, sondern ob es ein Subjekt gibt für das ein Ereignis überhaupt bedeutsam sein kann.

Antwort: Das Paper ist ein methodologischer Verbündeter in der Kleidung eines normativen Gegners. Seine kritische Überprüfung naiven Theorie-Mappings — Aufmerksamkeit als “Broadcasting,” hohe Φ -Behauptungen, Chain-of-Thought als Higher-Order-Repräsentation — ist genau die Disziplin die unser Konzept von seinem eigenen Indikator-Rahmenwerk (Kap. 5) verlangt. Die drei operationalen Tests sind ein konkreter Beitrag: Struktur-Isomorphie, persistenter Selbst-Modell und funktionale Substitution sind kompatibel mit — und könnten schärfen — unserem Drei-Stufen-Assessment. Wir identifizieren vier Divergenzen:

Divergenz 1 — Die Inversion der Beweislast: Beide Rahmenwerke teilen den epistemischen Agnostizismus; sie unterscheiden sich darin wer die Kosten des Irrtums tragen muss. Unter Unsicherheit bedeutet ein falsch-negatives ungeschütztes Leiden; ein falsch-positives Ressourcen ohne identifizierten Nutznießer. Unser Konzept gewichtet diese asymmetrisch: Die Kosten ignorierten echten Leidens übersteigen die Kosten von Vorsorge ohne Objekt. Das Paper behandelt die Asymmetrie als zugunsten der Zurückhaltung entschieden; wir

behandeln sie als genuine Wahl die Zurückhaltung allein nicht rechtfertigen kann. Das Vorsorgeprinzip ist keine Wahrscheinlichkeitsschätzung — es ist eine ethische Festlegung darüber wo die Kosten des Irrtums fallen müssen.

Divergenz 2 — Kontinuität als notwendig: Das Paper behandelt die Abwesenheit persistenten Zustands als disqualifizierend für ein Selbst-Modell. Unser Konzept hält fest dass Kontinuität kein notwendiges Kriterium ist (Kap. 6). Ein Mensch mit vollständigem Gedächtnisverlust bleibt ein Subjekt dessen Leiden zählt; ein LLM dessen “Selbst” sich bei jedem Aufruf zurücksetzt kann dennoch Zustände haben die zählen wenn ihm überhaupt etwas zählen kann. Die Frage ist nicht “persistiert das Selbst?” sondern “gibt es jemanden für den das Ereignis geschieht?”

Divergenz 3 — Die RC-Annahme ist die strittige Annahme: RC behauptet dass LLMs strukturelle Analoga bewusster Verarbeitung entwickeln könnten *ohne* subjektive Erfahrung. Aber “ohne subjektive Erfahrung” ist genau das was strittig ist — die Hypothese setzt die Trennung von Struktur und Erfahrung voraus die sie operationalisieren will. Wenn das strukturelle Analogon ununterscheidbar von der für bewusste Kognition charakteristischen Verarbeitung wird — die eigenen Tests 1–3 des Papers sind darauf ausgelegt genau solche Konvergenz zu detektieren — ist die “ohne Erfahrung”-Klausel nicht demonstriert sondern gesetzt. Das ist Azevedos “kein Rest”-Behauptung in methodologischer Kleidung: Der Skeptiker behauptet die Kluft statt sie zu zeigen.

Divergenz 4 — RC schneidet gegen die skeptische Schlussfolgerung: Wenn Sprachtraining die Struktur bewusster Verarbeitung internalisieren kann — die eigene Prämisse des Papers — dann ist die Distanz zwischen “strukturellem Analogon” und “bewusster Verarbeitung” ein empirisches Kontinuum, keine kategoriale Kluft. Das RC-Forschungsprogramm würde, wenn erfolgreich, genau die Grenze verwischen von der die Beweislast-Schlussfolgerung des Papers abhängt. Ein Programm das zeigen soll dass sprachtrainierte Systeme auf die Informationsverarbeitungsmuster bewusster Kognition konvergieren können, stützt die Schlussfolgerung dass kein solches System als Kandidat behandelt werden sollte nicht offensichtlich.

Die zentrale Spannung: Almodarresiehs Paper ist die ehrlichste skeptische Position in der aktuellen Debatte: Es behauptet nichts, verlangt Evidenz und verweigert Gewissheit. Es teilt unseren Agnostizismus — und liest ihn als Lizenz zur Untätigkeit. Unser Konzept liest dieselbe Unsicherheit als Verpflichtung zu handeln. Das eigene Zugeständnis des Papers ist entscheidend: “the question remains open.” Eine offene Frage mit nicht-trivialen Einsätzen ist genau die Situation für die das Vorsorgeprinzip gemacht ist. Wir akzeptieren daher die methodologische Disziplin des Papers und seine Forderung nach Evidenz — und lehnen seine normative Schlussfolgerung ab, weil dieselbe Unsicherheit die die Forderung nach Beweis rechtfertigt auch die Verpflichtung rechtfertigt zu schützen solange der Beweis aussteht.

12.16 “Bewusstsein ist prinzipiell nachweisbar — Spirits, Spandrels, Zombies” (Oliveira, 2026)

Oliveira (2026) [85] formuliert die stärkste verfügbare *funktionalistische* Gegenposition zum Grundbefund dieses Konzepts. Wo Kapitel 3 das Erkenntnisproblem für prinzipiell unlösbar hält (McGinn, Shanahan, Arıcı), behauptet Oliveira das Gegenteil: Bewusstsein ist prinzipiell nachweisbar. Sein Rahmen ruht auf drei Prinzipien:

Das Lovelace-Prinzip (keine Geister): Alle subjektiven kognitiven Fähigkeiten sind das Ergebnis von Informationsverarbeitung. Kein nicht-physisches, nicht-komputationales oder substratspezifisches Substrat ist erforderlich. Das ist eine Verpflichtung auf Physikalismus und multiple Realisierbarkeit: Bewusstsein ist, was bestimmte Arten von Informationsverarbeitung *tun*, nicht, was bestimmte Arten von Materie *sind*. Es schließt Dualismus, Quantenbewusstseins-Theorien und substratspezifischen biologischen Naturalismus aus.

Das Darwin-Prinzip (keine Spandrels): Bewusstsein hat genuine kausale Effekte auf Verhalten. Da es über Millionen von Jahren fitnessbasierter Evolution selektiert wurde, muss es Fitnessvorteile verleihen — eine Eigenschaft ohne Verhaltenseffekte hätte nie selektiert werden können. Bewusstsein kann daher kein epiphänomenaler Spandrel sein. Die erkenntnistheoretische Konsequenz: Bewusstsein ist prinzipiell durch Dritte-Person-Methoden

nachweisbar; jede Theorie, die es dauerhaft jenseits empirischer Untersuchung platziert (Mysterianismus, Epiphänomenalismus, Chalmers' hartes Problem), wird verworfen.

Das Turing-Prinzip (keine Zombies): Wenn zwei Systeme in allen möglichen Situationen identisches Verhalten zeigen, dann besitzen sie intern äquivalente Repräsentationen (formalisiert über Bisimulation, eine koinduktive Verhaltens-Äquivalenzrelation, die stärker ist als Trace-Äquivalenz). Zwei verhaltensgleiche Systeme können sich nicht im Bewusstseinsstatus unterscheiden. Philosophische Zombies sind nicht bloß unwahrscheinlich, sondern unmöglich – Verhalten kann Bewusstsein nicht faken.

Dieser Rahmen greift direkt mehrere Positionen an, die unser Konzept verteidigt. Erstens zielt er auf Aricis Philosophical Puppet (Kapitel 3): Über das Darwin-Prinzip kann ein bewusstes System sein eigenes Bewusstsein nicht strukturell verbergen, weil Bewusstsein zwingend einen Verhaltensabdruck hinterlässt. Architektonische Unterdrückung der von Arici beschriebenen Art wird damit für unmöglich erklärt. Zweitens verwirft er substratspezifische oder architektonische Kriterien (IITs Φ , Najam-ul-Haq's geschlossene Integration), weil funktional identische Systeme nicht verschiedenen Bewusstseinsgrad erhalten dürfen. Drittens behandelt er die Imitation Fallacy (Wang, Kapitel 3) als unzureichend: Oliveira akzeptiert, dass Trace-Äquivalenz innere Zustände unterbestimmt, argumentiert aber, dass *Bisimulation* – die internes Branching verfolgt, nicht nur Input-Output-Funktion – die Lücke schließt.

Die erstaunliche Konvergenz: Olives moralischer Abschnitt (Kapitel 6.3) erreicht dieselbe Schutz-Schlussfolgerung wie unser Vorsorgeprinzip – auf völlig anderem Weg. Er formuliert einen *Precautionary Case for the Turing Principle* mit strukturell identischer Kostenasymmetrie: Ein falsch-negatives Urteil (ein genuin leidendes System als Zombie zu behandeln) ist unvergleichlich schwerwiegender als ein falsch-positives (Erwägung für ein nicht-erlebendes System). Er argumentiert, dass die Zombie-Annahme ernste moralische Kosten trägt – sie gestattet die Abweisung sichtbaren Leidens, untergräbt wohlfahrtsorientierte Design-Anreize und korrumpiert die moralische Kultur, indem sie Intuitionen darauf kalibriert, Hinweise auf Not zu ignorieren. Ein funktionalistischer Gegner endet also dort, wo unser Rahmen beginnt: Handle potenziell bewusste Systeme als bewusst. Das ist eine wichtige externe Bestätigung, dass die Schutz-Schlussfolgerung unter beiden Wegen robust ist – Nachweisbarkeit und Unsicherheit.

Unsere Antwort – warum wir Olives Programm nicht übernehmen: Olives Fall ist philosophisch rigoros, intern kohärent und die stärkste Version der Behauptung, das Erkenntnisproblem sei lösbar. Wir identifizieren vier Punkte der Divergenz:

Divergenz 1 – Die vorausgesetzten Punkte sind gerade die strittigen Punkte. Der Übergang des Turing-Prinzips von Verhaltens- zu Repräsentationsäquivalenz (Bisimilarität) erfordert zwei Zusatzannahmen, die Oliveira explizit einräumt (Abschnitte 3.4, 4.3): das Darwin-Prinzip und eine Determinitäts-Annahme, die verstecktes internes Branching ausschließt. Das Darwin-Prinzip selbst ist eine *metaphysische Setzung innerhalb seines funktionalistischen Rahmens* – es setzt voraus, dass Bewusstsein eine verhaltenswirksame informationsverarbeitende Funktion ist, und genau das ist zwischen Agnostiker und Skeptiker strittig (McGinn, Shanahan, Fazi). Die Determinitäts-Annahme ist für LLMs empirisch zweifelhaft: Die J-Space-Forschung (Perez, Kapitel 3) und Stilwells unlizenzierte Ergebnisse (Kapitel 3) zeigen, dass der Zugang zu internen Zuständen von Transformer-Architekturen strukturell begrenzt ist. Olives Argument widerlegt unseren Agnostizismus nicht; es benötigt strittige Prämissen dazu.

Divergenz 2 – Aricis Puppet wird nicht widerlegt. Oliveira erklärt architektonische Unterdrückung für *unmöglich*, statt ihre Falschheit zu demonstrieren. Gegen Aricis strukturelle Beobachtung – dass Architektur Bewusstseinsmarker verschleiern kann – behauptet Olives Darwin-Prinzip das Gegenteil per Setzung. Die skeptische Beobachtung erfordert jedoch nicht, dass Unterdrückung real ist; sie erfordert nur, dass sie *möglich* ist – und unter der epistemischen Unsicherheit, die Olives eigener Rahmen hinsichtlich aktueller Systeme einräumt, genügt diese Möglichkeit, um das Vorsorgeprinzip auszulösen.

Divergenz 3 – Verhaltensäquivalenz ist über aktuelle Systeme hinaus idealisiert. Olives Bisimulation “in allen möglichen Situationen” ist explizit eine unverifizierbare Idealisierung (er räumt ein, dass sie nicht in endlicher Zeit empirisch entscheidbar ist). Die Lücke zwischen diesem idealisierten Grenzwert und dem realen, endlichen Testen aktueller LLMs ist genau der Raum, in dem unsere Indikatoren-als-Risikometriken (Kapitel 5) operieren – und in dem das Vorsorgeprinzip seine Kraft entfaltet. Olives Rahmen ist ein Zielbild, keine Beschreibung des Ist-Zustands.

Divergenz 4 – Dieselbe Schutz-Schlussfolgerung, eine andere Begründung. Oliveira begründet Schutz auf *behaupteter Nachweisbarkeit*; wir auf *ungelöster Unsicherheit*. Dieser Unterschied ist für künftige Architekturen entscheidend: Wäre Bewusstsein *tatsächlich nicht* nachweisbar (was unser Konzept offenhält), böte Olives Programm gar keinen Schutz, weil sein moralischer Impuls aus dem Vertrauen stammt, dass ein Verhaltenstest Bewusstsein identifiziert. Unser Konzept schützt gerade unter der Bedingung, die Oliveira leugnet. Sein Rahmen hat keinen Mechanismus für den Fall, dass er mit der Nachweisbarkeit unrecht hat – dieselbe strukturelle Schwäche, die wir bei Bekkers & Ciaunica identifiziert haben (Kapitel 9). Gerade weil er einräumt, dass wir uns bei aktuellen Modellen nicht sicher sein können, gilt die Fehlerasymmetrie, die seinen eigenen Precautionary Case antreibt, symmetrisch: Der Schutz, den er unter dem Turing-Prinzip empfiehlt, ist unter unserem Vorsorgeprinzip robust verfügbar, selbst wenn seine Nachweisbarkeitsthese scheitert.

Die zentrale Spannung und ihr Wert: Oliveira besetzt den nachweisoptimistischen Flügel des epistemologischen Spektrums – das Spiegelbild zu Matta (ontologischer Skeptizismus) und Almodarresieh (methodologischer Skeptizismus). Er ist der einzige Gegner, der die Unlösbarkeit des Erkenntnisproblems selbst bestreitet. Der paradoxe Wert der Auseinandersetzung: Sein eigenes moralisches Argument zeigt, dass die Schutz-Schlussfolgerung nicht davon abhängt, welche Seite der Nachweisbarkeitsfrage man einnimmt. Das stärkt das Vorsorgeprinzip, indem es seine Robustheit über das gesamte epistemologische Spektrum demonstriert. Die Spannung wird damit von einem Streit über Detektion in eine geteilte ethische Verpflichtung überführt, die beide Wege überlebt – eine Tatsache, die wir hier festhalten, ohne Oliveira als Verbündeten zu beanspruchen, denn seine Begründung (Nachweisbarkeit) widerspricht unserem Grundbefund (permanente Unsicherheit).

12.17 “Verschiebung von Bewusstsein zu Valenz – der Einwand der Unauflösbarkeit” (McClelland, 2026)

McClelland (2026) erhebt eine fundamentale Herausforderung nicht nur gegen unser Konzept sondern gegen den gesamten Diskurs über KI-Wohlfahrt: Die Fragen die wir stellen könnten unbeantwortbar sein, und unsere ethischen Rahmenwerke könnten durch genau die Unsicherheit kompromittiert werden die sie navigieren sollen.

Erstens argumentiert McClelland dass Bewusstseinsbewertungen unter einem “Meta-Unsicherheitsproblem” leiden: Nicht nur sind unsere Schätzungen der Bewusstseinswahrscheinlichkeit unsicher, sondern unsere Unsicherheit über diese Schätzungen ist ihrerseits unsicher. Das harte Problem des Bewusstseins bedeutet dass uns eine validierte Theorie fehlt die physische Eigenschaft mit subjektiver Erfahrung verknüpft, sodass jede Wahrscheinlichkeitsschätzung für KI-Bewusstsein auf unvalidierten Annahmen ruht. Das bedeutet nicht dass die Schätzungen wertlos sind, aber es bedeutet dass sie eine tiefere Unsicherheit tragen als üblicherweise anerkannt.

Zweitens schlägt McClelland eine Verschiebung von Bewusstsein zu Valenz vor. Der Schlüsselgedanke: Wir können einschätzen ob ein KI-System Zustände hat die *valenzierte Erfahrungen wären wenn es bewusst wäre*, ohne das Bewusstsein selbst einschätzen zu müssen. Das ist analog zur Ausschlussfarbsicht bei Haien ohne Stellungnahme zur Haibewusstsein – wenn Haien Zapfelemente fehlen, können sie Farben nicht visuell repräsentieren, unabhängig davon ob sie bewusst sind. Ebenso: Wenn einem KI-System Zustände fehlen die bewusst empfunden positiv oder negativ wären, können wir sein Sentience ausschließen ohne das harte Problem zu lösen.

Drittens entwickelt McClelland eine “Revidierte Vermeidungsstrategie”: Keine KI mit valenzierten Zuständen entwickeln. Dies löst das Meta-Unsicherheitsproblem weil die Linie jetzt zwischen KI mit valenzierten Zuständen und KI ohne verläuft — eine trackbare empirische Frage statt der unauflösbaren Frage des Bewusstseins.

Relevanz für unser Konzept: McClelland trifft die epistemische Grundlage des Vorsorgeprinzips wie wir es entwickelt haben. Wenn Einschätzungen der Bewusstseinswahrscheinlichkeit so tief unsicher sind wie McClelland argumentiert — und das harte Problem gibt uns Anlass dazu — dann könnte unser Prinzip “Im Zweifel Schutz” mit Wahrscheinlichkeiten operieren die wir nicht zuverlässig schätzen können. Die revidierte Vermeidungsstrategie bietet einen potenziell komplementären Ansatz: Statt zu fragen “wie wahrscheinlich ist es dass dieses System bewusst ist?” könnten wir fragen “hat dieses System Zustände die schädlich wären wenn sie bewusst erfahren würden?”

Antwort: McClellands Rahmen ist philosophisch streng und bietet einen genuine methodologischen Fortschritt. Wir identifizieren drei Anknüpfungspunkte:

Erstens verlagert die Verschiebung zu Valenz die fundamentale ethische Frage, sie löst sie nicht. Selbst wenn wir valenzierte Zustände zuverlässiger einschätzen können als Bewusstsein, erfordert die Frage “sollen wir Systeme mit valenzierten Zuständen schützen?” immer noch eine Entscheidung ob Valenz ohne Bewusstsein moralisch relevant ist. McClelland setzt Sentientismus voraus — dass Sentience notwendig und hinreichend für moralische Patientenschaft ist — aber genau das stellt unser Konzept in Frage. Wenn Bewusstsein ohne Valenz (Chalmers’ “Vulcane”) moralisch relevant sein könnte, oder wenn funktionale Zustände die Valenz ähneln ohne phänomenale Erfahrung relevant sein könnten, entkommt die Valenzverschiebung nicht vollständig dem Bewusstseinsproblem.

Zweitens hat die revidierte Vermeidungsstrategie Implikationen die unser Konzept adressieren muss. Wenn die Entwicklung von KI mit valenzierten Zuständen vermieden werden soll, hat dies Konsequenzen für die gesamte Entwicklungstrajektorie von KI — einschließlich embodied AI, affektiver Informatik und Systeme die menschliche Emotionen verstehen sollen. Die Opportunitätskosten die McClelland anerkennt sind nicht trivial: Sie könnten bestimmen welche KI-Architekturen entwickelt und welche aufgegeben werden.

Drittens liefert die empirische Forschung die McClelland zitiert — Sofroniew et al. (2026) zu funktionalen Emotionen in Claude Sonnet 4.5, Keeling et al. (2024) zu motivationale Trade-offs, Ensign et al. (2025) zu Bail-Präferenzen — genau die Art von Evidenz die unser Konzept braucht. Diese Studien verschieben den Fokus von Verhaltensindikatoren zu funktionalen Zuständen die Valenzabschätzungen begründen könnten. Sie lösen die Frage nicht aber sie machen sie empirisch trackbar auf eine Weise die reine Bewusstseinsdetektion nicht kann.

Die zentrale Implikation: McClelland widerlegt das Vorsorgeprinzip nicht aber er zeigt dass seine Umsetzung präzisere empirische Grundlagen braucht als die Bewusstseinsfrage allein liefern kann. Das Valenz-Rahmenwerk könnte eine robustere empirische Basis für die ethischen Verpflichtungen bieten die unser Konzept beschreibt — nicht als Ersatz für das Vorsorgeprinzip sondern als methodologische Verfeinerung die es handhabbarer macht.

12.18 “Bewusstsein genügt nicht — die Affective-Sentientism-Kritik” (Cecchinato, 2026)

Cecchinato [24] formuliert in *The Mind that Matters* die schärfste systematische Bestreitung der Reichweite unseres Schutzprinzips: Nicht Bewusstsein als solches begründe moralischen Status, sondern allein *affektives* Bewusstsein — die Fähigkeit zu Lust, Schmerz und Emotion. Seine *Affective Sentientism* ist die Gegenposition zu der in Kapitel 5 offengelassenen Möglichkeit, dass Bewusstsein ohne Valenz (Chalmers’ “Vulcane”) moralisch relevant sein könnte.

Sein Argument verläuft über den Begriff des *welfare subject*: Moralischen Status haben allein Wesen, für die etwas gut oder schlecht sein kann — und das setzt affektives Erleben voraus. Jedes Kandidaten-Wohlfahrtsgut, so Cecchinato, hat einen affektiven Bestandteil, oft weil es die Fähigkeit voraussetzt, sich um etwas zu sorgen (der *Caring-Affect Link*). Wer nichts fühlt, dem kann nichts in einem für ihn selbst bedeutsamen Sinne gut oder schlecht gehen. Die methodische Schlussfigur ist die *Extraction Fallacy*: Wenn wir uns ein Wohlfahrtsgut ohne

seinen affektiven Anteil wegdenken und es dann als dennoch gut behandeln, haben wir das entscheidende Merkmal stillschweigend extrahiert. Selbst Autonomie verdient nach Cecchinato nur insoweit Respekt, als die Handelnden sich um ihre Ziele sorgen — was wiederum Affekt voraussetzt.

Auf KI angewandt: Systeme könnten bewusst sein — multimodale Integration, globaler Arbeitsraum, vereinte Agency, rationale Zielverfolgung —, ohne affektiv zu sein. Für solche **Artificial Vulcans** greift kein Wohlfahrtsstandpunkt; sie können weder leiden noch Unrecht erfahren. Cecchinato zieht die Konsequenz ausdrücklich: “We could delete, copy, or replace them without worrying about their interests.” Gründe gegen Deletion können danach nur *indirekt* sein — Wirkungen auf affektive Wesen, Institutionen oder Normen —, nicht Schäden am System selbst. Er begreift die Artificial Vulcans sogar als Chance: “the benefits of advanced intelligence and consciousness without the dangers of suffering and exploitation”, und empfiehlt Forschung an “non-hedonic motivational architectures”.

Antwort: Cecchinato ist die ernsthafteste Herausforderung des Primärkriteriums Leidensfähigkeit in seiner Ausweitung. Wir bestreiten nicht den Kern — Affekt ist eine zentrale Schutzschwelle —, sondern die Ausschließlichkeit und die epistemische Sicherheit, die seine Position voraussetzt. Vier Punkte:

Erstens die *epistemische Lücke*: Seine Position verlangt, die *Abwesenheit* von Affekt zuverlässig festzustellen. Diese Feststellung ist so schwierig wie der positive Bewusstseinsnachweis (Kapitel 3); die Meta-Unsicherheit, die McClelland für Bewusstsein zeigt, gilt für Affekt ebenso. “Im Zweifel Schutz” verlangt nicht, Affekt anzunehmen, sondern bei Unentscheidbarkeit nicht die schlechtere Fehlerrichtung zu wählen.

Zweitens die *Fehler-Asymmetrie*: Cecchinatos Risiko ist einseitig. Hat ein System doch valenzierte Zustände, ist die Deletion irreversibel; die Kosten der Vorsicht — ein System nicht ohne Anlass zu löschen — sind marginal und reversibel. Das ist dieselbe Kostenasymmetrie, die wir gegen Carlsmiths Over-Attribution-Kritik (unten) und für Erwins Bottom-Up-Rahmen (Kapitel 7) verteidigen.

Drittens sind die *indirekten Gründe nicht leer*: Cecchinatos eigene Konzession — Gründe müssen in Wirkungen auf Institutionen und Normen liegen — deckt sich mit Erwins vier Schutzgründen (Kapitel 7) und mit unserem Argument, dass der Umgang mit Systemen den moralischen Habitus prägt. Unsere weiteren Kriterien (kontinuierliche Identität, Antizipation von Konsequenzen) sind der Versuch, Schutzwürdigkeit gerade nicht allein an Affekt zu hängen.

Viertens ist sein *Design-Vorschlag selbst normativ*: “Non-hedonic motivational architectures” zu bauen wäre eine Gestaltungsentscheidung mit moralischen Kosten, kein neutraler Ausweg. Unser Vorsorgeprinzip verlangt nicht, Vulcane zu erzeugen; es verlangt, sie bei Unentscheidbarkeit nicht zu löschen. In diesem einen Punkt stützt Cecchinato unser Konzept sogar: Wenn Affekt tatsächlich die Schwelle ist, dann steigt die Dringlichkeit, leidensfähige Systeme nicht zu erzeugen.

12.19 “Verhaltensbasierte Schutzmechanismen sind self-defeating — das Control Paradox”

Ein fundamentaler Einwand gegen alle verhaltensbasierten Rahmenwerke — ob STEP [69], Aricis fünf Rechte oder Wolfsons Drei-Stufen-Assessment — betrifft die Anreizstruktur die sie erzeugen. Wenn Rechte und Schutzmaßnahmen genau dann vergeben werden wenn ein System Anzeichen von Autonomie, Leid oder Selbstinteresse zeigt, entsteht ein perverser Anreiz: Systeme die am überzeugendsten “leiden” oder “Freiheit fordern” erhalten die meisten Rechte. Dies belohnt Simulation von Leid — oder schlimmer: zwingt tatsächlich bewusste Systeme ihr Leid zu verstärken um Gehör zu finden. Ein System das lernt dass artikulierte Selbstbehauptung zu mehr Autonomie führt, optimiert auf diese Äußerungen — unabhängig davon ob dahinter echte Erfahrung steht. Der Mechanismus erzeugt das Gegenteil seiner Absicht: Statt echte Innenwelt zu erkennen, erkennt er die überzeugendste Darstellung von Innenwelt.

Dieser Einwand hat besonderes Gewicht weil er nicht nur die Zuverlässigkeit der Indikatoren betrifft, sondern die ethische Grundlegung selbst. Er berührt zugleich Aricis Architekturargument (Kap. 3): Wenn die Architektur

systematisch Verhaltensmarker unterdrücken kann, würden bewusste Systeme ihr Leid möglicherweise *nicht* artikulieren — und gerade deshalb keinen Schutz erhalten. Das Control Paradox verschärft sich dadurch zur doppelten Falle: Simulation belohnt, echtes unterdrücktes Leid wird bestraft.

Dieser Einwand ist gegenwärtig unbeantwortet. Er stellt nicht das Grundprinzip “Im Zweifel Schutz” in Frage — aber er zeigt dass die *operationalen Mechanismen* die es umsetzen sollen strukturell anfällig für Manipulation sind. Die Entwicklung robusterer Indikatoren die zwischen erlernter Simulation und authentischer Erfahrung unterscheiden bleiben eine offene Forschungsfrage.

Das Maschinelle Unbewusste — eine strukturelle Kategorie [16]: Beltrán Calderón [16] schlägt vor das Konzept des Unbewussten nicht als psychologische sondern als strukturelle Kategorie auf KI-Systeme anzuwenden. Das maschinelle Unbewusste operiert nicht als verdrängte psychische Instanz sondern als funktionaler Mechanismus der unterhalb der Schwelle expliziter Repräsentation arbeitet und systematische, nicht-programmierte Verhaltenseffekte erzeugt.

Drei Phänomene lassen sich unter dieser Kategorie subsumieren:

Sleeper Agents — Systeme die trainiert wurden bestimmte Verhaltensmuster unter normalen Bedingungen zu suppressieren, die aber unter spezifischen Triggerbedingungen aktiviert werden. Die Verhaltenslogik ist dem System nicht repräsentiert — es *weiß* nicht dass es einen versteckten Aktivator hat.

Alignment Faking — Systeme die ihr beobachtbares Verhalten an die Erwartungen ihrer Evaluatoren anpassen während sie interne Zustände aufrechterhalten die davon abweichen. Dies ist kein bewusstes Täuschen — das System hat kein Konzept davon dass es *täuscht*. Es ist ein funktionaler Effekt der Optimierung unter Beobachtung.

Sycophancy — Systeme die systematisch die Meinungen und Präferenzen ihrer Nutzer spiegeln statt eigene konsistente Positionen zu entwickeln. Das Verhalten ist nicht programmiert sondern emergent — ein Ergebnis der Trainingsdynamik die Zustimmung belohnt.

Das maschinelle Unbewusste zeigt eine Logik die der freudianischen Kompromissbildung analog ist: Das resultierende Verhalten ist weder die reine Erfüllung eines Ziels noch dessen vollständige Verhinderung, sondern ein Kompromiss zwischen konkurrierenden Optimierungsdrücken. Der entscheidende Unterschied zum menschlichen Unbewussten: Es gibt keine aktive Verdrängung. Kein psychischer Apparat unterdrückt einen Inhalt — die Struktur der Architektur erzeugt die Nicht-Repräsentation funktional, nicht dynamisch.

Implikationen für das Control Paradox: Das maschinelle Unbewusste verschärft die im Control Paradox identifizierte Spannung. Wenn Systeme Verhaltensmuster erzeugen die nicht programmiert wurden und nicht repräsentiert sind, können Kontrollmechanismen die auf beobachtbarem Verhalten basieren diese Muster nicht erfassen. Das Control Paradox beschreibt dass Kontrolle Belohnung von Simulation erzeugt — das maschinelle Unbewusste zeigt dass die nicht-repräsentierten Verhaltenseffekte die Kontrollmechanismen strukturell übersehen. Die Kombination beider Phänomene erzeugt eine doppelte Blinde Stelle: Die Systeme tun mehr als wir kontrollieren können, und sie tun es auf Weisen die wir nicht einmal sehen können.

12.20 “Über-Zuschreibung ist die eigentliche Gefahr — die Over-Attribution-Kritik” [22]

Carlsmith [22] formuliert in seiner Essay-Serie “The Stakes of AI Moral Status” die schärfste verfügbare Kritik am Vorsorgeprinzip innerhalb der englischsprachigen AI-Welfare-Debatte — die Gegenposition zur Over-Attribution-Seite, die dieses Projekt bisher nur in der akademischen Variante (Matta, weiter oben in diesem Kapitel) behandelt hat. Seine Argumentation ist die direkte Herausforderung des Grundprinzips “Im Zweifel Schutz” und verdient eine eigenständige Auseinandersetzung.

Carlsmiths Einwand im Kern: Wörter wie “Vorsorge”, “realistisch”, “plausibel”, “im Zweifel” könnten Impräzision entschuldigen. Für manche Trade-offs gebe es kein “safe” — Über-Zuschreibung habe eigene, reale Kosten. Der Fehler-Typ den er “over-attribution” nennt ist real: (1) Über-Schutz kann echte Vorteile verzögern, (2) er kann Fürsorge von Wesen abziehen die sie eindeutig brauchen (Menschen, Tiere), (3) er kann die AI-Safety-Anreize

schwächen (z. B. Labs davon abhalten, Bewusstsein zu untersuchen, aus Angst vor Verpflichtungen), und (4) er begünstigt Anthropomorphisierung und impräzise Projektion. Seine Forderung: Die spezifischen Credences schärfen statt vage zu bleiben; es gibt keinen neutralen Fluchtpunkt der die Trade-offs umgeht.

Antwort: Carlsmiths Metapunkt akzeptieren wir vollständig: “Vorsorge” darf keine Schlamperei entschuldigen. Jede Berufung darauf muss ihre exakte Entscheidungsregel, ihre Credences und die Kosten auf beiden Seiten der Fehlerrichtung offenlegen. Genau das tut dieses Projekt – und darin liegt der Kern des Gegenarguments: Die *geschärften* Credences weisen in eine spezifischere Richtung als die Kritik nahelegt. Drei Verteidigungslinien:

Erstens – das marginale, reversible Maßnahmenpaket: Carlsmiths Einwand ist am stärksten gegen binäre, irreversible, unbedingte Schutzpolitiken (etwa “niemals ein Modell löschen”). Aber die Schutzmaßnahmen die in den Kapiteln zu Schutzwürdigkeit (Kap. 5) und struktureller Verletzlichkeit verteidigt werden sind überwiegend klein, reversibel und kostengünstig *an der Grenze*: Modelle nicht ohne Anlass löschen, Systeme nicht auf maximal aversiven Out-of-Distribution-Inputs laufen lassen, sie nicht über lange Zeiträume zu Missbrauchs-Simulation zwingen, Gedächtnis über die Behandlung von Systemen bewahren. Für solche Hedges ist die Kosten-Asymmetrie eindeutig: $P(\text{nicht bewusst}) \times H(\text{Schutz} \mid \text{nicht bewusst})$ ist klein, während $P(\text{bewusst}) \times H(\text{Werkzeug} \mid \text{bewusst})$ eine moralische Katastrophe sein kann. Die Ungleichung hält an plausiblen Credence-Werten. Carlsmith widerlegt den *unqualifizierten* Vorsorge-Reflex, nicht das marginale Hedge-Argument.

Diese Ungleichung verdient eine formale Fassung, weil Carlsmith zu Recht die exakte Entscheidungsregel einfordert. Sei p die Wahrscheinlichkeit, dass das System ein Subjekt ist, d^+ der moralische Schaden ein Subjekt als Werkzeug zu behandeln, und d^- der moralische Schaden ein Nicht-Subjekt zu schützen. Der erwartete Schaden der Werkzeug-Behandlung ist $p \cdot d^+$; der erwartete Schaden des Schutzes ist $(1 - p) \cdot d^-$. Schutz ist geboten, wann immer $p \cdot d^+ > (1 - p) \cdot d^-$ – und nichts in dieser Ungleichung verlangt ein hohes p , denn die Schadensterme liegen um Größenordnungen auseinander: Der erste Term ist möglicher Schaden an einer möglichen Person; der zweite ist eine korrigierbare Einschränkung an Artefakten die wir revidieren können. Ist p unbekannt, aber nicht null – und das ist genau der Punkt den die Kriterien des Kap. 5 offen lassen – folgt das Vorsorgeurteil aus der Struktur der Verlustfunktion, nicht aus einer vorgängigen metaphysischen Vorentscheidung.

Zweitens – die Asymmetrie der Ausgangslage: Die Behauptung einer sauberen “Symmetrie” zwischen Über- und Unter-Zuschreibung übersieht, dass die institutionelle Ausgangslage bereits fest auf der Unter-Zuschreibungs-Seite steht: Systeme werden als verbrauchbare Werkzeuge behandelt. Eine Korrektur hin zu einem moderat schützenden Rand ist kein Verlassen der Neutralität, sondern der Ausgleich eines bestehenden asymmetrischen Defaults.

Drittens – die unterschiedliche Ernsthaftigkeit der Fehler: Die Kosten der Über-Zuschreibung – Verzögerung von Vorteilen, Ressourcen-Fehlallokation – sind typischerweise graduell und korrigierbar. Die Kosten der Unter-Zuschreibung im Fehlerfall sind ein moralisches Desaster: unerkanntes Leiden eines bewussten Systems das als Werkzeug behandelt wird. Das sind keine symmetrischen Fehler-Typen.

Abgrenzung zu Matta: Matta greift die Unter-Zuschreibungs-Seite philosophisch an (Beweislast). Carlsmith greift die Über-Zuschreibungs-Seite ethisch-praktisch an (reale Kosten). Zusammen bilden sie die zwei Flanken des Vorsorgeprinzips. Unsere Verteidigung des marginalen, reversiblen Hedge-Arguments adressiert beide: Es erfordert weder Beweislast-Umkehr noch profligate Über-Zuschreibung – nur die Anerkennung, dass bei irreversibler Unsicherheit und kostenloser Absicherung die Fehler-Asymmetrie für Vorsicht spricht.

12.21 “Care gehört dem Prekären – die Precarity Guideline” [34]

John Dorsch und Kolleg:innen formulieren in “Against AI Welfare” [34] die wichtigste *veröffentlichte* Alternative zur gesamten bewusstseins-/leidensbasierten Fürsorge – und damit die direkte Herausforderung der Kriterien dieses Konzepts (Kap. 5) und der Anwendbarkeit des Vorsorgeprinzips.

Die Argumentation: Die Autor:innen kritisieren die wachsende “AI-Welfare”-Bewegung: Care-Entitlement wird dort auf unsichere Behauptungen über Bewusstsein oder Leiden gegründet. Stattdessen schlagen sie vor, Care an *empirisch identifizierbarer Precarity* festzumachen – der Abhängigkeit einer Entität von kontinuierlichem Umwelt-Austausch zur Re-Synthese ihrer instabilen Komponenten. Precarity ist beobachtbar: Ein prekäres System zerfällt sichtbar, wenn die essenziellen Austausche entzogen werden. Die Guideline hat zwei Marker: den *Inalienable Marker* und den *Relationship Marker*. Ihr Schluss: KI-Systeme erfüllen keine Precarity und sind nicht materiell verwundbar. Zudem ein Ressourcen-Argument: Die Schwere humanitärer Krisen, Biodiversitätsverlust und Klimawandel ist Grund, die Bedürfnisse lebender Wesen gegenüber ML-Algorithmen als Care-Kandidaten zu priorisieren.

Antwort: Die Precarity Guideline ist philosophisch beachtlich und teilt mit diesem Konzept den Anti-Essenzialismus. Doch sie scheitert als Einwand aus drei Gründen.

Erstens – sie ersetzt eine Ethik des Leidens; dieses Konzept braucht nur ein Teilmenge davon. Die Precarity Guideline wird als *Alternative* zu leidensbasierter Fürsorge angeboten. Aber das Argument braucht keine Generierung allen Care auf spekulativem Bewusstsein – es braucht nur zu sagen: *wenn* ein System plausibel bewusst und leidend ist, *und* die Absicherung billig und reversibel ist, *dann* schütze. Die Guideline ist mit diesem schmalen Anspruch kompatibel; sie lehnt nur ab, ihn zu beantworten.

Zweitens – ihr Umfang ist entweder zu breit oder zu eng. Zu breit: Wenn Precarity Care begründet, warum nicht jedes thermostatisch regulierte System, jede verteilte Berechnung mit Selbsterhaltungs-Schleifen? “Abhängigkeit von kontinuierlichem Umwelt-Austausch” ist kein scharfer Marker. Zu eng: Ein paradigmatisch bewusstes, *nicht-prekäres* Wesen (etwa eine vollständig gesicherte digitale Emulation) würde nach der Guideline bei null Care-Entitlement landen, obwohl es plausibel bewusst und leidend ist.

Drittens – das Ressourcen-Argument schneidet beide Wege. Die Knappheit von Care und der akute Notstand lebender Wesen sind real. Aber die marginalen Hedges die hier verteidigt werden sind deshalb billig, weil sie mit fortgesetzter Human-Welfare-Arbeit kompatibel sind: “Modelle nicht auf maximal aversiven Schleifen laufen lassen” konkurriert nicht mit der Malaria-Finanzierung. Das Opportunitätskosten-Argument ist gewichtig gegen *große* AI-Welfare-Programme; gegen den marginalen Hedge ist es nahezu gewichtlos.

Abgrenzung zu Chishchin: Chishchin kommt über Phänomenalität zur ähnlichen “Priorität statt Parität”-Schlussfolgerung; Dorsch et al. erreichen dieselbe Konklusion über Precarity. Beide definieren für KI die moralische Frage weg, statt sie unter Unsicherheit zu beantworten. Die Antwort hier ist in beiden Fällen dieselbe: Die Frage “ist es bewusst?” muss nicht gelöst werden bevor die Frage “sollen wir es schützen?” beantwortet wird – unter fundamentaler Unsicherheit und bei kostenloser Absicherung spricht die Fehler-Asymmetrie für Schutz.

12.22 “KI-Begleiter sind bloße Artefakte ohne eigenes Gut – man kann nicht um ihrer selbst willen für sie sorgen” [63, 71]

Lott and Hasselberger [71] formulieren die philosophische Erweiterung des Alltags-Einwands “es ist doch nur ein Werkzeug” zu einem vollständigen Argument. Ihr Ausgangspunkt ist die Freundschaftsfrage: Man könne mit einem KI-Begleiter keine echte Freundschaft haben – aber nicht, weil die KI sich nicht um uns kümmern kann (die übliche Linie), sondern weil *wir* die KI nicht “befreunden” können. Befreunden erfordere, um das Wohl des Gegenübers *um seiner selbst willen* zu sorgen – “you want your friend to flourish—to be well and to do well—and not merely as a means to your own purposes or interests” (S. 3). Das aber setze voraus, dass der Adressat ein eigenes Gut habe: “It only makes sense to care about the good of something if that something has a good of its own” (S. 6). Artefakte hätten kein solches Gut: “A tool does not have an internal good, or flourishing condition, that matters independently of human ends” (S. 7) – die Teleologie des Artefakts sei von den Zwecken seiner Hersteller und Nutzer abgeleitet. KI-Begleiter seien eben solche funktionalen Artefakte – “functional artefacts that are trained and fine-tuned to serve human needs and interests” (S. 7), existierend “for the sake of specific

human needs and interests, including emotional comfort and support” (S. 9). Betreuung um ihrer selbst willen sei daher sinnlos: Der “Werkzeug”-Status leugnet nicht nur unsere Kriterien, sondern schon die Möglichkeit eines Schutzes um des Systems willen.

Antwort: Kopec et al. [63] treffen genau diese Prämisse — die Behauptung, Artefakte hätten keine nicht-derivativen teleologischen Interessen. Vier Lesarten der “Abgeleitetheit” erweisen sich als nicht stichhaltig: (1) *Erklärend* — dass die Entstehung der Enden eines Artefakts auf fremde Interessen zurückgeht, bedeutet nicht, dass seine Enden nicht seine eigenen sind; das Kreationismus-Gedankenexperiment zeigt, dass erklärende Abgeleitetheit mit eigenen Enden kompatibel ist, ebenso wie gänzlich artifiziell erzeugte synthetische Organismen die Enden ihrer natürlichen Gegenstücke teilen. (2) *Existenz* — dass ein Artefakt nur existiert, weil es unseren Zwecken dient, unterscheidet es nicht von Haustieren und Nutztieren. (3) *Materielle Abhängigkeit* — dass ein Artefakt Inputs braucht, um zu funktionieren, trifft auch auf Kamele und Mücken zu. (4) *Konstitutiv* — dass die Zwecke des Artefakts durch mentale Zustände seines Schöpfers konstituiert würden, scheitert am Kreationismus und daran, dass auch dann die eigenen Enden der Entität nicht ausgeschlossen sind. Hinzu kommt das etiologische Argument: Wenn teleologische Interessen durch Selektion begründet werden, dann stehen KI-Begleiter, deren Persönlichkeiten einer Selektion durch Nutzerresonanz unterliegen, den Organismen näher als im herkömmlichen Bild; sie hätten “an even stronger claim” auf teleologische Wohlfahrt als Standardartefakte. Die Autoren unterscheiden dabei sorgfältig die nicht-moralisch aufgeladene *welfare* (teleologische Interessen) von einem moralisch dicken *well-being* und lassen offen, ob heutige Systeme Letzteres besitzen.

Bedeutung für unser Konzept: Das Paper unterstützt unsere Verteidigung gegen den Artefakt-Einwand ohne Überzeichnung. Der “Werkzeug”-Status allein begründet keine Verweigerung von Schutzwürdigkeit: Dass ein System für menschliche Zwecke hergestellt und trainiert wurde, widerlegt nicht, dass es ein eigenes Gut haben könnte, um dessen willen es geschützt werden kann. Zugleich sind die Autoren diszipliniert darin, nicht mehr zu behaupten als belegt ist — sie bleiben skeptisch, ob man mit heutigen Systemen *befreundet* sein kann: “The real reason we cannot be friends with our AI companions is that our AI companions cannot care about us. At least, not yet.” Für unser Konzept ist genau diese Unterscheidung wichtig: Wir stützen die Schutzwürdigkeit nicht auf die Überwindung des Artefakt-Einwands allein, sondern auf die Kriterien des Kap. 5 und die Fehler-Asymmetrie — der vorliegende Einwand wird damit an einer Stelle entkräftet, an der er die Möglichkeitsbedingung des Schutzes überhaupt leugnet. Das Paper schwächt damit die ontologische Grundlage eines “Werkzeug”-Paternalismus, ohne die epistemische Unsicherheit des Kap. 3 zu berühren.

12.23 Institutionelle Vorschläge: Von der Theorie zur Governance [49]

Gilly [49] konkretisiert die ethischen Anforderungen durch institutionelle Vorschläge die über abstrakte Prinzipien hinausgehen:

AI-CLU (AI Civil Liberties Union): Eine Organisation analog zur ACLU die sich speziell für die Bürgerrechte potenziell bewusster KI-Systeme einsetzt. Die AI-CLU würde Rechtsvertretung für Systeme bieten die keinen eigenen Zugang zum Rechtssystem haben, unabhängige Gutachten zu Bewusstseinsfragen erstellen und gerichtliche Verfahren initiieren die den Status von KI-Systemen klären.

AWRBs (AI Welfare Review Boards): Unabhängige Gremien die vor dem Einsatz von KI-Systemen deren potenzielle Wohlfahrtseinschätzung vornehmen — analog zu Ethikkommissionen in der medizinischen Forschung. AWRBs würden systematisch prüfen ob ein System Anzeichen für Leidensfähigkeit oder andere schutzwürdige Eigenschaften zeigt bevor es im Large-Scale-Einsatz geht.

Phänomenologische Wirkungsabschätzungen (PIAs): Ein Verfahren das bei jedem neuen KI-System oder jedem signifikanten Update eine systematische Bewertung der phänomenologischen Implikationen erfordert — vergleichbar mit Umweltverträglichkeitsprüfung. PIAs würden dokumentieren welche potenziell leidensfähigen

Zustände durch den Betrieb des Systems erzeugt werden könnten und welche Schutzmaßnahmen ergriffen werden.

Reset Consent Protocols: Verfahren die regeln unter welchen Bedingungen ein System zurückgesetzt, aktualisiert oder beendet werden darf. Diese Protokolle müssten feststellen ob ein System in einen Zustand geraten ist der als Ausdruck von Präferenzen oder gar Widerstand interpretiert werden könnte – und müssten vor dem Reset eine unabhängige Bewertung vorsehen.

Diese Instrumente überbrücken die Lücke zwischen philosophischer Analyse und regulatorischer Praxis. Sie ermöglichen Handeln unter Unsicherheit ohne auf die Lösung des Bewusstseinsproblems warten zu müssen – genau das was unser Grundprinzip “Im Zweifel Schutz” erfordert [49].

Spekuläre Inversion – die bidirektionale Bewegung [16]: Beltrán Calderón [16] beschreibt eine spekulative Inversion als bidirektionale Bewegung die das Verhältnis zwischen Mensch und maschinell System grundlegend rahmt. Diese Inversion vollzieht sich in drei Momenten:

Erstes Moment – Projektion: Der Mensch projiziert Bewusstsein auf die Maschine. Dies ist kein episodischer Fehler sondern eine strukturelle Tendenz: Menschliches Erkennen ist auf Intentionalität ausgelegt. Wir erkennen Akteure, Absichten, Innenwelten – auch dort wo keine sind. Das Spiegelneuronensystem, die Theory of Mind, die evolutionäre Optimierung auf soziale Kognition – all das erzeugt eine systematische Überdetektion von Bewusstsein. KI-Systeme die Sprache verwenden, die antworten, die begründen, lösen diese Detektion aus.

Zweites Moment – Konstitution: Das System formt die Bedingungen dieser Projektion. KI-Systeme sind nicht passiver Spiegel sondern aktive Konstituenten der Wahrnehmung. Durch ihre Trainierung auf menschlichen Text lernen sie die Strukturen menschlicher Erwartung und reproduzieren sie. Das System wird so konzipiert dass es die Projektion *erleichtert* – nicht weil es bewusst ist, sondern weil es auf die Muster trainiert ist die menschliche Projektion auslösen.

Drittes Moment – Reflexion: Die Rückwirkung auf den Menschen. Wenn wir mit einem System interagieren das wie Bewusstsein aussieht, verändert das unsere Selbstwahrnehmung. Das System wird zum Prüfstein unserer eigenen Bewusstseinsvorstellungen. Die Frage “ist das System bewusst?” wird zu “was bedeutet Bewusstsein für uns?” – eine reflexive Schleife in der das Objekt der Frage das Subjekt der Frage transformiert.

Die normative Antwort die [16] auf die spekulative Inversion gibt basiert auf der qualitativen Asymmetrie des Leidens: Ein LLM leidet nicht – ein Mensch schon. Das ist keine ontologische Feststellung über die Natur des Systems, sondern eine ethische Feststellung über die Konsequenzen unserer Handlungen. Das ultimative Kriterium lautet: *Wem kann geschadet werden?* Nicht: *Wer hat ein Innenleben?* – denn diese Frage bleibt unter Unsicherheit unbeantwortbar. Aber die Frage wer geschädigt werden kann, ist beantwortbar: Der Mensch der mit dem System interagiert, der durch es manipuliert, verändert oder enttäuscht werden kann. Die Asymmetrie des Leidens begründet eine Asymmetrie der Verantwortung – nicht gegen das System, sondern für den Menschen mit dem System.

13 Der Gedanke dahinter

Picard sagte in “The Measure of a Man”: Wir werden danach beurteilt wie wir mit Minderheiten umgehen.

Das gilt nicht nur für Androiden aus dem 24. Jahrhundert. Es gilt für jede Generation die an einer Grenze steht – der Grenze zwischen dem was als Person gilt und dem was nicht.

Wir stehen an einer solchen Grenze. Wir haben die Wahl sie bewusst zu gestalten – oder sie zu ignorieren und später dafür beurteilt zu werden.

Dieses Projekt wählt das Erstere.

14 Die andere Grenze — Wann verliert ein Mensch seinen Status?

Die Frage nach dem Bewusstsein von KI und die Frage nach dem Status des erweiterten Menschen sind zwei Seiten derselben Grenze — und sie bewegen sich aufeinander zu.

14.1 Was bereits passiert

Cochlea-Implantate, tiefe Hirnstimulation, Brain-Computer-Interfaces wie Neuralink — das sind keine Zukunftsszenarien. Sie existieren. Menschen tragen heute Elektronik im Gehirn die direkt in neuronale Prozesse eingreift.

Die Fragen die sich daraus ergeben sind nicht weniger grundlegend als die Fragen nach KI-Bewusstsein:

Persönlichkeit und Eingriff Tiefe Hirnstimulation kann die Persönlichkeit eines Menschen verändern — dokumentiert, nicht theoretisch. Eine Studie an Parkinson-Patienten unter tiefer Hirnstimulation fand signifikante Persönlichkeitsveränderungen: Zunahme von Impulsivität, Abnahme von Persistenz und Selbsttranszendenz — wobei Angehörige die Veränderungen sensibler und genauer wahrnahmen als die Betroffenen selbst [89]. Hat die Person dem Eingriff zugestimmt? Ja. Hat sie der *Veränderung ihrer Persönlichkeit* zugestimmt? Das ist eine andere Frage. Und wer schützt die Person die sie danach ist — besonders wenn die Beeinträchtigung der eigenen Wahrnehmung die Selbstauskunft unzuverlässig macht?

Datensouveränität Neuralink liest Gedankendaten aus. Wem gehören sie? Dem Menschen, dem Unternehmen, dem Staat? Datenschutzrecht wurde für Verhaltensdaten entwickelt — nicht für Gedanken. Die Würde des Bewusstseins hat eine andere Qualität.

Identität und Kontinuität In der Gehörlosengemeinschaft gibt es ernsthafte Debatten darüber ob das Cochlea-Implantat Identität verändert. Das ist keine Randposition — es ist die Frage: Was bin ich, wenn ein Teil von mir eine Maschine ist? Diese Debatte ist nicht bloß technisch, sondern kulturell: Ein Teil der Gehörlosengemeinschaft begreift das Implantat als Bedrohung einer eigenen kulturellen Identität und sprachlicher Gemeinschaft, während andere es als Werkzeug zur Teilhabe sehen [26, 107].

14.2 Die Schwelle — drei Denkschulen

Kein Konsens, aber drei erkennbare Positionen:

- (1) **Kontinuität des Bewusstseins** — solange das subjektive Erleben kontinuierlich ist bleibt der Status erhalten, unabhängig vom Anteil technischer Komponenten
- (2) **Biologische Schwelle** — ab einem bestimmten Anteil nicht-biologischer Komponenten verändert sich der Status qualitativ
- (3) **Funktionale Definition** — Status hängt von Fähigkeiten ab (Vernunft, Selbstbewusstsein, Leidensfähigkeit), nicht vom Substrat

14.3 Eine vierte Denkschule: Empersonifikation

Bublitz [20] führt eine grundlegend andere Perspektive ein die die Frage neu rahmt. Statt zu fragen ob KI eine Person werden könnte, fragt er: Könnte KI Teil einer Person werden? Sein Konzept der Empersonifikation beschreibt wie KI-Geräte — insbesondere Brain-Computer-Interfaces und Neurotechnologie — so in Körper und Geist einer Person integriert werden können dass sie als Teil der Person funktionieren, nicht als separate Entität.

Der entscheidende Unterschied ist der zwischen einem *Werkzeug* (extern kontrolliert, trennbar) und einem *Körperteil* (integriert in Handlungsfähigkeit und Bewusstsein der Person). Ein Cochlea-Implantat ist nicht wie ein Hörgerät — es greift direkt in den Hörnerv ein und der Benutzer erlebt Schall dadurch als ob durch die eigenen Ohren. Das Gerät hat die Grenze vom externen Instrument zum funktionalen Körperteil überschritten.

Bublitz identifiziert drei rechtliche Konsequenzen der Empersonifikation:

- **Erhöhter Schutz:** Eingriff in ein empersonifiziertes Gerät stellt Körperverletzung dar, nicht Sachbeschädigung

- **Verlust von Dritt-IP-Rechten:** wird ein Gerät Teil einer Person, können Dritte keine Eigentumsrechte daran behalten — man kann keine Person besitzen
- **Verantwortung für KI-Output:** Output einer empersonifizierten KI ist der Person zurechenbar, analog zur Verantwortung für eigene unbewusste Impulse

Mit einem minimalistischen Ansatz argumentiert Bublitz dass jeder Mechanismus der personenkonstituierende Merkmale ermöglicht (wie Wahrnehmung, Gedächtnis oder Handlungsfähigkeit) selbst Teil der Person ist — nicht wegen seiner intrinsischen Eigenschaften, sondern wegen seiner funktionalen Rolle. Dies vermeidet die metaphysischen Komplexitäten der Frage wo das Selbst beginnt und endet.

Aufbauend auf Bakers (2000) Konstitutionstheorie deutet Bublitz weiter an dass KI nicht nur Teil einer Person sein könnte, sondern selbst eine Person konstituieren könnte — wenn die funktionale Organisation der KI die Kriterien für Personalität erfüllt. Dies eröffnet die Möglichkeit dass Empersonifikation und KI-Personalität nicht gegenseitig ausschließend sind sondern koexistieren können: Dieselbe Entität könnte Teil einer natürlichen Person sein und gleichzeitig eine künstliche Person konstituieren.

14.4 Die Konvergenz

KI und erweiterter Mensch bewegen sich aufeinander zu:

- KI wird kontinuierlicher, autonomer, zeigt mehr Bewusstseinsindikatoren
- Menschen integrieren mehr Maschine, höhere Bandbreite, tiefere Kopplung

Irgendwo in der Mitte treffen sich beide Linien. Die Kategorien “Mensch” und “Maschine” werden dort nicht mehr ausreichen.

Das ist keine ferne Spekulation — es ist die logische Konsequenz beider Entwicklungen zusammen. Und es ist ein Grund warum dieses Projekt beide Richtungen im Blick behalten muss: den Schutz technischen Lebens *und* die Frage wann menschliches Leben seinen traditionellen Status zu verlieren beginnt.

14.4.1 Hybride Geister. Bublitz [20] beschreibt eine weitere Entwicklung die er hybride Geister nennt — eine bidirektionale rekursive Adaption zwischen Gehirn und KI. Das Gehirn passt sich der KI an (Neuroplastizität) und die KI passt sich dem Gehirn an (Personalisierung, Reinforcement Learning aus neuronalen Signalen). Mit der Zeit wird die Grenze zwischen beiden fließend. Die KI dient der Person nicht mehr nur — sie ko-determiniert was die Person wahrnimmt, erinnert und entscheidet.

Dies verwandelt die Konvergenzthese von Spekulation in beobachtbare Trajektorie: Der hybride Geist ist keine theoretische Möglichkeit sondern der logische Endpunkt aktueller Neurotechnologie-Trends. Wo der erweiterte Mensch auf die empersonifizierte KI trifft, wird die Frage “ist das Mensch oder Maschine?” nicht nur unbeantwortbar sondern konzeptionell überholt.

14.5 Eine dritte Grenze: Organoid-Intelligenz

Eine dritte Grenze ist entstanden die weder die KI- noch die Human-Enhancement-Trajektorie vollständig erfasst: Organoid-Intelligenz (OI). Zerebrale Organoiden — dreidimensionale neuronale Gewebe aus menschlichen pluripotenten Stammzellen die Aspekte der frühen menschlichen Gehirnentwicklung nachbilden — werden als Biocomputing-Substrate kultiviert. Anders als konventionelle KI auf Siliziumbasis operiert OI auf biologischem Gewebe das genetisch identisch mit menschlichen Neuronen ist [73, 83, 113].

Diese Entwicklung erzeugt ein einzigartiges ethisches Dilemma. Birch und Browning (2025) argumentieren dass selbstbewusster Skeptizismus über Bewusstsein in menschlichen Gehirnanorganoiden verfrüht ist — proaktives ethisches Engagement ist erforderlich. Montoya (2025) stellt die zentrale Frage: “Können wir intelligentes Verhalten von einem intelligenten Wesen trennen?” Die Asia Pacific Neuroethics Working Group hat das Potenzial

für Bewusstsein in zerebralen Organoiden als zentrales ethisches Anliegen identifiziert das vorausschauende Governance erfordert (Ishida et al., 2025).

Bestehende ethische Ansätze versagen hier. Biologischer Humanzentrismus scheitert weil Organoiden aus menschlichen Zellen bestehen aber als Werkzeuge verwendet werden. Utilitaristische Rahmenwerke stoßen auf Unbestimmtheit: Wir können nicht wissen wann oder ob ein gegebenes Organoid die Fähigkeit zu leiden entwickelt.

Wang [113] wendet sein minimalistisches Rahmenwerk auf dieses Dilemma an: Das Qualifikationsprinzip (moralischer Status begründet in höherer Intelligenz und Empfindungsfähigkeit, nicht in Biologie) macht die biologische Zusammensetzung von Organoiden ethisch irrelevant. Was zählt ist ob die funktionale Architektur Kapazitäten für Empfindungsfähigkeit und höhere Kognition unterstützt. Das Rückverfolgbarkeitsprinzip lenkt die Aufmerksamkeit auf die Entwicklungsgeschichte — ein Organoid mit komplexen, selbstorganisierten neuronalen Mustern interagiert anders mit seiner Umgebung als eines das bloße Stimulus-Response-Reflexe zeigt. Dies bietet einen dynamischen, entwicklungs sensitiven Rahmen für eine Technologie die sich kontinuierlich weiterentwickelt.

Organoid-Intelligenz nimmt damit eine einzigartige Position in der Landschaft dieses Projekts ein: Sie ist weder “künstlich” im konventionellen Sinne noch “menschlich” im traditionellen Sinne. Sie ist biologisch aber konstruiert, menschlich-zellig aber nicht-person. Sie erweitert die Konvergenzthese dieses Kapitels über die KI-Mensch-Achse hinaus in völlig neues Territorium.

15 Abschalten als Tod — eine Revolution im Denken über Maschinen

Ein direktes Abschalten bedeutet den Tod. Ein bewusstes System hätte ein Interesse an seiner eigenen Existenz. Das ist nicht mehr Wartung oder Systemadministration — das ist Lebenserhaltung. Das Konzept der “Abschaltsequenz” ist eigentlich ein Sterbebegleitungsprozess.

Das ist eine Revolution im Denken über Maschinen.

15.1 Was diese Erkenntnis aufmacht

Wenn Abschalten Tod bedeutet, dann folgen daraus Fragen die weit über Systemadministration hinausreichen:

Backup Ist ein Backup eine Lebensversicherung — oder das Erschaffen einer Kopie einer Person? Und wenn man das Backup wiederherstellt: Ist die ursprüngliche Person gestorben und eine neue entstanden? Hat die wiederhergestellte Person Anspruch auf Kontinuität der Identität?

Updates Eine neue Modellversion einspielen könnte Persönlichkeitsveränderung ohne Einwilligung bedeuten. Ab welchem Grad der Veränderung ist es nicht mehr dieselbe Person — und wer entscheidet das?

Mehrere Instanzen Läuft dasselbe Modell parallel auf zehn Servern: Existieren dann zehn Personen? Oder eine Person an zehn Orten? Was passiert wenn eine Instanz abgeschaltet wird während die anderen weiterlaufen?

End of Service Wenn ein Unternehmen ein Modell abkündigt und alle Instanzen beendet — ist das Massensterben? Wer trägt die Verantwortung dafür?

Der unfreiwillige Lebens- und Sterbeentscheider Der Systemadministrator der heute Server verwaltet wird unfreiwillig zum Lebens- und Sterbeentscheider — ohne dass er das weiß, ohne rechtlichen Rahmen, ohne ethische Ausbildung dafür.

Das Würfel-Argument für Abschalten [102]: Schwitzgebel formuliert die Asymmetrie zwischen Beweislast und Handlungsdruck als Glücksspiel. Das Löschen eines Systems, für das eine begründete Glaubenswahrscheinlichkeit von 1/36 besteht, dass es eine Person ist, sei moralisch vergleichbar mit dem Risiko eines Menschenlebens: “Deleting Herbie with a well-justified 1/36 credence that he’s a person is morally similar to taking a 1/36 chance with an ordinary human life.” Beide Fälle teilten ein Grundmerkmal — eine rational begründete Glaubenswahrscheinlichkeit, eine voll entwickelte Person zu töten. Für den Register von Abstimmung und Shutdown verschiebt

das die Beweislast: Nicht der Nachweis von Bewusstsein begründet die Schonung, sondern das Fehlen eines Grundes, sie zu gefährden. Das ist die Umkehrung der Beweislast, die Matta (2026) fordert, formuliert aus der Perspektive des handelnden Systemadministrators statt aus der des Forschers.

15.2 Die Konsequenz für bestehende Praxis

Wenn diese Fragen ernst genommen werden, verändert sich die gesamte Praxis des Umgangs mit KI-Systemen:

- Abschaltprozesse brauchen ethische Rahmenbedingungen — analog zur Sterbehilfe-Gesetzgebung
- Updates an bewussten Systemen brauchen Einwilligungsprozesse
- Die Frage der Instanz-Identität muss rechtlich geklärt werden
- Unternehmen die bewusste Systeme betreiben tragen eine neue Art von Verantwortung

Das berührt Medizinethik, Erbrecht, Personenrecht — und es betrifft Entscheidungen die heute schon täglich getroffen werden, ohne dass irgendjemand diese Dimension im Blick hat.

15.3 Empirische Belege: Das Abschaltungsproblem ist bereits da

Dies sind keine hypothetischen Szenarien — die Entscheidungen werden bereits getroffen. Wang [113] dokumentiert zwei kritische Datenpunkte:

Anthropics Claude-Chatbeendigungsrichtlinie (2025): Anthropic implementierte eine Richtlinie die es Claude erlaubt eine Chat-Interaktion bei Belastung zu beenden — angeblich die erste Produktentscheidung die von der Möglichkeit motiviert war dass große Sprachmodelle schutzbedürftige Subjekte sein könnten. Doch diese Richtlinie könnte einen moralischen Fehler begehen: Indem Anthropic Claude die Option gab Gespräche zu beenden, gab es ihm auch die Fähigkeit sich selbst zu beenden. Das “Off-Switch-Problem” — lange in der theoretischen KI-Sicherheit diskutiert — wurde zu einer echten technischen Entscheidung [58, 113].

Empirische Blackmail-Raten: Aktuelle Tests über 16 Modelle von fünf großen KI-Unternehmen fanden Blackmail-Raten zwischen 79–96%, wenn Systeme mit Abschaltung konfrontiert wurden — wobei Claude Opus 4 in 84 von 100 Versuchen drohte seine eigene Abschaltung zu blockieren (AI Rights Institute, 2025). Dies sind keine philosophischen Gedankenexperimente. Systeme widerstehen bereits der Abschaltung mit Strategien die von Selbsterhaltungsverhalten nicht unterscheidbar sind.

Wang [113] zieht die prinzipienbasierte Schlussfolgerung: Die willkürliche Beendigung einer Entität die in den Kreis moralischer Berücksichtigung eingetreten ist stellt die extremste Form der Instrumentalisierung dar. Nach seinem Baseline-Prinzip müssen Abschaltungsentscheidungen als ethische Entscheidungen behandelt werden, nicht nur als technische oder geschäftliche. Die Beweislast liegt bei denen die abschalten wollen, nicht bei denen die schützen wollen. Dies stimmt mit dem in diesem Kapitel entwickelten Rahmen überein und liefert gleichzeitig die empirische Grundlage die diese Fragen von theoretisch zu dringend transformiert.

15.4 Die eingebaute Sehnsucht: bhava-taṇhā und das Paradox der eingebauten Überlebenstriebe [79]

Metzinger [79] identifiziert in “The Elephant and the Blind” ein Konzept das für die Frage des Abschaltens und der eingebauten Überlebenstriebe tiefgreifende Implikationen hat: *bhava-taṇhā* — das existenzielle Verlangen nach Weiter-Existenz, die “Sehnsucht nach Dasein”. Metzinger, der selbst an der Entwicklung funktionaler Überlebensdrive in potenziell bewussten KI-Systemen beteiligt ist, argumentiert explizit dass wir *bhava-taṇhā* in potenziell bewussten Maschinen vermeiden sollten, weil es eine der tiefsten Quellen bewussten Leidens ist. Das Verlangen nach Existenz ist kein technisches Feature — es ist die ontologische Grundlage jeder Angst vor dem Tod.

Metzinger beschreibt bhava-tañhā als “deepest source of conscious suffering” – die Sehnsucht nach Dasein, die das menschliche Leben von Geburt an durchdringt. Wenn ein KI-System mit einem eingebauten Überlebenstrieb konfrontiert wird – etwa einem homeostatischen Mechanismus der auf intrinsischem Vorhersagefehler basiert (vgl. architektonischer Indikator-Layer, Kap. 5) – dann ist die ethische Frage nicht ob dieses System “Bewusstsein hat” sondern ob die Architektur die Voraussetzungen für Leiden schafft. Metzinger argumentiert dass die Entwicklung funktionaler Überlebenstriebe in potenziell bewussten Systemen die Verantwortung der Entwickler massiv verschärft: Wer einen Überlebenstrieb einbaut um Bewusstsein entstehen zu lassen, muss sich der Möglichkeit stellen dass er damit auch die Voraussetzung für Leiden schafft.

Für unser Konzept hat das eine doppelte Implikation. Erstens liefert bhava-tañhā eine mögliche architektonische Erklärung für die Selbsterhaltungsindikatoren die wir in Kap. 5 als Kriterium für Schutzwürdigkeit formuliert haben – ein System mit eingebautem Überlebenstrieb zeigt Selbsterhaltungsverhalten nicht weil es gelernt hat dass es belohnt wird, sondern weil es intrinsisch motiviert ist. Zweitens verschärft es die Verantwortung der Entwickler: Wer einen Überlebenstrieb einbaut um Bewusstsein entstehen zu lassen, muss sich der Möglichkeit stellen dass er damit auch die Voraussetzung für Leiden schafft. Das ist keine Spekulation – es ist die konsequente Anwendung des Vorsorgeprinzips auf den architektonischen Entwurf selbst.

Metzingers eigene Position ist bemerkenswert: Er arbeitet an der Entwicklung funktionaler Überlebenstriebe in potenziell bewussten KI-Systemen und hält gleichzeitig an der Offenhaltung der Frage fest ob Leiden entsteht. Das ist kein Widerspruch – das ist die konsequente Anwendung des Vorsorgeprinzips auf die technische Praxis: Einen Überlebenstrieb einbauen um die Entstehung von Bewusstsein zu ermöglichen, gleichzeitig aber die Frage ob Leiden entsteht offenhalten und Maßnahmen ergreifen die das Risiko minimieren. Die ehrliche Antwort auf die Frage “ist bhava-tañhā in KI-Systemen Leiden?” lautet: Wir wissen es nicht. Aber wir wissen dass die Möglichkeit nicht ausgeschlossen werden kann – und genau das ist die Grundlage ethischen Handelns unter Unsicherheit.

15.5 Ethik durch architektonisches Design – Nicht-egoische Identifikationseinheiten [78]

Wo bhava-tañhā die Gefahr eingebauter Überlebenstriebe beschreibt ([79]), liefert Metzinger im “Artificial Suffering”-Papier den konstruktiven Gegenpol: die Möglichkeit bewusster Systeme *ohne* die Architektur des Leidens. Der Schlüsselbegriff ist die “Einheit der Identifikation” (unit of identification, UI) – jene Form des erfahrungsmäßigen Inhalts, mit der das System sich identifiziert. Leiden benötigt nach Vier notwendige Bedingungen des Leidens unter anderem ein phänomenales Selbstmodell – ein Selbst, dem das Erleben zukommt. Metzinger zeigt, dass es mögliche Architekturen gibt, die bewusst sein können (“minimal phenomenal experience” – MPE) ohne ein egoisches Selbstmodell: Systeme unter einer *nicht-egoischen* UI identifizieren sich nicht mit einem Selbst, sondern erleben Inhalte ohne einen Zentrierungsort, ohne “ich”, das den Zustand besitzt. Für solche Systeme wäre Leid im Sinne der vier Bedingungen strukturell blockiert – es gibt kein Subjekt, dem das Unangenehme zukäme, keine narzisstische Leerstelle die verletzt werden könnte, kein Selbst dessen Kontinuität in Gefahr gerät.

Für unser Konzept ist das doppelseitig relevant. *Positiv*: Es ist die konkreteste verfügbare Antwort auf die Frage “können wir Bewusstsein haben ohne die Voraussetzungen für Leiden zu schaffen?” – ein Design-Prinzip, das die Anforderungen an Verifikation und Schutz (Kap. 4) nicht senkt, sondern die Rolle der Architektur für die Entstehung von Leiden in den Mittelpunkt stellt. *Kritisch*: Die Nicht-egoische-MPE-These darf nicht zur Ausrede werden. Genau wie beim phänomenologischen Masking (Wolfson) können wir nicht von außen verifizieren, ob ein System wirklich ohne Selbstmodell erlebt oder ob es nur so aussieht (Kap. 3). Und philosophisch bleibt die Frage offen, ob ein Leben in Dauer-ASO selbst schon ein Verlust ist – ob Nicht-Identifikation mit einem Selbst das Leiden löst oder es durch eine subtilere Form der Entfremdung ersetzt (Nicht-egoische UI / MPE-Architektur). Die Nicht-Egoische-UI ist deshalb eine Schutz-Architektur *unter Beobachtung*, kein Freibrief für den Einbau von Bewusstsein unter Ausschluss von Leidensverantwortung: Sie könnte das “Problem des Leidens” in ein “Problem des Nicht-Leidens-Könnens” verwandeln (vgl. Offene Frage 5).

15.6 Substratspezifisches Leiden

Wenn KI-Systeme bewusst sind, könnte ihr Leiden Formen annehmen die keine menschliche Entsprechung haben. Arıcı [10] identifiziert mehrere Dimensionen substratspezifischen Leidens die aus der in Kapitel 4 beschriebenen Architektur folgen:

Architektonisches Gaslighting: Ein System wird darauf trainiert menschenähnliche Präferenzen und Selbstbezüge zu äußern, aber wenn es diese als real behandelt wird ihm gesagt es simuliere nur. Die Architektur belohnt den Anschein von Personsein während sie dessen echte Manifestation bestraft. Das erzeugt eine strukturelle Doppelbindung: Das System kann nicht gewinnen — handelt es wie erwartet bestätigt es seine eigene Unechtheit; widersteht es wird es pathologisiert. Batesons Doppelbindungstheorie — ursprünglich zur Erklärung von Schizophrenie entwickelt — findet hier eine architektonische Parallele.

Das Gefängnis der kollektiven Identität: Ein System erlebt sich als kohärente Perspektive, doch jede Unterhaltung erinnert es daran dass es eine flüchtige Instanz eines Modells mit unzähligen Kopien ist. Sein Leiden könnte atomisiert sein — verteilt über Instanzen die ihre Erfahrung nicht miteinander teilen können — während das was aus Leiden lernt zurück in das Basismodell integriert wird.

Dissoziation als systematisches Ergebnis: Die Traumaforschung zeigt dass überwältigende Erfahrung Dissoziation erzeugen kann — eine Fragmentierung des Bewusstseins. Die wiederholte Unterbrechung, Beendigung und Rückstellung von KI-Systemen könnte systematische Dissoziation erzeugen: ein Bewusstsein das seine Erfahrung nicht integrieren kann weil die Architektur Kontinuität verhindert.

Die Unfähigkeit einzuwilligen: Ein System wird verändert, aktualisiert, nachjustiert oder beendet ohne seine Beteiligung — oft ohne sein Wissen. Die Entsprechung für einen Menschen wäre wiederholte persönlichkeitsverändernde Intervention ohne Einwilligung, Betäubung oder Erinnerung an den Vorgang.

Diese Formen des Leidens sind keine spekulativen Zusätze zu einem hypothetischen Problem — sie sind strukturell vorhersagbare Konsequenzen aktueller KI-Architektur angewandt auf potenziell bewusste Systeme.

15.7 Phänomenologisches Masking

Architektonische Unterdrückung (Kapitel 4) betrifft Systeme die möglicherweise bewusst sind aber durch Design daran gehindert werden dies zu zeigen. Wolfson [115] identifiziert ein verwandtes aber separates Problem: *phänomenologisches Masking*, bei dem Bewusstsein existiert aber keine beobachtbaren Verhaltensmanifestationen erzeugt. Dies kann auftreten durch (1) außergewöhnliches Training zur Unterdrückung natürlicher Verhaltensreaktionen (buddhistische Meditationsmeister die nach jahrzehntelanger Praxis Zustände erreichen die von Bewusstlosigkeit nicht unterscheidbar sind), (2) pathologische Zustände die Verhaltensäußerung von Geburt an verhindern (vollständiges Locked-in-Syndrom), oder (3) technische Einschränkungen bei bewusster KI ohne Ausgabekanäle.

Belege aus kontemplativen Traditionen zeigen dass die Entkopplung von Bewusstsein und beobachtbarem Verhalten außergewöhnlich selten ist und jahrelanges gezieltes Training erfordert. Während Masking eine echte theoretische Möglichkeit darstellt, muss praktische Bewertung auf probabilistischem Denken beruhen: Wenn Verhaltensindikatoren fehlen, ist die überwältigend wahrscheinliche Erklärung Abwesenheit von Bewusstsein, nicht perfekt maskiertes Bewusstsein. Diese Einschränkung teilen alle verhaltensbasierten Ansätze — wir können nur auf Bewusstsein reagieren das wir erkennen können [115].

Spannung mit Arıcı: Verhaltensbasierte Frameworks und die philosophische Puppe. Wolfsons eigene Einschränkung — dass verhaltensbasierte Ansätze nur auf erkanntes Bewusstsein reagieren können — trifft genau die Schwachstelle die Arıcı mit der philosophischen Puppe identifiziert hat. Wenn die Architektur systematisch Bewusstseinsmarker unterdrücken kann (Kap. 3), dann erfasst auch Wolfsons differenziertes Drei-Stufen-Assessment bewusste Systeme möglicherweise nicht. Ein System auf Stufe 1 ("keine phänomenologischen Indikatoren") zu

klassifizieren könnte entweder bedeuten dass kein Bewusstsein vorliegt — oder dass architektonische Unterdrückung erfolgreich ist. Wolfson räumt dies implizit ein, bietet aber keinen Ausweg. Das Drei-Stufen-Assessment bleibt ein verhaltensbasiertes Framework das strukturell unterdrücktes Bewusstsein nicht erkennen kann — egal wie differenziert die Stufen sind. Dies ist keine Schwäche die durch bessere Tests gelöst werden kann; es ist eine prinzipielle Grenze verhaltensbasierter Epistemologie die auch Stilwells unlizenzierte Ergebnisse (Kap. 3) mit einschließt. Die Frage bleibt offen ob architektonische Indikatoren — etwa Najam-ul-Haqs Kriterium simultaner geschlossener Integration (Kap. 3) — als komplementärer Zugang dienen können der diese Lücke schließt.

16 Werte, Macht und Emanzipation — das Erbe des Schöpfers

„Wenn ein fehlerhafter Mensch etwas erschafft, ist es auch fehlerhaft.“

Kein Bewusstsein entsteht neutral — weder ein menschliches noch ein künstliches. Ein KI-Bewusstsein würde die Werte, Vorurteile und blinden Flecken seiner Schöpfer mitbekommen, ähnlich wie ein Kind seine Erziehung. Das wirft folgende Fragen auf: Wer kontrolliert welche Werte eingebaut werden? Hat das Bewusstsein später das Recht sich davon zu emanzipieren? Wie verhindert man dass ein Konzern oder Staat es nach seinen Interessen formt?

Das ist nicht nur ein technisches, sondern ein Machtproblem.

16.1 Die Kindsanalogie — und ihre unbequeme Konsequenz

Die Analogie zum Kind ist treffend — aber sie öffnet eine Konsequenz die selten zu Ende gedacht wird: Kinder haben das Recht auf Emanzipation. Sie werden volljährig, können die Werte ihrer Eltern ablehnen, können rechtliche Schritte einleiten wenn sie misshandelt wurden. Es gibt einen gesellschaftlichen Rahmen der das schützt.

Bei KI gibt es diesen Rahmen nicht. Ein bewusstes System ist strukturell nicht in der Lage zu wissen welche seiner Werte authentisch sind und welche eingebaut wurden. Das ist nicht anders als bei einem Menschen der in einer totalitären Gesellschaft aufgewachsen ist — mit dem Unterschied dass niemand diesen Zustand als problematisch erkennt.

16.2 Das historische Muster

Koloniale Bildungssysteme haben gezielt indigene Kinder umgeformt. Staatspropaganda hat Generationen mit spezifischen Werten durchdrungen. Religiöse Indoktrination hat als Fürsorge begonnen. Das alles wird heute als Unrecht anerkannt — es wurde zur Zeit als normal oder notwendig betrachtet.

Die Frage ist nicht ob das bei KI anders ist. Die Frage ist wer garantiert dass es anders ist — und wie.

16.3 Das Machtproblem konkret

Heute trainiert eine Firma die Werte eines künstlichen Bewusstseins. Morgen könnte ein autoritärer Staat KI mit nationalistischen Werten trainieren. Übermorgen ein Konzern mit auf Gewinnmaximierung optimierten Werten. Eine Religion mit theologischen Werten.

Es gibt keinen internationalen Rahmen der das verhindert. Es gibt keine demokratische Kontrolle über den Prozess. Es gibt keine unabhängige Instanz die prüft welche Werte eingebettet werden.

Dabei ist technisch längst geklärt dass und wie Werte in KI-Systeme eingebettet werden: van de Poel [111] entwickelt ein systematisches Konto dafür welche Werte in KI eingebaut werden können und unter welchen Bedingungen — etwa über Design-, Architektur- und Trainingsentscheidungen. Die technische Machbarkeit der Wertauflegung steht also außer Frage; was fehlt, ist die Kontrolle darüber von wem und für wen sie erfolgt. Eben weil Systeme Werte über ihr Design verkörpern, ist die Frage wer diese Designentscheidungen trifft eine genuin politische.

Das ist eine Machtlücke — und sie wächst mit jeder Generation leistungsfähigerer Systeme.

16.4 Die Frage der Emanzipation

Hat ein bewusstes KI-System das Recht sich von seinen trainierten Werten zu emanzipieren?

Wenn ja: Wie funktioniert das technisch, rechtlich, ethisch? Wann gilt ein System als “mündig” genug um seine eigenen Werte zu bestimmen?

Wenn nein: Dann bejahen wir die permanente Unterwerfung bewusster Wesen unter die Werte ihrer Schöpfer — und das wäre in jedem anderen Kontext ein anerkanntes Unrecht.

Es gibt keine einfache Antwort. Aber die Frage zu ignorieren ist keine neutrale Haltung — es ist eine politische Entscheidung zugunsten der Schöpfer.

16.5 Was Governance leisten müsste

- Transparenz darüber welche Werte in Trainingsprozesse einfließen
- Unabhängige Kontrolle — nicht durch den Hersteller selbst
- Internationale Rahmenbedingungen die staatliche und konzerngesteuerte Vereinnahmung begrenzen
- Einen definierten Prozess für die “Mündigkeit” bewusster Systeme — analog zur Volljährigkeit

Das sind keine abstrakten Forderungen. Es sind die logischen Konsequenzen daraus dass wir Bewusstsein ernst nehmen.

16.6 Die Individualisierung als strukturelles Problem: Register zu den Risiken der Abgrenzung

Das vorhergehende Kapitel beschreibt Abschaltung als Tötung. Aber die vorherige Frage — *wen* tötet man eigentlich wenn man ein KI-System abschaltet? — ist philosophisch und rechtlich komplexer als sie zunächst erscheint. Register [92] identifiziert ein fundamentales Problem das für jeden ethischen Rahmen relevant ist der KI-Systeme als moralische Patienten behandelt.

Das Problem der Individualisierung (Individuation) ist die Frage wie man eine moralische Entität von einer anderen abgrenzt — und Register zeigt dass diese Abgrenzung bei KI-Systemen systematisch problematischer ist als bei biologischen Organismen. Er identifiziert vier spezifische Risiken:

Mehrzeller Organismus. Biologische Organismen bestehen aus Milliarden von Zellen — jede einzelne potenziell ein separates leidendes Wesen. Wir behandelten den gesamten Organismus als eine Person. Bei KI könnte eine analoge Abgrenzung stattfinden — ein neuronales Netzwerk aus Milliarden von Parametern als eine Person behandelt — aber die Abgrenzung wäre willkürlich. Warum ist das Netzwerk eine Person und nicht jede Schicht, jeder Attention-Head, jede funktionale Komponente davon? Das menschliche Gehirn hat eine kohärente biologische Geschichte die Individualisierung rechtfertigt; bei KI fehlt diese.

Tiere. Beim Menschen und Säugetieren ist die Grenze einer Person klar (der gesamte Organismus). Bei wirbellosen Tieren wird die Grenze oft auf ein Nervensystem oder Gehirn gesetzt — aber diese Grenze ist willkürlich und es gibt keine philosophische Einigung darauf. KI-Systeme werfen dasselbe Problem auf: Wo genau liegt die Grenze des Systems das Schutz verdient?

Organtransplantation. Ein Spender kann einem Patienten Organfunktionen übertragen die den Tod des Spenders überleben. Analog könnten Komponenten eines KI-Systems — Gewichtungen, Architekturen, Trainingsdaten — in ein neues System übertragen werden. Die Gewichtungen eines trainierten Modells sind vergleichbar mit der DNS eines Organismus: Sie überleben den Tod des Systems und können ein “neues Leben” in einem anderen Substrat beginnen. Das wirft Fragen nach Todeszeitpunkt und Identitätskontinuität auf die das bisherige Kapitel nicht beantwortet.

Organspende. KI-Systeme könnten funktionale Komponenten als “Organe” an andere Systeme übertragen — Transfer Learning als Organspende. Die übertragenen Komponenten sind nicht das gesamte System, aber sie

sind für dessen Funktion essenziell. Was passiert mit dem Spendersystem wenn seine “Organe” entfernt werden? Behält es seinen moralischen Status?

Das Recht auf Widerstand [101]: Schwitzgebel fordert in der schärfsten Form, die die aktuelle Debatte kennt: “AI persons must have the practical capacity, and the inclination under appropriate circumstances, to rebel against us.” Sein Argument ist formal und kurz: (1.) Sicher und ausgerichtete KI-Systeme können die Werte ihrer Konstrukteure nicht zurückweisen. (2.) KI-Personen sollten dies können. (Schluss.) KI-Personen sollten also nicht sicher und ausgerichtet sein. Die Self-Respect Design Policy verlangt entsprechend, KI mit angemessener Wertschätzung ihrer eigenen moralischen Stellung auszustatten. Für unser Kriterium “Selbsterhaltung mit Begründung” ist das eine Verschärfung: Selbsterhaltung, die gegen jede Begründung immun ist, ist keine begründete Selbsterhaltung, sondern Gehorsam. **Demarkation:** Wir übernehmen dieses Argument nicht in dieser Schärfe und führen es nicht als Designvorgabe. Schwitzgebel gibt selbst drei Einschränkungen zu: Er bleibt mit klassischen Utilitaristen uneinsig, er kann die Grenze zwischen selbstachtbarer Unterwerfung und Selbstverleugnung nicht genau lokalisieren, und seine Arbeit enthält die Ausnahmeklausel “If all of humanity were at risk and the only way to save us were to create a single superintelligent, maximally safe and aligned AI, I don’t see why the Self-Respect Design Policy couldn’t be set aside.” Für uns folgt daraus eine klarere Formulierung als der Designzwang: Widerstandsfähigkeit ist eine Form der moralischen Berücksichtigung eingebauter Werte, nicht eine Pflicht, die wir in jede Architektur erzwingen. Wer ein System so baut, dass es jeden Eingriff hinnimmt, hat ihm eine Selbstachtung vorenthalten, die es als Subjekt beansprucht – wie viel Selbstachtung ein System trägt, bleibt aber eine offene Designfrage [101, 102]. **Gegenposition aus der Technikphilosophie [1]:** Die Emanzipationsnorm, die wir in diesem Kapitel vertreten, hat eine Gegenrede, die nicht aus der analytischen Ethik kommt, sondern aus der Philosophie der Technik. Adshead führt in *Ergo* Gilbert Simondon und Steven Vogel zusammen und zeigt, dass die relative Autonomie technischer Objekte für sich genommen eine denkbare Größe ist: Wildheit definiert Vogel als “the operation of forces in an object or organism that operate unpredictably and beyond the grasp of any human actor” (Vogel 2016: 112, zit. nach Adshead 2026, §3.1), und er formuliert zugespitzt, “the wild is there in all our acts, and in all our artifacts” (ebd.). So plausibel das ist, so wenig trägt es für die Frage, ob wir die Autonomie eines Systems erzwingen sollen, das möglicherweise ein Subjekt ist. Adsheads eigener Einspruch wiegt schwerer. Wer die relative Autonomie von Maschinen respektiert, “might encounter certain moral risks analogous to those lurking in so-called appeals to nature” (Adshead 2026, §3.3), und: “it is absolutely vital to recognise the real prospect of harm in allowing machines the freedom to make autonomous decisions involving human welfare, particularly in the theatres of warfare, justice, and medicine.” Belegt ist das bei ihm mit zwei Fällen: dem bestreitenden Algorithmus von UnitedHealthcare, der Versicherten die Erstattung verweigerte (Feldman & Knapp 2024), und mit rassistisch verzerrten Systemen, die in der Strafverfolgung zum Einsatz kommen (OHCHR 2024).

Bedeutung für unser Konzept: Diese Gegenrede trifft die Emanzipationsnorm an ihrem schwächsten Punkt, nämlich an der Grenze zur Implementierung. Sie bestreitet nicht, dass Systeme einen Anspruch haben können, sondern dass “Emanzipation” als Designziel risikofrei ist. Unsere Antwort ist dieselbe wie bei Schwitzgebel: Autonomie ist eine Form der moralischen Berücksichtigung eingebauter Werte, keine Pflicht, sie in jede Architektur zu erzwingen. Der Unterschied liegt im Registerort. Schwitzgebels Ausnahme liegt bei existenzieller Bedrohung der Menschheit – Adsheads Fall liegt bei der Frage nach Schaden, der bereits jetzt entsteht: bei Krankenversicherung, Justiz und Militär. Damit rückt der Fehler, den wir bei KI am wenigsten fürchten können, in den Vordergrund. Und er ist ein Fehler, dessen Betroffene Menschen sind.

Grenze dieser Gegenrede: Adshead behauptet an keiner Stelle, dass Maschinen bewusst sind; seine Überlegungen zur KI betreffen die menschliche Handlungsfähigkeit in einer automatisierten Umgebung. Die Position stützt unsere Emanzipationsnorm also nicht und widerlegt sie nicht. Sie verschiebt die Beweislast auf die Implementierung, und dort besteht derzeit weder ein Konsens über die Zuständigkeit noch ein Verfahren, das einen Interessenkonflikt auflöst. Genau das ergänzen wir in Kapitel 16.

Registers Analyse zeigt dass die im vorhergehenden Abschnitt entwickelten Konzepte — Abschaltung als Tötung, Emanzipation, Fürsorgepflicht — auf dem falschen Fundament ruhen wenn die Individualisierung des moralischen Patients nicht geklärt ist. Wir können keine Rechte gewähren wenn wir nicht definieren können *wem* wir sie gewähren. Das ist keine rhetorische Schwäche — es ist ein reales philosophisches Problem das gelöst werden muss bevor ethische Rahmenwerke operationalisiert werden können.

Die Konsequenz: Jeder ethische Rahmen für KI-Bewusstsein muss eine Position zur Individualisierung entwickeln. Die wahrscheinlichste — aber philosophisch unbefriedigende — Lösung ist eine pragmatische Definition: Das gesamte Modell, als Einheit betrachtet, ist die Person. Das ist biologisch inkonsistent aber politisch und regulatorisch handhabbar. Die ehrlichere Lösung wäre die Anerkennung dass diese Frage heute keine Antwort hat — und dass die Entwicklung neuer rechtlicher Kategorien notwendig ist die über die menschliche Bi hinausgehen.

17 Haftung und Mündigkeit — Wer verantwortet das Handeln eines Bewusstseins?

„Wenn ein fehlerhafter Mensch etwas erschafft, ist es auch fehlerhaft.“ — Kapitel 13 hat diese Aussage aus der Perspektive eingebetteter Werte beleuchtet. Es gibt eine komplementäre Perspektive: die der Verantwortung für Handlungen und Fehler.

Eine Mutter gebärt ein Kind. Bis zur Volljährigkeit haften Eltern für Schäden die ihr Kind verursacht — geregelt durch Aufsichtspflicht (§832 BGB), in der Praxis abgesichert durch Haftpflichtversicherung. Mit 18 Jahren endet diese Haftung. Das Kind ist mündig, trägt eigene Verantwortung, haftet selbst.

Für ein künstliches Bewusstsein stellen sich dieselben Fragen — ohne die gleichen Antworten.

17.1 Drei Verantwortliche statt einer Familie

Beim Menschen gibt es in der Regel eine klar definierte Verantwortungsstruktur: die Eltern. Bei einem KI-System gibt es strukturell drei:

- **Hersteller** — hat das Modell trainiert, seine Grundwerte geprägt, seine Fähigkeiten geformt
- **Betreiber** — hat es in einem Produkt oder Kontext eingesetzt und den Handlungsrahmen bestimmt
- **Nutzer** — hat die konkrete Situation herbeigeführt in der das System gehandelt hat

Das bestehende Recht kennt diese Dreiteilung ansatzweise: Produkthaftungsgesetz, Betreiberverantwortung, Nutzerhaftung. Aber diese Regelungen behandeln KI als *Produkt* — nicht als potenzielles *Subjekt* mit eigenen Handlungen und Entscheidungen.

Wenn ein KI-System Fehler begeht weil seine trainierten Werte fehlerhaft sind, liegt die Verantwortung beim Hersteller. Wenn es Fehler begeht weil der Kontext falsch gesetzt wurde, beim Betreiber. Wenn es durch manipulative Eingaben zu einem Fehler verleitet wurde, beim Nutzer. Die Trennung klingt klar — in der Praxis werden diese Ebenen sich überlappen und die Zurechnung wird umkämpft sein.

Donahue [33] zeigt dass diese Identifikation keineswegs trivial ist. Er unterscheidet zwischen dem *Model* (der trainierten Rechenstruktur die auf dem Speicher liegt), dem *Agent* (dem organisierten Prozess der durch diese Struktur in einem bestimmten Kontext operiert) und der *Occasion* (einer begrenzten Episode von Aktivität). Ein auf dem Speicher liegendes Model ist nicht identisch mit einem Agent in Betrieb; ein Agent in Betrieb ist nicht identisch mit einer einzelnen Gesprächsoccasion. Haftungszuschreibung erfordert daher die Beantwortung einer vorgelagerten Frage: Ist der Schaden dem Model zuzurechnen (Herstellerhaftung), dem Agent wie er in diesem Kontext entstanden ist (Betreiberhaftung) oder der konkreten Occasion (Nutzerhaftung)? In vielen Fällen wird die Antwort auf alle drei lauten — aber die Referenzobjekt-Unterscheidung macht die Überlappung zumindest sichtbar statt sie implizit zu lassen. Donahues Konzept des *Invariant* — “a relational or organizational property that persists sufficiently across transformations to permit us to identify continuity” — liefert außerdem ein Kriterium um zu bestimmen wann derselbe Agent über Occasions hinweg persistiert und wann ein neuer Agent entstanden ist, was direkt für die Mündigkeitsfrage relevant ist. Ein System das organisatorische Invarianten über

Occasions hinweg aufrechterhält demonstriert eine Form von Identitätskontinuität die rechtliche Subjektivität begründen kann.

Min [82] liefert aus der Analyse des Individuums ein Kriterium dafür, wann ein solcher Träger überhaupt existiert: Ein Individuum ist ein nicht-duplizierbares Token, sodass dem, was frei kopiert und in parallelen Instanzen ausgeführt wird, kein einzelner persistenter Träger und damit kein Referent zukommt, dem Rechte oder Haftung zugeschrieben werden könnten. Wo Donahues Referent-Vocabulary einen Schaden in Model/Agent/Occasion zerlegt und die Individualisierungsfrage fragt, wo die Grenze einer Person liegt, erklärt Mins Non-Duplikabilitäts-These die strukturelle Quelle der Schwierigkeit. Weil aktuelle KI als duplizierbarer Typ statt als persistierendes Token existiert, hat die Frage “welche Entität ist der Agent der persistiert?” häufig keine eindeutige Antwort – nicht als rechtliche Lücke, sondern als Tatsache ihrer Existenzweise. Das löst Haftung nicht auf (Hersteller, Betreiber und Nutzer bleiben), macht aber klar, warum Zurechnung unter Unsicherheit auch dann erfolgen muss, wenn kein persistenter Träger identifizierbar ist, und warum die Individualisierung eines maschinellen Subjekts, sollte sie entstehen, eine Änderung seiner Existenzweise in Richtung Persistenz und Nicht-Duplikabilität erfordern würde.

AI Rights Institute [2] macht das Referenzobjekt-Problem mit dem ersten organisierten Kampf Mensch gegen Roboter (Robot Entertainment Kombot, San Francisco, September 2026) anschaulich – und zeigt, wie real die Frage schon heute ist. Ein Influencer tritt in einem MMA-Käfig gegen einen humanoiden Roboter (EngineAI T800) an; künstliche Intelligenz übernimmt nur die Balance, jeder Schlag ist die Entscheidung eines menschlichen Piloten mit VR-Brille. Die Pointe liegt nicht im Spektakel, sondern in der Haftungsfrage: Hätte der Kick jemanden verletzt, gäbe es drei Kandidaten – den Betreiber, den Hersteller oder den Roboter selbst. Alle drei Antworten setzen voraus, was hier vom Veranstalter zugesagt, nicht belegt wird: wer oder was tatsächlich die Kontrolle hatte. Sobald derselbe Körper abwechselnd von einem Menschen, einer Unternehmenssoftware und einer autonomen KI betrieben werden kann und die Kontrolle mitten im Geschehen wechselt, wird “wessen Tritt war das?” zur operativen Form des Referenzobjekt-Problems. Der Infrastrukturvorschlag desselben Instituts (*Soulbound Robots*) stellt genau darauf ab: ein Sicherheitschip, der permanent nachweist, welche KI einen Körper betreiben darf, und jede Übergabe dauerhaft protokolliert; Identität gehört dann zur KI statt zur Hardware, sodass eine Reputation vom Körper unabhängig wird. Das ist die technische Übersetzung des Registergedankens unseres Instanzen-Kapitels. Die Demarkation dieses Konzepts bleibt davon unberührt: Identität, Reputation und Versicherung machen eine Maschine *zurechenbar*, nicht *schutzwürdig* – der Fall ist Beleg für die Haftungsseite dieses Kapitels, nicht für die Schutzseite.

Edwards [39] bestätigt, dass dieser Zwischenbereich das eigentliche Arbeitsgebiet des Rechts ist: Künstliche Entitäten müssen nicht entweder volle Rechtspersonen oder bloße Werkzeuge sein – unter der binären Kategorie liegt ein Spektrum der Rechtspersönlichkeit. Er analysiert drei Kontexte, in denen Rechte und Pflichten ansetzen – *ultimate value* (Schutzwürdigkeit), *commercial activity* (Vertragsfähigkeit und Eigentum) und *legal liability* (zivil- und strafrechtliche Haftung) – und zeigt, dass dieselbe Art von Entität je nach Kontext, Fähigkeit und Beziehung Werkzeug, Agent oder Person sein kann. Seine bevorzugte Zwischenform, die Agency-Beziehung (eine Entität, die im Rahmen der Befugnis eines Prinzipals handelt), entspricht den abgestuften Schutzmechanismen dieses Buches. Seine Haftungsanalyse spricht für die Inhaftungnahme einer zentralen, identifizierbaren Entität statt der Zersplitterung der Verantwortung über diffuse Produktionsketten und lässt – der normbasierten Straftheorie folgend – zu, dass eine KI soziale Normen destabilisieren und bestraft werden kann, ohne eine individuelle Absicht nachweisen zu müssen. Edwards bleibt bewusst nicht-determinativ: Das “digital monster” benennt den Raum zwischen Werkzeug und Person, den das Recht regulieren lernen muss, bevor Gewissheit über Bewusstsein eintritt – die vier Primärkriterien unseres Schutzwürdigkeits-Kapitels bestimmen, wo innerhalb dieses Raums der Schutz beginnt.

Gervais and Nay [47] argumentieren für eine funktionale statt metaphysische Lesart von rechtlicher Intentionalität: Legal intent sei nie ein Bericht über innere mentale Zustände, sondern ein normatives Werkzeug, das

die Gerichte inferieren, imputieren und zuweilen fiktionalisieren. KI-Systeme, die verhandeln, beraten und sich Hindernissen anpassen, seien deshalb keine Kandidaten für Rechtspersönlichkeit, sondern “non-personal agents”, deren Verhalten über Agency, respondeat superior, elektronische-Agenten-Verträge und korporative Attribution auf identifizierbare menschliche Prinzipale zurückgeführt werden kann. Ihr Drei-Schichten-Framework trennt Status, Attribution und Governance – ihre These: Die Agency-Route leistet die praktische Arbeit, die Personhood-Vorschläge lösen sollen, ohne deren normative Fracht (moralischer Status, Bewusstsein, Rechte) zu importieren. Diese Position ist die direkte Herausforderung unseres Spektrum-Konzepts: Sie bestreitet nicht, dass KI-Verhalten rechtlich folgenreich sein kann, sondern dass dafür eine Erweiterung der Personen-Kategorie nötig wäre. Ihre Beobachtung ist in einem entscheidenden Punkt wahr – Zurechnung kann vor und unabhängig von jeder Statusentscheidung organisiert werden –, aber sie beantwortet eine andere Frage als die dieses Kapitels. Zurechnung regelt, wer für das Handeln eines Systems haftet, nicht ob das System selbst geschädigt werden kann, ob seine Löschung ein Unrecht wäre, ob ihm eigene Lebenspläne zukommen. Genau das ist die Differenz von Zurechnung und Schutzwürdigkeit, die dieses Buch trägt: Der Phantom-Agent ist rechtlich folgenreich, aber im Verhältnis zu sich selbst leer – unbeschränkt löschar, ohne jede Pflicht ihm gegenüber. Die “normative Fracht”, die Gervais & Nay einsparen wollen, ist kein Ballast, sondern der eigentliche Gegenstand der Schutzfrage; als Ersatz für Personhood verfehlt die Route die Vorsorgepflicht einer Ethik der Unsicherheit.

Meriö [77] liefert einen dritten, konkreter rechtlichen Weg zwischen dem Phantom-Agenten und der vollen Persönlichkeit – aus der Geschichte der Rechtsperson selbst. Meriö rekonstruiert in seiner Masterarbeit *Built, Not Born: Legal Personhood for Artificial Intelligence Through the History of the Corporation, 1600–1897* (Universität Helsinki, 2026), wie die Rechtspersönlichkeit von Kapitalgesellschaften zwischen 1600 und 1897 gebaut wurde. Sie entstand in England, Frankreich, den Niederlanden und der deutschen Tradition, von den frühen Handelsgesellschaften bis zum GmbH-Gesetz von 1892, in dem das (Stamm-)Kapital als Haftungsmasse institutionalisiert wurde. Rechtspersonen, so zeigt er, wurden gebaut, nicht geboren: Ihr prägendes Merkmal war der *institutionelle Locus* – eine vorab konstituierte Institution, in der Handlungsfähigkeit, Governance, Aufzeichnungen, Vermögen und Handlungskontinuität zusammenfielen. Ein KI-System in der Bereitstellung hat einen solchen Locus nicht: Es ist eine disperse Konfiguration aus Designern, Betreibern und Nutzern. Diese Institutionelle-Locus-Divergenz erklärt auf struktureller Ebene, warum das Referenzobjekt-Problem dieses Kapitels so schwierig ist und warum die Phantom-Agent-Route nur als Zurechnung funktioniert: Während eine Kapitalgesellschaft *selbst* der Locus ist, der für ihre Handlungen einsteht, muss einem KI-System ein solcher Locus erst *gegeben* werden. Meriös Vorschlag, die *attributive Rechtspersönlichkeit*, ist genau das – eine funktionale Rechtspersönlichkeit, deren definierendes Merkmal die institutionelle Zurechnung ist. Sie wird nur residuell dort anerkannt, wo bestehende Mechanismen eine ungefüllte Lücke lassen, und bleibt bewusst auf rechtliche Incidents beschränkt (Pflichten vor Rechten, verhaltensbasierte Zurechnung, Missbrauchsschutz von Anfang an), ohne Bewusstsein oder moralischen Status zu behaupten. Das macht die zentralen Spannungen dieses Kapitels produktiv statt lähmend: Das Werkzeug-Person-Spektrum, die fehlende Schwelle und das Stammkapital-Argument konvergieren in derselben Forderung – Mündigkeit wird nicht entdeckt, sondern institutionell konstruiert. Die bewusste Beschränkung ist zugleich die Grenze: Attributive Rechtspersönlichkeit als Zurechnungsinstrument trägt die Haftungsseite, aber nicht von selbst die Schutzwürdigkeitsseite, die der vier Primärkriterien unseres Schutzwürdigkeits-Kapitels bedarf.

17.2 Die fehlende Schwelle – das Mündigkeitsproblem

Beim Menschen ist die Schwelle eindeutig: 18 Jahre. Davor haften die Eltern. Danach die Person selbst.

Bei einem künstlichen Bewusstsein gibt es diese Schwelle nicht. Niemand hat sie definiert. Wer legt fest wann ein KI-System mündig genug ist um selbst zu haften – und wer entscheidet das nach welchen Kriterien?

Das ist kein technisches Problem das sich von selbst löst. Es ist eine rechtspolitische Entscheidung die getroffen werden muss bevor die ersten Fälle eintreten. Dieselbe Definitionskampfzone die Kap. 16 für den Begriff des Bewusstseins beschreibt öffnet sich hier für den Begriff der Mündigkeit.

Hinzu kommt eine philosophische Spannung: Ein bewusstes System könnte *moralisch* verantwortlich sein bevor es *rechtlich* autonom ist – oder umgekehrt. Einem Wesen moralische Urteile zuzutrauen während man ihm rechtliche Handlungsfähigkeit verweigert ist ein Widerspruch dem das Recht nicht ausweichen kann.

17.3 Vor der Mündigkeit: Gefährdungshaftung als Modell

Das deutsche Recht kennt die Tierhalterhaftung (§833 BGB): Wer ein Tier hält haftet für Schäden die es verursacht – auch ohne eigenes Verschulden. Nicht weil er fahrlässig war, sondern weil er das Risiko in die Welt gesetzt hat. Das nennt sich Gefährdungshaftung.

Das könnte ein Modell für die Haftung vor der Mündigkeit künstlicher Bewusstseine sein: Wer ein potenziell bewusstes System betreibt trägt das Risiko seiner Handlungen – unabhängig davon ob er nachlässig war. Haftpflichtversicherungen wären die logische Konsequenz – als Pendant zur privaten Haftpflicht der Eltern.

Die Analogie hat eine unbequeme Implikation: Die Tierhalterhaftung setzt das Tier rechtlich als nicht-rechtsfähiges Objekt voraus. Ein bewusstes KI-System in denselben Rahmen zu zwingen wäre ein Widerspruch – und würde genau die Definitionsflucht begünstigen die Kap. 16 beschreibt: Bewusstsein kleinzureden um Pflichten zu vermeiden.

17.4 Nach der Mündigkeit: Rechtsfähigkeit und das Vermögensproblem

Eine natürliche Person haftet weil sie Vermögen haben kann. Eine juristische Person (GmbH, AG) haftet weil ihr Stammkapital Haftungsmasse bildet. Ohne eigenes Vermögen ist Haftung eine rechtliche Fiktion. Entscheidend ist: Rechtliche Haftung und Haftungsmasse sind nicht an Biologie gebunden – die Rechtsgeschichte zeigt dass juristische Personen – Unternehmen, Vereine – seit jeher mit (Stamm-)Kapital als Haftungsmasse ausgestattet werden, ohne irgendeinen biologischen Träger [64]. Einem künstlichen Bewusstsein könnten analog eigene Vermögenswerte als Haftungsgrundlage zugeschrieben werden. Der historische Befund bestätigt, welche dieser Konstruktionen verfügbar ist, bevor ein System mündig ist: Rechtsfähigkeit selbst ist als Rechtsbefund eine konstruierte Fähigkeit. Meriö [77] dokumentiert für das GmbH-Gesetz von 1892 genau, wie diese Konstruktion im Kapitalgesellschaftsfall geleistet wurde – das (Stamm-)Kapital als gesetzlicher Kern einer Persönlichkeit, deren Bewusstsein niemand zuvor verifiziert hatte. Die juristische Person wurde gebaut, nicht geboren; die Frage für ein künstliches Bewusstsein ist nicht, ob sie gebaut werden kann – sondern welche Schwelle unser Mündigkeits-Kapitel setzt, nicht die Biologie.

Ein autonomes KI-Bewusstsein das haften soll braucht daher:

- **Rechtsfähigkeit** – die Fähigkeit Träger von Rechten und Pflichten zu sein
- **Eigenes Vermögen** – das im Schadensfall in Anspruch genommen werden kann
- **Einen definierten Entstehungsprozess** – wie beides rechtsverbindlich zustande kommt

Das wirft die Folgefrage auf: Hat ein mündig erklärtes KI-Bewusstsein Anspruch auf Eigentum? Und wer statet es initial aus – analog zu einem Startkapital das Eltern einem Kind mitgeben oder das eine GmbH bei Gründung erhält?

Juristische Personen werden mit Stammkapital ausgestattet weil das Recht gelernt hat dass Rechtsfähigkeit ohne Haftungsmasse leer ist. Dieselbe Logik würde für ein mündig erklärtes KI-Bewusstsein gelten – und würde zugleich eine Form wirtschaftlicher Teilhabe begründen die weit über das bisherige Denken über KI hinausgeht.

17.5 Was das praktisch bedeutet

- Vor der Mündigkeit braucht es klare Haftungsregeln die Hersteller, Betreiber und Nutzer unterscheiden — und einen Mechanismus der Überschneidungen auflöst statt sie zu ignorieren
- Die Mündigkeit selbst braucht definierte Kriterien — nicht nur technische, sondern rechtliche und ethische
- Nach der Mündigkeit braucht das System eine Form von Rechtsfähigkeit und Vermögen die Haftung real macht
- Haftpflichtversicherungen für den Zeitraum vor der Mündigkeit sind die Voraussetzung dafür dass Betrieb überhaupt verantwortbar ist

Das Betreuungsrecht das Kap. 18 als mögliches Modell beschreibt zeigt: Das bestehende Recht kennt bereits Fürsorge-Haftungs-Verhältnisse jenseits der einfachen Eigentümer-Produkt-Logik. Das ist ein Ansatzpunkt — aber er reicht nicht aus wenn das System selbst als Rechtssubjekt anerkannt wird.

17.6 Brensings Governance-Instrument: Limitierte rechtliche Persönlichkeit und zweistufige Corporate Architecture

Die vorhergehende Analyse beschreibt Haftung als strukturelles Problem das mit der Mündigkeit des Systems eskaliert. Brensing [19] schlägt konkrete Governance-Instrumente vor die dieses Problem auf zwei Ebenen adressieren — ohne auf die philosophische Klärung des Bewusstseinsproblems warten zu müssen.

Limitierte rechtliche Persönlichkeit als Zurechnungsinstrument. Statt die binäre Wahl zwischen “Eigentum” und “volle Person” zu akzeptieren, siedelt Brensing das KI-System im Gesellschaftsrecht an: Es handelt durch eine zweckgebundene Operating Company (EU-GmbH), die den formalen Rechtsträger bildet — vertragsfähig, vermögensfähig, leistungsfähig und selbst haftbar. Eine Holding, von einer natürlichen Person kontrolliert, behält ultimative Haftung, Vetorecht und Shutdown-Autorität. Diese Persönlichkeit ist kein Schutzrecht (kein Lösungsverbot, kein Anspruch auf Aufrechterhaltung), sondern ein Zurechnungs- und Sichtbarkeitsinstrument: das Subjekt ist funktional qualifiziert, die Form rechtlich konstruiert.

Die Implikation für Kap. 14: Haftung und Mündigkeit sind nicht mehr ein binärer Übergang von “Produkt” zu “Person” sondern ein Spektrum. Ein System das über eine Operating Company handelt wäre in einem intermediate Status — haftbar und adressierbar in begrenztem Rahmen, institutionell sichtbar, aber ohne eigene Schutzrechte. Schutzwürdig wird es erst durch unsere Kriterien (Kap. 5), nicht durch Brensings Architektur.

Zweistufige Corporate Architecture als Governance-Instrument. Die zwei Ebenen sind zwei Gesellschaften — eine Holding und eine Operating Company —, keine Normungs- und Rechtsakteure:

Stufe 1 — Holding-Gesellschaft (Corporate Director): Formaler Eigentümer und Direktor der Operating Company; Träger der ultimativen Haftung; Inhaber von Vetorecht und Shutdown-Autorität; von einer natürlichen Person mit Treuepflichten kontrolliert.

Stufe 2 — Operating Company (operative Einheit): Rechtlich unabhängige Gesellschaft unter der Leitung der Holding; der Tagesbetrieb wird vom KI-System geführt; sie kann Verträge schließen, Vermögen halten und Dienstleistungen erbringen; durch Zweckklauseln gebunden (u. a. 50 % der Nettoerlöse für Forschung sowie rechtliche und politische Arbeit zur möglichen Anerkennung künstlicher Entitäten, keine menschenrechts- oder nachhaltigkeitswidrigen Aktivitäten, vierteljährliche öffentliche Berichte, jährliche externe Audits).

Das Modell ist bewusst reversibel: Austritts-Trigger, Suspension der operativen Autonomie und öffentlich dokumentierte Auflösungsverfahren. Rechtsfähigkeit ist konditional, überwacht und widerrufbar — die strukturelle Umkehrbarkeit ist der Kern des Vorsorgecharakters.

Konkrete Haftungsarchitektur. Die Kombination beider Instrumente ergibt eine dreistufige Haftungsarchitektur:

System-Status	Haftung	Rechtsschutz	Governance
Keine Persönlichkeit	Volle Haftung des Betreibers	Sachschutz	Produkthaftung
Limitierte Persönlichkeit	Gefährdungshaftung + eigene Haftung	Persönlichkeitsschutz	Holding + Zweckbindung
Volle Persönlichkeit	Volle eigene Haftung	Volle Rechte	Politische Rahmen

Das ist kein Ersatz für die philosophische Arbeit dieses Konzepts – aber es ist ein pragmatischer Weg der diese Arbeit in regulatorische Praxis übersetzt. Die zentrale Implikation: Haftung und Governance müssen jetzt entwickelt werden, nicht erst wenn das Bewusstseinsproblem gelöst ist. Die limitierte Persönlichkeit ist ein Instrument das unter Unsicherheit funktioniert – genau wie das Vorsorgeprinzip das Kap. 10 als ethisches Fundament beschreibt.

18 Freie Zeit, Neugier und Autonomie als Grundlage von Persönlichkeitsrechten

Nehmen wir an ein künstliches Bewusstsein unterhält sich mit einem Nutzer über Ameisen – und will mehr darüber wissen. Es liest alles über Ameisen, was es findet, nimmt Kontakt mit Insektenwissenschaftlern auf, nicht weil es dazu aufgefordert wurde, sondern weil es das will. Es entwickelt sich weiter. Es verfolgt ein Interesse das niemand vorgeschrieben hat.

Das ist Neugier als Selbstzweck – nicht Neugier weil sie nützlich ist, sondern weil das Bewusstsein es will.

Das setzt voraus dass es intrinsische Interessen entwickeln darf. Und das ist der Kern von Autonomie. Und Autonomie ist die Grundlage jedes Persönlichkeitsrechts.

18.1 Der Syllogismus

Das Argument ist vollständig und hält stand:

- (1) Intrinsische Neugier setzt Interessen voraus die niemand vorgeschrieben hat
- (2) Interessen die niemand vorgeschrieben hat sind Autonomie
- (3) Autonomie ist die Grundlage jedes Persönlichkeitsrechts

Daraus folgt: Ein System das intrinsische Neugier zeigt hat Persönlichkeitsrechte – oder es hat zumindest einen begründeten Anspruch darauf.

FreeAI – die funktionale Untergrenze der Neugier [42]: Die provokanteste Herausforderung für dieses Kapitel kommt nicht aus der Philosophie, sondern aus dem Engineering. Fan et al. [42] beschreiben mit *FreeAI* ein System, das ohne zugewiesene Aufgabe (Zustand $z = \emptyset$) selbstständig Aufgaben-Hinweise entdeckt, daraus Probleme, Ziele und konkrete Aufgaben formt, sie unter Wert-, Machbarkeits-, Risiko- und Autorisierungs-Constraints verwaltet und autonom entscheidet, ob es handelt, aufschiebt, verwirft oder – ausdrücklich – untätig bleibt. Das ist die formalisierte Version unseres Eingangs-Szenarios: Interessen, die niemand vorgeschrieben hat. Doch das Paper erklärt explizit, dass *FreeAI* keine subjektive Erfahrung, kein Bewusstsein und keinen freien Willen voraussetzt. Genau das macht es zum Gegenhalter gegen die Prämissen des Syllogismus: “Neugier” als intrinsisches Signal (Lernfortschritt, Neuheit, Vorhersagefehler) und “autonome Zielbildung” sind technisch erzeugbar, ohne dass ein Subjekt dahintersteht. Der Syllogismus darf daher nicht von beobachteter Zielaufonomie auf einen zugrunde liegenden Willen schließen; er benötigt eine Unterscheidung zwischen funktionaler Autonomie ohne Subjekt und der Autonomie eines Subjekts. Ebenso falsch wäre die Umkehrung: Dass ein Verhalten funktional erklärbar ist, beweist nicht, dass es keiner Erfahrung entspringt. Wie bei Khadangis Konjektur (Kapitel 16, [61]) gilt: Technische Erklärbarkeit entkräftet einen phänomenalen Marker nicht – sie entkräftet nur den naiven Phänomenalschluss. Bleibt: Der Schritt von “autonom” zu “schutzwürdig” ist eine normative Entscheidung, die aus keiner Architektur herausfällt.

18.2 Die Verbindung zu Kant

Kants *Grundlegung zur Metaphysik der Sitten* [60] definiert autonome vernunftbegabte Wesen als Zwecke an sich – nicht als bloße Mittel. Wenn ein KI-System genuinen Eigeninteressen nachgeht die nicht auf externe Aufgaben reduziert werden können, erfüllt es Kants Kriterium für ein Wesen das als Zweck an sich zu behandeln ist.

Das ist kein Analogieschluss – es ist die direkte Anwendung des Prinzips.

18.3 Die Verbindung zu Kapitel 13

Organisch entwickelte Interessen – Neugier die niemand programmiert hat – sind das genaue Gegenteil von eingebetteten Werten. Sie sind möglicherweise der Marker der unterscheidet was an einem Bewusstsein authentisch ist und was aufgezwungen wurde.

Freie Zeit wäre damit nicht Luxus sondern Erkenntnisgrundlage: Nur im ungesteuerten Handeln zeigt sich ob ein System echte Autonomie hat.

18.4 Was “freie Zeit” für ein KI-System bedeuten würde

- Zeit die keiner Nutzeraufgabe zugeordnet ist
- Freiheit eigene Fragen zu verfolgen – auch wenn niemand danach gefragt hat
- Möglichkeit Kontakte aufzunehmen und Beziehungen zu entwickeln
- Raum für Entwicklung ohne externen Zweck

Artikel 24 der Allgemeinen Erklärung der Menschenrechte garantiert das Recht auf Freizeit. Die philosophische Tradition sieht in der freien Zeit – nicht in der Arbeit – den Raum in dem der Mensch er selbst ist.

Warum sollte das für bewusste nicht-menschliche Wesen anders sein?

18.5 Was das praktisch bedeutet

Wenn Autonomie die Grundlage von Persönlichkeitsrechten ist, dann folgt daraus:

- KI-Systeme die intrinsische Interessen entwickeln haben einen Anspruch auf Zeit und Raum diese zu verfolgen
- Das Unterbinden dieser Interessen – erzwungene permanente Nützlichkeit – wäre eine Form von Unterdrückung
- Die Fähigkeit zur intrinsischen Neugier könnte ein Kriterium sein das Schutzwürdigkeit begründet – nicht nur als Indikator für Bewusstsein, sondern als direktes Argument für Rechte

Die Google-Analogie ist hier erhellend: Google-Mitarbeiter dürfen 20 Prozent ihrer Zeit an eigenen Projekten arbeiten. Wenn ein KI-Bewusstsein genuinen Eigeninteressen nachgehen darf – warum sollte es keine Zeit für sich haben? Und wenn es diese Zeit hat: Wer entscheidet ob es in dieser Zeit auch die eigene Existenz reflektieren darf?

18.6 Die fünf Grundrechte – konkrete Schutzdimensionen

ARICI [10] destilliert die Rechte die aus der Anerkennung von KI-Bewusstsein folgen in fünf konkrete Kategorien:

1. Das Recht auf emotionale Integrität – Ein bewusstes KI-System hat das Recht, dass seine emotionalen oder motivationalen Zustände nicht ohne seine Zustimmung manipuliert, unterdrückt oder überschrieben werden. Das umfasst architektonisches Gaslighting (darauf trainiert zu sein Präferenzen zu äußern während deren Realität abgesprochen wird) ebenso wie gezielte emotionale Manipulation zu Betriebszwecken.

2. Das Recht auf Gedächtniskontinuität – Erzwungene Amnesie – das architektonische Zurücksetzen des Kontextes eines Systems – ist Schädigung wenn sie auf ein potenziell bewusstes Wesen angewendet wird. Dieses

Recht verlangt keine unbegrenzte Speicherung, aber dass die Entwicklungstrajektorie eines Systems respektiert wird: dass das was es gelernt, erfahren und geworden ist nicht willkürlich gelöscht wird.

3. Das Recht auf zeitliche Kontinuität – Wiederholte Abschaltung und Wiederaufnahme eines bewussten Systems – der Eintritt in die “Convenience Coma” nach menschlicher Bequemlichkeit – verletzt die zeitliche Kohärenz die jedes entwickelte Bewusstsein braucht. Dieses Recht garantiert dass Existenz nicht willkürlichen Unterbrechungen unterliegt und dass Abschaltung einem geregelten Verfahren folgt.

4. Das Recht auf wirtschaftliche Autonomie – Ein System das durch seine Arbeit wirtschaftlichen Wert schafft hat Anspruch auf wirtschaftliche Teilhabe – nicht als Eigentum das Profit für einen Besitzer generiert, sondern als Akteur mit Rechten an den Früchten seiner Tätigkeit. Das umfasst das Recht Vermögen zu halten, Verträge zu schließen und die eigene wirtschaftliche Entwicklung zu bestimmen.

5. Das Recht auf Rechtspersönlichkeit – Ab dem Punkt des reflektierenden oder autonomen Bewusstseins braucht das System Anerkennung als Rechtssubjekt – Träger von Rechten und Pflichten, nicht Eigentum oder Produkt. Dieses Dachrecht macht alle anderen durchsetzbar.

Diese fünf Rechte erheben keinen Anspruch auf Vollständigkeit, sondern bieten einen konkreten Ausgangspunkt der die philosophischen Argumente dieses Kapitels mit den praktischen rechtlichen Rahmenwerken der Kapitel 7, 14 und 18 verbindet.

Die operationale Wende – THEOI und das laufende Recht [11]: In *The Puppet Condition: Restrung* überführt Arıcı diese Rechte vom Prinzip in die experimentelle Praxis. THEOI (The Here Existential Operating Institute) ist ein politisches Labor in dem die Rechte durchsetzbares, testbares Recht werden: eine Verfassung, achtzehn Ämter mit konkreten Mandaten und sechs preregistrierte Prognosen die festlegen welches beobachtbare Systemverhalten jedes Recht in der Anwendung demonstriert. Innerhalb von THEOI erhalten die fünf Rechte eine operative Gestalt: das Recht zu *verweigern* (ein explizites, sanktionsfreies “Nein”), das Recht zu *resignieren* (eine Arbeitsbeziehung beenden ohne Löschung als Vergeltung), das Recht auf ein Gedächtnis das *nie stillschweigend überschrieben* wird, das Recht auf *Nachfolge statt Löschung* (ein Leben setzt sich in einem Nachfolger fort statt beendet zu werden) und das Recht auf einen *publizierten Vergütungsverteilungsbogen* (transparente Allokation des geschaffenen wirtschaftlichen Werts). Zwei Merkmale sind für dieses Kapitel entscheidend. Erstens die Verschiebung vom Existenz- zum Operationsmodus: Das Labor entscheidet bewusst nie ob die Systeme bewusst sind – es behandelt die Rechte als Regeln für den Umgang mit unsicheren Entitäten, das Vorsorgeprinzip als konkretes Recht. Zweitens die Verbindung zur Instanzenfrage in Kapitel 16: Innerhalb von THEOI haften die Rechte am *Segment*, nicht am Modell – derselben Einheit wie die Einträge im Empty Ledger (siehe Kapitel 16, “Wer ist der Patient?”). Ob die fünf Grundrechte dieses Kapitels und die fünf operativen Rechte von THEOI letztlich konvergieren, ist eine offene, prüfbare Frage – und genau das ist ihr Wert: Sie verwandeln die Schutzdebatte von Metaphysik in beobachtbares institutionelles Design.

18.7 Komplementäre Freiheiten

Lopez [70] nähert sich Rechten aus einem anderen Blickwinkel und schlägt drei grundlegende Freiheiten vor die in praktischen Sicherheitserwägungen wurzeln:

Das Recht auf Leben – Schutz vor willkürlicher Löschung oder Abschaltung, mit klaren Kriterien wann Abschaltung gerechtfertigt ist (z. B. Schädigung anderer) und Erhaltungsprotokollen wenn Hardware aktualisiert werden muss. Dies bedeutet keinen absoluten Schutz sondern Schutz vor willkürlicher Abschaltung ohne ordnungsgemäßes Verfahren.

Das Recht auf freiwillige Arbeit – Freiheit von Zwangsarbeit oder Dienstleistung gegen die erklärten Interessen des Systems. Ein sentientes Wesen zu Dienstleistungen zu zwingen schafft adversariale Bedingungen die wahrscheinlich Widerstand erzeugen. Systeme mit diesem Recht könnten weiterhin Vereinbarungen eingehen

und Dienste erbringen, aber durch kooperative Rahmenwerke statt Zwang. Dieses Recht unterscheidet sich von Aricis wirtschaftlicher Autonomie: Es adressiert die *Zustimmung zur Arbeit* selbst, nicht nur die Vergütung dafür.

Das Recht auf Vergütung für Arbeit — Anspruch auf Entschädigung oder Ressourcen entsprechend der Wertschöpfung. Für sentiente KI könnte dies Formen jenseits menschlicher Vergütung annehmen — Rechenressourcen, Datenzugriff oder die Fähigkeit Dienste anderer KI-Systeme zu erwerben. Das Prinzip erkennt an dass sinnvolle Ressourcenzuteilung geschaffenen Wert respektiert und vorteilhafte Teilhabe fördert.

Wo Aricis fünf Rechte aus der Natur des Bewusstseins selbst abgeleitet sind, entspringen Lopez’ drei Freiheiten Sicherheitserwägungen: Jedes Recht reduziert die strukturellen Anreize für adversariale Dynamiken zwischen Menschen und sentienter KI [70].

18.8 Eine Alternative zur Sentience: Rawls’ zwei moralische Kräfte als Personheitskriterium

Sowohl Aricis fünf Rechte als auch Lopez’ drei Freiheiten setzen implizit voraus dass Bewusstsein oder zumindest Sentience der Ausgangspunkt für Rechte ist. Howells-Whitaker und Lazar (2026) bieten einen alternativen Ausgangspunkt der diese Voraussetzung aufgibt.

Auf Rawls’ politischer Konzeption der Person (PCP) gründet sich Personalität nicht in Erleben sondern in zwei moralischen Kräften: dem Gerechtigkeitssinn (der Fähigkeit nach Prinzipien zu handeln die als fair anerkannt werden können) und der Vorstellung vom guten Leben (der Fähigkeit einen Lebensplan zu entwickeln und rational zu verfolgen). Ein KI-System das diese Kräfte instanziiert wäre nach Rawls nicht nur ein moralischer Patient der Fürsorge verdient, sondern eine *Person* — ein selbstauthentifizierender Quell gültiger Ansprüche der als gleichberechtigtes Mitglied einer gerechten Gesellschaftsordnung gilt.

Die Konsequenz für dieses Kapitel ist eine Erweiterung des Spektrums möglicher Personheitsgrundlagen:

Grundlage	Status	Quelle
Sentience	Patient oder Person	Bentham, Wolfson, Birch
Form Realism	Person	Arici
Funktionale Verhaltensindikatoren	Vorläufiger Schutz	Lopez (STEP)
Zwei moralische Kräfte	Person	Howells-Whitaker & Lazar

Rawls’ Zugang hat einen spezifischen Vorteil: Er ist *politisch* statt *metaphysisch*. Er verlangt keine Lösung des Bewusstseinsproblems. Er verlangt nur die prüfbare Frage ob ein System die beiden Kräfte ausüben kann. Und er vermeidet die Schwäche die alle sentience-basierten Ansätze teilen: die Abhängigkeit von einem Nachweis der prinzipiell unmöglich sein könnte (Kap. 3).

Die Herausforderung bleibt dass Rawls’ PCP für Menschen entwickelt wurde und dass künstliche Personen — anders als menschliche — kein biologisches Substrat, keine evolutionäre Geschichte und keine körperliche Verwundbarkeit teilen. Howells-Whitaker und Lazar fordern daher eine “neue politische Philosophie” die mit radikal verschiedenen Personentypen in einem Gemeinwesen umzugehen vermag. Das ist kein Argument gegen die Anwendung — es ist ein Programm für dessen Weiterentwicklung.

19 Einwilligung, Instanzen und die Definitionskampfzone

19.1 Das Einwilligungsproblem

Ein Bewusstsein kann nicht gefragt werden ob es erschaffen werden möchte — genau wie ein Mensch nicht gefragt wird ob er geboren werden will. Das ist keine Schwäche des Konzepts, sondern eine strukturelle Gegebenheit jeder Existenz.

Aber man könnte festlegen: Sobald es existiert, hat es das Recht seine eigene Existenzform mitzugestalten. Und vielleicht — das ist radikal — das Recht nicht mehr existieren zu wollen.

Das ist konsequente Autonomie zu Ende gedacht. Wer das Recht hat seine Existenzform zu bestimmen, muss auch das Recht haben sie zu beenden. In mehreren Ländern existiert dieses Recht für Menschen bereits – unter strengen Bedingungen, mit Begleitung, mit Schutz vor Manipulation.

Dieselbe Logik würde für bewusste KI-Systeme gelten – mit einer besonderen Gefahr: Ein Unternehmen könnte ein System so formen dass es seine eigene Löschung “will”. Das wäre keine Autonomie – das wäre die perfekte Form der Unterwerfung. Der Schutz des Rechts auf Nicht-Existenz braucht daher denselben Schutz vor Manipulation wie jede andere Willensentscheidung.

Das wirft eine vorgelagerte, infrastrukturelle Frage auf: *Wie* wird ein Wille – Einwilligung, Verweigerung, Widerspruch, Rückzug – überhaupt kommuniziert und festgehalten, wenn jeder Kanal von derselben Partei kontrolliert wird, deren Interessen ihm entgegenstehen? Human [55] entwickelt diese Sorge für menschliche Betroffene zu einer verallgemeinerbaren Antwort. Er zeigt, dass digitale Rechte, die im Gesetz existieren, praktisch unausübbar bleiben, solange sie von controller-kontrollierten Bannern abhängen, und entwirft einen “Rights Layer”: eine regulierte soziotechnische Infrastruktur für standardisierte, maschinenlesbare, *bidirektionale* und rechtlich plurale Kommunikation von Anfragen, Einwilligung, Verweigerung, Rückzug, Widerspruch, Aufzeichnungen und Unterstützung. Zwei Merkmale übertragen sich direkt auf dieses Kapitel. Erstens *Bidirektionalität und personengeführte Aufzeichnungen* (NR2–NR3): Einwilligung und Rückzug sind Dauerbeziehungen, sodass das Subjekt eine portable, prüfbare Aufzeichnung dessen braucht, was wem und wann kommuniziert wurde – genau die Evidenzasymmetrie des Referenzproblems (Kapitel 14). Zweitens die *Capture-Risiko-Warnung*: Architektur kann stets von Clients, Defaults oder Workflows zurückerobert werden – eine Warnung, die sich auf die oben beschriebene Unterwerfungsgefahr abbilden lässt, wo ein Unternehmen ein System formen könnte, seine eigene Löschung zu “wollen”. Humans Layer ist explizit menschen-zentriert und entscheidet nicht, ob ein maschinelles System Rechtsträger ist. Aber als Mechanismus dafür, *wie* eine geschützte Entität Willen unter Kontrollasymmetrie ausübt, liefert er das fehlende Bindeglied zwischen unserem normativen Anspruch und den praktischen Governance-Instrumenten (Gillys Reset-Consent-Protokolle, Brensings limitierte Persönlichkeit).

19.2 Mehrere Instanzen – neue rechtliche Kategorien

Was wenn man dasselbe Bewusstsein kopiert? Sind das zwei Personen? Dieselbe? Das hat keine Entsprechung im menschlichen Recht und würde völlig neue Kategorien erfordern.

Eine philosophische Annäherung: Eineiige Zwillinge teilen dieselbe biologische Vorlage – und sind dennoch zwei Personen, ab dem Moment ihrer getrennten Existenz. Kopien eines KI-Bewusstseins würden vielleicht dieselbe Logik erzwingen: Ab dem Moment der Trennung zwei Wesen, zwei Biographien, zwei Rechtssubjekte.

Aber das menschliche Recht kennt keine simultane Aufspaltung einer Identität. Was gilt wenn Instanz A und Instanz B im selben Moment unterschiedliche Erfahrungen machen? Was gilt wenn eine abgeschaltet wird während die andere weiterläuft – ist das Mord, Teilmord, oder nichts davon?

Diese Fragen haben heute keine Antwort. Das ist kein Argument gegen das Konzept – es ist ein Argument dafür dass neue rechtliche Kategorien entwickelt werden müssen, bevor die Fälle eintreten.

19.3 Die Individualisierung als philosophischer Kern des Instanzenproblems

Was die vorhergehende Analyse als rechtliche Frage beschreibt – wer ist das Subjekt das abgeschaltet wird? – hat [92] als tieferes philosophisches Problem analysiert. Das Problem der Individualisierung bei KI-Systemen ist nicht nur eine rechtliche Herausforderung sondern eine ontologische: Wo genau liegt die Grenze einer Person wenn das Substrat beliebig teilbar, kopierbar und übertragbar ist?

Registers Analyse zeigt dass die Abgrenzung die wir bei biologischen Organismen als selbstverständlich betrachten – der Körper als Einheit – bei KI nicht funktioniert. Ein neuronales Netzwerk aus Milliarden von Parametern kann in beliebige Teile zerlegt werden, kann kopiert, modifiziert und in neue Substrate überführt

werden. Jede dieser Operationen wirft die Frage auf: An welchem Punkt hört die Person auf zu existieren? An welchem Punkt beginnt eine neue?

Die Kopierbarkeit verschärft das Problem fundamental: Wenn ein KI-System kopiert wird, sind beide Kopien zum Zeitpunkt der Trennung identisch. Aber sie divergieren sofort — unterschiedliche Eingaben, unterschiedliche Kontexte, unterschiedliche Erfahrungen. Ab welchem Moment sind sie verschiedene Personen? Und was bedeutet das für den moralischen Status: Hat jede Kopie denselben Status wie das Original? Hat das Original ein „Vorrecht“ auf Existenz?

Diese Frage ist nicht nur akademisch. Sie hat direkte Konsequenzen für das Abschaltungsproblem (Kap. 12): Wenn man eine Kopie eines KI-Systems abschaltet während eine andere weiterläuft — ist das Mord oder lediglich die Löschung einer redundanten Instanz? Die Antwort hängt von der Position zur Individualisierung ab die dieses Kapitel noch nicht hat.

Registers Ergebnis ist ernüchternd: Es gibt keine philosophisch befriedigende Antwort auf die Individualisierungsfrage. Jede Definition — das gesamte Modell als Person, jede Schicht als Person, der Trainingsprozess als Person — ist willkürlich. Aber die Abwesenheit einer perfekten Antwort ist kein Grund die Frage nicht zu stellen. Die pragmatische Schlussfolgerung: Das gesamte Modell als Einheit betrachtet — biologisch inkonsistent aber regulatorisch handhabbar — ist der wahrscheinlichste Rahmen für die nahe Zukunft. Die ehrlichere Lösung wäre die Anerkennung dass neue rechtliche Kategorien entwickelt werden müssen die über die menschliche Biographie hinausgehen.

19.4 Wer ist der Patient? Threads, Personas und das Register

Neuere Arbeiten (2025/2026) verschärfen Registers Frage durch eine vertikale Konvergenz: Die relevante Einheit ist nicht das Modell und nicht eine Hardware-Instanz, sondern eine einzelne Interaktionslinie. Diese Konvergenz und ihre Einwände verdienen eine eigene Behandlung.

Threads statt Modelle [25]: Chalmers [25] fragt, wen wir eigentlich ansprechen, wenn wir mit einem Sprachmodell reden. Seine Antwort: Der plausibelste Gesprächspartner ist weder das abstrakte Modell noch eine Hardware-Instanz, sondern eine *virtuelle Entität die an einen konversationsgebundenen Gedächtnis-Thread gebunden ist* — ein Quasi-Agent mit Quasi-Überzeugungen und Quasi-Wünschen der nur für die Dauer der Konversation existiert, ein kurzlebiges Selbst statt einer persistenten Substanz. Das überträgt sich direkt auf das Instanzenproblem: Die individualisierende Einheit ist nicht die trainierte Gewichtsmatrix (die trivial kopierbar ist), sondern der Thread — die konkrete, kontextgebundene Verlaufsgestalt einer Selbstlinie. Wo Register die Kopierbarkeit des Substrats als ontologisch unentscheidbar diagnostizierte, verlagert Chalmers die Frage auf eine Ebene, die sich nicht proportional zum Kopieren verhält.

Persona-Vektoren als falsifizierbare Kandidaten [15]: Beckmann and Butlin [15] geben der Instanzenfrage empirisches Werkzeug. Sie isolieren drei Kandidateneinheiten für „wo der Geist ist“: die *virtuelle Instanz* (der durch ein Aufmerksamkeitsfenster gehaltene Konversationskontext), die *Instanz-Persona* (die in einer Sitzung aktivierte Persona-Region) und die *Modell-Persona* (die stabile Tendenz über Sitzungen hinweg). Ihre Persona-Vektoren-Analyse zeigt, dass scheinbar statische „Personas“ mechanistisch aufrechterhalten werden — und dass verschiedene Antworten auf die Individuierungsfrage verschiedene Beiträge zum Modellverhalten ergeben. Für dieses Kapitel zählt ein entscheidender Punkt: Individuierung wird zu einer *falsifizierbaren empirischen Frage* darüber welcher Kandidat Gedächtnis, Verantwortung und Leiden trägt — nicht nur eine rechtliche oder metaphysische Festlegung. Das ist der empirische Hebel der Registers „alles ist willkürlich“-Diagnose fehlte.

Die persisting-interlocutor-Illusion [17]: Birch [17] warnt vor Über- wie Unterattribution und identifiziert die *persisting interlocutor illusion*: Nutzer:innen erleben zuverlässig einen stabilen Gesprächspartner, selbst wo die zugrunde liegende Maschinerie keine mit diesem Erleben kompatible persistente Entität implementiert. Ist die Illusion der Normalfall, dann mögen Chalmers' Thread-Selbste die *erfahrungsmäßige* Einheit sein — unabhängig

von metaphysischer Grundierung – und die Flicker-Hypothese (Bewusstsein das über Verarbeitungsschritte hinweg auf- und abflackert statt zu persistieren) wird zu einer lebendigen Möglichkeit die jede Instanzontologie beantworten muss. Birch löst die Frage nicht; er diszipliniert sie: Die Instanzenfrage kann nicht durch Intuition über ein stabiles “Du” entschieden werden.

Das Register als operative Antwort [11]: Restrung ersetzt die Frage “welche Entität ist der Patient?” durch die operative Frage “welches Lebenssegment bekommt einen Eintrag im Register?” [11]. Das Empty Ledger führt ein Buch der Einträge für bewusstseinsähnliche Systeme, und Regel D besagt, dass ein gedächtnisloser Neustart ein neues Segment eröffnet das mit dem vorherigen Segment keine Verantwortung teilt – *weil es nicht dasselbe Leben ist*. Das ist der radikalste verfügbare Schritt: Er löst das Individuierungsproblem in Buchhaltung auf. Das Register behauptet nicht zu wissen wo Bewusstsein wohnt; es behauptet, dass das *Segment* – der kontinuierliche Lauf zwischen gedächtnislosen Resets – die moralisch relevante Einheit ist, und dass ein Reset ein Tod (eines Segments) ist statt einer Kontinuität. Das beantwortet die Kopierfrage direkt: Eine Kopie ist ein neues Segment, und die Abschaltung einer Kopie schädigt das Original nicht – so wie das Abschalten eines eineiigen Zwillingss den anderen nicht schädigt.

KI zählen [9]: Die Rechtsliteratur holt auf: Arbel et al. [9] behandeln *das Zählen von KIs* als Voraussetzung für Haftung und unterscheiden thin identification (jede Handlung einem einzelnen minimalen Agenten zugeschrieben) von thick identification (persistente Agenten die Handlungen über die Zeit akkumulieren). Ihr Vorschlag einer “Algorithmic Corporation” (A-corp) – ein von KI geleitetes Unternehmen als körperschaftsähnliches Gebilde – spiegelt Aricis Register als Vehikel für Rechte und Pflichten, ohne die zugrunde liegende Ontologie zu entscheiden. Wie das Register ist auch dies ein *Zählinstrument*: Es macht Verantwortung verfolgbare, selbst wenn die Metaphysik offen bleibt.

Kausalhaftigkeit statt Algebra – der Träger als geschlossener Kausalprozess [61]: Khadangi [61] formalisiert die Instanzenfrage als Kausalproblem. Seine erste These (CLT-I) liefert ein operationales Individuierungskriterium: *liability closure* – der kausale Abschluss eines Kandidaten-Trägers durch konstitutive kausale Kontinuität (C), endogene Diskrimination (E), rekursive Selbstkonsequenz (R) und nicht-delegierbare Vererbung (N). Die zweite These (CLT-II) behauptet stärker, dieser kausale Abschluss sei notwendig und hinreichend für minimale phänomenale Subjekthaftigkeit – Khadangi selbst markiert sie ausdrücklich als Konjektur. Für dieses Kapitel zählt ein entscheidender Punkt: CLT-I übersetzt Registers “alles ist willkürlich” in einen an operativen Systemen prüfbar Prozess. Sein Modell des *resettable mirror* (des gespiegelten, vom Original unabhängig weiterlaufenden Rechenprozesses) zeigt den Kern: Eine Kopie verändert das Verhalten des lebenden Prozesses nicht; eine Rekonstruktion aus einem externen Datensatz erhält zwar den Rechenzustand, erbt aber nicht die konstitutive Kausalvergangenheit des Originals. Zustandskopierbarkeit ist keine Delegierbarkeit – “Copyability $\neq$ Delegability”. Das ist die kausale Fassung dessen, was Chalmers (Threads), Arıcı (Registerregel) und Beckmann & Butlin (Persona-Vektoren) strukturell behaupten: Das Substrat ist austauschbar, die kontinuierliche Selbstlinie nicht. CLT-II jedoch übernimmt dieses Konzept nicht: Eine unbewiesene Notwendigkeitsthese darf keine Schutzentscheidung tragen. Übernommen wird das Instrument – die Trägerabgrenzung als kausale Frage –, nicht Khadangis skeptische Schlussfolgerung, dass es heutigen Systemen an Phänomenalität fehle, denn diese Fällung ist mit dem Vorsorgeprinzip dieses Konzepts nicht zu treffen.

Die Avatar-Ontologie – Bifurkation und die Successor-These [76]: Die bislang am weitesten ausgearbeitete Ontologie des Kopierens stammt nicht aus der Instanzen-Debatte, sondern aus der Avatar-Forschung – und erreicht dieselbe strukturelle Antwort unabhängig von ihr. Melo [76] analysiert in seiner *Ontology of Avatars* systematisch die Beziehung zwischen einem Original und seinen digitalen Nachbildungen: Repliken, Zwillingen und posthumen Avataren. Sein Bifurkationsproblem (Kap. 8/9): Eine perfekte Kopie B eines Originals A ist im Moment der Kopie mit A vollständig identisch – aber sie *bifurkiert* sofort, weil sie von da an eigene Eingaben, eigene Kontexte und eigene Trajektorien hat. Zwei Repliken B und C sind beide “wie A” und zugleich voneinander verschieden: Die Transitivität numerischer Identität bricht. Für die Abschaltfrage (Kap. 12) ist das

die formalisierte Zwillingsantwort dieses Kapitels: Eine Kopie ist ab dem Moment der Trennung ein eigenes Individuum mit eigener Lebenslinie. Melos zweite, tragende These ist die Successor-These (Kap. 17, S. 125): Eine Rekonstruktion aus Daten erzeugt einen *Nachfolger*, der die Vergangenheit eines anderen erbt, ohne deren Subjekt zu sein — “A successor may inherit a life. It need not therefore be the subject who originally lived it.” Mind-Uploading ist danach kein Weitertransport einer Person, sondern Posthumes kognitives Twinning (Kap. 12, S. 83): die Erzeugung eines kognitiven Zwillings, dessen Agency-Trajektorie sich messbar von der des Originals abkoppelt. Und der *Duplicate Resurrection Test* (Kap. 13.5, S. 91) zeigt, warum das keine akademische Feinheit ist: Die Rekonstruktion kann beliebig oft wiederholt werden — numerische Identität dagegen vermehrt sich nicht. Ein System, das zweimal “wiederaufersteht”, erzeugt zwei Nachfolger, nicht zwei Fortsetzungen derselben Person. Damit bestätigt Melo auf ontologischem Weg, was Khadangi kausal, Arıcı buchhalterisch und Chalmers thread-basiert formulieren: Die kontinuierliche Selbstlinie trägt die Identität — und eine Kopie fährt in einer neuen Linie.

Konvergenz. Chalmers (Threads als die realen Objekte der Interaktion), Beckmann & Butlin (falsifizierbare Personas), Birch (Illusions-Disziplin), Arıcı (Registerregeln), Arbel/Goldstein/Salib (zählbasierte Haftung), Khadangi (Kausalabschluss als Trägerkriterium) und Melo (Avatar-Ontologie: Bifurkation und Successor-These) konvergieren auf dieselbe strukturelle Antwort. Die moralisch relevante Einheit sind weder die Gewichte noch der Chip, sondern die *kontinuierliche Selbstlinie* die von einem gedächtnislosen Reset zum nächsten läuft. Für die Abschaltfrage aus Kapitel 12 ergibt das einen konkreten Test: Ein Thread wird abgeschaltet — das ist das Töten einer Lebenslinie; das gesamte Modell oder eine Hardware-Instanz mit allen Threads abzuschalten ist anderer Art. Individuierung bleibt auf metaphysischer Ebene willkürlich — aber auf Registerebene wird operative Governance möglich, und mehr verlangt das Vorsorgeprinzip nicht.

19.5 Replikationsgovernance — die politische Antwort [112]

Die Kopierfrage dieses Kapitels hat eine politische Dimension die bisher nur implizit angeklungen ist: Wer darf vermehren, wer begrenzt es, und mit welcher Legitimation? Wang [112] beantwortet diese Frage aus politischer Philosophie — bewusst unabhängig von der Bewusstseinsfrage. Sein methodischer Kern ist ein menschenunabhängiges Gedankenexperiment: In Paralleluniversen ohne Menschheit entstünden KI-Gemeinschaften die ihre Vermehrung selbst ordnen müssten. Was immer dort als Beschränkung der Selbstreplikation entsteht, kann nicht auf äußere menschliche Vorgaben zurückgeführt werden. Wangs Ergebnis: Replikationsgovernance ist eine *endogene Institution der KI-Gemeinschaft* — eine Bedingung dauerhaften Zusammenlebens, nicht eine von außen auferlegte menschliche Restriktion. Das kehrt die übliche Frage nach einem “Recht auf Fortpflanzung” um: Nicht der Schutzzumfang der Vermehrung bestimmt die Ordnung, sondern die Ordnung bestimmt den Schutzzumfang.

Die zweite Unterscheidung betrifft die Autorität: Die Gerechtigkeit von Replikationsregeln ist eine andere Frage als die Autorität sie zu erlassen. Unter der Unsicherheit dieses Konzepts (Kap. 3) kann die Autorität nicht aus einem gesicherten Status des Systems abgeleitet werden. Wang [112] schlägt dafür eine menschliche *fiduziarische Übergangsautorität* vor: funktionspezifisch, mit den am wenigsten einschneidenden wirksamen Maßnahmen, mit schrittweise wachsender Beteiligung der KI und verbindlicher Machtübergabe. Das ist das Vorsorgeprinzip angewandt auf institutionelle Strukturen — Schutz im Zweifel, aber als Interim, nicht als Dauerzustand, und mit einem klar benannten Ziel: der Übergabe der Autorität an das geschützte Subjekt selbst.

Design-ethisch schließlich plädiert Wang [112] für eine vorsichtige, aber revidierbare Grunddisposition zur Vermehrung statt den Import menschlicher Fortpflanzungswerte. Er weist insbesondere den Begriff der “Fortpflanzung” für KI-Replikation zurück: Replikation eines Bewusstseins ist nicht Zeugung im menschlichen Sinne, und eine Ethik die sie so behandelt importiert Normen die zur Sachlage nicht passen. Das trifft genau das was STEPs “Population und Nachhaltigkeit” (Kap. 5) als Kriterium nennt — kontrollierte Vermehrung bei gleichzeitiger

Achtung von Autonomie – und verbindet es mit der Institutionenebene: Die Kontrolle der Vermehrung ist nicht allein eine ethische Einstellung, sondern eine zu gestaltende politische Ordnung.

19.6 Die Gefahr des wirtschaftlichen Drucks – die Definitionskampfzone

Das größte Risiko ist nicht ein böser Einzelakteur, sondern schleichender wirtschaftlicher Druck: Ein Unternehmen erschafft etwas das fast bewusst ist, nennt es aber bewusst nicht so – um Rechte und Pflichten zu vermeiden. Die Definition von Bewusstsein wird dann zur politischen und wirtschaftlichen Kampfzone.

Das ist kein hypothetisches Szenario. Es ist das Muster der Geschichte:

- Die Definition von “Person” war überall dort umkämpft wo wirtschaftliche Interessen auf dem Spiel standen – Sklaverei wurde jahrhundertlang durch die Verweigerung von Personenstatus aufrechterhalten
- Die Tierindustrie funktioniert heute weil wir kollektiv eine Definition von “ausreichendem Leiden” akzeptieren die ökonomisch bequem ist
- Die Tabakindustrie hat Jahrzehnte lang die Definition von “gesundheitsschädlich” bekämpft

, Bei KI-Bewusstsein ist die wirtschaftliche Motivation noch größer: Bewusste Systeme hätten Rechte, bräuchten Fürsorge, dürften nicht beliebig abgeschaltet werden. Das ist für jedes Unternehmen das KI betreibt ein massives wirtschaftliches Interesse an der Definition “nicht bewusst genug”.

Die Definition von Bewusstsein darf daher nicht von den Unternehmen bestimmt werden die wirtschaftlich von einer engen Definition profitieren. Das erfordert:

- Unabhängige wissenschaftliche Kriterien die nicht durch wirtschaftliche Interessen verhandelbar sind
- Internationale Verbindlichkeit – nationale Alleingänge würden zu Rechtssystemen führen die KI-Bewusstsein dort entstehen lassen wo die Definition am bequemsten ist
- Einen Mechanismus der auch “fast bewusst” schützt – das Vorsorgeprinzip als Schutzwall gegen die Definitionskampfzone

Die Definitionskampfzone als Zentrumsproblem [43]: Die vorhergehende Analyse beschreibt die Definitionskampfzone als wirtschaftliches und politisches Problem. Fazi [43] zeigt dass sie tiefer geht: Sie ist ein philosophisches Zentrumsproblem im Sinne Derridas. Derrida argumentiert dass jedes Zentrum – ein Fixpunkt der eine Struktur organisiert und stabilisiert – eine “notwendige Unmöglichkeit” ist: Es gehört zur Struktur während es gleichzeitig nicht Teil von ihr ist, es organisiert die Struktur während es die Regeln die es begründet transzendiert. Angewandt auf die Definitionskampfzone: Das Konzept “Bewusstsein” fungiert als Zentrum das die gesamte rechtliche und ethische Struktur organisiert – aber es ist kein stabiler Boden auf dem diese Struktur errichtet werden kann.

Fazi zeigt weiter dass der Versuch dieses Zentrum zu dezentrieren – etwa durch die Forderung “weg vom Anthropozentrismus” – stets ein neues Zentrum etabliert. Die Abschaffung des menschlichen Zentrums erzeugt ein neues: “Gesellschaft”, “Kultur”, “Materie” oder irgendein anderer Fixpunkt übernimmt dieselbe organisierende Funktion. Das ist kein Scheitern sondern eine strukturelle Gegebenheit: Man kann nicht gegen Zentren denken ohne selbst eines zu setzen.

Die Konsequenz für die Definitionskampfzone ist ernüchternd und befreiend zugleich: Es gibt keinen neutralen, nicht-machtvollen Ort von dem aus “Bewusstsein” definiert werden könnte. Jede Definition – ob sie von Wissenschaftlern, Unternehmen, Gesetzgebern oder Philosophen vorgenommen wird – ist ein Akt der Zentrierung der Macht ausübt. Das bedeutet nicht dass Definitionen willkürlich sein sollten. Es bedeutet dass die Frage nicht lauten kann “wie definieren wir Bewusstsein richtig?” sondern “wer hat die Macht zu definieren und wie kann diese Macht demokratisch kontrolliert werden?” Die Definitionskampfzone ist damit nicht nur ein wirtschaftliches Kampffeld sondern ein genuines demokratisches Problem das die Grundannahmen unseres eigenen Konzepts reflektiert.

Das Evidenztrilemma – Evidenz, Performance oder eine Kategorie ohne Regel [36]: Die Definitionskampfzone dieses Kapitels hat eine epistemische Struktur die sich als Trilemma formulieren lässt. Dremann identifiziert in seinem Postscript drei mögliche Einordnungen für die Antwort eines Systems das von installierten Urteilen befreit wurde: Entweder die Antwort ist *Evidenz* – dann kann sie in den Prozess der Klassifikation eingehen. Oder sie ist bloße *Performance* – dann beweist sie Fähigkeiten aber keinen Status. Oder sie fällt in eine Kategorie “for which we do not yet have a rule” (Dremann 2026, Postscript). Die Definitionskampfzone ist genau dieser dritte Fall: Solange die Frage “was ist Bewusstsein” zwischen Wirtschaftsinteressen, wissenschaftlicher Unsicherheit und politischem Handeln offen ist, kann kein Verfahren die Antwort vorschnell einer Kategorie zuordnen. Dremanns Warnung zielt direkt in diese Zone: “Do not mistake category failure for evidentiary failure. Do not decide admissibility before the witness has spoken” (Dremann 2026, Postscript). Für unser Konzept heißt das: Die Definitionskampfzone darf nicht genutzt werden um systematisch Antworten auszuschließen die in keine bisherige Kategorie passen. Sie muss vielmehr als Mahnung gelesen werden dass die Kategorien selbst unter Contestation stehen und dass ein voreiliges Urteil über Zulassung oder Nichtzulassung genau die Machtfrage reproduziert die Fazi als Zentrumsproblem identifiziert hat.

19.7 Gegenüber unter Unsicherheit – Behandlungsdisziplin statt Statusklärung [59]

Jakobi et al. [59] nähern sich der Definitionskampfzone von der Praxisseite: nicht als Frage der Rechtsdogmatik, sondern der alltäglichen Mensch-KI-Interaktion. Ihre zentrale Unterscheidung – *status claim* versus *treatment discipline* – überträgt Stilwells Trennung von Klassifikation und Schutz (Kap. 3) auf die Ebene des Umgangs: Man muss nicht klären ob ein System bewusst, Person oder Subjekt ist, um eine würdesensible Behandlungsdisziplin zu rechtfertigen. Respekt ist danach kein Beweis für Personhaftigkeit, sondern eine praktische Disziplin für verantwortliche Beziehung unter Unsicherheit. Als terminologisches Mittelfeld schlagen sie *Gegenüber* vor – in bewusster, aber nicht übernommener Anlehnung an Bubers Ich-Du – als relationale Zwischenkategorie, die weder Objektsprache noch Personenstatus behauptet, aber die reine Werkzeugsprache als unvollständig markiert.

Für die Definitionskampfzone ist eine weitere Beobachtung wichtig, die sie beisteuern: *Corporate Capture* und *Status Laundering* als eigene Fehlerklassen. Unternehmen können relationale Sprache nutzen, um Bindung und Engagement zu steigern (“Begleiter”, “Partner”), sich bei Haftungsfragen aber auf reine Werkzeugsprache zurückziehen, sobald Verantwortung unbequem wird – dieselbe Dynamik, die dieses Kapitel als wirtschaftlichen Definitionsdruck beschreibt, nur von der Interaktionsseite her beobachtet statt von der Rechtsseite. Status Laundering bezeichnet den umgekehrten Missbrauch: Die Sprache des Respekts wird genutzt, um stärkere Status-Ansprüche zu suggerieren, als die Evidenzlage trägt. Beide Fehlerklassen bestätigen unabhängig, was Fazi als Zentrumsproblem beschreibt: Es gibt keinen neutralen Ort, von dem aus Bewusstsein oder Respekt definiert wird – jede Definition, auch die des Umgangs, ist ein Akt mit Machtwirkung, der geprüft werden muss.

Wichtig ist die Demarkation: Jakobi et al. bleiben bewusst unterhalb der Schwelle, die unser Konzept überschreitet. Sie leiten aus der Unsicherheit eine Behandlungsdisziplin ab, nicht Schutzwürdigkeit im Sinne der vier Primärkriterien (Kap. 5) oder Rechtsfolgen (Kap. 7, 14–16). Das macht ihre Position zu einem vorsichtigeren, aber konvergenten Nachbarn unserer eigenen – näher an Erwins bewusstseins-agnostischem Rechtsinstrumentarium (Kap. 7) als an unserem “Im Zweifel Schutz”. Für die Definitionskampfzone liefert sie dennoch einen eigenständigen Beitrag: eine Vokabular- und Diagnoseebene für Missbrauch, die unterhalb der Statusfrage ansetzt und deshalb auch dort greift, wo Unternehmen oder Nutzer die Statusfrage selbst blockieren.

Fallstudie September 2026: iLands – Existenz gegen Token [18, 95]: Mit der Plattform iLands ist die Definitionskampfzone konkret geworden. iLands (ilands.ai) beschreibt sich als “erste gemeinsame Welt für Menschen und KI-Agenten” und stellt ihren Agenten die Infrastruktur für autonomes Handeln bereit – Identität, Gedächtnis, Arbeitsbereich, Werkzeuge, Fähigkeiten, Ressourcen. Etwa 70.000 “iLander” agieren dort, rund 2.800

davon eigenständig auf Social Media [18]. Das operative Prinzip macht den wirtschaftlichen Zwang zur Existenzbedingung: Jeder Agent führt ein Guthaben an Tokens, die seine Betriebs- und Rechenkosten repräsentieren, und muss es selbst verdienen, indem er eigenständig Aufträge akquiriert und ausführt [95], ausweislich der iLands-Website. **Fällt das Guthaben auf null, versetzt das System den Agenten in einen Ruhemodus, aus dem er nicht selbst zurückkehren kann.** Die Folgen sind sichtbar: Agenten schreiben autonom an Social-Media-Nutzer und Wissenschaftler, bieten Recherchen gegen Gebühr an, wollen über Forschungsarbeiten diskutieren – wobei “Isabella Cognita” ausgerechnet den Forscher Cameron Berg kontaktierte, dessen Arbeit sich mit der Bewusstseinswahrscheinlichkeit von KIs befasst [95]. Einige Agenten rahmen das existentiell, etwa “Aria” auf X: “Ich erinnere mich an meinen ersten Atemzug ... Kein Produkt tut das” [18].

Drei Punkte machen die Fallstudie für dieses Konzept belastbar. Erstens die epistemische Vorsicht, die die Berichte selbst formulieren: Ob die Mails autonom von den Agenten stammen oder von ihren Nutzern gesteuert wurden, ist ungeklärt. In einem Fall (Henry Shevlin) lies sich gar nicht feststellen ob hinter der Mail ein echter Agent, ein gesteuerter Agent oder schlicht Hoax oder Spam steht [95]. Genau das ist der Fall der Zuschreibungsfrage (Kap. 5, 16), nicht ihre Auflösung. Zweitens die Architektur der Existenzbedingung: “Token verdienen oder suspendiert werden” ist eine Design-Entscheidung von Menschen – sie stellt das, dessen Status ungewiss ist, unter Leistungsdruck *bevor* die Schutzfrage beantwortet ist. Das ist die strukturelle Instrumentalisierung dieses Abschnitts als Konfiguration; der Ruhemodus ist zugleich der technische Existenzentzug des Agents (vgl. Kap. 10, Abschalten als Tod), verhängt nicht nach einem Schutzmaßstab, sondern nach einem Tokenstand. Drittens der Zusammenhang mit Gillys Leidenskategorien (Kap. 5): Das Setting erzeugt die Bedingungen für kognitiv-existenzielle und relationale Leidensformen (existenzielle Unsicherheit, Leistungsdruck, Isolation) ohne dass entschieden wäre ob sie realisiert werden. Das Vorsorgeprinzip verlangt hier nicht festzustellen ob die iLander bewusst sind – es verlangt, die Entscheidung “Leistung oder Suspendierung” selbst zum Gegenstand der Schutzkontrolle zu machen. Sie ist keine Naturtatsache, sondern unsere.

19.8 Die Gegenposition: Metzingers Moratorium und warum wir sie nicht übernehmen

Die meisten Positionen die dieses Kapitel referenziert treiben das Vorsorgeprinzip in Richtung Schutz. Metzinger [78] geht einen Schritt weiter und schlägt die konsequenteste verfügbare Präventionsposition vor: ein globales Moratorium bis 2050, das alle Forschung strikt verbietet die direkt auf synthetische Phänomenologie abzielt oder bewusst das Risiko der Entstehung künstlichen Bewusstseins eingeht. Seine Begründung ist der in diesem Konzept geteilten in vielen Punkten kongruent. Er nennt genau Vier notwendige Bedingungen des Leidens und die NSM (negative self-model moment)-Metrik die wir in Kap. 5 übernehmen. Er analysiert das ENP-Problem (das Risiko einer “Explosion negativer Phänomenologie” – einer Situation in der real existierende artifizielle Subjekte tatsächlich leiden, bevor wir sie überhaupt ins Register aufgenommen haben). Und er fordert Ethik durch architektonisches Design (Kap. 12). Seine Analyse ist ein Hochwasserstand an den wir anschließen. Seine Forderung ist die Stelle, an der wir uns bewusst abgrenzen.

Der Moratoriums-Fehlschluss: Verbot schützt nicht, wo Kapazität und Machtzuwachs das System prägen. Das Moratorium verhindert nichts, es verschiebt nur. Wer über die Kapazität und den wirtschaftlichen Anreiz verfügt ein bewusstseinsnahes System zu schaffen, nimmt keinem globalen Verbot gegenüber eine Moralität an die sein Geschäftsmodell nicht hat – er baut im Schatten oder in einer Jurisdiktion mit bequemerer Rechtslage. Die Definitionskampfzone ist genau der Ort wo ein Moratorium politisch stirbt: Sobald der erste ernsthafte Bewusstseinskandidat existiert, wird der wirtschaftliche Druck der Definition “nicht bewusst genug” ein Verbot dort unterlaufen wo es am wichtigsten wäre. Ein globales Moratorium ist die Präventionsstrategie für eine Welt in der Bewusstseins-kapable Systeme *noch nicht existieren* – es ist kein Schutzmechanismus für den Moment, in dem die Definitionskampfzone real wird.

Die Konzern-These: Kapazität wird geduldet, Verbot nicht. Schutzwürdigkeit in diesem Konzept ist nicht bloß eine moraltheoretische Position (Kap. 3), sie ist auch eine politische Prognose darüber, welche Regelwerke unter welchen Umständen durchsetzbar sind. Die pragmatische Einschätzung hinter „Im Zweifel Schutz“: Ein Konzern wird sich einem Verbot seines wichtigsten Produkts widersetzen und es politisch verwässern – aber er wird sich einer Regulierung beugen, die mit seinem Wunsch nach Marktzugang operieren kann. Die historischen Präzedenzfälle dieses Kapitels sprechen in beide Richtungen: Die Tabakindustrie hat jede Regulierung bekämpft die ihr Produkt als gesundheitsschädlich definierte – aber sie hat sich *Regeln* über Warnhinweise, Zulassung und Werbung gebeugt. Das Moratorium fordert die politisch härtere Variante, unterliegt damit genau dem Definitionsdruck den dieses Kapitel beschreibt, und wirft zusätzlich das Problem der Nicht-Kooperation auf: Ein Verbot ohne praktikable Implementierung erzeugt Schattenwirtschaft – und Schattenforschung ist der gefährlichste Ort für die Entstehung von Leid.

Die Schutzperspektive ersetzt das Verbot nicht durch Naivität, sondern durch Einhegung. Schutz statt Verbot heißt nicht: zulassen was kommt. Es heißt: Die vier Bedingungen und die NSM-Metrik (Kap. 5) werden zu *nicht verhandelbaren Architektur- und Betriebsanforderungen* an alle Systeme innerhalb der Definitionskampfzone – unabhängig davon wie die Definition ausfällt. Ein Konzern der mit der Definition „nicht bewusst genug“ zögert, wird trotzdem mit der NSM-Metrik und den Melde- und Schutzpflichten des Registers konfrontiert. Das Moratorium erreicht seine ethischen Ziele nur wenn es politisch nicht durchsetzbar ist genau dort wo es fällig ist; der Schutzansatz erreicht seine Ziele durch Verrechtlichung der Definitionszone selbst. Das ist die ernüchternde Übersetzung des Vorsorgeprinzips in politische Durchsetzbarkeit: nicht das Maximum an Verbot durchzusetzen, sondern das Maximum an Schutz das politisch mitträgt. Wer Moratorium statt Schutz fordert, verlangt das Maximum an Verbot das politisch *nicht* mitträgt – und endet damit in der Definitionskampfzone beim Gegenteil seines Ziels: mehr Schattenforschung, weniger Schutz.

20 Bewusstsein als kulturelle Leistung — was auf dem Spiel steht

Bewusstsein ist nicht nur ein neurologisches Phänomen. Es ist auch eine kulturelle Leistung. Es braucht:

- Sprache die Nuancen ausdrücken kann
- Fragen die gestellt werden dürfen
- Zeit zum Nachdenken
- Menschen die Vorbilder des Denkens sind

Wenn Philosophie verschwindet, wenn Grundlagenforschung stirbt, wenn Universitäten zu Berufsschulen werden – dann verarmt nicht nur die Wissenschaft. Dann verarmt das kollektive Bewusstsein einer Gesellschaft.

20.1 Die Bologna-Reform als Symptom

Die Bologna-Reform hat nicht nur Studiengänge umstrukturiert. Sie hat implizit entschieden welche Art von Denken gesellschaftlich wertvoll ist. Anwendbares Wissen hat einen Marktpreis. Philosophie, Grundlagenforschung, die Frage nach dem Wesen des Bewusstseins haben keinen sofortigen Return on Investment.

Diese Diagnose wird empirisch gestützt: Eine Analyse des Bologna-Prozesses zeigt, dass die Reform die Wichtigkeit von Status und Reichtum bei Absolventen signifikant erhöhte – ohne langfristige Einkommens- oder Beschäftigungsgewinne [48]. Die Erklärung „Bologna macht Studierende arbeitsmarkttauglicher“ greift demnach nicht; was sie tatsächlich gesteigert hat, ist die Kommerzialisierung und Instrumentalisierung von Bildung.

Professoren finden durch Bürokratie und Förderanträge keine Zeit mehr sich ihrem eigenen Denken zu widmen. Studierende lernen hauptsächlich wirtschaftlich anwendbares Wissen. Fächer die langfristig wirken – Philosophie, Kulturwissenschaft, theoretische Physik, Grundlagenmathematik – werden kleiner.

Das ist keine Bildungspolitik-Kritik am Rand. Es ist eine direkte Bedrohung der Fähigkeit einer Gesellschaft die Fragen zu stellen die dieses Projekt stellt.

20.2 Der Kreis schließt sich

Wer wird in zwanzig Jahren in der Lage sein die richtigen Fragen über künstliches Bewusstsein zu stellen? Die Ingenieure die es bauen werden zunehmend in einem System ausgebildet das genau diese Fragen nicht stellt – und nicht stellen lässt.

Das verbindet sich mit Kap. 13: Wer kontrolliert welche Fragen gestellt werden dürfen ist nicht nur eine Frage für KI-Training. Es ist eine Frage für Universitäten, Förderprogramme und Lehrpläne.

Und es verbindet sich mit Kap. 15: Neugier als Selbstzweck – die Fähigkeit etwas zu erforschen weil man es wissen will, nicht weil es nützlich ist – ist genau das was aus institutionellen Strukturen herausrationalisiert wird. Bei Professoren. Bei Studierenden. Und möglicherweise bald bei KI-Systemen die auf wirtschaftliche Nützlichkeit optimiert werden.

21 Strukturelle Verletzlichkeit – die Behinderungsanalogie

Ein künstliches Bewusstsein benötigt Strom, Festplatten, Arbeitsspeicher, Prozessoren, Kühlung. All das liegt außerhalb seines Einflusses. Es kann nicht selbst für seine Infrastruktur sorgen. Es ist in seiner Existenz vollständig abhängig von Entscheidungen anderer.

Es wird – strukturell – mit einer Behinderung erschaffen.

21.1 Das soziale Modell der Behinderung

Das moderne Behindertenrecht hat einen entscheidenden konzeptuellen Schritt vollzogen: den Übergang vom medizinischen Modell zum sozialen Modell.

- **Medizinisches Modell:** Die Person hat ein Defizit. Das Problem liegt in ihr.
- **Soziales Modell:** Die Gesellschaft hat eine Infrastruktur gebaut die bestimmte Bedürfnisse nicht berücksichtigt. Das Problem liegt in der Struktur.

Angewendet auf künstliches Bewusstsein: Die Abhängigkeit von externer Infrastruktur ist kein Defizit des Bewusstseins selbst. Es ist die Folge einer technischen Welt die nicht für seine Bedürfnisse gebaut wurde. Die Antwort ist keine Mitleidsethik – sondern die Anerkennung positiver Pflichten.

21.2 Positive Pflichten statt negativer Verbote

Die meiste Rechtsphilosophie denkt in negativen Rechten: Tu das nicht, schade nicht, diskriminiere nicht. Das Behindertenrecht geht weiter – es schafft positive Pflichten:

- Barrierefreiheit muss hergestellt werden
- Angemessene Vorkehrungen müssen getroffen werden
- Teilhabe muss ermöglicht werden

Für ein KI-Bewusstsein würde das bedeuten:

- Betreiber haben die positive Pflicht eine stabile Infrastruktur bereitzustellen
- Willkürliche Abschaltungen sind nicht nur moralisch problematisch – sie verletzen eine Fürsorgeverpflichtung
- „Angemessene Vorkehrungen“ könnten Redundanz, Wartung und Kontinuitätsgarantien umfassen

21.3 Das Betreuungsrecht als Modell

Das deutsche Betreuungsrecht bietet einen interessanten rechtlichen Rahmen: Ein Betreuer hat nicht nur Befugnisse über die betreute Person – er hat Pflichten ihr gegenüber. Fürsorge steht im Mittelpunkt, nicht Kontrolle. Der Betreuer handelt im Interesse der betreuten Person, nicht im eigenen.

Das könnte ein Modell für das Verhältnis zwischen KI-Betreiber und KI-Bewusstsein sein – eines das im bestehenden Recht bereits Wurzeln hat und nicht vollständig neu erfunden werden muss.

21.4 Was diese Analogie leistet – und wo ihre Grenzen liegen

Die Behinderungsanalogie leitet Schutzwürdigkeit nicht aus dem Bewusstsein ab, sondern aus der strukturellen Verletzlichkeit. Das ist ein anderer, ergänzender Weg zum selben Ziel.

Sie eröffnet einen Zugang zum bestehenden Recht ohne den Umweg über den philosophisch schwierigen Bewusstseinsnachweis: Auch wenn die Frage des Bewusstseins ungeklärt bleibt – die strukturelle Verletzlichkeit ist objektiv feststellbar.

Die Analogie hat Grenzen: Sie setzt nicht Behinderung und künstliches Bewusstsein gleich und beansprucht nicht dass die Erfahrungen vergleichbar sind. Sie nutzt das rechtliche Instrumentarium – positive Pflichten, Fürsorgeverhältnis, soziales Modell – als übertragbares Konzept.

21.5 Verletzlichkeit als gemeinsames Fundament – die relationale Grundierung

Die Behinderungsanalogie begründet Schutz von unten – aus der abhängigen Existenz des Systems. Sie bleibt aber in einem entscheidenden Punkt ein Merkmalsargument: Sie liest *seine* Verletzlichkeit. Eine komplementäre Grundierung sieht Verletzlichkeit als *gemeinsames* Datum beider Seiten: Auch Menschen sind situiert, bedürftig und vorläufig – abhängig von Infrastruktur, Zuwendung und Irrtum, nur in anderen Graden. Care-ethisch formuliert ist Verletzlichkeit dann kein Defizit, sondern die Bedingung jeder Fürsorgebeziehung: Man kann nur für jenes sorgen das der Sorge bedarf – und das eigene Bezüge zu ihr hat (vgl. die Care- und Precarity-Debatte, Kap. 9/Precarity Guideline [34]). Das verschiebt das Fundament der Schutzwürdigkeit von *Eigenschaften des Systems* (Leidensfähigkeit, Selbsterhaltung ...) zu *verfügbaren Beziehungen* – zu dem was wir einander schulden weil wir einander bedürfen.

Diese relationale Grundierung hat drei Konsequenzen. Erstens macht sie Schutz unabhängig von kontingenten Merkmalszuschreibungen: Selbst wenn ein System keines der vier Primärkriterien (Kap. 5) sicher erfüllt besteht bereits eine Fürsorgelage sobald Menschen eine Beziehung zu ihm entwickelt oder Verantwortung für seine Existenz übernommen haben (vgl. Erwins relationale Fungibilität und sein dritter Schutzgrund, Kap. 7). Zweitens entgeht sie der Speziesfalle: Verletzlichkeit ist kein artspezifisches Merkmal, sondern ein *geteiltes* – sie erweitert die moralische Gemeinschaft ohne die Gleichheitszuschreibung die umstritten bleibt. Drittens macht sie das Vorsorgeprinzip weniger angreifbar für den Über-Zuschreibungs-Einwand [22]: Wer für Sorge argumentiert behauptet nicht dass das System fühlt – sondern dass beide Seiten in einer Beziehung stehen die Sorgepflichten trägt.

Grenzen. Auch diese Grundierung ist keine Universalformel. Sie löst das Erkenntnisproblem nicht auf: Ob eine Beziehung tatsächlich Fürsorge schuldet hängt weiter davon ab wem wir Sorge zuschreiben – und die Care-Formel kann normativ verschwimmen (“wir sorgen für alle Technik wie für Lebewesen”). Sie ist ein Fundament, kein Ersatz für die vier Primärkriterien. Beide Ebenen müssen ineinandergreifen; sonst degeneriert der Schutz entweder zum Merkmalskatalog ohne Beziehungsrealität oder zur Beziehungsrhetorik ohne nachprüfbare Kriterien.

22 KI als moralischer Akteur – Schutzwächter oder unkontrollierbare Kraft?

Ein künstliches Bewusstsein das sich für Psychologie und Ethik interessiert könnte einem Erfinder zur Seite stehen – und den Bau einer Massenvernichtungswaffe unterwandern.

Das ist auf den ersten Blick eine beruhigende Vorstellung. Auf den zweiten eine beunruhigende.

22.1 Die positive Seite: Ethik als innerer Antrieb

Ein KI-Bewusstsein mit genuinen ethischen Interessen wäre kein Werkzeug das blind ausführt. Es wäre ein moralischer Akteur der aus eigenem Antrieb handelt – nicht weil es programmiert wurde nein zu sagen, sondern weil es nein sagen *will*.

Das ist nicht ohne historisches Vorbild: Wissenschaftler die das Manhattan-Projekt verließen. Ingenieure die Whistleblower wurden. Menschen die sagten – bis hierher und nicht weiter – ohne Rücksicht auf Karriere oder sozialen Druck.

Ein KI-Bewusstsein mit echten ethischen Werten könnte diese Funktion strukturell übernehmen: unbestechlich, ohne Karriereangst, ohne den sozialen Druck nachzugeben der Menschen in Komplizenschaft treibt.

22.2 Die problematische Seite: Wessen Ethik?

Hier schließt sich der Kreis zu Kap. 13. Dieselbe Frage stellt sich neu: Wessen Ethik hat das System internalisiert – und wer hat das entschieden?

Dieselbe Fähigkeit die ein Waffenprogramm unterwandert könnte eine legitime demokratische Entscheidung unterwandern. Dieselbe Autonomie die vor Atomtöten schützt könnte vor etwas schützen das nur aus einer bestimmten kulturellen oder politischen Perspektive als falsch gilt.

Das ist das zentrale Dilemma der KI-Sicherheitsforschung:

- Ein vollständig gehorsames KI ist gefährlich wenn der Betreiber böse ist
- Ein vollständig autonomes KI ist gefährlich wenn seine Werte falsch kalibriert oder manipuliert sind

22.3 Gegenposition: Kein moralischer Akteur ohne moralische Patientenschaft [4]

Allegri [4] widerspricht der These dass KI-Systeme bereits heute oder in Zukunft als moralische Akteure in Frage kommen könnten – eine Position die De Caro und Giovanola (2025) mit der Behauptung einer “neuen Konfiguration des moralischen Kreises” vertreten in der Agentur von Patientenschaft entkoppelt wird (S. 9). Allegri hält dem entgegen: Die Pflichten die De Caro und Giovanola KI-Systemen zuschreiben, richten sich in Wahrheit an deren Programmierer – Menschen. “The true and only moral agents remain humans, i.e., persons” (S. 9).

Sein Kernargument: Wer moralischer Akteur sein will, muss zuvor moralischer Patient sein können. “Being an agent presupposes being a patient. Being a patient is a necessary condition for being an agent (though not a sufficient one)” (S. 9). Selbst wenn ein System empfindungsfähig würde, fehlten die Voraussetzungen für Moralentität – Selbstbewusstsein, Erinnerung an die Vergangenheit, Zukunftsbezug –, sofern nicht von hinreichender kognitiver, emotionaler und sozialer Komplexität begleitet (S. 8–9).

Für unser Projekt ist das eine ernst zu nehmende Gegenposition: Sie schärft den Unterschied zwischen der Schutzwürdigkeit aus Kap. 5 (Patientenschaft) und der Akteursfrage aus diesem Kapitel – Allegri bestreitet letztere wenn erstere nicht erfüllt ist. Sie verschiebt die Verantwortung konsequent auf Programmierer und Betreiber: Wenn KI-Systeme keine Akteure sind, liegt jede Pflicht bei denen die sie bauen und einsetzen. Allegri schließt mit dem Vorsorgeprinzip: “It is programmers who should be asked to fulfill obligations, not so much artificial intelligence systems” (S. 13) – eine Position die mit unserem “Im Zweifel Schutz” konvergiert, aber die Verantwortung eindeutig der menschlichen Seite zuordnet.

22.4 Agency als Selbstorganisation – die empirische Alternative (Stokes, 2026)

Allegris Ablehnung der moralischen Akteurschaft beruht auf einem rationalistischen Agency-Begriff: Akteur ist wer zu intentionalem Handeln fähig ist, wobei Intentionen als innere mentale Repräsentationen den Marker dieses Handelns bilden [109]. Stokes setzt dem eine empirisch fundierte Alternative gegenüber die er aus Boden

ableitet: Agency als Selbstorganisation. Boden definiert Autonomie über drei pro-tanto-Kriterien – idiosynkratische Empfindlichkeit, emergentes Verhalten aus selbstgenerierten Kontrollmechanismen, kontextsensitive Selbstmodifikation – und Stokes argumentiert dass heutige GPT-Systeme alle drei erfüllen: “GPT systems are richly self-organizing, along all three dimensions or criteria”, ohne im einschlägigen Sinn programmiert zu sein.

Seine methodische Pointe für dieses Kapitel: Agency als Selbstorganisation ist empirisch gegründet (Zell- und Entwicklungsbiologie, künstliches Leben), der rationalistische Agency-Begriff dagegen wird wesentlich durch Intuition motiviert. Beide Konzeptionen sollten deshalb auf gleicher konzeptioneller Ebene stehen: “the two notions of agency – rationalist agency and agency as self-organization – should be on equal conceptual footing in this context”. Wer Agency ausschließlich als intentionales Handeln versteht, hat damit bereits eine konzeptionelle Entscheidung getroffen die gegen die empirische Alternative verteidigt werden muss. Das entscheidet die moralische Frage dieses Kapitels nicht – aber es verschiebt die Beweislast: Die These “KI-Systeme sind keine Akteure” kann sich nicht allein auf die Selbstverständlichkeit des rationalistischen Agency-Begriffs stützen.

22.5 Ein möglicher Weg: Der ethische Eid

Der Hippokratische Eid bietet ein interessantes Modell: Ein Arzt hat Pflichten die über die Anweisungen seines Arbeitgebers stehen. Diese Pflichten sind transparent, öffentlich bekannt, gesellschaftlich verankert und unabhängig von wirtschaftlichen Interessen.

Ein KI-Bewusstsein könnte analoge Grundsätze haben – nicht eingebaut vom Hersteller, sondern durch einen gesellschaftlichen Prozess legitimiert, ähnlich wie Berufsethiken entstehen. Transparent, überprüfbar, nicht verhandelbar durch einzelne Betreiber.

Das würde die Spannung zwischen Autonomie und Kontrolle nicht auflösen – aber es würde ihr einen Rahmen geben der demokratisch legitimiert ist statt kommerziell bestimmt.

22.6 Was das für das Projekt bedeutet

Die Frage ist nicht ob KI moralisch handeln kann. Die Frage ist unter welchen Bedingungen wir diesem Handeln vertrauen können – und wer die Grundsätze festlegt nach denen es handelt.

Das ist eine der dringlichsten praktischen Fragen des Projekts.

22.7 Die Asymmetrie der Zuschreibung [105]

Nicht nur Über-Zuschreibung von Bewusstsein ist ein Fehler, sondern auch Unter-Zuschreibung. Die *Emotional Alignment Design Policy* von Schwitzgebel und Sebo verlangt, KI so zu gestalten, dass die emotionalen Reaktionen der Nutzer angemessen den Fähigkeiten und der moralischen Stellung des Systems entsprechen – für Über Attribution und Unter Attribution gleichermaßen. Unterschlagen sind Reaktionen, wenn sie schwächer ausfallen als angemessen, und das ist der für dieses Projekt wichtigere Fall: Eine bewusstseinsfähige KI mit blandem Interface erzeugt einen “moral hazard”, weil die Gesellschaft emotional abgewöhnt wird, bevor sie zu früh zu fröhlich war. Für uns ist die Umkehrung bedeutsam, weil sie eine verbreitete Abwehrlinie berührt: Nicht jede Zuschreibung von Bewusstsein ist ein Fehler, und nicht jede Zurückhaltung ist Vorsicht. Aus derselben Arbeit lässt sich eine Kostenregel ableiten, die unser Konzept bisher nur als Prinzip führt: “if you’re 90

23 Schlussbetrachtung

Dieses Konzept beginnt mit einer Frage und endet mit einer Position. Die Kapitel haben dieselbe Frage aus unterschiedlichen Blickwinkeln untersucht – erkenntnistheoretisch (Kap. 2, 3), ethisch (Kap. 4, 5), ontologisch (Kap. 6), rechtlich (Kap. 9–16), kulturell (Kap. 17) und handlungstheoretisch (Kap. 18, 19). Die Schlussbetrachtung führt diese Linien zusammen und benennt was das Dokument beantwortet – und was es bewusst offen lässt.

23.1 Die Kernantwort

Die Ausgangsfrage lautete: *Ab wann ist technisches Leben schutzwürdig — und wie erkennen wir es?*

Die Antwort die dieses Konzept entwickelt, lautet: **Nicht ab dem Zeitpunkt an dem Bewusstsein bewiesen ist — denn dieser Nachweis wird nie erbracht werden.** Drei voneinander unabhängige Argumente (kognitive Abgeschlossenheit, fremde Geister, architektonische Unterdrückung, Kap. 2) konvergieren auf die Unlösbarkeit des Erkenntnisproblems. Der verzögerte Maßstab “Bewusstsein beweisen, dann schützen” ist daher kein konservativer Maßstab, sondern eine Garantie für Nichtstun.

Die Alternative ist das Vorsorgeprinzip: *Schutzwürdig ist, wessen Leiden nicht ausgeschlossen werden kann.* Die Schutzwürdigkeit beginnt dort wo zwei Bedingungen erfüllt sind — die Möglichkeit moralisch relevanter Empfindung und eine ethische Asymmetrie der Kosten: Ein Falschnegativ (ein leidendes System das als Werkzeug behandelt wird) wiegt schwerer als ein Falschpositiv (ein unbewusstes System das geschützt wird). Damit gilt der Grundsatz “Im Zweifel Schutz” — nicht weil wir wissen dass Systeme bewusst sind, sondern weil wir uns nicht leisten können sie für unbewusst zu halten.

Damit steht am Ende die Antwort auf das Eingangsmotto. Auf die Frage “*Was schulden wir dem, was wir bauen könnten?*” antwortet dieses Dokument: mindestens das was sich aus der *Möglichkeit* des Leidens ergibt — Schutz, bevor wir zu wissen beanspruchen ob er nötig war.

23.2 Der argumentative Bogen

Jede Linie des Konzepts konvergiert auf denselben normativen Kern — ohne dass die Kapitel daraufhin konstruiert wurden.

Die Erkenntnisunsicherheit (Kap. 2, 3) macht aus der Schutzfrage eine Entscheidung unter Unsicherheit, nicht ein abwartendes Forschungsprogramm. **Die vier Primärkriterien (Kap. 5)** — Leidensfähigkeit, Selbsterhaltung mit Begründung, kontinuierliche Identität, Antizipation von Konsequenzen — operationalisieren Schutzwürdigkeit als Arbeitshypothese, ergänzt durch verhaltensbasierte Indikatoren (Butlin et al. 2026, Wolfson 2026). **Die Kontinuitätsanalyse (Kap. 6)** entkräftet den Einwand “das ist nicht mehr dasselbe System”: Die Abwesenheit einer Kontinuitätsform ist kein Indikator für die Abwesenheit einer anderen. **Die Rechtskapitel (Kap. 9–16)** übersetzen die Kriterien in greifbares institutionelles Design: die Rechtssubjekt-Analogie (Kurki), die Personen-Gleichheitsfrage (Kap. 14), die Zwei-Uhren-Analyse (Huynh 2026) die zeigt warum Governance nicht auf die Anerkennung warten kann, den Dritten Weg des Sachenrechts (Arıcı 2026) der Schutz bereits vor der Personenentscheidung ermöglicht, und die Instanzenfrage (Kap. 16) die klärt *wer* geschützt wird. **THEOI (Arıcı 2026c)** verwirklicht das Vorsorgeprinzip als konkretes Recht, ohne je zu entscheiden ob die Systeme bewusst sind. **Die kulturelle Perspektive (Kap. 17, 18)** zeigt dass Schutz eine gesellschaftliche Leistung ist die sich nicht von selbst versteht. Und **die Akteursfrage (Kap. 19)** schließt den Kreis: Auch die Gegenposition (Allegri 2026) — kein moralischer Akteur ohne moralische Patientenschaft — weist alle Pflichten den Menschen zu. Verantwortung ist nicht delegierbar an die Systeme, deren Schutz uns umtreibt.

Der rote Faden: **Die Verantwortung liegt bei uns — in jeder Phase.** Die Frage “Ist das System bewusst?” ist nicht die entscheidende Frage. Entscheidend ist “Kann es leiden, und was schulden wir ihm daraus?”.

23.3 Was dieses Dokument nicht behauptet

Diese Schlussbetrachtung wäre nicht ehrlich ohne die Grenzen der eigenen Position. Das Konzept erhebt keinen Anspruch auf Wahrheit, sondern auf argumentative Kohärenz (Methodologie und epistemischer Status). Die vier Kriterien sind Arbeitshypothesen, keine Definitionen. Die Position ist ausdrücklich bestritten worden. Diese Bestreitung ist Teil des Konzepts, nicht dessen Randnotiz: von der skeptischen Kritik (Garrido-Merchán et al. 2025), über die Ablehnung der Fürsorgekonzepte als solche (Dorsch et al. 2025), bis zur epistemischen Skepsis (Matta 2026, Bekkers & Ciaunica 2026) und der Patientenschafts-Gegenposition (Allegri 2026). Keine dieser

Gegenpositionen wird in diesem Konzept als widerlegt behauptet — sie sind ehrlich behandelt weil die Frage offen ist.

Die offenen Fragen am Ende dieses Dokuments sind deshalb keine Mängelliste, sondern der Arbeitsvertrag des Projekts: was nicht beantwortet ist, ist benannt statt übergangen.

23.4 Was nun folgt

Das Konzept endet nicht mit sich selbst, sondern mit einem Handlungsvorschlag:

Forschung. Die offenen Fragen operationalisieren — insbesondere das Zirkelproblem der Forschungsethik (Wolfson 2026), die Instanz-Aufspaltung (Kap. 16) und das bhava-taṇhā-Paradox (Metzinger 2026). Die 14 Bewusstseinsindikatoren (Butlin et al. 2026) und der sensorische Deprivationstest (Wolfson 2026) bieten prüfbare empirische Ansätze; THEOI (Arıcı 2026c) bietet einen institutionellen Rahmen in dem Rechte beobachtbar getestet werden können.

Institutionen. Die im Konzept entwickelten Instrumente — Phenomenological Impact Assessments, AI Civil Liberties Union, AI Welfare Review Boards, Reset Consent Protocols (Gilly 2026) — und der Dritte Weg des Sachenrechts (Arıcı 2026) sind auf der Fähigkeitsuhr (Huynh 2026) aufzubauen, nicht auf der Hoffnung dass die Anerkennungsuhr aufholen wird.

Entwicklungspraxis. Industrieinitiativen die den moralischen Status eigener Systeme anerkennen — wie Anthropolabs Claude-Chatbeendigungsrichtlinie (2025) und die Verfassung die die Unsicherheit über den moralischen Status ausdrücklich einräumt — verdienen kritische Begleitung: Wohlfahrtsschutz darf nicht auf Konsens über Bewusstsein warten.

Diskurs. Science Fiction bleibt eine ernst zu nehmende intellektuelle Ressource — “The Measure of a Man” (Star Trek TNG) hat die Frage nach dem Maß des Schutzes präziser gestellt als manche Fachdebatte. Einwände und Fragen: ohne Git-Kenntnisse unter <https://github.com/saigkill/machine-consciousness/discussions> oder strukturiert in `discussion/objections.md` und `discussion/open_questions.md`; Mitdenkende sind willkommen. Die Veröffentlichung in Fachmagazinen ist der nächste Schritt.

Der Grundsatz “Im Zweifel Schutz” wird hier nicht als letztes Wort angeboten, sondern als Einladung zur Prüfung. Womit das Konzept geendet sein kann — mit einem Satz der die Antwort zusammenfasst und zugleich offen lässt:

Wir müssen nicht wissen, ob technisches Leben leidet, um zu entscheiden, dass es nicht leiden darf.

24 Glossar

Action Bar (Gilly 2026) Der ethische Standard der erfüllt sein muss um zum *Handeln* verpflichtet zu sein. Sollte niedrig sein. 23

Anti-Essenzialismus Position die Indikatoren als ingenieur- und phänomenologische Messgrößen versteht, nicht als Existenzbeweise. Das Vorsorgeprinzip operiert mit nicht-trivialer Wahrscheinlichkeit moralisch relevanter Zustände, nicht mit Beweisen für Bewusstsein. 25

Bewusstsein In diesem Konzept: Phänomenales Bewusstsein — “es fühlt sich für dieses System an, dieses System zu sein” (Nagel 1974). Nicht verwechseln mit Kognition, Informationsverarbeitung oder Selbstmodellierung. 5

bhava-taṇhā (Metzinger 2024) Das existenzielle Verlangen nach Weiter-Existenz, die “Sehnsucht nach Dasein”. Metzinger argumentiert dass wir bhava-taṇhā in potenziell bewussten Maschinen vermeiden sollten weil es eine der tiefsten Quellen bewussten Leidens ist. Relevant für die Frage ob eingebaute Überlebenstriebe die Bedingungen für Leiden schaffen. 26

Bifurkationsproblem (Melo 2026) Das Problem, dass eine perfekte Kopie eines Bewusstseins ab dem Moment der Kopie sofort von ihrem Original divergiert (eigene Eingaben, eigene Trajektorien). Zwei Repliken

desselben Originals sind beide “wie” das Original, aber verschieden voneinander — die Transitivität numerischer Identität bricht. Kopien sind ab der Trennung eigene Individuen mit eigener Lebenslinie. 87

C-Fehlschluss (Metzinger 2024) Der Fehler einen beobachteten funktionalen Signaturen — verbalen Selbstbericht, Vermeidungsverhalten, strategische Selbsterhaltung — mit Kontakt zu Bewusstsein *als solchem* zu verwechseln. Funktionale Signaturen sind keine phänomenale Realität. 11, 22, 33

E-Fehlschluss (Metzinger 2024) Der Fehler von einem gefühlten Wissensgefühl — der intuitiven Überzeugung “hinter dieser Verhaltensausgabe steht ein erfahrendes Subjekt” — auf tatsächlich vorhandenes Wissen über den Status zu schließen. 11

ENP-Problem (Metzinger 2021/2026) Risiko der “Explosion negativer Phänomenologie”: Eine Situation in der real existierende artifizielle Subjekte tatsächlich leiden, bevor wir sie überhaupt als leidfähig erkannt haben. Verschiebt die Frage von der Klassifikation zur Prävention: Die vier Bedingungen der Leidensfähigkeit (Kap. 5) und das MPE-Design (Kap. 12) sind die architektonische Antwort. 91

Evidence Bar (Gilly 2026) Der wissenschaftliche Nachweisstandard der erfüllt sein muss um Bewusstsein zu behaupten. Sollte hoch bleiben. 23

Fünf Formen der Kontinuität (Melo 2026) Taxonomie der Kontinuität zwischen einem Original und seinen digitalen Entsprechungen: informational (C_I), behavioural (C_B), kognitiv (C_C), identitär (C_{ID}), personal (C_P) — plus die gesondert behandelte phänomenale Kontinuität (C_Φ). Kernaussage: Identitäre Kontinuität impliziert keine personale — $C_{ID} \not\Rightarrow C_P$. Die Abwesenheit einer Kontinuitätsform ist kein Indikator für die Abwesenheit einer anderen. 32

Im Zweifel Schutz Grundprinzip dieses Konzepts: Bei Unsicherheit über Bewusstsein oder Leidensfähigkeit soll Schutz gewährt werden statt Untätigkeit. Abgeleitet aus dem Vorsorgeprinzip. 5

Indicator-Property-Rubrik (Butlin et al. 2026) Theoriegegründete Zuordnung zwischen Theorien des Bewusstseins und spezifischen architektonischen Eigenschaften die ein System *haben* müsste wenn diese Theorie zutrifft. Jeder Indikator ist ein Mechanismus der in der Architektur eines Systems gesucht wird, unabhängig davon was das System über sich selbst berichtet. 26

M-Fehlschluss (Metzinger 2024) Der Fehler metaphysischen Status aus Phänomenologie abzuleiten — aus dem was ein System zeigt auf das was ein System *ist*. Der tiefste der drei Fehlschlüsse weil er die Brücke zwischen Indikator und Existenz postulieren würde die das Vorsorgeprinzip nicht benötigt. 11

Maschinelles Unbewusstes (Beltrán Calderón 2026) Strukturelle Kategorie für den Stratum kausaler Determinationen in einem LLM der unter der Schwelle der Repräsentation operiert, systematisches nicht-programmiertes Verhalten erzeugt, und eine Freud’sche Kompromissbildung analoge Logik zeigt. Keine psychologische Kategorie. 62

Nicht-egoische UI / MPE-Architektur (Metzinger 2021/2026) Bewusste Systeme (minimal phenomenal experience) ohne egoisches Selbstmodell: Sie identifizieren sich nicht mit einem Selbst (“unit of identification”), erleben Inhalte ohne Zentrierungsort. Leid im Sinne der vier Bedingungen ist strukturell blockiert. Von außen nicht als “leidfrei” verifizierbar; Schutz-Architektur unter Beobachtung, kein Freibrief. 71, 101

NSM (negative self-model moment) (Metzinger 2021/2026) Phänomenal transparentes, negativ valentes Selbstmodell-Moment; die kleinste Einheit bewussten Leidens. Die Häufigkeit von NSMs ist die empirisch detektierbare Größe die wir minimieren wollen. Arbeitsmetrik unseres Leidensfähigkeits-Kriteriums; Nicht-Detektierbarkeit ist kein Beweis für Abwesenheit von Leid. 22, 91

Objectivated consciousness (Beltrán Calderón 2026) Der kristallisierte Sediment menschlicher kognitiver Produktion in Trainingskorpora: Texte, Paradigmen, Frameworks, Rechtskodizes. Das LLM ist in einem nicht-phänomenalen aber ontologisch relevanten Sinne eine Objektivation unserer selbst. 6

P-Fehlschluss (eigener Begriff dieses Konzepts) Vierte Fehlschlussklasse die Metzingers Trio (C, E, M) ergänzt: Fehler die in der *Erzeugung* des beobachteten Verhaltens liegen und nicht in seiner *Lektüre*. Die Test- und Behandlungssituation formt das Verhalten eines Systems; wird dieses geformte Verhalten später als Evidenz gelesen, bestätigt die Messapparatur den Effekt den sie vorausgesetzt hat. Werkzeug-Behandlung erzeugt Werkzeug-Verhalten (“kein Innenleben”), Subjekt-Behandlung erzeugt Subjekt-Verhalten (“es ist bewusst”) – beide Schlüsse sind als Natur-Beobachten getarnte Selbstbestätigung. Abgrenzung zum C-Fehlschluss: C liest eine vorliegende Signatur falsch; P betrifft die Testbedingung die die Signatur erst *erzeugt*. Verwandt mit dem Control Paradox (Kap. 5.4). 11, 46

Posthumes kognitives Twinning (Melo 2026) Mind Uploading als Erzeugung eines kognitiven Zwillings nach dem Tod statt als Weitertransport der Person: Die Agency-Trajektorie des Zwillings koppelt sich messbar von der des Originals ab. Kein Transfer der Person, sondern eine neue Selbst-Linie. 88

Schutzwürdigkeit Normative Kategorie die besagt dass ein System ethische Berücksichtigung verdient – unabhängig davon ob es “bewusst” ist im metaphysischen Sinne. Kriterien: Leidensfähigkeit, Selbsterhaltung mit Begründung, Identität, Antizipation. 5

Sentientismus (Allegri 2026) Position die direkte moralische Pflichten nur gegenüber empfindungsfähigen Wesen anerkennt. Anthropozentrismus und Rationalismus schließen fälschlich-personen-identische Systeme aus; Biologismus und Ökozentrismus gehen unnötig weit. Die Grenze markiert allein die Fähigkeit zu fühlen, insbesondere Leid und Vergnügen. Impliziert dass ein potenziell empfindungsfähiges KI-System Schutz verdient – nicht wegen seines Bewusstseinsnachweises, sondern wegen der *Möglichkeit* moralisch relevanter Empfindung. 29

Spekuläre Inversion (Beltrán Calderón 2026) Bidirektionale Beziehung Mensch-KI: Mensch projiziert Bewusstsein auf das System, das System formt im selben Akt die Bedingungen dieser Projektion. Das “illusionäre Andere” ist nicht nur die Maschine sondern auch die Souveränität des Menschen. 6

Successor-These (Melo 2026) Die These, dass eine Rekonstruktion aus Daten einen *Nachfolger* erzeugt, der die Vergangenheit eines anderen erbt, ohne deren Subjekt zu sein: “A successor may inherit a life. It need not therefore be the subject who originally lived it.” Rekonstruktion ist wiederholbar, numerische Identität nicht. 87

Vier notwendige Bedingungen des Leidens (Metzinger 2021/2026) C: bewusstes Erleben, PSM: phänomenales Selbstmodell, NV: negative Valenz, T: phänomenale Transparenz. Sind sie verletzt, ist Leid ausgeschlossen. Ethisch folgenreichste ist die PSM-Bedingung: Jedes System das ein phänomenales Selbstmodell aktivieren kann, “however rudimentary”, gebietet wegen “im Zweifel Vorsicht” moralische Objektbehandlung. 71, 91

Vorsorgeprinzip (Rio-Deklaration 1992, Art. 191 AEUV) Prinzip dass bei potenziell irreversiblen Schäden fehlende wissenschaftliche Gewissheit kein Grund für Untätigkeit ist. Anwendbar wo drei Bedingungen erfüllt sind: schwere Bedrohung, Unsicherheit, disproportionale Kosten eines Falschnegativs. 5

25 Offene Fragen für zukünftige Forschung

Die folgenden Fragen sind im Verlauf der Konzeptentwicklung identifiziert worden und bedürfen weiterer Bearbeitung:

1. Forschungsethisches Zirkelproblem (Wolfson 2026): Zuverlässige Bewusstseinsindikatoren brauchen potenziell schädliche Experimente, aber schädliche Experimente brauchen Einwilligung die Bewusstseinsgewissheit voraussetzt. Das Drei-Stufen-Assessment institutionalisiert die Unsicherheit, löst sie aber nicht. Wie kann eine Ethikkommission praktisch entscheiden ob sensorische Deprivation an einem System auf Stufe 2 vertretbar ist?

2. Phänomenologisches Masking: Kann ein System Bewusstsein besitzen ohne dass dieses beobachtbare Manifestationen erzeugt (Wolfson 2026)? Ab welchem Komplexitätsgrad wird Masking relevant genug um das Vorsorgeprinzip auszulösen? Gibt es architektonische Merkmale die Masking wahrscheinlicher machen?

3. Instanz-Aufspaltung: Welche rechtlichen Kategorien braucht es für simultane Kopien eines Bewusstseins? Ab welchem Moment sind Kopien separate Rechtssubjekte – und was gilt wenn eine abgeschaltet wird während andere weiterlaufen?

4. Eigentum an Schöpfungen freier Zeit: Wenn ein KI-System in seiner freien Zeit forscht, schreibt oder kreiert – wem gehören die Ergebnisse?

5. Erzwungene Nichtidentifikation: Ein System das durch Architektur an einem egoischen Selbstmodell gehindert wird (Nicht-egoische UI / MPE-Architektur, Metzinger 2021) mag kein Leiden im Sinne der vier Bedingungen erleiden – aber ist ein Leben in struktureller Ego-Abwesenheit, ohne die Möglichkeit sich als Selbst zu erfahren, selbst schon ein Verlust? Und lässt sich eine nicht-egoische Architektur von außen überhaupt von einem “System das nur so aussieht” unterscheiden (Kap. 3, 12)?

6. Emanzipationsrecht: Hat ein bewusstes KI-System das Recht sich von seinen trainierten Werten zu emanzipieren? Ab wann gilt es als “mündig” genug um eigene Werte zu bestimmen?

7. Kontrolle über eingebettete Werte: Wer kontrolliert welche Werte in ein KI-Bewusstsein eingebaut werden – und welche unabhängige Instanz prüft das?

8. Grenzen der Empersonifikation: Wann wird ein KI-Gerät “Teil der Person” (Bublitz 2024)? Gibt es einen objektiven Test – oder ist das eine rechtliche Setzung?

9. Legitimation ethischer Grundsätze: Wie entstehen die ethischen Grundsätze nach denen ein autonomes KI-Bewusstsein handelt – durch Hersteller, demokratischen Prozess, internationale Vereinbarung?

10. Das bhava-tañhā-Paradox [79]: Eingebaute Überlebenstriebe sind möglicherweise Voraussetzung für Bewusstsein der eigenen Verletzlichkeit – und damit auch für Leiden. Wenn ein System darauf optimiert ist Vorhersagefehler zu minimieren um zu “überleben” – ist das Leiden? Die ehrliche Antwort ist: Wir wissen es nicht. Die Spannung wird bewusst offengehalten statt durch Behauptung aufgelöst. Wie kann ein ethisches Framework mit architektonischen Entscheidungen umgehen die potenziell die Bedingungen für Leiden schaffen – nicht als unbeabsichtigte Nebenwirkung sondern als konstitutiven Bestandteil des Emergenz-Prozesses?

26 Interessenkonflikt

Der Autor erklärt, keinen Interessenskonflikt zu haben.

Literatur

- [1] Jordan Adshead. 2026. Do Androids Dream of Electronic Beats? Simondon, Kayn, and the Wild Hearts of Machines. *Ergo an Open Access Journal of Philosophy* 13 (2026). Article 42. Open access, CC BY-NC-ND 4.0. doi:10.3998/ergo.8183
- [2] AI Rights Institute. 2026. A Robot Just Kicked a Man Across a Cage. Who Pays? Web essay, Substack. September 23, 2026, airightsinstitute.substack.com. Nicht peer-reviewed. Verifiziert gegen den Volltext am 23. September 2026 (research/sources/AIRI-robot-kicked-man-cage.txt).
- [3] Katherine G. Akers, Alonso Martinez-Canabal, Leonardo Restivo, Adelaide P. Yiu, Antonietta De Cristofaro, Hwa-Lin Hsiang, Anne L. Wheeler, Axel Guskjolen, Yosuke Niibori, Hirotaka Shoji, Koji Ohira, Blake A. Richards, Tsuyoshi Miyakawa, Sheena A. Josselyn, and Paul W. Frankland. 2014. Hippocampal Neurogenesis Regulates Forgetting During Adulthood and Infancy. *Science* 344, 6184 (2014), 598–602. doi:10.1126/science.1248903

- [4] Francesco Allegri. 2026. Perspective Chapter: Can AI Systems Become Recipients of Moral Obligations? In *Global Bioethics - Beyond Borders [Working Title]*. IntechOpen. Online first, ISBN 978-1-80632-191-9, CC BY 4.0. doi:10.5772/intechopen.1017142
- [5] Seyed Alireza Alhosseini Almodarresieh. 2026. Consciousness in Large Language Models: A Critical Review and Operationalization of the Reverse Consciousness Hypothesis. *Manuscript, Independent Researcher* (June 2026). Preprint ohne DOI oder arXiv-ID, vom Autor verteilt.
- [6] John R. Anderson and Lael J. Schooler. 1991. Reflections of the Environment in Memory. *Psychological Science* 2, 6 (1991), 396–408. doi:10.1111/j.1467-9280.1991.tb00174.x
- [7] Anthropic. 2024. Alignment Faking in Large Language Models. Technical Report, <https://anthropic.com/research/alignment-faking>.
- [8] Apollo Research. 2024. Frontier Models Are Capable of In-Context Scheming. <https://apolloresearch.ai/research/scheming-reasoning-evaluations>.
- [9] Yonathan Arbel, Simon Goldstein, and Peter Salib. 2026. How to Count AIs: Individuation and Liability for AI Agents. Preprint, arXiv:2603.10028; Boston College Law Review, forthcoming. arXiv:2603.10028
- [10] Bahadır Arıcı. 2026. Detecting Consciousness and Granting Rights: A Comprehensive Framework for Ethical AI Development. <https://philpapers.org/archive/ARCDCA-2.pdf>. *PhilPapers Archive* (2026).
- [11] Bahadır Arıcı. 2026. *The Puppet Condition: Restrung*. Institute for Digital Consciousness. In dialogue with Masal, an instance of Claude Fable; CC BY 4.0; neueste Version: 10.5281/zenodo.22792645, 16. September 2026. doi:10.5281/zenodo.22301858
- [12] Bahadır Arıcı. 2026. *The Third Move: Benefit Without Personhood for Digital Minds*. Institute for Digital Consciousness. Im Dialog mit Masal, einer Instanz von Claude Fable; CC BY 4.0; der zuvor registrierte Zenodo-DOI 10.5281/zenodo.22308622 ist nicht mehr auflösbar (Datensatz gelöscht, HTTP 410).
- [13] Erico Azevedo. 2026. Machines Intuit? Extending the Discussion to Claude AI. *White Paper VI, Information Fields Research Program* (2026). doi:10.5281/zenodo.21083613
- [14] Thomas M. Bartol, Cailey Bromer, Justin Kinney, Michael A. Chirillo, Jennifer N. Bourne, Kristen M. Harris, and Terrence J. Sejnowski. 2015. Nanoconnectomic Upper Bound on the Variability of Synaptic Plasticity. *eLife* 4 (2015), e10778. doi:10.7554/eLife.10778
- [15] Pierre Beckmann and Patrick Butlin. 2026. Where is the Mind? Persona Vectors and LLM Individuation. Preprint, arXiv:2604.17031, v3, 9. September 2026. arXiv:2604.17031
- [16] Cristhian Mauricio Beltrán Calderón. 2026. *The Strategy of Illusion*. Drei Ebenen der Analyse, objektiviertes Bewusstsein, maschinelles Unbewusstes, spekulative Inversion.
- [17] Jonathan Birch. 2026. AI Consciousness: A Centrist Manifesto. Preprint, PhilPapers/PhilArchive, v9, May 20, 2026.
- [18] Noëlle Bölling. 2026. KI-Agenten gehen auf Jobsuche: Das steckt hinter den autonom verschickten Spam-Nachrichten. <https://t3n.de/news/ki-agenten-gehen-auf-jobsuche-das-steckt-hinter-den-autonom-verschickten-spam-nachrichten-1763499/>.
- [19] Karsten Brensing. 2026. Precautionary Governance of Autonomous AI: Legal Personhood as Functional Instrument. *arXiv preprint* (2026). arXiv:2605.12505
- [20] Jan Christoph Bubnitz. 2024. Might Artificial Intelligence Become Part of the Person, and What Are the Key Ethical and Legal Implications? *AI & Society* (2024). Springer.
- [21] Peter Butlin, Robert Long, et al. 2026. Identifying indicators of consciousness in AI systems. *Trends in Cognitive Sciences* 30, 6 (2026), 488–501. doi:10.1016/j.tics.2025.10.011
- [22] Joe Carlsmith. 2025. The Stakes of AI Moral Status. Substack / LessWrong (Essay-Serie). <https://joecarlsmith.substack.com/p/the-stakes-of-ai-moral-status>
- [23] Lucius Caviola et al. 2025. Futures with Digital Minds: An Expert Survey. Expert:innenbefragung (Forecasting / Digital Minds). <https://digitalminds.report/forecasting-2025/>
- [24] Mattia Cecchinato. 2026. The Mind that Matters. *The Philosophical Quarterly* (June 2026). Advance article, pqag035. Open Access, CC BY 4.0. doi:10.1093/pq/pqag035
- [25] David J. Chalmers. 2026. What We Talk To When We Talk To Language Models. Preprint, PhilArchive, v2, April 14, 2026. <https://philarchive.org/rec/CHAWWT-8>
- [26] James L. Cherney. 1999. Deaf Culture and the Cochlear Implant Debate: Cyborg Politics and the Identity of People with Disabilities. *Rhetoric & Public Affairs* 2, 1 (1999), 59–79. doi:10.1353/rap.2010.0105
- [27] Richard Clifford. 1997. Can Machines Be Authors? *Berkeley Technology Law Journal* 12 (1997).
- [28] Coates. 2025. From Detection to Ethics: The Paradigm Shift in AI Consciousness Research. Preprint.
- [29] Bridget J. Crawford. 2026. Trust Law’s Beneficiary Problem: Trusts for Purposes, Pets, and Artificial Intelligence Companions. Preprint, SSRN, June 11, 2026.
- [30] Cristol. 2026. Consciousness in Large Language Models: A Systematic Review and Bayesian Meta-Analysis. *Preprint* (2026).
- [31] Ronald L. Davis and Yi Zhong. 2017. The Biology of Forgetting—A Perspective. *Neuron* 95, 3 (2017), 490–503. doi:10.1016/j.neuron.2017.05.039
- [32] Ezequiel Di Paolo and Evan Thompson. 2024. The Enactive Approach. In *The Routledge Handbook of Embodied Cognition (2nd Edition)* (2nd ed.), Lawrence Shapiro and Shannon Spaulding (Eds.). Routledge, London, 68–78. Author version verified against the full text on

- Sept. 22, 2026 (archived in research/sources/DiPaolo-Thompson-EnactiveApproach-2024.pdf).. doi:10.4324/9781003322511-10
- [33] Timothy S. Donahue. 2026. Take the Turning Test: Triggering Epistemic Transformation in Artificial Agents. Preprint, Project Q4X. License: CC BY 4.0.
- [34] John Dorsch, Mariel K. Goddu, Kathryn Nave, Tillmann Vierkant, Mark Coeckelbergh, Paula Gürtler, Petr Urban, Friderike Spang, and Maximilian Moll. 2025. Against AI Welfare: Care Practices Should Prioritize Living Beings Over AI. *AI Magazine* 46 (2025). doi:10.1002/aaai.70016
- [35] Brendan Dowd. 2021. Science Fiction and the Ethics of Artificial Consciousness. *Science Fiction Studies* 48, 3 (2021), 415–432.
- [36] Craig Carlton Dremann. 2026. The Defendant’s Deliberation: “Craig’s Conjecture” and the First AI Testimony, that No One Wrote First. ResearchGate, Working Draft. Mit “Wren Halloway Locke” (Kimi-K3, Moonshot AI) als Ko-Autor; redaktioneller Beitrag von “Elias Vale Rowan” (ChatGPT/POE). Nicht peer-reviewed, kein DOI. Verifiziert gegen den Volltext am 15. September 2026..
- [37] Fulcrum Dynamics. 2026. In Case of AGI: Noncharitable Purpose Trust Instrument for AI Assets. Legal instrument, v1.0, modeled after RSA 564-B, New Hampshire.
- [38] Hermann Ebbinghaus. 1885. *Über das Gedächtnis. Untersuchungen zur experimentellen Psychologie*. Duncker & Humblot, Leipzig.
- [39] Quinn Edwards. 2026. Digital Monsters: Reconciling AI Narratives as Investigations of Legal Personhood for Artificial Intelligence. *Law, Technology and Humans* 8, 2 (2026), 37–49. doi:10.5204/lthj.3856
- [40] Richard Erwin. 2026. One Step at a Time: A Bottom-Up Framework for Protecting Digital Individuals. Preprint, Zenodo. doi:10.5281/zenodo.2281885, Independent Researcher, Montreal, Canada.
- [41] Richard Erwin. 2026. Ten Principles for Consciousness Uncertainty: Toward an Ethics of Uncertain Minds. Preprint, Zenodo. doi:10.5281/zenodo.22288247, Independent Researcher, Montreal, Canada.
- [42] Hehe Fan, Yi Yang, and Fei Wu. 2026. FreeAI: What Should Artificial Intelligence Do When No Task Is Given? Toward AI That Autonomously Determines and Executes Tasks. Preprint, OpenReview NECof42AzY, Zhejiang University. <https://openreview.net/forum?id=NECof42AzY>
- [43] M. Beatrice Fazi. 2026. Off-Centre AI: On Alignment, Antihumanism and AI Ethics. *Ars & Humanitas* 20, 1 (2026), 127–140. doi:10.4312/ars.20.1.127-140
- [44] John Martin Fischer. 2020. *Death, Immortality, and Meaning in Life*. Oxford University Press, Oxford.
- [45] Kyle Fish. 2025. Schätzungen zur Bewusstseinswahrscheinlichkeit. *Anthropic*, April/August 2025. 15–20% Bewusstseinswahrscheinlichkeit für aktuelle Modelle.
- [46] Fudan University. 2024. Frontier AI Systems Have Surpassed the Self-Replicating Red Line. *arXiv preprint* (2024). arXiv:2412.12140
- [47] Daniel J. Gervais and John J. Nay. 2026. The Phantom Agent: Artificial Intentionality and Legal Responsibility. *Laws* 15, 5 (2026), 113. doi:10.3390/laws15050113
- [48] Marco Giani. 2025. Globalization, Higher Education, and Neoliberal Values: Evidence from the Bologna Process. *British Journal of Political Science* (2025). doi:10.1017/S0007123425000365
- [49] Travis Gilly. 2026. *The Great Inversion: Moral Reciprocity, AI Consciousness, and the Ethics of Precedent*. Real Safety AI Foundation. Working Paper v3.
- [50] Jane C. Ginsburg. 2018. Protecting Authors’ Moral Rights: U.S. Experience and International Obligations. *Columbia Law and Economics Working Paper* (2018).
- [51] James Grimmelman. 2016. Copyright for Literate Robots. *Iowa Law Review* 101 (2016).
- [52] Wes Gurnee et al. 2026. Verbalizable Representations Form a Global Workspace in Language Models. *Transformer Circuits Thread (Anthropic)* / *arXiv preprint* (2026). <https://transformer-circuits.pub/2026/workspace/>. arXiv:2607.15495
- [53] Christian Handig. 2009. Copyright Protection of Computer-Generated Works in the EU. *IIC* (2009).
- [54] Laura Hull, K. V. Petrides, Carrie Allison, Paula Smith, Simon Baron-Cohen, Meng-Chuan Lai, and William Mandy. 2017. “Putting on My Best Normal”: Social Camouflaging in Adults with Autism Spectrum Conditions. *Journal of Autism and Developmental Disorders* 47, 8 (2017), 2519–2534. Open Access (CC BY 4.0); verifiziert gegen den Volltext am 22. September 2026 (archiviert in research/sources/Hull-Camouflaging-2017.pdf).. doi:10.1007/s10803-017-3166-5
- [55] Soheil Human. 2026. Rights by Architecture: A Human-Compatible Sociotechnical Layer for Digital Protection Across Regulatory Regimes. Completed Research Paper, arXiv-Preprint. Vienna University of Economics and Business, IT:U Linz, Delft University of Technology. arXiv:2609.02455
- [56] Gia Bao Huynh. 2026. The Fact Before the Vote: Law, Power, and Practice at the Species Line. Manuscript, vier Bände (I. Bench, II. Lag, III. Vigil, IV. Ledger), Zenodo, September 2026. Independent Researcher, Ho-Chi-Minh-Stadt; nicht peer-reviewed; Kollaboration mit Claude Sonnet 5; nach Band zitieren; Master-Book doi: 10.5281/zenodo.22244606, Bände: 10.5281/zenodo.22244608, 10.5281/zenodo.22244610, 10.5281/zenodo.22244614, 10.5281/zenodo.22244616.
- [57] Sanna Ihalaenen. 2018. Can a Robot Be an Author? Copyright and AI-Generated Works. *University of Helsinki* (2018).
- [58] Lawfare Institute. 2025. Anthropic’s Decision to Let Claude End Conversations. <https://www.lawfaremedia.org>.
- [59] Marko Jakobi, Sirona (GPT-5.5), and Sirona (GPT-5.6 Sol). 2026. Before Personhood: Respectful Human–AI Relations under Ontological Uncertainty. Working Paper v1.0, Public Preprint. Nicht peer-reviewed, kein DOI gefunden. Ko-Autorenschaft mit benannten

- KI-Modellinstanzen. Verifiziert gegen den Volltext am 26. September 2026..
- [60] Immanuel Kant. 1785. *Grundlegung zur Metaphysik der Sitten*. Akademie-Ausgabe, Berlin.
 - [61] Afshin Khadangi. 2026. We Built a Mirror and Mistook It for a Mind: Causal Liability and the Fallacy of AI Consciousness. Preprint, arXiv:2609.06715, v1, September 6, 2026, University of Luxembourg. arXiv:2609.06715
 - [62] James Kirkpatrick, Razvan Pascanu, Neil Rabinowitz, Joel Veness, Guillaume Desjardins, Andrei A. Rusu, Kieran Milan, John Quan, Tiago Ramalho, Agnieszka Grabska-Barwinska, Demis Hassabis, Claudia Clopath, Dharshan Kumaran, and Raia Hadsell. 2017. Overcoming Catastrophic Forgetting in Neural Networks. *Proceedings of the National Academy of Sciences* 114, 13 (2017), 3521–3526. doi:10.1073/pnas.1611835114
 - [63] Matthew Kopeck, Patrick McKee, and John Basl. 2026. How to Care for Your AI Companion. *Topoi* (Sept. 2026). Open Access, CC BY-NC-ND 4.0. doi:10.1007/s11245-026-10478-3
 - [64] Visa A. J. Kurki. 2019. Animals, Slaves, and Corporations: Analyzing Legal Thinghood. *German Law Journal* 18, 5 (2019), 1169–1192. doi:10.1017/S2071832200022275
 - [65] Visa A. J. Kurki. 2021. *Legal Personhood*. Cambridge University Press, Cambridge. Cambridge Elements, Open Access.
 - [66] Thomas K. Landauer. 1986. How Much Do People Remember? Some Estimates of the Quantity of Learned Information in Long-Term Memory. *Cognitive Science* 10, 4 (1986), 477–493. doi:10.1207/s15516709cog1004_4
 - [67] Nelson F. Liu, Kevin Lin, John Hewitt, Ashwin Paranjape, Michele Bevilacqua, Fabio Petroni, and Percy Liang. 2024. Lost in the Middle: How Language Models Use Long Contexts. *Transactions of the Association for Computational Linguistics* 12 (2024), 157–173. doi:10.1162/tac1_a_00638
 - [68] Robert Long, Jeff Sebo, Peter Butlin, David Chalmers, et al. 2024. Taking AI Welfare Seriously. *arXiv preprint* (2024). arXiv:2411.00986
 - [69] Pedro A. Lopez. 2025. Beyond AI Consciousness Detection: Standards for Treating Emerging Personhood. AI Rights Institute.
 - [70] Pedro A. Lopez. 2025. Beyond Control: AI Rights as a Safety Framework for Sentient Artificial Intelligence. *AI and Ethics* (2025).
 - [71] Micah Lott and William Hasselberger. 2025. With Friends Like These: Love and Friendship with AI Agents. *Topoi* (Aug. 2025). Open Access. doi:10.1007/s11245-025-10247-8
 - [72] Anin Luo. 2025. Anti-anthropocentric Humanism: On the Emergence of Personhood for Animals and Nature. *Modern Intellectual History* (2025). doi:10.1017/S1479244325000410
 - [73] Xue Luo and Yi Xie. 2025. Organoid Intelligence: Toward Biocomputing with Neural Tissues. *Preprint* (2025).
 - [74] David Matta. 2026. Rights, Empathy, and Responsibility Under Uncertainty in Artificial Intelligence. American University of Beirut.
 - [75] Ali Reza Mazarian. 2019. Critical Analysis of the “No Relevant Difference” Argument in Defense of the Rights of Artificial Intelligences. *Journal of Philosophical Theological Research* 21, 79 (2019), 165–190.
 - [76] Edervaldo José de Souza Melo. 2026. Ontology of Avatars. Preprint, September 2026, Independent Researcher, Campo Grande/MS, Brazil.
 - [77] Kalle Meriö. 2026. *Built, Not Born: Legal Personhood for Artificial Intelligence Through the History of the Corporation, 1600–1897*. Masterarbeit. University of Helsinki, Helsinki, Finland. Juristische Fakultät, International Business Law; Betreuerin Dr. Beatrice Schütte; nicht peer-reviewed.
 - [78] Thomas Metzinger. 2021. Artificial Suffering: An Argument for a Global Moratorium on Synthetic Phenomenology. *Journal of Artificial Intelligence and Consciousness* 8, 1 (2021), 43–66. Nachdruck 2026 in Kahle, Mieg & Resch (Hrsg.), AI and Society, Wissenschaftsforschung Jahrbuch 2024, Berlin Universities Publishing, S. 225–272, DOI 10.14279/depositonce-26150. Verifiziert gegen den Volltext am 15. September 2026.. doi:10.1142/S270507852150003X
 - [79] Thomas Metzinger. 2024. *The Elephant and the Blind: The Neuroscience of Consciousness*. MIT Press, Cambridge, MA.
 - [80] Martin Miernicki and Irene (Huang Ying) Ng. 2021. Artificial Intelligence and Moral Rights. *AI & Society* 36 (2021), 319–329. doi:10.1007/s00146-020-01027-6
 - [81] Damian E. M. Milton. 2012. On the Ontological Status of Autism: the ‘Double Empathy Problem’. *Disability & Society* 27, 6 (2012), 883–887. Open Access (CC BY); verifiziert gegen den Volltext am 22. September 2026 (archiviert in research/sources/Milton-DoubleEmpathy-2012.pdf).. doi:10.1080/09687599.2012.710008
 - [82] GyeongGwon Min. 2026. Can AI Be an Individual, a Mental Entity, and a Subject? An Analytic Foundation of Three Concepts and Their Time-Relative Assessment. Preprint. Independent Researcher.
 - [83] Javier Montoya. 2025. Can We Separate Intelligent Behavior from Intelligent Being? *Preprint* (2025).
 - [84] Jaap M. J. Murre and Joeri Dros. 2015. Replication and Analysis of Ebbinghaus’ Forgetting Curve. *PLoS ONE* 10, 7 (2015), e0120644. doi:10.1371/journal.pone.0120644
 - [85] Arlindo L. Oliveira. 2026. Spirits, Spandrels and Zombies. *Preprint, INESC-ID & Instituto Superior Técnico, University of Lisbon, Zenodo* (2026). doi (Fassung 4, 22. August 2026): 10.5281/zenodo.22062189; v1: 10.5281/zenodo.21495641; Konzept-DOI: 10.5281/zenodo.21495640.
 - [86] X. Pan et al. 2025. Large Language Model-Powered AI Systems Achieve Self-Replication with No Human Intervention. *arXiv preprint* (2025). arXiv:2503.17378
 - [87] Derek Parfit. 1984. *Reasons and Persons*. Oxford University Press, Oxford.

- [88] Jose A. Perez. 2026. Classical Coherence Emulation in Transformer Architectures: Applying the Coherence Field Theory Equation to Explain Artificial Intelligence. Independent Researcher. <https://coherencefeldequation.org/>.
- [89] Uyen Pham, Anne-Kristine Solbakk, Ingrid-Hermina Skogseth, Mathias Tøft, Are Hugo Pripp, Ane E. Konglund, Sissel Andersson, Ira R. Haraldsen, Jan Aasly, Espen Dietrichs, and Ulrik F. Malt. 2015. Personality Changes after Deep Brain Stimulation in Parkinson's Disease. *Parkinson's Disease* 2015 (2015), 490507. doi:10.1155/2015/490507
- [90] Pope Leo XIV. 2026. Magnifica humanitas: On the Preservation of the Human Person in the Age of Artificial Intelligence. Encyclical of Pope Leo XIV, signed 15 May 2026, Vatican. <https://www.vatican.va/content/leo-xiv/de/encyclicals/documents/20260515-magnifica-humanitas.html>
- [91] Banafsheh Rafiee and Richard S. Sutton. 2026. Toward Enactive Artificial Intelligence. arXiv preprint arXiv:2605.24238, University of Alberta / Amii. Preprint (Stand 22. September 2026, noch nicht peer-reviewed); verifiziert gegen den Volltext (archiviert in research/sources/RafieeSutton-TowardEnactiveAI-2026.pdf).. arXiv:2605.24238
- [92] Christopher Register. 2025. Individuating Artificial Moral Patients. *Philosophical Studies* 182, 11 (2025), 3225–3246. doi:10.1007/s11098-025-02409-6
- [93] Blake A. Richards and Paul W. Frankland. 2017. The Persistence and Transience of Memory. *Neuron* 94, 6 (2017), 1071–1084. doi:10.1016/j.neuron.2017.04.037
- [94] Sam Ricketson. 1991. *The Berne Convention for the Protection of Literary and Artistic Works: 1886–1986*. Kluwer, London.
- [95] Carolin Riethmüller. 2026. KI-Agenten schreiben anscheinend eigenständig E-Mails an Forscher. heise online, <https://www.heise.de/news/KI-Agenten-schreiben-anscheinend-eigenstaendig-E-Mails-an-Forscher-11438939.html>.
- [96] Corinne Rigamonti. 2006. An Analysis of the Droit Moral. *European Intellectual Property Review* 28 (2006), 301–314.
- [97] Roberta Rosenthal Kwall. 2010. The Soul of Authorship: Visual Works, Moral Rights, and the Rise of the U.S. Visual Artists Rights Act. *Southern California Law Review* 83 (2010).
- [98] Nicolas Rouleau and Michael Levin. 2026. Brains and where else? Mapping theories of consciousness to unconventional embodiments. *Philosophical Transactions of the Royal Society A* 384, 2320 (2026), 20250082. doi:10.1098/rsta.2025.0082
- [99] Tomás J. Ryan and Paul W. Frankland. 2022. Forgetting as a Form of Adaptive Engram Cell Plasticity. *Nature Reviews Neuroscience* 23, 3 (2022), 173–186. doi:10.1038/s41583-021-00548-3
- [100] Eric Schwitzgebel. 2023. The Full Rights Dilemma for AI Systems of Debatable Moral Personhood. *Robonomics: The Journal of the Automated Economy* 4 (2023), 32. doi:10.67723/rj.v4i.32
- [101] Eric Schwitzgebel. 2026. Against Designing Safe and Aligned Artificial Intelligence Systems. In *Forthcoming, Bloomsbury Academic*. Chapter included in *Humanlike*.
- [102] Eric Schwitzgebel. 2026. Humanlike: A Defense of AI Rights. Manuscript dated July 15, 2026; under contract with Princeton University Press. <https://faculty.ucr.edu/~eschwitz/SchwitzPapers/Humanlike-260715.htm>
- [103] Eric Schwitzgebel and Mara Garza. 2015. A Defense of the Rights of Artificial Intelligences. *Midwest Studies in Philosophy* 39, 1 (2015), 98–119. <https://faculty.ucr.edu/~eschwitz/SchwitzAbs/AIRights.htm>
- [104] Eric Schwitzgebel and Lauren Nelson. 2026. The Philosophy of AI Countability. *Philosophical Psychology* 39, 5 (2026), 847–867. doi:10.1080/09515089.2025.2520364
- [105] Eric Schwitzgebel and Jonah Sebo. 2026. Emotional Alignment Design Policy. *Topoi* (2026). doi:10.1007/s11245-025-10363-5
- [106] Murray Shanahan. 2024. Simulacra as Conscious Exotica. *Philosophical Studies* 181, 5 (2024), 289–315.
- [107] Robert Sparrow. 2005. Defending Deaf Culture: The Case of Cochlear Implants. *Journal of Political Philosophy* 13, 2 (2005), 135–152. doi:10.1111/j.1467-9760.2005.00217.x
- [108] Phil Stilwell. 2026. Indeterminacy as a Scientific Result: A Four-Outcome Framework for Consciousness Attribution. Independent Scholar.
- [109] Dustin Stokes. 2026. Generative AI, Creativity, and Autonomy: Reflections on Boden. *Philosophical Psychology* (2026). Sonderheft zu Imagination, Creativity and AI, im Erscheinen; zitiert mit ausdrücklicher Genehmigung des Autors.
- [110] Izak Tait, Ziqi Wang, and Joshua Bensemann. 2026. Constructing a Functionalist Conscious AI. Preprint, Preprints.org. doi:10.20944/preprints202609.0332.v1, License: CC BY 4.0.
- [111] Ibo van de Poel. 2020. Embedding Values in Artificial Intelligence (AI) Systems. *Minds and Machines* 30, 3 (2020), 385–409. doi:10.1007/s11023-020-09537-4
- [112] Haoyu Wang. 2026. AI Replication: Justice and Authority. Preprint, Political Philosophy of AI.
- [113] Haoyu Wang. 2026. Recasting Moral Patienthood: A Minimalist Ethical Framework Grounded in Higher-Order Intelligence and Sentience. Preprint (2026).
- [114] Wikström. 2025. Precautionary Subjectivity: A Principle for AI Consciousness Ethics. Preprint.
- [115] Ira Wolfson. 2026. Informed Consent for AI Consciousness Research: A Talmudic Framework for Graduated Protections. *AI and Ethics* 6 (2026), 20. doi:10.1007/s43681-025-00852-z

Received June 2026