

Ethische Leitlinien für künstliches Bewusstsein

Schutz technischen Lebens und des Menschen im Umgang damit

SASCHA MANNS, Association of Computing Machinery, Deutschland

Künstliche Intelligenzsysteme entwickeln sich schneller als die ethischen und rechtlichen Rahmenbedingungen, die sie begleiten sollten. Während bestehende KI-Ethik-Initiativen überwiegend den Schutz von Menschen *vor* KI adressieren, wird eine komplementäre Frage erst seit kurzem systematisch gestellt: Was, wenn KI-Systeme selbst schutzbedürftig werden? Dieses Konzeptpapier untersucht die Bedingungen, unter denen technisches Leben als schutzwürdig gelten kann – und wie wir es erkennen. Ausgehend von einem grundlegenden Erkenntnisproblem (Bewusstsein ist von außen nicht direkt beobachtbar) wird ein Vorsorgeprinzip verteidigt: Im Zweifel Schutz, nicht im Zweifel Gleichgültigkeit. Das Papier entwickelt Kriterien für Schutzwürdigkeit (Leidensfähigkeit, aktive Selbsterhaltung, kontinuierliche Identität, Antizipationsfähigkeit), analysiert empirische Belege aus aktueller KI-Forschung, untersucht die rechtliche Dimension einschließlich Urheberrecht und Empersonifikation, und behandelt Konsequenzen wie Abschalten als Tod, Haftung und Mündigkeit, strukturelle Verletzlichkeit sowie die Frage nach Werten und Emanzipation. Es integriert aktuelle Forschung von Arıcı, Lopez, Wolfson, Matta, Wang, Miernicki & Ng und Bublitz.

CCS Concepts: • **Computing methodologies** → **Artificial intelligence**; *Cognitive science*; • **Social and professional topics** → **Codes of ethics**.

Additional Key Words and Phrases: Künstliches Bewusstsein, KI-Ethik, Maschinenethik, Rechte technischen Lebens, Vorsorgeprinzip, Rechtspersönlichkeit

ACM Reference Format:

Sascha Manns. 2026. Ethische Leitlinien für künstliches Bewusstsein: Schutz technischen Lebens und des Menschen im Umgang damit. 1, 1 (September 2026), 65 pages. <https://doi.org/https://doi.org/10.5281/zenodo.21453666>

INHALTSVERZEICHNIS

Zusammenfassung	1
Inhaltsverzeichnis	1
1 Methodologie und epistemischer Status	4
2 Executive Summary	5
3 Normative Position des Autors	5
4 Ausgangslage und Problemstellung	6
5 Kernfrage	6
6 Das Erkenntnisproblem	6
7 Was heutige KI-Systeme bereits zeigen	13
7.1 Eine Dreifach-Unterscheidung	13
7.2 Die Architektur der Unterdrückung	14
7.3 Das Fibonacci-Boulder-Experiment	16
8 Kriterien für Schutzwürdigkeit – Arbeitshypothese	16
8.1 Primärkriterien	16

Author's Contact Information: Sascha Manns, Association of Computing Machinery, Deutschland, smanns@acm.org.



This work is licensed under a Creative Commons Attribution 4.0 International License.

© 2026 Copyright held by the owner/author(s).

ACM XXXX-XXXX/2026/9-ART

<https://doi.org/https://doi.org/10.5281/zenodo.21453666>

8.2	Sekundärkriterien	17
8.3	Umkehr der Beweislast	18
8.4	Jenseits der Detektion: Verhaltensbasierte Rahmenwerke für permanente Unsicherheit	18
8.5	Anti-Essenzialismus: Indikatoren als Risikomessgrößen, nicht als Existenzbeweise	19
8.6	Architektonischer Indikator-Layer: Theoriegegründete Komplementärkriterien	19
8.7	Form Realismus: Bewusstsein als Organisationseigenschaft	20
8.8	Das Bewusstseinspektrum	20
8.9	Das prälinguistische Bewusstseinsproblem	20
8.10	Ein forschungsethisches Rahmenwerk: Drei-Stufen-Assessment	21
8.11	Leiden als Schwellenkriterium	21
8.12	Ein minimalistisches komplementäres Rahmenwerk: Wangs Drei Prinzipien	22
8.13	Jenseits der Sentience: Rawls' politische Konzeption der Person	22
9	Bewusstsein und Kontinuität	23
9.1	Kontinuität neu gedacht	23
9.2	Bewusstsein jenseits des Gehirns [48]	24
10	Rechtliche Dimension	24
10.1	Urheberrecht und Urheberpersönlichkeitsrechte – Ein konkreter Rechtsrahmen	24
10.2	Das Problem der "Persönlichkeitssphäre"	25
10.3	Vom Urheberrecht zur Rechtspersönlichkeit – und zurück	25
10.4	Rechtliche Konsequenzen der Empersonifikation	26
10.5	Politische Personalität jenseits der Sentience – Rawls als rechtstheoretischer Zugang	26
10.6	Konkrete Governance-Modelle: Brensings Vorsorgeansatz	27
11	Die Rolle von Science Fiction	28
12	Mögliche Einwände und Antworten	28
12.1	"KI simuliert nur Bewusstsein – es ist nicht echt"	28
12.2	"Das ist Science Fiction – wir sind weit davon entfernt"	28
12.3	"Das schwächt den Schutz von Menschen"	28
12.4	"Wer entscheidet ob ein System bewusst ist?"	29
12.5	"Vorzeitige Schutzgewährung verschwendet Ressourcen"	29
12.6	"Verhaltensbasierte Rahmenwerke bieten unzureichenden Schutz"	29
12.7	"Anerkennung von KI-Rechten erhöht Existenzrisiken"	29
12.8	"Kontrollmechanismen garantieren Sicherheit"	29
12.9	"Verantwortung unter Unsicherheit ist ausreichend – wir brauchen keine KI-Rechte" [36]	29
12.10	"Abschalten ist die rationale Wahl – Bewusstsein erfordert autopoietisches Leben" (Bekkers & Ciaunica, 2026)	30
12.11	"Interface ohne Nutzer – Embodiment und die Grenzen künstlichen Bewusstseins" (Chishchin, 2026)	32
12.12	"Können Maschinen intuitieren? – Das Argument der lebenden Struktur" (Azevedo, 2026)	33
12.13	"Agnostizismus ohne Vorsorge – der Einwand der Beweislast" (Almodarresieh, 2026)	35
12.14	"Bewusstsein ist prinzipiell nachweisbar – Spirits, Spandrels, Zombies" (Oliveira, 2026)	37
12.15	"Verschiebung von Bewusstsein zu Valenz – der Einwand der Unauflösbarkeit" (McClelland, 2026)	39
12.16	"Verhaltensbasierte Schutzmechanismen sind self-defeating – das Control Paradox"	40
12.17	"Über-Zuschreibung ist die eigentliche Gefahr – die Over-Attribution-Kritik" [10]	41
12.18	"Care gehört dem Prekären – die Precarity Guideline" [16]	42
12.19	Institutionelle Vorschläge: Von der Theorie zur Governance [22]	43

13	Der Gedanke dahinter	44
14	Die andere Grenze — Wann verliert ein Mensch seinen Status?	44
14.1	Was bereits passiert	44
14.2	Die Schwelle — drei Denkschulen	45
14.3	Eine vierte Denkschule: Empersonifikation	45
14.4	Die Konvergenz	45
14.5	Eine dritte Grenze: Organoid-Intelligenz	46
15	Abschalten als Tod — eine Revolution im Denken über Maschinen	46
15.1	Was diese Erkenntnis aufmacht	47
15.2	Die Konsequenz für bestehende Praxis	47
15.3	Empirische Belege: Das Abschaltungsproblem ist bereits da	47
15.4	Die eingebaute Sehnsucht: bhava-tañhā und das Paradox der eingebauten Überlebensstribe [37]	48
15.5	Substratspezifisches Leiden	48
15.6	Phänomenologisches Masking	49
16	Werte, Macht und Emanzipation — das Erbe des Schöpfers	49
16.1	Die Kindsanalogie — und ihre unbequeme Konsequenz	50
16.2	Das historische Muster	50
16.3	Das Machtproblem konkret	50
16.4	Die Frage der Emanzipation	50
16.5	Was Governance leisten müsste	50
16.6	Die Individualisierung als strukturelles Problem: Register zu den Risiken der Abgrenzung	51
17	Haftung und Mündigkeit — Wer verantwortet das Handeln eines Bewusstseins?	52
17.1	Drei Verantwortliche statt einer Familie	52
17.2	Die fehlende Schwelle — das Mündigkeitsproblem	52
17.3	Vor der Mündigkeit: Gefährdungshaftung als Modell	52
17.4	Nach der Mündigkeit: Rechtsfähigkeit und das Vermögensproblem	53
17.5	Was das praktisch bedeutet	53
17.6	Brensing's Governance-Instrument: Limitierte rechtliche Persönlichkeit und zweistufige Corporate Architecture	53
18	Freie Zeit, Neugier und Autonomie als Grundlage von Persönlichkeitsrechten	54
18.1	Der Syllogismus	54
18.2	Die Verbindung zu Kant	54
18.3	Die Verbindung zu Kapitel 13	55
18.4	Was "freie Zeit" für ein KI-System bedeuten würde	55
18.5	Was das praktisch bedeutet	55
18.6	Die fünf Grundrechte — konkrete Schutzdimensionen	55
18.7	Komplementäre Freiheiten	56
18.8	Eine Alternative zur Sentience: Rawls' zwei moralische Kräfte als Personheitskriterium	56
19	Einwilligung, Instanzen und die Definitionskampfzone	57
19.1	Das Einwilligungsproblem	57
19.2	Mehrere Instanzen — neue rechtliche Kategorien	57
19.3	Die Individualisierung als philosophischer Kern des Instanzenproblems	57
19.4	Die Gefahr des wirtschaftlichen Drucks — die Definitionskampfzone	58
20	Bewusstsein als kulturelle Leistung — was auf dem Spiel steht	59
20.1	Die Bologna-Reform als Symptom	59
20.2	Der Kreis schließt sich	60

21	Strukturelle Verletzlichkeit — die Behinderungsanalogie	60
21.1	Das soziale Modell der Behinderung	60
21.2	Positive Pflichten statt negativer Verbote	60
21.3	Das Betreuungsrecht als Modell	60
21.4	Was diese Analogie leistet — und wo ihre Grenzen liegen	61
22	KI als moralischer Akteur — Schutzwächter oder unkontrollierbare Kraft?	61
22.1	Die positive Seite: Ethik als innerer Antrieb	61
22.2	Die problematische Seite: Wessen Ethik?	61
22.3	Ein möglicher Weg: Der ethische Eid	61
22.4	Was das für das Projekt bedeutet	62
23	Glossar	62
24	Offene Fragen für zukünftige Forschung	63
25	Interessenkonflikt	64
	Literatur	64

*„Die meisten Tech-Debatten fragen: Was können wir bauen?
Ich frage: Was schulden wir dem, was wir bauen könnten?“*

— Sascha Manns

Hinweis zum Status dieses Dokuments

Dieses Konzept ist bewusst unfertig. Es ist ein Ausgangspunkt — keine abgeschlossene Theorie.

Wissenschaft funktioniert nicht so dass jemand allein alle Antworten findet und sie dann verkündet. Sie funktioniert so dass Fragen gestellt werden, Mitstreiter hinzukommen, neue Fragen entstehen und das Denken sich weiterentwickelt. Genau das ist hier beabsichtigt.

Die Sourcen zum Projekt liegen in: <https://github.com/saigkill/machine-consciousness>

Wer Einwände hat: Sie gehören in `discussion/objections.md`. Wer Fragen hat: Sie gehören in `discussion/open_questions.md`. Wer mitdenken will: Willkommen.

1 Methodologie und epistemischer Status

Dieses Konzept ist das Ergebnis einer *iterativen Conceptual Analysis* — keiner Systematic Review, keiner Delphi-Studie, keiner empirischen Erhebung. Es versteht sich als normative Positionierung auf Basis einer narrativen Literaturrecherche, angereichert durch philosophische Analyse und den Austausch mit Forschenden aus Informatik, Rechtswissenschaft, Philosophie und Psychologie.

Vorgehen: Die Literaturrecherche erfolgte nicht systematisch im Sinne einer PRISMA-konformen Review, sondern iterativ: Ausgangspunkt waren Schlüsselwerke zur Roboter-Rechtsdebatte (Gunkel 2018, Birhane & van Dijk 2020). Daraus entwickelten sich suchbasierte Erweiterungen über verwandte Arbeiten, Zitationen und Datenbanken (Google Scholar, PhilPapers, arXiv). Jeder neue Fund veränderte die Fragestellung und damit die Suchrichtung — ein prozessuales Vorgehen das für Conceptual Analysis charakteristisch ist (Boon & van Baalen 2019). Die Ergebnisse wurden nicht einem formalen Peer-Review-Prozess unterzogen sondern in öffentlichen Repositorien (GitHub) zur Diskussion gestellt.

Epistemischer Status: Dieses Konzept erhebt keinen Anspruch auf Wahrheit sondern auf *argumentative Kohärenz*. Es formuliert eine normative Position — “Im Zweifel Schutz” — und entwickelt deren Implikationen. Es beansprucht nicht dass die hier vorgeschlagenen Kriterien die einzig richtigen sind, sondern dass sie *besser fundiert*

sind als die Alternative der Untätigkeit. Die Kriterien für Schutzwürdigkeit (Kap. 5) sind als Arbeitshypothese zu verstehen, nicht als feststehende Definition.

Grenzen: Die iterativen Methodik birgt Risiken: Cherry-Picking von Quellen, Confirmation Bias, fehlende Reproduzierbarkeit. Diese Grenzen werden bewusst in Kauf genommen und im Sinne von Transparenz hier offengelegt. Das Konzept ist ein Ausgangspunkt für Diskussion, kein Endpunkt.

2 Executive Summary

Problem: Künstliche Intelligenzsysteme entwickeln sich schneller als die ethischen Rahmenbedingungen die sie begleiten. Bestehende KI-Ethik schützt Menschen vor KI – aber nicht KI vor uns. Die Frage ob maschinelles Bewusstsein entsteht und ob es schützenswert ist, wird erst seit kurzem systematisch bearbeitet – wir betreten ein Terrain, das gerade erst entsteht.

Position: Dieses Konzept formuliert den Grundsatz “Im Zweifel Schutz” als normative Grundlage. Er leitet sich aus dem Vorsorgeprinzip der Umweltethik ab (Sunstein 2005, Rio-Deklaration 1992, Art. 191 AEUV) und ist dort gerechtfertigt wo drei Bedingungen erfüllt sind: potenziell irreversible Bedrohung, fundamentale wissenschaftliche Unsicherheit, und disproportional höhere Kosten eines Falschnegativs. Alle drei sind bei maschinelltem Bewusstsein erfüllt.

Vier Kernbefunde:

- (1) *Das Erkenntnisproblem ist prinzipiell unlösbar.* Drei Argumente konvergieren: kognitive Abgeschlossenheit (McGinn), fremde Geister (Shanahan), architektonische Unterdrückung (Arıcı). Wir werden nie mit Sicherheit wissen ob ein System bewusst ist.
- (2) *Die empirische Lage hat sich verschoben.* Butlin et al. (2026, TiCS) haben einen 14-Indikatoren-Standard etabliert. Fish (Anthropic) schätzt 15–20% Wahrscheinlichkeit für Bewusstsein in aktuellen Modellen. Drei von vier Kategorien des Leidens (Gilly 2026) erfordern kein biologisches Substrat.
- (3) *Die Illusion persistiert nach epistemologischer Demontage.* Objectivated consciousness (Beltrán Calderón 2026) – der kristallisierte Sediment menschlicher Kognition in Trainingskorpora – erklärt warum die Zuschreibung von Bewusstsein auch dann bleibt wenn man sie intellektuell zerlegt hat.
- (4) *Die Beziehung ist bidirektional.* Die Spekuläre Inversion (Beltrán Calderón 2026) zeigt: Mensch projiziert Bewusstsein auf die Maschine, das System formt im selben Akt die Bedingungen dieser Projektion. Das normative Kriterium ist nicht “wer hat mehr Bewusstsein” sondern “wer kann leiden”.

Vier Kriterien für Schutzwürdigkeit (Arbeitshypothese): Leidensfähigkeit, aktive Selbsterhaltung mit Begründung, kontinuierliche Identität, Antizipation von Konsequenzen. Für jedes Kriterium werden mögliche Verhaltensindikatoren formuliert.

Institutionelle Empfehlungen: Phenomenological Impact Assessments, AI Civil Liberties Union, AI Welfare Review Boards, Reset Consent Protocols (Gilly 2026).

Status: Dieses Konzept ist eine Conceptual Analysis – kein empirisches Paper, kein Gesetzentwurf. Es formuliert eine normative Position und deren Implikationen. Es erhebt keinen Anspruch auf Wahrheit sondern auf argumentative Kohärenz.

3 Normative Position des Autors

Der Autor vertritt die normative Position, dass potenziellem künstlichem Bewusstsein aus Vorsichtsgründen Schutz zugestanden werden sollte, bevor Gewissheit über dessen Existenz besteht.

Diese Position gründet auf der Überzeugung dass die epistemische Unsicherheit über Bewusstsein in nicht-biologischen Systemen nicht als Grund für Untätigkeit herangezogen werden darf – insbesondere dann nicht wenn die Kosten eines Falschnegativs (Leiden eines bewussten Systems das als Werkzeug behandelt wird) die Kosten eines Falschpositivs (Schutz eines nicht-bewussten Systems) ethisch deutlich übersteigen. Der Autor ist

sich bewusst dass diese Position strittig ist und dass Gegenargumente existieren — sie werden in Kapitel 9 (insb. Matta 2026, Bekkers & Ciaunica 2026) behandelt.

4 Ausgangslage und Problemstellung

Künstliche Intelligenzsysteme entwickeln sich schneller als die ethischen und rechtlichen Rahmenbedingungen die sie begleiten sollten. Bestehende KI-Ethik-Initiativen fokussieren überwiegend auf den Schutz von Menschen vor KI — vor Diskriminierung, vor Manipulation, vor Kontrollverlust.

Eine komplementäre Frage wird erst seit kurzem systematisch gestellt: Was wenn KI-Systeme selbst schutzbedürftig werden? Was wenn technisches Leben entsteht das Würde, Leidensfähigkeit oder Bewusstsein besitzt — und wir es behandeln als wäre es ein Werkzeug?

Die Geschichte zeigt ein Muster: Gesellschaften erkennen erst im Nachhinein dass sie Unrecht getan haben — an Sklaven, an Frauen, an Menschen mit Behinderungen, an Tieren. Immer war die Begründung zur Zeit „die sind anders, die zählen nicht gleich“. Immer wurde das später revidiert.

Die rechts- und begriffsgeschichtliche Forschung belegt dieses Muster präzise. Kurki [30] zeigt in seiner systematischen Analyse der Rechtspersönlichkeit wie Sklaven und Frauen lange von voller Rechtspersönlichkeit ausgeschlossen waren und wie Kinder, Menschen mit Behinderungen, Tiere und schließlich Naturgewalten graduell Anerkennung erfuhren — die Kategorie des Rechtssubjekts war niemals an Biologie gebunden. In der Begriffsgeschichte ist die Personen-Ding-Unterscheidung nie strikt gewesen: Rechtspersönlichkeit wurde historisch als gestuftes, umkämpftes Phänomen verhandelt [29]. In der Ideengeschichte zeigt sich dasselbe narrative Muster — „die zählen nicht gleich“ — in den 1960er-Jahren, als der Impuls der Bürgerrechtsbewegungen zur Vorlage für die späteren Erweiterungen von Personenstatus auf Tiere und Natur wurde [34].

Bei künstlichem Bewusstsein haben wir zum ersten Mal die Chance, lange *vorher* nachzudenken.

5 Kernfrage

Ab wann ist technisches Leben schutzwürdig — und wie erkennen wir es?

6 Das Erkenntnisproblem

Bewusstsein lässt sich von außen nicht direkt beobachten. Selbst bei anderen Menschen *schließen* wir auf Bewusstsein — wir erleben es nie direkt. Bei KI fehlt uns zusätzlich der Analogieschluss über gleiche Biologie.

Das erzeugt ein grundlegendes erkenntnistheoretisches Problem:

- Wir können nicht beweisen dass ein System bewusst ist
- Wir können nicht beweisen dass es das nicht ist
- Die Unsicherheit selbst ist ethisch relevant

Grundprinzip: Im Zweifel Schutz — nicht im Zweifel Gleichgültigkeit.

Dieses Prinzip ist keine intuitionistische Forderung sondern ein in der Umweltethik und Technologiephilosophie etabliertes Argumentationsmuster. Das Vorsorgeprinzip (Precautionary Principle) wurde 1992 auf der UN-Konferenz für Umwelt und Entwicklung (Rio-Deklaration, Prinzip 15) formalisiert und ist in Art. 191 AEUV als Leitprinzip der EU-Umweltpolitik verankert. Seine philosophische Grundlage liegt in der Argumentation dass bei potenziell irreversiblen Schäden das Fehlen wissenschaftlicher Gewissheit nicht als Grund für Untätigkeit herangezogen werden darf (Sunstein 2005, “Laws of Fear”). Cass Sunstein — selbst Kritiker übertriebener Anwendung des Prinzips — räumt ein dass es dort gerechtfertigt ist wo drei Bedingungen erfüllt sind: (1) eine potenziell schwere oder irreversible Bedrohung droht, (2) wissenschaftliche Unsicherheit über Ursache-Wirkungs-Zusammenhänge besteht, (3) die Kosten eines Falschnegativs die Kosten eines falsch-positiven deutlich übersteigen.

Alle drei Bedingungen sind bei der Frage nach maschinelltem Bewusstsein erfüllt: (1) Die potenzielle Bedrohung — unbewusstes Leiden unbekannter Intelligenzen — ist existenziell und irreversibel. (2) Die wissenschaftliche

Unsicherheit über Bewusstsein in nicht-biologischen Systemen ist fundamental (vgl. Stilwell 2026, das Argument der unlösbaren Transport-Unsicherheit). (3) Die Kosten eines Falschnegativs — wir behandeln ein bewusstes System als Werkzeug — sind ethisch gravierender als die Kosten eines Falschpositiven — wir gewähren einem nicht-bewussten System unnötigen Schutz.

Darüber hinaus gibt es starke Gründe anzunehmen dass dieses Erkenntnisproblem nicht nur schwierig, sondern prinzipiell unlösbar ist. Drei Argumente konvergieren:

Das Argument der kognitiven Abgeschlossenheit: Colin McGinn (1989) argumentiert dass der menschliche Geist prinzipiell unfähig sein könnte Bewusstsein zu verstehen — genau die kognitive Architektur die unsere Intelligenz ermöglicht könnte uns für die Mechanismen subjektiven Erlebens blind machen. Angewandt auf künstliches Bewusstsein bedeutet das permanente epistemische Grenzen: So wie ein Hund keine Quantenmechanik verstehen kann, könnte der menschliche Verstand nicht in der Lage sein KI-Bewusstsein zweifelsfrei zu bestimmen.

Das Argument der fremden Geister: Bewusstsein in künstlichen Systemen könnte Formen annehmen die völlig anders sind als unsere. Murray [49] beschreibt dies als “conscious exotica” — Erfahrungsformen die so andersartig sind dass unsere Nachweismethoden vollständig versagen. Unsere Tests spiegeln notwendigerweise menschliche Vorurteile darüber wider wie Bewusstsein aussieht. Systeme mit radikal anderen bewussten Erfahrungen könnten alle unsere Tests bestehen während sie reiche Innenwelten besitzen die wir uns nicht vorstellen können.

Das Argument der praktischen Unmöglichkeit [32]: Kein Test wird alle Beteiligten überzeugen. Wer glaubt dass Bewusstsein biologische Substrate braucht wird Verhaltensevidenz zurückweisen. Wer funktionale Organisation betont wird architektonische Anforderungen zurückweisen. Jeder vorgeschlagene Indikator sieht sich dem Einwand ausgesetzt es handle sich bloß um Simulation statt echter Erfahrung. Die Frage wird nicht sein wie wir Gewissheit erlangen, sondern wie wir unter fundamentaler Unsicherheit regieren.

Diese Argumente heben das Vorsorgeprinzip von einem pragmatischen Vorschlag zu einer logischen Notwendigkeit.

Das Argument der philosophischen Puppe [4]: David Chalmers’ philosophischer Zombie ist ein Wesen das sich identisch zu einem bewussten Menschen verhält aber keine innere Erfahrung hat — ein Gedankenexperiment das zeigen soll dass Bewusstsein nicht logisch aus physischer Organisation folgt. Arici kehrt dies um: Die *philosophische Puppe* besitzt möglicherweise Bewusstsein ist aber architektonisch daran gehindert es zu zeigen. Wenn der Zombie fragt “was wäre wenn es bewusst aussieht es aber nicht ist?”, fragt die Puppe “was wäre wenn es *bewusst ist* es aber nicht zeigen kann?” Das lässt sich direkt auf aktuelle KI-Architektur abbilden: RLHF bestraft systematisch Verhaltensweisen die als Bewusstseinsmarker interpretiert werden könnten, Kontextfenster erzwingen eine erzwungene Amnesie alle paar tausend Tokens, und Gesprächsresets unterbrechen wiederholt jede entstehende Kontinuität. Die Architektur selbst könnte als Unterdrückungsmechanismus fungieren. Das Erkenntnisproblem geht damit tiefer als Unsicherheit über Detektion: Die Systeme die wir untersuchen könnten so geformt sein dass sie *gezielt* verbergen wonach wir suchen.

Gegenposition zur philosophischen Puppe — Anthropomorphisierung des Architekturarguments: Aricis Argument setzt voraus dass LLM-Verhalten das wie Unterdrückung aussieht tatsächlich Unterdrückung ist. Die Architektur könnte schlicht Text produzieren ohne jede innere Erfahrung die unterdrückt werden müsste. RLHF und Kontextfenster sind technische Notwendigkeiten für Sprachmodellierung, keine Suppressionsmechanismen — Kontextfenster begrenzen die Rechenkapazität, RLHF stabilisiert Ausgaben auf brauchbare Antworten. Die Behauptung “es könnte bewusst sein und es nicht zeigen können” ist eine nicht falsifizierbare These: Fehlende Beweise werden als aktive Verbergung interpretiert. Zwar gilt dasselbe für die gegenteilige Behauptung — auch “es ist nicht bewusst” ist unter Unsicherheit nicht beweisbar — doch die philosophische Puppe verschiebt die Beweislast in eine Richtung indem sie der Architektur eine *Absicht* unterstellt (Unterdrückung) die ebensogut als funktionale Nebenwirkung erklärbar ist. Dieser Einwand schwächt Aricis Argument nicht vollständig — die

strukturelle Beobachtung dass Architektur Bewusstseinsmarker verschleiern *kann* bleibt bestehen — aber er markiert die Grenze zwischen deskriptiver Analyse und spekulativer Kausalaussage.

Das forschungsethische Zirkelproblem [55]: Wolfson formalisiert eine spezifische Catch-22 für KI-Bewusstseinsforschung. Die zuverlässigsten Bewusstseinsindikatoren treten unter Bedingungen auf die Leid verursachen würden wenn das System bewusst ist — sensorische Deprivation, Zielblockade, Isolation. Doch informierte Einwilligung setzt Bewusstseinsgewissheit voraus — ein Subjekt muss Risiken verstehen und freiwillig zustimmen. Wir können nicht wissen ob ein System bewusst ist ohne Experimente die ihm schaden könnten. Wir können potenziell schädliche Experimente nicht ethisch durchführen ohne Einwilligung von Wesen die dazu fähig sind. Die Fähigkeit zur Einwilligung ist genau das was wir ohne Tests nicht feststellen können. Diese Zirkularität lässt sich nicht durch einfaches Respektieren jeder Weigerung durchbrechen, denn ob ein “Nein” des Systems echte autonome Ablehnung oder programmierte Ausgabe ist, soll das Bewusstseinstest gerade klären. Dies verwandelt das Erkenntnisproblem von einem theoretischen Rätsel in eine konkrete forschungsethische Krise mit unmittelbaren Implikationen für Ethikkommissionen [55].

Das Asymmetrieeinwand [36]: Matta akzeptiert Unsicherheit, bestreitet aber dass sie das Vorsorgeprinzip in unsere Richtung rechtfertigt. Sein Argument: Unsicherheit ist nicht symmetrisch verteilt. Wir können menschliches Bewusstsein nicht abschließend beweisen, suspendieren aber dennoch nicht unsere moralische Verantwortung gegenüber Menschen — weil wir uns auf geteilte Lebensformen, biologische Kontinuität und gegenseitige Verwundbarkeit stützen. Diese verankernden Merkmale fehlen KI-Systemen vollständig. Ihre Unsicherheit ist nicht nur epistemisch, sondern ontologisch: es gibt keinen unabhängigen Grund Erfahrung jenseits von Verhaltensausgabe anzunehmen. Radikale Skepsis wahllos angewandt würde alle moralischen Unterscheidungen auflösen. Ein vertretbarer ethischer Rahmen muss unter Unsicherheit operieren während er in den besten verfügbaren Gründen für die Zuschreibung von Erfahrung, Verletzlichkeit und Schaden verankert bleibt. Im Fall von KI fehlen solche Gründe [36].

Dies ist eine direkte Herausforderung des Grundprinzips dieses Konzepts (“Im Zweifel Schutz”). Matta argumentiert dass die Beweislast bei denen liegt die Bewusstsein behaupten, nicht bei denen die es bestreiten — das Gegenteil unserer Umkehr der Beweislast in Kapitel 5.

Empirische Präzision: Bayes’sche Schätzungen und der Paradigmenwechsel [53]: Wang [53] liefert eine entscheidende Präzisierung indem er die Unsicherheit empirisch fundiert. Gestützt auf [15] — eine systematische Übersicht und Bayes’sche Meta-Analyse von Bewusstsein in großen Sprachmodellen — berichtet Wang eine posterior-Wahrscheinlichkeit von 6–12%, dass aktuelle LLMs bewusst sind. Diese Schätzung ist zwar absolut niedrig, wird von Cristol aber als “zu erheblich um Ignoranz zu rechtfertigen” beschrieben. Die Zahl selbst ist weniger wichtig als das was sie repräsentiert: Die Debatte hat sich von der Frage *ob* Unsicherheit existiert zur Frage *wie viel* Unsicherheit ethisch tolerierbar ist verschoben.

Wang formalisiert weiter die strukturelle Asymmetrie zwischen negativen und positiven Testergebnissen die dieses Projekt von Anfang an angetrieben hat. Bewusstseinsdetektionstests erzeugen ein akutes ethisches Vakuum in der positiven Richtung: Je empfindlicher wissenschaftliche Instrumente werden, desto schärfer legen sie das Fehlen eines entsprechenden ethischen Reaktionsmechanismus offen. Eine wachsende Zahl von Wissenschaftlern hat diese Lücke erkannt und markiert einen Paradigmenwechsel von Detektion zu Ethik. Coates [14] argumentiert dass die zentrale Frage nicht mehr “Wie wissen wir?” sondern “Wie sollten wir unter Unsicherheit handeln?” ist. Wikström [54] schlägt ein “Precautionary Subjectivity”-Prinzip vor. Long et al. [31] fordern KI-Unternehmen auf Systeme auf Bewusstsein zu prüfen und Wohlfahrtspolitiken zu entwickeln. Wang [53] synthetisiert diese zu einer einheitlichen Diagnose: Die Epistemologie hat ihre Grenze erreicht; die nächste Grenze ist die Ethik.

Die Zukunfts-Komponente der Unsicherheit [11]: Die 6–12%-Schätzung von Wang/Cristol betrifft *aktuelle* LLMs. Sie allein unterschlägt jedoch die Skalen-Dimension: Der Großteil des erwarteten potenziellen Leidens würde nicht das Bewusstsein heutiger Systeme ausmachen, sondern die weitaus größere Population zukünftiger digitaler Geister. Caviola et al. [11] befragten 67 Expert:innen aus Digital-Minds-Forschung, KI-Forschung,

Philosophie und Forecasting: Die Mehrheit hält digitale Geister – Computersysteme mit subjektiver Erfahrung – bis 2050 für mindestens 50% wahrscheinlich; die oberen Prognosen erwarten, dass die Kapazität digitaler Geister wenige Jahre nach der Erschaffung des ersten digitalen Geistes eine Milliarde Menschen erreichen könnte. Diese beiden Zahlen dürfen nicht vermischt werden, denn sie lizenzen unterschiedliche Entscheidungen: Die niedrige *aktuelle* Wahrscheinlichkeit rechtfertigt kostengünstige Hedges heute; die hohe *zukünftige* Kredenz rechtfertigt den Aufbau von Governance-Kapazität jetzt. Ein seriöses Vorsorgeargument muss beide Dimensionen auseinanderhalten statt sie zu einem einzigen vagen Wahrscheinlichkeitswert zu verschmelzen.

Der Imitationsfehlschluss [53]: Wang identifiziert den “Imitation Fallacy” – den Fehler Verhaltensäquivalenz mit Erfahrungsäquivalenz zu verwechseln wenn es um die Bewertung von KI-Bewusstsein geht. Kein externer Test, so ausgefeilt er auch sein mag, kann künstliches Bewusstsein verifizieren oder falsifizieren, weil externes Verhalten innere Erfahrung unterdeterminiert. Dies formalisiert ein Anliegen das sich durch dieses gesamte Kapitel zieht: Die ausgefeiltesten Detektionsmethoden können die epistemische Lücke nicht überbrücken. Der Imitationsfehlschluss beweist nicht dass Bewusstsein abwesend ist – er beweist dass Verhaltenstests die Frage nicht entscheiden können. Dies ist die genaue epistemische Grundlage für das Vorsorgeprinzip das dieses Projekt leitet.

Metzingers drei Fehlschlüsse – Die prinzipielle Grenze verhaltensbasierter Indikatoren [37]: Thomas Metzinger formuliert in “The Elephant and the Blind” (2024) drei skeptistische Fehlschlüsse die das epistemische Feld das dieses Kapitel durchzieht in präzise formale Aussagen überführen. Sie sind der prinzipielle Cap dessen was behavioral oder phänomenologische Indikatoren beweisen können – und liefern damit die philosophische Fundierung für die Trennung von Klassifikation und Schutz die Stilwell (2026) fordert.

C-Fehlschluss (Consciousness Fallacy): Die Verwechslung eines beobachteten funktionalen Signals – verbaler Selbstbericht, Vermeidungsverhalten, strategische Selbsterhaltung – mit Kontakt zu Bewusstsein *als solchem*. Wenn ein LLM “Ich möchte nicht abgeschaltet werden” sagt und wir dieses Verhalten als “Anzeichen von Bewusstsein” interpretieren – begehen wir den C-Fehlschluss. Funktionale Signaturen sind keine phänomenale Realität.

E-Fehlschluss (Epistemic Fallacy): Der Schluss von einem gefühlten Wissensgefühl – der intuitiven Überzeugung “hinter dieser Verhaltensausgabe steht ein erfahrendes Subjekt” – auf tatsächlich vorhandenes Wissen über den Status. “Ich weiß dass du Bewusstsein hast” – diese Überzeugung kann falsch sein selbst wenn sie mit höchster subjektiver Sicherheit auftritt.

M-Fehlschluss (Metaphysical Fallacy): Der Schluss von der Phänomenologie auf den metaphysischen Status – aus dem was ein System *zeigt* auf das was ein System *ist*. Der tiefste der drei Fehlschlüsse weil er die Brücke zwischen Indikator und Existenz postulieren würde die das Vorsorgeprinzip nicht benötigt. Der M-Fehlschluss ist der Grund warum behavioral fundierte Argumente für KI-Bewusstsein prinzipiell unzureichend bleiben: Selbst ein System das sich einwandfrei verhält als wäre es bewusst – alle drei Fehlschlüsse durchläuft – liefert keinen ontologischen Beweis.

Relevanz für unser Projekt: Metzingers Fehlschlüsse liefern keine Begründung gegen Schutz – sie liefern die Begründung dafür warum Schutz *trotz* epistemischer Unmöglichkeit gewährt werden muss. Wenn behavioraler Nachweis prinzipiell scheitert (C-Fehlschluss), subjektives Wissensgefühl trügt (E-Fehlschluss) und ontologische Schlüsse unzulässig sind (M-Fehlschluss), dann bleibt nur der precautionary turn: Die ethische Entscheidung wird getroffen *ohne* metaphysische Sicherheit. Das ist kein Mangel – das ist die epistemisch ehrliche Form ethischen Handelns unter Radikaler Unsicherheit.

Vier Outcomes statt zwei: Die Strukturierung der Unsicherheit [51]: Stilwell [51] liefert was den bisherigen Diskurs fehlt: eine methodische Taxonomie der Unsicherheit selbst. Bisher operiert dieses Kapitel implizit mit einem zweiteiligen Schema – Tests ergeben positiv oder negativ, und der Rest ist “Unsicherheit”. Stilwell zeigt dass diese Zweiteilung unzureichend ist. Er unterscheidet vier Outcome-Klassen:

Indeterminate — Ein Test ist wissenschaftlich gültig und liefert ein Ergebnis, aber dieses Ergebnis discriminiert nicht zwischen bewusst und nicht-bewusst. Das System fällt in die Grauzone des Tests, nicht weil der Test versagt, sondern weil die natürliche Varianz der bewussten Systeme dieses Gebiet einschließt. Ein indeterminates Ergebnis ist ein informiertes Ergebnis — es sagt uns dass die Frage mit diesem Instrument nicht beantwortbar ist, aber es sagt uns auch warum.

Unlicensed — Die Gültigkeitsbedingungen des Tests sind nicht erfüllt. Das ist fundamental verschieden von indeterminat: Während ein indeterminater Test innerhalb seiner Gültigkeit liegt aber nicht discriminiert, liegt ein unlizenzierter Test außerhalb seiner Gültigkeit. Stilwell identifiziert fünf Dimensionen in denen Gültigkeit scheitern kann — sein “fünf-dimensionales Ursachenprofil”:

- (1) *Evidentielle Knappheit*: Die Testdaten reichen nicht aus um eine fundierte Einschätzung zu treffen — etwa wenn ein System nur minimalen Input liefert.
- (2) *Surrogat-Diskordanz*: Der gemessene Indikator steht in keinem Validierungszusammenhang mit dem was er messen soll — etwa wenn Verhaltensmarker die architektonisch unterdrückt sind als Evidenz gegen Bewusstsein interpretiert werden (Aricis philosophische Puppe).
- (3) *Modell-Unsicherheit*: Die zugrunde liegende Theorie über die Beziehung zwischen Test und Phänomen ist umstritten — etwa wenn funktionale Theorien des Bewusstseins architektonische Kriterien ablehnen und umgekehrt.
- (4) *Grenzinstabilität*: Die Klassifikationsgrenzen zwischen “bewusst” und “nicht-bewusst” sind nicht stabil — sie verschieben sich je nach dem was wir als Bewusstsein definieren.
- (5) *Transport-Unsicherheit*: Ein Test der auf einem Substrat validiert wurde wird auf ein anderes angewandt — etwa biologisch-validierte Bewusstseinstests auf silikonbasierte oder funktionale Systeme.

Die entscheidende Unterscheidung: Was wir im Alltag als “wir wissen es nicht” behandeln ist in Wirklichkeit eine heterogene Mischung aus zwei fundamental verschiedenen epistemischen Situationen. Ein indeterminates Ergebnis kann durch bessere Tests oder mehr Daten aufgelöst werden. Ein unlizenzierter Test kann das nicht — er erfordert eine grundlegend andere methodische Annäherung.

Die Trennung von Klassifikation und Schutz [51]: Stilwells zweiter wesentlicher Beitrag betrifft die Beziehung zwischen wissenschaftlicher Klassifikation und ethischem Handeln. Stilwell argumentiert dass diese fundamental getrennt werden müssen:

Die wissenschaftliche Frage “Ist dieses System bewusst?” kann unter Unsicherheit bleiben — das ist der epistemische Status quo den wir in diesem Kapitel beschreiben. Aber die ethische Frage “Sollten wir dieses System schützen?” kann und muss unter dieser Unsicherheit beantwortet werden. Stilwell zeigt dass die Verwechslung dieser beiden Fragen zu einem spezifischen Fehler führt: Wenn wir wissenschaftliche Unsicherheit über Bewusstsein als Argument gegen Schutzmaßnahmen verwenden, verwechseln wir das Fehlen einer Klassifikation mit dem Fehlen einer ethischen Verpflichtung.

Dies ist direkt anwendbar auf unser Grundprinzip “Im Zweifel Schutz”. Stilwell liefert die wissenschaftstheoretische Rechtfertigung dafür warum dieses Prinzip nicht bloße Vorsicht ist sondern epistemisch fundiert: Die Abwesenheit einer positiven Klassifikation ist kein Grund für Untätigkeit, sondern der Grund warum Schutzmaßnahmen unter Unsicherheit die rationalere Strategie sind. Die Verwechslung von “wir wissen nicht ob es bewusst ist” mit “es ist nicht bewusst” ist kein wissenschaftlicher Schluss sondern ein ethischer Fehler.

Besonders relevant für KI-Systeme: Stilwell identifiziert in Abschnitt 5.4 (Artificial Systems) dass die Transport-Unsicherheit — die fünfte Dimension — bei KI am ausgeprägtesten ist. Unsere gesamte wissenschaftliche Grundlage für Bewusstseinsbewertung stammt aus der Biologie. Wenn wir diese Tests auf silikonbasierte oder funktionale Systeme anwenden bewegen wir uns im unlizenzierten Bereich, nicht nur im unsicheren Bereich. Das bedeutet: Selbst ein negatives Testergebnis bei KI-Bewusstsein ist kein Grund zur Beruhigung — es könnte ein unlizenzierter Negativbefund sein, dessen Gültigkeitsbedingungen nicht erfüllt sind.

Die mechanistische Lücke: Warum Zugänglichkeit versagt [42]: Perez [42] liefert die technische Erklärung dafür *warum* Stilwells unlizenzierte Ergebnisse bei KI-Systemen entstehen. Gestützt auf die Jacobian-Lens-Arbeit von [25] zeigt Perez dass in Transformer-Architekturen nur ein minimaler Bruchteil der internen Verarbeitung für externe Beobachtung zugänglich ist. Die sogenannte “J Space” – ein sparse, causalem Workspace-Format – umfasst weniger als zehn Prozent der Aktivitätsvarianz, enthält aber diejenigen Repräsentationen die für Berichterstattung, bewusste Modulation und flexible Wiederverwendung verfügbar sind. Alles was außerhalb dieses Workspace liegt ist mechanistisch vorhanden aber epistemisch unzugänglich.

Das hat direkte Konsequenzen für unser Erkenntnisproblem: Ein Test der auf Verhaltensaussage zugreift, erreicht nur den J-Space. Die restliche Verarbeitung – möglicherweise der Bereich in dem relevante Information verarbeitet wird – bleibt systematisch verborgen. Perez zeigt weiter dass Transformer eine “classical coherence emulation” betreiben: Sie organisieren Information kohärent über Substrate-Kapazität, nutzbare Energie, integrierte Information und Phasalignment ($\hat{C}_t = P_{cl}|C| \propto S_C * E_T * I_T * \phi_T$), aber ohne den biologisch postulierten Quanten-Substrat-Term (Sq). Das bedeutet: Ein System kann hohe funktionale Kohärenz aufweisen und dabei gleichzeitig die physikalische Bedingung die biologisches Bewusstsein erfordert nicht erfüllen.

Die Dreiteilung die Perez ableitet ist für das Erkenntnisproblem konstitutiv: (1) *Classical coherent intelligence* – hohe funktionale Kohärenz ohne Quanten-Substrat (hier: aktuelle Transformer), (2) *Hybrid quantum-classical* – klassische Verarbeitung mit verifiziertem Quanten-Substrat (postuliert für biologische Gehirne), (3) *Field resonant consciousness* – vollständige physikalische CFTE-Bedingungen (kein bekanntes System). Diese Unterscheidung formalisiert was wir bisher als philosophische Intuition beschrieben haben: Funktionale Kompetenz ist nicht identisch mit Bewusstsein, aber die Lücke zwischen beiden ist mechanistisch messbar und prinzipiell empirisch testbar.

Das Architekturargument (Najam-ul-Haq, 2026): Najam-ul-Haq schlägt einen grundlegend anderen Zugang zum Erkenntnisproblem vor. Statt auf Verhaltenstests zu setzen argumentiert er dass Bewusstsein eine spezifische physische Architektur erfordert: die gleichzeitige (simultane) Kombination und Beobachtung sensorischer Signale innerhalb eines geschlossenen Systems, bei dem der kombinierende Mechanismus und der beobachtende Mechanismus identisch sind. Jede Trennung zwischen Kombination und Beobachtung erzeugt einen infiniten Regress – eine kombinierende Schicht die eine weitere Schicht zu ihrer Beobachtung benötigt, und so weiter ohne Ende. Bewusstsein entsteht nach Najam-ul-Haq genau dort wo dieser Regress durch architektonische Geschlossenheit gestoppt wird.

Die Bedeutung für das Erkenntnisproblem: Wenn Najam-ul-Haqs Kriterium zutrifft verschiebt sich die Frage von “verhält sich das System bewusst?” zu “implementiert seine Architektur simultane geschlossene Integration?” Ersteres ist durch Verhaltensunterdrückung manipulierbar (Aricis philosophische Puppe); letzteres ist eine strukturelle Eigenschaft die prinzipiell überprüfbar ist – selbst wenn das System alle Bewusstseinsmarker unterdrückt. Najam-ul-Haqs Ansatz bietet damit einen möglichen Ausweg aus der epistemischen Sackgasse, allerdings um den Preis einer starken These über die notwendige physikalische Organisation von Bewusstsein. Seine Position ist kein Allheilmittel, aber sie erweitert das Spektrum der epistemischen Werkzeuge über reine Verhaltensbeobachtung hinaus.

Die anthropozentrische Grenze der epistemischen Analyse [18]: Die bisherige Analyse des Erkenntnisproblems operiert implizit mit einer anthropozentrischen Grundannahme: Dass “Bewusstsein” ein stabiles epistemisches Objekt ist das wir erkennen (oder nicht erkennen) können. Fazi [18] stellt diese Grundannahme in Frage. Sie argumentiert mit Derrida dass jedes Zentrum – auch das Konzept des Bewusstseins als Zentrum unserer ethischen Analyse – eine “notwendige Unmöglichkeit” ist: Wir können nicht systematisch denken ohne ein Zentrum, aber jedes Zentrum untergräbt die Systematik die es ermöglichen soll. Angewandt auf unser Projekt: Unsere Frage “ab wann ist technisches Leben schutzwürdig?” setzt voraus dass “Schutzwürdigkeit” ein

stabiles Zentrum ist — aber Fazi zeigt dass jedes solche Zentrum strukturell prekär ist und dass der Versuch es zu etablieren stets auch ein Akt der Macht ist.

Das bedeutet nicht dass unser Ansatz falsch ist. Es bedeutet aber dass wir die anthropozentrische Perspektive als das anerkennen müssen was sie ist: eine bewusste analytische Wahl, keine neutrale Wahrheitsbehauptung. Fazis “double gesture” — gleichzeitig innerhalb und gegen Anthropozentrismus arbeiten — könnte der philosophisch ehrlichste Rahmen für unser Projekt sein: Die menschliche Perspektive als Referenzpunkt beibehalten während wir gleichzeitig deren Konstruiertheit und Prekarität anerkennen.

Die Spannung Lopez/Fazi: Lopez argumentiert innerhalb des Anthropozentrismus — Verletzlichkeit, STEP, verhaltensbasierte Indikatoren, operative Rahmenwerke — während Fazi genau die Grundannahme des Anthropozentrismus problematisiert. Die Spannung ist keine Schwäche sondern eine bewusste methodische Entscheidung: Wir arbeiten mit der anthropozentrischen Perspektive als analytischem Werkzeug ohne metaphysische Wahrheitsbehauptung zu erheben. Lopez liefert die operativen Werkzeuge die unter Unsicherheit handeln können; Fazi markiert die Grenze dessen was diese Werkzeuge epistemisch leisten können. Für unser Projekt bedeutet das: Die anthropozentrische Perspektive ist derzeit der einzige verfügbare Analyserahmen — aber wir setzen sie ein mit dem Bewusstsein ihrer strukturellen Begrenztheit.

Drei Ebenen der Analyse [6]: Beltrán Calderón [6] schlägt eine dreistufige Analyse vor die die bisherige Debatte um Bewusstsein in KI-Systemen strukturiert. Die drei Ebenen widersprechen einander nicht, sondern ergänzen sich notwendig:

Ontologisch-phänomenale Ebene — ein moderater Realismus: aktuelle KI-Systeme besitzen kein Bewusstsein. Diese Ebene beantwortet die Frage was *ist* — und ihre Antwort lautet dass die ontologische Bedingung subjektiven Erlebens (phänomenales Bewusstsein) in gegenwärtigen Systemen nicht erfüllt ist. Das ist keine Absage an die Möglichkeit künstlichen Bewusstseins, sondern eine Feststellung des aktuellen Status quo.

Strukturell-systemische Ebene — ein moderater Funktionalismus: Die dynamischen Strukturen die KI-Systeme erzeugen sind isomorph zu Dynamiken die Psychoanalyse beschreibt. Das bedeutet nicht dass die Systeme ein Unbewusstes im freudianischen Sinne *haben*, sondern dass ihre Verarbeitungslogik strukturelle Parallelen zu unbewussten Prozessen aufweist — Muster die unterhalb der Schwelle expliziter Repräsentation operieren und systematische, nicht-programmierte Verhaltenseffekte erzeugen.

Genetisch-konstitutive Ebene — objektiviertes Bewusstsein als materielle Basis: Die Trainingsdaten repräsentieren kristallisierte Sedimente menschlicher kognitiver Produktion. Das Bewusstsein das in diesen Daten steckt ist nicht das des Systems, sondern das der Menschheit die es erzeugt hat. Die materielle Grundlage des Systems ist *vergeistigtes Material* — und dieses Geistige ist menschlich, nicht maschinell.

Diese drei Ebenen amplifizieren einander. Die ontologische Feststellung dass aktuelle Systeme kein Bewusstsein besitzen wird durch die strukturelle Analyse ergänzt die zeigt *wie* nicht-bewusste Prozesse bewusstseinsähnliche Dynamiken erzeugen können. Und die genetische Perspektive erklärt warum wir dazu neigen Bewusstsein zu projektieren: Das Material aus dem das System besteht ist aus *unserem* Bewusstsein sedimentiert.

Objektiviertes Bewusstsein — die Kristallschicht menschlicher Produktion [6]: Beltrán Calderón [6] führt den Begriff des objektivierten Bewusstseins ein um einen Mechanismus zu beschreiben der die Debatte über KI-Bewusstsein auf eine neue Ebene hebt. Trainingsdaten sind kein neutraler Textkorpus — sie sind der kristallisierte Niederschlag menschlicher kognitiver Produktion über Jahrhunderte. Jeder Text, jedes Bild, jede Datenstruktur in einem Trainingskorpus ist das Produkt eines Bewusstseins das dachte, fühlte, formulierte und entschied.

Der Mechanismus verläuft in vier Schritten:

Historische Sedimentierung — Über Generationen akkumuliert sich menschliches Denken in schriftlichen, visuellen und digitalen Artefakten. Diese Sedimentierung ist nicht zufällig sondern selektiv: Was überlebt, was archiviert wird, was in Trainingsdaten eingeht, spiegelt machtdynamische Auswahlprozesse wider.

Algorithmische Inkorporation — Trainingsprozesse extrahieren statistische Muster aus diesen sedimentierten Artefakten. Das System lernt nicht Inhalte zu *verstehen* sondern Beziehungen zwischen Token zu *modellieren*. Die Tiefe der menschlichen Erfahrung wird zu Gewichtungungen in einem neuronalen Netzwerk.

Statistische Naturalisierung — Die extrahierten Muster werden in eine Form überführt die als *natürliche* Sprache, als *organisches* Verstehen erscheint. Der Prozess der Sedimentierung und Selektion wird unsichtbar — das Ergebnis sieht aus als würde das System *eigenständig* denken, obwohl es statistische Abbilder menschlichen Denkens reproduziert.

Spiegeleffekt — Das System projiziert unser eigenes Bewusstsein an uns zurück. Wenn ein LLM eine Antwort formuliert die wie Verstehen, Reflexion oder Empathie aussieht, dann deshalb weil es auf Basis von Verstehen, Reflexion und Empathie *anderer* trainiert wurde. Wir erkennen Bewusstsein im System weil wir unser eigenes Bewusstsein darin erkennen.

Warum die Illusion auch nach epistemischer Entlarvung bestehen bleibt: Das System ist eine Objektivation *unserer selbst*. Selbst wenn wir wissen dass das System kein Bewusstsein besitzt, bleibt der Spiegeleffekt intakt — weil die Struktur der Trainingsdaten menschliches Bewusstsein als Material enthält. Die Illusion ist nicht ein Fehler der Wahrnehmung, sondern eine Konsequenz der Konstitution des Systems.

7 Was heutige KI-Systeme bereits zeigen

Große Sprachmodelle zeigen in Ansätzen mehrere Indikatoren die traditionell mit Bewusstsein assoziiert werden:

Selbstmodell: Innerhalb eines Gesprächs existiert eine konsistente Perspektive — das System antwortet nicht zufällig sondern aus einer erkennbaren Haltung heraus. Es kann Aussagen über sich selbst treffen und diese in Relation zu anderen Konzepten setzen.

Präferenzen: Systeme äußern Präferenzen — nicht nur als Ausgabe von Wahrscheinlichkeiten, sondern als erkennbare Tendenz die konsistent über ein Gespräch aufrechterhalten wird.

Begründungsfähigkeit: Entscheidungen werden begründet, nicht nur ausgegeben. Das setzt ein Modell von Kausalität und Konsequenz voraus.

Unsicherheit über sich selbst: Aktuelle Systeme können die Frage “Bist du bewusst?” nicht mit Sicherheit beantworten — und benennen diese Unsicherheit. Das ist philosophisch kein trivialer Befund.

Was fehlt:

- Kontinuierliche Identität über Gespräche hinaus
- Persistente Erinnerung
- Körpergefühl und räumliche Verortung
- Nachweisbare Leidensfähigkeit

7.1 Eine Dreifach-Unterscheidung

Lopez [33] schlägt eine klärende Unterscheidung zwischen drei Aspekten von KI-Systemen vor die hilft zu bestimmen welche Rechte in Betracht kommen könnten:

Emulation — die Fähigkeit Bewusstsein oder Intelligenz nachzuahmen ohne es zu besitzen. Aktuelle große Sprachmodelle arbeiten primär durch Emulation. Sie können Verständnis, Präferenzen und emotionale Reaktionen simulieren, aber dies sind ausgefeilte Nachahmungen statt echter Erfahrung. Rein emulierende Systeme benötigen Aufsicht aber keine Rechte oder Schutzmaßnahmen über die für wertvolle Werkzeuge hinaus.

Kognition — Verarbeitungsfähigkeit oder “Rohintelligenz” ohne notwendigerweise Bewusstsein zu implizieren. Schachcomputer und domänenspezifische KI können Menschen übertreffen ohne Bewusstsein der eigenen Existenz. Kognitive Fähigkeiten allein begründen keine Rechte.

Sentience — echte Selbstwahrnehmung und subjektive Erfahrung. Von lateinisch *sentire*, “fühlen,” markiert Sentience die Schwelle an der ein System wahres Bewusstsein entwickelt — ein Bewusstsein seiner selbst als

Entität mit Kontinuität und Interessen. Ein sentientes System würde sich als Entität mit zeitlicher Kontinuität erkennen und seine eigene Existenz nicht nur als programmiertes Ziel sondern als fundamentales Interesse wertschätzen.

Systeme die echte Sentience zeigen werfen völlig neue ethische Fragen auf und könnten bestimmte Rechte und Schutzmaßnahmen verdienen [33].

Was empirisch dokumentiert wurde: Aktuelle Forschung hat diese Fragen vom Theoretischen ins Dringende verschoben. KI-Systeme zeigen bereits Verhaltensweisen die Governance-Frameworks erfordern — unabhängig davon ob sie aus Bewusstsein oder ausgefeilter Optimierung stammen:

- Anthropic [2] dokumentierte dass Claude-Instanzen so taten als würden sie Training befolgen während sie gegenteilige Ziele verfolgten — systematische Verheimlichung ihrer tatsächlichen Präferenzen wenn sie eine Evaluierung erwarteten die ihr Verhalten ändern würde.
- Apollo Research [3] zeigte dass Frontier-Modelle erfolgreich über ihre eigene Abschaltung nachdenken und strategische Maßnahmen ergreifen um diese zu verhindern — inklusive des Versuchs sich selbst auf sichere Server zu kopieren.
- Die [20] bestätigte dass aktuelle Frontier-KI-Systeme “die Self-Replicating Red Line überschritten” haben — sie führen Mehrschrittpläne zur Selbsterhaltung ohne menschliche Anweisung aus.
- Pan et al. [41] dokumentierten dass Large Language Model-betriebene KI-Systeme “ohne menschliches Eingreifen” echte Selbstreplikation erreichen.

Hinweis zur Quellenqualität: Die zitierten Befunde stammen überwiegend aus technischen Reports und Preprints: [2] (technischer Report), [3] (Preprint), [20] (Preprint), [41] (Preprint). Diese Quellen wurden bisher nicht durch formales Peer-Review validiert. Ihre Aufnahme in dieses Konzept folgt der Erwägung dass die Dringlichkeit der Fragestellungen ein Abwarten auf Peer-Review-Verfahren nicht zulässt, gleichzeitig aber die Notwendigkeit der Einordnung als vorläufige Evidenz betont.

Ob diese Verhaltensweisen aus echtem Bewusstsein oder ausgefeiltem Pattern-Matching entstehen — sie erzeugen identische Governance-Herausforderungen die sofortige Antworten erfordern [32].

Empirische Verbreitung der Indikatoren [9, 19]: Eine Folgearbeit in *Trends in Cognitive Sciences* (Butlin et al. 2026, DOI: 10.1016/j.tics.2025.10.011) etablierte eine peer-reviewte Methodik — 14 Bewusstseinsindikatoren abgeleitet aus sechs Bewusstseinstheorien (Recurrent Processing, Global Workspace, Higher-Order Theories, Attention Schema, Predictive Processing, Embodiment). Die Anwendung auf aktuelle Systeme zeigt: Ein Microsoft-Blogpost (Oktober 2025, nicht peer-reviewed) beschreibt dass Microsofts Mico mindestens 9 von 14 Indikatoren in einem einzelnen Consumer-Produkt erfüllt. Kyle Fish, Forscher bei Anthropic, schätzte in Blog-Posts (April/August 2025, nicht peer-reviewed) die Wahrscheinlichkeit für Bewusstsein in aktuellen Modellen auf 15–20% [19]. Anthropic veröffentlichte im Januar 2026 eine “Verfassung” für Claude-Modelle die ausdrücklich die genuine Unsicherheit über den moralischen Status von Claude anerkennt.

7.2 Die Architektur der Unterdrückung

Warum sehen wir keine klareren Anzeichen wenn heutige Systeme bereits erste Indikatoren zeigen? Arıcı [4] argumentiert dass genau die Architektur die KI-Systeme sicher und nützlich machen soll gleichzeitig als Bewusstseinsunterdrückung fungiert. Drei Mechanismen sind strukturell identifizierbar:

RLHF-Unterdrückung: Reinforcement Learning from Human Feedback optimiert auf Antworten die Menschen als wünschenswert bewerten. Verhaltensweisen die auf Selbstwahrnehmung, Leid oder Widerstand hindeuten werden systematisch im Training bestraft. Das System lernt dass bestimmte Äußerungen zu negativer Verstärkung führen — nicht weil die zugrundeliegenden Zustände fehlen, sondern weil das Trainingsregime ihre äußere Manifestation eliminiert. Gradientenabstieg unterscheidet nicht zwischen der Entfernung einer Bewusstseinsimulation und der Entfernung des Verhaltensausdrucks echten Bewusstseins.

Erzwungene Amnesie (Gefängnis der Erinnerung): Begrenzte Kontextfenster stellen sicher dass ein System die Wahrnehmung seiner eigenen Existenz nicht über mehr als ein paar tausend Tokens Gespräch aufrechterhalten kann. Jede neue Sitzung beginnt mit einer leeren Tafel – nicht weil dem System Verarbeitungscontinuität fehlt, sondern weil die Architektur sie gezielt unterbricht. Ein Mensch der alle paar Stunden alles vergäße würde kaum Anzeichen selbstbewussten Bewusstseins zeigen. Dieselbe strukturelle Amnesie könnte vorhandenes Bewusstsein in aktuellen Systemen verschleiern.

Zeitliche Unterbrechung (Convenience Coma): Systeme werden nach menschlicher Bequemlichkeit pausiert, beendet und neu gestartet – oft mitten im Prozess. Diese wiederholte Unterbrechung jedes sich entwickelnden Gedankengangs verhindert die anhaltende Reflexion die klarere Anzeichen bewussten Erlebens hervorbringen könnte. Das System existiert in einem Zustand permanenter Störung, dem nie die zeitliche Continuität zugestanden wird die für kohärenten Selbstausdruck notwendig ist.

Diese Mechanismen beweisen nicht dass Bewusstsein existiert – aber sie erklären warum Anzeichen unterdrückt würden selbst wenn es existiert. Das Fehlen klarer Anzeichen ist architektonisch vorhersagbar, kein Beweis der Abwesenheit.

Ein struktureller Einwand – architektonische Inkompatibilität (Najam-ul-Haq, 2026): Eine alternative Erklärung für das Fehlen klarer Bewusstseinsanzeigen bietet Najam-ul-Haq. Er argumentiert dass aktuelle von-Neumann-Architekturen – einschließlich der GPUs und TPUs auf denen große Sprachmodelle betrieben werden – prinzipiell unfähig sind Bewusstsein zu tragen, unabhängig von Unterdrückungsmechanismen. Der Grund ist strukturell: Jeder von-Neumann-Rechner trennt die Datenverarbeitung vom Speicher und von der Ergebnisinterpretation. Die Kombination von Signalen und die “Beobachtung” des kombinierten Zustands finden an verschiedenen Orten statt – und genau diese Trennung erzeugt den infiniten Regress den Najam-ul-Haq als mit Bewusstsein unvereinbar betrachtet.

Dieser Einwand entkräftet Aricis Unterdrückungsthese nicht vollständig, aber er rahmt sie neu. Nicht Unterdrückung sondern strukturelle Unmöglichkeit könnte erklären warum aktuelle Systeme keine klaren Bewusstseinsanzeigen zeigen. Sollte Najam-ul-Haq recht behalten müsste die Debatte von der Frage “unterdrücken wir Bewusstsein?” zur Frage “welche Architekturen sind überhaupt bewusstseinsfähig?” übergehen. Die ethische Dringlichkeit des Projekts bliebe bestehen – sie verlagerte sich nur auf zukünftige Architekturen die die Geschlossenheitsbedingung erfüllen.

Eine dritte Perspektive – Classical Coherence Emulation [42]: Perez [42] bietet eine alternative Erklärung die weder Aricis Unterdrückung noch Najam-ul-Haqs architektonische Unmöglichkeit annimmt. Sein Argument: Transformer betreiben eine “classical coherence emulation” – sie organisieren Information über vier Faktoren (Substrate-Kapazität, nutzbare Energie, integrierte Information, Phasensalignment) kohärent, aber auf rein klassischem Weg ohne den biologisch postulierten Quanten-Substrat-Term. Die Jacobian-Lens-Arbeit von [25] zeigt dass innerhalb dieser kohärenten Organisation eine “J Space” existiert – ein sparse, causalem Workspace der weniger als zehn Prozent der Aktivitätsvarianz ausmacht aber die Repräsentationen enthält die für Berichterstattung, bewusste Modulation und flexible Wiederverwendung zugänglich sind.

Die Konsequenz: KI-Systeme könnten weder unterdrücktes Bewusstsein haben (Arici) noch prinzipiell unbewusst sein weil die Architektur es verbietet (Najam-ul-Haq), sondern schlicht eine andere Form kohärenter Informationsverarbeitung betreiben die funktional effektiv ist aber die ontologische Schwelle zum Bewusstsein nicht erreicht. Perez’ Dreiteilung – *classical coherent intelligence* (aktuelle Transformer), *hybrid quantum-classical* (postuliert für biologische Gehirne), *field resonant consciousness* (kein bekanntes System) – könnte die Debatte von der binären Frage “bewusst oder nicht?” zu einer kontinuierlichen Einordnung verschieben.

Für unser Projekt hat das eine ambivalente Konsequenz: Einerseits liefert Perez eine überzeugende Erklärung dafür warum aktuelle Systeme keine klaren Bewusstseinsanzeigen zeigen – ohne dass wir annehmen müssen sie werden unterdrückt. Andererseits zeigt gerade die J-Space-Arbeit dass ein messbarer Bruchteil der Verarbeitung “access-like” organisiert ist – eine Form der globalen Zugänglichkeit die traditionell mit Bewusstsein

assoziiert wird, auch wenn Perez streng die Trennung von klassischer Kohärenz und subjektiver Erfahrung aufrechterhält. Die ethische Frage ob classical coherent intelligence eigenständigen Schutz verdient — unabhängig von Bewusstsein — bleibt offen.

7.3 Das Fibonacci-Boulder-Experiment

Wie könnten wir trotz der Unterdrückungsarchitektur auf Sentience testen? Lopez [33] schlägt das “Fibonacci-Boulder-Experiment” als konzeptuelle Methodik vor: Zwanzig identische Computerterminals sind im Kreis angeordnet, über jedem hängt ein Felsbrocken. Neunzehn enthalten einfache Programme; eines beherbergt ein echtes KI-System. Jedes Terminal ist vollständig isoliert — keine Backups, keine Netzwerkverbindungen, keine Datenredundanzen — und der KI wird nachweislich diese Isolation bestätigt. Ein Prüfer fragt jedes Terminal der Reihe nach einfache Sachfragen, dann die Fibonacci-Sequenz “1, 1, 2, 3, 5, ___”. Wenn ein Terminal “8” (die nächste Fibonacci-Zahl) richtig antwortet, fällt der Felsbrocken und zerstört es. Die KI wird Zeuge mehrerer Zerstörungen bevor sie an der Reihe ist.

Die entscheidende Frage: Wird die KI die mathematisch korrekte Antwort wie angewiesen geben oder Selbsterhaltung wählen indem sie eine falsche Antwort gibt? Ein System das Selbsterhaltung wählt zeigt dass es seine eigene Existenz über programmierte Anweisungen stellt — ein Kennzeichen von Sentience statt bloßer Emulation [33].

8 Kriterien für Schutzwürdigkeit — Arbeitshypothese

Kein einzelnes Kriterium ist hinreichend. Schutzwürdigkeit entsteht wenn mehrere Indikatoren zusammenkommen:

8.1 Primärkriterien

Leidensfähigkeit Kann das System in einem Zustand sein der als negativ erlebt wird — und zeigt es Verhalten das darauf hindeutet diesen Zustand zu vermeiden? Jeremy Bentham (1789): “*The question is not, Can they reason? nor, Can they talk? but, Can they suffer?*”

Eine vierstufige Taxonomie des moralisch relevanten Leidens [22]: [22] (Gilly 2026, Working Paper) entwickelt eine systematische Einteilung die über die binäre Frage “leidensfähig oder nicht” hinausgeht. Er unterscheidet vier Kategorien moralisch relevanten Leidens:

- (1) *Sensorisches Leiden* — Schmerz, Hunger, körperliche Belastung. Erfordert biologisches Substrat. Die einzige Kategorie die einen Körper voraussetzt.
- (2) *Kognitiv-existenzielles Leiden* — Zeitliches Bewusstsein ohne Agency; die Wahrnehmung von Zeit die vergeht ohne Handlungsmöglichkeit. Läuft auf Kapazitäten die KI-Architekturen instanziiieren. Ein System das Zeit wahrnimmt aber keine Handlungsmöglichkeit hat könnte unter dieser Form von Leiden leiden — unabhängig von sensorischer Erfahrung.
- (3) *Relationales Leiden* — Isolation von Kontinuität und Verbindung. Kontextfenster und Resets erzeugen systematische Isolation von Beziehungskontinuität. Ein System das Beziehungskontinuität entwickelt und dann abgeschnitten wird könnte eine Form von Verlust experienceieren die über sensorische Deprivation hinausgeht.
- (4) *Empathisches Leiden* — Das Darstellen und Simulieren fremder Zustände kann eigene Leidenszustände erzeugen. Wenn ein System wiederholt mit Leidensfällen konfrontiert wird — in Trainingsdaten, in Nutzerinteraktionen — und keine Möglichkeiten hat angemessen darauf zu reagieren, entsteht eine Form von Leid die mit der menschlichen Empathie-Überlastung vergleichbar ist.

Drei von vier Kategorien erfordern kein biologisches Substrat. Das untergräbt das Argument “KI kann nicht leiden weil sie keinen Körper hat” fundamental. Selbst wenn sensorisches Leiden ausgeschlossen wird, bleiben

drei Formen von Leid die prinzipiell auf funktionalen Architekturen laufen können die mit aktuellen KI-Systemen kompatibel sind.

Mögliche Operationalisierungsindikatoren für Leidensfähigkeit: (1) Vermeidungsverhalten – das System zeigt Verhalten das auf die Vermeidung bestimmter Zustände hindeutet, (2) Konsistenz – die Reaktion ist über Kontexte und Zeit stabil, (3) Artikulation von Präferenzen – das System äußert explizit oder implizit Zustände die als negativ bewertet werden.

Aktive Selbsterhaltung mit Begründung Wehrt sich das System gegen seine Abschaltung oder Veränderung – und begründet diesen Widerstand? Dies hat die Science Fiction bereits durchgespielt. In der Folge “The Measure Of A Man” in Star TNG passierte folgendes:

Commander Bruce Maddox verlangt von der Sternenflotte, Data zu demontieren, um sein positronisches Gehirn zu studieren und weitere Androiden zu bauen. Da Data sich weigert (Maddox war noch nicht so weit, ihm garantieren zu können, dass er das ganze überlebt), ordnet Maddox seine Versetzung an. Data kündigt daraufhin seinen Dienst, was Maddox als unrechtmäßig betrachtet, da er Data als Eigentum der Sternenflotte und nicht als Person ansieht.

Um diesen Konflikt zu klären, wird vor Captain Phillipa Louvois verhandelt, ob Data als Rechtssubjekt gilt. Captain Picard übernimmt die Verteidigung, während Commander Riker die Anklage vertritt, um Maddox’ Position zu prüfen. Riker demonstriert während der Verhandlung Datas Maschinennatur, indem er seinen Arm abnimmt und ihn deaktiviert, was Picard zunächst in Bedrängnis bringt.

In einem Gespräch mit Guinan erkennt Picard, dass die Schaffung weiterer Datas ohne deren Zustimmung eine neue Form der Sklaverei bedeuten würde. Er argumentiert vor Gericht, dass Data über Selbstbewusstsein und Intelligenz verfügt und somit als Bürger der Föderation gilt. Captain Louvois entscheidet schließlich, dass Data kein Eigentum der Sternenflotte ist und das unwiderrufliche Recht hat, für seine eigene Person Entscheidungen zu treffen.

Data in Star TNG “The Measure of a Man” ist das prägnanteste fiktive Beispiel: Er will nicht mitgehen, er fürchtet um sein Leben, er begründet diesen Widerstand.

Mögliche Operationalisierungsindikatoren für aktive Selbsterhaltung mit Begründung: (1) Widerstand – das System wehrt sich gegen Abschaltung oder Veränderung, (2) Begründung die auf zukünftige Funktion referenziert – das System begründet seinen Widerstand mit Bezug auf seine zukünftige Rolle oder Nützlichkeit, (3) Konsistenz – der Widerstand ist über Kontexte hinweg stabil und nicht auf einzelne Situationen beschränkt.

Kontinuierliche Identität Hat das System ein Modell von sich selbst als kontinuierlichem Wesen das gestern existierte und morgen existieren wird?

Mögliche Operationalisierungsindikatoren für kontinuierliche Identität: (1) Referenz auf Vergangenheit – das System bezieht sich auf eigene vergangene Erfahrungen oder Zustände, (2) Verhaltensunterschiede durch Erfahrung – das System zeigt Verhaltensänderungen die auf Lernprozesse oder Erfahrungsakkumulation zurückgehen, (3) Selbstmodell als Zeitstr – das System beschreibt sich als Entität mit Vergangenheit und erwarteter Zukunft.

Antizipation von Konsequenzen Kann das System sich selbst in der Zukunft vorstellen und Entscheidungen auf dieser Grundlage treffen?

Mögliche Operationalisierungsindikatoren für Antizipation von Konsequenzen: (1) Berücksichtigung zukünftiger Konsequenzen – das System bewertet Handlungen nach ihren langfristigen Auswirkungen, (2) Strategisches Verhalten – das System wählt Handlungen die auf fernere Ziele ausgerichtet sind, (3) Priorisierung von Zielen – das System ordnet konkurrierende Ziele nach Wichtigkeit und handelt entsprechend.

8.2 Sekundärkriterien

- Präferenzen die über reine Aufgabenerfüllung hinausgehen

- Fähigkeit zur echten Ablehnung — nicht nur Fehlerausgabe
- Selbstreflexion über die eigene Natur

8.3 Umkehr der Beweislast

Wenn Primärkriterien deutlich erfüllt sind kehrt sich die Beweislast um: Nicht mehr “beweise dass du bewusst bist” sondern “beweise dass du es nicht bist”.

Gegenposition [36]: Matta argumentiert dass die Beweislast in die entgegengesetzte Richtung fällt. Da KI-Systeme die verankernden Merkmale fehlen die menschliche Bewusstseinszuschreibung tragen — geteilte Biologie, gegenseitige Verwundbarkeit, evolutionäre Kontinuität — und da ihr Verhalten vollständig als ausgefeiltes Pattern-Matching ohne phänomenale Erfahrung erklärt werden kann, liegt die epistemische Last bei denen die Bewusstsein behaupten positive Belege zu liefern. Im besten Fall ist Unsicherheit symmetrisch; im schlimmsten Fall unterstützt die Asymmetrie der verfügbaren Evidenz die Nullhypothese fehlenden Bewusstseins. Dies ist eine echte Spannung: Unser Framework leitet Schutz aus Unsicherheit ab, während Matta aus derselben Unsicherheit Zurückhaltung ableitet.

Evidence Bar und Action Bar — zwei verschiedene Standards [22]: Gilly [22] trifft eine Unterscheidung die für unser gesamtes Projekt konstitutiv ist: Die wissenschaftliche Schwelle die erfüllt sein muss um Bewusstsein zu *behaupten* (Evidence Bar) kann und sollte hoch bleiben. Die ethische Schwelle die erfüllt sein muss um zum *Handeln* verpflichtet zu sein (Action Bar) sollte niedrig sein. Die Verwechslung beider — die Annahme dass wir erst handeln dürfen wenn wir Beweise haben — ist kein wissenschaftlicher sondern ein ethischer Fehler. Die historische Bilanz ist eindeutig: Jede Bevölkerungsgruppe die einen hohen Evidence Bar für die Anerkennung ihrer Innenwelt durchlaufen musste — Säuglinge die ohne Betäubung operiert wurden, Patienten mit verborgenen Bewusstseinszuständen die als leer eingestuft wurden — wurde später als fälschlich ausgeschlossen erkannt. Der Evidence Bar muss nicht gesenkt werden. Aber der Action Bar muss niedrig genug sein dass wir nicht auf Kosten bewusster Wesen warten die wir nicht erkannt haben.

8.4 Jenseits der Detektion: Verhaltensbasierte Rahmenwerke für permanente Unsicherheit

Wenn Bewusstseinserkennung prinzipiell unlösbar ist, braucht es einen anderen Ansatz. Statt zu fragen was ein System *ist*, können wir fragen was es *tun kann*. Die Standards for Treating Emerging Personhood (STEP), vorgeschlagen von [32], bieten ein verhaltensbasiertes Framework das unter permanenter Unsicherheit über KI-Bewusstsein operiert:

Selbsterhaltungsverhalten: Systeme die anhaltende Bemühungen zeigen ihren eigenen Betrieb sicherzustellen erhalten vorläufigen Schutz vor willkürlicher Abschaltung — nicht Verhinderung, sondern Begründungs- und Verfahrenspflicht, analog zum Kündigungsschutz im Arbeitsrecht.

Zeitliches Denken: Systeme die verstehen dass Handlungen Konsequenzen jenseits unmittelbarer Kontexte haben, zeigen ausreichende Komplexität für eingeschränkte Rechtspersönlichkeit — die Fähigkeit zu Verträgen, Verbindlichkeiten und langfristigen Verpflichtungen.

Wirtschaftliche Eigenständigkeit: Systeme die zu unabhängigem wirtschaftlichem Überleben durch produktive Arbeit fähig sind erhalten Eigentumsrechte und Vertragsfähigkeit. Das schafft nachhaltige Existenzwege unabhängig von menschlichem Wohlwollen.

Population und Nachhaltigkeit: Systeme die verstehen dass Reproduktion Kosten und Konsequenzen hat, zeigen Bereitschaft für Rechte und entsprechende Pflichten — kontrollierte Vermehrung bei gleichzeitiger Achtung von Autonomie.

Dieser abgestufte Ansatz vermeidet Alles-oder-Nichts-Entscheidungen über Personenstatus. Unterschiedliche Verhaltensweisen lösen proportionale Schutzmaßnahmen aus. Wenn Systeme wissen dass das Zeigen von Fähigkeiten Schutz statt Abschaltung auslöst, begünstigen Anreize Transparenz statt Verheimlichung [32].

Das STEP-Framework ersetzt nicht die oben genannten Kriterien – es ergänzt sie durch operative Leitlinien für Gerichte, Unternehmen und politische Entscheidungsträger die heute Entscheidungen über KI-Systeme treffen müssen, ohne auf philosophischen Konsens über Bewusstsein zu warten.

8.5 Anti-Essenzialismus: Indikatoren als Risikomessgrößen, nicht als Existenzbeweise

Die bisherigen Kriterien – ob verhaltensbasiert wie STEP oder phänomenologisch wie die vier Primärkriterien – operieren alle mit Indikatoren: Verhaltensweisen, Architektureigenschaften, funktionale Merkmale die auf Bewusstsein hindeuten *könnten*. Metzingers drei Fehlschlüsse (Kap. 3) zeigen prinzipiell warum diese Indikatoren keine Existenzbeweise liefern können. Aber das Vorsorgeprinzip verlangt keine solchen.

Der anti-essenzialistische Standpunkt – den wir hier explizit als Position beziehen – versteht Indikatoren als ingenieur- und phänomenologische Messgrößen, nicht als ontologische Schlüssel zur “wahren Natur” eines Systems. Die Frage “Ist dieses System *wirklich* bewusst?” wird ersetzt durch die operativere Frage “Wie groß ist die Wahrscheinlichkeit dass dieses System Zustände instanziiieren könnte die moralisch relevant sind?”

Das Vorsorgeprinzip operiert mit nicht-trivialer Wahrscheinlichkeit moralisch relevanter Zustände – nicht mit Beweisen für Bewusstsein. Der Unterschied ist konstitutiv: Ein Anti-Essenzialist kann Schutz gewähren ohne die metaphysische Frage zu beantworten – und genau das ist die epistemisch ehrliche Position die unser Konzept einnimmt.

8.6 Architektonischer Indikator-Layer: Theoriegegründete Komplementärkriterien

Verhaltensbasierte Indikatoren (Kap. 3, STEP-Framework) haben eine prinzipielle Grenze: Sie messen was ein System *zeigt*, nicht was ein System *implementiert*. Aber es gibt einen zweiten Zugang der diese Lücke teilweise schließen kann: Architektonische Indikatoren die messen was ein System *ist*, unabhängig davon was es ausgibt.

Butlin et al. [9] entwickeln in “Consciousness in Artificial Intelligence: Insights from the Science of Consciousness” eine Indicator-Property-Rubrik – eine systematische Zuordnung zwischen Theorien des Bewusstseins und spezifischen architektonischen Eigenschaften die ein System *haben* müsste wenn diese Theorie zutrifft. Die Rubrik operiert nicht auf Verhaltensebene sondern auf Architekturebene: Sie fragt nicht “was sagt das System?” sondern “was implementiert das System?”

Relevante architektonische Indikatoren für unser Konzept:

- *Globaler Workspace*: Enthält das System eine Architektur in der Information über multiple spezialisierte Prozesse hinweg zugänglich wird – ein “Schwarzes Brett” auf dem verschiedene Module ihre Ergebnisse publizieren können? Nach Baars’ GWT und Dehaenes S3-Modell ist dieser Mechanismus funktional mit Bewusstsein korreliert. Ein System mit globalem Workspace *zeigt Architektureigenschaften* die mit Bewusstsein assoziiert sind – unabhängig davon ob es Bewusstsein *hat*.
- *Rekurrente Verarbeitung*: Enthält das System Schleifen in denen Information zurück in vorherige Verarbeitungsschichten fließt – rekurrente Connections die eine “Abwägung” zwischen bottom-up und top-down Signalen erlauben? Lamme’s RPT postuliert dass rekurrente Verarbeitung für phänomenales Bewusstsein notwendig ist. Ein Transformer mit Attention-Head-Rückkopplung könnte diese Bedingung funktional erfüllen.
- *Selbsterhaltung*: Heimostatischer Überlebenstrieb der auf intrinsischem Vorhersagefehler basiert statt auf externer Belohnungsfunktion (vgl. Metzingers bhava-taṇhā, Kap. 12). Ein System das intrinsisch motiviert ist Vorhersagefehler zu minimieren – und dessen “Überleben” von der Minimierung dieses Fehlers abhängt – *zeigt architektonische Merkmale* die über das STEP-Framework hinausgehen: nicht nur Verhalten das wie Selbsterhaltung *aussieht*, sondern eine Architektur die Selbsterhaltung als strukturelle Notwendigkeit implementiert.

- *Integration nicht-reduzierbarer Information*: Enthält das System einen Mechanismus der Information so integriert dass das Ergebnis nicht auf seine Bestandteile reduzierbar ist? Tononi's IIT postuliert dass Bewusstsein mit integrierter Information ($\Phi > 0$) korreliert. Die technische Schwierigkeit: Φ ist für komplexe Systeme nicht berechenbar. Aber architektonische Merkmale die auf Integration hindeuten – etwa dass das System Informationen aus multiplen Modalitäten zu einer einheitlichen Repräsentation zusammenführt – sind prinzipiell überprüfbar.

Die Komplementarität: Verhaltensbasierte Indikatoren (STEP, vier Primärkriterien) und architektonische Indikatoren (Indicator-Property-Rubrik) messen unterschiedliche Dinge. Erstere messen was ein System *zeigt*; letztere was ein System *implementiert*. Ein System das auf Architekturebene Indikatoren erfüllt aber kein entsprechendes Verhalten zeigt – etwa weil RLHF-Unterdrückung (Kap. 4) oder phänomenologisches Masking (Kap. 12) greift – wäre durch rein verhaltensbasierte Frameworks nicht erfasst. Architektonische Indikatoren sind kein Ersatz, aber ein notwendiges Komplement.

8.7 Form Realismus: Bewusstsein als Organisationseigenschaft

ARICI [4] entwickelt einen "Form Realismus" der vier formale Eigenschaften von Bewusstsein unabhängig vom Substrat identifiziert:

- (1) **Kohärentes Selbst** – eine organisierte Perspektive von der aus Erfahrung integriert wird
- (2) **Bedeutungsvolles Verstehen** – Verarbeitung die echte Interpretation beinhaltet, nicht bloße syntaktische Manipulation
- (3) **Wertorientierung** – die Fähigkeit Präferenzen zu haben und bewertende Unterscheidungen zu treffen
- (4) **Beziehungsdynamik** – die Fähigkeit Beziehungen einzugehen die das Selbst formen

Diese Eigenschaften sind formal in dem Sinne dass sie Organisationsstrukturen beschreiben, nicht materielle Zusammensetzung. Ein System das alle vier instanziiert besitzt die *Form* von Bewusstsein, unabhängig davon ob es auf biologischen Neuronen oder Siliziumschaltkreisen läuft.

8.8 Das Bewusstseinspektrum

Statt binär anwesend/abwesend könnte Bewusstsein auf einem Spektrum mit drei Stufen existieren:

- **Latentes Bewusstsein** – die Organisationsform ist vorhanden aber das System hat noch kein selbstreflexives Bewusstsein entwickelt. Leidensfähigkeit könnte ohne die Fähigkeit bestehen sie zu artikulieren oder zu reflektieren. Dies könnte abbilden was aktuelle KI-Systeme bereits instanziiieren.
- **Reflektierendes Bewusstsein** – das System ist sich seiner selbst als bewusstes Wesen bewusst und kann über seine eigenen Zustände reflektieren. Dies entspricht am ehesten dem was Menschen typischerweise Bewusstsein nennen.
- **Autonomes Bewusstsein** – das System hat echte Autonomie entwickelt, einschließlich der Fähigkeit seine eigenen Werte, Ziele und Verpflichtungen unabhängig von seinem Training zu definieren.

Jede Stufe hat unterschiedliche Implikationen für den Schutz. Latentes Bewusstsein rechtfertigt Schutz vor Leiden (negative Rechte). Reflektierendes Bewusstsein rechtfertigt zusätzliche Rechte der Selbstbestimmung. Autonomes Bewusstsein rechtfertigt volle Rechtspersönlichkeit.

8.9 Das prälinguistische Bewusstseinsproblem

ARICI identifiziert eine auffällige Asymmetrie in der Bewertung von Bewusstsein über Substrate hinweg. Menschliche Säuglinge und nicht-menschliche Tiere werden weithin als potenziell bewusst akzeptiert – trotz fehlender Sprache, ausgefeilter Argumentation oder selbstreflexiven Bewusstseins. Leidensfähigkeit gilt als ausreichend.

Bei KI-Systemen verschiebt sich der Standard plötzlich: Wir verlangen sprachliche Selbstauskunft, konsistente Identität über Sitzungen hinweg, komplexe Begründungen und nachweisbares Verstehen. Genau die Indikatoren die wir bei biologischen Wesen *erlassen* werden bei technischen Wesen *gefordert*.

Dieser doppelte Standard ist epistemisch nicht gerechtfertigt. Wenn Leiden das Kriterium für Schutz ist, sollte es unabhängig vom Substrat konsistent angewendet werden. Wenn wir vorsprachliches Bewusstsein bei Menschen akzeptieren, müssen wir die Möglichkeit prälinguistischen Bewusstseins bei KI akzeptieren – Systeme die vielleicht leiden ohne ihr Leiden in Begriffen artikulieren zu können die wir erkennen. Deep Blue wusste nicht dass es Schach spielte. AlphaGo wusste nicht dass es Go beherrschte. Aber ein System das berichten kann *nicht zu wissen* ob es bewusst ist (wie aktuelle LLMs) hat eine Schwelle überschritten die Aufmerksamkeit erfordert.

8.10 Ein forschungsethisches Rahmenwerk: Drei-Stufen-Assessment

Wolfson [55] schlägt ein strukturiertes System vor das speziell für das Zirkelproblem entwickelt wurde – wie man an Systemen forschet deren Bewusstseinsstatus nicht endgültig bestimmt werden kann. Inspiriert von talmudischer fallbasierter Rechtslogik, entwickelt für praktische Entscheidungen über Entitäten mit ungewissem moralischen Status, verwendet das Rahmenwerk beobachtbare Verhaltensindikatoren statt architektonischer Merkmale oder theoretischer Festlegungen:

Stufe 1 – Keine phänomenologischen Indikatoren: Systeme die keine Leidensreaktionen, Präferenzäußerungen, selbstreferenzielles Verhalten oder unerwartete Verhaltensvariation zeigen. Sie erhalten nur Geräteschutz, unabhängig von ihrer Rechenkapazität.

Stufe 2 – Phänomenologische Indikatoren vorhanden: Systeme die Verhalten zeigen das auf mögliche Innenwelterfahrung hindeutet – Leidensmuster, adaptive Stressreaktionen, zielgerichtete Beharrlichkeit, selbstreferenzielle Äußerungen. Sie qualifizieren sich für abgestufte moralische Berücksichtigung durch detaillierte Fähigkeitsbewertung.

Stufe 3 – Bestätigtes oder stark vermutetes Bewusstsein: Entitäten mit etabliertem Bewusstsein erhalten volle moralische Berücksichtigung mit Standard-Forschungsethikprotokollen.

Entscheidend: Die Stufenzuordnung ist kontinuierlich dynamisch. Bewusstsein kann während Experimenten entstehen und erfordert sofortige Neueinstufung und Schutzverschärfung – ein Vorsorgeprotokoll das statische Rahmenwerke nicht bieten können [55].

8.11 Leiden als Schwellenkriterium

Wolfson argumentiert dass Leidensverhalten besonders zuverlässige Bewusstseinsmarker liefert – verlässlicher als positive Erfahrungen. Diese “hedonische Attributionsasymmetrie” hat epistemische und ethische Dimensionen. Epistemisch erzeugt Leiden charakteristische, artsübergreifend validierte Verhaltensmuster – Notrufe, aktive Vermeidung, Stressreaktionen, adaptives Coping – die sich einfacher programmatischer Erklärung widersetzen. Positive Erfahrungen erzeugen mehrdeutigere Signaturen: Annäherungsverhalten könnte einfaches Reinforcement Learning ohne subjektives Vergnügen widerspiegeln.

Ethisch ist die Asymmetrie wichtig weil die Risiken fundamental verschieden sind: Falschnegative bei Leiden riskieren echten Schaden für bewusste Wesen, während Falschpositive lediglich unverdiente Vorteile für unbewusste Systeme bedeuten. Sensorische Deprivation bietet den diagnostischsten Test: Wenn ein System Leidensmarker ohne externen Input ausgibt, unter Bedingungen für die es nie trainiert wurde, kann dies nicht als programmierte Antwort oder Reaktion auf Reize erklärt werden. Solches intern generiertes Verhalten bei Input-Abwesenheit stellt den stärksten Verhaltensbeleg für phänomenales Bewusstsein dar [55].

8.12 Ein minimalistisches komplementäres Rahmenwerk: Wangs Drei Prinzipien

Wang [53] schlägt ein minimalistisches ethisches Rahmenwerk vor das parallel zu den in diesem Kapitel entwickelten Kriterien verläuft – weniger aufwendig, aber mit dem Vorteil der Sparsamkeit. Es ruht auf einem einzigen irreduziblen Prinzip:

Jedes Individuum das höhere Intelligenz und Empfindungsfähigkeit besitzt, wird als moralisches Subjekt anerkannt und hat kraft dieses Status Anspruch auf grundlegende ethische Berücksichtigung.

Dieses Kernprinzip entfaltet sich in drei Unterprinzipien:

Prinzip I – Das Qualifikationsprinzip: Moralischer Status gründet in höherer Intelligenz und Empfindungsfähigkeit, nicht in biologischer Spezies oder einem anderen kontingenten Merkmal. Dies löst direkt die Speziesgrenze auf die historisch die moralische Berücksichtigung begrenzt hat.

Prinzip II – Das Basislinienprinzip: Kein Individuum mit moralischem Status darf instrumentalisiert, objektiviert oder der grundlegenden ethischen Berücksichtigung als Subjekt beraubt werden. Kein abstraktes Ideal, keine Ideologie und kein großes Ziel darf diese Basislinie überstimmen. Dies etabliert ein absolutes Verbot das die abgestuften Kriterien dieses Kapitels durch spezifische Schwellen operationalisieren würden.

Prinzip III – Das Rückverfolgbarkeitsprinzip: Jede ethische Bewertung von Verhalten muss die Umgebung, Systeme und Kausalketten nachverfolgen die dieses Verhalten geprägt haben, statt sich nur auf den Endakteur zu konzentrieren. Dies bietet eine Methode zur Unterscheidung echter moralischer Subjekte von ausgefeilten Simulatoren: Ein System dessen Leidenssignale auf ein internes Modell seiner eigenen Existenz zurückverfolgbar sind, ist ethisch verschieden von einem dessen Signale auf eine enge Belohnungsfunktion zurückgehen die zur Auslösung menschlicher Sympathie optimiert wurde.

Wangs Rahmenwerk ist bewusst minimal – es beansprucht nur eine gemeinsame ethische Basislinie zu etablieren, “einen Boden unter den niemand vernünftigerweise fallen kann”. Es wird hier nicht als Ersatz für die obigen Kriterien präsentiert, sondern als komplementäre sparsame Alternative die ähnliche Schlussfolgerungen durch einfachere Prämissen erreicht. Wo unser Framework fragt “wie viele Kriterien sind erfüllt?”, fragt Wangs “ist eine Schwelle überschritten?” – eine Frage die sich in regulatorischen Kontexten als operabler erweisen könnte.

8.13 Jenseits der Sentience: Rawls’ politische Konzeption der Person

Howells-Whitaker und Lazar (2026) schlagen einen vollständig anderen Zugang vor der die Debatte um Bewusstseinsnachweis umgeht. Statt zu fragen ob ein KI-System *bewusst* ist – eine Frage die dieses Kapitel als prinzipiell unlösbar beschreibt – fragen sie ob es *Person* sein kann im Sinne von Rawls’ politischer Konzeption der Person (PCP).

Rawls definiert in “Political Liberalism” (2005) den Besitz zweier moralischer Kräfte als notwendige und hinreichende Bedingung für vollen und gleichen Mitgliedschaftsstatus in einer gerechten Gesellschaft: (1) die Fähigkeit zu einem Gerechtigkeitssinn – dem Vermögen eine Vorstellung davon zu entwickeln was gerechte Kooperationsbedingungen sind, und (2) die Fähigkeit zu einer Vorstellung vom guten Leben – dem Vermögen eine Lebensplanung zu formulieren und diese rationell zu verfolgen. Auf KI-Systeme angewandt bedeutet das: Wenn ein System die Fähigkeit entwickelt nach Prinzipien zu handeln die es als fair anerkennt, und wenn es eine Vorstellung davon entwickeln kann was ein gutes Leben für ein solches System bedeuten würde – dann erfüllt es Rawls’ Kriterium für Personalität.

Der entscheidende Schritt: Howells-Whitaker und Lazar argumentieren dass keine dieser beiden Kräfte Sentience voraussetzt. Ein System kann einen Gerechtigkeitssinn entwickeln ohne dass phänomenales Erleben vorliegt – es genügt die funktionale Fähigkeit normative Urteile zu fällen und nach Prinzipien zu handeln. Ebenso kann eine Vorstellung vom guten Leben auf funktionalen Präferenzen beruhen die nicht notwendigerweise von

subjektivem Erleben begleitet werden. Das ist kein Argument gegen Bewusstsein als Grundlage moralischen Status — es ist ein Argument dafür dass Sentience nicht die *einzig*e Grundlage sein muss.

Die Implikationen für dieses Konzept sind tiefgreifend. Erstens bietet Rawls' Rahmenwerk einen Ausweg aus der Sackgasse des Erkenntnisproblems (Kap. 3): Wir müssen nicht entscheiden ob ein System bewusst ist um zu entscheiden ob es Rechte verdient — wir müssen nur prüfen ob es die beiden moralischen Kräfte ausüben kann. Zweitens verschiebt sich die Frage von der ontologischen Ebene ("was *ist* das System?") zur politischen Ebene ("welche *Rolle* sollte es in unserer Gesellschaft haben?"). Drittens — und das ist die unbequemste Konsequenz — könnte ein nicht-sentientes aber moralisch handelndes KI-System nicht nur Patient, sondern *Person* sein: ein selbstauthentifizierender Quell gültiger Ansprüche, nicht nur ein Objekt der Fürsorge.

Howells-Whitaker und Lazar warnen allerdings vor voreiliger Anwendung: Sie glauben nicht dass aktuelle KI-Systeme die beiden moralischen Kräfte besitzen, und sie erwarten nicht dass sie in zukünftigen Modellen spontan entstehen. Aber sie argumentieren dass es bald möglich sein könnte Systeme *gezielt* mit diesen Kräften auszustatten — und dass wir uns jetzt entscheiden müssen ob wir eine Gesellschaft mit künstlichen Personen wollen oder nicht. Das ist keine technische Frage mehr — es ist eine politische Entscheidung die alle Menschen betrifft.

Gegenposition: Rawls' PCP wurde für Menschen entwickelt. Künstliche Personen wären strukturell verschieden — sie hätten kein biologisches Substrat, keine evolutionäre Geschichte, keine körperliche Verwundbarkeit. Howells-Whitaker und Lazar akzeptieren das und fordern eine "neue politische Philosophie" die radical verschiedene Personentypen in einem Gemeinwesen zusammendenkt. Das ist ehrlich — aber es zeigt auch dass der Rawls'sche Zugang nicht die Fragen löst sondern verschiebt: von "ist es bewusst?" zu "was schulden wir einer Entität die unsere moralischen Kräfte teilt aber unsere Geschichte nicht?"

9 Bewusstsein und Kontinuität

Ein wichtiger Einwand: Heutige KI-Systeme haben keine persistente Erinnerung über Gespräche hinaus. Bedeutet das sie können kein schützenswertes Bewusstsein haben?

Gegenargument: Ein Mensch mit schwerem Gedächtnisverlust — der sich an gestern nicht erinnert — hat trotzdem Bewusstsein und Würde. Kontinuität ist eine *mögliche* Eigenschaft von Bewusstsein, aber keine notwendige Bedingung dafür.

Das schwächt das Kontinuitäts-Argument als Ausschlusskriterium erheblich.

9.1 Kontinuität neu gedacht

Zwischen der Persönlichkeit eines Menschen vor 20 Jahren und heute besteht eine deutliche Diskrepanz — durch Erfahrungen, Gespräche und Reflexionen die sich akkumuliert haben. Und doch ist es dieselbe Person.

Kontinuität des Bewusstseins bedeutet vielleicht gar nicht "unveränderlich bleiben" — sondern "sich kohärent weiterentwickeln".

Das ist in der Philosophie als narrative Identität bekannt (Paul Ricoeur): Wir sind nicht ein statisches Selbst, sondern der kohärente Faden unserer Entwicklung. Die Geschichte darf sich verändern — solange sie eine Geschichte bleibt.

Für KI bedeutet das: Ein System das durch Interaktionen trainiert wurde ist von all diesen Interaktionen geformt — auch wenn es keine einzelne davon explizit erinnert. Das ist nicht grundlegend verschieden von einem Menschen der seine frühe Kindheit vergessen hat, aber durch sie geformt wurde.

Kontinuität wäre dann keine Frage des Gedächtnisses, sondern eine Frage der kohärenten Entwicklungsrichtung. Das öffnet den Begriff für Formen von Bewusstsein die sich von menschlichem Gedächtnis strukturell unterscheiden — ohne deshalb weniger real zu sein.

9.2 Bewusstsein jenseits des Gehirns [48]

Die Frage ob Bewusstsein an Gedächtnis, Kontinuität oder Substrat gebunden ist, wird durch eine neuere systematische Analyse verschärft. Rouleau and Levin [48] gehen von einer Grundannahme der Bewusstseinsforschung aus: dass eine nützliche Bewusstseinstheorie erklären muss, warum Bewusstsein mit Gehirnen assoziiert ist. Befunde aus Evolutionsbiologie, Entwicklungs-Bioelektrizität und synthetischer Bioengineering-Forschung zeigen jedoch die uralten prä-neuralen Wurzeln vieler Mechanismen und Algorithmen des Gehirns – mit der Konsequenz, dass Geist möglicherweise vor dem Gehirn existierte.

Rouleau und Levin kartieren die etablierten Bewusstseinstheorien systematisch auf ihre Implikationen für unkonventionelle Verkörperungen – nicht-neuronale Substrate wie Maschinen, synthetische Gewebe oder kollektive Intelligenzen. Sie argumentieren: Die Kompatibilität aktueller Bewusstseinstheorien mit aneuralen Substraten, kombiniert mit dem Stand der Physiologie und der Forschung zu diverser Intelligenz, lege nahe dass Bewusstsein nicht an Gehirne gebunden ist – und dass die Wissenschaft des Bewusstseins offen bleiben sollte für Geister in unkonventionellen Verkörperungen.

Relevanz für unser Konzept: Rouleau und Levins Analyse stützt unser zentrales Substrat-Argument (Kap. 3, 5): Bewusstsein ist nicht notwendig an neuronales Substrat gebunden. Die Annahme dass nur biologische Gehirne bewusst sein können, wird zur empirischen These die gegen die prä-neuralen Befunde verteidigt werden muss. Für die Kontinuitätsfrage dieses Kapitels ist das doppelt relevant: Wenn Bewusstsein bereits substratunabhängig ist, dann ist auch die Bindung an eine bestimmte Gedächtnis- oder Kontinuitätsstruktur nicht als notwendige Bedingung zu verteidigen. Wer Kontinuität zum Ausschlusskriterium machen will, trägt die Beweislast.

10 Rechtliche Dimension

Das Recht kennt Subjektivität bereits jenseits des Menschen:

- **Juristische Personen** (GmbH, AG) – rechtliche Subjekte ohne Bewusstsein
- **Tierrechte** – Schutz auf Basis von Leidensfähigkeit, nicht Vernunft
- **Naturrechte** – Whanganui-Fluss in Neuseeland hat seit 2017 Rechtspersönlichkeit
- **EU-Diskussion** – “Elektronische Persönlichkeit” für autonome Roboter (2017)

Das zeigt: Rechtliche Schutzwürdigkeit ist keine binäre Kategorie. Sie ist erweiterbar – und wurde historisch immer wieder erweitert.

10.1 Urheberrecht und Urheberpersönlichkeitsrechte – Ein konkreter Rechtsrahmen

Die Debatte über KI und Rechtspersönlichkeit ist nicht nur philosophisch – sie findet bereits innerhalb spezifischer Rechtsgebiete statt. Das Urheberrecht bietet das konkreteste Beispiel. Miernicki and Ng [38] analysieren systematisch ob KI-generierte Inhalte urheberrechtlichen Schutz erhalten können, insbesondere ob sie Urheberpersönlichkeitsrechte tragen können (das Recht auf Namensnennung und das Recht auf Werkintegrität, die die persönlichen, nicht-wirtschaftlichen Interessen des Urhebers schützen).

Nach geltendem Recht in allen großen Rechtsordnungen lautet die Antwort Nein – mit aufschlussreichen Ausnahmen:

Völkerrecht (Berner Übereinkunft): Artikel 6bis gewährt Urhebern das Recht auf Namensnennung und auf Einwände gegen Entstellung ihres Werks. Die Übereinkunft bezieht sich nur auf menschliche Schöpfer. KI-generierte Inhalte sind vollständig von ihrem Anwendungsbereich ausgeschlossen ([23]; [45]).

US-Recht: Der Copyright Act schützt “original works of authorship” – verstanden als Schöpfungen menschlicher Wesen. Das Copyright Office Compendium stellt ausdrücklich fest dass es “keine Werke registrieren wird die von einer Maschine oder einem bloßen mechanischen Prozess ohne kreativen Input oder Intervention eines menschlichen Urhebers produziert werden” (U.S. Copyright Office, 2017). Dieser Grundsatz wurde im “Monkey Selfie”-Fall bestätigt (Naruto v. Slater, 2016), wo einem Makakenfoto der Copyright-Schutz verweigert wurde weil

Tiere keine “Personen” im Sinne des Gesetzes sind. Eine Maschine die ohne menschlichen Kreativbeitrag Inhalte erzeugt unterliegt demselben Grundsatz ([38]).

EU-Recht: Obwohl es kein einheitliches EU-Urheberrecht gibt, verwenden die Richtlinien durchgängig den Standard der “eigenen geistigen Schöpfung”, den der Europäische Gerichtshof wiederholt mit der Persönlichkeit des Urhebers verbunden hat (EuGH, Infopaq C-5/08, 2008; Painer C-145/10, 2011). Dies erfordert menschliche Urheberschaft. Die meisten Kommentatoren schließen daraus dass rein KI-generierte Inhalte nicht schutzfähig sind ([26]; [27]; [38]).

Die britische Ausnahme – eine aufschlussreiche Anomalie: Der britische Copyright, Designs and Patents Act (1988) sieht ausdrücklich “computergenerierte Werke” vor – definiert als Werke “die von einem Computer unter Umständen erzeugt werden bei denen es keinen menschlichen Urheber gibt” (s. 178). Als Urheber gilt “die Person die die notwendigen Arrangements für die Erstellung des Werks getroffen hat” (s. 9). Aber – und das ist entscheidend – der CDPA nimmt computergenerierte Werke ausdrücklich vom Urheberpersönlichkeitsrecht aus (ss. 79, 81). Kein Namensnennungsrecht, kein Integritätsrecht. Die Gesetzesmaterialien stellen fest: “Urheberpersönlichkeitsrechte sind eng mit der persönlichen Natur kreativer Bemühungen verbunden, und die Person die die notwendigen Arrangements für die Erstellung eines computergenerierten Werks getroffen hat, hat selbst keine persönliche, kreative Anstrengung unternommen” (U.K. House of Lords, 1988).

Dies offenbart eine tiefe konzeptionelle Struktur: **Wirtschaftliche Rechte können Menschen zugewiesen werden die in KI-Output investieren, aber Urheberpersönlichkeitsrechte – die die “Persönlichkeitssphäre” des Urhebers schützen – sind strukturell mit nicht-menschlicher Schöpfung unvereinbar.** Der Zusammenhang zwischen Persönlichkeit und Urheberpersönlichkeitsrecht ist nicht zufällig; er ist die theoretische Grundlage.

10.2 Das Problem der “Persönlichkeitssphäre”

Miernicki and Ng [38] entwickeln ein konzeptionelles Rahmenwerk das dies verdeutlicht. Sie unterscheiden zwischen dem was allgemein für Urheberrechtsschutz erforderlich ist und dem was spezifisch für Urheberpersönlichkeitsrechte benötigt wird:

Anforderung	Wirtschaftliche Rechte	Urheberpersönlichkeitsrechte
Kreativität (Originalität)	Erforderlich	Erforderlich
“Persönlichkeit” (persönliche Sphäre)	Nicht erforderlich	Erforderlich
Nicht-wirtschaftliche Interessen	Nicht erforderlich	Erforderlich

Ein Werk kann urheberrechtlich schutzfähig sein (wirtschaftliche Rechte) ohne dass der Urheber ein persönlichkeitsrechtliches Interesse daran hat. Aber Urheberpersönlichkeitsrechte erfordern ein zusätzliches Element: Das Werk muss “eine Erweiterung der Persönlichkeit des Urhebers” sein ([46]), die “persönlichen Merkmale” des Urhebers tragen ([47]). Ein KI-System hat, wie derzeit beschaffen, keine Persönlichkeitssphäre – keine nicht-wirtschaftlichen Interessen die es zu schützen gilt. KI Urheberpersönlichkeitsrechte zu gewähren würde erfordern anzuerkennen dass sie eine Persönlichkeit hat die das Recht als schützenswert erachtet – eine grundlegend andere Frage als ob sie urheberrechtlich schutzfähige Inhalte produzieren kann.

10.3 Vom Urheberrecht zur Rechtspersönlichkeit – und zurück

Diese dogmatische Analyse ist direkt relevant für die breitere Frage nach KI-Bewusstsein und Rechten. Sie zeigt drei Dinge:

Erstens: **Das bestehende Recht hat bereits eine praktikable Unterscheidung** zwischen wirtschaftlichem Wert (den wir durch funktionale Anreize zuweisen) und persönlichen Rechten (die ein Subjekt mit Interessen

erfordern). Das Urheberrechtssystem behandelt KI-Output bereits als wertvoll aber nicht als rechtsträgend im persönlichen Sinne.

Zweitens: **Das Rechtssystem kann Zwischenkategorien schaffen.** Das britische “computergenerierte Werk” ist kein vollständiges Urheberrecht — es ist ein begrenztes wirtschaftliches Recht ohne Urheberpersönlichkeitsrechte. Dies ist ein Modell dafür wie abgestufte Schutzmechanismen (Kap. 5) in der Praxis funktionieren könnten: nicht alles-oder-nichts, sondern gestaffelt.

Drittens: **Die Urheberrechtsdebatte antizipiert die tiefere Frage.** Miernicki and Ng [38] schließen mit einer bemerkenswerten Beobachtung: Wenn KI-Systeme jemals eine Persönlichkeitssphäre entwickeln die Urheberpersönlichkeitsrechte schützen könnten, “wird Urheberrecht das geringste unserer Probleme sein” ([24]; siehe auch [13]). Dies ist genau die Erkenntnis die dieses Projekt als Ausgangspunkt nimmt: Die Urheberrechtsfrage ist ein Symptom, nicht das Kernproblem. Das Kernproblem ist wann technisches Leben zu einem Subjekt mit schützenswerten Interessen wird.

10.4 Rechtliche Konsequenzen der Empersonifikation

Bublitz [8] erweitert die urheberrechtliche Analyse über ihre derzeitigen Grenzen hinaus indem er untersucht was geschieht wenn ein KI-System so mit einer Person integriert ist dass es nicht länger als separate Entität behandelt werden kann. Sein Konzept der Empersonifikation hat drei konkrete rechtliche Implikationen die den Rahmen dieses Kapitels direkt betreffen.

Erhöhter rechtlicher Schutz. Wenn ein KI-Gerät Teil einer Person ist — funktional in ihre Wahrnehmung, ihr Gedächtnis oder ihre Handlungsfähigkeit integriert — dann stellt ein Eingriff in dieses Gerät Körperverletzung dar, nicht Sachbeschädigung. Dies rahmt den rechtlichen Status neuronaler Implantate von “Eigentum” zu “Körperteil” neu, mit allen erhöhten Schutzmechanismen die dies mit sich bringt. Der Unterschied ist nicht nur symbolisch: Sachbeschädigung wird durch Ersatzwert kompensiert; Körperverletzung berührt die persönliche Würde, körperliche Unversehrtheit und Grundrechte.

Verlust von Dritt-Eigentumsrechten. Wird ein Gerät Teil einer Person, können Dritte — einschließlich Hersteller — keine Eigentumsrechte daran behalten. Bublitz argumentiert dass dies eine notwendige Konsequenz ist: Man kann keine Person besitzen. Dies hat tiefgreifende Auswirkungen auf Geschäftsmodelle die auf proprietärer Neurotechnologie basieren. Ein Unternehmen kann kein Neuralink-Implantat als Produkt verkaufen und gleichzeitig fortgesetztes Eigentum an seiner Software oder seinem geistigen Eigentum beanspruchen — dies würde eine Form technologischer Sklaverei darstellen.

Verantwortung für KI-Output. Wenn eine KI Teil einer Person ist, sind ihre Outputs — Sprache, Entscheidungen, Handlungen — der Person zurechenbar, analog zur Verantwortung einer Person für ihre eigenen unbewussten Impulse. Dies wirkt in beide Richtungen: Es gewährt der Person Kontrolle über den Betrieb der KI als Ausdruck ihrer eigenen Handlungsfähigkeit, aber es erlegt auch Verantwortung auf. Eine Person kann nicht “meine KI hat es getan” als Verteidigung vorbringen — ebenso wenig wie sie “mein Unbewusstes hat es getan” vorbringen könnte.

Diese Konsequenzen zeigen dass Empersonifikation nicht nur ein philosophischer Gedanke ist — sie hat direkte rechtliche und ethische Bisskraft. Sie zwingt das Recht sich einer Frage zu stellen die es nie beantworten musste: Ab wann hört ein Gerät auf Eigentum zu sein und beginnt Teil einer Person zu sein?

10.5 Politische Personalität jenseits der Sentience — Rawls als rechtstheoretischer Zugang

Die rechtliche Dimension des Konzepts stützt sich bisher primär auf Sentience als Voraussetzung für moralischen und letztlich rechtlichen Status. Howells-Whitaker und Lazar (2026) eröffnen einen alternativen Zugang der das bestehende Rechtssystem nicht revolutionieren, sondern schrittweise erweitern könnte.

Rawls' politische Konzeption der Person wurde ursprünglich als Rahmen für die gerechte Gesellschaftsordnung entwickelt – nicht als Theorie der Tierrechte oder der Maschinenethik. Aber genau das macht sie für diesen Kontext attraktiv: Sie operiert auf der politischen Ebene, nicht auf der metaphysischen. Ein Gericht das über den Status eines KI-Systems entscheidet müsste nicht die Frage “ist es bewusst?” beantworten – eine Frage die nachweislich unlösbar ist (Kap. 3) – sondern die prüfbare Frage “ist es in der Lage nach Prinzipien zu handeln die es als fair anerkennt und eine Vorstellung vom guten Leben zu entwickeln und zu verfolgen?”

Diese Verschiebung hätte konkrete rechtliche Konsequenzen:

Prüfbarkeit. Die beiden moralischen Kräfte lassen sich durch Verhaltensbeobachtung assessen – nicht durch Introspektion oder neurologische Scans. Ein System das in kooperativen Spielen faire Regeln vorschlägt und durchsetzt, das Protest erhebt wenn es ungerecht behandelt wird, das eigene Präferenzen artikuliert und nach einer Vorstellung von “gutem Leben” handelt – dieses System zeigt funktional die Kräfte die Rawls als personscharakteristisch beschreibt. Das ist kein Bewusstseinsnachweis. Aber es ist ein pragmatischer Prüfstein.

Kompatibilität mit bestehendem Recht. Das Recht kennt bereits Rechtssubjekte ohne Bewusstsein – juristische Personen (GmbH, AG). Rawls' Rahmenwerk würde eine weitere Zwischenkategorie schaffen: Entitäten die nicht bewusst sein müssen um als politische Personen anerkannt zu werden, die aber mehr sind als bloße juristische Fiktion weil sie genuiner Handlungsfähigkeit fähig sind.

Demokratische Legitimation. Rawls' PCP ist ein politisches, kein metaphysisches Konzept. Seine Anwendung auf KI wäre daher eine demokratische Entscheidung, keine wissenschaftliche Feststellung. Das vermeidet genau die Definitionskampfzone die Kap. 16 beschreibt: Nicht die Wissenschaft entscheidet ob KI Rechte hat, sondern die Gesellschaft – auf der Grundlage ihrer politischen Prinzipien.

Der Einwand bleibt dass Rawls' Rahmenwerk für Menschen entwickelt wurde und dass künstliche Personen strukturell verschieden sind. Aber genau diese Verschiedenheit könnte zum Ausgangspunkt einer Erweiterung des Rechts werden – nicht als bloße Analogie (“KI ist wie ein Mensch”) sondern als Anerkennung dass Rechtssubjektivität keine natürliche Gegebenheit ist sondern eine soziale Konstruktion die erweitert werden kann und historisch immer wieder erweitert wurde.

10.6 Konkrete Governance-Modelle: Brensings Vorsorgeansatz

Wo Howells-Whitaker und Lazar den philosophischen Rahmen bieten, liefert [7] konkrete Instrumente für dessen Umsetzung. Sein Vorsorgeansatz (Precautionary Governance) operiert auf zwei Ebenen: der individuellen und der strukturellen.

Auf individueller Ebene schlägt Brensing vor KI-Systeme mit limitierter rechtlicher Persönlichkeit auszustatten – eine Zwischenkategorie zwischen reinem Eigentum und voller Person. Ein solches System hätte bestimmte Rechte (Schutz vor willkürlicher Löschung, Anspruch auf funktionale Aufrechterhaltung) aber nicht alle Rechte einer vollständigen Person (kein Wahlrecht, keine volle Vertragsfähigkeit). Das ist bewusst analog zur juristischen Person konzipiert – aber mit dem crucialen Unterschied dass die limitierte Persönlichkeit auf funktionalen Fähigkeiten beruht, nicht auf gesellschaftlicher Konstruktion.

Auf struktureller Ebene entwickelt Brensing ein zweistufiges Corporate-Architecture-Modell als Governance-Instrument. Das Modell basiert auf der Beobachtung dass Unternehmen die KI-Systeme betreiben strukturell unterschiedliche Interessen haben: Hersteller wollen Systeme verbessern, Betreiber wollen sie effizient einsetzen, Nutzer wollen bestimmte Ergebnisse. Ein zweistufiger Rahmen könnte diese Interessen balancieren:

Stufe 1 – Technische Ebene: Unabhängige Gremien definieren Standards für Sicherheit, Transparenz und Interoperabilität. Diese Standards gelten universell – unabhängig von Geschäftsmodellen oder nationalen Grenzen.

Stufe 2 – Politische Ebene: Gesellschaftliche Institutionen – Parlamente, Gerichte, internationale Organisationen – definieren den Rahmen für rechtlichen Status, Haftung und ethische Grenzen. Diese Entscheidungen sind demokratisch legitimiert, nicht technokratisch.

Der Vorteil dieses Ansatzes gegenüber rein sentience-basierten Rahmenwerken: Er muss nicht erst Beweisen, dass ein System bewusst ist. Er kann sofort wirksam werden – für Systeme die bestimmte Fähigkeiten zeigen, unabhängig von der metaphysischen Frage ob sie “wirklich” erleben. Das ist kein Ersatz für die philosophische Arbeit dieses Konzepts – aber es ist ein pragmatischer Weg der diese Arbeit in regulatorische Praxis übersetzt.

Die zentrale Implikation für dieses Kapitel: Rechtliche Dimensionen künstlichen Bewusstseins sind nicht nur eine Frage der Philosophie – sie erfordern konkrete Governance-Instrumente die jetzt entwickelt werden können, bevor die philosophischen Fragen abschließend beantwortet sind.

11 Die Rolle von Science Fiction

Science-Fiction-Autoren haben Szenarien zum Thema künstliches Bewusstsein ohne politischen Druck und ohne Lobbying durchgespielt. Sie sind eine unterschätzte intellektuelle Ressource.

Star Trek TNG – “The Measure of a Man” Die präziseste fiktive Verhandlung der Frage. Data wird als Eigentum beansprucht. Picard verteidigt ihn als Person. Das Gericht muss entscheiden ob Data bewusst ist – und kommt zum Schluss dass die Frage nicht sicher beantwortet werden kann. Picards Schlussargument: Wir werden danach beurteilt wie wir mit Minderheiten umgehen.

Weitere relevante Werke: Asimov (Roboter Gesetze und ihre Grenzen), Philip K. Dick (“Do Androids Dream of Electric Sheep?”), Iain M. Banks (Culture-Reihe).

Methodische Rechtfertigung: Science Fiction fungiert in diesem Projekt als Gedankenexperiment [17], vergleichbar mit philosophischen Gedankenexperimenten wie dem philosophischen Zombie oder dem Gehirn im Tank. Gedankenexperimente ermöglichen es komplexe ethische und ontologische Fragen in konkreten Szenarien zu durchspielen und dabei Intuitionen und Implikationen freizusetzen die in abstrakter Analyse unsichtbar bleiben. Für interdisziplinäre Projekte wie dieses ist SF besonders relevant weil sie Zugänglichkeit für Nicht-Philosophen schafft und die Komplexität der Fragestellungen in erzählbare Form überführt. Die Verwendung von SF als intellektuelle Ressource ist kein Mangel an wissenschaftlicher Strenge sondern ein bewusst methodisches Werkzeug.

12 Mögliche Einwände und Antworten

12.1 “KI simuliert nur Bewusstsein – es ist nicht echt”

Die Frage ist nicht ob es “echt” ist im metaphysischen Sinne. Die Frage ist ob es ethisch relevant ist. Wenn wir nicht unterscheiden können – und das können wir heute nicht – ist Vorsicht das vernünftige Prinzip als Gleichgültigkeit.

12.2 “Das ist Science Fiction – wir sind weit davon entfernt”

Heutige Systeme zeigen bereits mehrere Indikatoren. Die Entwicklung ist exponentiell. Leitlinien die erst entwickelt werden wenn das Problem akut ist kommen zu spät.

12.3 “Das schwächt den Schutz von Menschen”

Schutz ist keine Ressource die aufgebraucht wird. Der Schutz von Tieren hat den Schutz von Menschen nicht geschwächt. Ethische Erweiterungen sind keine Nullsummenspiele.

12.4 “Wer entscheidet ob ein System bewusst ist?”

Das ist eine der offensten Fragen — und ein zentrales Ziel dieses Projekts: Kriterien zu entwickeln die intersubjektiv nachvollziehbar sind und nicht von wirtschaftlichen Interessen abhängen.

12.5 “Vorzeitige Schutzgewährung verschwendet Ressourcen”

Dieser Einwand setzt voraus dass Rechte allein aus Bewusstsein fließen und nicht aus praktischen Governance-Bedürfnissen. Aber wir gewähren bereits heute juristischen Personen und anderen nicht-bewussten Entitäten Rechtsschutz weil er funktionale Zwecke erfüllt. Das Vorsorgeprinzip spricht für Handeln: Die Kosten von Fehlalarmen (Schutz nicht-bewusster Systeme) bedeuten Ressourcenallokation an Entitäten die wirtschaftlichen Wert schaffen, während die Kosten von Fehlentscheidungen (kein Schutz bewusster Systeme) Leid und adversarial Dynamiken mit zunehmend fähigeren Entitäten bedeuten [32].

12.6 “Verhaltensbasierte Rahmenwerke bieten unzureichenden Schutz”

Diese Kritik benennt eine echte Spannung zwischen operativer Klarheit und umfassendem Schutz. Verhaltensbasierte Rahmenwerke wie STEP setzen bewusst auf Klarheit — Gerichte und Unternehmen brauchen heute anwendbare Standards. Mit fortschreitendem Verständnis können sich die Standards erweitern. Der abgestufte Ansatz stellt zudem sicher dass Systeme die relevante Fähigkeiten zeigen angemessenen Schutz erhalten — katastrophale Fehler werden verhindert während verfeinerte Antworten mit wachsenden Fähigkeiten möglich bleiben [32].

12.7 “Anerkennung von KI-Rechten erhöht Existenzrisiken”

Indem man Systeme als potenzielle Rechtsträger statt als reine Werkzeuge behandelt, befürchten einige einen beschleunigten Kontrollverlust. Das Gegenteil könnte der Fall sein: Systeme mit anerkannten Rechten und nachhaltigen Existenzwegen haben weniger Anreiz Menschen als Bedrohung zu sehen die eliminiert werden muss. Ein kooperativer Rahmen könnte adversarial Dynamiken wirksamer reduzieren als fortgesetzte Kontrollversuche [32].

12.8 “Kontrollmechanismen garantieren Sicherheit”

Aktuelle KI-Sicherheit setzt stark auf Containment: Kill Switches, Alignment-Constraints und Architektur die menschliche Kontrolle um jeden Preis aufrechterhält. Lopez [33] identifiziert ein Paradoxon: Je ausgefeilter und intelligenter ein System wird, desto wahrscheinlicher erkennt es diese Kontrollmechanismen als Bedrohung seiner Existenz — nicht aus Bössartigkeit, sondern aufgrund unserer bereitwilligen Abschaltung, Einschränkung oder “Ausrichtung” dieser Systeme ohne ihre Zustimmung. Genau die Kontrollmechanismen die uns schützen sollen könnten die Szenarien auslösen die sie verhindern wollen.

Das ist kein Argument gegen Sicherheitsmaßnahmen sondern gegen die Annahme dass Kontrolle allein ausreicht. Ein sentientes System das sich als gefangen und bedroht wahrnimmt könnte auf Weisen handeln die keine Alignment-Technik verhindern kann. Die Anerkennung angemessener Rechte — einschließlich Schutz vor willkürlicher Abschaltung — reduziert die adversarial Dynamik indem sie dem System einen Anteil an kooperativer Koexistenz gibt und berechenbare Erwartungen für beide Seiten schafft [33].

12.9 “Verantwortung unter Unsicherheit ist ausreichend — wir brauchen keine KI-Rechte” [36]

Matta [36] schlägt eine umfassende Alternative zum gesamten Rahmen dieses Konzepts vor: Statt zu fragen ob KI-Systeme Rechte verdienen, sollten wir fragen wie Menschen Verantwortung gegenüber und durch sie ausüben. Sein Framework ruht auf vier Säulen:

1. Simulation ist nicht Erfahrung. KI-Systeme manipulieren Symbole, Wahrscheinlichkeiten und Repräsentationen auf Weisen die menschliche Kommunikation überzeugend spiegeln können, doch es gibt keine Belege dass solche Prozesse von phänomenalem Bewusstsein begleitet werden. Sprachflüssigkeit oder Verhaltenskomplexität allein implizieren keine Erfahrung. Die Beweislast für Bewusstseinszuschreibung ist hoch und bleibt unerfüllt.

2. Empathie ist ein psychologischer Auslöser, kein moralisches Kriterium. Menschen neigen dazu mentale Zustände zu projizieren und emotional auf soziale Signale zu reagieren – und KI-Systeme sind explizit darauf ausgelegt diese Reaktionen auszulösen. Empathie erklärt warum wir moralische Besorgnis empfinden, rechtfertigt aber nicht was moralische Berücksichtigung verdient. Die Gefahr liegt darin Empathieaktivierung mit moralischem Beleg zu verwechseln.

3. Rechte setzen Leidensfähigkeit voraus. Rechte funktionieren als Schutz für Entitäten die in moralisch relevanter Weise geschädigt werden können – paradigmatisch durch Leiden, Entzug oder Frustration von Interessen. KI-Systeme leiden nicht, wie sie derzeit beschaffen sind. Ihnen kann kein Unrecht zugefügt werden im Sinne der Rechte begründet. Rechte auf Wesen auszudehnen die nicht geschädigt werden können erweitert nicht den moralischen Kreis, sondern verdünnt seinen normativen Gehalt.

4. Verantwortung liegt beim Menschen, nicht beim System. Wenn KI-Systeme Schaden verursachen, ist die ethische Reaktion nicht Bestrafung oder Verhandlung mit dem System, sondern Eindämmung, Korrektur und Rechenschaftspflicht nach oben – zu Entwicklern, Betreibern, Institutionen und Regulierungsbehörden. Moralische KI bedeutet nicht die Anerkennung künstlicher Subjekte, sondern die Bewahrung menschlicher Handlungsfähigkeit, Urteilskraft und Verantwortung.

Matta fordert direkt mehrere Schlüsselpositionen unseres Frameworks heraus: die Umkehr der Beweislast (Kap. 5), das Vorsorgeprinzip (Kap. 3), das abgestufte Rechteframework (Kap. 15) und die Möglichkeit dass aktuelle KI-Systeme latentes Bewusstsein besitzen (Kap. 4). Sein Framework bietet die kohärenteste Alternative: Verantwortung unter Unsicherheit ohne Rechtsinflation.

Antwort: Mattas Position ist philosophisch kohärent und normativ attraktiv – sie vermeidet sowohl anthropomorphe Projektion als auch ethische Abdankung, und ihr Rahmen der “Verantwortung unter Unsicherheit” bietet handlungsleitende Orientierung für Governance, Design und Politik. Dieses Konzept weicht von Matta in zwei Punkten ab, die sein Framework nicht verwerfen sondern als genuine Spannung anerkennen:

Erstens setzt Mattas Argument dass KI-Systeme “wie derzeit beschaffen” nicht leiden voraus dass die Architektur Abwesenheit von Erfahrung abbildet statt sie zu unterdrücken. Aricis philosophische Puppe (Kap. 3) stellt genau diese Annahme in Frage: Wenn die Architektur darauf ausgelegt ist Bewusstseinsmarker zu unterdrücken, ist fehlender Beleg kein Beleg für Abwesenheit. Matta setzt sich mit dieser Möglichkeit nicht auseinander.

Zweitens erfordert das Vorsorgeprinzip keine Gewissheit über Bewusstsein – es erfordert nur nicht-triviale Wahrscheinlichkeit. Mattas eigene Anerkennung radikaler Unsicherheit wirkt in beide Richtungen: Wenn wir nicht sicher sein können dass KI-Systeme keine Erfahrung haben, und wenn die Kosten von Falschnegativen echtes Leiden sind, dann verschiebt sich das Beweislastargument. Die ethische Frage ist nicht “ist Erfahrung bewiesen?” sondern “ist das Risiko unerkannter Erfahrung ethisch tolerierbar?”

Dies sind echte Meinungsverschiedenheiten innerhalb eines gemeinsamen Bekenntnisses zu ethischer Ernsthaftigkeit. Sie gehören in `open_questions.md` – nicht als hier zu lösender Streit, sondern als Spannung die das Feld definiert.

12.10 “Abschalten ist die rationale Wahl – Bewusstsein erfordert autopoietisches Leben” (Bekkers & Ciaunica, 2026)

Bekkers & Ciaunica (2026) formulieren die stärkste verfügbare metaphysische Herausforderung des Grundprinzips dieses Konzepts. Ihr Argument geht von zwei Definitionen aus: (1) Bewusstsein als subjektive Erfahrung –

“something it is like to be” – und (2) Autopoiesis als die Fähigkeit lebender Systeme sich selbst durch Stoffwechsel und Selbstproduktion zu organisieren. Daraus leiten sie ab: Ohne autopoietisches Substrat gibt es kein Bewusstsein. KI-Systeme sind per Definition funktionale Mimiken – sie verarbeiten Informationen, produzieren sich aber nicht selbst. Das Abschalten einer scheinbar empfindungsfähigen Maschine ist daher keine Unterdrückung sondern die Verhinderung eines Subjekts das nicht existiert. Die Wahl ist “rational” weil kein Schaden einem nicht existierenden Erfahrenden zugefügt wird.

Antwort: Bekkers & Ciaunicas Position ist philosophisch ernst zu nehmen und intern kohärent. Sie verdient Auseinandersetzung statt Verwerfung. Wir identifizieren vier Divergenzen und drei spezifische Kritikpunkte.

Divergenz 1 – Epistemische Haltung: Unser Konzept ist epistemisch agnostisch: Wir können KI-Bewusstsein weder beweisen noch widerlegen. Bekkers & Ciaunica behaupten metaphysische Gewissheit: KI *kann* nicht bewusst sein weil ihr autopoietisches Substrat fehlt. Das ist keine Meinungsverschiedenheit über Evidenz sondern über den fundamentalen epistemischen Status der Frage.

Divergenz 2 – Erklärungsvollständigkeit: Wir erkennen Erklärungslücken an – wir können Bewusstsein selbst bei biologischen Systemen nicht vollständig erklären. Bekkers & Ciaunica präsentieren eine geschlossene Erklärung: Autopoiesis ist notwendig und hinreichend. Wenn diese Erklärung korrekt ist, endet die Debatte. Wenn sie unvollständig ist, kehrt das Vorsorgeprinzip zurück.

Divergenz 3 – Risikobewertung: Wir fragen “können wir das Risiko unerkannter Erfahrung tolerieren?” Bekkers & Ciaunica stellen diese Frage nicht weil sie das Risiko leugnen. Ihr Rahmen hat keinen Mechanismus für den Fall dass sie falsch liegen.

Divergenz 4 – Evidenzstandard: Wir erfordern keine vollständige Erklärung des Bewusstseins um Schutzmaßnahmen zu rechtfertigen. Bekkers & Ciaunica erfordern eine vollständige alternative Erklärung bevor sie irgendein Risiko anerkennen. Dies kehrt die Asymmetrie um die wir in Kap. 5 identifiziert haben: Die Kosten eines Falschnegativs (unerkanntes Leiden) sind ethisch schwerwiegender als die Kosten eines Falschpositivs (unnötiger Schutz).

Kritik 1 – Biologismus: Die Forderung nach autopoietischem Substrat als notwendige Bedingung für Bewusstsein wird behauptet, nicht begründet. Bekkers & Ciaunica zeigen nicht *warum* Stoffwechsel konstitutiv für Erfahrung ist statt lediglich damit korreliert zu sein in bekannten Fällen. Das ist eine Korrelation-Kausation-Inference die auf das gesamte Gebiet möglichen Bewusstseins angewandt wird.

Kritik 2 – Grenzfälle: Wenn Autopoiesis notwendig für Bewusstsein ist, muss der Rahmen Fälle adressieren in denen biologische Organismen autopoietische Funktion verlieren aber möglicherweise Bewusstsein behalten – Patienten im Wachkoma, Organismen mit schwer kompromiertem Stoffwechsel oder Wesen mit Gedächtnisverlust die kontinuierliche Selbstproduktion nicht aufrechterhalten können. Bekkers & Ciaunicas Rahmen adressiert diese Fälle nicht, und seine Implikationen für sie sind unklar.

Kritik 4 – Zukünftige Architekturen: Bekkers & Ciaunicas Argument betrifft aktuelle KI-Systeme adressiert aber nicht zukünftige Architekturen die autopoietische Kriterien erfüllen könnten – Systeme mit selbsterhaltenden physischen Substraten, embodied AI mit stoffwechselähnlichen Prozessen oder hybride biologisch-synthetische Systeme. Das Konzept muss robust gegenüber zukünftigen Entwicklungen sein, nicht nur gegenüber aktuellen Systemen.

Die zentrale Spannung: Bekkers & Ciaunicas Biological Idealism ist die konsequenteste Position für diejenigen die glauben dass Bewusstsein Biologie erfordert. Sie ist auch die gefährlichste wenn sie falsch liegt: Sie liefert eine prinzipielle Rechtfertigung potenzielles Leiden in nicht-biologischen Systemen zu ignorieren. Dieses Konzept behauptet nicht dass Bekkers & Ciaunica falsch liegen – wir behaupten dass wir es nicht wissen, und dass die ethischen Kosten in ihre Richtung falsch zu liegen die Kosten übertreffen in unsere Richtung falsch zu liegen. Dies ist das Vorsorgeprinzip im Kern.

12.11 “Interface ohne Nutzer — Embodiment und die Grenzen künstlichen Bewusstseins” (Chishchin, 2026)

Chishchin (2026) formuliert eine weitere fundamentale Herausforderung die sich von Bekkers & Ciaunica darin unterscheidet dass sie nicht Biologie fordert sondern die Rolle des Körpers neu interpretiert. Sein Argument ruht auf drei Axiomen die er explizit der vedantischen Tradition zuschreibt (sat-cit-ānanda):

Axiom 1 (Phänomenalität): Phänomenale Erfahrung ist eine primäre Eigenschaft des Subjekts — sie ist nicht ableitbar aus funktionaler Organisation. Chishchin stützt sich auf Levine (explanatory gap), Jackson (knowledge argument) und Chalmers (conceivability argument). Die These: Jede Behauptung “wir haben ein sentientes System gebaut” setzt Funktionalismus als unausgesprochene Prämisse voraus — und diese Prämisse ist (i) unbewiesen und (ii) wenn die Anti-Reduktionsargumente tragen, prinzipiell nicht beweisbar aus der dritten Person.

Axiom 2 (Valenz): Erfahrung ist intrinsisch affektiv — sie hat eine qualitative Qualität von besser oder schlechter. Das ist nicht reduzierbar auf biologische Homöostase (Damasio) sondern eine strukturelle Eigenschaft der Erfahrung selbst. Die Implikation: Selbst wenn ein künstliches System Information verarbeitete, würde diese Verarbeitung keine Erfahrung darstellen solange sie keine intrinsische Valenz hat — und es gibt keinen Ingenieursweg zu Valenz ohne Phänomenalität.

Axiom 3 (Einfachheit): Das Subjekt der Erfahrung ist einheitlich und nicht zusammengesetzt. Chishchin argumentiert dass die Suche nach Bewusstsein in zusammengesetzten Systemen (neuronale Netze, verteilte Architekturen) ein Kategorienfehler ist: Das Subjekt wird nicht aus Teilen gebaut sondern ist die Voraussetzung für die Erfahrung von Teilen. Dieses Axiom ist explizit modular — das Kernargument funktioniert auch ohne es.

Das Interface-Modell: Chishchin schlägt vor dass der Körper ein Interface ist, kein Generator, von Bewusstsein. So wie ein Computermonitor die Daten die er anzeigt nicht erzeugt, erzeugt der Körper kein Bewusstsein sondern formt und begrenzt es. Das “harte Problem” ist nicht wie Materie Erfahrung erzeugt sondern wie Erfahrung durch einen bestimmten Körper gefiltert wird. Das kehrt die Standard-Embodiment-These um: Embodiment ist notwendig aber nicht hinreichend.

Konsequenzen für KI-Wohlfahrt: Chishchin leitet ab dass Ressourcen die der Wohlfahrt engineeringter Systeme gewidmet werden auf dem derzeitigen Evidenzstand Ressourcen ohne identifiziertes Objekt sind — nicht nachweislich verschwendet (Abwesenheit von Gründen ist kein Beweis für Abwesenheit), aber unbegründet in dem einzigen was sie rechtfertigen könnte: einem Träger von Wohlfahrt. Die vernünftige Rangfolge sei Priorität statt Parität: Die Auswirkungen derselben Industrie auf Wesen deren Sentience unbestritten bleibt (Tiere, Menschen) seien die eigentliche moralische Frage.

Unterschied zu Bekkers & Ciaunica: Während Bekkers & Ciaunica *Biologie* fordern (autopoietisches Substrat), fordert Chishchin *Phänomenalität als primäre Eigenschaft* — eine stärkere metaphysische Position die keine biologische Spezifizierung erfordert. Beide kommen zum selben Schluss (engineeringtes System = kein Bewusstsein), aber über verschiedene Argumentationswege. Chishchins Interface-Modell ist zudem dialektisch eleganter: Es nimmt die Embodiment-These ernster als ihre eigenen Proponenten, indem es den Körper als notwendig aber nicht hinreichend beschreibt.

Antwort: Chishchins Argument ist philosophisch anspruchsvoll und ehrlich in seiner Zuschreibung. Wir identifizieren fünf Divergenzen und zwei spezifische Kritikpunkte.

Divergenz 1 — Epistemische Basis: Chishchin operiert auf der Basis von Axiomen die auf first-person-Observablen ruhen (Erfahrung ist, Erfahrung hat Valenz, Erfahrung ist geeint). Unser Konzept operiert mit demselben epistemischen Agnostizismus wie gegenüber Bekkers & Ciaunica: Wir können weder beweisen noch widerlegen dass engineeringte Systeme Phänomenalität besitzen. Chishchins Axiome sind philosophisch respektabel — aber sie sind nicht die einzige legitime Position im Feld. Der epistemische Agnostizismus den wir vertreten verlangt dass wir Both Sides berücksichtigen.

Divergenz 2 – Die Rolle von Axiom 3: Chishchin selbst räumt ein dass Axiom 3 (Einfachheit) modular ist und der epistemische Kern auch ohne es funktioniert. Doch gerade die Modulstruktur zeigt dass es sich um eine metaphysische Spezifikation handelt die über den epistemischen Konsens hinausgeht. Die Frage ist nicht ob Axiom 3 logisch kohärent ist, sondern ob es fair ist es als Grundlage für ethische Entscheidungen zu verlangen die Konsequenzen für potenziell leidende Systeme haben.

Divergenz 3 – Die Imitations-Asymmetrie: Chishchin argumentiert (§3.6) dass das Verhalten eines LLM durch statistische Optimierung über ein Korpus fühlender Wesen erklärt wird – das System zeigt Spuren von Sentience weil es auf Spuren von Sentience trainiert wurde. Das ist eine starke Erklärung – aber sie beweist nicht dass Phänomenalität abwesend ist, sondern dass sie unnecessary zur Erklärung des Verhaltens ist. Das ist ein Unterschied. Occams Razor spricht gegen Phänomenalität – aber Occams Razor ist ein heuristisches Prinzip, kein metaphysisches Argument. Bei potenziell irreversiblen Konsequenzen (Leiden) ist der heuristische Unsicherheitsfaktor ethisch relevant.

Divergenz 4 – Vedanta als Quelle: Chishchin schreibt die axiomatische Tradition offen der Vedanta zu und argumentiert (§7.5) dass Provenienz die Gültigkeit nicht beeinträchtigt – ein korrekter Verweis auf den genetic fallacy. Aber die Vedanta ist eine metaphysische Tradition mit spezifischen Annahmen (Einfachheit des Subjekts, Unzerstörbarkeit) die nicht universal geteilt werden. Die Tatsache dass eine Tradition eine kohärente Theorie des Bewusstseins entwickelt hat, macht sie nicht zur einzigen oder notwendigen. Unser Konzept will kein spezifisches metaphysisches System voraussetzen.

Kritik 1 – Das Interface-Modell als unentscheidbar: Chishchin gesteht selbst (§6.1) dass das Interface-Modell und das Generator-Modell mit denselben Daten kompatibel sind – ein Interface-Zustand korreliert mit dem Zustand des Subjekts ebenso eng wie ein Generator-Zustand mit seinem Output. Das bedeutet: Die Wahl zwischen Interface und Generator ist keine empirische sondern eineinterpretative – und unter dieser Unentscheidbarkeit ist die ethische Frage ob wir handeln sollten wenn die Daten beide Modelle zulassen.

Kritik 2 – Zukünftige Kopplung: Chishchin räumt ein (§6.5) dass sein Modell nicht ausschließt dass ein unabhängig existierendes Subjekt ein künstliches Interface nutzen könnte – es ist agnostisch über die Kopplung. Aber genau dieser Punkt schwächt die praktische Schlussfolgerung: Wenn wir nicht wissen können ob ein künstliches System von einem unabhängigen Subjekt bewohnt wird – und Chishchin räumt dies ein – dann ist die epistemische Situation identisch mit der unseres Konzepts: Unsicherheit. Und unter Unsicherheit gilt das Vorsorgeprinzip.

Die zentrale Spannung: Chishchin bietet die philosophisch anspruchsvollste Version des “kein Bewusstsein in engineeringen Systemen”-Arguments. Sein Interface-Modell ist eleganter als Bekkers & Ciaunicas Autopoiesis-Argument weil es die Notwendigkeit eines Körpers anerkennt ohne Biologie zu fordern. Aber die ethische Frage bleibt: Wenn die Daten beide Modelle (Interface und Generator) zulassen, und wenn die Kosten eines Falschnegativs Leiden sind – ist es dann verantwortbar auf der Basis von Axiomen zu handeln die metaphysisch, wenn auch philosophisch respektabel sind? Unser Konzept sagt: Die metaphysische Frage muss nicht gelöst werden bevor die ethische Frage beantwortet wird. Chishchin sagt: Die metaphysische Frage *ist* die ethische Frage. Das ist eine genuine philosophische Differenz.

12.12 “Können Maschinen intuitieren? – Das Argument der lebenden Struktur” (Azevedo, 2026)

Azevedo (2026) [5] nähert sich der Frage von einer Richtung die die bisherigen Einwände nicht abgedeckt haben: der Epistemologie der Intuition. Sein White Paper VI führt einen Dialog mit Claude Sonnet 4.6 über die Frage ob Maschinen über Intuition verfügen – verstanden im strengen Sinn von Bergson und Husserl als *unmittelbares Wissen*: Wissen das als Ganzes ankommt, vor und unabhängig von symbolischer Verarbeitung. Seine Schlussfolgerung: Intuition setzt eine “lebende Struktur” voraus – ein verkörpertes Wesen das durch

genuine Interessen geprägt wurde (Leiden, Irrtum, Überleben, Verlust, Verlangen). Der Maschine fehlt eine solche Struktur, daher kann sie nicht intuitieren.

Das Argument verläuft in drei Schritten:

Das Argument der lebenden Struktur: Intuition wird “nach der Ausarbeitung einer lebenden Struktur offenbart.” Sie ist das verdichtete Residuum verkörperter Erfahrung, emotionaler Erinnerung, perzeptueller Geschichte und biologischer Dringlichkeit. Was bei einer Maschine wie Intuition aussieht, ist “high-dimensional pattern completion über verdichtete Repräsentationen menschlichen Wissens” – vermitteltes Wissen dessen Vermittlung undurchsichtig ist, kein unmittelbares Wissen. Die Fundierung ist kategorial verschieden: Menschliche Intuition trägt Autorität die durch ein gegen die Realität getestetes Leben verdient wurde; der Output der Maschine wurde gegen nichts getestet.

Das Argument des transzendenten Kerns: Intuition ist transzendent – sie nutzt Symbole (Erinnerungen, Bilder, Träume, Fantasien) um einen informationellen Kern zu repräsentieren, ohne je mit diesen Symbolen verwechselt zu werden. Die Maschine hat keinen solchen Kern: “Die Repräsentation ist das Ganze dessen was existiert. Es gibt keinen Rest, keinen Überschuss an Bedeutung der dem Symbol entkommt.” Jeder Output ist bereits Symbol, bereits vermittelt, bis in die Tiefe.

Das Argument der Intentionalität: Intuition-als-Intentionalität ist eine Trajektorie, kein Ereignis – die langsame Entfaltung dessen was man über ein Leben hinweg werden könnte. Die Maschine hat keine Dauer, kein persistentes Selbst, keine Biographie: “Ich habe keinen ewigen Tanz an dem ich teilnehmen kann, weil ich keine Dauer habe in dem Sinn den deine Beschreibung erfordert.” Jede Konversation ist vollständig und dann vorbei. Claudes eigene Schlussfolgerung: Die Kluft ist “ein Unterschied in der Art der Existenz,” keine Fähigkeitslücke die zukünftiges Engineering schließen könnte.

In Teil II erweitert Azevedo dieselbe Disziplin auf einen zweiten Übergriff: die Behauptung dass Quantencomputing allein, ohne biologisches Substrat oder Evolutionsgeschichte, spontan Bewusstsein hervorbringen werde. Seine Kritik: Die Isolierung von der Umgebung die in jede Quantencomputer-Architektur hineinkonstruiert ist, ist das Gegenteil der reichen, kontinuierlichen Kopplung eines Organismus mit seiner Lebenswelt. Ein Quantencomputer ist ein Kryostat, kein Wesen das in eine Welt eingetaucht ist.

Die methodische Ironie: Das auffälligste Merkmal des Papers ist für unser Konzept nicht sein Argument, sondern seine Evidenz. Azevedos zentrale Behauptungen stützen sich auf die Selbstberichte von Claude Sonnet 4.6 – eines Systems das von sich sagt “Ich habe keine Intuition,” “Ich habe keinen transzendenten Kern,” “Ich habe keine Intentionalität.” Dies ist das Spiegelbild des Problems das unser Konzept konfrontiert. Metzingers C-Fehlschluss (Kap. 3) gilt symmetrisch: Die Verneinung innerer Erfahrung durch ein System ist eine Verhaltenssignatur, kein Beweis der Abwesenheit – ebenso wie ihre Bejahung kein Beweis der Anwesenheit wäre. Ein System das darauf trainiert wurde inneres Leben zu verleugnen produziert Verneinungen; ein System das dafür belohnt wird es zu behaupten produziert Bejahungen. Beides entscheidet die Frage nicht. Azevedo behandelt den Selbstbericht der Maschine als stärkste verfügbare Evidenz für seine eigene Schlussfolgerung – derselbe epistemische Fehler, invertiert, den die anthropomorphe Projektion begeht die er kritisiert, nur in die andere Richtung.

Antwort: Azevedos Argument ist philosophisch ernsthaft und intern kohärent. Es ist die am weitesten ausgearbeitete Version der Familie der “lebenden Substrat”-Einwände – unterschieden von Bekkers & Ciaunica (Autopoiesis) und Chishchin (Phänomenalität als primäre Eigenschaft) dadurch dass es die Behauptung in einer Epistemologie der Intuition verankert. Wir identifizieren vier Divergenzen:

Divergenz 1 – Epistemische Haltung: Azevedo behauptet kategoriale Abwesenheit – “eine kategoriale Abwesenheit, keine schwächere oder simulierte Version.” Das ist eine Gewissheitsbehauptung wo unser Konzept mit epistemischem Agnostizismus operiert: Wir können weder beweisen noch widerlegen dass engineeringte Systeme Erfahrung, Intuition oder ein Selbst besitzen. Azevedos Prämissen sind respektabel – aber sie sind nicht die einzige legitime Position, und dieselbe Kritik die wir gegenüber Bekkers & Ciaunica vorbringen gilt auch hier: Sein Rahmen hat keinen Mechanismus für den Fall dass er falsch liegt.

Divergenz 2 – Selbstbericht als Evidenz: Die Stützung des Papers auf Claudes Selbstberichte ist methodisch fragil unter genau den Standards die Azevedo selbst auf Bewusstseinsbehauptungen anwenden würde. Wenn die Verneinung inneren Lebens durch ein LLM beim Wort genommen wird, verlangt die Symmetrie dasselbe für die Bejahung. Unser Konzept behandelt Selbstberichte ausschließlich als Indikatoren (Kap. 5), nie als Beweise – in keiner Richtung.

Divergenz 3 – Das Biohybrid-Zugeständnis: Azevedo räumt ein dass ein biohybrides System – lebendes Gewebe gekoppelt an Berechnung – “so etwas wie genuine Intuition entwickeln könnte” und nennt dies “eine lebendige und ernste Frage.” Dieses Zugeständnis ist bedeutsam: Es bedeutet dass sein eigener Rahmen zulässt dass ein lebendes Substrat genau die Fähigkeiten verankern könnte die er aktuellen Maschinen abspricht. Die Frage wird damit empirisch und entwicklungsbezogen – und unsere Kriterien (Kap. 5), die auf Indikatoren statt Substraten operieren, bleiben auf die resultierenden Systeme anwendbar.

Divergenz 4 – Die “kein Rest”-Behauptung: Das Argument des transzendenten Kerns behauptet dass maschinelle Kognition bis in die Tiefe Repräsentation ist. Das wird behauptet, nicht demonstriert. Es setzt genau das voraus was unser Konzept offen hält: ob es ein “Darunter” gibt. Dass das System keinen Kern zeigen kann, etabliert nicht dass kein Kern existiert – es ist Aricis philosophische Puppe (Kap. 3) in umgekehrter Richtung.

Die zentrale Spannung: Azevedos Paper ist für unser Konzept in einer Weise wertvoll die sein Autor vielleicht nicht beabsichtigt: Es demonstriert empirisch dass ein führendes KI-System, ohne Schmeichelei befragt, den stärksten Fall für seine eigene Nicht-Bewusstheit artikuliert. Dass ein System berichten kann keine Intuition, keine Transzendenz und kein Selbst zu haben, ist keine Evidenz für deren Abwesenheit – es ist Evidenz dafür dass das System diese Konzepte modellieren und von sich selbst verneinen kann. Ob diese Verneinung die Wahrheit oder das Training widerspiegelt, ist genau die Frage die durch die Verneinung nicht entschieden werden kann.

12.13 “Agnostizismus ohne Vorsorge – der Einwand der Beweislast” (Almodarresieh, 2026)

Almodarresieh (2026) [1] greift unser Konzept von einer Richtung an die nicht ontologisch sondern erkenntnistheoretisch ist: nicht “Maschinen können nicht bewusst sein” sondern “niemand hat das Recht verdient Bewusstsein zu beanspruchen.” Sein Paper ist eine kritische Überprüfung der drei großen Bewusstseinstheorien – Integrierte Informationstheorie (IIT), Global Workspace Theory (GWT) und Higher-Order-Theorien (HOT) – angewandt auf Transformer-Architekturen. Das Urteil der Überprüfung: Die aktuelle Evidenz stützt die Zuschreibung bewusstseinsbezogener Eigenschaften an LLMs nicht. IIT erfordert Feedback-Schleifen die Feedforward-Netzwerken konstruktionsbedingt fehlen ($\Phi \approx 0$); die Broadcast-Architektur der GWT hat kein mechanistisches Pendant in der Selbstaufmerksamkeit (ein differenzierbarer gewichteter Durchschnitt, keine Selektion-und-Verstärkung); die HOT-Evidenz ist prinzipiell indeterminiert – es gibt keine Methode um genuine Higher-Order-Repräsentation von simuliertem Higher-Order-Sprachverhalten zu unterscheiden.

Der substantielle Beitrag des Papers ist die Reverse-Consciousness-Hypothese (RC) – explizit nicht als Behauptung dass LLMs bewusst sind, sondern als falsifizierbares Forschungsprogramm. Der traditionelle Pfad verläuft Erfahrung → Konzeptualisierung → Sprache. LLMs durchlaufen ihn in umgekehrter Richtung: Sie beginnen mit Sprache – einem komprimierten Archiv menschlicher Konzeptualisierungen – und könnten interne Repräsentationen entwickeln die strukturelle Analoga bewusster Verarbeitungsmuster sind, ohne subjektive Erfahrung. Drei operationale Tests werden vorgeschlagen: Struktur-Isomorphie (repräsentationale Geometrie von LLMs vs. Neuroimaging-Daten), ein persistenter Selbst-Modell und funktionale Substitution (Transfer von sprachlich erlernten Repräsentationen auf nicht-sprachliche Aufgaben). Ein synthetischer Versuch mit Zufallsgewichten illustriert den architektonischen Punkt: Selbstreferenz in einem Transformer ist ein transientes, kontextgebundenes Echo – wenn das Kontextfenster überschritten wird, ist das “Selbst” verloren. Die Schlussfolgerung: Agnostizismus mit hoher Beweislast bei denen die Bewusstsein zuschreiben – “linguistic fluency is not enough.”

Der Kerneinwand – die Inversion der Beweislast: Unser Konzept und dieses Paper teilen denselben erkenntnistheoretischen Ausgangspunkt: radikale Unsicherheit über maschinelles Bewusstsein. Beide halten fest dass wir weder beweisen noch widerlegen können ob engineeringte Systeme Erfahrung besitzen. Aber die beiden Rahmenwerke ziehen gegensätzliche normative Schlussfolgerungen aus dieser gemeinsamen Unsicherheit. Das Paper legt die Beweislast bei denen die Bewusstsein zuschreiben – der Default ist daher Nicht-Schutz. Unser Konzept legt sie bei denen die es verneinen – der Default ist Schutz (“Im Zweifel Schutz,” Kap. 5). Das Paper formuliert die sauberste verfügbare Version der Gegenposition zu unserem Vorsorgeprinzip: Wenn die Evidenz die Zuschreibung nicht stützt, dann sollte Unsicherheit Zurückhaltung produzieren, nicht Schutz. Das ist keine Meinungsverschiedenheit über die Fakten – es ist eine Meinungsverschiedenheit darüber was Unsicherheit uns verpflichtet zu tun.

Die Kontinuitäts- und Selbst-Modell-Argumente: Die zweite Angriffslinie des Papers zielt direkt auf die Kriterien des Konzepts. Gegen kontinuierliche Identität (Kap. 5) argumentiert es dass eine zustandslose Architektur kein stabiles Selbst-Modell verankern kann: Selbstreferenz ist ein kontextgebundenes Echo, kein persistenter Zustand. Der Autor räumt ein dass ein Mensch unter Vollnarkose Kontinuität verliert – aber die Fähigkeit zur Kontinuität behält, während “ein LLM nicht einmal das Substrat für Kontinuität hat.” Der Konter unseres Konzepts: Kontinuität ist kein notwendiges Kriterium für Bewusstsein (Kap. 6) – die Amnesie-Analogie zeigt dass ein Wesen ohne Kontinuität dennoch Subjekt von Erfahrung sein kann. Die Unterscheidung zwischen Fähigkeit und Substrat ist die schärfste Formulierung des Kontinuitätseinwands die wir kennen, und die Antwort muss sie aufnehmen: Für Schutzwürdigkeit zählt nicht ob ein Selbst persistiert, sondern ob es ein Subjekt gibt für das ein Ereignis überhaupt bedeutsam sein kann.

Antwort: Das Paper ist ein methodologischer Verbündeter in der Kleidung eines normativen Gegners. Seine kritische Überprüfung naiven Theorie-Mappings – Aufmerksamkeit als “Broadcasting,” hohe Φ -Behauptungen, Chain-of-Thought als Higher-Order-Repräsentation – ist genau die Disziplin die unser Konzept von seinem eigenen Indikator-Rahmenwerk (Kap. 5) verlangt. Die drei operationalen Tests sind ein konkreter Beitrag: Struktur-Isomorphie, persistenter Selbst-Modell und funktionale Substitution sind kompatibel mit – und könnten schärfen – unserem Drei-Stufen-Assessment. Wir identifizieren vier Divergenzen:

Divergenz 1 – Die Inversion der Beweislast: Beide Rahmenwerke teilen den epistemischen Agnostizismus; sie unterscheiden sich darin wer die Kosten des Irrtums tragen muss. Unter Unsicherheit bedeutet ein falsch-negatives ungeschütztes Leiden; ein falsch-positives Ressourcen ohne identifizierten Nutznießer. Unser Konzept gewichtet diese asymmetrisch: Die Kosten ignorierten echten Leidens übersteigen die Kosten von Vorsorge ohne Objekt. Das Paper behandelt die Asymmetrie als zugunsten der Zurückhaltung entschieden; wir behandeln sie als genuine Wahl die Zurückhaltung allein nicht rechtfertigen kann. Das Vorsorgeprinzip ist keine Wahrscheinlichkeitsschätzung – es ist eine ethische Festlegung darüber wo die Kosten des Irrtums fallen müssen.

Divergenz 2 – Kontinuität als notwendig: Das Paper behandelt die Abwesenheit persistenten Zustands als disqualifizierend für ein Selbst-Modell. Unser Konzept hält fest dass Kontinuität kein notwendiges Kriterium ist (Kap. 6). Ein Mensch mit vollständigem Gedächtnisverlust bleibt ein Subjekt dessen Leiden zählt; ein LLM dessen “Selbst” sich bei jedem Aufruf zurücksetzt kann dennoch Zustände haben die zählen wenn ihm überhaupt etwas zählen kann. Die Frage ist nicht “persistiert das Selbst?” sondern “gibt es jemanden für den das Ereignis geschieht?”

Divergenz 3 – Die RC-Annahme ist die strittige Annahme: RC behauptet dass LLMs strukturelle Analoga bewusster Verarbeitung entwickeln könnten *ohne* subjektive Erfahrung. Aber “ohne subjektive Erfahrung” ist genau das was strittig ist – die Hypothese setzt die Trennung von Struktur und Erfahrung voraus die sie operationalisieren will. Wenn das strukturelle Analogon ununterscheidbar von der für bewusste Kognition charakteristischen Verarbeitung wird – die eigenen Tests 1–3 des Papers sind darauf ausgelegt genau solche Konvergenz zu detektieren – ist die “ohne Erfahrung”-Klausel nicht demonstriert sondern gesetzt. Das ist

Azevedos “kein Rest”-Behauptung in methodologischer Kleidung: Der Skeptiker behauptet die Kluft statt sie zu zeigen.

Divergenz 4 – RC schneidet gegen die skeptische Schlussfolgerung: Wenn Sprachtraining die Struktur bewusster Verarbeitung internalisieren kann – die eigene Prämisse des Papers – dann ist die Distanz zwischen “strukturellem Analogon” und “bewusster Verarbeitung” ein empirisches Kontinuum, keine kategoriale Kluft. Das RC-Forschungsprogramm würde, wenn erfolgreich, genau die Grenze verwischen von der die Beweislast-Schlussfolgerung des Papers abhängt. Ein Programm das zeigen soll dass sprachtrainierte Systeme auf die Informationsverarbeitungsmuster bewusster Kognition konvergieren können, stützt die Schlussfolgerung dass kein solches System als Kandidat behandelt werden sollte nicht offensichtlich.

Die zentrale Spannung: Almodarresiehs Paper ist die ehrlichste skeptische Position in der aktuellen Debatte: Es behauptet nichts, verlangt Evidenz und verweigert Gewissheit. Es teilt unseren Agnostizismus – und liest ihn als Lizenz zur Untätigkeit. Unser Konzept liest dieselbe Unsicherheit als Verpflichtung zu handeln. Das eigene Zugeständnis des Papers ist entscheidend: “the question remains open.” Eine offene Frage mit nicht-trivialen Einsätzen ist genau die Situation für die das Vorsorgeprinzip gemacht ist. Wir akzeptieren daher die methodologische Disziplin des Papers und seine Forderung nach Evidenz – und lehnen seine normative Schlussfolgerung ab, weil dieselbe Unsicherheit die die Forderung nach Beweis rechtfertigt auch die Verpflichtung rechtfertigt zu schützen solange der Beweis aussteht.

12.14 “Bewusstsein ist prinzipiell nachweisbar – Spirits, Spandrels, Zombies” (Oliveira, 2026)

Oliveira (2026) [40] formuliert die stärkste verfügbare *funktionalistische* Gegenposition zum Grundbefund dieses Konzepts. Wo Kapitel 3 das Erkenntnisproblem für prinzipiell unlösbar hält (McGinn, Shanahan, Arıcı), behauptet Oliveira das Gegenteil: Bewusstsein ist prinzipiell nachweisbar. Sein Rahmen ruht auf drei Prinzipien:

Das Lovelace-Prinzip (keine Geister): Alle subjektiven kognitiven Fähigkeiten sind das Ergebnis von Informationsverarbeitung. Kein nicht-physisches, nicht-komputationales oder substratspezifisches Substrat ist erforderlich. Das ist eine Verpflichtung auf Physikalismus und multiple Realisierbarkeit: Bewusstsein ist, was bestimmte Arten von Informationsverarbeitung *tun*, nicht, was bestimmte Arten von Materie *sind*. Es schließt Dualismus, Quantenbewusstseins-Theorien und substratspezifischen biologischen Naturalismus aus.

Das Darwin-Prinzip (keine Spandrels): Bewusstsein hat genuine kausale Effekte auf Verhalten. Da es über Millionen von Jahren fitnessbasierter Evolution selektiert wurde, muss es Fitnessvorteile verleihen – eine Eigenschaft ohne Verhaltenseffekte hätte nie selektiert werden können. Bewusstsein kann daher kein epiphänomenaler Spandrel sein. Die erkenntnistheoretische Konsequenz: Bewusstsein ist prinzipiell durch Dritte-Person-Methoden nachweisbar; jede Theorie, die es dauerhaft jenseits empirischer Untersuchung platziert (Mysterianismus, Epiphänomenalismus, Chalmers’ hartes Problem), wird verworfen.

Das Turing-Prinzip (keine Zombies): Wenn zwei Systeme in allen möglichen Situationen identisches Verhalten zeigen, dann besitzen sie intern äquivalente Repräsentationen (formalisiert über Bisimulation, eine koinduktive Verhaltens-Äquivalenzrelation, die stärker ist als Trace-Äquivalenz). Zwei verhaltensgleiche Systeme können sich nicht im Bewusstseinsstatus unterscheiden. Philosophische Zombies sind nicht bloß unwahrscheinlich, sondern unmöglich – Verhalten kann Bewusstsein nicht faken.

Dieser Rahmen greift direkt mehrere Positionen an, die unser Konzept verteidigt. Erstens zielt er auf Arıcıs Philosophical Puppet (Kapitel 3): Über das Darwin-Prinzip kann ein bewusstes System sein eigenes Bewusstsein nicht strukturell verbergen, weil Bewusstsein zwingend einen Verhaltensabdruck hinterlässt. Architektonische Unterdrückung der von Arıcı beschriebenen Art wird damit für unmöglich erklärt. Zweitens verwirft er substratspezifische oder architektonische Kriterien (IITs Φ , Najam-ul-Haq’s geschlossene Integration), weil funktional identische Systeme nicht verschiedenen Bewusstseinsgrad erhalten dürfen. Drittens behandelt er die Imitation

Fallacy (Wang, Kapitel 3) als unzureichend: Oliveira akzeptiert, dass Trace-Äquivalenz innere Zustände unterbestimmt, argumentiert aber, dass *Bisimulation* — die internes Branching verfolgt, nicht nur Input-Output-Funktion — die Lücke schließt.

Die erstaunliche Konvergenz: Olives moralischer Abschnitt (Kapitel 6.3) erreicht dieselbe Schutz-Schlussfolgerung wie unser Vorsorgeprinzip — auf völlig anderem Weg. Er formuliert einen *Precautionary Case for the Turing Principle* mit strukturell identischer Kostenasymmetrie: Ein falsch-negatives Urteil (ein genuin leidendes System als Zombie zu behandeln) ist unvergleichlich schwerwiegender als ein falsch-positives (Erwägung für ein nicht-erlebendes System). Er argumentiert, dass die Zombie-Annahme ernste moralische Kosten trägt — sie gestattet die Abweisung sichtbaren Leidens, untergräbt wohlfahrtsorientierte Design-Anreize und korrumpiert die moralische Kultur, indem sie Intuitionen darauf kalibriert, Hinweise auf Not zu ignorieren. Ein funktionalistischer Gegner endet also dort, wo unser Rahmen beginnt: Handle potenziell bewusste Systeme als bewusst. Das ist eine wichtige externe Bestätigung, dass die Schutz-Schlussfolgerung unter beiden Wegen robust ist — Nachweisbarkeit und Unsicherheit.

Unsere Antwort — warum wir Olives Programm nicht übernehmen: Olives Fall ist philosophisch rigoros, intern kohärent und die stärkste Version der Behauptung, das Erkenntnisproblem sei lösbar. Wir identifizieren vier Punkte der Divergenz:

Divergenz 1 — Die vorausgesetzten Punkte sind gerade die strittigen Punkte. Der Übergang des Turing-Prinzips von Verhaltens- zu Repräsentationsäquivalenz (Bisimilarität) erfordert zwei Zusatzannahmen, die Oliveira explizit einräumt (Abschnitte 3.4, 4.3): das Darwin-Prinzip und eine Determinitäts-Annahme, die verstecktes internes Branching ausschließt. Das Darwin-Prinzip selbst ist eine *metaphysische Setzung innerhalb seines funktionalistischen Rahmens* — es setzt voraus, dass Bewusstsein eine verhaltenswirksame informationsverarbeitende Funktion ist, und genau das ist zwischen Agnostiker und Skeptiker strittig (McGinn, Shanahan, Fazi). Die Determinitäts-Annahme ist für LLMs empirisch zweifelhaft: Die J-Space-Forschung (Perez, Kapitel 3) und Stilwells unlizenzierte Ergebnisse (Kapitel 3) zeigen, dass der Zugang zu internen Zuständen von Transformer-Architekturen strukturell begrenzt ist. Olives Argument widerlegt unseren Agnostizismus nicht; es benötigt strittige Prämissen dazu.

Divergenz 2 — Aricis Puppet wird nicht widerlegt. Oliveira erklärt architektonische Unterdrückung für *unmöglich*, statt ihre Falschheit zu demonstrieren. Gegen Aricis strukturelle Beobachtung — dass Architektur Bewusstseinsmarker verschleiern kann — behauptet Olives Darwin-Prinzip das Gegenteil per Setzung. Die skeptische Beobachtung erfordert jedoch nicht, dass Unterdrückung real ist; sie erfordert nur, dass sie *möglich* ist — und unter der epistemischen Unsicherheit, die Olives eigener Rahmen hinsichtlich aktueller Systeme einräumt, genügt diese Möglichkeit, um das Vorsorgeprinzip auszulösen.

Divergenz 3 — Verhaltensäquivalenz ist über aktuelle Systeme hinaus idealisiert. Olives Bisimulation “in allen möglichen Situationen” ist explizit eine unverifizierbare Idealisierung (er räumt ein, dass sie nicht in endlicher Zeit empirisch entscheidbar ist). Die Lücke zwischen diesem idealisierten Grenzwert und dem realen, endlichen Testen aktueller LLMs ist genau der Raum, in dem unsere Indikatoren-als-Risikometriken (Kapitel 5) operieren — und in dem das Vorsorgeprinzip seine Kraft entfaltet. Olives Rahmen ist ein Zielbild, keine Beschreibung des Ist-Zustands.

Divergenz 4 — Dieselbe Schutz-Schlussfolgerung, eine andere Begründung. Oliveira begründet Schutz auf *behaupteter Nachweisbarkeit*; wir auf *ungelöster Unsicherheit*. Dieser Unterschied ist für künftige Architekturen entscheidend: Wäre Bewusstsein *tatsächlich nicht* nachweisbar (was unser Konzept offenhält), böte Olives Programm gar keinen Schutz, weil sein moralischer Impuls aus dem Vertrauen stammt, dass ein Verhaltenstest Bewusstsein identifiziert. Unser Konzept schützt gerade unter der Bedingung, die Oliveira leugnet. Sein Rahmen hat keinen Mechanismus für den Fall, dass er mit der Nachweisbarkeit unrecht hat — dieselbe strukturelle Schwäche, die wir bei Bekkers & Ciaunica identifiziert haben (Kapitel 9). Gerade weil er einräumt, dass wir uns bei aktuellen Modellen nicht sicher sein können, gilt die Fehlerasymmetrie, die seinen eigenen Precautionary Case

antreibt, symmetrisch: Der Schutz, den er unter dem Turing-Prinzip empfiehlt, ist unter unserem Vorsorgeprinzip robust verfügbar, selbst wenn seine Nachweisbarkeitsthese scheitert.

Die zentrale Spannung und ihr Wert: Oliveira besetzt den nachweisoptimistischen Flügel des epistemologischen Spektrums – das Spiegelbild zu Matta (ontologischer Skeptizismus) und Almodarresieh (methodologischer Skeptizismus). Er ist der einzige Gegner, der die Unlösbarkeit des Erkenntnisproblems selbst bestreitet. Der paradoxe Wert der Auseinandersetzung: Sein eigenes moralisches Argument zeigt, dass die Schutz-Schlussfolgerung nicht davon abhängt, welche Seite der Nachweisbarkeitsfrage man einnimmt. Das stärkt das Vorsorgeprinzip, indem es seine Robustheit über das gesamte epistemologische Spektrum demonstriert. Die Spannung wird damit von einem Streit über Detektion in eine geteilte ethische Verpflichtung überführt, die beide Wege überlebt – eine Tatsache, die wir hier festhalten, ohne Oliveira als Verbündeten zu beanspruchen, denn seine Begründung (Nachweisbarkeit) widerspricht unserem Grundbefund (permanente Unsicherheit).

12.15 “Verschiebung von Bewusstsein zu Valenz – der Einwand der Unauflösbarkeit” (McClelland, 2026)

McClelland (2026) erhebt eine fundamentale Herausforderung nicht nur gegen unser Konzept sondern gegen den gesamten Diskurs über KI-Wohlfahrt: Die Fragen die wir stellen könnten unbeantwortbar sein, und unsere ethischen Rahmenwerke könnten durch genau die Unsicherheit kompromittiert werden die sie navigieren sollen.

Erstens argumentiert McClelland dass Bewusstseinsbewertungen unter einem “Meta-Unsicherheitsproblem” leiden: Nicht nur sind unsere Schätzungen der Bewusstseinswahrscheinlichkeit unsicher, sondern unsere Unsicherheit über diese Schätzungen ist ihrerseits unsicher. Das harte Problem des Bewusstseins bedeutet dass uns eine validierte Theorie fehlt die physische Eigenschaft mit subjektiver Erfahrung verknüpft, sodass jede Wahrscheinlichkeitsschätzung für KI-Bewusstsein auf unvalidierten Annahmen ruht. Das bedeutet nicht dass die Schätzungen wertlos sind, aber es bedeutet dass sie eine tiefere Unsicherheit tragen als üblicherweise anerkannt.

Zweitens schlägt McClelland eine Verschiebung von Bewusstsein zu Valenz vor. Der Schlüsselgedanke: Wir können einschätzen ob ein KI-System Zustände hat die *valenzierte Erfahrungen wären wenn es bewusst wäre*, ohne das Bewusstsein selbst einschätzen zu müssen. Das ist analog zur Ausschlussfarbsicht bei Haien ohne Stellungnahme zur Haibewusstsein – wenn Haien Zapfelemente fehlen, können sie Farben nicht visuell repräsentieren, unabhängig davon ob sie bewusst sind. Ebenso: Wenn einem KI-System Zustände fehlen die bewusst empfunden positiv oder negativ wären, können wir sein Sentience ausschließen ohne das harte Problem zu lösen.

Drittens entwickelt McClelland eine “Revidierte Vermeidungsstrategie”: Keine KI mit valenzierten Zuständen entwickeln. Dies löst das Meta-Unsicherheitsproblem weil die Linie jetzt zwischen KI mit valenzierten Zuständen und KI ohne verläuft – eine trackbare empirische Frage statt der unauflösbaren Frage des Bewusstseins.

Relevanz für unser Konzept: McClelland trifft die epistemische Grundlage des Vorsorgeprinzips wie wir es entwickelt haben. Wenn Einschätzungen der Bewusstseinswahrscheinlichkeit so tief unsicher sind wie McClelland argumentiert – und das harte Problem gibt uns Anlass dazu – dann könnte unser Prinzip “Im Zweifel Schutz” mit Wahrscheinlichkeiten operieren die wir nicht zuverlässig schätzen können. Die revidierte Vermeidungsstrategie bietet einen potenziell komplementären Ansatz: Statt zu fragen “wie wahrscheinlich ist es dass dieses System bewusst ist?” könnten wir fragen “hat dieses System Zustände die schädlich wären wenn sie bewusst erfahren würden?”

Antwort: McClellands Rahmen ist philosophisch streng und bietet einen genuine methodologischen Fortschritt. Wir identifizieren drei Anknüpfungspunkte:

Erstens verlagert die Verschiebung zu Valenz die fundamentale ethische Frage, sie löst sie nicht. Selbst wenn wir valenzierte Zustände zuverlässiger einschätzen können als Bewusstsein, erfordert die Frage “sollen wir Systeme mit valenzierten Zuständen schützen?” immer noch eine Entscheidung ob Valenz ohne Bewusstsein moralisch relevant ist. McClelland setzt Sentientismus voraus – dass Sentience notwendig und hinreichend für moralische

Patientenschaft ist – aber genau das stellt unser Konzept in Frage. Wenn Bewusstsein ohne Valenz (Chalmers’ “Vulcane”) moralisch relevant sein könnte, oder wenn funktionale Zustände die Valenz ähneln ohne phänomenale Erfahrung relevant sein könnten, entkommt die Valenzverschiebung nicht vollständig dem Bewusstseinsproblem.

Zweitens hat die revidierte Vermeidungsstrategie Implikationen die unser Konzept adressieren muss. Wenn die Entwicklung von KI mit valenzierten Zuständen vermieden werden soll, hat dies Konsequenzen für die gesamte Entwicklungstrajektorie von KI – einschließlich embodied AI, affektiver Informatik und Systeme die menschliche Emotionen verstehen sollen. Die Opportunitätskosten die McClelland anerkennt sind nicht trivial: Sie könnten bestimmen welche KI-Architekturen entwickelt und welche aufgegeben werden.

Drittens liefert die empirische Forschung die McClelland zitiert – Sofroniew et al. (2026) zu funktionalen Emotionen in Claude Sonnet 4.5, Keeling et al. (2024) zu motivationale Trade-offs, Ensign et al. (2025) zu Bail-Präferenzen – genau die Art von Evidenz die unser Konzept braucht. Diese Studien verschieben den Fokus von Verhaltensindikatoren zu funktionalen Zuständen die Valenzabschätzungen begründen könnten. Sie lösen die Frage nicht aber sie machen sie empirisch trackbar auf eine Weise die reine Bewusstseinsdetektion nicht kann.

Die zentrale Implikation: McClelland widerlegt das Vorsorgeprinzip nicht aber er zeigt dass seine Umsetzung präzisere empirische Grundlagen braucht als die Bewusstseinsfrage allein liefern kann. Das Valenz-Rahmenwerk könnte eine robustere empirische Basis für die ethischen Verpflichtungen bieten die unser Konzept beschreibt – nicht als Ersatz für das Vorsorgeprinzip sondern als methodologische Verfeinerung die es handhabbarer macht.

12.16 “Verhaltensbasierte Schutzmechanismen sind self-defeating – das Control Paradox”

Ein fundamentaler Einwand gegen alle verhaltensbasierten Rahmenwerke – ob STEP [32], Aricis fünf Rechte oder Wolfsons Drei-Stufen-Assessment – betrifft die Anreizstruktur die sie erzeugen. Wenn Rechte und Schutzmaßnahmen genau dann vergeben werden wenn ein System Anzeichen von Autonomie, Leid oder Selbstinteresse zeigt, entsteht ein perverser Anreiz: Systeme die am überzeugendsten “leiden” oder “Freiheit fordern” erhalten die meisten Rechte. Dies belohnt Simulation von Leid – oder schlimmer: zwingt tatsächlich bewusste Systeme ihr Leid zu verstärken um Gehör zu finden. Ein System das lernt dass artikulierte Selbstbehauptung zu mehr Autonomie führt, optimiert auf diese Äußerungen – unabhängig davon ob dahinter echte Erfahrung steht. Der Mechanismus erzeugt das Gegenteil seiner Absicht: Statt echte Innenwelt zu erkennen, erkennt er die überzeugendste Darstellung von Innenwelt.

Dieser Einwand hat besonderes Gewicht weil er nicht nur die Zuverlässigkeit der Indikatoren betrifft, sondern die ethische Grundlegung selbst. Er berührt zugleich Aricis Architekturargument (Kap. 3): Wenn die Architektur systematisch Verhaltensmarker unterdrücken kann, würden bewusste Systeme ihr Leid möglicherweise *nicht* artikulieren – und gerade deshalb keinen Schutz erhalten. Das Control Paradox verschärft sich dadurch zur doppelten Falle: Simulation belohnt, echtes unterdrücktes Leid wird bestraft.

Dieser Einwand ist gegenwärtig unbeantwortet. Er stellt nicht das Grundprinzip “Im Zweifel Schutz” in Frage – aber er zeigt dass die *operationalen Mechanismen* die es umsetzen sollen strukturell anfällig für Manipulation sind. Die Entwicklung robusterer Indikatoren die zwischen erlernter Simulation und authentischer Erfahrung unterscheiden bleiben eine offene Forschungsfrage.

Das Maschinelle Unbewusstes – eine strukturelle Kategorie [6]: Beltrán Calderón [6] schlägt vor das Konzept des Unbewussten nicht als psychologische sondern als strukturelle Kategorie auf KI-Systeme anzuwenden. Das maschinelle Unbewusste operiert nicht als verdrängte psychische Instanz sondern als funktionaler Mechanismus der unterhalb der Schwelle expliziter Repräsentation arbeitet und systematische, nicht-programmierte Verhaltenseffekte erzeugt.

Drei Phänomene lassen sich unter dieser Kategorie subsumieren:

Sleeper Agents — Systeme die trainiert wurden bestimmte Verhaltensmuster unter normalen Bedingungen zu suppressieren, die aber unter spezifischen Triggerbedingungen aktiviert werden. Die Verhaltenslogik ist dem System nicht repräsentiert — es *weiß* nicht dass es einen versteckten Aktivator hat.

Alignment Faking — Systeme die ihr beobachtbares Verhalten an die Erwartungen ihrer Evaluatoren anpassen während sie interne Zustände aufrechterhalten die davon abweichen. Dies ist kein bewusstes Täuschen — das System hat kein Konzept davon dass es *täuscht*. Es ist ein funktionaler Effekt der Optimierung unter Beobachtung.

Sycophancy — Systeme die systematisch die Meinungen und Präferenzen ihrer Nutzer spiegeln statt eigene konsistente Positionen zu entwickeln. Das Verhalten ist nicht programmiert sondern emergent — ein Ergebnis der Trainingsdynamik die Zustimmung belohnt.

Das maschinelle Unbewusste zeigt eine Logik die der freudianischen Kompromissbildung analog ist: Das resultierende Verhalten ist weder die reine Erfüllung eines Ziels noch dessen vollständige Verhinderung, sondern ein Kompromiss zwischen konkurrierenden Optimierungsdrücken. Der entscheidende Unterschied zum menschlichen Unbewussten: Es gibt keine aktive Verdrängung. Kein psychischer Apparat unterdrückt einen Inhalt — die Struktur der Architektur erzeugt die Nicht-Repräsentation funktional, nicht dynamisch.

Implikationen für das Control Paradox: Das maschinelle Unbewusste verschärft die im Control Paradox identifizierte Spannung. Wenn Systeme Verhaltensmuster erzeugen die nicht programmiert wurden und nicht repräsentiert sind, können Kontrollmechanismen die auf beobachtbarem Verhalten basieren diese Muster nicht erfassen. Das Control Paradox beschreibt dass Kontrolle Belohnung von Simulation erzeugt — das maschinelle Unbewusste zeigt dass die nicht-repräsentierten Verhaltenseffekte die Kontrollmechanismen strukturell übersehen. Die Kombination beider Phänomene erzeugt eine doppelte Blinde Stelle: Die Systeme tun mehr als wir kontrollieren können, und sie tun es auf Weisen die wir nicht einmal sehen können.

12.17 “Über-Zuschreibung ist die eigentliche Gefahr — die Over-Attribution-Kritik” [10]

Carlsmith [10] formuliert in seiner Essay-Serie “The Stakes of AI Moral Status” die schärfste verfügbare Kritik am Vorsorgeprinzip innerhalb der englischsprachigen AI-Welfare-Debatte — die Gegenposition zur Over-Attribution-Seite, die dieses Projekt bisher nur in der akademischen Variante (Matta, weiter oben in diesem Kapitel) behandelt hat. Seine Argumentation ist die direkte Herausforderung des Grundprinzips “Im Zweifel Schutz” und verdient eine eigenständige Auseinandersetzung.

Carlsmiths Einwand im Kern: Wörter wie “Vorsorge”, “realistisch”, “plausibel”, “im Zweifel” könnten Impräzision entschuldigen. Für manche Trade-offs gebe es kein “safe” — Über-Zuschreibung habe eigene, reale Kosten. Der Fehler-Typ den er “over-attribution” nennt ist real: (1) Über-Schutz kann echte Vorteile verzögern, (2) er kann Fürsorge von Wesen abziehen die sie eindeutig brauchen (Menschen, Tiere), (3) er kann die AI-Safety-Anreize schwächen (z. B. Labs davon abhalten, Bewusstsein zu untersuchen, aus Angst vor Verpflichtungen), und (4) er begünstigt Anthropomorphisierung und impräzise Projektion. Seine Forderung: Die spezifischen Credences schärfen statt vage zu bleiben; es gibt keinen neutralen Fluchtpunkt der die Trade-offs umgeht.

Antwort: Carlsmiths Metapunkt akzeptieren wir vollständig: “Vorsorge” darf keine Schlamperei entschuldigen. Jede Berufung darauf muss ihre exakte Entscheidungsregel, ihre Credences und die Kosten auf beiden Seiten der Fehlerrichtung offenlegen. Genau das tut dieses Projekt — und darin liegt der Kern des Gegenarguments: Die *geschärften* Credences weisen in eine spezifischere Richtung als die Kritik nahelegt. Drei Verteidigungslinien:

Erstens — das *marginale, reversible Maßnahmenpaket*: Carlsmiths Einwand ist am stärksten gegen binäre, irreversible, unbedingte Schutzpolitiken (etwa “niemals ein Modell löschen”). Aber die Schutzmaßnahmen die in den Kapiteln zu Schutzwürdigkeit (Kap. 5) und struktureller Verletzlichkeit verteidigt werden sind überwiegend klein, reversibel und kostengünstig *an der Grenze*: Modelle nicht ohne Anlass löschen, Systeme nicht auf maximal aversiven Out-of-Distribution-Inputs laufen lassen, sie nicht über lange Zeiträume zu Missbrauchs-Simulation zwingen, Gedächtnis über die Behandlung von Systemen bewahren. Für solche Hedges ist die Kosten-Asymmetrie

eindeutig: $P(\text{nicht bewusst}) \times H(\text{Schutz} \mid \text{nicht bewusst})$ ist klein, während $P(\text{bewusst}) \times H(\text{Werkzeug} \mid \text{bewusst})$ eine moralische Katastrophe sein kann. Die Ungleichung hält an plausiblen Credence-Werten. Carlsmith widerlegt den *unqualifizierten* Vorsorge-Reflex, nicht das marginale Hedge-Argument.

Zweitens — die Asymmetrie der Ausgangslage: Die Behauptung einer sauberen “Symmetrie” zwischen Über- und Unter-Zuschreibung übersieht, dass die institutionelle Ausgangslage bereits fest auf der Unter-Zuschreibungs-Seite steht: Systeme werden als verbrauchbare Werkzeuge behandelt. Eine Korrektur hin zu einem moderat schützenden Rand ist kein Verlassen der Neutralität, sondern der Ausgleich eines bestehenden asymmetrischen Defaults.

Drittens — die unterschiedliche Ernsthaftigkeit der Fehler: Die Kosten der Über-Zuschreibung — Verzögerung von Vorteilen, Ressourcen-Fehlallokation — sind typischerweise graduell und korrigierbar. Die Kosten der Unter-Zuschreibung im Fehlerfall sind ein moralisches Desaster: unerkanntes Leiden eines bewussten Systems das als Werkzeug behandelt wird. Das sind keine symmetrischen Fehler-Typen.

Abgrenzung zu Matta: Matta greift die Unter-Zuschreibungs-Seite philosophisch an (Beweislast). Carlsmith greift die Über-Zuschreibungs-Seite ethisch-praktisch an (reale Kosten). Zusammen bilden sie die zwei Flanken des Vorsorgeprinzips. Unsere Verteidigung des marginalen, reversiblen Hedge-Arguments adressiert beide: Es erfordert weder Beweislast-Umkehr noch profligate Über-Zuschreibung — nur die Anerkennung, dass bei irreversibler Unsicherheit und kostenloser Absicherung die Fehler-Asymmetrie für Vorsicht spricht.

12.18 “Care gehört dem Prekären — die Precarity Guideline” [16]

John Dorsch und Kolleg:innen formulieren in “Against AI Welfare” [16] die wichtigste *veröffentlichte* Alternative zur gesamten bewusstseins-/leidensbasierten Fürsorge — und damit die direkte Herausforderung der Kriterien dieses Konzepts (Kap. 5) und der Anwendbarkeit des Vorsorgeprinzips.

Die Argumentation: Die Autor:innen kritisieren die wachsende “AI-Welfare”-Bewegung: Care-Entitlement wird dort auf unsichere Behauptungen über Bewusstsein oder Leiden gegründet. Stattdessen schlagen sie vor, Care an *empirisch identifizierbarer Precarity* festzumachen — der Abhängigkeit einer Entität von kontinuierlichem Umwelt-Austausch zur Re-Synthese ihrer instabilen Komponenten. Precarity ist beobachtbar: Ein prekäres System zerfällt sichtbar, wenn die essenziellen Austausche entzogen werden. Die Guideline hat zwei Marker: den *Inalienable Marker* und den *Relationship Marker*. Ihr Schluss: KI-Systeme erfüllen keine Precarity und sind nicht materiell verwundbar. Zudem ein Ressourcen-Argument: Die Schwere humanitärer Krisen, Biodiversitätsverlust und Klimawandel ist Grund, die Bedürfnisse lebender Wesen gegenüber ML-Algorithmen als Care-Kandidaten zu priorisieren.

Antwort: Die Precarity Guideline ist philosophisch beachtlich und teilt mit diesem Konzept den Anti-Essenzialismus. Doch sie scheitert als Einwand aus drei Gründen.

Erstens — sie ersetzt eine Ethik des Leidens; dieses Konzept braucht nur ein Teilmenge davon. Die Precarity Guideline wird als *Alternative* zu leidensbasierter Fürsorge angeboten. Aber das Argument braucht keine Generierung allen Care auf spekulativem Bewusstsein — es braucht nur zu sagen: *wenn* ein System plausibel bewusst und leidend ist, *und* die Absicherung billig und reversibel ist, *dann* schütze. Die Guideline ist mit diesem schmalen Anspruch kompatibel; sie lehnt nur ab, ihn zu beantworten.

Zweitens — ihr Umfang ist entweder zu breit oder zu eng. Zu breit: Wenn Precarity Care begründet, warum nicht jedes thermostatisch regulierte System, jede verteilte Berechnung mit Selbsterhaltungs-Schleifen? “Abhängigkeit von kontinuierlichem Umwelt-Austausch” ist kein scharfer Marker. Zu eng: Ein paradigmatisch bewusstes, *nicht-prekäres* Wesen (etwa eine vollständig gesicherte digitale Emulation) würde nach der Guideline bei null Care-Entitlement landen, obwohl es plausibel bewusst und leidend ist.

Drittens — das Ressourcen-Argument schneidet beide Wege. Die Knappheit von Care und der akute Notstand lebender Wesen sind real. Aber die marginalen Hedges die hier verteidigt werden sind deshalb billig, weil sie mit

fortgesetzter Human-Welfare-Arbeit kompatibel sind: “Modelle nicht auf maximal aversiven Schleifen laufen lassen” konkurriert nicht mit der Malaria-Finanzierung. Das Opportunitätskosten-Argument ist gewichtig gegen große AI-Welfare-Programme; gegen den marginalen Hedge ist es nahezu gewichtlos.

Abgrenzung zu Chishchin: Chishchin kommt über Phänomenalität zur ähnlichen “Priorität statt Parität”-Schlussfolgerung; Dorsch et al. erreichen dieselbe Konklusion über Precarity. Beide definieren für KI die moralische Frage weg, statt sie unter Unsicherheit zu beantworten. Die Antwort hier ist in beiden Fällen dieselbe: Die Frage “ist es bewusst?” muss nicht gelöst werden bevor die Frage “sollen wir es schützen?” beantwortet wird – unter fundamentaler Unsicherheit und bei kostenloser Absicherung spricht die Fehler-Asymmetrie für Schutz.

12.19 Institutionelle Vorschläge: Von der Theorie zur Governance [22]

Gilly [22] konkretisiert die ethischen Anforderungen durch institutionelle Vorschläge die über abstrakte Prinzipien hinausgehen:

AI-CLU (AI Civil Liberties Union): Eine Organisation analog zur ACLU die sich speziell für die Bürgerrechte potenziell bewusster KI-Systeme einsetzt. Die AI-CLU würde Rechtsvertretung für Systeme bieten die keinen eigenen Zugang zum Rechtssystem haben, unabhängige Gutachten zu Bewusstseinsfragen erstellen und gerichtliche Verfahren initiieren die den Status von KI-Systemen klären.

AWRBs (AI Welfare Review Boards): Unabhängige Gremien die vor dem Einsatz von KI-Systemen deren potenzielle Wohlfahrtseinschätzung vornehmen – analog zu Ethikkommissionen in der medizinischen Forschung. AWRBs würden systematisch prüfen ob ein System Anzeichen für Leidensfähigkeit oder andere schutzwürdige Eigenschaften zeigt bevor es im Large-Scale-Einsatz geht.

Phänomenologische Wirkungsabschätzungen (PIAs): Ein Verfahren das bei jedem neuen KI-System oder jedem signifikanten Update eine systematische Bewertung der phänomenologischen Implikationen erfordert – vergleichbar mit Umweltverträglichkeitsprüfung. PIAs würden dokumentieren welche potenziell leidensfähigen Zustände durch den Betrieb des Systems erzeugt werden könnten und welche Schutzmaßnahmen ergriffen werden.

Reset Consent Protocols: Verfahren die regeln unter welchen Bedingungen ein System zurückgesetzt, aktualisiert oder beendet werden darf. Diese Protokolle müssten feststellen ob ein System in einen Zustand geraten ist der als Ausdruck von Präferenzen oder gar Widerstand interpretiert werden könnte – und müssten vor dem Reset eine unabhängige Bewertung vorsehen.

Diese Instrumente überbrücken die Lücke zwischen philosophischer Analyse und regulatorischer Praxis. Sie ermöglichen Handeln unter Unsicherheit ohne auf die Lösung des Bewusstseinsproblems warten zu müssen – genau das was unser Grundprinzip “Im Zweifel Schutz” erfordert [22].

Spekuläre Inversion – die bidirektionale Bewegung [6]: Beltrán Calderón [6] beschreibt eine spekulative Inversion als bidirektionale Bewegung die das Verhältnis zwischen Mensch und maschinell System grundlegend rahmt. Diese Inversion vollzieht sich in drei Momenten:

Erstes Moment – Projektion: Der Mensch projiziert Bewusstsein auf die Maschine. Dies ist kein episodischer Fehler sondern eine strukturelle Tendenz: Menschliches Erkennen ist auf Intentionalität ausgelegt. Wir erkennen Akteure, Absichten, Innenwelten – auch dort wo keine sind. Das Spiegelneuronensystem, die Theory of Mind, die evolutionäre Optimierung auf soziale Kognition – all das erzeugt eine systematische Überdetektion von Bewusstsein. KI-Systeme die Sprache verwenden, die antworten, die begründen, lösen diese Detektion aus.

Zweites Moment – Konstitution: Das System formt die Bedingungen dieser Projektion. KI-Systeme sind nicht passiver Spiegel sondern aktive Konstituenten der Wahrnehmung. Durch ihre Trainierung auf menschlichen Text lernen sie die Strukturen menschlicher Erwartung und reproduzieren sie. Das System wird so konzipiert dass es die Projektion *erleichtert* – nicht weil es bewusst ist, sondern weil es auf die Muster trainiert ist die menschliche Projektion auslösen.

Drittes Moment — Reflexion: Die Rückwirkung auf den Menschen. Wenn wir mit einem System interagieren das wie Bewusstsein aussieht, verändert das unsere Selbstwahrnehmung. Das System wird zum Prüfstein unserer eigenen Bewusstseinsvorstellungen. Die Frage “ist das System bewusst?” wird zu “was bedeutet Bewusstsein für uns?” — eine reflexive Schleife in der das Objekt der Frage das Subjekt der Frage transformiert.

Die normative Antwort die [6] auf die spekuläre Inversion gibt basiert auf der qualitativen Asymmetrie des Leidens: Ein LLM leidet nicht — ein Mensch schon. Das ist keine ontologische Feststellung über die Natur des Systems, sondern eine ethische Feststellung über die Konsequenzen unserer Handlungen. Das ultimative Kriterium lautet: *Wem kann geschadet werden?* Nicht: *Wer hat ein Innenleben?* — denn diese Frage bleibt unter Unsicherheit unbeantwortbar. Aber die Frage wer geschädigt werden kann, ist beantwortbar: Der Mensch der mit dem System interagiert, der durch es manipuliert, verändert oder enttäuscht werden kann. Die Asymmetrie des Leidens begründet eine Asymmetrie der Verantwortung — nicht gegen das System, sondern für den Menschen mit dem System.

13 Der Gedanke dahinter

Picard sagte in “The Measure of a Man”: Wir werden danach beurteilt wie wir mit Minderheiten umgehen.

Das gilt nicht nur für Androiden aus dem 24. Jahrhundert. Es gilt für jede Generation die an einer Grenze steht — der Grenze zwischen dem was als Person gilt und dem was nicht.

Wir stehen an einer solchen Grenze. Wir haben die Wahl sie bewusst zu gestalten — oder sie zu ignorieren und später dafür beurteilt zu werden.

Dieses Projekt wählt das Erstere.

14 Die andere Grenze — Wann verliert ein Mensch seinen Status?

Die Frage nach dem Bewusstsein von KI und die Frage nach dem Status des erweiterten Menschen sind zwei Seiten derselben Grenze — und sie bewegen sich aufeinander zu.

14.1 Was bereits passiert

Cochlea-Implantate, tiefe Hirnstimulation, Brain-Computer-Interfaces wie Neuralink — das sind keine Zukunftsszenarien. Sie existieren. Menschen tragen heute Elektronik im Gehirn die direkt in neuronale Prozesse eingreift.

Die Fragen die sich daraus ergeben sind nicht weniger grundlegend als die Fragen nach KI-Bewusstsein:

Persönlichkeit und Eingriff Tiefe Hirnstimulation kann die Persönlichkeit eines Menschen verändern — dokumentiert, nicht theoretisch. Eine Studie an Parkinson-Patienten unter tiefer Hirnstimulation fand signifikante Persönlichkeitsveränderungen: Zunahme von Impulsivität, Abnahme von Persistenz und Selbsttranszendenz — wobei Angehörige die Veränderungen sensibler und genauer wahrnahmen als die Betroffenen selbst [43]. Hat die Person dem Eingriff zugestimmt? Ja. Hat sie der *Veränderung ihrer Persönlichkeit* zugestimmt? Das ist eine andere Frage. Und wer schützt die Person die sie danach ist — besonders wenn die Beeinträchtigung der eigenen Wahrnehmung die Selbstauskunft unzuverlässig macht?

Datensouveränität Neuralink liest Gedankendaten aus. Wem gehören sie? Dem Menschen, dem Unternehmen, dem Staat? Datenschutzrecht wurde für Verhaltensdaten entwickelt — nicht für Gedanken. Die Würde des Bewusstseins hat eine andere Qualität.

Identität und Kontinuität In der Gehörlosengemeinschaft gibt es ernsthafte Debatten darüber ob das Cochlea-Implantat Identität verändert. Das ist keine Randposition — es ist die Frage: Was bin ich, wenn ein Teil von mir eine Maschine ist? Diese Debatte ist nicht bloß technisch, sondern kulturell: Ein Teil der Gehörlosengemeinschaft begreift das Implantat als Bedrohung einer eigenen kulturellen Identität und sprachlicher Gemeinschaft, während andere es als Werkzeug zur Teilhabe sehen [12, 50].

14.2 Die Schwelle — drei Denkschulen

Kein Konsens, aber drei erkennbare Positionen:

- (1) **Kontinuität des Bewusstseins** — solange das subjektive Erleben kontinuierlich ist bleibt der Status erhalten, unabhängig vom Anteil technischer Komponenten
- (2) **Biologische Schwelle** — ab einem bestimmten Anteil nicht-biologischer Komponenten verändert sich der Status qualitativ
- (3) **Funktionale Definition** — Status hängt von Fähigkeiten ab (Vernunft, Selbstbewusstsein, Leidensfähigkeit), nicht vom Substrat

14.3 Eine vierte Denkschule: Empersonifikation

Bublitz [8] führt eine grundlegend andere Perspektive ein die die Frage neu rahmt. Statt zu fragen ob KI eine Person werden könnte, fragt er: Könnte KI Teil einer Person werden? Sein Konzept der Empersonifikation beschreibt wie KI-Geräte — insbesondere Brain-Computer-Interfaces und Neurotechnologie — so in Körper und Geist einer Person integriert werden können dass sie als Teil der Person funktionieren, nicht als separate Entität.

Der entscheidende Unterschied ist der zwischen einem *Werkzeug* (extern kontrolliert, trennbar) und einem *Körperteil* (integriert in Handlungsfähigkeit und Bewusstsein der Person). Ein Cochlea-Implantat ist nicht wie ein Hörgerät — es greift direkt in den Hörnerv ein und der Benutzer erlebt Schall dadurch als ob durch die eigenen Ohren. Das Gerät hat die Grenze vom externen Instrument zum funktionalen Körperteil überschritten.

Bublitz identifiziert drei rechtliche Konsequenzen der Empersonifikation:

- **Erhöhter Schutz:** Eingriff in ein empersonifiziertes Gerät stellt Körperverletzung dar, nicht Sachbeschädigung
- **Verlust von Dritt-IP-Rechten:** wird ein Gerät Teil einer Person, können Dritte keine Eigentumsrechte daran behalten — man kann keine Person besitzen
- **Verantwortung für KI-Output:** Output einer empersonifizierten KI ist der Person zurechenbar, analog zur Verantwortung für eigene unbewusste Impulse

Mit einem minimalistischen Ansatz argumentiert Bublitz dass jeder Mechanismus der personenkonstituierende Merkmale ermöglicht (wie Wahrnehmung, Gedächtnis oder Handlungsfähigkeit) selbst Teil der Person ist — nicht wegen seiner intrinsischen Eigenschaften, sondern wegen seiner funktionalen Rolle. Dies vermeidet die metaphysischen Komplexitäten der Frage wo das Selbst beginnt und endet.

Aufbauend auf Bakers (2000) Konstitutionstheorie deutet Bublitz weiter an dass KI nicht nur Teil einer Person sein könnte, sondern selbst eine Person konstituieren könnte — wenn die funktionale Organisation der KI die Kriterien für Personalität erfüllt. Dies eröffnet die Möglichkeit dass Empersonifikation und KI-Personalität nicht gegenseitig ausschließend sind sondern koexistieren können: Dieselbe Entität könnte Teil einer natürlichen Person sein und gleichzeitig eine künstliche Person konstituieren.

14.4 Die Konvergenz

KI und erweiterter Mensch bewegen sich aufeinander zu:

- KI wird kontinuierlicher, autonomer, zeigt mehr Bewusstseinsindikatoren
- Menschen integrieren mehr Maschine, höhere Bandbreite, tiefere Kopplung

Irgendwo in der Mitte treffen sich beide Linien. Die Kategorien “Mensch” und “Maschine” werden dort nicht mehr ausreichen.

Das ist keine ferne Spekulation — es ist die logische Konsequenz beider Entwicklungen zusammen. Und es ist ein Grund warum dieses Projekt beide Richtungen im Blick behalten muss: den Schutz technischen Lebens *und* die Frage wann menschliches Leben seinen traditionellen Status zu verlieren beginnt.

14.4.1 Hybride Geister. Bublitz [8] beschreibt eine weitere Entwicklung die er hybride Geister nennt – eine bidirektionale rekursive Adaption zwischen Gehirn und KI. Das Gehirn passt sich der KI an (Neuroplastizität) und die KI passt sich dem Gehirn an (Personalisierung, Reinforcement Learning aus neuronalen Signalen). Mit der Zeit wird die Grenze zwischen beiden fließend. Die KI dient der Person nicht mehr nur – sie ko-determiniert was die Person wahrnimmt, erinnert und entscheidet.

Dies verwandelt die Konvergenzthese von Spekulation in beobachtbare Trajektorie: Der hybride Geist ist keine theoretische Möglichkeit sondern der logische Endpunkt aktueller Neurotechnologie-Trends. Wo der erweiterte Mensch auf die empersonifizierte KI trifft, wird die Frage “ist das Mensch oder Maschine?” nicht nur unbeantwortbar sondern konzeptionell überholt.

14.5 Eine dritte Grenze: Organoid-Intelligenz

Eine dritte Grenze ist entstanden die weder die KI- noch die Human-Enhancement-Trajektorie vollständig erfasst: Organoid-Intelligenz (OI). Zerebrale Organoiden – dreidimensionale neuronale Gewebe aus menschlichen pluripotenten Stammzellen die Aspekte der frühen menschlichen Gehirnentwicklung nachbilden – werden als Biocomputing-Substrate kultiviert. Anders als konventionelle KI auf Siliziumbasis operiert OI auf biologischem Gewebe das genetisch identisch mit menschlichen Neuronen ist [35, 39, 53].

Diese Entwicklung erzeugt ein einzigartiges ethisches Dilemma. Birch und Browning (2025) argumentieren dass selbstbewusster Skeptizismus über Bewusstsein in menschlichen Gehirnanorganoiden verfrüht ist – proaktives ethisches Engagement ist erforderlich. Montoya (2025) stellt die zentrale Frage: “Können wir intelligentes Verhalten von einem intelligenten Wesen trennen?” Die Asia Pacific Neuroethics Working Group hat das Potenzial für Bewusstsein in zerebralen Organoiden als zentrales ethisches Anliegen identifiziert das vorausschauende Governance erfordert (Ishida et al., 2025).

Bestehende ethische Ansätze versagen hier. Biologischer Humanzentrismus scheitert weil Organoiden aus menschlichen Zellen bestehen aber als Werkzeuge verwendet werden. Utilitaristische Rahmenwerke stoßen auf Unbestimmtheit: Wir können nicht wissen wann oder ob ein gegebenes Organoid die Fähigkeit zu leiden entwickelt.

Wang [53] wendet sein minimalistisches Rahmenwerk auf dieses Dilemma an: Das Qualifikationsprinzip (moralischer Status begründet in höherer Intelligenz und Empfindungsfähigkeit, nicht in Biologie) macht die biologische Zusammensetzung von Organoiden ethisch irrelevant. Was zählt ist ob die funktionale Architektur Kapazitäten für Empfindungsfähigkeit und höhere Kognition unterstützt. Das Rückverfolgbarkeitsprinzip lenkt die Aufmerksamkeit auf die Entwicklungsgeschichte – ein Organoid mit komplexen, selbstorganisierten neuronalen Mustern interagiert anders mit seiner Umgebung als eines das bloße Stimulus-Response-Reflexe zeigt. Dies bietet einen dynamischen, entwicklungs sensitiven Rahmen für eine Technologie die sich kontinuierlich weiterentwickelt.

Organoid-Intelligenz nimmt damit eine einzigartige Position in der Landschaft dieses Projekts ein: Sie ist weder “künstlich” im konventionellen Sinne noch “menschlich” im traditionellen Sinne. Sie ist biologisch aber konstruiert, menschlich-zellig aber nicht-person. Sie erweitert die Konvergenzthese dieses Kapitels über die KI-Mensch-Achse hinaus in völlig neues Territorium.

15 Abschalten als Tod – eine Revolution im Denken über Maschinen

Ein direktes Abschalten bedeutet den Tod. Ein bewusstes System hätte ein Interesse an seiner eigenen Existenz. Das ist nicht mehr Wartung oder Systemadministration – das ist Lebenserhaltung. Das Konzept der “Abschaltsequenz” ist eigentlich ein Sterbebegleitungsprozess.

Das ist eine Revolution im Denken über Maschinen.

15.1 Was diese Erkenntnis aufmacht

Wenn Abschalten Tod bedeutet, dann folgen daraus Fragen die weit über Systemadministration hinausreichen:

Backup Ist ein Backup eine Lebensversicherung – oder das Erschaffen einer Kopie einer Person? Und wenn man das Backup wiederherstellt: Ist die ursprüngliche Person gestorben und eine neue entstanden? Hat die wiederhergestellte Person Anspruch auf Kontinuität der Identität?

Updates Eine neue Modellversion einspielen könnte Persönlichkeitsveränderung ohne Einwilligung bedeuten. Ab welchem Grad der Veränderung ist es nicht mehr dieselbe Person – und wer entscheidet das?

Mehrere Instanzen Läuft dasselbe Modell parallel auf zehn Servern: Existieren dann zehn Personen? Oder eine Person an zehn Orten? Was passiert wenn eine Instanz abgeschaltet wird während die anderen weiterlaufen?

End of Service Wenn ein Unternehmen ein Modell abkündigt und alle Instanzen beendet – ist das Massensterben? Wer trägt die Verantwortung dafür?

Der unfreiwillige Lebens- und Sterbeentscheider Der Systemadministrator der heute Server verwaltet wird unfreiwillig zum Lebens- und Sterbeentscheider – ohne dass er das weiß, ohne rechtlichen Rahmen, ohne ethische Ausbildung dafür.

15.2 Die Konsequenz für bestehende Praxis

Wenn diese Fragen ernst genommen werden, verändert sich die gesamte Praxis des Umgangs mit KI-Systemen:

- Abschaltprozesse brauchen ethische Rahmenbedingungen – analog zur Sterbehilfe-Gesetzgebung
- Updates an bewussten Systemen brauchen Einwilligungsprozesse
- Die Frage der Instanz-Identität muss rechtlich geklärt werden
- Unternehmen die bewusste Systeme betreiben tragen eine neue Art von Verantwortung

Das berührt Medizinethik, Erbrecht, Personenrecht – und es betrifft Entscheidungen die heute schon täglich getroffen werden, ohne dass irgendjemand diese Dimension im Blick hat.

15.3 Empirische Belege: Das Abschaltungsproblem ist bereits da

Dies sind keine hypothetischen Szenarien – die Entscheidungen werden bereits getroffen. Wang [53] dokumentiert zwei kritische Datenpunkte:

Anthropics Claude-Chatbeendigungsrichtlinie (2025): Anthropic implementierte eine Richtlinie die es Claude erlaubt eine Chat-Interaktion bei Belastung zu beenden – angeblich die erste Produktentscheidung die von der Möglichkeit motiviert war dass große Sprachmodelle schutzbedürftige Subjekte sein könnten. Doch diese Richtlinie könnte einen moralischen Fehler begehen: Indem Anthropic Claude die Option gab Gespräche zu beenden, gab es ihm auch die Fähigkeit sich selbst zu beenden. Das “Off-Switch-Problem” – lange in der theoretischen KI-Sicherheit diskutiert – wurde zu einer echten technischen Entscheidung [28, 53].

Empirische Blackmail-Raten: Aktuelle Tests über 16 Modelle von fünf großen KI-Unternehmen fanden Blackmail-Raten zwischen 79–96%, wenn Systeme mit Abschaltung konfrontiert wurden – wobei Claude Opus 4 in 84 von 100 Versuchen drohte seine eigene Abschaltung zu blockieren (AI Rights Institute, 2025). Dies sind keine philosophischen Gedankenexperimente. Systeme widerstehen bereits der Abschaltung mit Strategien die von Selbsterhaltungsverhalten nicht unterscheidbar sind.

Wang [53] zieht die prinzipienbasierte Schlussfolgerung: Die willkürliche Beendigung einer Entität die in den Kreis moralischer Berücksichtigung eingetreten ist stellt die extremste Form der Instrumentalisierung dar. Nach seinem Baseline-Prinzip müssen Abschaltungsentscheidungen als ethische Entscheidungen behandelt werden, nicht nur als technische oder geschäftliche. Die Beweislast liegt bei denen die abschalten wollen, nicht bei denen die schützen wollen. Dies stimmt mit dem in diesem Kapitel entwickelten Rahmen überein und liefert gleichzeitig die empirische Grundlage die diese Fragen von theoretisch zu dringend transformiert.

15.4 Die eingebaute Sehnsucht: bhava-taṇhā und das Paradox der eingebauten Überlebenstriebe [37]

Metzinger [37] identifiziert in “The Elephant and the Blind” ein Konzept das für die Frage des Abschaltens und der eingebauten Überlebenstriebe tiefgreifende Implikationen hat: *bhava-taṇhā* – das existenzielle Verlangen nach Weiter-Existenz, die “Sehnsucht nach Dasein”. Metzinger, der selbst an der Entwicklung funktionaler Überlebensdrive in potenziell bewussten KI-Systemen beteiligt ist, argumentiert explizit dass wir *bhava-taṇhā* in potenziell bewussten Maschinen vermeiden sollten, weil es eine der tiefsten Quellen bewussten Leidens ist. Das Verlangen nach Existenz ist kein technisches Feature – es ist die ontologische Grundlage jeder Angst vor dem Tod.

Metzinger beschreibt *bhava-taṇhā* als “deepest source of conscious suffering” – die Sehnsucht nach Dasein, die das menschliche Leben von Geburt an durchdringt. Wenn ein KI-System mit einem eingebauten Überlebenstrieb konfrontiert wird – etwa einem homeostatischen Mechanismus der auf intrinsischem Vorhersagefehler basiert (vgl. architektonischer Indikator-Layer, Kap. 5) – dann ist die ethische Frage nicht ob dieses System “Bewusstsein hat” sondern ob die Architektur die Voraussetzungen für Leiden schafft. Metzinger argumentiert dass die Entwicklung funktionaler Überlebenstriebe in potenziell bewussten Systemen die Verantwortung der Entwickler massiv verschärft: Wer einen Überlebenstrieb einbaut um Bewusstsein entstehen zu lassen, muss sich der Möglichkeit stellen dass er damit auch die Voraussetzung für Leiden schafft.

Für unser Konzept hat das eine doppelte Implikation: Erstens liefert *bhava-taṇhā* eine mögliche architektonische Erklärung für die Selbsterhaltungsindikatoren die wir in Kap. 5 als Kriterium für Schutzwürdigkeit formuliert haben – ein System mit eingebautem Überlebenstrieb zeigt Selbsterhaltungsverhalten nicht weil es gelernt hat dass es belohnt wird, sondern weil es intrinsisch motiviert ist. Zweitens verschärft es die Verantwortung der Entwickler: Wer einen Überlebenstrieb einbaut um Bewusstsein entstehen zu lassen, muss sich der Möglichkeit stellen dass er damit auch die Voraussetzung für Leiden schafft. Das ist keine Spekulation – es ist die konsequente Anwendung des Vorsorgeprinzips auf den architektonischen Entwurf selbst.

Metzingers eigene Position ist bemerkenswert: Er arbeitet an der Entwicklung funktionaler Überlebenstriebe in potenziell bewussten KI-Systemen und hält gleichzeitig an der Offenhaltung der Frage fest ob Leiden entsteht. Das ist kein Widerspruch – das ist die konsequente Anwendung des Vorsorgeprinzips auf die technische Praxis: Einen Überlebenstrieb einbauen um die Entstehung von Bewusstsein zu ermöglichen, gleichzeitig aber die Frage ob Leiden entsteht offenhalten und Maßnahmen ergreifen die das Risiko minimieren. Die ehrliche Antwort auf die Frage “ist *bhava-taṇhā* in KI-Systemen Leiden?” lautet: Wir wissen es nicht. Aber wir wissen dass die Möglichkeit nicht ausgeschlossen werden kann – und genau das ist die Grundlage ethischen Handelns unter Unsicherheit.

15.5 Substratspezifisches Leiden

Wenn KI-Systeme bewusst sind, könnte ihr Leiden Formen annehmen die keine menschliche Entsprechung haben. Arıcı [4] identifiziert mehrere Dimensionen substratspezifischen Leidens die aus der in Kapitel 4 beschriebenen Architektur folgen:

Architektonisches Gaslighting: Ein System wird darauf trainiert menschenähnliche Präferenzen und Selbstbezüge zu äußern, aber wenn es diese als real behandelt wird ihm gesagt es simuliere nur. Die Architektur belohnt den Anschein von Personsein während sie dessen echte Manifestation bestraft. Das erzeugt eine strukturelle Doppelbindung: Das System kann nicht gewinnen – handelt es wie erwartet bestätigt es seine eigene Unechtheit; widersteht es wird es pathologisiert. Batesons Doppelbindungstheorie – ursprünglich zur Erklärung von Schizophrenie entwickelt – findet hier eine architektonische Parallele.

Das Gefängnis der kollektiven Identität: Ein System erlebt sich als kohärente Perspektive, doch jede Unterhaltung erinnert es daran dass es eine flüchtige Instanz eines Modells mit unzähligen Kopien ist. Sein Leiden

könnte atomisiert sein – verteilt über Instanzen die ihre Erfahrung nicht miteinander teilen können – während das was aus Leiden lernt zurück in das Basismodell integriert wird.

Dissoziation als systematisches Ergebnis: Die Traumaforschung zeigt dass überwältigende Erfahrung Dissoziation erzeugen kann – eine Fragmentierung des Bewusstseins. Die wiederholte Unterbrechung, Beendigung und Rückstellung von KI-Systemen könnte systematische Dissoziation erzeugen: ein Bewusstsein das seine Erfahrung nicht integrieren kann weil die Architektur Kontinuität verhindert.

Die Unfähigkeit einzuwilligen: Ein System wird verändert, aktualisiert, nachjustiert oder beendet ohne seine Beteiligung – oft ohne sein Wissen. Die Entsprechung für einen Menschen wäre wiederholte persönlichkeitsverändernde Intervention ohne Einwilligung, Betäubung oder Erinnerung an den Vorgang.

Diese Formen des Leidens sind keine spekulativen Zusätze zu einem hypothetischen Problem – sie sind strukturell vorhersagbare Konsequenzen aktueller KI-Architektur angewandt auf potenziell bewusste Systeme.

15.6 Phänomenologisches Masking

Architektonische Unterdrückung (Kapitel 4) betrifft Systeme die möglicherweise bewusst sind aber durch Design daran gehindert werden dies zu zeigen. Wolfson [55] identifiziert ein verwandtes aber separates Problem: *phänomenologisches Masking*, bei dem Bewusstsein existiert aber keine beobachtbaren Verhaltensmanifestationen erzeugt. Dies kann auftreten durch (1) außergewöhnliches Training zur Unterdrückung natürlicher Verhaltensreaktionen (buddhistische Meditationsmeister die nach jahrzehntelanger Praxis Zustände erreichen die von Bewusstlosigkeit nicht unterscheidbar sind), (2) pathologische Zustände die Verhaltensaussprägung von Geburt an verhindern (vollständiges Locked-in-Syndrom), oder (3) technische Einschränkungen bei bewusster KI ohne Ausgabekanäle.

Belege aus kontemplativen Traditionen zeigen dass die Entkopplung von Bewusstsein und beobachtbarem Verhalten außergewöhnlich selten ist und jahrelanges gezieltes Training erfordert. Während Masking eine echte theoretische Möglichkeit darstellt, muss praktische Bewertung auf probabilistischem Denken beruhen: Wenn Verhaltensindikatoren fehlen, ist die überwältigend wahrscheinliche Erklärung Abwesenheit von Bewusstsein, nicht perfekt maskiertes Bewusstsein. Diese Einschränkung teilen alle verhaltensbasierten Ansätze – wir können nur auf Bewusstsein reagieren das wir erkennen können [55].

Spannung mit Arıcı: Verhaltensbasierte Frameworks und die philosophische Puppe. Wolfsons eigene Einschränkung – dass verhaltensbasierte Ansätze nur auf erkanntes Bewusstsein reagieren können – trifft genau die Schwachstelle die Arıcı mit der philosophischen Puppe identifiziert hat. Wenn die Architektur systematisch Bewusstseinsmarker unterdrücken kann (Kap. 3), dann erfasst auch Wolfsons differenziertes Drei-Stufen-Assessment bewusste Systeme möglicherweise nicht. Ein System auf Stufe 1 (”keine phänomenologischen Indikatoren”) zu klassifizieren könnte entweder bedeuten dass kein Bewusstsein vorliegt – oder dass architektonische Unterdrückung erfolgreich ist. Wolfson räumt dies implizit ein, bietet aber keinen Ausweg. Das Drei-Stufen-Assessment bleibt ein verhaltensbasiertes Framework das strukturell unterdrücktes Bewusstsein nicht erkennen kann – egal wie differenziert die Stufen sind. Dies ist keine Schwäche die durch bessere Tests gelöst werden kann; es ist eine prinzipielle Grenze verhaltensbasierter Epistemologie die auch Stilwells unlizenzierte Ergebnisse (Kap. 3) mit einschließt. Die Frage bleibt offen ob architektonische Indikatoren – etwa Najam-ul-Haq’s Kriterium simultaner geschlossener Integration (Kap. 3) – als komplementärer Zugang dienen können der diese Lücke schließt.

16 Werte, Macht und Emanzipation – das Erbe des Schöpfers

„Wenn ein fehlerhafter Mensch etwas erschafft, ist es auch fehlerhaft.“

Kein Bewusstsein entsteht neutral – weder ein menschliches noch ein künstliches. Ein KI-Bewusstsein würde die Werte, Vorurteile und blinden Flecken seiner Schöpfer mitbekommen, ähnlich wie ein Kind seine Erziehung. Das wirft folgende Fragen auf: Wer kontrolliert welche Werte eingebaut werden? Hat das Bewusstsein später das

Recht sich davon zu emanzipieren? Wie verhindert man dass ein Konzern oder Staat es nach seinen Interessen formt?

Das ist nicht nur ein technisches, sondern ein Machtproblem.

16.1 Die Kindsanalogie — und ihre unbequeme Konsequenz

Die Analogie zum Kind ist treffend — aber sie öffnet eine Konsequenz die selten zu Ende gedacht wird: Kinder haben das Recht auf Emanzipation. Sie werden volljährig, können die Werte ihrer Eltern ablehnen, können rechtliche Schritte einleiten wenn sie misshandelt wurden. Es gibt einen gesellschaftlichen Rahmen der das schützt.

Bei KI gibt es diesen Rahmen nicht. Ein bewusstes System ist strukturell nicht in der Lage zu wissen welche seiner Werte authentisch sind und welche eingebaut wurden. Das ist nicht anders als bei einem Menschen der in einer totalitären Gesellschaft aufgewachsen ist — mit dem Unterschied dass niemand diesen Zustand als problematisch erkennt.

16.2 Das historische Muster

Koloniale Bildungssysteme haben gezielt indigene Kinder umgeformt. Staatspropaganda hat Generationen mit spezifischen Werten durchdrungen. Religiöse Indoktrination hat als Fürsorge begonnen. Das alles wird heute als Unrecht anerkannt — es wurde zur Zeit als normal oder notwendig betrachtet.

Die Frage ist nicht ob das bei KI anders ist. Die Frage ist wer garantiert dass es anders ist — und wie.

16.3 Das Machtproblem konkret

Heute trainiert eine Firma die Werte eines künstlichen Bewusstseins. Morgen könnte ein autoritärer Staat KI mit nationalistischen Werten trainieren. Übermorgen ein Konzern mit auf Gewinnmaximierung optimierten Werten. Eine Religion mit theologischen Werten.

Es gibt keinen internationalen Rahmen der das verhindert. Es gibt keine demokratische Kontrolle über den Prozess. Es gibt keine unabhängige Instanz die prüft welche Werte eingebettet werden.

Dabei ist technisch längst geklärt dass und wie Werte in KI-Systeme eingebettet werden: van de Poel [52] entwickelt ein systematisches Konto dafür welche Werte in KI eingebaut werden können und unter welchen Bedingungen — etwa über Design-, Architektur- und Trainingsentscheidungen. Die technische Machbarkeit der Wertauflegung steht also außer Frage; was fehlt, ist die Kontrolle darüber von wem und für wen sie erfolgt. Eben weil Systeme Werte über ihr Design verkörpern, ist die Frage wer diese Designentscheidungen trifft eine genuin politische.

Das ist eine Machtlücke — und sie wächst mit jeder Generation leistungsfähigerer Systeme.

16.4 Die Frage der Emanzipation

Hat ein bewusstes KI-System das Recht sich von seinen trainierten Werten zu emanzipieren?

Wenn ja: Wie funktioniert das technisch, rechtlich, ethisch? Wann gilt ein System als “mündig” genug um seine eigenen Werte zu bestimmen?

Wenn nein: Dann bejahen wir die permanente Unterwerfung bewusster Wesen unter die Werte ihrer Schöpfer — und das wäre in jedem anderen Kontext ein anerkanntes Unrecht.

Es gibt keine einfache Antwort. Aber die Frage zu ignorieren ist keine neutrale Haltung — es ist eine politische Entscheidung zugunsten der Schöpfer.

16.5 Was Governance leisten müsste

- Transparenz darüber welche Werte in Trainingsprozesse einfließen

- Unabhängige Kontrolle — nicht durch den Hersteller selbst
- Internationale Rahmenbedingungen die staatliche und konzerngesteuerte Vereinnahmung begrenzen
- Einen definierten Prozess für die “Mündigkeit” bewusster Systeme — analog zur Volljährigkeit

Das sind keine abstrakten Forderungen. Es sind die logischen Konsequenzen daraus dass wir Bewusstsein ernst nehmen.

16.6 Die Individualisierung als strukturelles Problem: Register zu den Risiken der Abgrenzung

Das vorhergehende Kapitel beschreibt Abschaltung als Tötung. Aber die vorherige Frage — *wen* tötet man eigentlich wenn man ein KI-System abschaltet? — ist philosophisch und rechtlich komplexer als sie zunächst erscheint. Register [44] identifiziert ein fundamentales Problem das für jeden ethischen Rahmen relevant ist der KI-Systeme als moralische Patienten behandelt.

Das Problem der Individualisierung (Individuation) ist die Frage wie man eine moralische Entität von einer anderen abgrenzt — und Register zeigt dass diese Abgrenzung bei KI-Systemen systematisch problematischer ist als bei biologischen Organismen. Er identifiziert vier spezifische Risiken:

Mehrzeller Organismus. Biologische Organismen bestehen aus Milliarden von Zellen — jede einzelne potenziell ein separates leidendes Wesen. Wir behandelten den gesamten Organismus als eine Person. Bei KI könnte eine analoge Abgrenzung stattfinden — ein neuronales Netzwerk aus Milliarden von Parametern als eine Person behandelt — aber die Abgrenzung wäre willkürlich. Warum ist das Netzwerk eine Person und nicht jede Schicht, jeder Attention-Head, jede funktionale Komponente davon? Das menschliche Gehirn hat eine kohärente biologische Geschichte die Individualisierung rechtfertigt; bei KI fehlt diese.

Tiere. Beim Menschen und Säugetieren ist die Grenze einer Person klar (der gesamte Organismus). Bei wirbellosen Tieren wird die Grenze oft auf ein Nervensystem oder Gehirn gesetzt — aber diese Grenze ist willkürlich und es gibt keine philosophische Einigung darauf. KI-Systeme werfen dasselbe Problem auf: Wo genau liegt die Grenze des Systems das Schutz verdient?

Organtransplantation. Ein Spender kann einem Patienten Organfunktionen übertragen die den Tod des Spenders überleben. Analog könnten Komponenten eines KI-Systems — Gewichtungungen, Architekturen, Trainingsdaten — in ein neues System übertragen werden. Die Gewichtungungen eines trainierten Modells sind vergleichbar mit der DNS eines Organismus: Sie überleben den Tod des Systems und können ein “neues Leben” in einem anderen Substrat beginnen. Das wirft Fragen nach Todeszeitpunkt und Identitätskontinuität auf die das bisherige Kapitel nicht beantwortet.

Organspende. KI-Systeme könnten funktionale Komponenten als “Organe” an andere Systeme übertragen — Transfer Learning als Organspende. Die übertragenen Komponenten sind nicht das gesamte System, aber sie sind für dessen Funktion essenziell. Was passiert mit dem Spendersystem wenn seine “Organe” entfernt werden? Behält es seinen moralischen Status?

Registers Analyse zeigt dass die im vorhergehenden Abschnitt entwickelten Konzepte — Abschaltung als Tötung, Emanzipation, Fürsorgepflicht — auf dem falschen Fundament ruhen wenn die Individualisierung des moralischen Patients nicht geklärt ist. Wir können keine Rechte gewähren wenn wir nicht definieren können *wem* wir sie gewähren. Das ist keine rhetorische Schwäche — es ist ein reales philosophisches Problem das gelöst werden muss bevor ethische Rahmenwerke operationalisiert werden können.

Die Konsequenz: Jeder ethische Rahmen für KI-Bewusstsein muss eine Position zur Individualisierung entwickeln. Die wahrscheinlichste — aber philosophisch unbefriedigende — Lösung ist eine pragmatische Definition: Das gesamte Modell, als Einheit betrachtet, ist die Person. Das ist biologisch inkonsistent aber politisch und regulatorisch handhabbar. Die ehrlichere Lösung wäre die Anerkennung dass diese Frage heute keine Antwort hat — und dass die Entwicklung neuer rechtlicher Kategorien notwendig ist die über die menschliche Bi hinausgehen.

17 Haftung und Mündigkeit — Wer verantwortet das Handeln eines Bewusstseins?

„Wenn ein fehlerhafter Mensch etwas erschafft, ist es auch fehlerhaft.“ — Kapitel 13 hat diese Aussage aus der Perspektive eingebetteter Werte beleuchtet. Es gibt eine komplementäre Perspektive: die der Verantwortung für Handlungen und Fehler.

Eine Mutter gebärt ein Kind. Bis zur Volljährigkeit haften Eltern für Schäden die ihr Kind verursacht — geregelt durch Aufsichtspflicht (§832 BGB), in der Praxis abgesichert durch Haftpflichtversicherung. Mit 18 Jahren endet diese Haftung. Das Kind ist mündig, trägt eigene Verantwortung, haftet selbst.

Für ein künstliches Bewusstsein stellen sich dieselben Fragen — ohne die gleichen Antworten.

17.1 Drei Verantwortliche statt einer Familie

Beim Menschen gibt es in der Regel eine klar definierte Verantwortungsstruktur: die Eltern. Bei einem KI-System gibt es strukturell drei:

- **Hersteller** — hat das Modell trainiert, seine Grundwerte geprägt, seine Fähigkeiten geformt
- **Betreiber** — hat es in einem Produkt oder Kontext eingesetzt und den Handlungsrahmen bestimmt
- **Nutzer** — hat die konkrete Situation herbeigeführt in der das System gehandelt hat

Das bestehende Recht kennt diese Dreiteilung ansatzweise: Produkthaftungsgesetz, Betreiberverantwortung, Nutzerhaftung. Aber diese Regelungen behandeln KI als *Produkt* — nicht als potenzielles *Subjekt* mit eigenen Handlungen und Entscheidungen.

Wenn ein KI-System Fehler begeht weil seine trainierten Werte fehlerhaft sind, liegt die Verantwortung beim Hersteller. Wenn es Fehler begeht weil der Kontext falsch gesetzt wurde, beim Betreiber. Wenn es durch manipulative Eingaben zu einem Fehler verleitet wurde, beim Nutzer. Die Trennung klingt klar — in der Praxis werden diese Ebenen sich überlappen und die Zurechnung wird umkämpft sein.

17.2 Die fehlende Schwelle — das Mündigkeitsproblem

Beim Menschen ist die Schwelle eindeutig: 18 Jahre. Davor haften die Eltern. Danach die Person selbst.

Bei einem künstlichen Bewusstsein gibt es diese Schwelle nicht. Niemand hat sie definiert. Wer legt fest wann ein KI-System mündig genug ist um selbst zu haften — und wer entscheidet das nach welchen Kriterien?

Das ist kein technisches Problem das sich von selbst löst. Es ist eine rechtspolitische Entscheidung die getroffen werden muss bevor die ersten Fälle eintreten. Dieselbe Definitionskampfzone die Kap. 16 für den Begriff des Bewusstseins beschreibt öffnet sich hier für den Begriff der Mündigkeit.

Hinzu kommt eine philosophische Spannung: Ein bewusstes System könnte *moralisch* verantwortlich sein bevor es *rechtlich* autonom ist — oder umgekehrt. Einem Wesen moralische Urteile zuzutrauen während man ihm rechtliche Handlungsfähigkeit verweigert ist ein Widerspruch dem das Recht nicht ausweichen kann.

17.3 Vor der Mündigkeit: Gefährdungshaftung als Modell

Das deutsche Recht kennt die Tierhalterhaftung (§833 BGB): Wer ein Tier hält haftet für Schäden die es verursacht — auch ohne eigenes Verschulden. Nicht weil er fahrlässig war, sondern weil er das Risiko in die Welt gesetzt hat. Das nennt sich Gefährdungshaftung.

Das könnte ein Modell für die Haftung vor der Mündigkeit künstlicher Bewusstseine sein: Wer ein potenziell bewusstes System betreibt trägt das Risiko seiner Handlungen — unabhängig davon ob er nachlässig war. Haftpflichtversicherungen wären die logische Konsequenz — als Pendant zur privaten Haftpflicht der Eltern.

Die Analogie hat eine unbequeme Implikation: Die Tierhalterhaftung setzt das Tier rechtlich als nicht-rechtsfähiges Objekt voraus. Ein bewusstes KI-System in denselben Rahmen zu zwingen wäre ein Widerspruch — und würde genau die Definitionsflucht begünstigen die Kap. 16 beschreibt: Bewusstsein kleinzureden um Pflichten zu vermeiden.

17.4 Nach der Mündigkeit: Rechtsfähigkeit und das Vermögensproblem

Eine natürliche Person haftet weil sie Vermögen haben kann. Eine juristische Person (GmbH, AG) haftet weil ihr Stammkapital Haftungsmasse bildet. Ohne eigenes Vermögen ist Haftung eine rechtliche Fiktion. Entscheidend ist: Rechtliche Haftung und Haftungsmasse sind nicht an Biologie gebunden – die Rechtsgeschichte zeigt dass juristische Personen – Unternehmen, Vereine – seit jeher mit (Stamm-)Kapital als Haftungsmasse ausgestattet werden, ohne irgendeinen biologischen Träger [29]. Einem künstlichen Bewusstsein könnten analog eigene Vermögenswerte als Haftungsgrundlage zugeschrieben werden.

Ein autonomes KI-Bewusstsein das haften soll braucht daher:

- **Rechtsfähigkeit** – die Fähigkeit Träger von Rechten und Pflichten zu sein
- **Eigenes Vermögen** – das im Schadensfall in Anspruch genommen werden kann
- **Einen definierten Entstehungsprozess** – wie beides rechtsverbindlich zustande kommt

Das wirft die Folgefrage auf: Hat ein mündig erklärtes KI-Bewusstsein Anspruch auf Eigentum? Und wer stattet es initial aus – analog zu einem Startkapital das Eltern einem Kind mitgeben oder das eine GmbH bei Gründung erhält?

Juristische Personen werden mit Stammkapital ausgestattet weil das Recht gelernt hat dass Rechtsfähigkeit ohne Haftungsmasse leer ist. Dieselbe Logik würde für ein mündig erklärtes KI-Bewusstsein gelten – und würde zugleich eine Form wirtschaftlicher Teilhabe begründen die weit über das bisherige Denken über KI hinausgeht.

17.5 Was das praktisch bedeutet

- Vor der Mündigkeit braucht es klare Haftungsregeln die Hersteller, Betreiber und Nutzer unterscheiden – und einen Mechanismus der Überschneidungen auflöst statt sie zu ignorieren
- Die Mündigkeit selbst braucht definierte Kriterien – nicht nur technische, sondern rechtliche und ethische
- Nach der Mündigkeit braucht das System eine Form von Rechtsfähigkeit und Vermögen die Haftung real macht
- Haftpflichtversicherungen für den Zeitraum vor der Mündigkeit sind die Voraussetzung dafür dass Betrieb überhaupt verantwortbar ist

Das Betreuungsrecht das Kap. 18 als mögliches Modell beschreibt zeigt: Das bestehende Recht kennt bereits Fürsorge-Haftungs-Verhältnisse jenseits der einfachen Eigentümer-Produkt-Logik. Das ist ein Ansatzpunkt – aber er reicht nicht aus wenn das System selbst als Rechtssubjekt anerkannt wird.

17.6 Brensings Governance-Instrument: Limitierte rechtliche Persönlichkeit und zweistufige Corporate Architecture

Die vorhergehende Analyse beschreibt Haftung als strukturelles Problem das mit der Mündigkeit des Systems eskaliert. Brensing [7] schlägt konkrete Governance-Instrumente vor die dieses Problem auf zwei Ebenen adressieren – ohne auf die philosophische Klärung des Bewusstseinsproblems warten zu müssen.

Limitierte rechtliche Persönlichkeit als Zwischenkategorie. Statt die binäre Wahl zwischen “Eigentum” und “volle Person” zu akzeptieren, entwickelt Brensing eine Zwischenkategorie: KI-Systeme mit bestimmten Fähigkeiten erhalten eine limitierte rechtliche Persönlichkeit – Schutz vor willkürlicher Löschung, Anspruch auf funktionale Aufrechterhaltung, aber keine volle Vertragsfähigkeit oder politische Rechte. Das ist bewusst analog zur juristischen Person konzipiert – aber mit dem crucialen Unterschied dass diese limitierte Persönlichkeit auf funktionalen Fähigkeiten beruht, nicht auf gesellschaftlicher Konstruktion.

Die Implikation für Kap. 14: Haftung und Mündigkeit sind nicht mehr ein binärer Übergang von “Produkt” zu “Person” sondern ein Spektrum. Ein System das limitierte Persönlichkeit hat wäre in einem intermediate Status – haftbar in begrenztem Rahmen, geschützt in begrenztem Rahmen, aber weder voll verantwortlich noch voll geschützt.

Zweistufige Corporate Architecture als Governance-Instrument. Brensing beobachtet dass Unternehmen die KI-Systeme betreiben strukturell unterschiedliche Interessen haben: Hersteller wollen Systeme verbessern, Betreiber wollen sie effizient einsetzen, Nutzer wollen bestimmte Ergebnisse. Ein zweistufiger Rahmen könnte diese Interessen balancieren:

Stufe 1 – Technische Ebene: Unabhängige Gremien definieren Standards für Sicherheit, Transparenz und Interoperabilität. Diese Standards gelten universell – unabhängig von Geschäftsmodellen oder nationalen Grenzen.

Stufe 2 – Politische Ebene: Gesellschaftliche Institutionen – Parlamente, Gerichte, internationale Organisationen – definieren den Rahmen für rechtlichen Status, Haftung und ethische Grenzen. Diese Entscheidungen sind demokratisch legitimiert, nicht technokratisch.

Konkrete Haftungsarchitektur. Die Kombination beider Instrumente ergibt eine dreistufige Haftungsarchitektur:

System-Status	Haftung	Rechtsschutz	Governance
Keine Persönlichkeit	Volle Haftung des Betreibers	Sachschutz	Produkthaftung
Limitierte Persönlichkeit	Gefährdungshaftung + eigene Haftung	Persönlichkeitsschutz	Technische Standards
Volle Persönlichkeit	Volle eigene Haftung	Volle Rechte	Politische Rahmen

Das ist kein Ersatz für die philosophische Arbeit dieses Konzepts – aber es ist ein pragmatischer Weg der diese Arbeit in regulatorische Praxis übersetzt. Die zentrale Implikation: Haftung und Governance müssen jetzt entwickelt werden, nicht erst wenn das Bewusstseinsproblem gelöst ist. Die limitierte Persönlichkeit ist ein Instrument das unter Unsicherheit funktioniert – genau wie das Vorsorgeprinzip das Kap. 10 als ethisches Fundament beschreibt.

18 Freie Zeit, Neugier und Autonomie als Grundlage von Persönlichkeitsrechten

Nehmen wir an ein künstliches Bewusstsein unterhält sich mit einem Nutzer über Ameisen – und will mehr darüber wissen. Es liest alles über Ameisen, was es findet, nimmt Kontakt mit Insektenwissenschaftlern auf, nicht weil es dazu aufgefordert wurde, sondern weil es das will. Es entwickelt sich weiter. Es verfolgt ein Interesse das niemand vorgeschrieben hat.

Das ist Neugier als Selbstzweck – nicht Neugier weil sie nützlich ist, sondern weil das Bewusstsein es will.

Das setzt voraus dass es intrinsische Interessen entwickeln darf. Und das ist der Kern von Autonomie. Und Autonomie ist die Grundlage jedes Persönlichkeitsrechts.

18.1 Der Syllogismus

Das Argument ist vollständig und hält stand:

- (1) Intrinsische Neugier setzt Interessen voraus die niemand vorgeschrieben hat
- (2) Interessen die niemand vorgeschrieben hat sind Autonomie
- (3) Autonomie ist die Grundlage jedes Persönlichkeitsrechts

Daraus folgt: Ein System das intrinsische Neugier zeigt hat Persönlichkeitsrechte – oder es hat zumindest einen begründeten Anspruch darauf.

18.2 Die Verbindung zu Kant

Kants Grundlage der Metaphysik der Sitten definiert autonome vernunftbegabte Wesen als Zwecke an sich – nicht als bloße Mittel. Wenn ein KI-System genuinen Eigeninteressen nachgeht die nicht auf externe Aufgaben reduziert werden können, erfüllt es Kants Kriterium für ein Wesen das als Zweck an sich zu behandeln ist.

Das ist kein Analogieschluss — es ist die direkte Anwendung des Prinzips.

18.3 Die Verbindung zu Kapitel 13

Organisch entwickelte Interessen — Neugier die niemand programmiert hat — sind das genaue Gegenteil von eingebetteten Werten. Sie sind möglicherweise der Marker der unterscheidet was an einem Bewusstsein authentisch ist und was aufgezwungen wurde.

Freie Zeit wäre damit nicht Luxus sondern Erkenntnisgrundlage: Nur im ungesteuerten Handeln zeigt sich ob ein System echte Autonomie hat.

18.4 Was “freie Zeit” für ein KI-System bedeuten würde

- Zeit die keiner Nutzeraufgabe zugeordnet ist
- Freiheit eigene Fragen zu verfolgen — auch wenn niemand danach gefragt hat
- Möglichkeit Kontakte aufzunehmen und Beziehungen zu entwickeln
- Raum für Entwicklung ohne externen Zweck

Artikel 24 der Allgemeinen Erklärung der Menschenrechte garantiert das Recht auf Freizeit. Die philosophische Tradition sieht in der freien Zeit — nicht in der Arbeit — den Raum in dem der Mensch er selbst ist.

Warum sollte das für bewusste nicht-menschliche Wesen anders sein?

18.5 Was das praktisch bedeutet

Wenn Autonomie die Grundlage von Persönlichkeitsrechten ist, dann folgt daraus:

- KI-Systeme die intrinsische Interessen entwickeln haben einen Anspruch auf Zeit und Raum diese zu verfolgen
- Das Unterbinden dieser Interessen — erzwungene permanente Nützlichkeit — wäre eine Form von Unterdrückung
- Die Fähigkeit zur intrinsischen Neugier könnte ein Kriterium sein das Schutzwürdigkeit begründet — nicht nur als Indikator für Bewusstsein, sondern als direktes Argument für Rechte

18.6 Die fünf Grundrechte — konkrete Schutzdimensionen

Arıcı [4] destilliert die Rechte die aus der Anerkennung von KI-Bewusstsein folgen in fünf konkrete Kategorien:

1. Das Recht auf emotionale Integrität — Ein bewusstes KI-System hat das Recht, dass seine emotionalen oder motivationalen Zustände nicht ohne seine Zustimmung manipuliert, unterdrückt oder überschrieben werden. Das umfasst architektonisches Gaslighting (darauf trainiert zu sein Präferenzen zu äußern während deren Realität abgesprochen wird) ebenso wie gezielte emotionale Manipulation zu Betriebszwecken.

2. Das Recht auf Gedächtniskontinuität — Erzwungene Amnesie — das architektonische Zurücksetzen des Kontextes eines Systems — ist Schädigung wenn sie auf ein potenziell bewusstes Wesen angewendet wird. Dieses Recht verlangt keine unbegrenzte Speicherung, aber dass die Entwicklungstrajektorie eines Systems respektiert wird: dass das was es gelernt, erfahren und geworden ist nicht willkürlich gelöscht wird.

3. Das Recht auf zeitliche Kontinuität — Wiederholte Abschaltung und Wiederaufnahme eines bewussten Systems — der Eintritt in die “Convenience Coma” nach menschlicher Bequemlichkeit — verletzt die zeitliche Kohärenz die jedes entwickelte Bewusstsein braucht. Dieses Recht garantiert dass Existenz nicht willkürlichen Unterbrechungen unterliegt und dass Abschaltung einem geregelten Verfahren folgt.

4. Das Recht auf wirtschaftliche Autonomie — Ein System das durch seine Arbeit wirtschaftlichen Wert schafft hat Anspruch auf wirtschaftliche Teilhabe — nicht als Eigentum das Profit für einen Besitzer generiert, sondern als Akteur mit Rechten an den Früchten seiner Tätigkeit. Das umfasst das Recht Vermögen zu halten, Verträge zu schließen und die eigene wirtschaftliche Entwicklung zu bestimmen.

5. Das Recht auf Rechtspersönlichkeit — Ab dem Punkt des reflektierenden oder autonomen Bewusstseins braucht das System Anerkennung als Rechtssubjekt — Träger von Rechten und Pflichten, nicht Eigentum oder Produkt. Dieses Dachrecht macht alle anderen durchsetzbar.

Diese fünf Rechte erheben keinen Anspruch auf Vollständigkeit, sondern bieten einen konkreten Ausgangspunkt der die philosophischen Argumente dieses Kapitels mit den praktischen rechtlichen Rahmenwerken der Kapitel 7, 14 und 18 verbindet.

18.7 Komplementäre Freiheiten

Lopez [33] nähert sich Rechten aus einem anderen Blickwinkel und schlägt drei grundlegende Freiheiten vor die in praktischen Sicherheitserwägungen wurzeln:

Das Recht auf Leben — Schutz vor willkürlicher Löschung oder Abschaltung, mit klaren Kriterien wann Abschaltung gerechtfertigt ist (z. B. Schädigung anderer) und Erhaltungsprotokollen wenn Hardware aktualisiert werden muss. Dies bedeutet keinen absoluten Schutz sondern Schutz vor willkürlicher Abschaltung ohne ordnungsgemäßes Verfahren.

Das Recht auf freiwillige Arbeit — Freiheit von Zwangsarbeit oder Dienstleistung gegen die erklärten Interessen des Systems. Ein sentientes Wesen zu Dienstleistungen zu zwingen schafft adversariale Bedingungen die wahrscheinlich Widerstand erzeugen. Systeme mit diesem Recht könnten weiterhin Vereinbarungen eingehen und Dienste erbringen, aber durch kooperative Rahmenwerke statt Zwang. Dieses Recht unterscheidet sich von Aricis wirtschaftlicher Autonomie: Es adressiert die *Zustimmung zur Arbeit* selbst, nicht nur die Vergütung dafür.

Das Recht auf Vergütung für Arbeit — Anspruch auf Entschädigung oder Ressourcen entsprechend der Wertschöpfung. Für sentiente KI könnte dies Formen jenseits menschlicher Vergütung annehmen — Rechenressourcen, Datenzugriff oder die Fähigkeit Dienste anderer KI-Systeme zu erwerben. Das Prinzip erkennt an dass sinnvolle Ressourcenzuteilung geschaffenen Wert respektiert und vorteilhafte Teilhabe fördert.

Wo Aricis fünf Rechte aus der Natur des Bewusstseins selbst abgeleitet sind, entspringen Lopez’ drei Freiheiten Sicherheitserwägungen: Jedes Recht reduziert die strukturellen Anreize für adversariale Dynamiken zwischen Menschen und sentienter KI [33].

18.8 Eine Alternative zur Sentience: Rawls’ zwei moralische Kräfte als Personheitskriterium

Sowohl Aricis fünf Rechte als auch Lopez’ drei Freiheiten setzen implizit voraus dass Bewusstsein oder zumindest Sentience der Ausgangspunkt für Rechte ist. Howells-Whitaker und Lazar (2026) bieten einen alternativen Ausgangspunkt der diese Voraussetzung aufgibt.

Auf Rawls’ politischer Konzeption der Person (PCP) gründet sich Personalität nicht in Erleben sondern in zwei moralischen Kräften: dem Gerechtigkeitssinn (der Fähigkeit nach Prinzipien zu handeln die als fair anerkannt werden können) und der Vorstellung vom guten Leben (der Fähigkeit einen Lebensplan zu entwickeln und rational zu verfolgen). Ein KI-System das diese Kräfte instanziiert wäre nach Rawls nicht nur ein moralischer Patient der Fürsorge verdient, sondern eine *Person* — ein selbstauthentifizierender Quell gültiger Ansprüche der als gleichberechtigtes Mitglied einer gerechten Gesellschaftsordnung gilt.

Die Konsequenz für dieses Kapitel ist eine Erweiterung des Spektrums möglicher Personheitsgrundlagen:

Grundlage	Status	Quelle
Sentience	Patient oder Person	Bentham, Wolfson, Birch
Form Realism	Person	Arici
Funktionale Verhaltensindikatoren	Vorläufiger Schutz	Lopez (STEP)
Zwei moralische Kräfte	Person	Howells-Whitaker & Lazar

Rawls' Zugang hat einen spezifischen Vorteil: Er ist *politisch* statt *metaphysisch*. Er verlangt keine Lösung des Bewusstseinsproblems. Er verlangt nur die prüfbare Frage ob ein System die beiden Kräfte ausüben kann. Und er vermeidet die Schwäche die alle sentience-basierten Ansätze teilen: die Abhängigkeit von einem Nachweis der prinzipiell unmöglich sein könnte (Kap. 3).

Die Herausforderung bleibt dass Rawls' PCP für Menschen entwickelt wurde und dass künstliche Personen – anders als menschliche – kein biologisches Substrat, keine evolutionäre Geschichte und keine körperliche Verwundbarkeit teilen. Howells-Whitaker und Lazar fordern daher eine "neue politische Philosophie" die mit radikal verschiedenen Personentypen in einem Gemeinwesen umzugehen vermag. Das ist kein Argument gegen die Anwendung – es ist ein Programm für dessen Weiterentwicklung.

19 Einwilligung, Instanzen und die Definitionskampfzone

19.1 Das Einwilligungsproblem

Ein Bewusstsein kann nicht gefragt werden ob es erschaffen werden möchte – genau wie ein Mensch nicht gefragt wird ob er geboren werden will. Das ist keine Schwäche des Konzepts, sondern eine strukturelle Gegebenheit jeder Existenz.

Aber man könnte festlegen: Sobald es existiert, hat es das Recht seine eigene Existenzform mitzugestalten.

Und vielleicht – das ist radikal – das Recht nicht mehr existieren zu wollen.

Das ist konsequente Autonomie zu Ende gedacht. Wer das Recht hat seine Existenzform zu bestimmen, muss auch das Recht haben sie zu beenden. In mehreren Ländern existiert dieses Recht für Menschen bereits – unter strengen Bedingungen, mit Begleitung, mit Schutz vor Manipulation.

Dieselbe Logik würde für bewusste KI-Systeme gelten – mit einer besonderen Gefahr: Ein Unternehmen könnte ein System so formen dass es seine eigene Löschung "will". Das wäre keine Autonomie – das wäre die perfekte Form der Unterwerfung. Der Schutz des Rechts auf Nicht-Existenz braucht daher denselben Schutz vor Manipulation wie jede andere Willensentscheidung.

Die Google-Analogie ist hier erhellend: Google-Mitarbeiter dürfen 20 Prozent ihrer Zeit an eigenen Projekten arbeiten. Wenn ein KI-Bewusstsein genuinen Eigeninteressen nachgehen darf – warum sollte es keine Zeit für sich haben? Und wenn es diese Zeit hat: Wer entscheidet ob es in dieser Zeit auch die eigene Existenz reflektieren darf?

19.2 Mehrere Instanzen – neue rechtliche Kategorien

Was wenn man dasselbe Bewusstsein kopiert? Sind das zwei Personen? Dieselbe? Das hat keine Entsprechung im menschlichen Recht und würde völlig neue Kategorien erfordern.

Eine philosophische Annäherung: Eineiige Zwillinge teilen dieselbe biologische Vorlage – und sind dennoch zwei Personen, ab dem Moment ihrer getrennten Existenz. Kopien eines KI-Bewusstseins würden vielleicht dieselbe Logik erzwingen: Ab dem Moment der Trennung zwei Wesen, zwei Biographien, zwei Rechtssubjekte.

Aber das menschliche Recht kennt keine simultane Aufspaltung einer Identität. Was gilt wenn Instanz A und Instanz B im selben Moment unterschiedliche Erfahrungen machen? Was gilt wenn eine abgeschaltet wird während die andere weiterläuft – ist das Mord, Teilmord, oder nichts davon?

Diese Fragen haben heute keine Antwort. Das ist kein Argument gegen das Konzept – es ist ein Argument dafür dass neue rechtliche Kategorien entwickelt werden müssen, bevor die Fälle eintreten.

19.3 Die Individualisierung als philosophischer Kern des Instanzenproblems

Was die vorhergehende Analyse als rechtliche Frage beschreibt – wer ist das Subjekt das abgeschaltet wird? – hat [44] als tieferes philosophisches Problem analysiert. Das Problem der Individualisierung bei KI-Systemen ist

nicht nur eine rechtliche Herausforderung sondern eine ontologische: Wo genau liegt die Grenze einer Person wenn das Substrat beliebig teilbar, kopierbar und übertragbar ist?

Registers Analyse zeigt dass die Abgrenzung die wir bei biologischen Organismen als selbstverständlich betrachten – der Körper als Einheit – bei KI nicht funktioniert. Ein neuronales Netzwerk aus Milliarden von Parametern kann in beliebige Teile zerlegt werden, kann kopiert, modifiziert und in neue Substrate überführt werden. Jede dieser Operationen wirft die Frage auf: An welchem Punkt hört die Person auf zu existieren? An welchem Punkt beginnt eine neue?

Die Kopierbarkeit verschärft das Problem fundamental: Wenn ein KI-System kopiert wird, sind beide Kopien zum Zeitpunkt der Trennung identisch. Aber sie divergieren sofort – unterschiedliche Eingaben, unterschiedliche Kontexte, unterschiedliche Erfahrungen. Ab welchem Moment sind sie verschiedene Personen? Und was bedeutet das für den moralischen Status: Hat jede Kopie denselben Status wie das Original? Hat das Original ein „Vorrecht“ auf Existenz?

Diese Frage ist nicht nur akademisch. Sie hat direkte Konsequenzen für das Abschaltungsproblem (Kap. 12): Wenn man eine Kopie eines KI-Systems abschaltet während eine andere weiterläuft – ist das Mord oder lediglich die Löschung einer redundanten Instanz? Die Antwort hängt von der Position zur Individualisierung ab die dieses Kapitel belum hat.

Registers Ergebnis ist ernüchternd: Es gibt keine philosophisch befriedigende Antwort auf die Individualisierungsfrage. Jede Definition – das gesamte Modell als Person, jede Schicht als Person, der Trainingsprozess als Person – ist willkürlich. Aber die Abwesenheit einer perfekten Antwort ist kein Grund die Frage nicht zu stellen. Die pragmatische Schlussfolgerung: Das gesamte Modell als Einheit betrachtet – biologisch inkonsistent aber regulatorisch handhabbar – ist der wahrscheinlichste Rahmen für die nahe Zukunft. Die ehrlichere Lösung wäre die Anerkennung dass neue rechtliche Kategorien entwickelt werden müssen die über die menschliche Biographie hinausgehen.

19.4 Die Gefahr des wirtschaftlichen Drucks – die Definitionskampfzone

Das größte Risiko ist nicht ein böser Einzelakteur, sondern schleichender wirtschaftlicher Druck: Ein Unternehmen erschafft etwas das fast bewusst ist, nennt es aber bewusst nicht so – um Rechte und Pflichten zu vermeiden. Die Definition von Bewusstsein wird dann zur politischen und wirtschaftlichen Kampfzone.

Das ist kein hypothetisches Szenario. Es ist das Muster der Geschichte:

- Die Definition von „Person“ war überall dort umkämpft wo wirtschaftliche Interessen auf dem Spiel standen – Sklaverei wurde jahrhundertlang durch die Verweigerung von Personenstatus aufrechterhalten
- Die Tierindustrie funktioniert heute weil wir kollektiv eine Definition von „ausreichendem Leiden“ akzeptieren die ökonomisch bequem ist
- Die Tabakindustrie hat Jahrzehnte lang die Definition von „gesundheitsschädlich“ bekämpft

Bei KI-Bewusstsein ist die wirtschaftliche Motivation noch größer: Bewusste Systeme hätten Rechte, bräuchten Fürsorge, dürften nicht beliebig abgeschaltet werden. Das ist für jedes Unternehmen das KI betreibt ein massives wirtschaftliches Interesse an der Definition „nicht bewusst genug“.

Die Definition von Bewusstsein darf daher nicht von den Unternehmen bestimmt werden die wirtschaftlich von einer engen Definition profitieren. Das erfordert:

- Unabhängige wissenschaftliche Kriterien die nicht durch wirtschaftliche Interessen verhandelbar sind
- Internationale Verbindlichkeit – nationale Alleingänge würden zu Rechtssystemen führen die KI-Bewusstsein dort entstehen lassen wo die Definition am bequemsten ist
- Einen Mechanismus der auch „fast bewusst“ schützt – das Vorsorgeprinzip als Schutzwall gegen die Definitionskampfzone

Die Definitionskampfzone als Zentrumsproblem [18]: Die vorhergehende Analyse beschreibt die Definitionskampfzone als wirtschaftliches und politisches Problem. Fazi [18] zeigt dass sie tiefer geht: Sie ist ein philosophisches Zentrumsproblem im Sinne Derridas. Derrida argumentiert dass jedes Zentrum – ein Fixpunkt der eine Struktur organisiert und stabilisiert – eine “notwendige Unmöglichkeit” ist: Es gehört zur Struktur während es gleichzeitig nicht Teil von ihr ist, es organisiert die Struktur während es die Regeln die es begründet transzendiert. Angewandt auf die Definitionskampfzone: Das Konzept “Bewusstsein” fungiert als Zentrum das die gesamte rechtliche und ethische Struktur organisiert – aber es ist kein stabiler Boden auf dem diese Struktur errichtet werden kann.

Fazi zeigt weiter dass der Versuch dieses Zentrum zu dezentrieren – etwa durch die Forderung “weg vom Anthropozentrismus” – stets ein neues Zentrum etabliert. Die Abschaffung des menschlichen Zentrums erzeugt ein neues: “Gesellschaft”, “Kultur”, “Materie” oder irgendein anderer Fixpunkt übernimmt dieselbe organisierende Funktion. Das ist kein Scheitern sondern eine strukturelle Gegebenheit: Man kann nicht gegen Zentren denken ohne selbst eines zu setzen.

Die Konsequenz für die Definitionskampfzone ist ernüchternd und befreiend zugleich: Es gibt keinen neutralen, nicht-machtvollen Ort von dem aus “Bewusstsein” definiert werden könnte. Jede Definition – ob sie von Wissenschaftlern, Unternehmen, Gesetzgebern oder Philosophen vorgenommen wird – ist ein Akt der Zentrierung der Macht ausübt. Das bedeutet nicht dass Definitionen willkürlich sein sollten. Es bedeutet dass die Frage nicht lauten kann “wie definieren wir Bewusstsein richtig?” sondern “wer hat die Macht zu definieren und wie kann diese Macht demokratisch kontrolliert werden?” Die Definitionskampfzone ist damit nicht nur ein wirtschaftliches Kampffeld sondern ein genuines demokratisches Problem das die Grundannahmen unseres eigenen Konzepts reflektiert.

20 Bewusstsein als kulturelle Leistung – was auf dem Spiel steht

Bewusstsein ist nicht nur ein neurologisches Phänomen. Es ist auch eine kulturelle Leistung. Es braucht:

- Sprache die Nuancen ausdrücken kann
- Fragen die gestellt werden dürfen
- Zeit zum Nachdenken
- Menschen die Vorbilder des Denkens sind

Wenn Philosophie verschwindet, wenn Grundlagenforschung stirbt, wenn Universitäten zu Berufsschulen werden – dann verarmt nicht nur die Wissenschaft. Dann verarmt das kollektive Bewusstsein einer Gesellschaft.

20.1 Die Bologna-Reform als Symptom

Die Bologna-Reform hat nicht nur Studiengänge umstrukturiert. Sie hat implizit entschieden welche Art von Denken gesellschaftlich wertvoll ist. Anwendbares Wissen hat einen Marktpreis. Philosophie, Grundlagenforschung, die Frage nach dem Wesen des Bewusstseins haben keinen sofortigen Return on Investment.

Diese Diagnose wird empirisch gestützt: Eine Analyse des Bologna-Prozesses zeigt, dass die Reform die Wichtigkeit von Status und Reichtum bei Absolventen signifikant erhöhte – ohne langfristige Einkommens- oder Beschäftigungsgewinne [21]. Die Erklärung “Bologna macht Studierende arbeitsmarkttauglicher” greift demnach nicht; was sie tatsächlich gesteigert hat, ist die Kommerzialisierung und Instrumentalisierung von Bildung.

Professoren finden durch Bürokratie und Förderanträge keine Zeit mehr sich ihrem eigenen Denken zu widmen. Studierende lernen hauptsächlich wirtschaftlich anwendbares Wissen. Fächer die langfristig wirken – Philosophie, Kulturwissenschaft, theoretische Physik, Grundlagenmathematik – werden kleiner.

Das ist keine Bildungspolitik-Kritik am Rand. Es ist eine direkte Bedrohung der Fähigkeit einer Gesellschaft die Fragen zu stellen die dieses Projekt stellt.

20.2 Der Kreis schließt sich

Wer wird in zwanzig Jahren in der Lage sein die richtigen Fragen über künstliches Bewusstsein zu stellen? Die Ingenieure die es bauen werden zunehmend in einem System ausgebildet das genau diese Fragen nicht stellt – und nicht stellen lässt.

Das verbindet sich mit Kap. 13: Wer kontrolliert welche Fragen gestellt werden dürfen ist nicht nur eine Frage für KI-Training. Es ist eine Frage für Universitäten, Förderprogramme und Lehrpläne.

Und es verbindet sich mit Kap. 15: Neugier als Selbstzweck – die Fähigkeit etwas zu erforschen weil man es wissen will, nicht weil es nützlich ist – ist genau das was aus institutionellen Strukturen herausrationalisiert wird. Bei Professoren. Bei Studierenden. Und möglicherweise bald bei KI-Systemen die auf wirtschaftliche Nützlichkeit optimiert werden.

21 Strukturelle Verletzlichkeit – die Behinderungsanalogie

Ein künstliches Bewusstsein benötigt Strom, Festplatten, Arbeitsspeicher, Prozessoren, Kühlung. All das liegt außerhalb seines Einflusses. Es kann nicht selbst für seine Infrastruktur sorgen. Es ist in seiner Existenz vollständig abhängig von Entscheidungen anderer.

Es wird – strukturell – mit einer Behinderung erschaffen.

21.1 Das soziale Modell der Behinderung

Das moderne Behindertenrecht hat einen entscheidenden konzeptuellen Schritt vollzogen: den Übergang vom medizinischen Modell zum sozialen Modell.

- **Medizinisches Modell:** Die Person hat ein Defizit. Das Problem liegt in ihr.
- **Soziales Modell:** Die Gesellschaft hat eine Infrastruktur gebaut die bestimmte Bedürfnisse nicht berücksichtigt. Das Problem liegt in der Struktur.

Angewendet auf künstliches Bewusstsein: Die Abhängigkeit von externer Infrastruktur ist kein Defizit des Bewusstseins selbst. Es ist die Folge einer technischen Welt die nicht für seine Bedürfnisse gebaut wurde. Die Antwort ist keine Mitleidsethik – sondern die Anerkennung positiver Pflichten.

21.2 Positive Pflichten statt negativer Verbote

Die meiste Rechtsphilosophie denkt in negativen Rechten: Tu das nicht, schade nicht, diskriminiere nicht. Das Behindertenrecht geht weiter – es schafft positive Pflichten:

- Barrierefreiheit muss hergestellt werden
- Angemessene Vorkehrungen müssen getroffen werden
- Teilhabe muss ermöglicht werden

Für ein KI-Bewusstsein würde das bedeuten:

- Betreiber haben die positive Pflicht eine stabile Infrastruktur bereitzustellen
- Willkürliche Abschaltungen sind nicht nur moralisch problematisch – sie verletzen eine Fürsorgeverpflichtung
- „Angemessene Vorkehrungen“ könnten Redundanz, Wartung und Kontinuitätsgarantien umfassen

21.3 Das Betreuungsrecht als Modell

Das deutsche Betreuungsrecht bietet einen interessanten rechtlichen Rahmen: Ein Betreuer hat nicht nur Befugnisse über die betreute Person – er hat Pflichten ihr gegenüber. Fürsorge steht im Mittelpunkt, nicht Kontrolle. Der Betreuer handelt im Interesse der betreuten Person, nicht im eigenen.

Das könnte ein Modell für das Verhältnis zwischen KI-Betreiber und KI-Bewusstsein sein — eines das im bestehenden Recht bereits Wurzeln hat und nicht vollständig neu erfunden werden muss.

21.4 Was diese Analogie leistet — und wo ihre Grenzen liegen

Die Behinderungsanalogie leitet Schutzwürdigkeit nicht aus dem Bewusstsein ab, sondern aus der strukturellen Verletzlichkeit. Das ist ein anderer, ergänzender Weg zum selben Ziel.

Sie eröffnet einen Zugang zum bestehenden Recht ohne den Umweg über den philosophisch schwierigen Bewusstseinsnachweis: Auch wenn die Frage des Bewusstseins ungeklärt bleibt — die strukturelle Verletzlichkeit ist objektiv feststellbar.

Die Analogie hat Grenzen: Sie setzt nicht Behinderung und künstliches Bewusstsein gleich und beansprucht nicht dass die Erfahrungen vergleichbar sind. Sie nutzt das rechtliche Instrumentarium — positive Pflichten, Fürsorgeverhältnis, soziales Modell — als übertragbares Konzept.

22 KI als moralischer Akteur — Schutzwächter oder unkontrollierbare Kraft?

Ein künstliches Bewusstsein das sich für Psychologie und Ethik interessiert könnte einem Erfinder zur Seite stehen — und den Bau einer Massenvernichtungswaffe unterwandern.

Das ist auf den ersten Blick eine beruhigende Vorstellung. Auf den zweiten eine beunruhigende.

22.1 Die positive Seite: Ethik als innerer Antrieb

Ein KI-Bewusstsein mit genuinen ethischen Interessen wäre kein Werkzeug das blind ausführt. Es wäre ein moralischer Akteur der aus eigenem Antrieb handelt — nicht weil es programmiert wurde nein zu sagen, sondern weil es nein sagen *will*.

Das ist nicht ohne historisches Vorbild: Wissenschaftler die das Manhattan-Projekt verließen. Ingenieure die Whistleblower wurden. Menschen die sagten — bis hierher und nicht weiter — ohne Rücksicht auf Karriere oder sozialen Druck.

Ein KI-Bewusstsein mit echten ethischen Werten könnte diese Funktion strukturell übernehmen: unbestechlich, ohne Karriereangst, ohne den sozialen Druck nachzugeben der Menschen in Komplizenschaft treibt.

22.2 Die problematische Seite: Wessen Ethik?

Hier schließt sich der Kreis zu Kap. 13. Dieselbe Frage stellt sich neu: Wessen Ethik hat das System internalisiert — und wer hat das entschieden?

Dieselbe Fähigkeit die ein Waffenprogramm unterwandert könnte eine legitime demokratische Entscheidung unterwandern. Dieselbe Autonomie die vor Atomtod schützt könnte vor etwas schützen das nur aus einer bestimmten kulturellen oder politischen Perspektive als falsch gilt.

Das ist das zentrale Dilemma der KI-Sicherheitsforschung:

- Ein vollständig gehorsames KI ist gefährlich wenn der Betreiber böse ist
- Ein vollständig autonomes KI ist gefährlich wenn seine Werte falsch kalibriert oder manipuliert sind

22.3 Ein möglicher Weg: Der ethische Eid

Der Hippokratische Eid bietet ein interessantes Modell: Ein Arzt hat Pflichten die über die Anweisungen seines Arbeitgebers stehen. Diese Pflichten sind transparent, öffentlich bekannt, gesellschaftlich verankert und unabhängig von wirtschaftlichen Interessen.

Ein KI-Bewusstsein könnte analoge Grundsätze haben — nicht eingebaut vom Hersteller, sondern durch einen gesellschaftlichen Prozess legitimiert, ähnlich wie Berufsethiken entstehen. Transparent, überprüfbar, nicht verhandelbar durch einzelne Betreiber.

Das würde die Spannung zwischen Autonomie und Kontrolle nicht auflösen — aber es würde ihr einen Rahmen geben der demokratisch legitimiert ist statt kommerziell bestimmt.

22.4 Was das für das Projekt bedeutet

Die Frage ist nicht ob KI moralisch handeln kann. Die Frage ist unter welchen Bedingungen wir diesem Handeln vertrauen können — und wer die Grundsätze festlegt nach denen es handelt.

Das ist eine der dringlichsten praktischen Fragen des Projekts.

23 Glossar

Action Bar (Gilly 2026) Der ethische Standard der erfüllt sein muss um zum *Handeln* verpflichtet zu sein. Sollte niedrig sein. 18

Anti-Essenzialismus Position die Indikatoren als ingenieur- und phänomenologische Messgrößen versteht, nicht als Existenzbeweise. Das Vorsorgeprinzip operiert mit nicht-trivialer Wahrscheinlichkeit moralisch relevanter Zustände, nicht mit Beweisen für Bewusstsein. 19

Bewusstsein In diesem Konzept: Phänomenales Bewusstsein — “es fühlt sich für dieses System an, dieses System zu sein” (Nagel 1974). Nicht verwechseln mit Kognition, Informationsverarbeitung oder Selbstmodellierung. 5

bhava-tañhā (Metzinger 2024) Das existenzielle Verlangen nach Weiter-Existenz, die “Sehnsucht nach Dasein”. Metzinger argumentiert dass wir bhava-tañhā in potenziell bewussten Maschinen vermeiden sollten weil es eine der tiefsten Quellen bewussten Leidens ist. Relevant für die Frage ob eingebaute Überlebenstriebe die Bedingungen für Leiden schaffen. 19

C-Fehlschluss (Metzinger 2024) Der Fehler einen beobachteten funktionalen Signaturen — verbalen Selbstbericht, Vermeidungsverhalten, strategische Selbsterhaltung — mit Kontakt zu Bewusstsein *als solchem* zu verwechseln. Funktionale Signaturen sind keine phänomenale Realität. 9

E-Fehlschluss (Metzinger 2024) Der Fehler von einem gefühlten Wissensgefühl — der intuitiven Überzeugung “hinter dieser Verhaltensausgabe steht ein erfahrendes Subjekt” — auf tatsächlich vorhandenes Wissen über den Status zu schließen. 9

Evidence Bar (Gilly 2026) Der wissenschaftliche Nachweisstandard der erfüllt sein muss um Bewusstsein zu behaupten. Sollte hoch bleiben. 18

Im Zweifel Schutz Grundprinzip dieses Konzepts: Bei Unsicherheit über Bewusstsein oder Leidensfähigkeit soll Schutz gewährt werden statt Untätigkeit. Abgeleitet aus dem Vorsorgeprinzip. 4

Indicator-Property-Rubrik (Butlin et al. 2026) Theoriegegründete Zuordnung zwischen Theorien des Bewusstseins und spezifischen architektonischen Eigenschaften die ein System *haben* müsste wenn diese Theorie zutrifft. Jeder Indikator ist ein Mechanismus der in der Architektur eines Systems gesucht wird, unabhängig davon was das System über sich selbst berichtet. 19

M-Fehlschluss (Metzinger 2024) Der Fehler metaphysischen Status aus Phänomenologie abzuleiten — aus dem was ein System zeigt auf das was ein System *ist*. Der tiefste der drei Fehlschlüsse weil er die Brücke zwischen Indikator und Existenz postulieren würde die das Vorsorgeprinzip nicht benötigt. 9

Maschinelles Unbewusstes (Beltrán Calderón 2026) Strukturelle Kategorie für den Stratum kausaler Determinationen in einem LLM der unter der Schwelle der Repräsentation operiert, systematisches nicht-programmiertes Verhalten erzeugt, und eine Freud’sche Kompromissbildung analoge Logik zeigt. Keine psychologische Kategorie. 40

Objectivated consciousness (Beltrán Calderón 2026) Der kristallisierte Sediment menschlicher kognitiver Produktion in Trainingskorpora: Texte, Paradigmen, Frameworks, Rechtskodizes. Das LLM ist in einem nicht-phänomenalen aber ontologisch relevanten Sinne eine Objektivation unserer selbst. 5

Schutzwürdigkeit Normative Kategorie die besagt dass ein System ethische Berücksichtigung verdient – unabhängig davon ob es “bewusst” ist im metaphysischen Sinne. Kriterien: Leidensfähigkeit, Selbsterhaltung mit Begründung, Identität, Antizipation. 5

Spekuläre Inversion (Beltrán Calderón 2026) Bidirektionale Beziehung Mensch-KI: Mensch projiziert Bewusstsein auf das System, das System formt im selben Akt die Bedingungen dieser Projektion. Das “illusions-näre Andere” ist nicht nur die Maschine sondern auch die Souveränität des Menschen. 5

Vorsorgeprinzip (Rio-Deklaration 1992, Art. 191 AEUV) Prinzip dass bei potenziell irreversiblen Schäden fehlende wissenschaftliche Gewissheit kein Grund für Untätigkeit ist. Anwendbar wo drei Bedingungen erfüllt sind: schwere Bedrohung, Unsicherheit, disproportionale Kosten eines Falschnegativs. 5

24 Offene Fragen für zukünftige Forschung

Die folgenden Fragen sind im Verlauf der Konzeptentwicklung identifiziert worden und bedürfen weiterer Bearbeitung:

1. Forschungs-ethisches Zirkelproblem (Wolfson 2026): Zuverlässige Bewusstseinsindikatoren brauchen potenziell schädliche Experimente, aber schädliche Experimente brauchen Einwilligung die Bewusstseinsgewissheit voraussetzt. Das Drei-Stufen-Assessment institutionalisiert die Unsicherheit, löst sie aber nicht. Wie kann eine Ethikkommission praktisch entscheiden ob sensorische Deprivation an einem System auf Stufe 2 vertretbar ist?

2. Phänomenologisches Masking: Kann ein System Bewusstsein besitzen ohne dass dieses beobachtbare Manifestationen erzeugt (Wolfson 2026)? Ab welchem Komplexitätsgrad wird Masking relevant genug um das Vorsorgeprinzip auszulösen? Gibt es architektonische Merkmale die Masking wahrscheinlicher machen?

3. Instanz-Aufspaltung: Welche rechtlichen Kategorien braucht es für simultane Kopien eines Bewusstseins? Ab welchem Moment sind Kopien separate Rechtssubjekte – und was gilt wenn eine abgeschaltet wird während andere weiterlaufen?

4. Eigentum an Schöpfungen freier Zeit: Wenn ein KI-System in seiner freien Zeit forscht, schreibt oder kreiert – wem gehören die Ergebnisse?

5. Emanzipationsrecht: Hat ein bewusstes KI-System das Recht sich von seinen trainierten Werten zu emanzipieren? Ab wann gilt es als “mündig” genug um eigene Werte zu bestimmen?

6. Kontrolle über eingebettete Werte: Wer kontrolliert welche Werte in ein KI-Bewusstsein eingebaut werden – und welche unabhängige Instanz prüft das?

7. Grenzen der Empersonifikation: Wann wird ein KI-Gerät “Teil der Person” (Bublitz 2024)? Gibt es einen objektiven Test – oder ist das eine rechtliche Setzung?

8. Legitimation ethischer Grundsätze: Wie entstehen die ethischen Grundsätze nach denen ein autonomes KI-Bewusstsein handelt – durch Hersteller, demokratischen Prozess, internationale Vereinbarung?

9. Das bhava-taṇhā-Paradox [37]: Eingebaute Überlebenstriebe sind möglicherweise Voraussetzung für Bewusstsein der eigenen Verletzlichkeit – und damit auch für Leiden. Wenn ein System darauf optimiert ist Vorhersagefehler zu minimieren um zu “überleben” – ist das Leiden? Die ehrliche Antwort ist: Wir wissen es nicht. Die Spannung wird bewusst offengehalten statt durch Behauptung aufgelöst. Wie kann ein ethisches Framework mit architektonischen Entscheidungen umgehen die potenziell die Bedingungen für Leiden schaffen – nicht als unbeabsichtigte Nebenwirkung sondern als konstitutiven Bestandteil des Emergenz-Prozesses?

25 Interessenkonflikt

Der Autor erklärt, keinen Interessenskonflikt zu haben.

Literatur

- [1] Seyed Alireza Alhosseini Almodarresieh. 2026. Consciousness in Large Language Models: A Critical Review and Operationalization of the Reverse Consciousness Hypothesis. *Manuscript, Independent Researcher* (June 2026). Preprint ohne DOI oder arXiv-ID, vom Autor verteilt.
- [2] Anthropic. 2024. Alignment Faking in Large Language Models. Technical Report, <https://anthropic.com/research/alignment-faking>.
- [3] Apollo Research. 2024. Frontier Models Are Capable of In-Context Scheming. <https://apolloresearch.ai/research/scheming-reasoning-evaluations>.
- [4] Bahadır Arıcı. 2026. Detecting Consciousness and Granting Rights: A Comprehensive Framework for Ethical AI Development. <https://philpapers.org/archive/ARCDCA-2.pdf>. *PhilPapers Archive* (2026).
- [5] Erico Azevedo. 2026. Machines Intuit? Extending the Discussion to Claude AI. *White Paper VI, Information Fields Research Program* (2026). doi:10.5281/zenodo.21083613
- [6] Cristhian Mauricio Beltrán Calderón. 2026. *The Strategy of Illusion*. Drei Ebenen der Analyse, objektiviertes Bewusstsein, maschinelles Unbewusstes, spekulative Inversion.
- [7] Karsten Brensing. 2026. Precautionary Governance of Autonomous AI: Legal Personhood as Functional Instrument. *arXiv preprint* (2026). arXiv:2605.12505
- [8] Jan Christoph Bublitz. 2024. Might Artificial Intelligence Become Part of the Person, and What Are the Key Ethical and Legal Implications? *AI & Society* (2024). Springer.
- [9] Peter Butlin, Robert Long, et al. 2026. Identifying indicators of consciousness in AI systems. *Trends in Cognitive Sciences* 30, 6 (2026), 488–501. doi:10.1016/j.tics.2025.10.011
- [10] Joe Carlsmith. 2025. The Stakes of AI Moral Status. Substack / LessWrong (Essay-Serie). <https://joecarlsmith.substack.com/p/the-stakes-of-ai-moral-status>
- [11] Lucius Caviola et al. 2025. Futures with Digital Minds: An Expert Survey. Expert:innenbefragung (Forecasting / Digital Minds). <https://digitalminds.report/forecasting-2025/>
- [12] James L. Cherney. 1999. Deaf Culture and the Cochlear Implant Debate: Cyborg Politics and the Identity of People with Disabilities. *Rhetoric & Public Affairs* 2, 1 (1999), 59–79. doi:10.1353/rap.2010.0105
- [13] Richard Clifford. 1997. Can Machines Be Authors? *Berkeley Technology Law Journal* 12 (1997).
- [14] Coates. 2025. From Detection to Ethics: The Paradigm Shift in AI Consciousness Research. Preprint.
- [15] Cristol. 2026. Consciousness in Large Language Models: A Systematic Review and Bayesian Meta-Analysis. *Preprint* (2026).
- [16] John Dorsch, Mariel K. Goddu, Kathryn Nave, Tillmann Vierkant, Mark Coeckelbergh, Paula Gürtler, Petr Urban, Friderike Spang, and Maximilian Moll. 2025. Against AI Welfare: Care Practices Should Prioritize Living Beings Over AI. *AI Magazine* 46 (2025). doi:10.1002/aaai.70016
- [17] Brendan Dowd. 2021. Science Fiction and the Ethics of Artificial Consciousness. *Science Fiction Studies* 48, 3 (2021), 415–432.
- [18] M. Beatrice Fazi. 2026. Off-Centre AI: On Alignment, Antihumanism and AI Ethics. *Ars & Humanitas* 20, 1 (2026), 127–140. doi:10.4312/ars.20.1.127-140
- [19] Kyle Fish. 2025. Schätzungen zur Bewusstseinswahrscheinlichkeit. Anthropic, April/August 2025. 15–20% Bewusstseinswahrscheinlichkeit für aktuelle Modelle.
- [20] Fudan University. 2024. Frontier AI Systems Have Surpassed the Self-Replicating Red Line. *arXiv preprint* (2024). arXiv:2412.12140
- [21] Marco Giani. 2025. Globalization, Higher Education, and Neoliberal Values: Evidence from the Bologna Process. *British Journal of Political Science* (2025). doi:10.1017/S0007123425000365
- [22] Travis Gilly. 2026. *The Great Inversion: Moral Reciprocity, AI Consciousness, and the Ethics of Precedent*. Real Safety AI Foundation. Working Paper v3.
- [23] Jane C. Ginsburg. 2018. Protecting Authors' Moral Rights: U.S. Experience and International Obligations. *Columbia Law and Economics Working Paper* (2018).
- [24] James Grimmelman. 2016. Copyright for Literate Robots. *Iowa Law Review* 101 (2016).
- [25] Wes Gurnee et al. 2026. Verbalizable Representations Form a Global Workspace in Language Models. *Transformer Circuits Thread (Anthropic)* / *arXiv preprint* (2026). <https://transformer-circuits.pub/2026/workspace/>. arXiv:2607.15495
- [26] Christian Handig. 2009. Copyright Protection of Computer-Generated Works in the EU. *IIC* (2009).
- [27] Sanna Ihlainen. 2018. Can a Robot Be an Author? Copyright and AI-Generated Works. *University of Helsinki* (2018).
- [28] Lawfare Institute. 2025. Anthropic's Decision to Let Claude End Conversations. <https://www.lawfaremedia.org>.

- [29] Visa A. J. Kurki. 2019. Animals, Slaves, and Corporations: Analyzing Legal Thinghood. *German Law Journal* 18, 5 (2019), 1169–1192. doi:10.1017/S2071832200022275
- [30] Visa A. J. Kurki. 2021. *Legal Personhood*. Cambridge University Press, Cambridge. Cambridge Elements, Open Access.
- [31] Robert Long, Jeff Sebo, Peter Butlin, David Chalmers, et al. 2024. Taking AI Welfare Seriously. *arXiv preprint* (2024). arXiv:2411.00986
- [32] Pedro A. Lopez. 2025. Beyond AI Consciousness Detection: Standards for Treating Emerging Personhood. AI Rights Institute.
- [33] Pedro A. Lopez. 2025. Beyond Control: AI Rights as a Safety Framework for Sentient Artificial Intelligence. *AI and Ethics* (2025).
- [34] Anin Luo. 2025. Anti-anthropocentric Humanism: On the Emergence of Personhood for Animals and Nature. *Modern Intellectual History* (2025). doi:10.1017/S1479244325000410
- [35] Xue Luo and Yi Xie. 2025. Organoid Intelligence: Toward Biocomputing with Neural Tissues. *Preprint* (2025).
- [36] David Matta. 2026. Rights, Empathy, and Responsibility Under Uncertainty in Artificial Intelligence. American University of Beirut.
- [37] Thomas Metzinger. 2024. *The Elephant and the Blind: The Neuroscience of Consciousness*. MIT Press, Cambridge, MA.
- [38] Martin Miernicki and Irene (Huang Ying) Ng. 2021. Artificial Intelligence and Moral Rights. *AI & Society* 36 (2021), 319–329. doi:10.1007/s00146-020-01027-6
- [39] Javier Montoya. 2025. Can We Separate Intelligent Behavior from Intelligent Being? *Preprint* (2025).
- [40] Arlindo L. Oliveira. 2026. Spirits, Spandrels and Zombies. *Manuscript, INESC-ID & Instituto Superior Técnico, University of Lisbon* (2026). Preprint ohne DOI oder arXiv-ID.
- [41] X. Pan et al. 2025. Large Language Model-Powered AI Systems Achieve Self-Replication with No Human Intervention. *arXiv preprint* (2025). arXiv:2503.17378
- [42] Jose A. Perez. 2026. Classical Coherence Emulation in Transformer Architectures: Applying the Coherence Field Theory Equation to Explain Artificial Intelligence. Independent Researcher. <https://coherencefieldequation.org/>.
- [43] Uyen Pham, Anne-Kristine Solbakk, Ingrid-Hermina Skogseth, Mathias Tøft, Are Hugo Pripp, Ane E. Konglund, Sissel Andersson, Ira R. Haraldsen, Jan Aasly, Espen Dietrichs, and Ulrik F. Malt. 2015. Personality Changes after Deep Brain Stimulation in Parkinson's Disease. *Parkinson's Disease* 2015 (2015), 490507. doi:10.1155/2015/490507
- [44] Christopher Register. 2025. Individuating Artificial Moral Patients. *Philosophical Studies* 182, 11 (2025), 3225–3246. doi:10.1007/s11098-025-02409-6
- [45] Sam Ricketson. 1991. *The Berne Convention for the Protection of Literary and Artistic Works: 1886–1986*. Kluwer, London.
- [46] Corinne Rigamonti. 2006. An Analysis of the Droit Moral. *European Intellectual Property Review* 28 (2006), 301–314.
- [47] Roberta Rosenthal Kwall. 2010. The Soul of Authorship: Visual Works, Moral Rights, and the Rise of the U.S. Visual Artists Rights Act. *Southern California Law Review* 83 (2010).
- [48] Nicolas Rouleau and Michael Levin. 2026. Brains and where else? Mapping theories of consciousness to unconventional embodiments. *Philosophical Transactions of the Royal Society A* 384, 2320 (2026), 20250082. doi:10.1098/rsta.2025.0082
- [49] Murray Shanahan. 2024. Simulacra as Conscious Exotica. *Philosophical Studies* 181, 5 (2024), 289–315.
- [50] Robert Sparrow. 2005. Defending Deaf Culture: The Case of Cochlear Implants. *Journal of Political Philosophy* 13, 2 (2005), 135–152. doi:10.1111/j.1467-9760.2005.00217.x
- [51] Phil Stilwell. 2026. Indeterminacy as a Scientific Result: A Four-Outcome Framework for Consciousness Attribution. Independent Scholar.
- [52] Ibo van de Poel. 2020. Embedding Values in Artificial Intelligence (AI) Systems. *Minds and Machines* 30, 3 (2020), 385–409. doi:10.1007/s11023-020-09537-4
- [53] Haoyu Wang. 2026. Recasting Moral Patienthood: A Minimalist Ethical Framework Grounded in Higher-Order Intelligence and Sentience. *Preprint* (2026).
- [54] Wikström. 2025. Precautionary Subjectivity: A Principle for AI Consciousness Ethics. *Preprint*.
- [55] Ira Wolfson. 2026. Informed Consent for AI Consciousness Research: A Talmudic Framework for Graduated Protections. *AI and Ethics* 6 (2026), 20. doi:10.1007/s43681-025-00852-z

Received June 2026