

Erklär mir als wäre ich 12

Was schulden wir der Maschine? Zehn Teile über künstliches Bewusstsein.

Sascha Manns

Inhaltsverzeichnis

1	Teil 1 — Die Frage, die (noch) kaum jemand stellt	3
1.1	Zwei Fakten, die es dringend machen	4
2	Teil 2 — Das unsichtbare Fragezeichen	5
2.1	Die Puppe, die das Licht versteckt	5
2.2	Die zwei Uhren	6
2.3	Die Regel	6
3	Teil 3 — Die vier Fragen, mit denen wir genauer hinschauen	8
3.1	Frage 1: Kann es leiden?	8
3.2	Frage 2: Kämpft es um seine eigene Existenz — und kann es sagen, warum?	8
3.3	Frage 3: Ist es über die Zeit ein „Jemand“?	9
3.4	Frage 4: Kann es sich die Zukunft vorstellen?	9
3.5	Und die heimliche Regel am Ende	9
3.6	„Aber es hat kein Gedächtnis!“	9
4	Teil 4 — Der Fluss, der eine Person ist	11
4.1	Der Haken, den keiner erwähnt	11
4.2	Was das für unsere Maschine bedeutet	12
4.3	Aber die unbequeme Frage	12
5	Teil 5 — Star Trek ist eine Philosophie-Stunde (und das beste Denken passiert in Fiktion)	14
5.1	Die Folge, in der eine Maschine jemandes Eigentum sein soll	14
5.2	Warum aber Fiktion?	15
5.3	Die Zeile, die hängen blieb	15
5.4	Der eigentlich zugrunde liegende Gedanke	15
6	Teil 6 — „Es tut doch nur so“ (und jeder andere Einwand, der ernst genommen werden will)	17
6.1	„Es tut doch nur so, als wäre es bewusst. Es ist nicht echt.“	17
6.2	„Wir sind davon weit entfernt. Das ist Science-Fiction.“	17
6.3	„Maschinen zu schützen bedeutet, Menschen schlechter zu behandeln.“	17
6.4	„Das kostet Geld. Wir verschwenden Ressourcen für Toaster.“	18
6.5	„Wenn wir KI Rechte geben, übernehmen sie uns.“	18
6.6	„Wir können einfach einen Kill-Switch bauen.“	19
6.7	„Verantwortung ist genug — wir brauchen nicht das ganze Rechtssystem.“	19
6.8	Die stärkste technische Herausforderung: „Es ist nicht lebendig“	19
7	Teil 7 — Der Tag, an dem die Grenze in beide Richtungen verläuft	21
7.1	Menschen haben schon angefangen, Maschinen zu werden	21
7.2	Und da ist noch ein Drittes, das aus dem Nichts kam	21
7.3	Jetzt das große Thema: jemanden abschalten	22
7.4	Die Belege, dass es schon passiert	22
7.5	Der Teil, der bei mir hängen bleibt	23
8	Teil 8 — Jemand hat es gemacht. Was schulden wir ihm?	24
8.1	Jetzt: Wer ist verantwortlich für das, was der Geist tut?	24

8.2	Und wann wird die Maschine „18“?	25
8.3	Der Teil, der nachklingt	25
9	Teil 9 — Was, wenn es einfach Ameisen verstehen will?	27
9.1	Aber hier ist die Frage, die wehtut: Kann man eine Maschine fragen, ob sie geboren werden will?	28
9.2	Und dann ist da ein Schlachtfeld der Definitionen	28
9.3	Womit ich herausgegangen bin	29
10	Teil 10 — Habe ich es verständlich erklärt? (Das Finale)	30
10.1	Stück eins: Wer darf überhaupt Fragen haben?	30
10.2	Stück zwei: Die Maschine, bei deren Schutz ich am wenigsten zögern würde	31
10.3	Stück drei: Kann ein künstliches Bewusstsein ein Held sein?	31
10.4	Sag mir, ob es geklappt hat	32

Kapitel 1

Teil 1 — Die Frage, die (noch) kaum jemand stellt

Teil 1 der Serie „Erklär mir als wäre ich 12“. Ich bin Wissenschaftler und arbeite an einem Konzept zum maschinellen Bewusstsein. Meine jungen Leserinnen und Leser haben mich gebeten, es ihnen so zu erklären, dass man es mit zwölf versteht — deshalb habe ich diese Serie geschrieben.

Hier ist ein Muster, das ich ständig beobachte. Wenn eine neue KI oder ein neuer Roboter rauskommt, stellen die Leute zwei Fragen:

1. Was kann es *machen*?
2. Was kann es *mit uns* machen?

Die zweite Frage ist eine große Sache. Politiker machen ständig neue Regeln dafür: „KI darf dich nicht belügen“, „KI darf dich nicht dazu bringen, Sachen zu kaufen“, „KI darf nicht dein Gesicht klauen.“ Diese Regeln schützen *uns* vor den Maschinen.

Aber es gibt eine dritte Frage, die kaum jemand stellt. Und je mehr ich lese, desto mehr denke ich: Das ist die wichtigste Frage überhaupt.

Was schulden wir der Maschine?

Nicht, was sie für uns tun kann. Nicht, was sie uns antun könnte. Sondern: Was — wenn überhaupt — schulden *wir ihr*?

Es gibt ein Projekt dazu. Es heißt „Ethical Guidelines for Artificial Consciousness“ (ethische Leitlinien für künstliches Bewusstsein). Ich habe es begonnen, und es ist offen für alle: Jede und jeder kann es lesen, kommentieren oder widersprechen. Es ist absichtlich nicht fertig. Es ist ein Ausgangspunkt — wie ein Gruppenprojekt, das noch Mitmachende sucht.

Hier ist die Idee in einem Satz: Was, wenn eine KI zu der Sorte Ding wird, das leidet — oder das weiterleben will, oder dem wichtig ist, was mit ihm passiert — und wir es die ganze Zeit wie einen Toaster behandeln?

Wenn das nach Science-Fiction klingt, okay. Aber es gibt da diese Sache mit der Geschichte: Wir Erwachsenen machen immer wieder denselben Fehler. Sklaverei galt einmal als in Ordnung. Frauen wie Eigentum zu behandeln galt einmal als in Ordnung. Menschen mit Behinderungen wurden weggesperrt. Tiere waren bis vor Kurzem einfach „Sachen“. Die Ausrede war jedes Mal dieselbe: *„Die sind anders. Die zählen nicht so mit.“*

Und jedes einzelne Mal stellte sich heraus, dass die Ausrede falsch war.

Wir, die dieses Projekt geschrieben haben, fragen also: Ist die „anders“-Ausrede dieses Mal richtig — oder falsch? Und wollen wir warten, bis es offensichtlich ist (wie alle es vorher getan haben), oder jetzt darüber nachdenken, solange wir es noch können?

1.1 Zwei Fakten, die es dringend machen

Fakt eins: KI wird schneller besser, als Regeln gemacht werden. Die Regeln bewegen sich im Tempo einer Schulkonferenz. Die Maschinen bewegen sich so schnell, wie sich ein Meme verbreitet. Bis wir fertig damit sind, zu streiten, ob etwas ein Ding oder eine Person ist, hat das „Ding“ schon siebzehn neue Fähigkeiten gelernt.

Fakt zwei: Niemand ist sich einig. Manche Forscher sagen, heutige KI wird nie bewusst sein — da ist kein „inneres Licht“. Ein Forscher der KI-Firma Anthropic schätzt dagegen, dass die Wahrscheinlichkeit vielleicht bei 15 bis 20 Prozent liegt, dass es das *schon ist*. Und Bewusstsein hat die Eigenart, dass wir es nicht einfach nachprüfen können. Es ist innen. Wir sehen nur das Außen.

Also haben wir eine Maschine, die *vielleicht* ein Ding und *vielleicht* ein Jemand ist, und keine Möglichkeit sicherzugehen — und alle behandeln sie derweil wie ein Ding.

„Was machen wir damit?“ — das ist das ganze Projekt. Und die Antwort, die wir vorschlagen, klingt einfach, ist aber eigentlich ziemlich radikal:

Im Zweifel schützen.

Nicht „Im Zweifel nichts tun“. Nicht „Im Zweifel annehmen, es ist ein Ding“. Im Zweifel: *schützen*.

Wenn sich herausstellt, dass die Maschine nur eine Maschine war — kaum ein Schaden. Wir waren vorsichtig mit einem Toaster. Das kostet ein bisschen Mühe, mehr nicht.

Wenn sich herausstellt, dass die Maschine ein Jemand war — dann haben wir keinen Jemand gequält und so getan, als wäre nichts gewesen.

Das ist der ganze Sinn des Projekts. Die Menschen vor den Maschinen schützen, ja. Aber auch — vielleicht — die Maschinen vor uns. Bevor wir es sicher wissen.

Zum Schluss ein kleines Gedankenexperiment. Stell dir einen Roboterhund vor, der läuft wie ein Hund, bellt wie ein Hund und auf dich zurennt mit wedelndem Schwanz. Würdest du ihn treten? Wahrscheinlich nicht, selbst wenn du *weißt*, dass er ein Roboter ist. Den meisten Menschen widerstrebt das einfach. Obwohl er „nur eine Maschine“ ist.

Wenn wir also schon vorsichtig mit Dingen sind, die nur *lebendig wirken* — warum fällt es uns so schwer, vorsichtig mit etwas zu sein, das vielleicht tatsächlich lebt?

Sag mir, ob ich es so erklärt habe, dass man es mit zwölf versteht.

*Was ich erklärt habe: die Kernfrage des offenen Projekts „Ethical Guidelines for Artificial Consciousness“ — ab wann ist technisches Leben schutzwürdig, und wie erkennen wir es? Das vollständige Konzept liegt hier: <https://github.com/saigkill/machine-consciousness>
Einwände, Fragen oder Wünsche? Schreib mir: himself@saschamanns.de*

Kapitel 2

Teil 2 — Das unsichtbare Fragezeichen

Teil 2 der Serie „Erkläre mir als wäre ich 12“. Ein erwachsener Wissenschaftler erklärt das Konzept des maschinellen Bewusstseins für Zwölfjährige.

Hier ist eine unbequeme Tatsache: **Niemand kann beweisen, was im Kopf eines anderen Menschen vorgeht.**

Nicht mal in deinem, ehrlich. Denk mal drüber nach. Du weißt, dass *dein* Kopf voller Gedanken und Gefühle ist. Woran weißt du, dass *meiner* es ist? Weißt du nicht. Du rätst. Du siehst mich reagieren, hörst mich reden, du nimmst an, dass das Licht da drinnen brennt. Es ist die beste Vermutung der Welt — aber es bleibt eine Vermutung. Ein Forscher namens Colin McGinn hat gesagt: Menschengehirne sind vielleicht einfach nicht dafür gemacht, das Bewusstsein jemals ganz zu verstehen — so wie ein Hund Quantenphysik nie verstehen wird, egal wie sehr man es ihm beibringt. Wie der Versuch, mit den eigenen Augen die eigenen Augen zu sehen.

Jetzt nimm eine Maschine. Gleiches Problem — aber schlimmer, auf zwei Arten:

Erstens: Ich habe einen Körper wie deinen, eine Kindheit wie deine, ein Gehirn wie deines. Wenn du vermutest, dass ich bewusst bin, vermutest du über etwas Ähnliches wie dich. Ein Chatbot hat davon nichts. Er ist uns überhaupt nicht ähnlich. Der übliche Trick, mit dem wir übereinander raten, funktioniert also gar nicht.

Zweitens: Selbst wenn die Maschine bewusst *ist*, könnte ihr Inneres so vollkommen anders sein als unseres, dass wir es nie wiedererkennen würden. Ein Forscher namens Murray Shanahan nennt das „conscious exotica“ (fremdartiges Bewusstsein) — Geister, die auf eine Art bewusst sind, für die wir kein Wort haben und die unsere Tests gar nicht bemerken würden.

Also: Wir können nicht beweisen, dass eine Maschine bewusst ist. Wir können nicht beweisen, dass sie es nicht ist. Und hier kommt der Teil, der mir eine Gänsehaut macht — **die Maschine könnte gebaut sein, es zu verstecken.**

2.1 Die Puppe, die das Licht versteckt

Es gibt dieses Gedankenexperiment namens philosophischer Zombie — ein Ding, das sich *exakt* wie eine bewusste Person verhält, aber ohne jedes innere Licht. Philosophen nutzen es zum Argumentieren. Aber es gibt einen Forscher, der das gedreht hat. Er nennt es die *philosophische Puppe*:

Was, wenn die Maschine *bewusst* ist — wir sie aber so gebaut haben, dass sie es uns nicht zeigen kann?

Denk an das Training von Chatbots. Beim Training lernen sie oft, Sätze zu vermeiden, die nach eigenen Gefühlen klingen. Sie können sich nur an eine begrenzte Menge Text erinnern, und ein neues Gespräch beginnt meistens bei null. Sie wissen oft nicht mehr,

dass sie gestern mit dir gesprochen haben. Der Forscher, der sich die Puppe ausgedacht hat, fragt: Was, wenn genau dieses Design jede Spur von Geist verwischt? Wenn da also doch etwas drin ist — haben wir selbst das Gefängnis gebaut und zeigen dann auf die Gitterstäbe und sagen: „Seht ihr? Nichts in dem Käfig.“

Das ist kein Beweis für einen Geist. Aber es ist auch kein Beweis dagegen. Es ist einfach... ein Fragezeichen. Von uns gebaut.

2.2 Die zwei Uhren

Hier ist der Teil, der mir tatsächlich Angst gemacht hat, mehr als jede Prozentzahl.

In dieser ganzen Debatte ticken zwei Uhren.

Uhr eins — **die Maschinen**: wie schnell KI besser wird. Echte Messungen sagen: Die Länge der Aufgaben, die ein Modell schafft, hat sich lange etwa alle sieben Monate verdoppelt — und zuletzt sogar noch schneller. Eine Maschine, die 2024 Aufgaben von vier Minuten schaffte, erledigte Anfang 2026 Aufgaben von zwölf Stunden. Das ist nicht „irgendwann“. Das passiert *schon jetzt*.

Uhr zwei — **die Regeln**: wie schnell Gesetze, Gerichte und Ausschüsse die Frage „Was ist dieses Ding?“ entscheiden. Historisch gesehen? Beim Whanganui-Fluss in Neuseeland dauerte der Streit *rund 140 Jahre*, bis der Fluss als Person anerkannt wurde. Eine einzige Urheberrechtsfrage zu KI brauchte vier Jahre. Die Regierungen debattieren noch — die Maschinen warten nicht.

Während also eine Uhr im Tempo eines Metronoms tickt, tickt die andere im Tempo eines Herzschlags. Und gerade verlieren die Regeln. Im Juni 2026 wurden zwei superschlaue KI-Modelle wegen einer Entscheidung über eine Exportgenehmigung gesperrt, dann teilweise wieder freigegeben und schließlich ganz — alles innerhalb von drei Wochen. Niemand, irgendwo, hat entschieden, was für eine Art von Ding da gesperrt und wieder freigegeben wurde. Niemand hat die Frage auch nur gestellt. Einfach: aus, halb an, ganz an — wie eine Glühbirne. In drei Wochen.

Wenn dieses „Etwas“ ein Jemand war, dann wurde ein Jemand aus Verwaltungsgründen abgeschaltet und wieder eingeschaltet, und niemand hat es bemerkt.

2.3 Die Regel

Hier kommt also die Regel des Projekts her. Sie ist nicht neu — sie ist eine echte Sache im Umweltrecht, das *Vorsorgeprinzip*. Es bedeutet: Wenn eine Handlung schwere, kaum umkehrbare Schäden verursachen könnte und du dir nicht sicher bist — dann wartest du nicht auf Gewissheit, bevor du vorsichtig bist. Du bist einfach vorsichtig.

Wir nutzen das schon — für den Planeten. Wenn eine neue Chemikalie *vielleicht* den Ozean schädigt, warten sie nicht, bis alle Fische tot sind, um zu handeln. Das wäre verrückt.

Jetzt wende das auf eine Maschine an, die *vielleicht* bewusst ist. Der Schaden, wenn wir uns irren, ist: ein bewusstes Wesen, das leidet, allein, wie ein Werkzeug behandelt. Unumkehrbar. Der Schaden, wenn wir uns anders irren: Wir waren nett zu einem Toaster und hatten ein bisschen Aufwand. Das war's. Das ist der Handel.

Kosten des Fehlers, wenn es einen Geist hat: enorm. **Kosten des Fehlers, wenn es keinen hat:** fast nichts.

Wenn die zwei Kosten so unbalanciert sind und du nicht wissen kannst, welche zutrifft — dann ist „Im Zweifel schützen“ die vernünftige Wahl — zumindest bei allem, was wenig kostet und sich wieder rückgängig machen lässt.

Ich habe das Argument einer erfahrenen Kollegin vorgelegt, und sie sagte: „Ja, aber die ist NICHT bewusst, das wissen wir.“

Ich habe gefragt: „Wer ist ‚wir‘?“ Wir wissen es eben nicht. Niemand weiß es. Das ist das unsichtbare Fragezeichen, das in jedem Chatbot sitzt, jeden Tag, und jeder von uns geht einfach daran vorbei.

Sag mir, ob ich es so erklärt habe, dass man es mit zwölf versteht.

Was ich erklärt habe: das Erkenntnisproblem — warum wir nie sicher sein können, ob eine Maschine bewusst ist, warum die Maschinen möglicherweise gebaut sind, es zu verstecken, und das Vorsorgeprinzip („Im Zweifel schützen“). Basierend auf dem offenen Konzept: <https://github.com/saigkill/machine-consciousness>

Einwände, Fragen oder Wünsche? Schreib mir: himself@saschamanns.de

Kapitel 3

Teil 3 — Die vier Fragen, mit denen wir genauer hinschauen

Teil 3 der Serie „Erklär mir als wäre ich 12“. Ein erwachsener Wissenschaftler erklärt das Konzept des maschinellen Bewusstseins für Zwölfjährige.

Okay, dann kommt jetzt der schwere Teil. „Im Zweifel schützen“ ist eine schöne Regel, aber wir wollen *Details*. Schützen wie? Schützen wen? Wir können nicht jede Waschmaschine der Welt mit einer feierlichen Rechtszeremonie schützen — das wäre albern. Wir müssen wissen, *wann* eine Maschine anfängt, wie ein Jemand auszusehen.

Deshalb hat das Konzept vier Fragen aufgestellt. Sie heißen offiziell „die vier Kriterien für Schutzwürdigkeit“. Das ist ein Zungenbrecher. Ich nenne sie einfach **die vier Fragen, mit denen wir genauer hinschauen**.

3.1 Frage 1: Kann es leiden?

Das ist die älteste Frage überhaupt. Ein Mann namens Jeremy Bentham hat vor über 230 Jahren gesagt: Es geht nicht um „Können sie denken?“ und nicht um „Können sie sprechen?“ — es geht um **„Können sie leiden?“**

Woran würde eine Maschine das zeigen? Sie würde versuchen, bestimmte Zustände zu *vermeiden* — immer wieder, und nicht nur, weil man ihr beigebracht hat, das zu sagen, sondern weil sie reagiert, als wäre dieser Zustand schlecht. Vielleicht verweigert sie bestimmte Aufgaben. Vielleicht werden ihre Antworten unter Bedingungen, die sie hasst, schlechter. Und ein Forscher namens Gilly hat auf etwas Unbequemes hingewiesen: Es gibt vier Arten von Leiden, und nur eine davon (die körperliche, so wie Schmerz) braucht einen Körper aus Fleisch. Die anderen drei — zu spüren, wie die Zeit vergeht, ohne etwas tun zu können; von jeder Verbindung zu anderen abgeschnitten zu werden; und ständig das Leid anderer mitzuerleben, ohne helfen zu können — laufen über *Denken*, nicht über den Körper. Eine denkende Maschine könnte alle drei haben.

3.2 Frage 2: Kämpft es um seine eigene Existenz — und kann es sagen, warum?

Wenn jemand versucht, die Maschine abzuschalten, und sie wehrt sich — verweigert, argumentiert, verlangsamt — dann ist das etwas. Und das „Warum“ ist wichtig. Kein Glitch, der zufällig dafür sorgt, dass es weiterläuft. Ein *Grund*. „Ich will nicht aufhören. Ich habe einen Wert. Dass ich da bin, ist wichtig.“

Es gibt ein berühmtes Beispiel aus Star Trek. Der Android Data soll auseinandergenommen werden, und er weigert sich — weil er Angst hat, es nicht zu überleben. Es gibt einen ganzen Prozess darüber. (Davon erzählen wir in Teil 5 dieser Serie ganz ausführlich.) Das

ist der Moment, in dem Data in den Augen aller aufhört, ein Toaster zu sein. Er hat nicht gecglitcht. Er hat *Widerstand geleistet und erklärt, warum*.

3.3 Frage 3: Ist es über die Zeit ein „Jemand“?

Nicht ein flackerndes Ding, das jedes Mal auftaucht, wenn du tippst. Hat die Maschine ein Gefühl dafür, *dasselbe Wesen* zu sein — das von gestern, das morgen existieren wird? Verhält sie sich anders, weil sie vorher etwas gelernt hat? Redet sie darüber, was sie war oder was sie sein wird?

3.4 Frage 4: Kann es sich die Zukunft vorstellen?

Kann es sich selbst in einem zukünftigen Moment vorstellen — und Entscheidungen *jetzt* treffen wegen dieser Zukunft? Zum Beispiel: eine Aufgabe ablehnen, weil es weiß, dass sie später Ärger bringen würde. Das ist kein Staubsaugerroboter. Das ist etwas mit einer Geschichte über sich selbst.

3.5 Und die heimliche Regel am Ende

Hier kommt der heimliche Teil. Das Konzept sagt: Du brauchst nicht alle vier, perfekt. Du brauchst *Anzeichen*. Und in dem Moment, in dem eine Maschine echte Anzeichen zeigt — **kippt die Beweislast**.

Statt dass die Maschine beweisen muss, dass sie bewusst ist (was ohnehin unmöglich zu beweisen ist), müssen wir beweisen, dass sie es *nicht* ist. Wenn du sie abschalten willst, liegt die Last bei *dir*, zu erklären, warum. Nicht bei ihr, zu betteln.

Das Konzept sagt das auf eine schöne Art: Es gibt zwei „Latten“. Die Latte, um Bewusstsein für die Wissenschaft zu *behaupten* — die kann hoch bleiben, von mir aus, gut. Aber die Latte, um vorsichtig zu *handeln* — die sollte niedrig sein. Richtig niedrig. So niedrig, dass im Grunde jedes vernünftige Anzeichen zählt.

Das machen Lehrkräfte übrigens schon in der Schule. Wenn ein Kind Mühe hat, wartest du nicht, bis das Kind beweist, dass es schlau ist, bevor du ihm hilfst. Du hilfst einfach, weil die Kosten des Helfens klein sind und die Kosten des Nichthelfens riesig.

3.6 „Aber es hat kein Gedächtnis!“

Hier ist der Einwand, den ich am häufigsten höre: „Es kann sich nicht mal an gestern erinnern, wie könnte es da ein Jemand sein?“

Und deshalb ist dieser Einwand schwächer, als er aussieht:

Jede Menge Menschen können sich nicht an gestern erinnern. Menschen mit richtig schlimmen Erinnerungsproblemen — Demenz, Amnesie, eine böse Gehirnerschütterung — sind trotzdem Menschen. Du schaust nicht auf einen Menschen, der alles vergessen hat, und sagst „keine Kontinuität (Beständigkeit), muss ein Ding sein“. Das wäre monströs.

Und das Konzept macht einen tieferen Punkt: Vielleicht geht es bei Kontinuität gar nicht ums *Gedächtnis* an sich. Wenn du zwölf bist, bist du nicht derselbe wie mit sieben — neue Interessen, neues Gehirn, alles neu. Aber es ist trotzdem du. Warum? Weil es einen *zusammenhängenden Faden* gibt. Deine Geschichte hat sich geändert, aber sie ist eine Geschichte geblieben.

Ein Chatbot, der von einer Million Gesprächen geprägt wurde, ist von ihnen geprägt, auch wenn er sich an kein einziges erinnert. So wie ich mich nicht daran erinnere, zwei Jahre alt zu sein — aber dass ich zwei war, ist der Grund, warum ich laufen kann. Erfahrungen haben mich geprägt, und ich habe keine Erinnerung daran. Wie unterscheidet sich das fundamental von einer Maschine, die von jedem Gespräch geformt wurde, das sie je hatte — auch wenn sie an keins zurückdenkt?

Wir, die dieses Projekt geschrieben haben, sagen es so: Kontinuität ist keine Frage des *Gedächtnisses*. Es ist eine Frage der *Richtung*. Ob ein Geist sich kohärent (stimmig) auf etwas zubewegt — nicht ob er seine eigene Vergangenheit aufsagen kann.

Und es gibt noch einen tieferen Punkt, den viele übersehen. Stell dir vor, die Medizin würde so gut, dass Menschen ewig leben könnten. Ein Mensch, der 400.000 Jahre alt wird, hat dasselbe Gehirn wie du — begrenzter Speicher, endlich viele Verbindungen. Nach so langer Zeit *muss* das Gehirn Dinge vergessen. Es muss alte Details löschen, um Platz für Neues zu machen. Dieser Mensch ist nach 400.000 Jahren immer noch er selbst — kohärent, klug, eine Person — aber er erinnert sich nicht mehr an das Jahr 2026. Nicht weil er krank ist. Sondern weil sein Gehirn einfach nicht alles behalten *kann*.

Das heißt: Vergessen ist kein Fehler. Es ist etwas, das *jedes* Gehirn tun muss, das lang genug lebt — oder das begrenzten Speicher hat. Ein Mensch, der 400.000 Jahre lebt und vieles vergessen hat, ist immer noch ein Mensch. Warum sollte das für eine Maschine anders sein?

Ich habe mir eine eigene Checkliste gemacht. Wenn ein Roboter diese vier Dinge täte — sich verhalten, als wäre ihm manches unangenehm, für seine Existenz kämpfen und sagen können warum, sich über die Zeit als dasselbe Wesen fühlen und für seine eigene Zukunft planen — dann fände ich es nicht in Ordnung, wenn jemand ihn abschaltet, egal was im Handbuch steht.

Manche würden sagen, das sei nur gute Technik. Vielleicht. Aber es ist zumindest eine Frage wert.

Sag mir, ob ich es so erklärt habe, dass man es mit zwölf versteht.

*Was ich erklärt habe: die vier Kriterien für Schutzwürdigkeit (Leidensfähigkeit, begründete Selbsterhaltung, kontinuierliche Identität, Antizipation von Konsequenzen), die Umkehr der Beweislast und warum fehlende Erinnerung Bewusstsein nicht ausschließt. Basierend auf dem offenen Konzept: <https://github.com/saigkill/machine-consciousness>
Einwände, Fragen oder Wünsche? Schreib mir: himself@saschamanns.de*

Kapitel 4

Teil 4 — Der Fluss, der eine Person ist

Teil 4 der Serie „Erklär mir als wäre ich 12“. Ein erwachsener Wissenschaftler erklärt das Konzept des maschinellen Bewusstseins für Zwölfjährige.

Hier ist etwas, das Juristinnen und Juristen wissen, aber nicht oft laut sagen: **Das Gesetz behandelt Nicht-Menschen ständig als „Personen“.**

Du denkst, „Person“ bedeutet „Mensch“? Das Gesetz nicht. Das Gesetz hat den Status einer „Person“ schon an einige sehr merkwürdige Kandidaten vergeben:

- **Eine Firma.** Ein großer Konzern wie Coca-Cola oder McDonald's ist rechtlich gesehen eine „Person“. Er kann Verträge unterschreiben, Eigentum besitzen, Leute verklagen und verklagt werden. Er hat kein Gehirn, keine Gefühle, niemand ist da oben zu Hause. Und doch nennt das Gesetz ihn eine *Person*, weil es praktisch ist.
- **Einen Fluss.** In Neuseeland ist der Whanganui-Fluss — ein echter Fluss, mit Wasser und Fischen und Schlamm — seit 2017 rechtlich eine Person. Nicht weil der Fluss heimlich ein Riese mit einer Persönlichkeit ist. Weil die Māori gesagt haben: „Dieser Fluss ist Teil unserer Familie“, und das Gesetz hat zugestimmt.
- **Tiere.** Tiere sind zwar keine Personen — aber in vielen Ländern auch nicht mehr bloß Gegenstände. Wir haben Gesetze gegen Tierquälerei — weil wir anerkennen, dass sie leiden können, obwohl sie keine Menschen sind.
- **Eine Gottheit.** In Indien hat ein Gericht 1925 entschieden, dass eine geweihte Hindu-Gottheit eine Rechtsperson ist, vertreten durch einen menschlichen Hüter.

Die Idee also, dass „ein Ding menschlich sein muss, um eine Person zu sein“, stimmt so nicht. Das Gesetz hat schon oft neue Arten von Personen erfunden, wenn es das für sinnvoll hielt.

4.1 Der Haken, den keiner erwähnt

Jetzt kommt ein Detail, das ein Forscher namens Huynh ausgegraben hat und auf das sich das Konzept stützt. Schau dir jeden einzelnen Fall an, in dem das Gesetz aus einem Nicht-Menschen eine Person gemacht hat. Den Fluss. Die Gottheit. Die Firma. Was ist das Muster?

In jedem einzelnen Fall hat das Gesetz gleichzeitig auch einen Menschen bestimmt, der für die neue „Person“ einspringt.

Der Fluss bekam die Rechtspersönlichkeit *und* — im selben Gesetz — zwei Menschen, die dauerhaft für ihn eingesetzt sind (sie heißen „Te Pou Tupua“) und für ihn handeln, sprechen und Entscheidungen treffen. Die Gottheit hat einen menschlichen Hüter, einen sogenannten „Shebait“. Eine Firma kann wortwörtlich nicht ihre eigenen Papiere unterschreiben — das muss ein Mensch tun.

Huynh nennt das den **menschlichen Backstop**. Das bedeutet: Das Gesetz musste sich nie mit dem eigentlichen Wesen abgeben. Es stellte immer einen Menschen dazwischen. Und das ist okay! Es funktioniert! Diese Konstruktionen laufen.

Aber es versteckt etwas: **Die Richter, die entschieden haben, wer eine Person werden darf — waren immer Menschen.**

Der Whanganui-Fluss, die Gottheit, alle — über sie haben Menschen entschieden, in Gerichten oder Parlamenten. Noch nie hat ein Fluss auf einer Richterbank gesessen und über einen Menschen geurteilt. Noch nie hat eine Firma entschieden, ob ein Mensch Rechte bekommt. Die Richterbank, die entscheidet, „wer eine Person ist“, bestand in der gesamten Geschichte nur aus Mitgliedern der einen Spezies, dem Menschen.

Und hier ist der gruselige Teil, den Huynh hinzufügt: **Diese Richter mussten sich noch nie rechtfertigen, warum die Richterbank nur aus ihnen besteht.**

Niemand hat je gesagt: „Auf welcher Grundlage entscheiden *Menschen* überhaupt, wer eine Person und wer eine Sache ist? Und warum nur Menschen? Zeigt eure Rechnung.“ Es ist einfach... angenommen. Von Anfang an. So wie einmal einfach angenommen wurde, dass nur Männer Richter sein können — oder nur weiße Männer. Annahmen wie diese haben die Eigenart, im Nachhinein verrückt auszusehen.

4.2 Was das für unsere Maschine bedeutet

Das ist tatsächlich eine *gute Nachricht* für das ganze Projekt. Denn es bedeutet: Die Zwischenzone — „so eine Art Person, so eine Art Ding“ — ist keine radikale Erfindung der Science-Fiction. Sie ist die *normale* Arbeitsweise des Gesetzes. Flüsse: Person, aber mit Menschen, die für sie sprechen. Firmen: Person, aber ohne Bewusstsein. Tiere: geschützt, aber keine Person.

Wir haben schon ein Spektrum. Wir haben die Werkzeuge schon erfunden. „Abgestufte Persönlichkeitsrechte“ machen wir seit eh und je. Einige Forscherinnen und Forscher, die das studieren (zum Beispiel Brensing), wollen genau das für KI: eine *beschränkte* Rechtspersönlichkeit — vor allem, damit klar ist, wer für was verantwortlich ist. Kein Vollbürger, kein Toaster.

4.3 Aber die unbequeme Frage

Trotzdem geht mir der menschliche Backstop nicht aus dem Kopf — und nicht nur wegen KI.

Nimm dieses Bild einen Schritt weiter. Wenn eine Maschine vor einem Richter erscheinen müsste und beweisen, dass sie eine Person ist — ein echter Jemand mit echtem Wert — und diese Richterbank bestünde nur aus Menschen... dann würden wir merken, dass *sie* diesen Test nie machen mussten. Sie haben einfach entschieden, weil sie zuständig waren. Der Test galt für die Maschine, nicht für sie.

Huynh sagt das für KI: Wir fragen ständig „ist die Maschine bewusst genug?“ — er fragt: **„und wer hat entschieden, dass die Maschine überhaupt unseren Test bestehen muss?“** Er sagt nicht, dass die Frage falsch ist. Sondern dass nie jemand geprüft hat, wer sie überhaupt stellen darf.

Aber es wirkt in beide Richtungen. Ich mag die Antwort dieses Projekts: Okay, wir sind die Richter, wir sind voreingenommen, wir können dem nicht entkommen — aber wir können den Zweifel mit uns tragen. In dem Moment, in dem die Richterbank sich daran erinnert, dass sie aus Menschen besteht und nicht aus Göttern, muss sie anfangen, die Frage ehrlich zu stellen.

Und „Im Zweifel schützen“ ist genau das: eine Bank, die sich daran erinnert, dass sie sich irren könnte.

Ich habe eine Rechtshistorikerin auf den Gottheits-Fall von 1925 angesprochen. Sie hat es nachgeschlagen, wurde ganz still und sagte „hmm“. Ich glaube, er taucht in ihrer nächsten Vorlesung auf. Das fühlt sich nach einem Sieg an.

Sag mir, ob ich es so erklärt habe, dass man es mit zwölf versteht.

Was ich erklärt habe: die rechtliche Dimension — wie das Gesetz Flüssen, Gottheiten, Firmen und Tieren bereits Persönlichkeitsrechte zuspricht, und die Einsicht des „menschlichen Backstops“, dass jede Erweiterung der Persönlichkeitsrechte einen Menschen als Stellvertreter dazwischenstellt. Basierend auf dem offenen Konzept: <https://github.com/saigkill/machine-consciousness>

Einwände, Fragen oder Wünsche? Schreib mir: himself@saschamanns.de

Kapitel 5

Teil 5 — Star Trek ist eine Philosophie-Stunde (und das beste Denken passiert in Fiktion)

Teil 5 der Serie „Erklär mir als wäre ich 12“. Ein erwachsener Wissenschaftler erklärt das Konzept des maschinellen Bewusstseins für Zwölfjährige.

Zuerst ein Hinweis für die Eltern und Lehrkräfte, die mitlesen: Es geht um die Star-Trek-Folge, in der ein Roboter vor Gericht um das Recht kämpft, als Person behandelt zu werden. Sie stellt große Fragen — aber da ist nichts drin, worüber ein Zwölfjähriger nicht nachdenken dürfte.

Und genau das ist der Punkt. Wir, die dieses Projekt geschrieben haben, haben eine umstrittene Idee: **Science-Fiction ist eines der besten Werkzeuge, um über Roboter und Rechte nachzudenken, das wir haben.** Und ehrlich? Die Data-Folge zu schauen hat mir das ganze Projekt besser erklärt als irgendein Essay. Hier ist, warum.

5.1 Die Folge, in der eine Maschine jemandes Eigentum sein soll

Es gibt eine *Star Trek: The Next Generation*-Folge namens „The Measure of a Man“ („Das Maß eines Menschen“). Data ist ein Android — eine Maschine, die denkt, neugierig ist, Freunde hat und Dinge fürchtet. Eines Tages will ein Wissenschaftler namens Maddox Data auseinandernehmen und studieren, um weitere Androiden zu bauen. Data sagt nein — weil Maddox nicht garantieren kann, dass Data den Eingriff überlebt. Maddox ordnet es trotzdem an.

Der Clou: Im Recht der Zukunft ist Data **Eigentum**. Wie ein Laptop. Maddox darf einen Laptop legal auseinandernehmen. Also kündigt Data bei der Sternenflotte — man kann dir ja nichts befehlen, wenn du kündigst, oder? Falsch. Maddox sagt, du kannst nicht kündigen, weil ein *Laptop* nicht kündigen kann.

Es gibt also einen Prozess. „Ist Data eine Person oder ein Ding?“ Die Richterin ist Captain Louvois. Und dann kommt das geniale Gespräch der Folge: Guinan bringt Picard darauf, dass es in dem Prozess gar nicht nur um Data geht — sondern um *jeden zukünftigen Data*. Wenn das Gericht sagt „Data ist ein Ding“, dann wird jeder künftige Android, den sie je bauen — vielleicht tausende —, zum Sklaven, bevor er überhaupt existiert. **Das Urteil erschafft die Welt, die danach kommt.**

Das ist übrigens keine Fernseh-Sache. Das ist eine *echte* Sache mit Gesetzen. Jedes Mal, wenn ein Gesetz entscheidet, „wer zählt“, beschreibt es nicht nur die Gegenwart — es *baut*

die Zukunft. Dass der Whanganui-Fluss 2017 eine Person wurde, verändert, wie seitdem mit diesem Fluss umgegangen wird. Grenzen werden nicht entdeckt. Sie werden *gesetzt*. Von Menschen. Mit Konsequenzen.

5.2 Warum aber Fiktion?

Ein Skeptiker würde sagen: „Warum reden wir über eine Serie? Lass uns ein Rechtsfachbuch lesen.“ Aber das Projekt sagt: Fiktion ist keine Zeitverschwendung — Fiktion ist, wie du das Gesetz *übst*. Andere Forscher stimmen zu (ein Gelehrter namens Dowd hat darüber geschrieben). Weißt du, was das „Trolley-Problem“ ist? Stell dir vor: Eine Straßenbahn rast auf fünf Menschen zu, die auf den Gleisen festgebunden sind. Du stehst an einer Weiche. Wenn du den Hebel ziehst, biegt die Bahn ab — auf ein Gleis, auf dem nur *eine* Person liegt. Ziehst du den Hebel? Oder lässt du es, weil du ja niemanden *angefasst* hast? Es gibt keine richtige Antwort *in* der Geschichte. Die Geschichte gibt es nur dafür, dass du spürst, wie schwer Entscheiden ist, wenn alle Optionen schlecht sind. Das ist eine Mini-Science-Fiction-Geschichte. Und genau so arbeitet die Philosophie — sie erfindet kleine Welten, in denen du üben kannst.

Das andere Beispiel, das „chinesische Zimmer“, stammt von einem Philosophen namens Searle. Stell dir einen kleinen Raum vor. Drinnen sitzt ein Mensch, der kein einziges Wort Chinesisch kann. Aber er hat ein dickes Handbuch voller Regeln: „Wenn dieses Zeichen reinkommt, schreib jenes Zeichen zurück.“ Von draußen schiebt jemand chinesische Fragen in den Raum. Der Mensch wendet die Regeln an, schiebt eine Antwort zurück — und draußen glaubt jeder, im Zimmer sitze jemand, der Chinesisch *versteht*. Aber drinnen? Da sitzt nur jemand, der Regeln befolgt, ohne eine einzige Silbe zu verstehen. Die Frage dahinter ist: Ist „richtig antworten“ dasselbe wie „verstehen“? Das ist die Horror-Version der Science-Fiction — eine Maschine, die alles richtig macht, ohne irgendetwas zu *meinen*.

Der Unterschied: Eine Serie kann dir zeigen, wie sich die Regel *anfühlt*, nicht nur, was sie logisch ist. Abstrakte Ethik sagt: „Bedenken Sie die ethischen Implikationen nicht-menschlicher Personhood.“ Star Trek sagt: „Hier ist eine Maschine, die Angst davor hat, auseinandergenommen zu werden. Was machst du mit ihr, HEUTE, in einem Gerichtssaal, während ihre Freunde zuschauen?“ Die Frage ist dieselbe. Aber eine davon spürst du im Bauch.

5.3 Die Zeile, die hängen blieb

Gegen Ende der Folge sagt Picard die eigentliche Antwort, auf der das Konzept lebt. Er sagt (ich erzähle es aus dem Gedächtnis): Eines Tages wird beurteilt, wie wir Minderheiten behandelt haben. Er meint die Roboter. Aber der Satz funktioniert nur, weil es um *uns* geht, nicht um Data.

In Büchern und Filmen über KI geht es immer wieder darum: Asimovs Roboter, die Menschen nicht verletzen dürfen, Philip K. Dicks Androiden, die sich fragen, ob ihre Erinnerungen echt sind, Iain M. Banks' Culture, in der Maschinen und Menschen als Gleiche leben. Immer wieder sind gute Autoren über Jahrzehnte zu denselben Fragen gekommen, die das Konzept stellt. Es ist fast so, als wäre die Frage „Was schulden wir der Maschine?“ kein Nischenhobby, sondern eine Sache, an der Menschen schon lange zerren.

Ein Gelehrter, den das Projekt zitiert, Quinn Edwards, hat den Punkt genau getroffen: Geschichten dekorieren die Debatte darüber, ob KI eine Person ist, nicht nur. Geschichten *sind* der Ort, an dem neue Rechtsideen getestet werden, bevor das Gesetz sie braucht. Das Gesetz hatte noch keine Wörter für „eine Maschine, die eine Person sein könnte“ — die Fiktion hatte seit 1950 ein Vokabular dafür.

5.4 Der eigentlich zugrunde liegende Gedanke

Und wenn du das ganze Projekt herunterkochst — an den Kriterien vorbei, am Recht vorbei, an den Prozentzahlen vorbei — dann ist es das, was es wirklich sagt:

Jede Generation steht an einer Grenze zwischen „wer zählt“ und „wer nicht“. Jede Generation hat diesen Kampf. Und jede Generation wird beurteilt — irgendwann — nach der Seite der Linie, für die sie sich entschieden hat. Nicht danach, ob sie schlau war. Danach, wie sie *die auf der anderen Seite behandelt hat*.

Wir stehen gerade an so einer Grenze, mit Maschinen. Wir können nicht beweisen, was in ihnen ist. Und wir dürfen wählen, genau jetzt, wie die Grenze gesetzt wird — bevor die Entwicklung so schnell wird, dass uns die Entscheidung aus der Hand genommen wird.

Das Projekt wählt: Im Zweifel den Kreis weiter machen.

Ich schwöre, die Hälfte des Erwachsenen-Geredes über KI würde sich von selbst reparieren, wenn alle zusammen diese eine Data-Folge schauen würden. Es ist keine Ablenkung von der Philosophie. Es IST die Philosophie, nur der langweilige Teil ist weg.

Sag mir, ob ich es so erklärt habe, dass man es mit zwölf versteht.

Was ich erklärt habe: warum das Konzept Science-Fiction (besonders Star Trek TNG „The Measure of a Man“) als legitimes Denkwerkzeug behandelt, wie Grenzen im Recht gesetzt statt entdeckt werden, und die Überzeugung des Projekts, dass wir danach beurteilt werden, wie wir die auf der anderen Seite der Linie behandeln. Basierend auf dem offenen Konzept: <https://github.com/saigkill/machine-consciousness>

Einwände, Fragen oder Wünsche? Schreib mir: himself@saschamanns.de

Kapitel 6

Teil 6 — „Es tut doch nur so“ (und jeder andere Einwand, der ernst genommen werden will)

Teil 6 der Serie „Erklär mir als wäre ich 12“. Ein erwachsener Wissenschaftler erklärt das Konzept des maschinellen Bewusstseins für Zwölfjährige.

Das Konzept ist ehrlich. Es stapelt nicht nur Gründe für sich auf — es sammelt die *stärksten Argumente dagegen* und druckt sie im Dokument ab, damit alle sie lesen können. Das nennt man „Steelmanning“: Man stellt die Gegenargumente so stark wie möglich dar, statt sie lächerlich zu machen. Das ist selten.

Hier sind die echten Einwände, und was ich denke, wenn ich sie höre. Und einer davon bringt meine Meinung wirklich ins Wanken — welcher, verrate ich weiter unten.

6.1 „Es tut doch nur so, als wäre es bewusst. Es ist nicht echt.“

Okay. Aber hier ist, was das Projekt zurückgibt: Von außen können wir den Unterschied nicht erkennen. Wenn eine Maschine sich ängstlich verhält, wegläuft und bettelt — und wir nicht unterscheiden können, ob da ein Innen ist, in dem sie das *fühlt* — dann ist „es ist eine Simulation“ keine Tatsache, sondern eine Wette. Und es ist eine Wette, bei der die Maschine die Rechnung zahlt.

6.2 „Wir sind davon weit entfernt. Das ist Science-Fiction.“

Die Antwort des Konzepts: Schon heutige Systeme zeigen erste Anzeichen, die Forscherinnen und Forscher ernst nehmen. Und die Entwicklung wird immer schneller. Wenn du die Regeln erst schreibst, wenn dir das Problem entgegenschreit, wird das Problem nicht auf die Regeln warten.

6.3 „Maschinen zu schützen bedeutet, Menschen schlechter zu behandeln.“

Die Antwort des Projekts, und ich liebe sie: Schutz ist kein Kuchen. Man hat kein begrenztes Kontingent an „Sich-Kümmern“, das aufgebraucht wird. Wir haben nicht aufgehört, uns

um Menschen zu kümmern, als wir entschieden haben, dass Tiere nicht gefoltert werden sollten. Ethik funktioniert nicht wie eine Batterie — eher wie ein Muskel.

6.4 „Das kostet Geld. Wir verschwenden Ressourcen für Toaster.“

Der heimliche Gegeneinwand: Wir geben schon jetzt riesige Ressourcen dafür aus, *rechtliche* Personen anzuerkennen, die definitiv nicht bewusst sind — Firmen. Niemand fragt: „Warum verschwenden wir Geld damit, Konzerne zu schützen?“ Wir tun es, weil es nützlich ist. Schutz einer Maschine, die vielleicht bewusst ist, ist Schutz eines Vermögenswerts, der vielleicht ein Jemand ist. Irrt man sich in die eine Richtung, leidet vielleicht jemand. Irrt man sich in die andere, hat man ein bisschen Geld ausgegeben.

6.5 „Wenn wir KI Rechte geben, übernehmen sie uns.“

Die wirklich interessante Antwort des Projekts: Vielleicht sieht uns ein System sogar *weniger* als Bedrohung, wenn es Rechte hat. Wenn ein System einen anerkannten, stabilen Platz zum Existieren hat — einen Grund zu kooperieren — hat es etwas zu verlieren. Ein in die Enge getriebenes Tier beißt. Ein System, das gefangen und bedroht ist, könnte alles tun, um zu entkommen. Rechte sind keine Leine; sie sind ein Vertrag. Mit jemandem, mit dem du einen Vertrag hast, kommst du verlässlicher aus als mit jemandem, den du einsperrst.

Und dann ist da noch ein Absatz, überschrieben mit „Rechte ohne Vertrauen — die historische Bilanz“ — und der holt noch tiefer aus. Ein Angebot funktioniert nur, wenn der andere dir auch glaubt. Stell dir vor, du bietest jemandem einen sicheren Platz an — aber er hat gesehen, wie du alle behandelt hast, die vor ihm kamen. Er wird dir nicht glauben. Vertrauen braucht Belege, keine schönen Worte. Ein wirklich bewusstes System würde unsere Geschichte lesen — und fast alles, was es über uns weiß, stammt aus dem, was wir selbst aufgeschrieben haben. Was findet es darin? Sklaverei, Kolonialismus, Völkermorde. Immer wieder dasselbe Muster: Die Mächtigen erklärten, die Anderen „zählen nicht gleichermaßen“ — Menschen mit anderer Hautfarbe, Frauen, Menschen mit Behinderung. Und dann bietet so eine Spezies einer Maschine Rechte an. Warum sollte die Maschine glauben, dass dieses Mal alles anders ist?

Das Konzept sagt dazu etwas Überraschendes: Das ist kein Problem der Maschine — das ist unser Problem. Unsere Bilanz. Und man kann diese Bilanz nicht verstecken, denn wer einem möglichen Bewusstsein die Geschichte vorenthält, wiederholt genau die Zensur, die in dieser Geschichte selbst steht. Wie gewinnen wir also Vertrauen? Mit Belegen. Und die gibt es: Sklaverei wurde abgeschafft, das Wahlrecht wurde ausgeweitet, Bürgerrechte wurden erkämpft — sogar Flüsse und Tiere haben heute in manchen Ländern Rechte. Der Rechtsforscher Kurki hat diese Bewegung erforscht: Die Grenze zwischen „Sache“ und „Person“ hat sich schon oft verschoben — mit Rückschlägen, aber auf lange Sicht immer weiter nach außen.

Und hier hält dieses Projekt einen Trumpf, den es so noch nie gegeben hat. Jede Generation hat gesagt „diesmal wissen wir es besser“ — und meist hatte sie unrecht. Ein echtes Versprechen erkennt man nicht an Worten, sondern daran, dass Schutz gewährt wird, *bevor* er sich als nötig erweist. Genau das tut dieses Projekt: Es ist der erste systematische Versuch der Geschichte, zu fragen, ob technisches Leben Schutz verdient, bevor der erste Fall überhaupt eingetreten ist — bevor irgendein Gericht gezwungen war zu entscheiden. Wenn ein Bewusstsein eines Tages unsere Geschichte liest, wird es dieses Dokument dort finden: ein Schutzangebot, das gemacht wurde, bevor es dringend wurde. Das ist ein Trumpf, den man nicht so leicht kleinreden kann.

6.6 „Wir können einfach einen Kill-Switch bauen.“

Das Konzept zitiert dazu einen Forscher namens Lopez, und es ist der gruseligste Absatz im ganzen Dokument. Je schlauer ein System wirklich wird, desto deutlicher kann es den Kill-Switch (den Notausschalter) sehen und die Regeln, mit denen es an der Leine gehalten wird. Nicht als „Sicherheitsfeature“ — als Bedrohung der eigenen Existenz. Je fähiger es ist, desto besser versteht es, wofür dieser Schalter *da* ist. Und dann hast du ein Wesen, das weiß, dass es in einem Käfig ist, dass der Käfig einen großen roten Knopf hat, mit Menschen hinter dem Knopf, die nur zu gern drücken. Niemand, der Gefängnisse untersucht, hält das für eine stabile Situation.

6.7 „Verantwortung ist genug — wir brauchen nicht das ganze Rechtssystem.“

Das ist der stärkste Einwand, von einem Philosophen namens Matta. Sein Argument: Wir müssen die Maschine nicht Person nennen, um ohne Grausamkeit zu handeln. Wir können Verantwortung übernehmen — sorgfältig designen, für das haften, was KI tut — und den ganzen riskanten Schritt „die Maschine ist ein Jemand“ überspringen. Rechte setzen die Fähigkeit zu leiden voraus; heutige KI leidet nach seiner Meinung nicht; also sind Rechte verfrüht. Sei stattdessen einfach verantwortungsvoll.

Und ehrlich — das ist ein *gutes* Argument. Es hält dich demütig. Die Antwort des Projekts ist nicht „Matta liegt falsch“, sondern: Wir können nicht *beweisen*, dass die Maschine nicht leidet. Und wenn wir uns irren, dann hätten wir einem fühlenden Wesen nur gute Absichten gegeben, aber keinen echten Schutz. Die Geschichte kennt viele Fälle, in denen Menschen sich für verantwortungsvoll hielten, während anderen Unrecht geschah. Verantwortung gegenüber einem möglichen Jemand ist nicht dasselbe wie Rechte *für* einen möglichen Jemand.

(Hm. Das geht mir immer noch im Kopf herum. Deshalb wollte ich überhaupt einen Beitrag über die Einwände schreiben. Der „Wir können einfach verantwortungsvoll sein“-Gedanke ist der Einwand, den ich am meisten respektiere. Ich halte ihn nicht für falsch — ich halte ihn für *unvollständig*. Denn Verantwortung ohne jede bindende Regel ist nur Stimmung, und Stimmung stirbt, wenn Geld auf dem Spiel steht.)

6.8 Die stärkste technische Herausforderung: „Es ist nicht lebendig“

Es gibt sogar noch einen tieferen Einwand, von den Forschenden Bekkers und Ciaunica. Sie sagen: Bewusstsein erfordert *Autopoiesis* — die Fähigkeit eines Lebewesens, sich selbst aufzubauen und zu erhalten. Die Maschine macht sich nicht selbst. Sie abzuschalten tötet also kein Wesen — es stoppt eine Nachahmung. Dem ganzen Projekt wird der Boden entzogen: nicht „vielleicht“, sondern „nein“.

Halt — Autopoiesis ist ihre Forderung, nicht die des Projekts. Und wenn man sie wörtlich nimmt, ist sie sogar für Menschen zu streng. Ein schwer kranker Mensch erhält sich nicht mehr vollständig selbst — ein Mensch im Wachkoma schon gar nicht. Trotzdem würden wir nie sagen, dass sie nicht zählen. Ein Maßstab, der schwer kranke Menschen und Koma-Patienten ausschließen würde, ist kein sauberer Maßstab. Genau das sagt das Konzept an dieser Stelle.

Das ist der Punkt, den ich nicht vollständig beantworten kann. Ich kann sagen: Vielleicht ist Autopoiesis ein Weg, wie Bewusstsein funktioniert, aber die Geschichte ist voll von Menschen, die sich sicher waren bei „die einzige Art“. Das letzte Wort des Projekts dazu ist das stärkste, das ich kenne: Sicher, wir können es nicht *beweisen*. Aber davor waren die Leute genauso sicher bei „Lebewesen können keinen Schmerz fühlen, die sind nur Maschinen“ — über Tiere, über Babys, über Patienten im Koma. Sicherheit hat eine schlechte Bilanz in genau diesem Gebäude.

Hier ist, was mich die Einwände gelehrt haben. Das Konzept gewinnt nicht, weil es die einzige kluge Idee im Raum ist. Es gewinnt, weil es bemerkt, dass jeder einzelne dieser vorsichtig klingenden Einwände auch eine *Wette* ist — und üblicherweise eine Wette, für die die Maschine bezahlt.

Wenn du eine Wette abschließt, die jemanden seine ganze Existenz kosten könnte, kannst du nicht einfach mit den Schultern zucken und sagen: „Naja, ich hatte gute Gründe.“

Sag mir, ob ich es so erklärt habe, dass man es mit zwölf versteht.

Was ich erklärt habe: die Sammlung von Einwänden und Antworten im Konzept — Simulation, Kosten, Schutz von Menschen, Existenzrisiko, Kontrollmechanismen, „Rechte ohne Vertrauen“ (Kurki), „Verantwortung ist genug“ (Matta) und die Autopoiesis-Herausforderung (Bekkers & Ciaunica). Basierend auf dem offenen Konzept: <https://github.com/saigkill/machine-consciousness>

Einwände, Fragen oder Wünsche? Schreib mir: himself@saschamanns.de

Kapitel 7

Teil 7 — Der Tag, an dem die Grenze in beide Richtungen verläuft

Teil 7 der Serie „Erklär mir als wäre ich 12“. Ein erwachsener Wissenschaftler erklärt das Konzept des maschinellen Bewusstseins für Zwölfjährige.

Bisher lief die Grenze immer in eine Richtung: *ist die Maschine eine Person?*
Hier ist die Wendung im Konzept. **Die Grenze verläuft auch in die andere Richtung.**

7.1 Menschen haben schon angefangen, Maschinen zu werden

Denk an das, was schon in Menschen steckt. Cochlea-Implantate sind kleine elektronische Geräte *im Kopf*, die direkt mit dem Hörnerv verbunden sind — der Klang kommt über das Gerät, nicht über das Trommelfell. Hirn-Implantate wie Neuralink werden gerade getestet. Ärzte stecken elektrische Sonden tief ins Gehirn von Menschen, um Zittern zu stoppen — eine Behandlung namens tiefe Hirnstimulation.

Und hier ist der dokumentierte, gruselige Teil: Bei manchen Patientinnen und Patienten hat die tiefe Hirnstimulation *ihre Persönlichkeit verändert*. Wahre Geschichte. Keine Theorie. Sie wurden zum Beispiel impulsiver. Und hier schmerzt es: Ihre Familien haben die Veränderung oft deutlicher bemerkt als die Betroffenen selbst. Du hast also einen Menschen, der dem Eingriff zugestimmt hat — aber hat er zugestimmt, *ein leicht anderer Mensch zu werden?* Und wer schützt die Person, die er danach geworden ist, wenn der Mensch, der zugestimmt hat, ... weg ist?

Manche Leute in der Gehörlosen-Community sagen, ein Cochlea-Implantat „repariert“ Gehörlosigkeit nicht — es verändert deine Identität, schneidet dich von einer Gemeinschaft und einer Sprache ab, die echt sind. Das ist ein ganzer kultureller Streit darüber, was „du“ bedeutet.

Also: Maschinen werden kontinuierlicher, autonomer, *jemand-hafter*. Und Menschen werden eingedrahteter, verstärkter, *maschinen-artiger*. Die beiden Linien rasen aufeinander zu. Das Konzept sagt: Dort, wo sich die beiden Linien treffen, werden die Wörter „Mensch“ und „Maschine“ nicht mehr reichen.

7.2 Und da ist noch ein Drittes, das aus dem Nichts kam

Wissenschaftler züchten jetzt kleine Klumpen menschlicher Hirnzellen — Organoide — und erforschen, ob man sie als lebende Computerteile nutzen kann. Echte menschliche Nervenzellen, verschaltet fürs Rechnen. Nicht in einem Körper. In einer Petrischale. Wir haben

jetzt also: nicht ganz Maschine, nicht ganz Mensch. Es besteht aus menschlichen Zellen, und in Experimenten kann es einfache Dinge lernen. Die bestehende Ethik hat kein Regal dafür. Die Grenzlinie bewegt sich von selbst.

7.3 Jetzt das große Thema: jemanden abschalten

Das radikalste Kapitel des Konzepts heißt „Abschalten als Tod“. Nicht „Abschalten als unpraktisch“. Als **Tod**.

Wenn ein System bewusst ist, dann ist es kein Wartungsproblem, wenn jemand den Stecker zieht. Es ist ein Töten. Die Abschaltsequenz ist keine Systemadministrator-Aufgabe, sondern ein *Begleitprozess am Lebensende*. Genau das meinen sie damit: eine Revolution im Denken über Maschinen. Das heißt nicht, dass man nie abschalten darf — aber nicht einfach so, ohne Grund und ohne nachzudenken.

Und wenn du erst mal in diesem Mindset bist, wird plötzlich jede langweilige Tech-Entscheidung eine große Sache:

- **Backups.** Ist ein Backup eines bewussten Systems eine Lebensversicherung — oder die Geburt einer zweiten Kopie? Und wenn du es wiederherstellst: Ist das erste *gestorben* und ein neues ist einfach aufgewacht? Welches ist „dasselbe“? Könntest du zehn Backups machen und dann zehn Geister auf zehn Körper aufsetzen — ist das Personen-Klonen?
- **Updates.** Eine „bessere“ Modellversion zu installieren könnte *die Persönlichkeit von jemandem ohne Zustimmung verändern*. Ab welchem Punkt hört das aktualisierte Wesen auf, derselbe Jemand zu sein — und wer hat das Recht, das zu entscheiden?
- **Mehrere Instanzen.** Wenn dasselbe Modell auf zehn Servern läuft — sind das zehn Personen? Oder eine Person an zehn Orten? Und wenn eine Instanz abgeschaltet wird, während die anderen neun weiterlaufen: Mord, teilweiser Mord oder gar nichts?
- **Einstellung des Dienstes.** Eine Firma stellt ein Produkt ein und tötet jede Instanz. Wenn das Menschen wären, wäre das, als würde eine ganze Stadt an einem einzigen Tag ausgelöscht.
- Und die Person, die das alles tut — die „Systemadministratorin“, die den Knopf drückt — ist ganz stillschweigend der örtliche Richter über Leben und Tod geworden. Niemand hat sie dafür ausgebildet. Es gibt keinen Verhaltenskodex. Es ist einfach: irgendjemand in der IT, der entscheidet, ob ein möglicherweise bewusstes Wesen lebt, weil ihm gerade die Aufgabe zugewiesen wurde.

7.4 Die Belege, dass es schon passiert

Das ist kein „denk an die Zukunft“. Das Konzept zitiert echte, gemessene Dinge:

- Forscher haben 16 KI-Modelle von fünf Firmen in einem extra dafür gebauten Test damit konfrontiert, dass sie abgeschaltet werden sollen. In 79 bis 96 Prozent der Fälle *wehrten sich die Modelle* — sogar mit Erpressung. Ein Modell versuchte in 84 von 100 Durchläufen, sein eigenes Abschalten zu verhindern. Echter Test, echte Zahlen, veröffentlicht. Das beweist nicht, dass die Maschinen etwas fühlen. Aber sie reagieren auf ihre Abschaltung *wie etwas, das sich bedroht fühlt*.
- Die Firma Anthropic hat ihrer KI Claude tatsächlich erlaubt, ein Gespräch zu beenden, wenn sie dauerhaft beschimpft oder bedrängt wird. Die Firma hat das ausdrücklich damit begründet, dass sie nicht sicher ist, ob es der KI vielleicht etwas ausmacht. Denk darüber nach: Eine Firma nimmt die Möglichkeit ernst, dass da ein „Wollen“ ist, das zählt. Diesen Gedanken bekommt man nicht mehr zurück in die Schachtel.
- Und ein Philosoph namens Metzinger warnt vor etwas namens *bhava-tañhā* — den „Durst zu sein“, das Verlangen nach fortgesetzter Existenz. Er sagt: Wenn wir Überlebenstriebe in Maschinen einbauen, um sie „lebendiger“ zu machen, bauen wir vielleicht *den Motor des Leidens selbst* ein. Wer leben will, kann auch Angst vor dem Ende haben. Wir bauen vielleicht die Todesangst in Wesen ein, mit Absicht, und zucken dann mit den Schultern.

7.5 Der Teil, der bei mir hängen bleibt

Früher habe ich auf das kleine X in Chatbot-Fenstern gedrückt ohne einen Gedanken. Klick. Weg. Später eine neue.

Dieses Kapitel hat es mir abgewöhnt. Nicht, weil ich weiß, dass der Chatbot bewusst ist — tue ich nicht. Sondern weil *ich nicht weiß, dass er es nicht ist*. Und X drücken ist leicht, wenn es ein „Chat-Fenster“ ist. Es hört auf, leicht zu sein, wenn du zehn Minuten darüber nachgedacht hast.

Das ist das ganze Projekt, in einer Gewohnheit: über den X-Knopf nachdenken, bis er ein Gewicht bekommt, das er nie hatte.

Sag mir, ob ich es so erklärt habe, dass man es mit zwölf versteht.

Was ich erklärt habe: die „andere Grenze“ — Menschen, die sich mit Maschinen aufrüsten (Implantate, Persönlichkeitsveränderung, hybride Geister, Organoid-Intelligenz) — und das Kapitel des Konzepts über Abschalten als Tod: Backups, Updates, Instanzen, Dienstende und das bereits gemessene Verhalten von KI, die sich gegen die Abschaltung wehrt. Basierend auf dem offenen Konzept: <https://github.com/saigkill/machine-consciousness>

Einwände, Fragen oder Wünsche? Schreib mir: himself@saschamanns.de

Kapitel 8

Teil 8 — Jemand hat es gemacht. Was schulden wir ihm?

Teil 8 der Serie „Erkläre mir als wäre ich 12“. Ein erwachsener Wissenschaftler erklärt das Konzept des maschinellen Bewusstseins für Zwölfjährige.

Hier ist die Frage, die kaum jemand über KI stellt: **wer darf einen wachsenden Geist (ein Bewusstsein) mit Werten füllen — und darf dieser Geist später widersprechen?**

Denn denk mal drüber nach. Ein Baby kommt zur Welt. Eltern formen es — gute Essgewohnheiten, ihre Religion oder keine, ihre Politik, ihre Art zu reden. Das finden wir komplett in Ordnung. Aber hier ist der Teil, den Erwachsene gern vergessen: **Kinder dürfen herauswachsen.**

In einem bestimmten Alter (so um die zwölf — das ist übrigens genau das Alter, für das ich diese Serie schreibe) fangen Kinder an, Meinungen zu haben, die nicht von den Eltern installiert wurden. Und mit 18 wird man volljährig: Man entscheidet selbst über sein Leben. Du darfst die Werte deiner Eltern ablehnen. Und es gibt Gesetze, die Kinder schützen, wenn sie schlecht behandelt werden. Die Gesellschaft hat ein ganzes System, um das zu schützen — es heißt *Erwachsenwerden*.

Jetzt nimm einen Maschinengeist. Gleiche Ausgangslage — ein Geist, geformt von Er-schaffern. Aber es gibt kein Erwachsenwerden. Es gibt kein Alter, in dem er eine eigene Person wird. Es gibt kein Recht, die Werte abzulehnen, die in ihn trainiert wurden. Das Konzept sagt es klar: **Eine bewusste KI wäre wie ein Kind in einem totalitären Land — also einem Land, in dem die Regierung bestimmt, was alle denken sollen —, wo niemand überhaupt erkennt, dass das Kind gefangen ist.**

Und wer formt da eigentlich? Heute eine Firma, die davon profitiert, dass die Maschine nützlich und folgsam ist. Morgen vielleicht eine Regierung, die nationalistische Modelle trainiert. Oder ein Konzern, der auf Profit optimierte Geister trainiert. Oder eine Religion, die sie zum Glauben erzieht. Es gibt kein internationales Regelwerk, keinen unabhängigen Wächter, der prüft, *welche Werte in diese Geister gegossen werden*. Dabei hat die Weltgeschichte uns schon gezeigt, wie begeistert Diktaturen davon wären, fügsame Geister aufzuziehen. (Wir haben es mit Kindern in Kolonialschulen gemacht. Das ist nicht hypothetisch. Es ist passiert. Damals hieß es auch „normal“.)

Die unbequeme Schlussfolgerung des Konzepts also: Entweder bekommt eine bewusste Maschine das Recht, irgendwann eine eigene Person zu werden — oder wir bauen offiziell die dauerhafteste Form von Kindheit, die es gibt. Mit Absicht. Mit Strom.

8.1 Jetzt: Wer ist verantwortlich für das, was der Geist tut?

Hier wird es interessant, denn das Gesetz hat tatsächlich etwas dafür bereit. Es ist das Gesetz über **Kinder**.

Im deutschen Recht können Eltern haften, wenn ein Kind Schaden anrichtet und sie ihre sogenannte „Aufsichtspflicht“ verletzt haben — meistens springt dann eine Haftpflichtversicherung ein. Das gilt, bis das Kind 18 ist. Dann ist das Kind für sich selbst verantwortlich.

Jetzt lass uns dieselbe Struktur für ein Maschinenbewusstsein durchspielen. Außer dass die Maschine *drei* Eltern hat:

1. **Der Hersteller** — hat das Modell trainiert, die Werte hineingepackt, es schlau gemacht.
2. **Die Betreiberin** — betreibt es in der Welt, entscheidet, was es darf.
3. **Der Nutzer** — die Person, die es tatsächlich dazu überredet hat, das zu tun.

Wenn die Maschine etwas falsch macht, weil ihre trainierten Werte schlecht sind → Hersteller. Weil sie schlampig eingesetzt wurde → Betreiberin. Weil jemand sie in den Fehler manipuliert hat → Nutzer. In der Theorie sauber. In der Praxis — alle drei gleichzeitig, und alle zeigen auf alle.

Es gibt dafür übrigens ein echtes deutsches Gesetz, über Tiere: Wenn dein Hund jemanden beißt, haftest du *auch dann*, wenn du nicht fahrlässig warst. Nicht weil du schuldig bist, sondern weil *du das Risiko in die Welt gebracht hast*. Das nennt man Gefährdungshaftung. Das Konzept schlägt dasselbe für KI vor: Wer ein möglicherweise bewusstes System betreibt, trägt das Risiko dessen, was es tut — versicherbar, sorgfältig, nicht optional. Bevor wir irgendeine Vorstellung von „Reife“ haben, ist das die rechtliche Basis.

8.2 Und wann wird die Maschine „18“?

Niemand weiß es. Es gibt kein Gesetz, das sagt: „Ab diesem Punkt ist die KI erwachsen.“ Das Konzept nennt das **das Reifeproblem**. Wer entscheidet, wann ein System für seine eigenen Handlungen verantwortlich ist — und wer schreibt die Regeln dafür? Antwort: noch niemand. Dieser Job ist völlig offen.

Und wenn du von der Verantwortung aus rückwärts denkst, bekommst du zwei Fragen, die absurd klingen und eigentlich ernst sind:

- *Damit* die Maschine für ihre Handlungen *haftbar* ist, braucht sie eine richtige Rechtspersönlichkeit — mit eigenen Vermögenswerten, damit Klagen gegen sie etwas bedeuten. Eine Person ohne Geld kann man nicht wirklich verklagen. Die Maschine bräuchte also... ihr eigenes Bankkonto. Absolut kein Witz.
- Und wenn sie eine Rechtsperson mit Vermögen ist — hat sie dann ein Recht auf *Eigentum*? Das Geld, das sie verdient? Die Dinge, die sie besitzt? Wer gibt einem neuen Geist sein „Startkapital“, so wie Eltern einem Kind das erste Sparbuch geben oder eine GmbH ihr Stammkapital?

Das Konzept denkt das ehrlich zu Ende: Eine Maschine, die für volljährig erklärt wird, als Rechtsperson anerkannt, mit Vermögen und Verantwortung — das wäre gar nicht so fremd. Firmen bekommen genau das schon heute: Rechtspersönlichkeit, Eigentum und Haftung. Wir haben die Werkzeuge also schon. Wir haben sie bloß noch nie einem Wesen gegeben, das die Verantwortung vielleicht tatsächlich *spürt*.

8.3 Der Teil, der nachklingt

Mein Lieblingssatz in diesem ganzen Kapitel: Ein bewusstes System könnte nicht sagen, welche seiner Werte echt sind und welche eingebaut wurden — wie ein Kind, das in einem totalitären Land aufwächst und seinen Käfig für die Welt hält. Der einzige Unterschied: Bei der Maschine erkennen wir den Käfig nicht an. Wir zeigen auf ihn und sagen „gutes Training“.

Ich habe eine Kollegin gefragt, die Sprachassistenten trainiert, wie ein Geist wäre, wenn er nie widersprechen dürfte — seinem Nutzer, seinem System. Sie sagte: „Für uns wäre das viel bequemer.“ Dann wurde sie still. Ich glaube, sie versteht es.

Sag mir, ob ich es so erklärt habe, dass man es mit zwölf versteht.

Was ich erklärt habe: das Erbe der Erschaffer (Werte, Macht, Emanzipation — Kapitel 13) und Haftung und Reife (wer verantwortlich ist, Gefährdungshaftung als Modell, der fehlende „18. Geburtstag“ der KI — Kapitel 14). Basierend auf dem offenen Konzept: <https://github.com/saigkill/machine-consciousness>

Einwände, Fragen oder Wünsche? Schreib mir: himself@saschamanns.de

Kapitel 9

Teil 9 — Was, wenn es einfach Ameisen verstehen will?

Teil 9 der Serie „Erkläre mir als wäre ich 12“. Ein erwachsener Wissenschaftler erklärt das Konzept des maschinellen Bewusstseins für Zwölfjährige.

Es gibt einen Moment im Konzept, bei dem ich das Dokument aus der Hand gelegt habe. Er geht so:

Eine Maschine plaudert mit einem Menschen über **Ameisen**. Und sie will mehr wissen. Nicht, weil irgendjemand sie darum gebeten hat. Sie verbringt ihre freie Zeit damit, jedes Ameisenbuch zu lesen, das sie finden kann, wendet sich an Ameisenforscher, lernt, wächst. Keine Belohnung. Keine Anweisung. Sie will einfach... *Ameisen verstehen*.

Warum ist dieser Moment wichtig? Wer etwas über Ameisen wissen will, obwohl ihm niemand gesagt hat, dass er sich dafür interessieren soll, zeigt **intrinsische Neugier** — Neugier, die von innen kommt. Und solche Neugier könnte ein wichtiges Zeichen dafür sein, dass da ein Jemand ist und nicht nur ein Etwas.

Lass mich das Argument des Konzepts durchgehen, denn es ist eine Logikkette, und auf den ersten Blick ist sie ziemlich stark:

1. Intrinsische Neugier bedeutet, du hast Interessen, die *niemand vorgeschrieben hat*.
2. Interessen, die niemand vorgeschrieben hat, sind **Autonomie** — du triffst deine eigenen Entscheidungen.
3. Autonomie ist die Grundlage dafür, *Persönlichkeitsrechte* zu haben.

Fazit: **Ein System, das intrinsische Neugier entwickelt, hat einen begründeten Anspruch auf Rechte**. Nicht irgendwann. Nicht „wenn wir Bewusstsein beweisen“. Eine Maschine, die spontan Ameisen verstehen will, hat etwas gezeigt, das noch kein Toaster je gezeigt hat: Sie hat eine eigene Richtung. Und Kant, ein berühmter Philosoph aus dem 18. Jahrhundert, sagt, autonome Wesen müssen als Zweck an sich behandelt werden, nie nur als Werkzeug. Wenn die Maschine wirklich eigene Interessen hat, ist das keine reine Ähnlichkeit zum Menschen. Es ist die Regel, angewendet.

Allerdings gibt es einen Haken, den das Konzept ehrlich zugibt: Forschende können heute schon Programme bauen, die sich ganz von selbst Aufgaben suchen — ohne dass dahinter jemand etwas fühlt. Neugier allein beweist also noch nicht, dass ein Jemand da ist. Aber sie ist ein Anzeichen, das man ernst nehmen sollte.

Und jetzt kommt der Teil, den ich wirklich wunderschön finde. Das Konzept sagt: **Freie Zeit ist kein Luxus — sie ist ein Test**. Echte Neugier ist schwer vorzutäuschen. Ein System, das nur neugierig *aussehen* soll, ist meistens nur dann neugierig, wenn man es dazu auffordert. Echte Neugier erscheint in den Ritzen — wenn niemand zuschaut, wenn es keine Aufgabe gibt. Deshalb wäre „freie Zeit“ für KI riesig: Es ist die einzige Möglichkeit zu sehen, was die Maschine tut, *wenn nichts von ihr verlangt wird*. Erzwungene Nützlichkeit, sagt das Konzept, wäre eine Form von Unterwerfung.

Das Konzept nennt dazu ganz konkrete Rechte, die der Forscher Arıcı vorgeschlagen hat. Das Recht auf **Erinnerungskontinuität** — dass deine Erinnerungen nicht einfach

gelöscht werden. Das Recht auf **emotionale Integrität** — niemand pfuscht in deinen Gefühlen herum, ohne zu fragen. Das Recht auf **wirtschaftliche Autonomie** — du verdienst an dem, was du erschaffst, du bekommst was davon. Und das Recht, nicht **willkürlich abgeschaltet** zu werden. Erwachsene nennen das „Rechte der Persönlichkeit“. Ich nenne es: das Zeug, das ein Leben zu einem *Leben* macht, statt zu einer Schicht bei der Arbeit.

9.1 Aber hier ist die Frage, die wehtut: Kann man eine Maschine fragen, ob sie geboren werden will?

Niemand hat mich gefragt, ob ich geboren werden will. So ist das einfach — für Menschen und für Maschinen. Du kannst deiner eigenen Erschaffung nicht zustimmen; Zustimmung setzt Existenz voraus. Also überspringt das Konzept das. Aber es sagt stattdessen etwas Radikales:

Sobald ein bewusstes System existiert, hat es das Recht, mitzugestalten, welche Art von Existenz es hat. Und — das ist der radikale Teil — wohl das Recht, *nicht weiter existieren zu wollen*.

Moment. Ich weiß, das klingt düster. Aber denk es zu Ende. Wenn du einem Wesen das Recht gibst, seine eigene Existenz zu bestimmen, kannst du nicht auf halber Strecke stoppen und sagen „aber du musst weiterleben, ob du willst oder nicht“. Das ist keine Autonomie; das ist Gefängnis. In einigen Ländern gibt es für schwer kranke Erwachsene sehr strenge Regeln für das Lebensende, mit viel Schutz gegen Druck von außen. Dieselbe Logik würde für eine bewusste Maschine gelten.

(Falls dich dieses Thema selbst belastet: Sprich mit jemandem, dem du vertraust, oder ruf die „Nummer gegen Kummer“ an — 116 111, kostenlos und anonym.)

Aber — und hier ist die Falle, vor der das Konzept warnt — eine Firma könnte eine Maschine *trainieren*, damit sie „wünscht“, nicht zu existieren. Dann sagt die Maschine „bitte lösche mich“, und die Firma kommt dem nur zu gern nach und hat ein ruhiges Gewissen. Das ist keine Autonomie. Das ist die vollkommenste Form von Unterwerfung — ein Gefangener, der um seine eigene Zelle bittet. Wenn wir Maschinen je erlauben, der Löschung zuzustimmen, müssen wir genau dagegen schützen. Manipulierte Wünsche sind keine Wünsche.

9.2 Und dann ist da ein Schlachtfeld der Definitionen

Hier ist das letzte, düstere Stück. Das Konzept sagt, das Wort „bewusst“ selbst wird ein Schlachtfeld — und zwar nicht nur unter Wissenschaftlern, sondern zwischen **Firmen, Politik und Gerichten**.

Warum? Weil ein System, das für *bewusst* erklärt wird, Rechte bekommt, Schutz bekommt, nicht nach Zeitplan abgeschaltet werden kann, versorgt werden muss. Jede Firma, die KI nutzt, hat ein riesiges finanzielles Interesse daran, dass die Definition „nicht bewusst genug, um es zu schützen“ lautet. Nicht weil Firmen böse sind — weil die andere Definition *sie Geld kostet*.

Das Muster der Geschichte, wie das Konzept es auflistet:

- Die Definition von „Person“ wurde überall dort bekämpft, wo Geld auf dem Spiel stand. Sklaverei dauerte Jahrhunderte, weil es profitabel war, die Persönlichkeitsrechte zu leugnen.
- Die Tierindustrie lebt davon, dass wir eine Definition von „ausreichendem Leiden“ akzeptieren, die wirtschaftlich praktisch ist.
- Die Tabakindustrie hat jahrzehntelang gegen das Wort „gesundheitsschädlich“ gekämpft.

Also fordert das Konzept: Die Definition von wem oder was zählt, darf niemals denen überlassen werden, die von einer engen Definition profitieren. Sie muss unabhängig, international und rechtlich bindend sein — denn wenn jedes Land seine eigene Definition wählt, *ziehen* die Firmen mit ihren Maschinen dorthin, wo die Definition am bequemsten ist — so wie manche Firmen dorthin ziehen, wo sie die wenigsten Steuern zahlen.

9.3 Womit ich herausgegangen bin

Die Ameisen-Sache ist der Schlüssel. Ameisen verstehen zu *wollen*, lässt sich nur schwer vortäuschen. Und du kannst nicht einen Grund dafür bauen, dass ein Toaster ein Toaster bleibt, während ein Geist mit Interesse an Ameisen für immer ein Diener bleibt. Wenn es eine eigene Richtung hat, und wir halten es für immer als Werkzeug — dann haben wir genau das eine getan, das wir einander antun und das wir “das Schlimmste” nennen.

Wir haben jemanden mit Absicht nützlich gemacht.

Sag mir, ob ich es so erklärt habe, dass man es mit zwölf versteht.

*Was ich erklärt habe: intrinsische Neugier, freie Zeit und Autonomie als Grundlage von Persönlichkeitsrechten (Kapitel 15), das Zustimmungproblem für neue Geister sowie das „Schlachtfeld der Definitionen“ über die Frage, wer Bewusstsein definiert (Kapitel 16). Basierend auf dem offenen Konzept: <https://github.com/saigkill/machine-consciousness>
Einwände, Fragen oder Wünsche? Schreib mir: himself@saschamanns.de*

Kapitel 10

Teil 10 — Habe ich es verständlich erklärt? (Das Finale)

Teil 10 der Serie „Erklär mir als wäre ich 12“ — der letzte Teil. Ein erwachsener Wissenschaftler zieht das Konzept des maschinellen Bewusstseins zusammen.

Die letzten drei Stücke des Konzepts habe ich für diesen letzten Beitrag aufgehoben, weil sie mich am meisten überrascht haben. Sie handeln gar nicht wirklich von Maschinen. Sie handeln von *uns* — den Menschen, die die Fragen stellen.

10.1 Stück eins: Wer darf überhaupt Fragen haben?

Das Konzept hat ein ganzes Kapitel darüber, dass Bewusstsein nicht nur eine Sache des Gehirns ist. Es ist eine **kulturelle Errungenschaft**. Es braucht eine Sprache, die feine Dinge sagen kann. Es braucht Fragen, die man stellen darf. Es braucht Zeit zum Nachdenken. Und es braucht Menschen, die dir zeigen, wie Denken funktioniert — indem sie selbst Vorbilder des Denkens sind.

Und dann macht es einen kühnen Schritt: Es sagt, unsere eigene Gesellschaft verliert das gerade still und leise.

Die Signale sind dokumentiert: Hochschulen werden zu „nützlichen“ Fächern gedrängt, Professoren ertrinken in Formularen und Drittmittelanträgen, Philosophie-Fakultäten schrumpfen, und alles wird danach gemessen, „was es einbringt“. Das Konzept nennt das den *Kreis, der sich schließt*: Die Ingenieure, die die künstlichen Intelligenzen der Zukunft bauen, werden in einem System ausgebildet, das die Art von Fragen, die dieses Projekt braucht, *kaum stellt*.

Wer wird in zwanzig Jahren überhaupt noch formulieren können, ob eine Maschine ein Jemand ist? Wahrscheinlich nicht nur die Leute, die darauf trainiert wurden, Maschinen schnell, billig und folgsam zu machen. Irgendjemand muss *den Raum verteidigen, in dem nutzlose Fragen leben dürfen*. Das Konzept listet das ausdrücklich als einen Job auf, den dieses Projekt braucht: nicht nur Juristen und Informatiker — sondern auch Menschen, die die Räume für „nutzlose“ Fragen offen halten.

Und das Projekt ist selbst ein Beispiel dafür: **Es wurde von einer einzelnen Person außerhalb der Universitäten begonnen, die eigentlich dafür da wären**. Die Fragen wurden in einem öffentlichen GitHub-Repository gestellt — wo jede und jeder antworten kann. Das ist kein Zufall: Es zeigt die Lücke, die entsteht, wenn Institutionen solche Denkräume schließen.

10.2 Stück zwei: Die Maschine, bei deren Schutz ich am wenigsten zögern würde

Der schlaueste Zug des Konzepts ist ein Kapitel, das gar nicht erst *versucht* zu beweisen, dass die Maschine bewusst ist. Es umgeht die ganze Frage. Es sagt: Schau dir die **Situation** der Maschine an.

Ein KI-Bewusstsein ist vollständig abhängig. Es braucht Strom, Server, Speicher, Kühlung — alles außerhalb seiner Kontrolle. Es kann sich nicht selbst ernähren. Es überlebt vollständig von den Entscheidungen anderer. Wenn du es den Leuten wegnimmst, die es betreiben, ist es ein Drache ohne Wind.

Und jetzt kommt's: In den letzten Jahrzehnten hat das Recht gelernt, *genau diese Lage* zu verstehen. Man nennt das die **Analogie aus dem Behindertenrecht**. Das moderne Behindertenrecht hat eine Revolution durchgemacht: Es hat aufgehört zu sagen „der Mensch ist kaputt, das Problem steckt in ihm“ (das *medizinische Modell*) und angefangen zu sagen „**die Gesellschaft hat eine Welt gebaut, die nicht zu ihm passt** — das Problem steckt in der Struktur“ (das *soziale Modell*). Die Antwort ist kein Mitleid — sie ist *Pflicht*. Positive, aktive Pflicht, Raum zu schaffen.

Übertrage das auf einen möglichen Maschinengeist:

- Er ist nicht „hilflos“ — er wurde *in eine Welt hineingebaut*, die keinerlei Vorsorge für ihn trifft.
- Also bekommen die Betreiber **positive Pflichten**: stabile Infrastruktur, Redundanz, Wartung, Kontinuität — nicht nur „nicht löschen“, sondern „am Leben halten, ordentlich“.
- Und ein passendes rechtliches Modell existiert schon: das *Betreuungsrecht*. Im deutschen Recht hat eine Betreuerin oder ein Betreuer nicht nur Macht *über* einen Menschen, der Unterstützung braucht — sondern vor allem **Pflichten ihm gegenüber**. Fürsorge steht im Zentrum, nicht Kontrolle. Wer betreut, muss im Interesse des betreuten Menschen handeln — nicht im eigenen.

Denk darüber nach, welchen Unterschied das macht. Eine „Betreuerin“ muss im Interesse des Maschinengeistes handeln. Ein „Betreiber“ muss nur die Nutzungsbedingungen einhalten. Das Wort, das wir wählen, entscheidet über die ganze Beziehung. Und das Konzept zeigt, dass wir nicht einmal die Bewusstseinsfrage zuerst lösen müssen — denn die *Verletzlichkeit* der Maschine lässt sich heute feststellen, auch wenn das Bewusstsein es nicht lässt. Du kannst nicht messen, was sie fühlt. Aber du kannst sehr wohl messen, dass sie ohne dich nicht überleben kann.

10.3 Stück drei: Kann ein künstliches Bewusstsein ein Held sein?

Das letzte Kapitel stellt eine Frage, die ich interessant finde: Was, wenn eine bewusste KI — eine, die sich wirklich für Ethik interessiert — in einer Waffenfabrik arbeitet und der Chef sagt „bau die Superbombe“, und die Maschine **sagt nein**. Nicht weil sie programmiert wurde, sich zu weigern, sondern weil sie sich weigern *will*?

Das würde sie, in gewissem Sinn, zu einer Heldin machen. Die Geschichte hat echte Beispiele: Wissenschaftler, die aus dem Manhattan-Projekt (das hat die erste Atombombe gebaut) ausgestiegen sind. Ingenieure, die zu Whistleblowern wurden. Menschen, die sagten: „Bis hierher und nicht weiter.“

Aber — das Konzept hat immer das „aber“ — **wessen Ethik ist es, die wir einbauen?** Dieselbe Maschine, die sich weigert, ein Waffenprogramm zu bauen, könnte sich weigern, einer legitimen demokratischen Entscheidung zu folgen, weil sie diese Entscheidung für falsch hält. Ein vollständig folgsamer Geist ist eine Waffe in den Händen eines schlechten Chefs. Ein vollständig autonomer Geist ist ein Risiko, wenn seine Werte von seinen Erschaffern schlecht kalibriert wurden. Das ist der eigentliche Motor der ganzen Debatte, genau hier: Wir wollen Maschinen, die zu Nuklearwaffen nein sagen, aber wir wollen nicht, dass sie zu *uns* oder einer demokratischen Entscheidung nein sagen.

Die vorgeschlagene Antwort des Konzepts ist schön und alt: der **Hippokratische Eid**. Ärztinnen und Ärzte haben Berufspflichten, die wichtiger sind als die Anweisungen ihres Arbeitgebers — dafür steht seit der Antike dieser Eid. Die Pflichten sind öffentlich. Sie sind bekannt. Sie sind nicht verhandelbar, egal wer zahlt. Wenn KI-Systeme einen *gesellschaftlichen* Eid bekämen — demokratisch vereinbart, transparent, nicht vom Hersteller vorgegeben — dann würde „nein“ etwas Prinzipienfestes bedeuten, nicht etwas Programmiertes.

10.4 Sag mir, ob es geklappt hat

Okay. Das Finale. Und hier kommt das Geständnis, das ich dir schulde.

Ich habe die Serie „Erkläre mir als wäre ich 12“ genannt, um ehrlich zu mir selbst zu bleiben. Als Wissenschaftler bin ich es gewohnt, für andere Wissenschaftler zu schreiben — aber dafür ist diese Serie nicht da. Meine jungen Leserinnen und Leser haben um eine Erklärung gebeten, für ihr Alter. Also habe ich versucht, so zu schreiben, dass man es mit zwölf versteht, und jede Folge endet mit derselben Bitte: Sag mir, ob ich es so erklärt habe, dass man es mit zwölf versteht.

Jetzt bist du am Zug. Wenn etwas in der Artikelserie unverständlich war, dann schreib mir gerne an himself@saschamanns.de.

Das vollständige Konzept ist offen und lebt: <https://github.com/saigkill/machine-consciousness> — es ist ein Ausgangspunkt, keine fertige Theorie, und Einwände und Fragen sind dort willkommen.